

Regressão Multivariada: Perfil de Usuários Vulneráveis em Sinistros de Trânsito

Infosiga.SP — Sistema de Informações Gerenciais de Sinistros de Trânsito (2022–2025)

Matheus

02 de Junho de 2026

Contents

1	Introdução	2
1.1	Tema	2
1.2	A estrutura do problema	2
1.3	Variáveis-resposta	2
2	Preparação dos dados	3
2.1	Leitura e diagnóstico inicial	3
2.2	Filtros	3
2.3	Construção das respostas e agregação	4
2.4	Filtro de robustez e variáveis derivadas	4
3	Análise descritiva	6
3.1	Desfechos e correlações	6
3.2	Boxplots dos desfechos	6
3.3	Dispersão: preditor de exposição vs. desfechos	7
4	Diagnósticos pré-regressão	8
4.1	Normalidade multivariada dos desfechos	8
5	Ajuste da regressão multivariada	9
6	Testes de hipótese multivariados	12
7	Decomposição manual: matrizes B, Σ, H e E	14
8	Diagnóstico dos resíduos multivariados	15
8.1	Colinearidade (VIF)	15
8.2	Outliers multivariados (distância de Mahalanobis)	15
8.3	Visualização dos resíduos multivariados	15
8.4	Coefficientes estimados por desfecho	16
9	Resultados substantivos	17

10 Limitações e conclusão	18
10.1 Limitações	18
10.2 Conclusão	18

1 Introdução

1.1 Tema

Este trabalho aplica **regressão linear multivariada** a dados de sinistros de trânsito do estado de São Paulo. O objetivo é investigar se fatores estruturais — tipo de via, região administrativa, volume de sinistros e tempo — afetam de forma diferenciada três categorias de usuário vulnerável: **pedestres, ciclistas e motociclistas**.

A escolha do tema decorre da disponibilidade pública de dados ricos do **Infosiga.SP**, mantido pela Coordenadoria Geral de Segurança Viária do Detran-SP, e da adequação natural do problema à regressão multivariada: três desfechos correlacionados, medidos sobre as mesmas unidades, com fatores estruturais comuns como preditores.

1.2 A estrutura do problema

A pergunta poderia, em princípio, ser respondida por três regressões univariadas independentes — uma por resposta. Essa abordagem, contudo, ignora que os três desfechos são correlacionados (emergem do mesmo sistema viário) e que testar o efeito de um fator sobre o vetor de respostas **como um todo** exige estatísticas que considerem a covariância entre elas (Wilks, Pillai, Lawley-Hotelling, Roy). A regressão multivariada fornece esse arcabouço.

1.3 Variáveis-resposta

As três respostas, todas em escala $\log(1 + y)$ para estabilização de variância:

- Y_1 : n° de sinistros não fatais com **pedestres** envolvidos
- Y_2 : n° de sinistros não fatais com **ciclistas** envolvidos
- Y_3 : n° de sinistros não fatais com **motociclistas** envolvidos

Nota de interpretação. Y_k conta sinistros em que a categoria k esteve *presente*, não necessariamente em que ela foi a vítima ferida. Esta limitação é retomada na Seção 10.

2 Preparação dos dados

A base do Infosiga é distribuída em formato *parquet*, com uma linha por sinistro registrado. A unidade de análise do modelo será a **célula**, definida pelo cruzamento de região administrativa $\times$ ano-mês $\times$ tipo de via.

```
library(arrow)      # leitura de parquet
library(dplyr)      # manipulação
library(car)        # vif()
library(ggplot2)    # gráficos
```

2.1 Leitura e diagnóstico inicial

```
sinistros <- read_parquet("C:/Users/Matheus/Desktop/Arquivos_PUC/sinistros_2022-2026.parquet")
```

```
dim(sinistros)
```

```
## [1] 841984      48
```

```
table(sinistros$tipo_registro)
```

```
##
```

```
##      NOTIFICACAO      SINISTRO FATAL SINISTRO NAO FATAL
##           302310           23527           516147
```

```
table(sinistros$tipo_via)
```

```
##
```

```
## ESTRADAS E RODOVIAS      NAO DISPONIVEL      VIAS URBANAS
##           134646           3186           704152
```

A base traz **841.984 sinistros** entre 2022 e 2025, em 48 variáveis. Convivem três tipos de registro: não fatais (com vítimas feridas, 61%), notificações (registros sem boletim formal, 36%) e fatais (3%). Quanto à via, predominam as urbanas (84%) sobre estradas e rodovias (16%).

2.2 Filtros

Mantêm-se apenas sinistros **não fatais** com tipo de via conhecido. Fatais são categoria substantivamente distinta (óbitos, não ferimentos); notificações carregam viés de subnotificação.

```
base <- sinistros %>%
  filter(
    tipo_registro == "SINISTRO NAO FATAL",
    tipo_via %in% c("VIAS URBANAS", "ESTRADAS E RODOVIAS")
  )
dim(base)
```

```
## [1] 516126      48
```

Restam **516.126 sinistros** (61% da base original).

2.3 Construção das respostas e agregação

As colunas `qtd_pedestre`, `qtd_bicicleta` e `qtd_motocicleta` registram o número de envolvidos de cada categoria, mas usam NA (não zero) quando a categoria não aparece no sinistro. Ou seja, **NA significa “categoria ausente”**. Por isso, a operação correta para construir as respostas agregadas é contar *quantos sinistros tiveram cada categoria presente* (contar não-NA), não somar valores.

```
celulas <- base %>%
  mutate(
    tem_pedestre = as.integer(!is.na(qtd_pedestre)),
    tem_bicicleta = as.integer(!is.na(qtd_bicicleta)),
    tem_motocicleta = as.integer(!is.na(qtd_motocicleta))
  ) %>%
  group_by(regiao_administrativa, ano_mes_sinistro, tipo_via) %>%
  summarise(
    n_sinistros = n(),
    y1_ped = sum(tem_pedestre),
    y2_cic = sum(tem_bicicleta),
    y3_mot = sum(tem_motocicleta),
    .groups = "drop"
  )

dim(celulas)

## [1] 1664    7
head(celulas, 6)
```

```
## # A tibble: 6 x 7
##   regiao_administrativa ano_mes_sinistro tipo_via      n_sinistros y1_ped y2_cic
##   <chr>                <chr>        <chr>          <int>  <int>  <int>
## 1 ARAÇATUBA            2022/01      ESTRADAS E R~        24      0      0
## 2 ARAÇATUBA            2022/01      VIAS URBANAS        188      6     13
## 3 ARAÇATUBA            2022/02      ESTRADAS E R~        20      0      1
## 4 ARAÇATUBA            2022/02      VIAS URBANAS       252      6     18
## 5 ARAÇATUBA            2022/03      ESTRADAS E R~        40      0      3
## 6 ARAÇATUBA            2022/03      VIAS URBANAS       315     10     33
## # i 1 more variable: y3_mot <int>
```

A agregação produz **1.664 células**.

2.4 Filtro de robustez e variáveis derivadas

Células com pouquíssimos sinistros tornam as contagens instáveis. Aplica-se um piso de **30 sinistros por célula**. Em seguida, constroem-se as respostas em escala log, o controle de exposição `log_n`, o índice de tempo `t` (meses desde jan/2022) e o fator de região com referência na Metropolitana de São Paulo.

```
celulas_f <- celulas %>%
  filter(n_sinistros >= 30) %>%
  mutate(
```

```

log_y1 = log1p(y1_ped),
log_y2 = log1p(y2_cic),
log_y3 = log1p(y3_mot),
log_n  = log(n_sinistros),
ano    = as.integer(substr(ano_mes_sinistro, 1, 4)),
mes    = as.integer(substr(ano_mes_sinistro, 6, 7)),
t      = (ano - 2022) * 12 + mes,
regiao = relever(factor(regiao_administrativa),
                  ref = "METROPOLITANA DE SÃO PAULO"),
tipo_via = factor(tipo_via)
)

dim(celulas_f)

```

```
## [1] 1433 15
```

```
summary(celulas_f$n_sinistros)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      30.0   62.0   202.0   356.9   368.0   4196.0
```

Sobram **1.433 células** (86% da agregação), com mediana de 202 sinistros por célula — tamanho confortável para inferência multivariada.

3 Análise descritiva

3.1 Desfechos e correlações

A correlação entre os desfechos justifica o modelo conjunto; a correlação entre preditores antecipa a discussão de multicolinearidade.

```
# Correlação entre as respostas (escala log): justifica o modelo conjunto
round(cor(celulas_f[, c("log_y1", "log_y2", "log_y3")]), 3)
```

```
##          log_y1 log_y2 log_y3
## log_y1  1.000  0.792  0.926
## log_y2  0.792  1.000  0.786
## log_y3  0.926  0.786  1.000
```

```
# Correlação dos desfechos com o controle de exposição
```

```
round(cor(celulas_f[, c("log_y1", "log_y2", "log_y3", "log_n")]), 3)
```

```
##          log_y1 log_y2 log_y3 log_n
## log_y1  1.000  0.792  0.926  0.927
## log_y2  0.792  1.000  0.786  0.787
## log_y3  0.926  0.786  1.000  0.984
## log_n   0.927  0.787  0.984  1.000
```

As três respostas exibem correlações altas (0,79 a 0,93). Boa parte dessa associação, porém, vem de um **componente comum de exposição**: as correlações de cada resposta com `log_n` também são altíssimas (0,79 a 0,98). Esse é o motivo central de incluir `log_n` como controle — sem ele, o modelo atribuiria efeitos parecidos às três respostas, refletindo apenas o tamanho da célula.

3.2 Boxplots dos desfechos

```
vars_desfecho <- c("log_y1", "log_y2", "log_y3")
rotulos <- c(log_y1 = "Pedestres", log_y2 = "Ciclistas", log_y3 = "Motociclistas")

df_long <- do.call(rbind, lapply(vars_desfecho, function(v) {
  data.frame(variavel = rotulos[v], valor = celulas_f[[v]])
}))

ggplot(df_long, aes(x = variavel, y = valor, fill = variavel)) +
  geom_boxplot(alpha = 0.8, outlier.color = "white",
               outlier.size = 1, linewidth = 0.4) +
  scale_fill_manual(values = c("Pedestres" = cor_laranja,
                               "Ciclistas" = "gray60",
                               "Motociclistas" = cor_clara)) +
  labs(title = "Distribuição dos desfechos (escala log)",
       subtitle = "Infosiga.SP - 1.433 células (região × mês × tipo de via)",
       x = NULL, y = "log(1 + nº de sinistros)", fill = NULL) +
  tema_escuro + theme(legend.position = "none")
```

Motociclistas têm nível muito superior (mediana em torno de 4,8 na escala log, contra ~1,9 das demais), refletindo a presença massiva de motocicletas nos sinistros do estado.

3.3 Dispersão: preditor de exposição vs. desfechos

```
df_sc <- do.call(rbind, lapply(vars_desfecho, function(v) {
  data.frame(desfecho = rotulos[v], x = celulas_f$log_n, y = celulas_f[[v]])
}))

ggplot(df_sc, aes(x = x, y = y)) +
  geom_point(color = cor_laranja, alpha = 0.4, size = 1.2) +
  geom_smooth(method = "lm", color = "white", linewidth = 0.7, se = FALSE) +
  facet_wrap(~desfecho, scales = "free_y") +
  labs(title = "Relação entre volume de sinistros (log_n) e desfechos",
       subtitle = "Linha branca = tendência linear",
       x = "log(nº de sinistros na célula)", y = NULL) +
  tema_escuro
```

A relação quase perfeita entre `log_n` e motociclistas antecipa o R^2 elevado dessa resposta — sinistros com moto são quase uma fração fixa do total.

4 Diagnósticos pré-regressão

4.1 Normalidade multivariada dos desfechos

Avalia-se a normalidade multivariada via distância de Mahalanobis comparada à distribuição qui-quadrado de referência (teste de Kolmogorov-Smirnov).

```
Y_desc <- as.matrix(celulas_f[, vars_desfecho])
xbar   <- colMeans(Y_desc)
S_inv  <- solve(cov(Y_desc))
d2     <- apply(Y_desc, 1, function(x) t(x - xbar) %*% S_inv %*% (x - xbar))
```

```
ks.test(d2, "pchisq", df = length(vars_desfecho))
```

```
##
## Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  d2
## D = 0.081698, p-value = 9.847e-09
## alternative hypothesis: two-sided
```

O teste rejeita a normalidade multivariada ($p < 0,001$), o que é esperado dado o acúmulo de zeros em pedestres e ciclistas (células onde a categoria não apareceu). Como será discutido na Seção 6, o traço de Pillai é robusto a esse tipo de desvio, e o tamanho amostral ($n = 1433$) sustenta a inferência assintótica.

5 Ajuste da regressão multivariada

O ajuste usa `lm()` com `cbind()` no lado esquerdo da fórmula — é o `cbind` que sinaliza ao R tratar-se de regressão multivariada (múltiplas respostas).

```
fit <- lm(
  cbind(log_y1, log_y2, log_y3) ~ tipo_via + log_n + t + regioao,
  data = celulas_f
)

coef(fit)[1:4, ]    # coeficientes principais (uma coluna por desfecho)
```

```
##              log_y1      log_y2      log_y3
## (Intercept)   -1.719314683 -3.63324424 0.236201581
## tipo_viaVIAS URBANAS  0.925472962  0.43002339 0.499073419
## log_n          0.796212902  0.93484509 0.860969759
## t              -0.005969745 -0.01502966 0.002177758
```

```
summary(fit)      # resumo por equação (nível univariado)
```

```
## Response log_y1 :
##
## Call:
## lm(formula = log_y1 ~ tipo_via + log_n + t + regioao, data = celulas_f)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.65404 -0.23067  0.02144  0.25106  1.35551
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -1.7193147  0.2118265  -8.117 1.03e-15 ***
## tipo_viaVIAS URBANAS  0.9254730  0.0491578  18.827 < 2e-16 ***
## log_n          0.7962129  0.0310835  25.615 < 2e-16 ***
## t              -0.0059697  0.0007627  -7.827 9.72e-15 ***
## regioaoARAÇATUBA   -1.1601406  0.1004943 -11.544 < 2e-16 ***
## regioaoBAIXADA SANTISTA -0.5139060  0.0834543  -6.158 9.59e-10 ***
## regioaoBARRETOS    -1.2678224  0.1221877 -10.376 < 2e-16 ***
## regioaoBAURU       -0.9503375  0.0953648  -9.965 < 2e-16 ***
## regioaoCAMPINAS    -0.7879399  0.0593870 -13.268 < 2e-16 ***
## regioaoCENTRAL     -0.9851522  0.0982039 -10.032 < 2e-16 ***
## regioaoFRANCA      -0.9533106  0.1066232  -8.941 < 2e-16 ***
## regioaoITAPEVA     -0.8032904  0.1229105  -6.536 8.82e-11 ***
## regioaoMARÍLIA     -0.9470458  0.0928109 -10.204 < 2e-16 ***
## regioaoPRESIDENTE PRUDENTE -0.8428596  0.0961615  -8.765 < 2e-16 ***
## regioaoREGISTRO    -0.7152983  0.1121388  -6.379 2.41e-10 ***
## regioaoRIBEIRÃO PRETO -0.9444608  0.0908164 -10.400 < 2e-16 ***
## regioaoSÃO JOSÉ DO RIO PRETO -0.9752253  0.0804286 -12.125 < 2e-16 ***
## regioaoSÃO JOSÉ DOS CAMPOS -0.4510831  0.0735985  -6.129 1.14e-09 ***
```

```

## regioaSOROCABA          -0.7682588  0.0718980 -10.685  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3987 on 1414 degrees of freedom
## Multiple R-squared:  0.9178, Adjusted R-squared:  0.9168
## F-statistic: 877.5 on 18 and 1414 DF,  p-value: < 2.2e-16
##
##
## Response log_y2 :
##
## Call:
## lm(formula = log_y2 ~ tipo_via + log_n + t + regioa, data = celulas_f)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.5678 -0.2452  0.0979  0.3820  1.4159
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -3.633244    0.335745 -10.821  < 2e-16 ***
## tipo_viaVIAS URBANAS    0.430023    0.077915  5.519 4.05e-08 ***
## log_n          0.934845    0.049267  18.975  < 2e-16 ***
## t             -0.015030    0.001209 -12.433  < 2e-16 ***
## regioaARAÇATUBA    1.171452    0.159284  7.355 3.23e-13 ***
## regioaBAIXADA SANTISTA 1.296018    0.132275  9.798  < 2e-16 ***
## regioaBARRETOS     1.080150    0.193667  5.577 2.92e-08 ***
## regioaBAURU        0.585675    0.151153  3.875 0.000112 ***
## regioaCAMPINAS     0.412457    0.094128  4.382 1.26e-05 ***
## regioaCENTRAL      0.804897    0.155653  5.171 2.66e-07 ***
## regioaFRANCA       0.971343    0.168998  5.748 1.11e-08 ***
## regioaITAPEVA      0.748529    0.194813  3.842 0.000127 ***
## regioaMARÍLIA      0.894016    0.147105  6.077 1.57e-09 ***
## regioaPRESIDENTE PRUDENTE 0.916981    0.152416  6.016 2.27e-09 ***
## regioaREGISTRO     1.141556    0.177740  6.423 1.83e-10 ***
## regioaRIBEIRÃO PRETO 0.741484    0.143944  5.151 2.95e-07 ***
## regioaSÃO JOSÉ DO RIO PRETO 0.660414    0.127479  5.181 2.53e-07 ***
## regioaSÃO JOSÉ DOS CAMPOS 1.207607    0.116654 10.352  < 2e-16 ***
## regioaSOROCABA     0.354834    0.113958  3.114 0.001885 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.6319 on 1414 degrees of freedom
## Multiple R-squared:  0.7571, Adjusted R-squared:  0.754
## F-statistic: 244.9 on 18 and 1414 DF,  p-value: < 2.2e-16
##
##
## Response log_y3 :

```

```
##
## Call:
## lm(formula = log_y3 ~ tipo_via + log_n + t + regiao, data = celulas_f)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.72149 -0.08252  0.01434  0.10574  0.36105
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      0.2362016   0.0775062    3.048  0.00235 **
## tipo_viaVIAS URBANAS      0.4990734   0.0179866   27.747 < 2e-16 ***
## log_n            0.8609698   0.0113733   75.701 < 2e-16 ***
## t                0.0021778   0.0002791    7.804 1.16e-14 ***
## regiaoARAÇATUBA      -0.5201882   0.0367704  -14.147 < 2e-16 ***
## regiaoBAIXADA SANTISTA -0.2286650   0.0305355   -7.488 1.22e-13 ***
## regiaoBARRETOS       -0.6521029   0.0447078  -14.586 < 2e-16 ***
## regiaoBAURU          -0.5774390   0.0348935  -16.549 < 2e-16 ***
## regiaoCAMPINAS       -0.2265056   0.0217294  -10.424 < 2e-16 ***
## regiaoCENTRAL        -0.5475471   0.0359323  -15.238 < 2e-16 ***
## regiaoFRANCA         -0.5450004   0.0390129  -13.970 < 2e-16 ***
## regiaoITAPEVA        -0.6998985   0.0449723  -15.563 < 2e-16 ***
## regiaoMARÍLIA        -0.4594026   0.0339590  -13.528 < 2e-16 ***
## regiaoPRESIDENTE PRUDENTE -0.5191120   0.0351850  -14.754 < 2e-16 ***
## regiaoREGISTRO       -0.9316263   0.0410310  -22.705 < 2e-16 ***
## regiaoRIBEIRÃO PRETO  -0.4605570   0.0332293  -13.860 < 2e-16 ***
## regiaoSÃO JOSÉ DO RIO PRETO -0.4065977   0.0294284  -13.817 < 2e-16 ***
## regiaoSÃO JOSÉ DOS CAMPOS -0.3188378   0.0269293  -11.840 < 2e-16 ***
## regiaoSOROCABA       -0.3226215   0.0263071  -12.264 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1459 on 1414 degrees of freedom
## Multiple R-squared:  0.9866, Adjusted R-squared:  0.9864
## F-statistic: 5784 on 18 and 1414 DF, p-value: < 2.2e-16
```

Os coeficientes de determinação são **0,92 (pedestres)**, **0,76 (ciclistas)** e **0,99 (motociclistas)**. O valor quase perfeito de motociclistas reflete o papel dominante de `log_n`: como motocicletas estão na maioria dos sinistros, a contagem com moto é quase função determinística do total.

Um ponto conceitual importante: cada coluna de $\hat{\mathbf{B}}$ é **idêntica** à que se obteria ajustando aquela resposta isoladamente por OLS. A informação genuinamente multivariada não está nos coeficientes, e sim na matriz de covariância dos resíduos $\hat{\Sigma}$ — base dos testes conjuntos.

6 Testes de hipótese multivariados

Os testes a seguir avaliam a significância conjunta de cada preditor sobre o vetor (Y_1, Y_2, Y_3) . Todas as quatro estatísticas derivam dos autovalores da matriz $\mathbf{HE}^{-1}$ (hipótese sobre erro), combinados de formas diferentes: Wilks via produto, Pillai via soma de proporções, Lawley-Hotelling via soma simples, Roy via maior autovalor.

```
fit_manova <- manova(
  cbind(log_y1, log_y2, log_y3) ~ tipo_via + log_n + t + regiao,
  data = celulas_f
)
```

```
summary(fit_manova, test = "Wilks") # Lambda de Wilks
```

```
##              Df    Wilks approx F num Df den Df    Pr(>F)
## tipo_via      1 0.02651  17286.8      3 1412.0 < 2.2e-16 ***
## log_n         1 0.01728  26768.0      3 1412.0 < 2.2e-16 ***
## t             1 0.75802   150.2      3 1412.0 < 2.2e-16 ***
## regiao       15 0.39237    34.5     45 4195.5 < 2.2e-16 ***
## Residuals 1414
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
summary(fit_manova, test = "Pillai") # Traço de Pillai
```

```
##              Df   Pillai approx F num Df den Df    Pr(>F)
## tipo_via      1 0.97349  17286.8      3 1412 < 2.2e-16 ***
## log_n         1 0.98272  26768.0      3 1412 < 2.2e-16 ***
## t             1 0.24198   150.2      3 1412 < 2.2e-16 ***
## regiao       15 0.77806    33.0     45 4242 < 2.2e-16 ***
## Residuals 1414
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
summary(fit_manova, test = "Hotelling-Lawley") # Traço de Lawley-Hotelling
```

```
##              Df Hotelling-Lawley approx F num Df den Df    Pr(>F)
## tipo_via      1          36.728  17286.8      3 1412 < 2.2e-16 ***
## log_n         1          56.873  26768.0      3 1412 < 2.2e-16 ***
## t             1           0.319   150.2      3 1412 < 2.2e-16 ***
## regiao       15           1.149    36.0     45 4232 < 2.2e-16 ***
## Residuals 1414
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
summary(fit_manova, test = "Roy") # Maior raiz de Roy
```

```
##              Df    Roy approx F num Df den Df    Pr(>F)
## tipo_via      1 36.728  17286.8      3 1412 < 2.2e-16 ***
## log_n         1 56.873  26768.0      3 1412 < 2.2e-16 ***
## t             1  0.319   150.2      3 1412 < 2.2e-16 ***
```

```
## regiao      15  0.700      66.0      15  1414 < 2.2e-16 ***
## Residuals 1414
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Todos os preditores são fortemente significativos ($p < 0,001$) nas quatro estatísticas. A concordância completa é esperada quando os efeitos são fortes e bem definidos; as quatro só divergem em situações limítrofes. O traço de Pillai é tomado como referência principal por sua robustez a desvios de normalidade (relevante dado o diagnóstico anterior).

Atenção à **regiao**: por ser fator de 16 níveis, o teste avalia o **bloco inteiro** das 15 dummies de uma vez. A hipótese nula — “nenhuma região difere da Metropolitana de São Paulo em nenhuma das respostas” — é rejeitada com folga, indicando heterogeneidade geográfica significativa.

Nota técnica. O `summary.manova` usa soma de quadrados sequencial (Tipo I), de modo que a estatística de cada termo depende da ordem de entrada na fórmula. A conclusão (todos significativos) é robusta à ordem.

7 Decomposição manual: matrizes B , Σ , H e E

Para explicitar a mecânica do modelo, reconstroem-se os estimadores a partir das matrizes, sem usar `lm()`.

```
X <- model.matrix(fit)
Y <- as.matrix(celulas_f[, vars_desfecho])
n <- nrow(celulas_f)
p <- ncol(X)
```

```
# Estimador de mínimos quadrados:  $B = (X'X)^{-1} X'Y$ 
B_hat <- solve(t(X) %*% X) %*% t(X) %*% Y
round(B_hat[1:4, ], 3) # confere com coef(fit)
```

```
##                log_y1 log_y2 log_y3
## (Intercept)    -1.719 -3.633  0.236
## tipo_viaVIAS URBANAS  0.925  0.430  0.499
## log_n           0.796  0.935  0.861
## t               -0.006 -0.015  0.002
```

```
# Resíduos e matriz de covariância dos erros
Y_hat <- X %*% B_hat
E_resid <- Y - Y_hat
Sigma_hat <- (t(E_resid) %*% E_resid) / (n - p)
round(Sigma_hat, 4)
```

```
##          log_y1 log_y2 log_y3
## log_y1  0.1589 0.0199 -0.0071
## log_y2  0.0199 0.3993  0.0004
## log_y3 -0.0071 0.0004  0.0213
```

```
# Em escala de correlação
round(cov2cor(Sigma_hat), 3)
```

```
##          log_y1 log_y2 log_y3
## log_y1  1.000  0.079 -0.123
## log_y2  0.079  1.000  0.005
## log_y3 -0.123  0.005  1.000
```

A leitura de $\hat{\Sigma}$ é o **achado metodológico central**. Enquanto as respostas brutas tinham correlações de 0,79 a 0,93, a correlação entre os **resíduos** é praticamente nula (entre $-0,12$ e $0,08$). Ou seja: quase toda a associação observada entre pedestres, ciclistas e motociclistas era efeito de escala (volume de circulação). Removido esse componente comum via `log_n`, o que resta de cada resposta é praticamente ortogonal às demais — não há um “mecanismo de vulnerabilidade compartilhado” além da exposição.

8 Diagnóstico dos resíduos multivariados

8.1 Colinearidade (VIF)

A matriz X é a mesma para as três respostas; o VIF independe da resposta
`vif(lm(log_y1 ~ tipo_via + log_n + t + regiao, data = celulas_f))`

```
##              GVIF Df GVIF^(1/(2*Df))
## tipo_via  5.370682  1      2.317473
## log_n    10.841539  1      3.292649
## t         1.152886  1      1.073725
## regiao    8.233004 15      1.072800
```

O VIF de `log_n` é elevado (11), por colinearidade com as dummies de região (ambos capturam o “tamanho” da célula). **Optou-se por manter `log_n`**: a colinearidade afeta a precisão dos coeficientes individuais de volume/região — que não são o foco —, mas não as previsões nem os testes conjuntos de Pillai/Wilks. O controle de exposição é conceitualmente necessário para colocar as regiões em base comparável.

8.2 Outliers multivariados (distância de Mahalanobis)

```
residuos <- as.data.frame(E_resid)
colnames(residuos) <- c("res_ped", "res_cic", "res_mot")
```

```
maha <- mahalanobis(residuos,
                    center = colMeans(residuos),
                    cov     = cov(residuos))

corte <- qchisq(0.975, df = length(vars_desfecho))
outliers <- which(maha > corte)
length(outliers)           # quantidade
```

```
## [1] 79
```

```
celulas_f$regiao_administrativa[outliers][1:10] # exemplos
```

```
## [1] "ARAÇATUBA"      "ARAÇATUBA"      "ARAÇATUBA"      "ARAÇATUBA"
## [5] "ARAÇATUBA"      "ARAÇATUBA"      "BAIXADA SANTISTA" "BAIXADA SANTISTA"
## [9] "BAIXADA SANTISTA" "BAIXADA SANTISTA"
```

São **79 células** (5,5%) acima do corte qui-quadrado de 97,5% — proporção saudável, sem dominância de uma única região.

8.3 Visualização dos resíduos multivariados

```
df_resid <- residuos
df_resid$maha <- maha
df_resid$outlier <- maha > corte

ggplot(df_resid, aes(x = res_ped, y = res_mot, color = outlier)) +
```

```

geom_point(size = 2, alpha = 0.7) +
stat_ellipse(aes(group = 1), color = cor_laranja,
             linetype = "dashed", linewidth = 0.8) +
geom_hline(yintercept = 0, color = "gray50", linetype = "dotted") +
geom_vline(xintercept = 0, color = "gray50", linetype = "dotted") +
scale_color_manual(values = c("FALSE" = "gray60", "TRUE" = cor_laranja),
                  labels = c("Normal", "Outlier multivariado")) +
labs(title = "Resíduos multivariados: pedestres × motociclistas",
     subtitle = "Elipse de 95% baseada na distância de Mahalanobis",
     x = "Resíduo (pedestres)", y = "Resíduo (motociclistas)", color = NULL) +
tema_escuro

```

8.4 Coeficientes estimados por desfecho

```

df_coef <- as.data.frame(coef(fit))
df_coef$preditor <- rownames(df_coef)
# Manter apenas os preditores principais (não as 15 dummies de região)
df_coef <- df_coef[df_coef$preditor %in%
                  c("tipo_viaVIAS URBANAS", "log_n", "t"), ]

df_coef_long <- do.call(rbind, lapply(vars_desfecho, function(v) {
  data.frame(preditor = df_coef$preditor, desfecho = rotulos[v],
             coeficiente = df_coef[[v]])
}))

ggplot(df_coef_long, aes(x = preditor, y = coeficiente, fill = preditor)) +
  geom_col(width = 0.6) +
  geom_hline(yintercept = 0, color = "gray50", linetype = "dashed") +
  facet_wrap(~desfecho, scales = "free_y") +
  scale_fill_manual(values = c("tipo_viaVIAS URBANAS" = cor_laranja,
                              "log_n" = cor_clara, "t" = cor_extra)) +
  labs(title = "Coeficientes estimados por preditor e desfecho",
       subtitle = "Efeitos principais (regiões omitidas)",
       x = NULL, y = "Coeficiente estimado", fill = NULL) +
tema_escuro + theme(legend.position = "none",
                    axis.text.x = element_text(angle = 20, hjust = 1))

```

O painel evidencia a **divergência de efeitos** entre desfechos: `tipo_via` (urbana) eleva fortemente pedestres (+0,93), bem mais do que motociclistas (+0,50) ou ciclistas (+0,43). Vias urbanas concentram desproporcionalmente sinistros com pedestres — o achado substantivo central.

9 Resultados substantivos

Sintetizando a leitura dos coeficientes (controlando por volume de sinistros):

- **Tipo de via.** Vias urbanas aumentam o envolvimento de todas as categorias, mas o efeito sobre **pedestres** é o mais intenso — coerente com a circulação de pedestres concentrar-se no ambiente urbano.
- **Região administrativa.** Após controlar pelo volume, a Metropolitana de São Paulo concentra mais sinistros com **pedestres** do que o interior, enquanto várias regiões do interior apresentam mais sinistros com **ciclistas** do que o esperado pelo seu tamanho. O perfil de vulnerabilidade é geograficamente heterogêneo.
- **Tempo.** A tendência temporal é pequena, com leve queda para pedestres e ciclistas e leve alta para motociclistas ao longo do período.
- **Volume (log_n).** Domina o modelo, sobretudo para motociclistas — o que configura uma relação quase contábil (sinistros com moto fração fixa do total) e explica o R^2 de 0,99 dessa resposta.

10 Limitações e conclusão

10.1 Limitações

1. **Envolvimento ferimento.** As respostas contam sinistros em que a categoria esteve *presente*, não em que ela foi a vítima ferida. Um atropelamento moto-pedestre soma a Y_1 e Y_3 simultaneamente. O refinamento natural é cruzar a tabela **sinistros** com a tabela **pessoas** (que traz **gravidade_lesao** e posição da vítima) e recontar ferimentos por categoria — direção futura imediata.
2. **Normalidade multivariada rejeitada.** Originada nos zeros estruturais. Mitigada pela escolha do traço de Pillai e pelo grande n .
3. **Colinearidade volume $\times$ região (VIF 11).** Mantida deliberadamente; afeta coeficientes isolados, não as previsões nem os testes conjuntos.

10.2 Conclusão

A regressão multivariada confirmou que tipo de via, região, volume e tempo afetam **conjuntamente** o perfil de usuários vulneráveis em sinistros não fatais de São Paulo (todos os preditores significativos a $p < 0,001$ nas quatro estatísticas). O achado metodológico mais relevante é que a forte correlação aparente entre pedestres, ciclistas e motociclistas é quase inteiramente um efeito de exposição: controlado o volume, os resíduos tornam-se praticamente ortogonais. Substantivamente, o ambiente urbano e a Metropolitana de São Paulo destacam-se no envolvimento de pedestres, enquanto o interior apresenta perfil relativamente mais ciclístico — heterogeneidade geográfica que recomenda políticas de segurança viária diferenciadas por território.