

Análise Multivariada — Anotações de Aula

Aula 2: Álgebra Linear & Análise Exploratória Multivariada

Professor: Vinícius Osterne, PhD

Observação do professor: "A segunda aula é sempre um pouco mais complicada porque a gente fala de álgebra linear — cansa um pouco. Mas tentei trazer o máximo possível para o nosso contexto para que não fique tão cansativo."

Onde Estamos na Linha do Tempo

Introdução & Conceitos Prévios

Álgebra Linear HOJE

Análise Exploratória HOJE

Probabilidade & Inferência (próxima aula)

Modelos Multivariados

Estrutura dos Dados

Classificação & Agrupamento

PARTE 1 — ÁLGEBRA LINEAR

Por que isso importa? Toda a estatística multivariada é escrita em linguagem de matrizes. Covariância, correlação, PCA, MANOVA — tudo depende de operações matriciais. É como aprender o alfabeto antes de ler: chato, mas indispensável.

Escalares, Vetores e Matrizes

***Analogia:** Pense assim: um **escalar** é uma nota musical única (ex.: Lá = 440 Hz). Um **vetor** é uma melodia — uma sequência de notas. Uma **matriz** é uma partitura inteira — múltiplas melodias ao mesmo tempo, organizadas em linhas e colunas.*

```
# Escalar: um único número
altura <- 1.75

# Vetor: uma sequência de valores (uma observação com p variáveis)
pessoa_1 <- c(altura = 1.75, peso = 70, idade = 30)

# Matriz: n observações × p variáveis (a estrutura base dos nossos dados)
# Cada linha = uma observação; cada coluna = uma variável
X <- matrix(
  c(1.75, 70, 30,
    1.60, 55, 25,
    1.80, 90, 45),
  nrow = 3,    # 3 pessoas
  ncol = 3,    # 3 variáveis: altura, peso, idade
  byrow = TRUE, # preenche linha por linha
  dimnames = list(
    c("p1", "p2", "p3"),
    c("Altura", "Peso", "Idade")
  )
)

print(X)
dim(X) # retorna c(n_linhas, n_colunas) = c(3, 3)
```

Operações Matriciais Essenciais

Transposta

***Analogia:** Transpor é como virar a partitura de cabeça para baixo: as linhas viram colunas e as colunas viram linhas.*

```
A <- matrix(c(1, 2, 3,
              4, 5, 6), nrow = 2, byrow = TRUE)
```

```
cat("A:\n"); print(A)
cat("t(A) — transposta:\n"); print(t(A))
```

Multiplicação de Matrizes

Atenção: multiplicação de matrizes **não é** multiplicar elemento por elemento. É uma operação de produto interno entre linhas e colunas. Em R, usa-se `%%` (não `*`).

```
A <- matrix(c(1, 2,
              3, 4), nrow = 2, byrow = TRUE)
B <- matrix(c(5, 6,
              7, 8), nrow = 2, byrow = TRUE)

cat("Multiplicação matricial A %% B:\n"); print(A %% B)
cat("Multiplicação elemento-a-elemento A * B:\n"); print(A * B)
# Os resultados são DIFERENTES!
```

Inversa de uma Matriz

Analogia: A inversa de uma matriz é como o “número recíproco” no mundo das matrizes. Assim como $5 \times (1/5) = 1$, uma matriz A multiplicada pela sua inversa A^{-1} resulta na **matriz identidade** I (que faz o papel do número 1).

```
A <- matrix(c(4, 7,
              2, 6), nrow = 2, byrow = TRUE)

A_inv <- solve(A) # solve() calcula a inversa em R
cat("A:\n"); print(A)
cat("A^-1:\n"); print(A_inv)
cat("A %% A^-1 deve ser a identidade:\n")
print(round(A %% A_inv, 10)) # round para eliminar erros numéricos
```

Matriz Identidade e Diagonal

```
# Identidade: 1s na diagonal, 0s no resto — o "neutro" da multiplicação matricial
I3 <- diag(3)
print(I3)
```

```
# Diagonal: só tem valores na diagonal principal
```

```
D <- diag(c(3, 7, 2))
```

```
print(D)
```

```
# A inversa de uma diagonal é trivial: basta inverter cada elemento
```

```
print(diag(1 / c(3, 7, 2)))
```

Matriz Simétrica e Matriz de Covariância

*Conexão fundamental: A matriz de covariância **sempre é simétrica**, porque $Cov(X, Y) = Cov(Y, X)$. Isso significa que todas as propriedades de matrizes simétricas se aplicam diretamente a ela!*

```
# Uma matriz simétrica: A = t(A)
```

```
S <- matrix(c(4, 2, 1,
```

```
2, 5, 3,
```

```
1, 3, 6), nrow = 3, byrow = TRUE)
```

```
cat("S == t(S)?", all.equal(S, t(S)), "\n") # deve ser TRUE
```

```
# A covariância de dados reais também é simétrica
```

```
set.seed(42)
```

```
dados <- matrix(rnorm(50), nrow = 10)
```

```
cov_mat <- cov(dados)
```

```
cat("Cov(dados) é simétrica?", all.equal(cov_mat, t(cov_mat)), "\n")
```

```
# Propriedade:  $A^T * A$  sempre produz uma matriz simétrica!
```

```
A3 <- matrix(1:6, nrow = 3)
```

```
simetrica <- t(A3) %*% A3
```

```
cat("t(A) %*% A é simétrica?", all.equal(simetrica, t(simetrica)), "\n")
```

Autovalores e Autovetores — O Coração da Multivariada

Analogia (a melhor delas!): Imagine que você tem uma máquina de espirografar vetores — ela pega qualquer seta e, em geral, muda tanto o tamanho quanto a direção. Os **autovetores** são as setas especiais que essa máquina **não consegue torcer** — ela só muda o tamanho. O quanto ela alonga ou encolhe essa seta especial é o **autovalor**.

Matematicamente: $\mathbf{Av} = \lambda \mathbf{v}$

Onde:

- $\mathbf{A}$ = a matriz (ex: matriz de covariância S)
- $\mathbf{v}$ = autovetor (direção especial que não rotaciona)
- λ = autovalor (fator de escala)

Intuição geométrica dos autovalores

Autovalor λ	O que acontece com o vetor
$\lambda > 1$	Estica (fica mais longo)
$0 < \lambda < 1$	Encolhe
$\lambda < 0$	Inverte a direção
$\lambda = 1$	Não muda nada

Conexão com os dados

Analogia: Os dados formam uma **nuvem de pontos** no espaço. Pense nessa nuvem como uma bola de futebol americano (elipse). Os **autovetores da covariância** são os eixos dessa bola — as direções em que ela mais se alonga. Os **autovalores** são o comprimento de cada eixo — o quanto os dados se espalharam em cada direção.

```
# Calculando autovalores e autovetores em R
A_eig <- matrix(c(3, 1,
                  1, 3), nrow = 2, byrow = TRUE)

resultado <- eigen(A_eig) # função nativa do R

cat("Autovalores:\n");      print(resultado$values)
cat("Autovetores (colunas):\n"); print(resultado$vectors)

# VERIFICAÇÃO: A %*% v deve ser igual a lambda * v
```

```

v1 <- resultado$variables[, 1] # primeiro autovetor (coluna 1)
lambda1 <- resultado$values[1] # primeiro autovalor

cat("\nVerificação Av = λv:\n")
cat("A %*% v1: ", round(A_eig %*% v1, 6), "\n")
cat("lambda1*v1: ", round(lambda1 * v1, 6), "\n")
# Devem ser iguais!

# Exemplo do slide: S = [[3,1],[1,3]] λ1 = 4, λ2 = 2
S_ex <- matrix(c(3, 1, 1, 3), nrow = 2)
cat("\nAutovalores de S =[[3,1],[1,3]]:", eigen(S_ex)$values, "\n")
# Esperado: 4 e 2

```

Decomposição Espectral

Toda matriz simétrica pode ser reescrita como: $\mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^T$

Onde P é a matriz de autovetores e $\mathbf{\Lambda}$ é a matriz diagonal de autovalores.

```

# Reconstruindo a matriz a partir de autovalores e autovetores
P <- resultado$variables # matriz de autovetores
Lambda <- diag(resultado$values) # diagonal de autovalores

A_reconstruida <- P %*% Lambda %*% t(P)
cat("A original:\n"); print(A_eig)
cat("A reconstruída:\n"); print(round(A_reconstruida, 10))
# Deve ser idêntica!

```

Por que isso é importante? A PCA (Análise de Componentes Principais) é literalmente a decomposição espectral da matriz de covariância. Entender autovalores = entender PCA.

PARTE 2 — ANÁLISE EXPLORATÓRIA MULTIVARIADA

Citação do professor: “Nem tudo se resume a rede neural, nem tudo se resume a IA, nem tudo se resume a LLM. Os gráficos revelam estruturas que as estatísticas

Distâncias Multivariadas

Antes de visualizar, precisamos entender como **medir diferença** entre observações no espaço multivariado.

***Analogia:** Imagine que você quer saber o quão “diferente” dois pacientes são com base em múltiplos exames. A distância euclidiana seria como medir em linha reta — ingênua. A distância de Mahalanobis é como um GPS inteligente que leva em conta o tráfego (a correlação entre as variáveis).*

Distância	Fórmula	Considera correlação?
Manhattan	$\sum x_j - y_j $	Não
Euclidiana	$\sqrt{\sum (x_j - y_j)^2}$	Não
Mahalanobis	$\sqrt{(x-y)^T S^{-1} (x-y)}$	Sim

A **Mahalanobis** é a mais importante na multivariada: ela pondera pelo inverso da variância, evitando que variáveis com maior escala dominem a distância.

```
# Calculando as três distâncias em R
x <- c(1, 2)
y <- c(4, 6)
S <- matrix(c(2, 1, 1, 3), nrow = 2) # matriz de covariância

# Manhattan
d_manhattan <- sum(abs(x - y))
cat("Manhattan:", d_manhattan, "\n") # esperado: 7

# Euclidiana
d_euclidiana <- sqrt(sum((x - y)^2))
cat("Euclidiana:", round(d_euclidiana, 4), "\n") # esperado: 5

# Mahalanobis (manual)
diff_vec <- x - y
S_inv <- solve(S)
d_maha <- sqrt(t(diff_vec) %*% S_inv %*% diff_vec)
cat("Mahalanobis:", round(d_maha, 4), "\n") # esperado: ~2.65
```

```

# Mahalanobis via função nativa do R
# mahalanobis() calcula distâncias de PONTOS ao centroide da distribuição
set.seed(42)
dados_ex <- data.frame(
  x1 = rnorm(50, mean = 5, sd = 2),
  x2 = rnorm(50, mean = 10, sd = 3)
)
centro <- colMeans(dados_ex)
cov_dados <- cov(dados_ex)

d_mahal <- mahalanobis(dados_ex, center = centro, cov = cov_dados)

# Distâncias elevadas = possíveis outliers multivariados
hist(d_mahal, main = "Distâncias de Mahalanobis",
     xlab = "D²", col = "steelblue", breaks = 15)
# Sob normalidade, D² ~ Qui-quadrado(p)
abline(v = qchisq(0.975, df = 2), col = "red", lty = 2, lwd = 2)
legend("topright", "Limiar 97.5% (χ²)", col = "red", lty = 2, lwd = 2)

```

Ferramentas Gráficas da Análise Exploratória Multivariada

Regra de ouro do professor: “Use mais de um gráfico, mas que tragam informações distintas. Não use gráficos diferentes para mostrar a mesma coisa — isso é encher espaço, não informar.”

Guia de Uso: Qual Gráfico para Qual Situação?

Gráfico	Objetivo	Nº de variáveis
Histograma / Densidade	Distribuição marginal de uma variável	$p = 1$
Dispersão simples	Relação entre duas variáveis	$p = 2$
Boxplots paralelos	Comparar distribuições entre grupos	$p \geq 2$
Matriz de dispersão	Ver todos os pares simultaneamente	$2 \leq p \leq 6$
Heatmap de correlação	Estrutura de dependência global	$p \geq 3$

Perfis médios	Comparação multivariada de grupos	$p \geq 3$
Coordenadas paralelas	Padrões com muitas variáveis	$p \geq 4$

```
# Instalando pacotes necessários (execute uma vez)
# install.packages(c("GGally", "reshape2", "MASS", "ggplot2"))

library(ggplot2)
library(GGally)
library(reshape2)
library(MASS)

# Gerando dados de exemplo: 2 grupos, 4 variáveis
set.seed(123)
n <- 60
dados <- data.frame(
  Altura = c(rnorm(n/2, 170, 8), rnorm(n/2, 165, 7)),
  Peso = c(rnorm(n/2, 75, 12), rnorm(n/2, 60, 10)),
  Idade = c(rnorm(n/2, 40, 10), rnorm(n/2, 30, 8)),
  Renda = c(rnorm(n/2, 8000, 2000), rnorm(n/2, 5000, 1500)),
  Grupo = rep(c("A", "B"), each = n/2)
)
```

1. Histograma + Densidade

```
# Revela: assimetria, multimodalidade, outliers univariados
ggplot(dados, aes(x = Altura)) +
  geom_histogram(aes(y = after_stat(density)),
    bins = 12, fill = "gray60", color = "white", alpha = 0.8) +
  geom_density(color = "darkorange", linewidth = 1) +
  labs(title = "Distribuição de Altura", x = "Altura (cm)", y = "Densidade") +
  theme_minimal()
```

2. Boxplots Paralelos

```
# Compara distribuições por grupo — ótimo para ver diferenças entre grupos
dados_long <- melt(dados[, c("Altura", "Peso", "Idade", "Renda", "Grupo")],
  id.vars = "Grupo")
```

```
ggplot(dados_long, aes(x = variable, y = value, fill = Grupo)) +
  geom_boxplot(alpha = 0.7, outlier.size = 1.5) +
  scale_fill_manual(values = c("A" = "darkorange", "B" = "gray60")) +
  labs(title = "Boxplots Paralelos por Grupo", x = NULL, y = "Valor") +
  theme_minimal()
```

3. Matriz de Dispersão (scatterplot matrix)

```
# Mostra todos os pares de variáveis ao mesmo tempo
# Na diagonal: distribuição de cada variável
# No triângulo superior: correlação numérica
# No triângulo inferior: gráfico de dispersão
ggpairs(
  dados[, c("Altura", "Peso", "Idade", "Renda")],
  lower = list(continuous = wrap("points", alpha = 0.4, size = 1.2, color = "gray40")),
  upper = list(continuous = wrap("cor", size = 3.5)),
  diag = list(continuous = wrap("densityDiag", fill = "gray70", alpha = 0.6)),
  title = "Matriz de Dispersão"
) + theme_minimal()
```

4. Heatmap de Correlação

Professor em aula: “Laranja indica correlação positiva forte. Azul indica correlação negativa. De cara, imediato, você já enxerga: X2 e X1 têm correlação 0.85 — as demais não me importam porque a correlação é muito baixa.”

```
# Muito mais informativo que olhar uma matriz de números crua
R_mat <- cor(dados[, c("Altura", "Peso", "Idade", "Renda")])
R_long <- melt(R_mat)

ggplot(R_long, aes(x = Var1, y = Var2, fill = value)) +
  geom_tile(color = "white") +
  geom_text(aes(label = round(value, 2)), size = 3.5, fontface = "bold") +
  scale_fill_gradient2(
    low = "steelblue", # correlação negativa
    mid = "white", # sem correlação
    high = "darkorange", # correlação positiva
    midpoint = 0,
```

```
limits = c(-1, 1),
name = "Correlação"
) +
labs(title = "Heatmap de Correlação") +
theme_minimal() +
theme(axis.title = element_blank())
```

5. Gráfico de Perfis Médios

***Analogia:** Imagine dois times de futebol (Grupo A e Grupo B). O gráfico de perfis médios é como comparar o desempenho médio de cada time em várias categorias (velocidade, força, técnica, resistência) ao mesmo tempo — conectando os pontos para ver qual time se destaca em quê.*

***Conexão com MANOVA:** este gráfico é a “prévia visual” do teste MANOVA — que formalmente vai testar se os vetores de médias dos grupos são estatisticamente diferentes.*

```
# Padronizando para colocar todas as variáveis na mesma escala
dados_pad <- dados
dados_pad[, c("Altura", "Peso", "Idade", "Renda")] <-
  scale(dados[, c("Altura", "Peso", "Idade", "Renda")])

medias_grupo <- aggregate(. ~ Grupo,
  data = dados_pad[, c("Altura", "Peso", "Idade", "Renda", "Grupo")],
  FUN = mean)

medias_long <- melt(medias_grupo, id.vars = "Grupo")

ggplot(medias_long, aes(x = variable, y = value, color = Grupo, group = Grupo)) +
  geom_line(linewidth = 1) +
  geom_point(size = 3) +
  scale_color_manual(values = c("A" = "darkorange", "B" = "gray50")) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "gray70") +
  labs(title = "Perfis Médios por Grupo (variáveis padronizadas)",
    x = NULL, y = "Média padronizada") +
  theme_minimal()
```

6. Coordenadas Paralelas

*Quando usar: quando você tem **mais de 4 variáveis** e a matriz de dispersão fica grande demais. Cada linha é uma observação; cada eixo vertical é uma variável. Linhas que se cruzam entre dois eixos = correlação negativa. Linhas paralelas = correlação positiva.*

```
# Regra do professor:
# p <= 3 variáveis   use gráfico de perfis médios
# p >= 4 variáveis   use coordenadas paralelas

cores <- ifelse(dados$Grupo == "A", "darkorange", "gray60")

parcoord(
  dados[, c("Altura", "Peso", "Idade", "Renda")],
  col = adjustcolor(cores, alpha.f = 0.4), # transparência para ver sobreposição
  lty = 1,
  main = "Coordenadas Paralelas"
)
legend("topright",
  legend = c("Grupo A", "Grupo B"),
  col = c("darkorange", "gray60"),
  lty = 1, lwd = 2, bty = "n")
```

Insights do Professor (da transcrição)

“Nem tudo se resume a rede neural, IA ou LLM. Isso é uma doença. Fico indignado.”

- Dominar álgebra linear + análise exploratória é o que diferencia quem entende estatística de quem apenas roda modelos
- Use gráficos distintos no mesmo relatório — cada um revela um aspecto diferente dos dados
- O heatmap de correlação é muito mais eficiente para comunicar com clientes do que uma matriz de números no console do R
- Gráfico de perfis médios é a base visual para testes como MANOVA — que veremos na próxima aula

Próxima Aula — O que vem pela frente

Na **Aula 3**, o professor prometeu:

- **Distribuições multivariadas:** distribuição Normal Multivariada (generalização da curva normal para vetores)
- **T² de Hotelling:** a versão multivariada do teste t de Student — compara vetores de médias
- **MANOVA:** comparação de médias entre grupos com múltiplas variáveis simultaneamente

“A gente começa a falar sobre diferença. Não é fácil, mas se você dominar essa ideia, você domina qualquer coisa.”

Referências

- Johnson & Wichern — *Applied Multivariate Statistical Analysis*, Cap. 1-4
- Hair et al. — *Multivariate Data Analysis*, Cap. 2 (Análise Exploratória)
- Documentação do pacote GGally : <https://ggobi.github.io/ggally/>
- Documentação do pacote MASS (função parcoord): <https://cran.r-project.org/package=MASS>