

Análise Multivariada — Anotações de Aula

Aula 3: Probabilidade, Inferência Multivariada, T^2 de Hotelling, MANOVA e MANCOVA

Professor: Vinícius Osterne, PhD

Observação do professor: "A terceira aula é mais carregada. Mas quem escolhe entender de fato a coisa se diferencia. As coisas estão cada vez mais fáceis e cada vez mais complicadas — ao mesmo tempo."

Onde Estamos na Linha do Tempo

Introdução & Conceitos Prévios
Álgebra Linear
Análise Exploratória
Probabilidade & Inferência HOJE
 Teorema Central do Limite (Multivariado)
 Distribuição Normal Multivariada
 T^2 de Hotelling (1 e 2 populações)
 MANOVA
 MANCOVA
Modelos Multivariados
Estrutura dos Dados (PCA, Fatorial)
Classificação & Agrupamento

O Papel do Teorema Central do Limite (TLC) na Multivariada

Analogia: Imagine que você tem uma urna cheia de bolas com números aleatórios de qualquer formato de distribuição — pode ser assimétrica, bimodal, o que for. Se

you grab samples from this urn repeatedly and calculate the mean of each sample, the distribution of these means will seem each time more like a bell curve (normal) as you increase the size of the samples. The CLT is this magical guarantee.

Por que o TLC é fundamental para a multivariada?

O TLC garante que, independente da distribuição original dos dados, **as médias amostrais** convergem para a distribuição normal quando **n é grande**. Isso nos permite:

- Construir **intervalos de confiança** para o vetor de médias
- Realizar **testes de hipóteses** sobre médias
- Fundamentar a **estatística T^2 de Hotelling**
- Sustentar toda a **teoria assintótica de modelos lineares e multivariados**

*Nuance importante (apontada pelo professor): O TLC não dispensa a suposição de normalidade — ele **viabiliza a construção** do teste mesmo quando a população não é perfeitamente normal. Para amostras grandes ($n \geq 30$), o teste funciona de forma robusta. Para amostras pequenas, a normalidade da população ainda é necessária.*

Demonstração do TLC na prática:

Mesmo com uma distribuição exponencial (assimétrica), as médias se normalizam

```
set.seed(42)
```

```
n_simulacoes <- 5000
```

```
n_amostra <- 50 # tamanho de cada amostra
```

```
# Distribuição original: exponencial (assimétrica para a direita)
```

```
medias <- replicate(n_simulacoes, mean(rexp(n_amostra, rate = 1)))
```

```
par(mfrow = c(1, 2))
```

```
# Distribuição original
```

```
hist(rexp(10000, rate = 1),
```

```
  main = "Distribuição Original (Exponencial)",
```

```
  xlab = "X", col = "steelblue", breaks = 50)
```

```
# Distribuição das médias amostrais fica normal!
```

```
hist(medias,
```

```
  main = paste("Distribuição das Médias (n =", n_amostra, ")"),
```

```
  xlab = "Média Amostral", col = "darkorange", breaks = 50,
```

```
freq = FALSE)
curve(dnorm(x, mean = mean(medias), sd = sd(medias)),
      add = TRUE, col = "darkred", lwd = 2)

par(mfrow = c(1, 1))
```

Distribuição Normal Multivariada (DNM)

Analogia: A normal univariada é uma curva de sino em 1D. A normal multivariada é como uma “barraca de acampamento” (elipsoide) em múltiplas dimensões — a barraca se deforma de acordo com as correlações entre as variáveis.

Notação: $X \sim N_p(\mu, \Sigma)$

Onde:

- μ = vetor de médias ($p \times 1$) — o centro da distribuição
- Σ = matriz de covariância ($p \times p$) — a forma e orientação da distribuição

Propriedades Fundamentais (que sustentam toda a inferência)

1. Fechada sob marginalização:

Se $(X, Y) \sim N$ multivariada, então X sozinha também segue uma N multivariada. Você pode “esquecer” variáveis e a estrutura normal se mantém.

2. Independência Correlação zero:

Na DNM e **apenas na DNM**: se $\sigma_{jk} = 0$ (sem correlação), as variáveis são independentes. Isso não vale para outras distribuições!

3. Fechada sob transformações lineares:

Se $X \sim N_p(\mu, \Sigma)$ e A é uma matriz $q \times p$, então $AX \sim N_q(A\mu, A\Sigma A^T)$.

Isso fundamenta o PCA, a MANOVA e os modelos lineares multivariados.

```
# Simulando dados de uma Normal Multivariada
# install.packages("MASS")
library(MASS)

# Definindo parâmetros
mu <- c(5, 10)      # vetor de médias
Sigma <- matrix(c(4, 3,
                  3, 9), nrow = 2)
```

```
# Cov(X1, X2) = 3   correlação positiva

set.seed(42)
dados_dnm <- mvrnorm(n = 500, mu = mu, Sigma = Sigma)
colnames(dados_dnm) <- c("X1", "X2")

# Visualizando
plot(dados_dnm, col = adjustcolor("steelblue", 0.5),
     main = "Distribuição Normal Bivariada",
     xlab = "X1", ylab = "X2", pch = 16)

# Testando normalidade multivariada com distâncias de Mahalanobis
# Sob normalidade,  $D^2 \sim \text{Qui-quadrado}(p)$ 
xbar <- colMeans(dados_dnm)
S <- cov(dados_dnm)
d2 <- mahalanobis(dados_dnm, center = xbar, cov = S)

# QQ-plot qui-quadrado: pontos alinhados = normalidade
qqplot(qchisq(ppoints(nrow(dados_dnm))), df = 2), d2,
     main = "QQ-Plot Qui-quadrado (teste de normalidade multivariada)",
     xlab = "Quantis Teóricos  $\chi^2(2)$ ",
     ylab = "Distâncias de Mahalanobis ao quadrado")
abline(0, 1, col = "red", lwd = 2)
```

Por que não fazer Vários Testes t Separados?

Antes de entrar no T^2 , é fundamental entender **por que não podemos simplesmente fazer um teste t para cada variável separadamente**.

***Analogia:** Imagine que você está jogando cara ou coroa com uma moeda honesta. A chance de errar uma vez é 5%. Mas se você jogar 20 vezes, a chance de errar pelo menos uma vez é muito maior. Fazer múltiplos testes t é a mesma coisa — o erro se acumula.*

O problema da inflação do erro Tipo I

Com múltiplos testes a $\alpha = 0,05$:

Número de Testes	Chance de ao menos 1 falso positivo
------------------	-------------------------------------

1	5,0%
3	14,3%
5	22,6%
10	40,1%
20	64,2%

Além disso, testes t separados **ignoram a correlação entre as variáveis** — o que é exatamente o que a análise multivariada quer estudar!

```
# Demonstrando a inflação do erro Tipo I
set.seed(42)
n_sim <- 10000
p <- 5 # número de variáveis

# Dados onde H0 é VERDADEIRA (não há diferença real)
rejeitou_ao_menos_um <- replicate(n_sim, {
  dados_grupo1 <- matrix(rnorm(30 * p), nrow = 30)
  dados_grupo2 <- matrix(rnorm(30 * p), nrow = 30)

  # t-test separado para cada variável
  pvals <- sapply(1:p, function(j) {
    t.test(dados_grupo1[, j], dados_grupo2[, j])$p.value
  })
  any(pvals < 0.05) # TRUE se rejeitou H0 em pelo menos 1 teste
})

cat("Taxa de erro real com", p, "testes t separados:",
    round(mean(rejeitou_ao_menos_um) * 100, 1), "%\n")
cat("Taxa esperada (teoria): ~", round((1 - 0.95^p) * 100, 1), "%\n")
# Deveria ser 5% — mas está inflado!
```

T² de Hotelling — O Teste t Multivariado

Analogia: O teste t univariado pergunta: “a média da minha amostra está longe demais do valor hipotético μ_0 ?” O T² de Hotelling pergunta a mesma coisa, mas para um **vetor de médias inteiro** — e ele usa a **distância de Mahalanobis** para medir esse

afastamento, levando em conta a correlação entre todas as variáveis ao mesmo tempo.

A Progressão Lógica: de t^2 ao T^2

Univariado (1 variável):

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \Rightarrow t^2 = n(\bar{x} - \mu_0)(s^2)^{-1}(\bar{x} - \mu_0)$$

Multivariado (p variáveis) — T^2 de Hotelling:

$$T^2 = n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)$$

É **exatamente** a distância de Mahalanobis ao quadrado entre $\bar{x}$ e μ_0 , ponderada por n .

Tabela Comparativa: t vs. T^2

Aspecto	Univariado (t)	Multivariado (T^2)
Estatística	$t^2 = n(\bar{x} - \mu_0)^2/s^2$	$T^2 = n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)$
Distribuição	$F(1, n-1)$	$(p(n-1)/(n-p)) \times F(p, n-p)$
Rejeita H_0 se	$t^2 > F_{1, n-1; \alpha}$	$T^2 > p(n-1)/(n-p) \times F_{p, n-p; \alpha}$

Por que a distribuição envolve F se o nome é T^2 ? Porque no caso univariado $t^2 = F(1, n-1)$. A generalização segue a mesma lógica: numerador normal + denominador Wishart = distribuição F reescalada.

Cenários de Aplicação

1 população T^2 de uma amostra ($H_0: \mu = \mu_0$)
2 populações independentes T^2 de duas amostras ($H_0: \mu_1 = \mu_2$)
2 populações pareadas T^2 pareado ($H_0: \mu_D = 0$)
 $g > 2$ populações MANOVA

Código R — T^2 de Hotelling (1 população)

```
# install.packages("DescTools")  
library(DescTools)
```

```

# Simulando dados: 3 variáveis de desempenho cognitivo
set.seed(123)
n <- 40
dados <- data.frame(
  memoria = rnorm(n, mean = 52, sd = 8),
  atencao = rnorm(n, mean = 48, sd = 6),
  raciocinio = rnorm(n, mean = 55, sd = 10)
)

# Vetor hipotético (norma esperada para a população)
mu_0 <- c(50, 50, 50)

# Calculando T² manualmente
xbar <- colMeans(dados)
S <- cov(dados)
p <- ncol(dados)

#  $T^2 = n * (xbar - mu_0)' * S^{-1} * (xbar - mu_0)$ 
diff <- xbar - mu_0
T2 <- n * t(diff) %*% solve(S) %*% diff
cat("T² calculado manualmente:", round(T2, 4), "\n")

# Convertendo para estatística F
F_stat <- (n - p) / (p * (n - 1)) * T2
gl1 <- p
gl2 <- n - p
p_val <- pf(F_stat, df1 = gl1, df2 = gl2, lower.tail = FALSE)

cat("Estatística F:", round(F_stat, 4), "\n")
cat("Graus de liberdade:", gl1, "e", gl2, "\n")
cat("p-valor:", round(p_val, 4), "\n")
cat("Decisão:", ifelse(p_val < 0.05, "Rejeita H0 ( $\mu \neq \mu_0$ )", "Não rejeita H0"), "\n")

# Usando a função do pacote DescTools
HotellingsT2Test(dados, mu = mu_0)

```

Código R — T² de Hotelling (2 populações independentes)

```
# Comparando dois grupos: tratamento vs controle
set.seed(42)
grupo_A <- data.frame(
  memoria   = rnorm(30, mean = 55, sd = 8),
  atencao   = rnorm(30, mean = 52, sd = 6),
  raciocinio = rnorm(30, mean = 58, sd = 10)
)
grupo_B <- data.frame(
  memoria   = rnorm(30, mean = 48, sd = 9),
  atencao   = rnorm(30, mean = 45, sd = 7),
  raciocinio = rnorm(30, mean = 50, sd = 11)
)

# Usando HotellingsT2Test para 2 grupos
HotellingsT2Test(grupo_A, grupo_B)
# Se  $p < 0.05$  os vetores de médias dos dois grupos são diferentes
```

Região de Confiança (vs. Intervalo de Confiança)

***Analogia:** No caso univariado, um intervalo de confiança é um segmento de reta. No caso multivariado, ele vira uma **elipse** (em 2D) ou um **elipsoide** (em p dimensões). Todos os valores de μ dentro dessa elipse são “plausíveis” dado os dados.*

```
# Visualizando a região de confiança 95% no caso bivariado
library(car) # install.packages("car")

dados_biv <- dados[, c("memoria", "atencao")]
mu_0_biv <- c(50, 50)

# dataEllipse plota a nuvem de pontos + elipse de confiança
dataEllipse(dados_biv$memoria, dados_biv$atencao,
  levels = 0.95,
  col    = c("steelblue", "darkblue"),
  pch    = 16, cex = 0.7,
  xlab    = "Memória", ylab = "Atenção",
  main    = "Região de Confiança 95% para ( $\mu_1, \mu_2$ )")
points(mu_0_biv[1], mu_0_biv[2], pch = 4, col = "red", cex = 2, lwd = 2)
legend("topright", c(" $\mu_0$  hipotético", "Nuvem de dados"),
  col = c("red", "steelblue"), pch = c(4, 16))
```


MANOVA — Análise Multivariada de Variância

Analogia: A ANOVA pergunta: “as médias de **uma** variável são diferentes entre os grupos?” (como comparar o peso médio de pacientes em 3 dietas diferentes).

A MANOVA pergunta: “os **vetores de médias de múltiplas** variáveis são diferentes entre os grupos?” (como comparar peso + colesterol + pressão ao mesmo tempo).

A hierarquia dos testes:

Uma variável t de Student (2 grupos)
Uma variável ANOVA (g > 2 grupos)
 generaliza para p variáveis
p variáveis T² de Hotelling (2 grupos)
p variáveis MANOVA (g > 2 grupos)

Hipóteses

- **H₀:** $\mu_1 = \mu_2 = \dots = \mu_g$ (todos os vetores de médias são iguais)
- **H₁:** pelo menos um vetor de médias é diferente

Decomposição da Variabilidade

Assim como na ANOVA divide $SQ_{total} = SQ_{entre} + SQ_{dentro}$, a MANOVA faz o mesmo com **matrizes** (não escalares):

$$\mathbf{T} = \mathbf{H} + \mathbf{E}$$

- **T** = variabilidade total (todos os pontos em torno da média geral)
- **H** = variabilidade **H**ipótese / entre grupos (médias dos grupos vs. média geral)
- **E** = variabilidade do **E**rro / dentro dos grupos (indivíduos vs. média do seu grupo)

Intuição: Se os grupos forem muito diferentes, H será grande em relação a E. Se forem parecidos, H será pequena.

Lambda de Wilks — A Estatística de Teste Principal

$$\Lambda^* = \frac{|\mathbf{E}|}{|\mathbf{H} + \mathbf{E}|} \in (0, 1]$$

Analogia: O Lambda de Wilks é como uma “pontuação de semelhança” entre os grupos. Λ^* próximo de 1 grupos parecidos (H_0 plausível). Λ^* próximo de 0 grupos

muito diferentes (rejeita H_0).

As 4 Estatísticas Multivariadas

Todas são funções dos autovalores λ de $E^{-1}H$:

Estatística	Fórmula	Melhor quando...
<i>Wilks (Λ)</i> *	$\prod (1 + \lambda_i)^{-1}$	Uso geral — mais comum na literatura
Pillai (V)	$\sum \lambda_i / (1 + \lambda_i)$	Mais robusto a violações de normalidade
Lawley-Hotelling (U)	$\sum \lambda_i$	Diferenças em todas as dimensões
Roy (θ)	$\lambda_1 / (1 + \lambda_1)$	Separação máxima em uma única direção

Na prática, se as 4 estatísticas concordam — conclusão sólida. Se divergem investigue as suposições.

Suposições da MANOVA

1. **Normalidade multivariada** dentro de cada grupo
2. **Homogeneidade das matrizes de covariância** ($\Sigma_1 = \Sigma_2 = \dots = \Sigma_g$) — testada com o **Teste de Box M**
3. **Independência** das observações

```
# install.packages(c("heplots", "biotools"))
library(heplots) # para boxM
library(ggplot2)

# Usando o dataset clássico de siris de caranguejos (pacote MASS)
data(crabs, package = "MASS")

# Variáveis morfológicas: FL, RW, CL, CW, BD
# Grupos: sp (espécie) × sex (sexo) — aqui usamos só sp
dados_manova <- crabs[, c("sp", "FL", "RW", "CL", "CW", "BD")]

# ----- 1. Verificar normalidade multivariada por grupo -----
# (QQ-plot Mahalanobis — já vimos na seção anterior)

# ----- 2. Teste de Box M (homogeneidade das covariâncias) -----
box_m <- boxM(dados_manova[, 2:6], dados_manova$sp)
```

```

print(box_m)
# H0:  $\Sigma_B = \Sigma_O$  (covariâncias iguais)
# p < 0.05   covariâncias diferentes   use Pillai (mais robusto)

# ----- 3. Ajustar a MANOVA -----
fit_manova <- manova(
  cbind(FL, RW, CL, CW, BD) ~ sp,
  data = dados_manova
)

# Testando com as 4 estatísticas
summary(fit_manova, test = "Wilks")
summary(fit_manova, test = "Pillai")
summary(fit_manova, test = "Hotelling")
summary(fit_manova, test = "Roy")

# ----- 4. ANOVAs univariadas como follow-up (post-hoc) -----
# Se a MANOVA rejeita H0, investigamos qual(is) variável(is) diferem
summary.aov(fit_manova)

```

Decomposição Manual: Matrizes H e E

```

# Calculando H e E manualmente para entender a estrutura

Y      <- as.matrix(dados_manova[, 2:6])
grupos <- unique(dados_manova$sp)
media_geral <- colMeans(Y)
N      <- nrow(Y)
p      <- ncol(Y)
g      <- length(grupos)

# Matriz E (within groups — erro)
E_mat <- Reduce("+", lapply(grupos, function(gr) {
  sub <- as.matrix(dados_manova[dados_manova$sp == gr, 2:6])
  xbar <- colMeans(sub)
  # Soma dos produtos cruzados dos desvios em torno da média do grupo
  t(sweep(sub, 2, xbar)) %*% sweep(sub, 2, xbar)
}))

```

```

# Matriz H (between groups — hipótese)
n_por_grupo <- table(dados_manova$sp)
H_mat <- Reduce("+", lapply(grupos, function(gr) {
  ni <- n_por_grupo[gr]
  xbar <- colMeans(as.matrix(dados_manova[dados_manova$sp == gr, 2:6]))
  diff <- xbar - media_geral
  # Produto externo ponderado pelo tamanho do grupo
  ni * outer(diff, diff)
}))

# Lambda de Wilks manual
Lambda <- det(E_mat) / det(H_mat + E_mat)
cat("Lambda de Wilks manual:", round(Lambda, 4), "\n")

# Estatística qui-quadrado aproximada
qui2 <- -(N - 1 - (p + g) / 2) * log(Lambda)
gl <- p * (g - 1)
pval <- pchisq(qui2, df = gl, lower.tail = FALSE)

cat("Estatística  $\chi^2$ :", round(qui2, 4), "\n")
cat("GL:", gl, "\n")
cat("p-valor:", round(pval, 6), "\n")

```

MANCOVA — MANOVA com Covariáveis

***Analogia:** Imagine que você quer comparar o desempenho cognitivo de pessoas que meditam vs. que fazem exercício. Mas o grupo de meditação é mais velho e mais escolarizado. Se você fizer a MANOVA direto, não sabe se a diferença vem da prática ou da idade/escolaridade. A MANCOVA **remove o efeito da idade e escolaridade primeiro** e então compara os grupos — como nivelar o campo de jogo antes da partida.*

Modelo

$$X_{kj} = \mu + \tau_k + \Gamma z_{kj} + \mathbb{I}_{kj}$$

- μ = média geral
- τ_k = efeito do grupo k (o que queremos testar)
- Γ = coeficientes das covariáveis (efeito a ser removido)

- $\mathbf{z}_{kj}$ = vetor de covariáveis da observação j do grupo k

Hipóteses

- H_0 : $\tau_1 = \tau_2 = \dots = \tau_g = 0$ (não há efeito de grupo após remover covariáveis)
- H_1 : pelo menos um $\tau_k \neq 0$

Quando usar MANOVA vs. MANCOVA?

Situação	Use
Grupos aleatorizados, sem variáveis de confusão	MANOVA
Grupos diferem em variáveis contínuas relevantes (idade, escore basal, etc.)	MANCOVA
Quer aumentar o poder controlando variabilidade extra	MANCOVA

***Suposição crítica da MANCOVA:** a relação entre a covariável e as variáveis dependentes deve ser **a mesma em todos os grupos** (homogeneidade das inclinações). Sempre teste isso antes!*

```
# Exemplo de MANCOVA em R
set.seed(42)
n_grupo <- 30

# Simulando dados com covariável confundidora (idade)
dados_mancova <- data.frame(
  grupo = rep(c("Meditacao", "Exercicio", "Controle"), each = n_grupo),
  idade = c(rnorm(n_grupo, 45, 8), rnorm(n_grupo, 35, 7), rnorm(n_grupo, 40, 9)),
  memoria = NA,
  atencao = NA,
  raciocinio = NA
)

# Desempenho influenciado pelo grupo E pela idade
for (i in 1:nrow(dados_mancova)) {
  efeito_grupo <- switch(dados_mancova$grupo[i],
    Meditacao = 5, Exercicio = 2, Controle = 0)
  dados_mancova$memoria[i] <- 50 + efeito_grupo + 0.3 * dados_mancova$idade[i] + r
  dados_mancova$atencao[i] <- 48 + efeito_grupo + 0.2 * dados_mancova$idade[i] + rr
```

```

dados_mancova$raciocinio[i] <- 52 + efeito_grupo + 0.4 * dados_mancova$idade[i] + rr
}

# ----- MANOVA sem controlar a covariável (pode ser enganosa) -----
fit_manova <- manova(
  cbind(memoria, atencao, raciocinio) ~ grupo,
  data = dados_mancova
)
summary(fit_manova, test = "Wilks")

# ----- MANCOVA controlando a idade -----
# Basta adicionar a covariável na fórmula com +
fit_mancova <- manova(
  cbind(memoria, atencao, raciocinio) ~ grupo + idade,
  data = dados_mancova
)
summary(fit_mancova, test = "Wilks")

# Comparando resultados:
# Lambda de Wilks deve mudar após controlar a idade
# Se a covariável era importante, o p-valor do grupo muda!

```

Insights do Professor (da transcrição)

“Rodar uma função qualquer IA te passa. Entender a construção do teste é o que diferencia. 90% das pessoas ficam só no primeiro nível — me passa a função. Poucos chegam no segundo: como eu obtenho essa estatística? Que suposições foram feitas?”

- **A regressão logística não foi criada agora** — foi proposta em 1972. Conhecer a história evita reinventar a roda e permite contextualizar os modelos
 - O TLC é o que nos permite **usar a matemática da distribuição normal no mundo real**, onde as populações raramente são normais
 - MANOVA e T^2 são **equivalentes** para $g = 2$ grupos — o T^2 é um caso particular da MANOVA
 - Para $p = 1$ variável, a MANOVA se reduz à ANOVA e o Lambda de Wilks se reduz ao F da ANOVA clássica
-

Próxima Aula

O professor avisou que na próxima aula entraremos em **Inferência sobre o vetor de médias de uma população** com mais profundidade:

- Região de confiança elipsoidal (versão multivariada do IC)
 - T^2 pareado (observações dependentes — ex.: antes/depois)
 - Início dos **Modelos Multivariados** (regressão multivariada)
-

Referências

- Johnson & Wichern — *Applied Multivariate Statistical Analysis*, Cap. 5 e 6
- Rencher, A. — *Methods of Multivariate Analysis*, Cap. 3 e 5
- Pacote DescTools — HotellingsT2Test() : <https://cran.r-project.org/package=DescTools>
- Pacote heplots — boxM() e heplot() : <https://cran.r-project.org/package=heplots>
- Pacote car — Manova() com diagnósticos: <https://cran.r-project.org/package=car>