

# Análise Multivariada — Anotações de Aula

## Aula 4: Modelos Multivariados — Regressão, Regressão Canônica e Correlação Canônica

*Professor: Vinícius Osterne, PhD*

*Observação do professor: "Aula super densa — densa para vocês, densa para mim também. A ideia é que vocês adquiram pelo menos 30 a 40% do conhecimento: a formulação do problema, como resolver. A caixa preta por trás, a nomenclatura — isso vem com o tempo."*

### Onde Estamos na Linha do Tempo

Introdução & Conceitos Prévios

Álgebra Linear

Análise Exploratória

Probabilidade & Inferência ( $T^2$ , MANOVA, MANCOVA)

Modelos Multivariados    HOJE

i. Regressão Multivariada

ii. Regressão Canônica

iii. Correlação Canônica

Estrutura dos Dados (PCA, Análise Fatorial)

Classificação & Agrupamento

### A Família dos Modelos com Múltiplos Y

*Analogia: Pense nas técnicas de hoje como três câmeras fotografando a mesma cena, mas com lentes diferentes. A **Regressão Multivariada** é uma câmera com zoom em cada detalhe separadamente. A **Regressão Canônica** usa uma lente panorâmica*

para ver o melhor ângulo de predição. A **Correlação Canônica** é como dois fotógrafos olhando um para o outro — sem hierarquia, só associação.

### A progressão lógica das técnicas de regressão:

Regressão Simples: 1 preditor X 1 desfecho Y

Regressão Múltipla: p preditores X 1 desfecho Y

Regressão Multivariada: p preditores X q desfechos Y HOJE (i)

Regressão Canônica: combinações de X combinações de Y HOJE (ii)

Correlação Canônica: associação simétrica entre X e Y HOJE (iii)

MANOVA: caso especial com X categórico (grupos)

## PARTE I — REGRESSÃO MULTIVARIADA

### O Modelo

***Analogia:** Na regressão múltipla você tem um painel de instrumentos com vários botões (X) controlando uma única saída (Y) — como a velocidade de um carro. Na regressão multivariada, você controla **vários resultados ao mesmo tempo** — velocidade, temperatura do motor e consumo — todos com os mesmos botões.*

#### Modelo formal:

$$\mathbf{Y}_{n \times q} = \mathbf{X}_{n \times p} \mathbf{B}_{p \times q} + \mathbf{E}_{n \times q}$$

Onde:

- **Y** ( $n \times q$ ): matriz de **q desfechos** (cada coluna = uma variável resposta)
- **X** ( $n \times p$ ): matriz de **p preditores** (com coluna de 1s para o intercepto)
- **B** ( $p \times q$ ): matriz de coeficientes —  $\beta_{jk}$  = efeito do preditor  $X_j$  sobre o desfecho  $Y_k$
- **E** ( $n \times q$ ): erros com distribuição  $\text{vec}(\mathbf{E}) \sim N(0, \Sigma \otimes \mathbf{I}_n)$

***O que é  $\Sigma \otimes \mathbf{I}_n$ ?** Diz duas coisas ao mesmo tempo:  $\Sigma$  captura a correlação entre os desfechos do mesmo indivíduo (pressão sistólica e diastólica do mesmo paciente são correlacionadas).  $\mathbf{I}_n$  garante que indivíduos diferentes são independentes entre si.*

### Estimação

O estimador de mínimos quadrados é:

$$\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

*Insight crucial: cada coluna de  $\hat{\mathbf{B}}$  é **idêntica** ao estimador de uma regressão múltipla separada para aquele desfecho. A vantagem do modelo conjunto **não está nos coeficientes**, mas na **inferência** — que leva em conta a correlação entre os desfechos via  $\hat{\Sigma}$ .*

A matrix de covariância residual é estimada por:

$$\hat{\Sigma} = \frac{1}{n - p} \hat{\mathbf{E}}^\top \hat{\mathbf{E}}$$

## Suposições

1. **Linearidade** entre X e cada  $Y_j$
2. **Normalidade multivariada** dos erros:  $\mathbf{e} \sim N_q(0, \Sigma)$
3. **Homogeneidade de covariâncias**:  $\text{Cov}(\mathbf{e}_i) = \Sigma$  para todo i
4. **Independência** entre as observações
5. **Ausência de multicolinearidade** entre os preditores

## Interpretação: dois níveis

1. **Nível multivariado (primário)**: os testes (Wilks, Pillai, etc.) indicam se um preditor influencia o **conjunto de desfechos** como um todo. Só avance para o próximo nível se houver significância aqui.
2. **Nível univariado (secundário)**: após confirmar a significância multivariada, examine cada equação separadamente — quais desfechos são afetados por quais preditores.

## Exemplo Prático — Dataset `state.x77` (censo EUA, 1977)

O professor usou este dataset em aula: 50 estados norte-americanos com variáveis socioeconômicas.

- **Desfechos Y**: `vida` (expectativa), `homicidio` (taxa), `analfabetismo`
- **Preditores X**: `renda`, `diploma` (% com ensino superior), `geadas`

```
# Carregando e preparando os dados
dados <- as.data.frame(state.x77)
```

```

# Renomeando para português
names(dados) <- c("populacao", "renda", "analfabetismo",
                  "vida", "homicidio", "diploma", "geadas", "area")

# ---- Diagnóstico pré-regressão ----

# 1. Verificar linearidade: gráficos de dispersão
pairs(dados[, c("vida", "homicidio", "analfabetismo",
               "renda", "diploma", "geadas")],
      col = "steelblue", pch = 16, cex = 0.7)

# 2. Normalidade multivariada dos desfechos (distância de Mahalanobis)
vars_desfecho <- c("vida", "homicidio", "analfabetismo")
Y_desc <- as.matrix(dados[, vars_desfecho])
xbar <- colMeans(Y_desc)
S_inv <- solve(cov(Y_desc))
d2 <- apply(Y_desc, 1, function(x) t(x - xbar) %*% S_inv %*% (x - xbar))

# Teste KS: H0 = os dados seguem distribuição chi-quadrado(p)
ks_resultado <- ks.test(d2, "pchisq", df = length(vars_desfecho))
cat("KS p-valor:", round(ks_resultado$p.value, 4), "\n")
# Se p > 0.05: não rejeita H0 normalidade multivariada plausível

# QQ-plot qui-quadrado
qqplot(qchisq(ppoints(nrow(dados)), df = 3), d2,
      main = "QQ-Plot: normalidade multivariada dos desfechos",
      xlab = "Quantis  $\chi^2(3)$ ", ylab = "D2 de Mahalanobis")
abline(0, 1, col = "red", lwd = 2)

# ---- Ajuste da Regressão Multivariada ----
# Sintaxe: cbind(Y1, Y2, Y3) ~ X1 + X2 + X3
fit <- lm(
  cbind(vida, homicidio, analfabetismo) ~ renda + diploma + geadas,
  data = dados
)

# Coeficientes: cada COLUNA corresponde a um desfecho
coef(fit)
# Exemplo de leitura: coef["renda", "vida"] = efeito da renda sobre expectativa de vida

```

```

# Resumo univariado (um modelo por desfecho)
summary(fit)

# Note: os coeficientes são os mesmos que em regressões separadas,
# mas os testes de hipótese podem diferir quando se usa a inferência conjunta

# ---- Testes de Hipótese Multivariados ----
# Usa as mesmas 4 estatísticas da MANOVA
fit_manova <- manova(
  cbind(vida, homicidio, analfabetismo) ~ renda + diploma + geadas,
  data = dados
)

summary(fit_manova, test = "Wilks")  # Lambda de Wilks (mais comum)
summary(fit_manova, test = "Pillai")  # Traço de Pillai (mais robusto)
summary(fit_manova, test = "Hotelling")  # Traço de Lawley-Hotelling
summary(fit_manova, test = "Roy")  # Maior raiz de Roy

# ---- Testando cada preditor individualmente ----
for (pred in c("renda", "diploma", "geadas")) {
  formula_str <- paste("cbind(vida, homicidio, analfabetismo) ~", pred)
  fit_uni <- manova(as.formula(formula_str), data = dados)
  cat("\nPreditor:", pred, "\n")
  print(summary(fit_uni, test = "Wilks"))
}

# ---- Diagnóstico dos resíduos ----
# Resíduos multivariados: cada observação tem um VETOR de resíduos
residuos <- residuals(fit)

# Normalidade dos resíduos por desfecho
par(mfrow = c(1, 3))
for (j in 1:3) {
  qqnorm(residuos[, j], main = paste("QQ-Plot:", vars_desfecho[j]))
  qqline(residuos[, j], col = "red")
}
par(mfrow = c(1, 1))

```

---

# PARTE ii — REGRESSÃO CANÔNICA

## Motivação

*Analogia: Imagine um aluno com 3 hábitos (estudo, frequência, sono) e 4 notas (Matemática, Português, Ciências, História). As notas são todas correlacionadas — um aluno esforçado tende a ir bem em tudo. Modelar cada nota separadamente **desperdiça essa estrutura**. A regressão canônica pergunta: “existe uma combinação dos hábitos que resume bem a performance geral?”*

Diferença da regressão multivariada:

| Aspecto     | Regressão Multivariada                | Regressão Canônica                                |
|-------------|---------------------------------------|---------------------------------------------------|
| Opera em    | Variáveis originais                   | Combinações lineares (canônicas)                  |
| Prediz      | Cada $Y_j$ diretamente                | Combinações de $Y$ a partir de combinações de $X$ |
| Útil quando | Desfechos relativamente independentes | Desfechos muito correlacionados entre si          |

## Variáveis Canônicas

$$U_k = \mathbf{a}_k^T \mathbf{X} \quad \text{e} \quad V_k = \mathbf{b}_k^T \mathbf{Y}$$

Os vetores  $\mathbf{a}_k$  e  $\mathbf{b}_k$  são encontrados **maximizando**  $\text{Cor}(U_k, V_k) = \rho_k$ , sujeito a  $\text{Var}(U_k) = \text{Var}(V_k) = 1$  e não correlação com pares anteriores.

A solução vem dos **autovalores** da matriz:  $\Sigma^{-1}_{XX} \Sigma_{XY} \Sigma^{-1}_{YY} \Sigma_{YX}$

*Conexão com autovalores (Aula 2)! Mais uma vez os autovalores aparecem — eles são o denominador comum de toda a estatística multivariada.*

## Número de Pares e Qualidade

- São obtidos  $r = \min(p, q)$  pares canônicos com  $\rho_1 \geq \rho_2 \geq \dots \geq \rho_r \geq 0$
- O **1º par** captura a maior predição possível
- O **2º par** captura a maior predição residual, ortogonal ao 1º
- Na prática, **apenas os primeiros pares são significativos**

*Armadilha —  $\rho_k$  alto pode enganar! Uma correlação canônica alta entre  $U_k$  e  $V_k$  não garante que essas combinações representem bem as variáveis originais. Use sempre o **índice de redundância** para medir a qualidade real:*

$$\text{Rd}(Y | X) = \frac{1}{q} \sum_{k=1}^r \rho_k^2 \cdot \sum_{j=1}^q r^2(Y_j, V_k)$$

## Teste de Bartlett (quantos pares são significativos?)

O teste sequencial avalia par a par:

$$\chi_k^2 \approx - \left[ n - 1 - \frac{1}{2}(p + q + 1) \right] \ln \prod_{i=k}^r (1 - \rho_i^2)$$

Procedimento: testa todos se rejeita, remove  $\rho_1$  e testa o restante continua até não rejeitar.

## PARTE iii — CORRELAÇÃO CANÔNICA

### A Diferença Fundamental: Simetria

*Analogia: A regressão canônica é como uma rua de mão única —  $X$  prediz  $Y$ , há hierarquia. A correlação canônica é uma **praça pública** —  $X$  e  $Y$  têm papel equivalente, nenhum prediz o outro, apenas se associam.*

**Enquanto a regressão canônica pergunta:** “quanto  $X$  prediz  $Y$ ?”

**A correlação canônica pergunta:** “como  $X$  e  $Y$  se associam?”

Na prática, os **cálculos são idênticos** — a distinção está no objetivo e na interpretação.

### O que muda ao trocar $X$ e $Y$ ?

|                                | Muda?                        |
|--------------------------------|------------------------------|
| Correlações canônicas $\rho_k$ | Não mudam                    |
| Testes de significância        | Não mudam                    |
| Vetores $a_k$ e $b_k$          | Mudam (mas de forma análoga) |

|                          |      |
|--------------------------|------|
| Interpretação das cargas | Muda |
|--------------------------|------|

## Três Níveis de Interpretação

1. **Correlações canônicas ( $\rho_k$ ):** força da associação entre o k-ésimo par.  $\rho_k^2 =$  proporção de variância compartilhada entre  $U_k$  e  $V_k$ .
2. **Cargas canônicas:** correlação entre variáveis originais e variáveis canônicas do **mesmo conjunto**. Permitem nomear as dimensões latentes ("este par representa o fator de dedicação").
3. **Cargas cruzadas:** correlação entre variáveis de X e variáveis canônicas de Y (e vice-versa). São a medida **mais direta** de associação entre os conjuntos.

## Comparativo Final das Três Técnicas

| Aspecto                    | Reg. Multivariada       | Reg. Canônica         | Corr. Canônica               |
|----------------------------|-------------------------|-----------------------|------------------------------|
| <b>Relação</b>             | Assimétrica             | Assimétrica           | <b>Simétrica</b>             |
| <b>Objetivo</b>            | Predição direta         | Predição em dimensões | <b>Associação</b>            |
| <b>Opera em</b>            | Variáveis originais     | Vars. canônicas       | Vars. canônicas              |
| <b>Pergunta</b>            | Quais X afetam quais Y? | Como X resume Y?      | Como X e Y se relacionam?    |
| <b>Medida de qualidade</b> | $R^2$ por desfecho      | Índice de redundância | Correlação canônica $\rho_k$ |

## Código R — Correlação Canônica

```
# install.packages("CCA") # pacote especializado para correlação canônica
library(CCA)

# Usando o dataset state.x77 — mesmas variáveis do exemplo anterior
# X: condições socioeconômicas
# Y: indicadores de saúde/educação
X <- scale(dados[, c("renda", "diploma", "geadas")]) # padronizando
```



```

Y <- scale(dados[, c("vida", "homicidio", "analfabetismo")])

# Ajuste da correlação canônica
cc_result <- cc(X, Y)

# Correlações canônicas ( $\rho_k$ )
cat("Correlações canônicas:\n")
print(round(cc_result$cor, 4))
#  $\rho_1 \geq \rho_2 \geq \rho_3$  ( $r = \min(3,3) = 3$  pares)

# Coeficientes canônicos (vetores  $a_k$  e  $b_k$ )
cat("\nCoeficientes canônicos de X ( $a_k$ ):\n")
print(round(cc_result$xcoef, 4))
cat("\nCoeficientes canônicos de Y ( $b_k$ ):\n")
print(round(cc_result$ycoef, 4))

# Cargas canônicas e cruzadas
cc_comp <- comput(X, Y, cc_result)

cat("\nCargas canônicas de X:\n")
print(round(cc_comp$corr.X.xscores, 4))

cat("\nCargas cruzadas (X com scores de Y):\n")
print(round(cc_comp$corr.X.yscores, 4))

# ---- Teste de Bartlett (quantos pares são significativos?) ----
# install.packages("CCP")
library(CCP)

n <- nrow(X)
p <- ncol(X)
q <- ncol(Y)

# Teste sequencial de Wilks para os pares canônicos
p_vals <- p.asym(rho = cc_result$cor, n = n, p = p, q = q, tstat = "Wilks")
print(p_vals)
# Interpreta: qual o menor k tal que o p-valor > 0.05?
# Pares anteriores a esse k são significativos

# ---- Visualizando os pares canônicos ----

```

```

# Scores canônicos
U <- X %*% cc_result$xcoef # scores de X
V <- Y %*% cc_result$ycoef # scores de Y

par(mfrow = c(1, min(2, ncol(U))))
for (k in 1:min(2, ncol(U))) {
  plot(U[, k], V[, k],
       main = paste0("Par canônico ", k, " (ρ = ", round(cc_result$cor[k, 2], 2), ")",
       xlab = paste0("U", k, " (combinação de X)",
       ylab = paste0("V", k, " (combinação de Y)",
       col = "steelblue", pch = 16, cex = 0.8)
  abline(lm(V[, k] ~ U[, k]), col = "red", lwd = 2)
  # Nuvem alongada = alta correlação; nuvem circular = baixa correlação
}
par(mfrow = c(1, 1))

# ---- Índice de redundância ----
# Mede quanto de Y é predito pelo conjunto X (melhor que ρ sozinho)
#  $R_d = (1/q) * \sum \rho_k^2 * \sum r^2(Y, V_k)$ 
cargas_Y <- cc_comp$corr.Y.scores # cargas canônicas de Y
rho2 <- cc_result$cor^2 # quadrado das correlações canônicas

Rd <- mean(sapply(1:length(rho2), function(k) {
  rho2[k] * mean(cargas_Y[, k]^2)
}))
cat("\nÍndice de Redundância Rd(Y|X):", round(Rd, 4), "\n")
cat("Interpretação: X explica em média", round(Rd*100, 1),
    "% da variância de Y\n")

```

## Insights do Professor (da transcrição)

*“Isolation Forest é uma abordagem baseada em árvore para detectar outliers. Mas uma distância de Mahalanobis é capaz de identificar o mesmo — com suas restrições, claro, como a suposição de normalidade. Existem técnicas mais simples que podem detectar o mesmo.”*

- A distância de Mahalanobis (vista na Aula 2) é a fundação da detecção de outliers multivariados — mas tem restrições (normalidade). Isolation Forest e deep learning ampliam isso sem suposições.

- A regressão multivariada e a MANOVA são **casos da mesma família** — a MANOVA é regressão multivariada com preditores categóricos.
  - A sugestão do professor para o trabalho final: **comparar** o modelo de regressão multivariada com regressões univariadas separadas — os coeficientes são idênticos, mas os testes de hipótese podem diferir por conta da estrutura de correlação  $\Sigma$ .
  - *“Tudo que eu tinha no meu caderno na graduação, mercado, doutorado — digitei em LaTeX. Essa é a forma que eu encontrei de aprender melhor: anotar não só o que o professor escreve no quadro, mas o que ele fala.”*
- 

## Próxima Aula — Estrutura dos Dados

O professor anunciou que entraremos em:

- **PCA (Análise de Componentes Principais):** redução de dimensionalidade — onde os **autovalores e autovetores da Aula 2** finalmente ganham seu papel central
  - **Análise Fatorial:** estruturas latentes por trás das variáveis observadas
- 

## Referências

- Johnson & Wichern — *Applied Multivariate Statistical Analysis*, Cap. 7 (Reg. Multivariada) e Cap. 10 (Correlação Canônica)
- Rencher, A. — *Methods of Multivariate Analysis*, Cap. 8 e 11
- Pacote CCA : <https://cran.r-project.org/package=CCA>
- Pacote CCP (testes de significância para correlação canônica): <https://cran.r-project.org/package=CCP>
- Dataset `state.x77` : nativo do R — `?state.x77` no console