

Análise Multivariada — Anotações de Aula

Aula 5: Estrutura dos Dados & Classificação — PCA, Análise Fatorial e Clustering

Professor: Vinícius Osterne, PhD

Frase da aula: "Pra mim, Multivariada é a mais linda disciplina que tem na estatística. São muitos detalhezinhas que quem não é formado em estatística vai deixar passar — e eu não quero que deixe passar."

"Sentiram uma carga fatorial muito forte hoje."

Onde Estamos na Linha do Tempo

Introdução & Conceitos Prévios

Álgebra Linear

Análise Exploratória

Probabilidade & Inferência

Modelos Multivariados

Estrutura dos Dados HOJE

i. PCA (Análise de Componentes Principais)

ii. Análise de Correspondência

iii. Análise Fatorial Exploratória (AFE)

iv. Análise Fatorial Confirmatória (AFC)

Classificação & Agrupamento HOJE

Clustering Hierárquico

K-means

Apresentação dos Trabalhos (Encontro 6)

PARTE I — PCA: ANÁLISE DE COMPONENTES PRINCIPAIS

O que é PCA?

Analogia: Imagine que você tem 20 fotos da mesma pessoa, tiradas de ângulos levemente diferentes. Você poderia descrevê-las com 20 números (os ângulos). Mas com apenas 2 ou 3 ângulos “principais”, você já consegue explicar a maior parte das diferenças entre as fotos. A PCA faz exatamente isso: encontra os ângulos mais informativos nos dados.

A PCA é uma técnica de **redução de dimensionalidade** que transforma p variáveis originais correlacionadas em $k < p$ componentes principais **não correlacionadas**, ordenadas da que captura mais variância para a que captura menos.

*Conexão fundamental com a Aula 2: A PCA é literalmente a **decomposição espectral** da matriz de covariância — os autovetores são as direções das componentes, os autovalores são a variância de cada componente.*

O Problema de Otimização

A PCA busca o vetor $\mathbf{e}_1$ que maximiza a variância da projeção:

$$\text{maximizar } \text{Var}(\mathbf{e}_1^\top \mathbf{X}) = \mathbf{e}_1^\top \Sigma \mathbf{e}_1 \quad \text{sujeito a } \mathbf{e}_1^\top \mathbf{e}_1 = 1$$

Usando multiplicadores de Lagrange:

$$\frac{\partial h}{\partial \mathbf{e}_1} = 2\Sigma \mathbf{e}_1 - 2\lambda \mathbf{e}_1 = 0 \implies (\Sigma - \lambda \mathbf{I})\mathbf{e}_1 = 0$$

Essa é exatamente a **equação de autovalores**: λ é autovalor de Σ e $\mathbf{e}_1$ é o autovetor associado. Como queremos maximizar a variância $= \lambda$, escolhemos o **maior autovalor** λ_1 .

As demais componentes seguem em ordem: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$.

Variância Explicada e Critérios de Retenção

A proporção da variância explicada pela k -ésima componente:

$$\lambda_k$$

$$\sum_{i=1}^p \lambda_i$$

Critério	Regra
Kaiser	Reter componentes com $\lambda_k > 1$ (dados padronizados)
Variância acumulada	Reter até atingir 70%–80% da variância total
Scree plot (cotovelo)	Reter até o ponto de inflexão do gráfico de autovalores
Análise paralela	Comparar autovalores observados com os de dados aleatórios — mais rigoroso

Recomendação: use mais de um critério e triângule com a interpretabilidade das componentes.

Covariância ou Correlação?

	Matriz de Covariância (Σ)	Matriz de Correlação (P)
Quando usar	Variáveis na mesma escala	Variáveis em escalas diferentes
Risco	Variáveis com maior variância dominam	—
Equivale a	—	Padronizar antes da PCA

Na prática: quando as variáveis têm escalas diferentes (ex: salário em R\$ e idade em anos), sempre use a matriz de correlação — ou padronize com `scale()` antes de `prcomp()`.

Exemplo Numérico (do slide)

Para $S = [[3,1],[1,3]]$, os autovalores são $\lambda_1 = 4$ e $\lambda_2 = 2$:

- **1ª componente** (v_1): captura $4/6 \approx 67\%$ da variância
- **2ª componente** (v_2): captura $2/6 \approx 33\%$ da variância

Com apenas a 1ª componente, já retemos 2/3 da informação — esse é o ganho da PCA.

Código R — PCA Completo

```
# install.packages(c("factoextra", "ggplot2"))
library(factoextra)
library(ggplot2)

# Usando o dataset USArrests (nativo do R): 4 variáveis criminais nos 50 estados
data(USArrests)
head(USArrests)

# ---- 1. Decisão: covariância ou correlação? ----
# Variáveis em escalas diferentes usamos correlação (scale = TRUE)
pca_result <- prcomp(USArrests, scale = TRUE)

# Resumo: variância explicada por cada componente
summary(pca_result)
# Proportion of Variance proporção de cada CP
# Cumulative Proportion acumulado

# ---- 2. Autovalores e variância explicada ----
autovalores <- pca_result$sdev^2 # sdev = desvio padrão das CPs; sdev^2 = autovalores
var_exp <- autovalores / sum(autovalores)
var_acum <- cumsum(var_exp)

cat("Autovalores ( $\lambda$ ):", round(autovalores, 3), "\n")
cat("Variância explicada:", round(var_exp * 100, 1), "%\n")
cat("Variância acumulada:", round(var_acum * 100, 1), "%\n")

# ---- 3. Scree plot (gráfico do cotovelo) ----
fviz_eig(pca_result,
  addlabels = TRUE,
  ylim = c(0, 60),
  main = "Scree Plot — PCA de USArrests",
  xlab = "Componente Principal",
  ylab = "% de Variância Explicada")
# Busque o "cotovelo" — onde a queda desacelera bruscamente

# ---- 4. Autovetores (loadings) ----
# Cada coluna é um autovetor — define a direção da componente
loadings <- pca_result$rotation
```

```

print(round(loadings, 3))
# Exemplo de leitura: loading[j, k] = correlação entre variável j e CP k
# Valores altos (|. | > 0.4 é comum) indicam contribuição relevante

# ---- 5. Scores: projeção dos dados nas novas CPs ----
scores <- pca_result$x # cada linha = uma observação no novo sistema de coordenada

# ---- 6. Biplot: variáveis e observações no mesmo espaço ----
fviz_pca_biplot(pca_result,
  repel = TRUE, # evita sobreposição de rótulos
  col.var = "darkorange",
  col.ind = "steelblue",
  title = "Biplot PCA — USArrests")
# Setas longas  variável com alta variância nessa direção
# Setas próximas  variáveis correlacionadas
# Setas opostas  correlação negativa

# ---- 7. Contribuição das variáveis por CP ----
fviz_contrib(pca_result, choice = "var", axes = 1,
  title = "Contribuição das Variáveis para CP1")
fviz_contrib(pca_result, choice = "var", axes = 2,
  title = "Contribuição das Variáveis para CP2")

# ---- 8. Análise paralela (critério mais rigoroso) ----
# install.packages("paran")
library(paran)
paran(USArrests, iterations = 5000, centile = 95, status = FALSE)
# Retém componentes cujos autovalores observados > autovalores aleatórios simulado

```

PARTE iii — ANÁLISE FATORIAL EXPLORATÓRIA (AFE)

***Analogia:** A PCA pergunta: “como posso resumir esses dados em menos dimensões, maximizando a variância?” A AFE pergunta algo diferente: “existe alguma variável latente — invisível, não medida diretamente — que explica as correlações que eu observo entre as minhas variáveis?”*

Pense num questionário de saúde. As questões sobre dores musculares, dores nas costas e fôlego são correlacionadas porque todas refletem um fator latente subjacente: **saúde física**. A AFE tenta descobrir esses fatores ocultos.

PCA vs. AFE — A distinção fundamental

Aspecto	PCA	AFE
Pergunta	Como resumir a variância total?	Quais fatores latentes causam as correlações?
Objetivo	Redução de dimensionalidade	Descoberta de estrutura latente
Variância	Explica toda a variância (incluindo erro)	Separa variância comum de variância específica
Resultado	Componentes (combinações lineares de X)	Fatores latentes não observáveis
Uso típico	Pré-processamento, visualização	Validação de escalas, construção de constructos

O Modelo Fatorial

$$\mathbf{Z} = \mathbf{L}\mathbf{F} + \mathbf{\epsilon}$$

Desenvolvendo para cada variável padronizada Z :

$$Z_i = l_{i1}F_1 + l_{i2}F_2 + \dots + l_{im}F_m + \epsilon_i$$

Onde:

- $\mathbf{F}$ = vetor de fatores latentes (não observáveis)
- $\mathbf{L}$ = matriz de **cargas fatoriais** ($p \times m$) — o que queremos estimar
- $\boldsymbol{\epsilon}$ = erros aleatórios específicos de cada variável
- l_{ij} = carga fatorial: correlação entre Z_i e F_j

Suposições do modelo ortogonal:

- $E(\mathbf{F}) = \mathbf{0}$, $\text{Var}(\mathbf{F}) = \mathbf{I}$ (fatores padronizados)
- $E(\boldsymbol{\epsilon}) = \mathbf{0}$, $\text{Var}(\boldsymbol{\epsilon}) = \boldsymbol{\Psi}$ (diagonal — erros não correlacionados)
- $\mathbf{F}$ e $\boldsymbol{\epsilon}$ são não correlacionados

Comunalidade e Variância Específica

$$\text{Var}(Z_i) = \underbrace{\sum_{j=1}^m l_{ij}^2}_{h_i^2 \text{ (comunalidade)}} + \underbrace{\Psi_i}_{\text{variância específica}} = 1$$

Comunalidade h^2 = proporção da variância de Z explicada pelos fatores comuns. Quanto maior, mais a variável é "capturada" pelo modelo. Valores baixos ($< 0,5$) indicam que a variável não se encaixa bem na estrutura fatorial.

Pipeline da AFE (na ordem correta!)

O professor mostrou em aula esta sequência obrigatória:

1. Análise descritiva inicial
2. Pré-testes de adequação (Bartlett + KMO)
3. Escolha do número de fatores (Kaiser + Scree + Análise Paralela)
4. Extração dos fatores
5. Rotação (se necessário)
6. Interpretação e nomeação dos fatores

Pré-testes de Adequação

Teste de Bartlett: testa H_0 : a matriz de correlação é uma matriz identidade.

- Se **rejeitar H_0** ($p < 0,05$) há correlações entre as variáveis AFE é aplicável
- Se não rejeitar não há correlação AFE não faz sentido

KMO (Kaiser-Meyer-Olkin): mede a adequação amostral para cada variável e globalmente.

KMO	Adequação
$\geq 0,90$	Excelente
$0,80 - 0,89$	Boa
$0,70 - 0,79$	Média
$0,60 - 0,69$	Razoável (limiar mínimo)
$< 0,50$	Inaceitável

O professor mencionou que em aula todos os itens deram acima de 0,60 — suficiente para prosseguir.

Rotação de Fatores — Por que Rotacionar?

Analogia: Imagine que você tem um mapa com dois eixos (norte-sul e leste-oeste). Os fatores iniciais são como eixos em posições matematicamente convenientes, mas que cortam os dados em diagonais confusas. A rotação gira esses eixos para que cada fator aponte para um “grupo” mais claro de variáveis — mantendo a qualidade do ajuste, mas facilitando a interpretação.

Tipos de rotação:

Tipo	Método	Fatores correlacionados?	Quando usar
Ortogonal	Varimax (Kaiser, 1958)	Não	Fatores independentes — mais comum, mais fácil de interpretar
Ortogonal	Quartimax	Não	Quando suspeita de um fator geral dominante
Oblíqua	Oblimin, Promax	Sim	Ciências humanas e da saúde, onde fatores raramente são independentes

Varimax maximiza a variabilidade das cargas dentro de cada fator — produz cargas altas para algumas variáveis e próximas de zero para as demais, facilitando a atribuição de cada variável a um único fator.

O que aconteceu em aula (transcrição)

O professor mostrou que **sem rotação** as cargas eram ambíguas: a questão 4 carregava simultaneamente em F1 e F3, e a questão 9 carregava no fator errado. **Após a rotação Varimax**, a estrutura ficou clara:

- Questões 1–4 **Fator 1**
- Questões 5–8 **Fator 3**
- Questões 9–12 **Fator 2**

Que o professor suspeitava corresponderam a: saúde física, saúde mental e vida social.

Código R — AFE Completo

```
# install.packages(c("psych", "GPArotation"))
library(psych)

# Usando um questionário simulado: 12 itens, 3 fatores latentes esperados
set.seed(42)
n <- 300
# Fator 1: físico (itens 1-4), Fator 2: social (9-12), Fator 3: mental (5-8)
F1 <- rnorm(n); F2 <- rnorm(n); F3 <- rnorm(n)
questionario <- data.frame(
  q1 = 0.7*F1 + rnorm(n, 0, 0.5), q2 = 0.8*F1 + rnorm(n, 0, 0.5),
  q3 = 0.6*F1 + rnorm(n, 0, 0.5), q4 = 0.7*F1 + rnorm(n, 0, 0.5),
  q5 = 0.8*F3 + rnorm(n, 0, 0.5), q6 = 0.7*F3 + rnorm(n, 0, 0.5),
  q7 = 0.6*F3 + rnorm(n, 0, 0.5), q8 = 0.7*F3 + rnorm(n, 0, 0.5),
  q9 = 0.7*F2 + rnorm(n, 0, 0.5), q10 = 0.8*F2 + rnorm(n, 0, 0.5),
  q11 = 0.6*F2 + rnorm(n, 0, 0.5), q12 = 0.7*F2 + rnorm(n, 0, 0.5)
)

# ---- PASSO 1: Pré-testes de adequação ----

# Teste de Bartlett: H0 = matriz de correlação é identidade
# Rejeitar H0 é pré-requisito para a AFE
bartlett_teste <- cortest.bartlett(cor(questionario), n = n)
cat("Bartlett  $\chi^2$ :", round(bartlett_teste$chisq, 2),
    "| p-valor:", round(bartlett_teste$p.value, 4), "\n")
# p < 0.05 rejeita H0 há correlações AFE aplicável

# KMO: mede adequação amostral
kmo_resultado <- KMO(questionario)
cat("KMO global:", round(kmo_resultado$MSA, 3), "\n")
print(round(kmo_resultado$MSAi, 3)) # KMO por item — identifica variáveis problemáticas
# Itens com KMO < 0.5 devem ser considerados para remoção

# ---- PASSO 2: Critérios para número de fatores ----

# Critério de Kaiser (autovalores > 1)
autovalores_r <- eigen(cor(questionario))$values
cat("Autovalores:", round(autovalores_r, 2), "\n")
cat("Número por Kaiser ( $\lambda > 1$ ):", sum(autovalores_r > 1), "\n")
```

```
# Scree plot
fa.parallel(questionario, fa = "fa", n.iter = 100,
            main = "Análise Paralela + Scree Plot")
# A linha pontilhada é o critério aleatório (análise paralela)
# Reter fatores cujos autovalores reais (linha sólida) estão acima da linha pontilhada

# ---- PASSO 3: Extração dos fatores (SEM rotação) ----
afe_sem_rot <- fa(questionario, nfactors = 3, rotate = "none", fm = "ml")
# fm = "ml" máxima verossimilhança (permite teste de hipóteses)
# fm = "pa" fatores principais (mais robusto à não normalidade)
print(afe_sem_rot$loadings, cutoff = 0.3)
# cutoff = 0.3 suprime cargas pequenas para facilitar a leitura

# ---- PASSO 4: Rotação Varimax ----
afe_varimax <- fa(questionario, nfactors = 3, rotate = "varimax", fm = "ml")
print(afe_varimax$loadings, cutoff = 0.3)
# Agora cada item deve carregar claramente em um único fator

# Comunalidades ( $h^2$ ): proporção da variância explicada pelos fatores
cat("\nComunalidades:\n")
print(round(afe_varimax$communalities, 3))
#  $h^2$  baixa (<0.5) indica que o item não é bem explicado pelo modelo

# Variância explicada por fator
cat("\nVariância explicada por fator:\n")
print(afe_varimax$Vaccounted)

# ---- PASSO 5: Visualização das cargas fatoriais ----
fa.diagram(afe_varimax,
            main = "Estrutura Fatorial com Rotação Varimax")

# ---- PASSO 6: Escores fatoriais ----
# Gera um score fatorial para cada observação em cada fator
escores <- afe_varimax$scores
head(round(escores, 3))
# Cada coluna é um fator latente estimado — pode ser usado em análises subseqüente
```

PARTE iv — ANÁLISE FATORIAL

CONFIRMATÓRIA (AFC)

Analogia: A AFE é como ser um detetive sem pistas prévias — você coleta evidências e descobre a estrutura dos dados. A AFC é como ter uma teoria e ir a campo testá-la: você já sabe que quer 3 fatores específicos e verifica se os dados são compatíveis com essa estrutura.

	AFE	AFC
Objetivo	Descobrir estrutura	Testar estrutura pré-definida
Hipótese prévia	Não	Sim (baseada em teoria)
Cargas	Todas livres (estimadas)	Algumas fixadas em 0 ou 1
Avaliação	Interpretação das cargas	Índices de ajuste (CFI, RMSEA, SRMR)
Fase da pesquisa	Exploratória	Confirmatória
Ferramenta	psych::fa()	lavaan (SEM)

O professor avisou: na próxima aula haverá uma breve revisão da AFC antes das apresentações.

PARTE v — CLUSTERING: CLASSIFICAÇÃO E

AGRUPAMENTO

*Analogia: Imagine que você tem 1.000 pacientes sem diagnóstico. Você não sabe se são grupos homogêneos ou não. O clustering é como a triagem de um hospital: agrupa os pacientes por similaridade de sintomas, sem saber de antemão quais grupos existem. É aprendizado **não supervisionado** — sem rótulos, sem classes pré-definidas.*

Clustering Hierárquico (Aglomerativo)

***Analogia:** Começa com cada paciente sendo seu próprio grupo (n clusters). Em cada passo, os dois grupos mais parecidos se fundem — como famílias se reunindo num casamento. O processo para quando todos estão num único grupo gigante. O **dendrograma** registra toda a história dessas fusões.*

Algoritmo:

1. Cada observação é um cluster (n clusters iniciais)
2. Calcula todas as distâncias entre pares de clusters
3. Funde os dois clusters mais próximos
4. Recalcula as distâncias
5. Repete até restar 1 cluster

Métodos de ligação (linkage) — como medir distância entre clusters:

Método	Distância usada	Característica
Ligação simples	Mínima entre todos os pares	Efeito de encadeamento (clusters alongados)
Ligação completa	Máxima entre todos os pares	Clusters compactos
Ligação média	Média de todos os pares	Compromisso
Ward	Minimiza variância total intra-cluster após fusão	Mais recomendado — clusters homogêneos

```
# Clustering hierárquico em R
library(factoextra)

# Usando iris (nativo) sem os rótulos de espécie
dados_cl <- scale(iris[, 1:4]) # padronizando (obrigatório!)

# Calculando matriz de distâncias euclidianas
dist_mat <- dist(dados_cl, method = "euclidean")

# Ajuste com linkage de Ward
hc_ward <- hclust(dist_mat, method = "ward.D2")

# Dendrograma
plot(hc_ward, main = "Dendrograma — Ward",
     xlab = "Observações", sub = "", cex = 0.5)
```

```
# Corte a uma altura que produza k clusters
rect.hclust(hc_ward, k = 3, border = c("red","blue","green"))

# Extraíndo os rótulos de cluster com k=3
clusters_hc <- cutree(hc_ward, k = 3)
table(clusters_hc)

# Comparando com as espécies reais (se disponível)
table(Real = iris$Species, Cluster = clusters_hc)

# Visualização dos clusters no espaço das 2 primeiras CPs
fviz_cluster(list(data = dados_cl, cluster = clusters_hc),
  main = "Clusters Hierárquicos (Ward, k=3)")
```

K-means — Clustering Particional

Analogia: O K-means é como dividir uma sala de estudantes em k grupos para projetos. Você sorteia k “líderes” aleatoriamente, cada estudante vai para o grupo do líder mais próximo de si, recalculam-se os líderes como o centro de cada grupo, e o processo se repete até ninguém mais querer mudar de grupo.

Algoritmo:

1. Inicializa k centróides aleatoriamente
2. Aloca cada observação ao cluster cujo centróide é mais próximo (distância euclidiana)
3. Recalcula os centróides como a média das observações em cada cluster
4. Repete 2–3 até convergência

O K-means **minimiza a WCSS** (soma dos quadrados intra-cluster):

$$WCSS = \sum_{k=1}^K \sum_{x_i \in C_k} ||x_i - \bar{x}_k||^2$$

Como escolher k?

Critério	Descrição
Cotovelo (Elbow)	Plota WCSS × k — busca o “joelho” onde a redução desacelera

Silhueta	Mede coesão intra-cluster e separação inter-cluster; $s(i)$ $[-1, 1]$
Gap statistic	Compara WCSS observado com WCSS de dados aleatórios
Calinski-Harabasz	Razão entre variância entre clusters e variância dentro

Índice de Silhueta

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

Onde:

- **a(i)** = distância média de i às demais observações do **seu** cluster (coesão)
- **b(i)** = distância média mínima de i ao cluster vizinho mais próximo (separação)

$s(i)$ $[-1, 1]$: próximo de **1** = bem alocado; próximo de **0** = fronteira ambígua; **negativo** = provavelmente no cluster errado.

```
# K-means em R
library(factoextra)

set.seed(42) # IMPORTANTE: k-means é aleatório — fixe a semente!

# ---- Escolhendo k: método do cotovelo ----
fviz_nbclust(dados_cl, kmeans, method = "wss",
             main = "Método do Cotovelo",
             xlab = "Número de clusters k",
             ylab = "WCSS") +
  geom_vline(xintercept = 3, linetype = "dashed", color = "red")

# ---- Escolhendo k: índice de silhueta ----
fviz_nbclust(dados_cl, kmeans, method = "silhouette",
             main = "Índice de Silhueta Médio")

# ---- Ajuste do K-means com k=3 ----
km_result <- kmeans(dados_cl,
                   centers = 3, # número de clusters
                   nstart = 25, # tenta 25 inicializações aleatórias pega a melhor
                   iter.max = 100) # máximo de iterações

# Resultado
```

```

cat("WCSS total:", round(km_result$tot.withinss, 2), "\n")
cat("Tamanho dos clusters:", km_result$size, "\n")
cat("Centróides:\n"); print(round(km_result$centers, 3))

# Comparando com espécies reais
table(Real = iris$Species, K_means = km_result$cluster)

# ---- Silhueta pós-hoc (qualidade da solução) ----
library(cluster)
sil <- silhouette(km_result$cluster, dist(dados_cl))
fviz_silhouette(sil, main = "Silhueta — K-means (k=3)")
cat("Silhueta média:", round(mean(sil[, "sil_width"]), 3), "\n")

# ---- Visualização dos clusters ----
fviz_cluster(km_result,
              data = dados_cl,
              geom = "point",
              ellipse.type = "convex",
              palette = "jco",
              main = "K-means — Iris (k=3)")

```

K-means vs. Hierárquico — Quando usar cada um?

	K-means	Hierárquico
k conhecido de antemão	Ideal	Funciona
k desconhecido	Precisa testar vários k	Dendrograma orienta
n grande	Eficiente	Lento ($O(n^2 \log n)$)
Clusters não esféricos	Fraco	Depende do linkage
Interpretabilidade	Boa	Excelente (dendrograma)
Estratégia combinada	Usar hierárquico para explorar k, depois k-means para escalar	

Insights do Professor (da transcrição)

“É uma disciplina muito rica. Merece uma atenção de vocês depois — mesmo quando terminar a disciplina. MANOVA, correlação canônica, análise fatorial confirmatória são aplicados em 80% das consultorias.”

- A AFE **sem rotação** frequentemente gera cargas ambíguas (variáveis carregando em múltiplos fatores). **Sempre aplique uma rotação** — Varimax como primeiro passo, oblíqua se houver razão teórica para os fatores se correlacionarem.
- O professor usou o exemplo de um questionário com 12 itens sobre saúde (física, mental, social) para mostrar como a rotação Varimax separou o que estava misturado.
- No LaTeX (citado no início da aula): ferramenta muito superior ao Word para escrever fórmulas — recomendada para o trabalho final. Overleaf como alternativa online.

Trabalho Final — Lembrete

- **Próxima aula (Encontro 6):** cada aluno apresenta por 20 minutos
- **Tema:** livre, desde que use algum método do curso
- **Recomendação do professor:** aplique um método a dados reais da sua área de atuação
- **Prazo:** comunicar o tema com **1 semana de antecedência**

Referências

- Johnson & Wichern — *Applied Multivariate Statistical Analysis*, Cap. 8 (PCA) e Cap. 9 (AFE)
- Hair et al. — *Multivariate Data Analysis*, Cap. 3 (AFE/AFC) e Cap. 8 (Clustering)
- Pacote `psych` (AFE): <https://cran.r-project.org/package=psych>
- Pacote `factoextra` (PCA + Clustering visualização): <https://cran.r-project.org/package=factoextra>
- Pacote `cluster` (silhueta): <https://cran.r-project.org/package=cluster>
- Pacote `lavaan` (AFC/SEM): <https://lavaan.ugent.be>