

Estatística Multivariada


Vinícius Osterne, PhD

vinicius@osterne.com

| www.viniciusosterne.com

Linha do tempo da disciplina

progressão lógica do curso →



Cronograma das aulas

- **Encontro 1:** Introdução · Conceitos Prévios · Álgebra Linear · Análise Exploratória
- **Encontro 2:** Probabilidade · Inferência (testes de hipóteses, T^2 de Hotelling, MANOVA)
- **Encontro 3:** Modelos Multivariados (regressão, regressão canônica, análise de correlação)
- **Encontro 4:** Estrutura dos Dados (análise de componentes principais, análise fatorial)
- **Encontro 5:** Técnicas de Classificação e Agrupamento (clustering)
- **Encontro 6:** Apresentação dos Trabalhos

Apresentação dos trabalhos

- Cada aluno realizará uma **apresentação individual** ao longo do encontro 6
- **Duração:** 20 minutos por apresentação
- **Tema:** livre, desde que esteja relacionado a algum dos tópicos abordados ao longo do curso
- **Definição do tema:** o tema deverá ser comunicado ao professor com **uma semana de antecedência** em relação ao encontro 6, após a cobertura do conteúdo que o fundamenta
- **Recomendação:** escolha um tema que tenha despertado interesse durante o curso e aplique-o a dados reais da sua área de atuação (ou a que preferir)

Sobre o seu professor :)

Formação

- ▶ Estatístico, Mestre e Doutor
- ▶ Pós-doutorado em modelagem multimodal para detecção de diabetes

Atuação acadêmica

- ▶ *Jefe de Trabajos Prácticos*: Instituto de Cálculo, Universidad de Buenos Aires (UBA)
- ▶ Pesquisador na Universidade Federal do Ceará, Université de Bordeaux e UBA
- ▶ Professor da PUC Minas

Atuação profissional

- ▶ CEO da Vixe (consultoria, treinamentos e cursos online)
- ▶ Data Science Leader: Laboratório de Políticas Públicas do Governo do Estado do Ceará

Minha segunda vida:

- ▶ Bailarino profissional de tango

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Relação entre Conjuntos de Variáveis
- 8 Técnicas de Redução de Dimensionalidade
- 9 Estruturas Latentes
- 10 Métodos de Classificação e Agrupamento

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Relação entre Conjuntos de Variáveis
- 8 Técnicas de Redução de Dimensionalidade
- 9 Estruturas Latentes
- 10 Métodos de Classificação e Agrupamento

- A estatística multivariada é um ramo da estatística que lida com a análise simultânea de duas ou mais variáveis
- Ao contrário da estatística univariada, que se concentra em uma única variável, a estatística multivariada examina as relações entre múltiplas variáveis
- Os métodos da estatística multivariada são utilizados em diversas áreas, como ciências sociais, biologia, economia, engenharia, entre outras

- A estatística multivariada tem vários objetivos importantes, dentre os quais destacamos:
 - ▶ **Análise de correlação e covariância:** permite estudar as relações entre várias variáveis simultaneamente
 - ▶ **Redução de dimensionalidade:** oferece técnicas, como a análise de componentes principais (PCA), para reduzir a dimensão dos dados, mantendo a maior parte da informação
 - ▶ **Classificação e agrupamento:** ajuda a classificar e agrupar observações com base em múltiplas variáveis
 - ▶ **Modelagem preditiva:** modelos multivariados, como regressão múltipla, permitem prever uma variável com base em outras variáveis independentes

- É aplicada em diversas áreas para entender relações complexas entre várias variáveis:
 - ▶ **Análise descritiva multivariada:** imagine mapear como diferentes estados do Brasil são percebidos com base em várias características; isso envolve análise multivariada para entender as distâncias entre os estados e suas similaridades
 - ▶ **Análise de componentes principais:** esse método reduz a dimensionalidade dos dados, identificando combinações lineares das variáveis originais; por exemplo, um banco pode usá-lo para avaliar candidatos a empréstimos com base em renda, escolaridade, idade, entre outras variáveis
 - ▶ **Análise de correspondência:** verifica associações entre variáveis categóricas por meio de tabelas de contingência; por exemplo, explorar como diferentes categorias de acidentes de trânsito se relacionam

- ▶ **Análise de cluster:** agrupa observações com base em múltiplas variáveis; por exemplo, segmentar clientes com base em seus comportamentos de compra
 - ▶ **Análise de regressão múltipla:** modela a relação entre uma variável dependente e várias variáveis independentes; é útil para previsões financeiras ou de mercado
 - ▶ **Modelagem de equações estruturais:** explora relações complexas entre variáveis latentes em um modelo; amplamente utilizada em pesquisa de marketing e psicologia
- Esses são apenas alguns exemplos; como veremos no decorrer do curso, a estatística multivariada é amplamente aplicada em muitos campos para obter insights valiosos e embasar decisões

Conhecimentos de base recomendados

- Para estudar estatística multivariada, é útil ter uma compreensão sólida dos seguintes conceitos:
 - ▶ **Análise exploratória:** medidas como média, mediana, desvio padrão e gráficos para resumir e visualizar dados
 - ▶ **Probabilidade e distribuições:** conceitos de probabilidade e distribuições de probabilidade
 - ▶ **Álgebra linear:** vetores, matrizes, espaços vetoriais e operações matriciais
 - ▶ **Inferência estatística:** testes de hipóteses, intervalos de confiança e regressão
 - ▶ **Análise de variância (ANOVA):** comparação de médias entre grupos
 - ▶ **Cálculo:** derivadas e integrais, usados em técnicas como a regressão múltipla

- Lembre-se de que a estatística multivariada é uma área ampla e interdisciplinar
- Estar familiarizado com os conceitos básicos apresentados anteriormente ajudará você a explorar análises cada vez mais avançadas ao longo do curso!

Sumário

- 1 Introdução
- 2 Conceitos Prévios**
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Relação entre Conjuntos de Variáveis
- 8 Técnicas de Redução de Dimensionalidade
- 9 Estruturas Latentes
- 10 Métodos de Classificação e Agrupamento



Tipos de variáveis

Prof. Vinícius Osterne, PhD

Tipos de variáveis

- As variáveis podem ser classificadas em dois grandes grupos:
 - ▶ **Quantitativas:** assumem valores numéricos com sentido aritmético
 - ▶ **Qualitativas (categóricas):** representam categorias ou atributos

Tipos de variáveis: detalhamento

- As **variáveis quantitativas** se subdividem em:
 - ▶ **Contínuas:** podem assumir qualquer valor em um intervalo (ex.: altura, temperatura, salário)
 - ▶ **Discretas:** assumem valores inteiros e contáveis (ex.: número de filhos, contagem de defeitos)
- As **variáveis qualitativas** se subdividem em:
 - ▶ **Nominais:** categorias sem ordem natural (ex.: gênero, cor dos olhos, estado civil)
 - ▶ **Ordinais:** categorias com ordem definida (ex.: grau de instrução, nível de satisfação)
- **Atenção:** variáveis qualitativas frequentemente são codificadas numericamente para a análise (ex.: variáveis *dummy* 0/1), mas isso não as torna quantitativas



Dados transversais vs. Dados longitudinais

Prof. Vinícius Osterne, PhD

Dados transversais vs. longitudinais

- A estrutura temporal da coleta dos dados afeta diretamente a forma da matriz $\mathbf{X}$ e as técnicas adequadas de análise
- **Dados transversais (*cross-sectional*)**: cada unidade amostral é observada em um único momento; as linhas da matriz $\mathbf{X}$ representam diferentes indivíduos
- **Dados longitudinais (ou de painel)**: o mesmo conjunto de indivíduos é medido em múltiplos instantes de tempo; cada indivíduo gera várias linhas na matriz de dados

Dados transversais vs. longitudinais: exemplo

- Suponha que medimos renda (X_1) e escolaridade (X_2) de n pessoas:

Transversal: n linhas

dados de n pessoas em 2024

Pessoa	X_1 (renda)	X_2 (escol.)
$i = 1$	3.200	12
$i = 2$	5.100	16
$i = 3$	4.800	14

Longitudinal: $5n$ linhas

as mesmas n pessoas, 2020 - 2024

Pessoa	Ano	X_1	X_2
$i = 1$	2020	2.800	12
$i = 1$	2024	3.200	12
$i = 2$	2020	4.500	16
$i = 2$	2024	5.100	17

Dados transversais vs. longitudinais: uma analogia

Dados transversais



Uma fotografia

Captura o estado de cada indivíduo em um único instante


Dados longitudinais



Um vídeo

Registra o comportamento de cada indivíduo ao longo do tempo

Analogia sugerida pelo Prof. Juvêncio Santos Nobre (UFC).



Vetor aleatório

Prof. Vinícius Osterne, PhD

- Um **vetor aleatório** é uma coleção ordenada de variáveis aleatórias, denotado por

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix},$$

onde cada X_j é uma variável aleatória

- É a extensão natural do conceito de variável aleatória escalar para o caso multidimensional

Abrindo a matriz $\mathbf{X}$

- Cada linha da matriz $\mathbf{X}$ é a realização de um vetor aleatório $\mathbf{X}^{(i)\top}$:

$$\mathbf{X} \longrightarrow \begin{bmatrix} \text{idade} \\ \text{renda} \\ \vdots \\ \text{escolaridade} \end{bmatrix} \longrightarrow \begin{bmatrix} \mathbf{X}^{(1)\top} \\ \mathbf{X}^{(2)\top} \\ \vdots \\ \mathbf{X}^{(n)\top} \end{bmatrix} \longrightarrow \begin{bmatrix} 32 & 4.800 & 15 \\ 45 & 7.200 & 18 \\ \vdots & \vdots & \vdots \\ 2 & 2 & 8 \end{bmatrix}$$

Vetor aleatório vs. vetor de observações

- É importante distinguir dois objetos:
 - ▶ **Vetor aleatório $\mathbf{X}$:** representa o mecanismo gerador dos dados; seus elementos são variáveis aleatórias com uma distribuição conjunta
 - ▶ **Vetor de observação $\mathbf{x}_i$:** é uma *realização* do vetor aleatório para o i -ésimo indivíduo, ou seja, um conjunto de valores concretos observados
- Exemplo: $\mathbf{X} = (X_{\text{altura}}, X_{\text{peso}})^T$ é o vetor aleatório; $\mathbf{x}_1 = (1,72 \text{ m}, 68 \text{ kg})^T$ é uma observação



Matriz de dados X

Prof. Vinícius Osterne, PhD

A matriz de dados $\mathbf{X}$

- A organização dos dados multivariados é feita com o auxílio de vetores e matrizes
- Nessas matrizes, as **colunas** representam as variáveis (características medidas) e as **linhas** representam as unidades amostrais (indivíduos observados)

A matriz de dados $\mathbf{X}$: notação formal

- Sejam $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_p$ variáveis aleatórias. Denotamos por $\mathbf{X}$ a matriz que as organiza:

$$\mathbf{X} = [\mathbf{X}_1 \quad \mathbf{X}_2 \quad \cdots \quad \mathbf{X}_p] = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix},$$

onde x_{ij} representa o valor da variável j na observação i , n é o número de observações e p é o número de variáveis

A matriz de dados $\mathbf{X}$: exemplo

- Por exemplo, podemos ter uma matriz $\mathbf{X}$ com as variáveis idade (X_1) e gênero (X_2):

$$\mathbf{X} = [\mathbf{X}_1 \quad \mathbf{X}_2] = \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ \vdots & \vdots \\ x_{n1} & x_{n2} \end{bmatrix} = \begin{bmatrix} 23 & F \\ 67 & M \\ \vdots & \vdots \\ 38 & F \end{bmatrix},$$

onde F indica sexo feminino e M indica sexo masculino



Espaço amostral multivariado


Prof. Vinícius Osterne, PhD

Espaço amostral multivariado

- Cada observação $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip})^\top$ pode ser vista como um **ponto no espaço** $\mathbb{R}^p$
- O conjunto de todas as n observações forma uma **nuvem de pontos** nesse espaço
- A posição e a forma dessa nuvem revelam informações sobre a distribuição conjunta das variáveis: espalhamento, correlação, grupos naturais e observações atípicas


Espaço amostral multivariado: $p = 2$

Para $p = 2$, cada observação $\mathbf{x}_i = (x_{i1}, x_{i2})^\top$ é um ponto no plano $\mathbb{R}^2$:
a nuvem de pontos é simplesmente um **gráfico de dispersão**:



Espaço amostral multivariado: $p = 3$

Para $p = 3$, ainda conseguimos visualizar os pontos em $\mathbb{R}^3$:



Espaço amostral multivariado: $p > 3$

- Para $p > 3$, a visualização direta se torna impossível: os dados habitam um espaço que não conseguimos enxergar
- Por isso, técnicas como a **Análise de Componentes Principais (PCA)** buscam **projetar** os dados em dimensões menores sem perder muita informação
- A **geometria da nuvem de pontos** (sua posição, forma e espalhamento em $\mathbb{R}^p$) é o ponto de partida conceitual para quase todos os métodos multivariados que estudaremos nesta disciplina



Maldição da dimensionalidade

Prof. Vinícius Osterne, PhD

Maldição da dimensionalidade

- À medida que o número de variáveis p cresce, surgem problemas que não existem no caso univariado
- Fenômeno chamado de **maldição da dimensionalidade** (*curse of dimensionality*)


Maldição da dimensionalidade: principais consequências

- **Dados cada vez mais esparsos:** o volume do espaço $\mathbb{R}^p$ cresce exponencialmente com p (para cobrir o espaço com a mesma densidade, precisaríamos de amostras exponencialmente maiores)
- **Distâncias perdem significado:** em dimensões altas, qualquer par de pontos tende a ficar aproximadamente à mesma distância (a diferença entre “vizinho próximo” e “vizinho distante” desaparece, o que compromete métodos baseados em distância, como k-NN, clustering, etc.)
- **Estimação se torna inviável:** estimar a distribuição conjunta de p variáveis requer amostras que crescem exponencialmente com p (na prática, nunca temos dados suficientes)

Maldição da dimensionalidade: distâncias perdem significado


À medida que p cresce, todos os pontos tendem a ficar **igualmente distantes** entre si:

$p = 1 (\mathbb{R}^1)$




Distâncias **variam muito**:
há pares próximos e distantes

$p = 2 (\mathbb{R}^2)$



Distâncias ainda **variam**:
pares próximos existem

$p \gg 3 (\mathbb{R}^p)$



Distâncias **convergem**:
todos igualmente distantes

Por que as distâncias convergem?

- A distância euclidiana entre dois pontos em $\mathbb{R}^p$ é:

$$d = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}$$

- Com p grande, essa soma tem muitos termos: pela **Lei dos Grandes Números**, ela converge para seu valor esperado
- Consequência: todas as distâncias convergem para a **mesma constante** e a variação entre elas desaparece proporcionalmente

Lei dos Grandes Números: intuição (I)

- Se $Z_1, Z_2, \dots, Z_p$ são variáveis aleatórias independentes com média μ , então:

$$\frac{1}{p} \sum_{j=1}^p Z_j \xrightarrow{p \rightarrow \infty} \mu$$

- A variabilidade relativa da soma **desaparece** conforme p cresce: o resultado converge para um valor fixo e previsível
- **Analogia:** jogar um dado poucas vezes gera resultados muito variáveis; jogar milhares de vezes faz a média convergir inevitavelmente para 3,5

Lei dos Grandes Números: intuição (II)

- **Aplicação às distâncias:** cada termo $(x_j - y_j)^2$ se comporta como uma variável aleatória com média μ
- Com p grande, a soma converge:

$$\sum_{j=1}^p (x_j - y_j)^2 \approx p \cdot \mu$$

- Essa aproximação vale para **qualquer** par de pontos: daí todas as distâncias convergirem para o mesmo valor
- É exatamente esse nivelamento que faz o conceito de **proximidade perder o sentido** em dimensões altas

Por que as distâncias convergem?

- Formalmente, o que desaparece é a **variação relativa** entre distâncias:


$$\frac{d_{\max} - d_{\min}}{d_{\min}} \rightarrow 0 \quad \text{quando } p \rightarrow \infty$$

- Exemplo numérico:**

- ▶ Em $p = 2$: vizinhos podem estar a distâncias 0,1 e 1,4 (razão de $14\times$)
 - ▶ Em $p = 1000$: todos ficam entre 12,3 e 12,5 (praticamente **indistinguíveis**)
- O conceito de “vizinho mais próximo” perde o sentido e, com ele, todos os métodos baseados em distância (k-NN, clustering, kernels)

Maldição da dimensionalidade: esparsidade (p pequeno)


- Com p pequeno, n observações **cobrem bem** o espaço
- Os pontos são **próximos** entre si: vizinhos existem de verdade
- Estimativas locais (médias, densidades) são **confiáveis**



$$p = 2, \quad n = 25$$

Maldição da dimensionalidade: esparsidade (p grande)

- Com p grande, os **mesmos** n **pontos** precisam cobrir um espaço imensamente maior
- Os pontos ficam **isolados**: não há vizinhos reais
- Estimativas locais tornam-se **não confiáveis** ou impossíveis



$p = 100, \quad n = 25$

Maldição da dimensionalidade: implicações práticas

- Isso significa que:
 - ▶ Ter muitas variáveis (p grande) não é sempre vantajoso: pode prejudicar modelos e aumentar o custo computacional
 - ▶ É importante **selecionar** ou **reduzir** as variáveis antes de aplicar técnicas multivariadas
 - ▶ Técnicas como PCA, análise fatorial e seleção de variáveis existem, em parte, para mitigar esse problema
- Uma regra prática comum é ter ao menos $n \geq 10p$ observações para análises multivariadas confiáveis



Dados faltantes

Prof. Vinícius Osterne, PhD

Dados faltantes (*missing values*)

- Na prática, a matriz de dados $\mathbf{X}$ pode estar está completa: algumas entradas x_{ij} podem ser desconhecidas
- Os dados faltantes surgem por diversas razões: recusa em responder, falha de equipamento, perda de registros, entre outros
- Ignorar os dados faltantes sem tratamento adequado pode introduzir **viés** nas análises e reduzir o poder estatístico

Dados faltantes: por que ignorar é um problema?

Viés nas estimativas

- Se os dados não faltam aleatoriamente, a amostra restante **não representa** mais a população
- Exemplo: em uma pesquisa de saúde, pacientes com quadros mais graves tendem a **abandonar o estudo** (a média de melhora estimada fica **superestimada**)
- O modelo aprende um padrão **distorcido** da realidade

Perda de poder estatístico

- Ao excluir observações com dados faltantes, reduzimos o n efetivo
- Intervalos de confiança ficam **mais largos** e testes menos sensíveis
- Em dados multivariados, a perda é amplificada: basta **um** valor faltante numa linha para descartar o indivíduo inteiro

A forma como os dados faltam importa tanto quanto a quantidade que falta.

Estratégias para dados faltantes

- As principais abordagens são:
 - ▶ **Remoção (*listwise deletion*)**: excluir toda a linha que contenha ao menos um valor faltante; simples, mas pode desperdiçar muita informação
 - ▶ **Imputação pela média/mediana**: substituir o valor faltante pela média ou mediana da variável; fácil de implementar, mas subestima a variabilidade
 - ▶ **Imputação múltipla**: gerar várias versões plausíveis do conjunto de dados e combiná-las; método mais robusto e recomendado na prática
- A escolha da estratégia depende do mecanismo de geração dos dados faltantes e do percentual de *missings*



Por que a escala dos dados importa?

Prof. Vinícius Osterne, PhD

Por que a escala importa?

- Variáveis medidas em escalas muito diferentes podem distorcer análises multivariadas
- Exemplo: se X_1 é salário (ordem de grandeza 10^3) e X_2 é idade (ordem de grandeza 10^1), a variável salário **dominará** qualquer medida baseada em distâncias ou variâncias
- Portanto, antes de aplicar muitos métodos multivariados, é necessário **padronizar** ou **normalizar** as variáveis

- **Padronização Z-score:** transforma cada variável para ter média zero e desvio padrão um:


$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j},$$

onde $\bar{x}_j$ é a média amostral e s_j é o desvio padrão amostral da variável j

- **Normalização Min-Max:** reescala os valores para o intervalo $[0, 1]$:

$$z_{ij} = \frac{x_{ij} - \min_j}{\max_j - \min_j}$$

- A padronização Z-score é a mais utilizada em estatística multivariada, pois torna a matriz de covariância equivalente à matriz de correlação



Aprendizado estatístico vs. Aprendizado de máquina

Prof. Vinícius Osterne, PhD

Aprendizado estatístico vs. aprendizado de máquina

Aprendizado estatístico

- Foco em **inferência**: entender a relação entre variáveis
- Modelos **interpretáveis**, baseados em suposições sobre a distribuição dos dados
- Interesse em **incerteza**: intervalos de confiança, testes de hipótese
- Pergunta central: *por quê?*

Aprendizado de máquina

- Foco em **predição**: maximizar a acurácia em dados novos
- Modelos **flexíveis**, muitas vezes caixas-pretas, com poucas suposições
- Interesse em **generalização**: desempenho fora da amostra
- Pergunta central: *o quê?*

Na prática, as fronteiras são tênues: os métodos que estudaremos transitam entre as duas abordagens.

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear**
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Relação entre Conjuntos de Variáveis
- 8 Técnicas de Redução de Dimensionalidade
- 9 Estruturas Latentes
- 10 Métodos de Classificação e Agrupamento



Escalares

Prof. Vinícius Osterne, PhD

- Um **escalar** é um único número real, denotado por letras minúsculas não-negritadas:
 $a, b, c \in \mathbb{R}$
- Exemplos no contexto multivariado:
 - ▶ A altura de um indivíduo: $x_{11} = 1,72$
 - ▶ O número de observações: $n = 150$
 - ▶ O número de variáveis: $p = 5$
- Escalares são o caso mais simples; vetores e matrizes generalizam esse conceito para múltiplas dimensões



Vetores

Prof. Vinícius Osterne, PhD

- Um **vetor** é uma lista ordenada de escalares
- Usaremos sempre **vetores coluna**, denotados por letras minúsculas em negrito:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^p$$

- Cada x_j é um **elemento** (ou componente) do vetor
- O **vetor transposto** $\mathbf{x}^\top = [x_1 \ x_2 \ \cdots \ x_p]$ é um vetor linha

Vetores: exemplo

- Suponha que medimos três características de um indivíduo: altura (1,72 m), peso (68 kg) e idade (34 anos)
- Organizamos essas medidas em um vetor coluna:

$$\mathbf{x} = \begin{bmatrix} 1,72 \\ 68 \\ 34 \end{bmatrix} \in \mathbb{R}^3$$

- Sua transposta é o vetor linha:

$$\mathbf{x}^T = [1,72 \quad 68 \quad 34]$$

- Cada linha da matriz de dados $\mathbf{X}$ é exatamente um vetor desse tipo (uma observação multivariada)



Produto interno

Prof. Vinícius Osterne, PhD

- O **produto interno** (ou produto escalar) entre dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ é definido como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y} = \sum_{j=1}^p x_j y_j$$

- O resultado é sempre um **escalar**
- **Conexão estatística:** a covariância amostral entre duas variáveis pode ser escrita como um produto interno dos vetores centrados (veremos isso nas próximas aulas)

Produto interno: exemplo

- Sejam os vetores $\mathbf{x} = (1, 2, 3)^\top$ e $\mathbf{y} = (4, 0, -1)^\top$:

$$\mathbf{x}^\top \mathbf{y} = 1 \cdot 4 + 2 \cdot 0 + 3 \cdot (-1) = 4 + 0 - 3 = 1$$

- Agora, $\mathbf{x} = (1, 2, 3)^\top$ e $\mathbf{z} = (2, 4, 6)^\top$:


$$\mathbf{x}^\top \mathbf{z} = 1 \cdot 2 + 2 \cdot 4 + 3 \cdot 6 = 2 + 8 + 18 = 28$$

- Note que $\mathbf{z} = 2\mathbf{x}$ (vetores paralelos têm produto interno grande)


Intuição do produto interno

- O produto interno pode ser positivo (vetores com mesma direção), zero (vetores ortogonais) ou negativo (vetores com direções opostas)


Mesma direção



Ortogonais



Direções opostas



Produto interno: para que serve?

- **Medir similaridade entre observações:** o produto interno entre dois vetores de dados indica o quanto duas observações “se parecem” em direção e magnitude
- **Calcular projeções:** a projeção de $\mathbf{x}$ na direção de $\mathbf{y}$ é dada por $\frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{y}\|}$, operação central em métodos como PCA e regressão

- **Expressar covariâncias:** a covariância amostral entre duas variáveis centradas $\tilde{\mathbf{x}}$ e $\tilde{\mathbf{y}}$ é simplesmente:

$$s_{xy} = \frac{1}{n-1} \tilde{\mathbf{x}}^\top \tilde{\mathbf{y}}$$


- **Definir distâncias:** a norma euclidiana (e portanto a distância) vem do produto interno:
 $\|\mathbf{x}\| = \sqrt{\mathbf{x}^\top \mathbf{x}}$

O produto interno é a operação fundamental por trás de quase todos os métodos multivariados que estudaremos.

Norma de um vetor


- A **norma euclidiana** é o comprimento de um vetor $\mathbf{x} \in \mathbb{R}^p$ e é definida por:

$$\|\mathbf{x}\| = \sqrt{\mathbf{x}^T \mathbf{x}} = \sqrt{\sum_{j=1}^p x_j^2}$$



Vetor unitário

- Um vetor com $\|\mathbf{x}\| = 1$ é chamado **vetor unitário**
- Todos os vetores unitários têm o mesmo comprimento, só diferem na **direção**:



- A norma do vetor diferença é chamada de **distância euclidiana**
- Logo, a distância euclidiana entre dois pontos $\mathbf{x}$ e $\mathbf{y}$ é

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\| = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}$$



Ângulo entre vetores

Prof. Vinícius Osterne, PhD

Ângulo entre vetores e ortogonalidade

- O produto interno está ligado ao **ângulo** θ entre dois vetores:


$$\cos \theta = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}$$

- Dois vetores são **ortogonais** quando $\mathbf{x}^\top \mathbf{y} = 0$, isto é, $\theta = 90^\circ$
- **Conexão com correlação:** se centrarmos as colunas da matriz $\mathbf{X}$, a correlação entre duas variáveis é exatamente o cosseno do ângulo entre seus vetores coluna:
 - ▶ Correlação = 1: vetores paralelos ($\theta = 0^\circ$)
 - ▶ Correlação = 0: vetores ortogonais ($\theta = 90^\circ$)
 - ▶ Correlação = -1: vetores antiparalelos ($\theta = 180^\circ$)

Ângulo entre vetores e correlação

Correlação = 1


$$\theta = 0^\circ$$



Vetores **paralelos**:
apontam na mesma direção

Correlação = 0


$$\theta = 90^\circ$$



Vetores **ortogonais**:
nenhuma direção em comum

Correlação = -1

$$\theta = 180^\circ$$



Vetores **antiparalelos**:
direções opostas

$$\cos \theta = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}$$

(a correlação é o cosseno do ângulo entre os vetores centrados)

Ângulo entre vetores: exemplo

- Sejam $\mathbf{u} = (1, 0)^\top$ e $\mathbf{v} = (1, 1)^\top$:

$$\cos \theta = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} = \frac{1 \cdot 1 + 0 \cdot 1}{\sqrt{1} \cdot \sqrt{2}} = \frac{1}{\sqrt{2}} \approx 0,707 \implies \theta = 45^\circ$$

- Agora, $\mathbf{u} = (1, 0)^\top$ e $\mathbf{w} = (0, 1)^\top$:

$$\cos \theta = \frac{1 \cdot 0 + 0 \cdot 1}{\sqrt{1} \cdot \sqrt{1}} = 0 \implies \theta = 90^\circ \quad (\text{ortogonais})$$

- Interpretação:** $\mathbf{u}$ e $\mathbf{w}$ são ortogonais (representam variáveis com correlação zero; $\mathbf{u}$ e $\mathbf{v}$ compartilham parte da mesma direção) correlação positiva



Projeção ortogonal

Prof. Vinícius Osterne, PhD

Projeção ortogonal

- A **projeção** de $\mathbf{x}$ sobre a direção de $\mathbf{y}$ é o vetor

$$\text{proj}_{\mathbf{y}} \mathbf{x} = \frac{\mathbf{x}^{\top} \mathbf{y}}{\|\mathbf{y}\|^2} \mathbf{y}$$


- Geometricamente: é a “sombra” de $\mathbf{x}$ sobre a reta definida por $\mathbf{y}$

Projeção ortogonal

- A **projeção** de $\mathbf{x}$ sobre a direção de $\mathbf{y}$ é o vetor:

$$\text{proj}_{\mathbf{y}} \mathbf{x} = \frac{\mathbf{x}^{\top} \mathbf{y}}{\|\mathbf{y}\|^2} \mathbf{y}$$

- Geometricamente: é a “sombra” de $\mathbf{x}$ sobre a reta definida por $\mathbf{y}$



Por que isso importa?


- A **Análise de Componentes Principais (PCA)** é geometricamente uma sequência de projeções: encontramos as direções (componentes) que maximizam a variância projetada dos dados
- Sempre que trabalharmos com combinações lineares de variáveis, estaremos fazendo projeções

Projeção ortogonal: exemplo

- Sejam $\mathbf{x} = (3, 4)^\top$ e $\mathbf{y} = (1, 0)^\top$ (eixo horizontal):

$$\text{proj}_{\mathbf{y}} \mathbf{x} = \frac{3}{1} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}$$

- A projeção é simplesmente a componente horizontal de $\mathbf{x}$
- Intuição para PCA:** cada componente principal é uma direção $\mathbf{y}$; a projeção é o **escore** do componente





Matrizes

Prof. Vinícius Osterne, PhD

- Uma **matriz** é uma tabela retangular de escalares organizada em linhas e colunas, denotada por letras maiúsculas em negrito:

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1q} \\ a_{21} & a_{22} & \cdots & a_{2q} \\ \vdots & \vdots & \ddots & \vdots \\ a_{p1} & a_{p2} & \cdots & a_{pq} \end{bmatrix} \in \mathbb{R}^{p \times q}$$

- ▶ p é o número de **linhas** e q é o número de **colunas**; dizemos que $\mathbf{A}$ é uma matriz $p \times q$
- ▶ O elemento a_{ij} está na linha i e coluna j
- ▶ Um vetor coluna é um caso especial: matriz $p \times 1$

Matrizes: exemplo

- Suponha $n = 4$ indivíduos e $p = 3$ variáveis (altura, peso, idade). A matriz de dados $\mathbf{X} \in \mathbb{R}^{4 \times 3}$ é:

$$\mathbf{X} = \begin{bmatrix} 1,72 & 68 & 34 \\ 1,65 & 55 & 28 \\ 1,80 & 82 & 45 \\ 1,58 & 61 & 52 \end{bmatrix}$$

- ▶ Cada **linha** é um indivíduo; cada **coluna** é uma variável
- ▶ O elemento $x_{32} = 82$ indica o peso (variável 2) do terceiro indivíduo
- ▶ O elemento x_{14} não existe: a matriz tem apenas 3 colunas

Convenções de notação

- Adotaremos as seguintes convenções ao longo do curso:
 - ▶ **Escalares:** letras minúsculas não-negritadas (a , x_{ij} , n , p)
 - ▶ **Vetores:** letras minúsculas em negrito ($\mathbf{x}$, $\mathbf{y}$, $\boldsymbol{\mu}$)
 - ▶ **Matrizes:** letras maiúsculas em negrito ($\mathbf{X}$, $\mathbf{S}$, $\boldsymbol{\Sigma}$)

Matrizes: muito além de tabelas

- No nosso nível, não podemos enxergar uma matriz apenas como uma organização tabular de números
- Uma matriz é a representação de uma **transformação linear**
- O termo *matrix* vem do latim *mater* (mãe) e era sinônimo de útero na Idade Média: aquilo que **gera**, que **transforma**

Matrizes: muito além de tabelas

- Dado um vetor de entrada $\mathbf{x} \in \mathbb{R}^n$, a matriz $\mathbf{W}_{m \times n}$ o transforma em um novo vetor de saída $\mathbf{y} \in \mathbb{R}^m$:

$$\mathbf{y}_{m \times 1} = \mathbf{W}_{m \times n} \mathbf{x}_{n \times 1}$$

- É exatamente nesse sentido que o nome faz jus à etimologia: **W gera y** a partir de **x**



Adição e Multiplicação de Matrizes

Prof. Vinícius Osterne, PhD

Adição de matrizes e multiplicação por escalar

- **Adição:** soma elemento a elemento; exige que **A** e **B** tenham a *mesma dimensão*

$$(\mathbf{A} + \mathbf{B})_{ij} = a_{ij} + b_{ij}$$

- **Multiplicação por escalar:** multiplica todos os elementos pelo escalar c

$$(c\mathbf{A})_{ij} = c a_{ij}$$

- Ambas as operações são realizadas **elemento a elemento**

Adição e multiplicação por escalar: exemplo

- Sejam as matrizes $\mathbf{A}$ e $\mathbf{B}$ de dimensão 2×2 :

$$\mathbf{A} = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

- Multiplicação por escalar:

$$2\mathbf{A} = \begin{bmatrix} 2 & 6 \\ 4 & 8 \end{bmatrix}$$

- Adição:

$$2\mathbf{A} + \mathbf{B} = \begin{bmatrix} 2 & 6 \\ 4 & 8 \end{bmatrix} + \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 2 & 7 \\ 5 & 8 \end{bmatrix}$$

- Erro comum:** tentar somar matrizes de dimensões diferentes: operação indefinida

Multiplicação de matrizes

- O produto $\mathbf{AB}$ é definido quando o número de **colunas de A** é igual ao número de **linhas de B**
- Se $\mathbf{A} \in \mathbb{R}^{p \times k}$ e $\mathbf{B} \in \mathbb{R}^{k \times q}$, então $\mathbf{C} = \mathbf{AB} \in \mathbb{R}^{p \times q}$ com

$$c_{ij} = \sum_{l=1}^k a_{il} b_{lj}$$

- **Atenção:** a multiplicação de matrizes **não é comutativa** em geral: $\mathbf{AB} \neq \mathbf{BA}$
- No contexto do curso: $\mathbf{X}^T \mathbf{X}$ é uma operação central (gera uma matriz $p \times p$ que resume as relações entre variáveis)

Multiplicação de matrizes: exemplo

- Sejam $\mathbf{A} \in \mathbb{R}^{2 \times 3}$ e $\mathbf{B} \in \mathbb{R}^{3 \times 2}$; o produto $\mathbf{C} = \mathbf{AB} \in \mathbb{R}^{2 \times 2}$:

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 4 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 2 & 1 \\ 0 & 3 \\ 1 & 2 \end{bmatrix}$$

- Calculando cada elemento de $\mathbf{C}$:

$$c_{11} = 1 \cdot 2 + 2 \cdot 0 + 0 \cdot 1 = 2$$

$$c_{12} = 1 \cdot 1 + 2 \cdot 3 + 0 \cdot 2 = 7$$

$$c_{21} = 3 \cdot 2 + 1 \cdot 0 + 4 \cdot 1 = 10$$

$$c_{22} = 3 \cdot 1 + 1 \cdot 3 + 4 \cdot 2 = 14$$

$$\mathbf{C} = \begin{bmatrix} 2 & 7 \\ 10 & 14 \end{bmatrix}$$



Matriz Transposta

Prof. Vinícius Osterne, PhD


Matriz Transposta

- A **transposta** de $\mathbf{A}$ é denotada por $\mathbf{A}^\top$
- Operação: **troca linhas por colunas**
 - ▶ Se $\mathbf{A}$ é $m \times n$, então $\mathbf{A}^\top$ é $n \times m$
 - ▶ O elemento (i, j) de $\mathbf{A}$ vira o elemento (j, i) de $\mathbf{A}^\top$
- **Propriedades importantes:**
 - ▶ $(\mathbf{A}^\top)^\top = \mathbf{A}$
 - ▶ $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$

Matriz Transposta — exemplo

- Dada a matriz $\mathbf{A}$ de dimensão 3×2 , sua transposta $\mathbf{A}^\top$ tem dimensão 2×3 :

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}_{3 \times 2} \implies \mathbf{A}^\top = \begin{bmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{bmatrix}_{2 \times 3}$$



- As setas mostram como a primeira coluna de $\mathbf{A}$ vira a primeira linha de $\mathbf{A}^\top$



Traço de uma matriz

Prof. Vinícius Osterne, PhD

Traço de uma matriz

- O **traço** de uma matriz quadrada $\mathbf{A} \in \mathbb{R}^{p \times p}$ é a soma dos elementos da diagonal principal:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p a_{jj} = a_{11} + a_{22} + \cdots + a_{pp}$$

- Propriedades úteis:

- ▶ $\text{tr}(\mathbf{A} + \mathbf{B}) = \text{tr}(\mathbf{A}) + \text{tr}(\mathbf{B})$
- ▶ $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$ (mesmo que $\mathbf{AB} \neq \mathbf{BA}$)

- **Aplicação:** na matriz de covariâncias $\mathbf{S}$, o traço representa a **variância total** das variáveis (um resumo escalar da dispersão multivariada)

Traço de uma matriz: exemplo

- Considere uma matriz de covariâncias $\mathbf{S}$ de três variáveis (altura, peso, idade):

$$\mathbf{S} = \begin{bmatrix} 0,04 & 1,20 & 0,30 \\ 1,20 & 64,00 & 8,50 \\ 0,30 & 8,50 & 25,00 \end{bmatrix}$$

- O traço é:

$$\text{tr}(\mathbf{S}) = 0,04 + 64,00 + 25,00 = 89,04$$

- Isso significa que a **variância total** do conjunto de dados é 89,04
- **Observação:** o peso domina o traço por estar em escala maior (motivação para padronizar as variáveis antes da análise)



Determinante de uma matriz


Prof. Vinícius Osterne, PhD

- O **determinante** de uma matriz quadrada $\mathbf{A}$, denotado $\det(\mathbf{A})$ ou $|\mathbf{A}|$, é um escalar que resume propriedades estruturais da matriz
- Para 2×2 :

$$\det \begin{bmatrix} a & b \\ c & d \end{bmatrix} = ad - bc$$

Determinante: área do paralelogramo

Os vetores coluna de A definem um paralelogramo



Por que essa área é igual ao determinante? $\rightarrow$ próximo slide

Por que o determinante mede área?

- O paralelogramo formado por $\mathbf{a}_1 = (a, 0)^\top$ e $\mathbf{a}_2 = (b, d)^\top$ cabe dentro de um retângulo de lados $(a + b)$ e d

- **Área do retângulo:** $(a + b) \cdot d$

- Subtraímos as regiões externas ao paralelogramo:

- ▶ Dois triângulos laterais (base b , altura d): área total = bd
- ▶ Dois triângulos inferior e superior (base a , altura $\frac{d}{2}$ cada): área total = $\frac{1}{2}ad$


- Resultado final:

$$\text{Área} = (a + b)d - bd - \frac{1}{2}ad - \frac{1}{2}ad = \boxed{ad - bc}$$

- Que é exatamente $\det \begin{bmatrix} a & b \\ 0 & d \end{bmatrix} = ad - b \cdot 0$, e o caso geral $(a, c)^\top, (b, d)^\top$ segue o mesmo argumento

Determinante: volume do paralelepípedo

Em 3D, os vetores coluna definem um paralelepípedo



Por que esse volume é igual ao determinante?

Por que o determinante mede volume?

- O argumento é uma extensão direta do caso 2D, aplicado por indução
- O paralelepípedo também cabe dentro de um **bloco retangular** (o menor que o contém); calculamos o volume do bloco e subtraímos os pedaços externos
- Cada “fatia” subtraída corresponde a um menor determinante 2×2 : é exatamente a **expansão de Laplace** que aparece na fórmula recursiva do determinante:

$$\det(\mathbf{A}) = \sum_{j=1}^p (-1)^{1+j} a_{1j} \det(\mathbf{A}_{1j})$$

onde $\mathbf{A}_{1j}$ é a submatriz obtida removendo a linha 1 e coluna j

- **Intuição:** cada termo $(-1)^{1+j} a_{1j} \det(\mathbf{A}_{1j})$ mede o volume de uma “fatia”: somar com sinais alternados é exatamente incluir e excluir as regiões externas ao paralelepípedo

Determinante: exemplo

- Considere duas situações para uma matriz de covariâncias 2×2 :

$$\mathbf{S}_1 = \begin{bmatrix} 4 & 0 \\ 0 & 9 \end{bmatrix}, \quad \mathbf{S}_2 = \begin{bmatrix} 4 & 6 \\ 6 & 9 \end{bmatrix}$$

- Calculando os determinantes:

$$\det(\mathbf{S}_1) = 4 \cdot 9 - 0 \cdot 0 = 36$$

$$\det(\mathbf{S}_2) = 4 \cdot 9 - 6 \cdot 6 = 36 - 36 = 0$$

- **Interpretação:** $\mathbf{S}_2$ tem determinante zero: as duas variáveis são perfeitamente correlacionadas (correlação = 1), ou seja, uma é combinação linear da outra
- Nesse caso, $\mathbf{S}_2$ **não é invertível**: qualquer método que exija $\mathbf{S}^{-1}$ irá falhar



Matriz inversa

Prof. Vinícius Osterne, PhD

- A **inversa** de uma matriz quadrada $\mathbf{A} \in \mathbb{R}^{p \times p}$ é a matriz $\mathbf{A}^{-1}$ tal que

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}_p,$$

onde $\mathbf{I}_p$ é a **matriz identidade** (1's na diagonal, 0's fora)

- A inversa existe somente se $\det(\mathbf{A}) \neq 0$; nesse caso, $\mathbf{A}$ é dita **invertível** (ou não-singular)
- **Analogia escalar:** $\mathbf{A}^{-1}$ é o análogo matricial de $1/a$ para escalares
- **Aplicação central no curso:** a distância de Mahalanobis e o teste de Hotelling T^2 envolvem $\mathbf{S}^{-1}$ (a inversa da matriz de covariâncias)

Matriz inversa: exemplo

- Para uma matriz 2×2 , a fórmula da inversa é direta:

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \implies \mathbf{A}^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

- Exemplo com $\mathbf{S} = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$:

$$\det(\mathbf{S}) = 4 \cdot 3 - 2 \cdot 2 = 8 \implies \mathbf{S}^{-1} = \frac{1}{8} \begin{bmatrix} 3 & -2 \\ -2 & 4 \end{bmatrix}$$

- Verificação: $\mathbf{S}\mathbf{S}^{-1} = \frac{1}{8} \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix} \begin{bmatrix} 3 & -2 \\ -2 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2 \checkmark$



Matriz identidade e Matriz diagonal

Prof. Vinícius Osterne, PhD

Matriz identidade e matriz diagonal

- A **matriz identidade** $\mathbf{I}_p$ tem 1's na diagonal e 0's fora; funciona como o número 1 na multiplicação: $\mathbf{A}\mathbf{I} = \mathbf{I}\mathbf{A} = \mathbf{A}$
- Uma **matriz diagonal** tem elementos não-nulos apenas na diagonal principal:

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & 0 \\ 0 & d_2 & 0 \\ 0 & 0 & d_3 \end{bmatrix} = \text{diag}(d_1, d_2, d_3)$$

- **Aplicação:** quando as variáveis são **não correlacionadas**, a matriz de covariâncias $\mathbf{S}$ é diagonal, ou seja, os elementos fora da diagonal (covariâncias) são todos zero

Matriz diagonal: exemplo

- Suponha três variáveis independentes com variâncias $\sigma_1^2 = 4$, $\sigma_2^2 = 9$, $\sigma_3^2 = 1$:

$$\mathbf{S} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 9 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

- Sua inversa é imediata, basta inverter cada elemento diagonal:

$$\mathbf{S}^{-1} = \begin{bmatrix} 1/4 & 0 & 0 \\ 0 & 1/9 & 0 \\ 0 & 0 & 1/1 \end{bmatrix} = \begin{bmatrix} 0,25 & 0 & 0 \\ 0 & 0,11 & 0 \\ 0 & 0 & 1,00 \end{bmatrix}$$

- **Conclusão:** matrizes diagonais são computacionalmente simples; matrizes com covariâncias não-nulas exigem métodos mais elaborados para inversão



Matriz Simétrica

Prof. Vinícius Osterne, PhD

Matriz simétrica

- Uma matriz quadrada $\mathbf{A}$ é **simétrica** se $\mathbf{A} = \mathbf{A}^\top$, ou seja, $a_{ij} = a_{ji}$ para todo i, j
- **Importância central:** a matriz de covariâncias $\mathbf{S}$ e a matriz de correlações $\mathbf{R}$ são **sempre simétricas**, pois $\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j)$

- Exemplo:

$$\mathbf{S} = \begin{bmatrix} 4,0 & 1,2 & 0,8 \\ 1,2 & 9,0 & 2,1 \\ 0,8 & 2,1 & 1,0 \end{bmatrix} = \mathbf{S}^\top$$

- Matrizes simétricas têm propriedades algébricas convenientes: autovalores sempre reais e autovetores ortogonais entre si

Matriz simétrica: exemplo e verificação

- Uma forma de construir matrizes simétricas: dado qualquer $\mathbf{A}$, o produto $\mathbf{A}^\top \mathbf{A}$ é sempre simétrico

- Verificação com $\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}$:

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix} = \begin{bmatrix} 35 & 44 \\ 44 & 56 \end{bmatrix}$$

- Note que 35 e 56 estão na diagonal, e os dois elementos fora da diagonal são iguais a 44
- **Conexão direta:** a matriz de covariâncias amostral pode ser escrita como $\mathbf{S} \propto \mathbf{X}_c^\top \mathbf{X}_c$, onde $\mathbf{X}_c$ é a matriz de dados centrada



Autovalores e Autovetores

Prof. Vinícius Osterne, PhD

- Dado um escalar λ e um vetor não-nulo $\mathbf{v}$, dizemos que λ é **autovalor** e $\mathbf{v}$ é **autovetor** de $\mathbf{A}$ se:

$$\mathbf{A}\mathbf{v} = \lambda \mathbf{v}$$




- **Interpretação geométrica:** multiplicar $\mathbf{v}$ por $\mathbf{A}$ apenas *escala* $\mathbf{v}$ pelo fator λ (a direção não muda, só o comprimento)

Autovalores e autovetores: intuição geométrica

- Pense numa matriz como uma **máquina de transformar vetores**: em geral, ela muda a direção e o comprimento de qualquer vetor que passa por ela
- Um **autovetor** é uma direção *especial*: quando passa pela máquina, **não muda de direção** (só o comprimento é afetado)
- O **autovalor** é o fator de escala dessa direção:
 - ▶ $\lambda = 4$: o vetor fica 4 vezes mais longo
 - ▶ $\lambda = 0,5$: o vetor encolhe pela metade
 - ▶ $\lambda < 0$: o vetor inverte o sentido, mas mantém a direção

Autovalores e autovetores: interpretação geométrica

- Multiplicar $\mathbf{v}$ por $\mathbf{A}$ apenas *escala* $\mathbf{v}$ pelo fator λ : a direção não muda, só o comprimento




$\mathbf{v}$

$\mathbf{Av}$

interpretação

Autovalores, autovetores e variabilidade

- Os dados formam uma **nuvem de pontos** em $\mathbb{R}^p$: pense nessa nuvem como uma elipse (figura ao lado)
- Os **autovetores** de S são os **eixos dessa elipse**: as direções naturais de alongamento
- Os **autovalores** são os **comprimentos desses eixos**: o quanto a nuvem se estende em cada direção



Autovalores e autovetores: exemplo

- Considere a matriz de covariância:

$$\mathbf{S} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

- Os autovalores são obtidos de $\det(\mathbf{S} - \lambda \mathbf{I}) = 0$:

$$(3 - \lambda)^2 - 1 = 0 \implies \lambda_1 = 4, \quad \lambda_2 = 2$$

- Os autovetores correspondentes são:

- ▶ $\lambda_1 = 4$: $\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ (diagonal positiva)
- ▶ $\lambda_2 = 2$: $\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ (diagonal negativa)

O que significa “capturar mais variância”?

- Projetando os dados na direção $\mathbf{v}_1 = \frac{1}{\sqrt{2}}(1, 1)^\top$, a variância dos escores é $\lambda_1 = 4$
- Projetando na direção $\mathbf{v}_2 = \frac{1}{\sqrt{2}}(1, -1)^\top$, a variância dos escores é $\lambda_2 = 2$
- $\mathbf{v}_1$ é a direção onde os dados **mais se espalham**: o autovetor do maior autovalor é a direção que **maximiza o espalhamento**
- Pense na elipse: $\mathbf{v}_1$ aponta para o **eixo maior**, $\mathbf{v}_2$ para o **eixo menor**

Autovalores e autovetores: conexão com PCA

- **Variância total** dos dados: $\lambda_1 + \lambda_2 = 4 + 2 = 6$
- **Variância explicada** por cada componente:
 - ▶ 1º componente ($\mathbf{v}_1$): $\frac{4}{6} \approx 67\%$
 - ▶ 2º componente ($\mathbf{v}_2$): $\frac{2}{6} \approx 33\%$
- PCA nada mais faz do que **reorientar o sistema de coordenadas**: o novo eixo 1 aponta para a direção de maior espalhamento, o eixo 2 para a segunda maior, e assim por diante
- Com apenas o 1º componente já capturamos 67% da informação total: esse é o ganho da **redução de dimensionalidade**



Matriz positiva semidefinida e definida

Prof. Vinícius Osterne, PhD

Matriz positiva (semi-)definida

- Uma matriz simétrica $\mathbf{A}$ é **positiva definida** (denotada $\mathbf{A} \succ 0$) se

$$\mathbf{v}^\top \mathbf{A} \mathbf{v} > 0 \quad \text{para todo } \mathbf{v} \neq \mathbf{0}$$

- É **positiva semidefinida** ($\mathbf{A} \succeq 0$) se a desigualdade for ≥ 0
- Equivalentemente: $\mathbf{A} \succ 0 \iff$ todos os autovalores de $\mathbf{A}$ são **estritamente positivos**
- **Por que isso importa?**
 - ▶ A matriz de covariâncias $\mathbf{S}$ é sempre positiva semidefinida
 - ▶ Para ser invertível (necessário em Mahalanobis, Hotelling, etc.), $\mathbf{S}$ precisa ser **positiva definida**, o que requer $n > p$ e variáveis não redundantes

Matriz positiva definida: exemplo

- Verifique se $\mathbf{S} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$ é positiva definida
- **Método 1 (autovalores):** $\lambda_1 = 4 > 0$ e $\lambda_2 = 2 > 0$ ✓
- **Método 2 (forma quadrática):** para $\mathbf{v} = (v_1, v_2)^\top$:

$$\mathbf{v}^\top \mathbf{S} \mathbf{v} = 3v_1^2 + 2v_1v_2 + 3v_2^2 = 2(v_1 + v_2)^2 + v_1^2 + v_2^2 > 0$$

sempre que $(v_1, v_2) \neq (0, 0)$ ✓

- Portanto $\mathbf{S} \succ 0$: é invertível e pode ser usada em todos os métodos do curso



Decomposição Espectral

Prof. Vinícius Osterne, PhD

Decomposição espectral

- Toda matriz simétrica $\mathbf{A} \in \mathbb{R}^{p \times p}$ pode ser escrita como

$$\mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^T,$$

onde $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p)$ contém os autovalores e $\mathbf{P}$ é a matriz cujas colunas são os autovetores correspondentes

- **Interpretação geométrica:** $\mathbf{P}$ define uma *rotação* do espaço e $\mathbf{\Lambda}$ define um *escalonamento* em cada direção rotacionada
- Esta decomposição é o **coração matemático** da PCA, da Análise Fatorial e da maioria dos métodos que estudaremos

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória**
- 5 Probabilidade
- 6 Inferência
- 7 Relação entre Conjuntos de Variáveis
- 8 Técnicas de Redução de Dimensionalidade
- 9 Estruturas Latentes
- 10 Métodos de Classificação e Agrupamento

- A partir de uma matriz de dados, podemos começar a realizar algumas análises descritivas
- Nesta seção, apresentaremos as principais e algumas ferramentas gráficas comuns no contexto multivariado



Vetor de Médias

Prof. Vinícius Osterne, PhD

Vetor de Médias: Definição

- O vetor de médias da matriz de dados $\mathbf{X}$ é dado por

$$\boldsymbol{\mu} = [\mu_1 \quad \mu_2 \quad \cdots \quad \mu_p]^\top,$$

onde μ_j é a média da variável $\mathbf{X}_j$, dada por $\mu_j = \mathbb{E}(\mathbf{X}_j)$, com $j = 1, 2, \dots, p$

- Cada componente μ_j resume o **valor esperado** (centro de localização) da j -ésima variável
- O vetor $\boldsymbol{\mu}$ representa o **centroide** da distribuição multivariada no espaço $\mathbb{R}^p$

Estimação Amostral

- Na prática, μ é desconhecido e estimado a partir de uma amostra de n observações
- O **vetor de médias amostral** é definido como

$$\bar{\mathbf{x}} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix}, \quad \text{onde} \quad \bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$$

- Em notação matricial, podemos escrever

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n,$$

onde $\mathbf{1}_n$ é o vetor coluna de uns de dimensão n


- $\bar{\mathbf{x}}$ é um estimador **não-viesado** e **consistente** de μ

Interpretação Geométrica

- O vetor de médias μ (ou $\bar{x}$) representa o **centroide** da nuvem de pontos no espaço multivariado
- Geometricamente, é o ponto que **minimiza a soma das distâncias quadráticas** a todas as observações:

$$\bar{x} = \arg \min_{\mathbf{c}} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{c}\|^2$$

- ▶ Como assim? Imagine 3 pessoas em posições diferentes numa sala; você quer colocar uma mesa no ponto onde a soma das distâncias ao quadrado até cada pessoa seja mínima; esse ponto ótimo é a média das posições das 3 pessoas (centroide)



Exemplo Numérico

- Considere uma amostra de $n = 4$ indivíduos com $p = 3$ variáveis: **Altura** (cm), **Peso** (kg) e **Idade** (anos)

Indivíduo	Altura	Peso	Idade
1	170	65	25
2	182	80	30
3	158	55	22
4	174	72	28

- O vetor de médias amostral é

$$\bar{\mathbf{x}} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \bar{x}_3 \end{bmatrix} = \begin{bmatrix} (170 + 182 + 158 + 174)/4 \\ (65 + 80 + 55 + 72)/4 \\ (25 + 30 + 22 + 28)/4 \end{bmatrix} = \begin{bmatrix} 171,0 \\ 68,0 \\ 26,25 \end{bmatrix}$$



Matriz de Variâncias e Covariâncias

Prof. Vinícius Osterne, PhD

Matriz de Variâncias e Covariâncias: Definição

- A matriz de variâncias e covariâncias da matriz de dados $\mathbf{X}$ é dada por

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix},$$

onde $\sigma_{jk} = \mathbb{E}[(\mathbf{X}_j - \mu_j)(\mathbf{X}_k - \mu_k)]$ é a covariância entre $\mathbf{X}_j$ e $\mathbf{X}_k$

- Quando $j = k$, temos $\sigma_{jj} = \mathbb{E}[(\mathbf{X}_j - \mu_j)^2] = \text{Var}(\mathbf{X}_j)$, ou seja, a **diagonal principal contém as variâncias**
- Σ é sempre **simétrica** ($\sigma_{jk} = \sigma_{kj}$) e **semidefinida positiva** ($\mathbf{a}^\top \Sigma \mathbf{a} \geq 0$ para todo $\mathbf{a}$)

- Quando $j = k$, temos $\sigma_{jj} = \sigma_j^2$, que é a variância da variável $\mathbf{X}_j$, ou seja, a diagonal principal da matriz Σ é composta pelas variâncias das variáveis da matriz de dados $\mathbf{X}$
- Assim, podemos reescrever essa matriz da seguinte forma

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_2^2 & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_p^2 \end{bmatrix}.$$

- A matriz de covariância também pode ser diagonal, ou seja

$$\Sigma = \begin{bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 \end{bmatrix},$$

nesse caso, as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$, para $j \neq k$, são independentes e, por isso, a covariância é igual a zero

- **Cuidado:** com essa última afirmação, pois o contrário "se duas variáveis tem covariância igual a zero, então elas são independentes" não é sempre válida

- Na prática, Σ é desconhecida e estimada pela **matriz de covariâncias amostral** S , cujos elementos são

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)$$


- Em notação matricial, definindo $\tilde{\mathbf{X}} = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top$ como a matriz de dados centrada, temos

$$\mathbf{S} = \frac{1}{n-1} \tilde{\mathbf{X}}^\top \tilde{\mathbf{X}}$$

- O divisor $n-1$ (e não n) garante que S seja um estimador **não-viesado** de Σ

Interpretação Geométrica

- Σ descreve a **forma e orientação** da nuvem de pontos no espaço multivariado
- A **diagonal** controla o *tamanho* da dispersão em cada eixo
- Os **elementos fora da diagonal** controlam a *inclinação*: covariância positiva inclina a nuvem para cima, negativa para baixo
- Geometricamente, Σ define o **elipsoide de concentração** ao redor do centroide $\bar{\mathbf{x}}$



Exemplo Numérico

- Considere uma amostra de $n = 4$ indivíduos com $p = 2$ variáveis: **Altura** (X_1 , cm) e **Peso** (X_2 , kg)

Indivíduo	Altura x_{i1}	Peso x_{i2}
1	170	65
2	182	80
3	158	55
4	174	72
$\bar{x}_j$	171,0	68,0

- A partir dessas médias, calculamos os elementos da matriz amostral S usando $n - 1 = 3$ no denominador

Exemplo Numérico: Cálculo de S

- Calculando cada elemento com $n - 1 = 3$:


$$s_{11} = \frac{(-1)^2 + (11)^2 + (-13)^2 + (3)^2}{3} = \frac{1 + 121 + 169 + 9}{3} \approx 100,0$$

$$s_{22} = \frac{(-3)^2 + (12)^2 + (-13)^2 + (4)^2}{3} = \frac{9 + 144 + 169 + 16}{3} \approx 112,7$$

$$s_{12} = \frac{(-1)(-3) + (11)(12) + (-13)(-13) + (3)(4)}{3} = \frac{3 + 132 + 169 + 12}{3} \approx 105,3$$

- Portanto, a matriz de covariâncias amostral é:

$$\mathbf{S} = \begin{bmatrix} 100,0 & 105,3 \\ 105,3 & 112,7 \end{bmatrix}$$



Matriz de Correlação

Prof. Vinícius Osterne, PhD

- A matriz de correlação da matriz de dados $\mathbf{X}$ é dada por

$$\mathbf{C} = \begin{bmatrix} \rho_{11} & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & \rho_{22} & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & \rho_{pp} \end{bmatrix},$$

onde ρ_{jk} é a correlação entre as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$ que é dada por

$$\rho_{jk} = \frac{\sigma_{jk}}{\sigma_j \sigma_k},$$

sendo $-1 \leq \rho_{jk} \leq 1$

- Quando $j = k$, temos $\rho_{jj} = 1$, pois a correlação entre uma variável e ela mesma é igual a 1
- Assim, podemos reescrever essa matriz da seguinte forma:

$$\mathbf{C} = \begin{bmatrix} \rho_{11} & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & \rho_{22} & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & \rho_{pp} \end{bmatrix} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix}.$$

- A matriz de correlação também pode ser diagonal, ou seja

$$\mathbf{C} = \begin{bmatrix} \rho_1 & 0 & \cdots & 0 \\ 0 & \rho_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \rho_p \end{bmatrix},$$

nesse caso, as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$, para $j \neq k$, são independentes e, por isso, a correlação é igual a zero

- **Cuidado:** com essa última afirmação, pois o contrário “se duas variáveis tem correlação igual a zero, então elas são independentes” não é sempre válida)

- Definindo a matriz diagonal de desvios-padrão

$$\mathbf{D} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_p),$$

a relação exata entre $\mathbf{C}$ e Σ é:

$$\mathbf{C} = \mathbf{D}^{-1} \Sigma \mathbf{D}^{-1}$$

- A operação inversa também é válida:

$$\Sigma = \mathbf{D} \mathbf{C} \mathbf{D}$$

- Essa relação é fundamental em técnicas como **PCA sobre a matriz de correlação**, usada quando as variáveis estão em escalas muito diferentes entre si

- A correlação amostral entre X_j e X_k é estimada por

$$r_{jk} = \frac{s_{jk}}{s_j s_k}$$

- A **matriz de correlação amostral** $\mathbf{R}$ é obtida por


$$\mathbf{R} = \mathbf{D}_S^{-1} \mathbf{S} \mathbf{D}_S^{-1}, \quad \mathbf{D}_S = \text{diag}(s_1, \dots, s_p)$$

- Equivalentemente, $\mathbf{R}$ é a matriz de covariâncias calculada sobre os dados **padronizados**

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

- r_{jk} é um estimador consistente de ρ_{jk} , com $-1 \leq r_{jk} \leq 1$

- ρ_{jk} mede a **força e direção** da associação linear entre X_j e X_k
 - ▶ $\rho > 0$: nuvem inclinada para **cima**
 - ▶ $\rho \approx 0$: nuvem **circular**, sem tendência linear
 - ▶ $\rho < 0$: nuvem inclinada para **baixo**
- A elipse de concentração fica **mais alongada** quanto mais $|\rho_{jk}|$ se aproxima de 1



Exemplo Numérico

- Usando a mesma amostra ($n = 4$, Altura e Peso), com

$$\mathbf{S} = \begin{bmatrix} 100,0 & 105,3 \\ 105,3 & 112,7 \end{bmatrix}$$

- Os desvios-padrão amostrais são:

$$s_1 = \sqrt{100,0} = 10,00 \quad s_2 = \sqrt{112,7} \approx 10,62$$


- A correlação amostral entre Altura e Peso é:

$$r_{12} = \frac{s_{12}}{s_1 s_2} = \frac{105,3}{10,00 \times 10,62} \approx 0,992$$

- Portanto:

$$\mathbf{R} = \begin{bmatrix} 1,000 & 0,992 \\ 0,992 & 1,000 \end{bmatrix}$$

Altura e Peso possuem correlação **muito forte e positiva** nessa amostra



Distâncias Multivariadas

Prof. Vinícius Osterne, PhD

- Outras métricas utilizadas a partir da matriz de dados $\mathbf{X}$ são as chamadas distâncias multivariadas
- Essas distâncias podem ser de:
 - ▶ **Similaridade:** quanto maior o valor observado, mais parecidos são os objetos (ex.: coeficiente de correlação, que nós já vimos)
 - ▶ **Dissimilaridade:** quanto maior o valor observado, menos parecidos serão os objetos (ex.: veremos a seguir)

- As principais medidas de dissimilaridade são:
 - ▶ Distância de Manhattan (distância L_1 : distância puramente geométrica)
 - ▶ Distância Euclidiana (distância L_2 : distância puramente geométrica)
 - ▶ Distância de Mahalanobis (distância estatística)
- Vamos detalhar essas medidas a seguir

Distância de Manhattan

$$d(\mathbf{x}, \mathbf{y}) = \sum_{j=1}^p |x_j - y_j|$$

- **Ideia:** Soma das diferenças absolutas entre coordenadas (como andar por quarteirões de uma cidade)
- **Vantagens:** Robusta a outliers
- **Desvantagens:** Sensível à escala das variáveis; ignora correlação entre elas


Distância de Manhattan: Exemplo Numérico

- Considere $\mathbf{x} = (1, 2)$ e $\mathbf{y} = (4, 6)$

- Calculando:

$$d = |4 - 1| + |6 - 2| = 3 + 4 = 7$$

- O caminho percorre **3 unidades** na horizontal e **4 unidades** na vertical, totalizando **7**



Distância Euclidiana

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}$$

- **Ideia:** Medida direta ("em linha reta") entre dois pontos no espaço (generalização do Teorema de Pitágoras)
- **Vantagens:** Intuitiva e fácil de calcular
- **Desvantagens:** Sensível à escala das variáveis; ignora correlação entre elas


Distância Euclidiana: Exemplo Numérico

- Considere $\mathbf{x} = (1, 2)$ e $\mathbf{y} = (4, 6)$

- Calculando:

$$\begin{aligned}d &= \sqrt{(4 - 1)^2 + (6 - 2)^2} \\&= \sqrt{9 + 16} = \sqrt{25} = 5\end{aligned}$$

- A distância em linha reta é **5**, menor que a Manhattan (**7**)



Distância de Mahalanobis

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(\mathbf{x} - \mathbf{y})^\top \mathbf{S}^{-1} (\mathbf{x} - \mathbf{y})},$$

onde $\mathbf{S}$ é a matriz de covariância dos dados

- **Ideia:** Leva em conta a correlação e a escala entre variáveis (mede a distância entre um ponto e uma distribuição)
- **Vantagens:** Invariante à escala; considera correlação entre variáveis; eficaz para detectar outliers multivariados
- **Desvantagens:** Requer estimar $\mathbf{S}$; pode ser instável com dados escassos ou variáveis colineares (quando uma é combinação linear da outra)

Distância de Mahalanobis: Exemplo Numérico

- Considere $\mathbf{x} = (1, 2)^\top$, $\mathbf{y} = (4, 6)^\top$ e a matriz de covariância

$$\mathbf{S} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \Rightarrow \mathbf{S}^{-1} = \frac{1}{5} \begin{bmatrix} 3 & -1 \\ -1 & 2 \end{bmatrix}$$


- O vetor de diferenças é $\mathbf{d} = \mathbf{x} - \mathbf{y} = (-3, -4)^\top$
- Calculando o produto quadrático:

$$\begin{aligned} \mathbf{d}^\top \mathbf{S}^{-1} \mathbf{d} &= \frac{1}{5} \begin{bmatrix} -3 & -4 \end{bmatrix} \begin{bmatrix} 3 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} -3 \\ -4 \end{bmatrix} = \frac{1}{5} (9 \cdot 1 + 2 \cdot (-3)(-4) + 2 \cdot 16 - \dots) \\ &= \frac{1}{5} [(-3)(3)(-3) + (-3)(-1)(-4) + (-4)(-1)(-3) + (-4)(2)(-4)] \\ &= \frac{1}{5} (27 - 12 - 12 + 32) = \frac{35}{5} = 7 \end{aligned}$$

- Portanto: $d_M = \sqrt{7} \approx 2,65$, bem menor que a Euclidiana ($d_E = 5$), pois $\mathbf{S}^{-1}$ **desconta a correlação** entre as variáveis

Distância de Mahalanobis: Visualização

- A elipse representa a **forma da distribuição** dos dados, definida por S
- x_1 está **mais longe** da média na Euclidiana, mas **dentro** do padrão da distribuição
- x_2 está **mais perto** na Euclidiana, mas **fora** do padrão (maior distância de Mahalanobis)
- A Mahalanobis mede quão **incomum** é o ponto, não apenas quão **longe** ele está



Por que a Distância de Manhattan e Euclidiana não são suficientes?

- A distância de Manhattan e Euclidiana trata todas as variáveis como se fossem **iguais em escala e independentes** entre si (o que raramente é verdade)
- Problemas:
 - ▶ **Escala diferente:** imagine medir a distância entre duas pessoas usando salário (R\$) e idade (anos); o salário tem variância milhares de vezes maior e vai **dominar completamente** o cálculo, como se a idade não existisse
 - ▶ **Correlação entre variáveis:** se altura e peso estão muito correlacionados, a distância Euclidiana os trata como se fossem **duas informações independentes**, quando na verdade estão medindo aspectos parecidos e “conta duas vezes” o mesmo fenômeno
- A distância de Mahalanobis foi criada para corrigir **exatamente esses dois problemas** ao mesmo tempo, usando S^{-1}

O que a Distância de Mahalanobis faz diferente?

- **Corrige a escala:** ao multiplicar por S^{-1} , ela “normaliza” cada variável pela sua própria variabilidade (variáveis com alta variância contribuem proporcionalmente menos)
- **Desconta a correlação:** se duas variáveis são muito correlacionadas, S^{-1} reduz a contribuição conjunta delas, evitando que o mesmo fenômeno seja contado duas vezes

O que a Distância de Mahalanobis faz diferente?

- **Mede o quanto o ponto é incomum:** não pergunta “quão longe está da média?”, mas sim “quão improvável é esse ponto, dado o padrão dos dados?” (um ponto pode estar longe da média mas ser perfeitamente comum dentro da nuvem)
- **Caso especial:** quando $S = \mathbf{I}$ (ou seja, variáveis independentes e com mesma variância) $S^{-1} = \mathbf{I}$ e a Mahalanobis se reduz exatamente à distância Euclidiana:

$$d_M = \sqrt{(\mathbf{x} - \mathbf{y})^\top \mathbf{I} (\mathbf{x} - \mathbf{y})} = \sqrt{\sum_{j=1}^p (x_j - y_j)^2} = d_E$$

Comparação entre as Distâncias

- Usando $\mathbf{x} = (1, 2)^\top$ e $\mathbf{y} = (4, 6)^\top$ com $\mathbf{S} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$:

Distância	Fórmula	Valor	Considera correlação?
Manhattan	$\sum x_j - y_j $	7,00	Não
Euclidiana	$\sqrt{\sum (x_j - y_j)^2}$	5,00	Não
Mahalanobis	$\sqrt{(\mathbf{x} - \mathbf{y})^\top \mathbf{S}^{-1} (\mathbf{x} - \mathbf{y})}$	2,65	Sim

- A Mahalanobis pondera a distância pelo inverso da variância, fazendo com que deslocamentos em direções de alta variabilidade tenham menor impacto na distância, medindo: quão improvável é o ponto dado a distribuição dos dados



Análises Gráficas


Prof. Vinícius Osterne, PhD

Análises Gráficas: Visão Geral

- A análise exploratória multivariada requer o uso de técnicas de visualização: os gráficos revelam estruturas que as estatísticas resumidas escondem
- As principais ferramentas gráficas são:
 - ▶ Gráfico de dispersão simples
 - ▶ Matriz de dispersão (*scatterplot matrix*)
 - ▶ Histogramas e densidades
 - ▶ Boxplots paralelos
 - ▶ Heatmap de correlação
 - ▶ Gráfico de perfis médios
 - ▶ Coordenadas paralelas
- Cada gráfico revela um aspecto diferente dos dados e usá-los em conjunto é essencial


Gráfico de Dispersão

- Visualiza a relação entre **duas variáveis quantitativas**
- Permite detectar:
 - ▶ Tendências lineares e não-lineares
 - ▶ Força e direção da correlação
 - ▶ Outliers bivariados
 - ▶ Agrupamentos naturais
- É o ponto de partida de qualquer análise bivariada




Histograma e Densidade

- Avalia a **distribuição marginal** de cada variável individualmente
- Revela:
 - ▶ Assimetria (skewness)
 - ▶ Curtose (caudas pesadas)
 - ▶ Multimodalidade
 - ▶ Outliers univariados
- Comparar histogramas de diferentes variáveis é o primeiro passo para entender a estrutura dos dados




Matriz de Dispersão (*Scatterplot Matrix*)

- Extensão do gráfico de dispersão para **mais de duas variáveis simultaneamente**
- Cada célula (j, k) mostra o gráfico de X_j vs. X_k
- A diagonal exibe a distribuição marginal de cada variável
- Permite identificar rapidamente **quais pares** de variáveis estão correlacionados



Boxplots Paralelos

- Exibe **múltiplos boxplots lado a lado**, um para cada variável ou grupo
- Permite comparar simultaneamente:
 - ▶ Medianas e dispersões
 - ▶ Assimetria de cada variável
 - ▶ Outliers
 - ▶ Diferenças entre grupos
- Muito usado para comparar distribuições entre grupos (ex.: antes/depois, tratamento/controlado)




Heatmap de Correlação

- Representa a **matriz de correlação R** por meio de cores
- Cada célula (j, k) recebe uma cor proporcional a r_{jk} :
 - ▶ **Laranja/quente**: correlação positiva forte
 - ▶ **Neutro**: sem correlação
 - ▶ **Frio**: correlação negativa
- Permite identificar rapidamente a **estrutura de dependência** entre todas as variáveis

	X_1	X_2	X_3	X_4
X_1	1.00	0.85	-0.30	0.10
X_2	0.85	1.00	-0.20	0.05
X_3	-0.30	-0.20	1.00	0.60
X_4	0.10	0.05	0.60	1.00


Gráfico de Perfis Médios

- Conecta as **médias de cada variável** por grupo com uma linha
- Útil para comparar **padrões multivariados** entre grupos distintos (ex.: pacientes vs. controles)
- Permite visualizar:
 - ▶ Quais variáveis mais diferenciam os grupos
 - ▶ Se os perfis são paralelos (interação entre grupo e variável)
- Base visual para testes como **MANOVA**



Coordenadas Paralelas

- Cada **eixo vertical** representa uma variável; cada **linha** representa uma observação
- Permite visualizar padrões em **muitas variáveis ao mesmo tempo**
- Linhas que se cruzam entre dois eixos indicam **correlação negativa**; linhas paralelas indicam **correlação positiva**
- Muito usado em dados com $p > 4$ variáveis, onde a matriz de dispersão fica impraticável



Quando Usar Cada Gráfico?

Gráfico	Objetivo principal	Nº de variáveis
Dispersão simples	Relação entre duas variáveis	$p = 2$
Histograma/Densidade	Distribuição marginal	$p = 1$
Boxplots paralelos	Comparar distribuições por grupo	$p \geq 2$
Matriz de dispersão	Todos os pares simultaneamente	$2 \leq p \leq 6$
Heatmap de correlação	Estrutura de dependência global	$p \geq 3$
Perfis médios	Comparação multivariada de grupos	$p \geq 3$
Coordenadas paralelas	Padrões em alta dimensão	$p \geq 4$

- Na prática, **use mais de um gráfico**: cada um revela um aspecto diferente da estrutura dos dados

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade**
- 6 Inferência
- 7 Relação entre Conjuntos de Variáveis
- 8 Técnicas de Redução de Dimensionalidade
- 9 Estruturas Latentes
- 10 Métodos de Classificação e Agrupamento

Distribuições de Probabilidade Multivariadas


- Neste bloco estudamos as principais distribuições de probabilidade no contexto multivariado
- **O que veremos:**
 - ▶ **Distribuição Normal Multivariada:** generalização da Normal univariada para vetores aleatórios; base de toda a inferência multivariada clássica
 - ▶ **Distribuição de Wishart:** generalização multivariada da qui-quadrado; distribuição natural para matrizes de covariância amostrais
 - ▶ **Distribuição T^2 de Hotelling:** generalização da estatística t de Student para o caso multivariado; usada para inferência sobre o vetor de médias

- **Por que essa ordem importa?**

- ▶ A Normal Multivariada descreve o comportamento de $\bar{\mathbf{X}}$
- ▶ A Wishart descreve o comportamento de $\mathbf{S}$
- ▶ O T^2 de Hotelling combina os dois para construir o teste sobre $\boldsymbol{\mu}$

- **Por que isso importa?**

- ▶ Toda a teoria de testes e intervalos de confiança multivariados depende dessas distribuições
- ▶ Compreendê-las é essencial para interpretar os resultados corretamente



Distribuição Normal Multivariada

Prof. Vinícius Osterne, PhD

Distribuição Normal Univariada: Revisão

- A distribuição normal é uma das distribuições de probabilidade mais utilizadas na Estatística
- Se $X \sim \mathcal{N}(\mu, \sigma^2)$, então a sua função densidade de probabilidade é dada por

$$f(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi} \sigma} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\},$$

sendo $\mu \in \mathbb{R}$ a esperança matemática (parâmetro de localização) e $\sigma^2 > 0$ a variância (parâmetro de dispersão)

- É uma **distribuição absolutamente contínua**: existe uma função densidade $f(x)$ tal que

$$F(x) = \int_{-\infty}^x f(t) dt$$


- Explicando a diferença:
 - ▶ **Distribuição contínua**: $\mathbb{P}(X = x) = 0$ para todo x , mas **pode não ter densidade**. Ex.: Distribuição de Cantor (contínua, mas não possui PDF)
 - ▶ **Distribuição absolutamente contínua**: $\mathbb{P}(X = x) = 0$ e existe $f(x) \geq 0$ tal que $F(x) = \int_{-\infty}^x f(t) dt$. Ex.: Normal, Exponencial, Gama, Beta, Uniforme

- **Por que importa?**

- ▶ Apenas distribuições absolutamente contínuas possuem PDF
- ▶ Permitem o uso direto de integrais para cálculo de probabilidades
- ▶ São necessárias para as técnicas clássicas de inferência

- **Nota:** $\mathbb{P}(X = x) = 0$ não significa impossibilidade (significa que a probabilidade está “espalhada” continuamente pelo eixo real, sem massa em pontos isolados)

Curvas Normais



Mudar μ desloca a curva; mudar σ altera sua largura e altura

Da Normal Univariada para a Multivariada

- Quando $\mu = 0$ e $\sigma^2 = 1$, temos a **distribuição normal padrão**: $X \sim \mathcal{N}(0, 1)$
- No **contexto multivariado**, generalizamos os parâmetros escalares para objetos matriciais:

Parâmetro	Univariado	Multivariado
Localização	$\mu \in \mathbb{R}$	$\boldsymbol{\mu} \in \mathbb{R}^p$
Dispersão	$\sigma^2 > 0$	$\boldsymbol{\Sigma} \in \mathbb{R}^{p \times p}$, def. positiva
Notação	$X \sim \mathcal{N}(\mu, \sigma^2)$	$\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$

- $\boldsymbol{\Sigma}$ deve ser **simétrica e positiva definida**: garante que a distribuição seja não-degenerada (tudo não aconteça em um único ponto, existe dispersão, incerteza, variabilidade) e que $\boldsymbol{\Sigma}^{-1}$ exista

Distribuição Normal Multivariada: Definição

- Se $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então sua função densidade de probabilidade é


$$f(\mathbf{x} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{p/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\}$$

- Comparando com a versão univariada:

- ▶ $(x - \mu)^2 / \sigma^2 \longrightarrow (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})$ (distância de Mahalanobis ao quadrado!)
- ▶ $\sigma \longrightarrow |\boldsymbol{\Sigma}|^{1/2}$ (determinante faz o papel da escala)
- ▶ $1/\sqrt{2\pi} \longrightarrow 1/(2\pi)^{p/2}$ (constante de normalização em p dimensões)


Geometria da Normal Bivariada: Superfície

- Para $p = 2$, a densidade $f(x_1, x_2)$ define uma **superfície em sino** sobre o plano (X_1, X_2)
- O **pico** da superfície está em μ
- A superfície decai simetricamente em todas as direções, controlada por Σ
- **Cortes horizontais** nessa superfície geram curvas de igual densidade, as chamadas **curvas de nível**



Geometria da Normal Bivariada: Curvas de Nível

- Ao **projetar** os cortes horizontais no plano (X_1, X_2) , obtemos as **curvas de nível**
- Cada curva conecta pontos de **igual densidade** e igual distância de Mahalanobis ao centro
- As curvas de nível da DNM são sempre **elipses** centradas em μ
- A **forma e orientação** dependem de Σ :
 - ▶ $\sigma_{12} = 0 \Rightarrow$ elipses com eixos paralelos
 - ▶ $\sigma_{12} \neq 0 \Rightarrow$ elipses inclinadas

Curvas de nível da DNM com $\rho_{12} > 0$

Propriedades da Normal Multivariada

- A DNM possui três propriedades estruturais que a tornam central na estatística multivariada
- Veremos cada uma em detalhe a seguir

As três propriedades

- ❶ **Fechada sob marginalização:** subconjuntos de variáveis também seguem uma DNM
- ❷ **Independência equivale a correlação zero:** propriedade exclusiva da DNM
- ❸ **Fechada sob transformações lineares:** combinações lineares de variáveis normais também são normais

Propriedade 1: Fechada sob Marginalização

- **Intuição:** se altura, peso e idade seguem uma DNM conjunta e você analisa apenas altura e idade, a distribuição dessas duas variáveis continua sendo normal multivariada
- **Por que não é óbvio?** Em muitas famílias, a marginal não pertence à mesma família da conjunta. Na DNM isso é garantido pela estrutura quadrática da densidade
- **Consequência prática:** subconjuntos de variáveis podem ser analisados sem perder a estrutura normal, o que é essencial em PCA, análise discriminante e modelos hierárquicos

Formalmente

$$\text{Se } \begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \sim \mathcal{N}\left(\begin{bmatrix} \mu_{\mathbf{X}} \\ \mu_{\mathbf{Y}} \end{bmatrix}, \begin{bmatrix} \Sigma_{\mathbf{XX}} & \Sigma_{\mathbf{XY}} \\ \Sigma_{\mathbf{YX}} & \Sigma_{\mathbf{YY}} \end{bmatrix}\right), \quad \text{então} \quad \mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, \Sigma_{\mathbf{XX}})$$

Propriedade 2: Independência e Correlação Zero

- Em geral, **independência implica correlação zero**, mas a recíproca é falsa
- Na DNM, as duas condições são **equivalentes**:

$$\sigma_{jk} = 0 \iff X_j \perp X_k$$

- **Por que isso importa?** Verificar independência em geral é difícil. Na DNM, basta olhar para Σ : entradas nulas fora da diagonal indicam independência
- **Atenção:** essa equivalência **não vale** para outras distribuições. É uma propriedade exclusiva da estrutura normal

Propriedade 3: Fechada sob Transformações Lineares

- Combinações lineares de um vetor normal multivariado também seguem uma DNM
- Isso vale para qualquer matriz $\mathbf{A}$ de dimensão $q \times p$

Formalmente

Se $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e $\mathbf{A}$ é uma matriz $q \times p$, então

$$\mathbf{AX} \sim \mathcal{N}_q(\mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top)$$

- **Consequência prática:** essa propriedade fundamenta PCA (que aplica uma rotação linear aos dados), a construção de contrastes em MANOVA e a teoria de modelos lineares multivariados



Distribuição T^2 de Hotelling

Prof. Vinícius Osterne, PhD

Da Estatística t à Estatística T^2

- No **univariado**, para testar $H_0 : \mu = \mu_0$ com σ^2 desconhecido, usamos a estatística

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} \sim t_{n-1}$$

- Observe que: elevando ao quadrado a expressão acima, temos:

$$t^2 = n(\bar{x} - \mu_0)(s^2)^{-1}(\bar{x} - \mu_0)$$

Da Estatística t à Estatística T^2

- No **multivariado**, a generalização natural de t^2 para p variáveis é a **estatística T^2 de Hotelling**:

$$T^2 = n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)$$

- Observe que o produto $(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)$ é exatamente a **distância de Mahalanobis ao quadrado** entre $\bar{\mathbf{x}}$ e $\boldsymbol{\mu}_0$, ponderada pelo tamanho amostral n
- T^2 é uma **estatística de teste**, não uma densidade: mede o quanto o vetor de médias amostral se afasta do valor hipotético $\boldsymbol{\mu}_0$

Distribuição Amostral do T^2

- Sob $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$ e normalidade dos dados, a estatística T^2 segue uma distribuição T^2 de Hotelling com parâmetros p e $n - 1$
- Para realizar o teste, convertemos T^2 para uma estatística F :

$$F = \frac{n - p}{p(n - 1)} T^2 \sim F_{p, n-p}$$

- **Comparação com o caso univariado:**

	Univariado	Multivariado
Estatística	$t^2 = n(\bar{x} - \mu_0)^2 / s^2$	$T^2 = n(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}_0)$
Distribuição	$F_{1, n-1}$	$\frac{p(n-1)}{n-p} F_{p, n-p}$
Rejeita H_0	$t^2 > F_{1, n-1; \alpha}$	$T^2 > \frac{p(n-1)}{n-p} F_{p, n-p; \alpha}$


Revisão: Distribuição t de Student

- A distribuição t de Student surge quando estimamos σ^2 a partir dos dados (é mais “conservadora” que a Normal por ter **caudas mais pesadas**)
- Parametrizada pelos **graus de liberdade** ν , que estão ligados ao tamanho amostral: quanto menor ν , mais pesadas as caudas e mais incerteza no teste
- Para $\mu = 0$ e $\sigma = 1$, sua PDF é:

$$f(x | \nu) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\nu\pi} \Gamma(\frac{\nu}{2})} \left(1 + \frac{x^2}{\nu}\right)^{-\frac{\nu+1}{2}}$$

- À medida que $\nu \rightarrow \infty$, a t converge para a $\mathcal{N}(0, 1)$

Curvas t de Student



À medida que ν cresce, a t se aproxima da Normal padrão

t de Student vs. Normal: Caudas

- A t tem **caudas mais pesadas** que a Normal: atribui mais probabilidade a valores extremos
- Isso é importante quando n é pequeno e σ^2 é desconhecido: a incerteza extra precisa ser refletida na distribuição
- Na prática: intervalos de confiança e regiões críticas baseados na t são **mais largos** que os baseados na Normal (o teste é mais conservador)
- Para $\nu \geq 30$, a diferença é negligenciável na maioria das aplicações



Distribuição de Wishart

Prof. Vinícius Osterne, PhD

Da Qui-Quadrado à Wishart

- Assim como a T^2 de Hotelling generaliza a estatística t de Student, a distribuição de **Wishart** generaliza a distribuição **qui-quadrado** para o caso multivariado

- Revisão:** se $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma^2)$, então

$$\sum_{i=1}^n X_i^2 \sim \sigma^2 \chi^2(n)$$

- Generalização:** se $\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}_p(\mathbf{0}, \Sigma)$, então

$$\mathbf{W} = \sum_{i=1}^n \mathbf{X}_i \mathbf{X}_i^\top \sim W_p(\Sigma, n)$$

- O escalar $\sum X_i^2$ vira uma **soma de matrizes de posto 1**; σ^2 vira Σ ; o grau de liberdade n permanece

Distribuição de Wishart: Definição

- Dizemos que $\mathbf{W} \sim W_p(\Sigma, \nu)$ se $\mathbf{W}$ é uma matriz $p \times p$ **simétrica e positiva definida** que pode ser escrita como

$$\mathbf{W} = \sum_{i=1}^{\nu} \mathbf{z}_i \mathbf{z}_i^{\top}, \quad \mathbf{z}_i \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}_p(\mathbf{0}, \Sigma)$$

- Os parâmetros são:
 - ▶ Σ : matriz de escala ($p \times p$, positiva definida) análogo a σ^2 na qui-quadrado
 - ▶ ν : graus de liberdade (requer $\nu \geq p$ para $\mathbf{W}$ ser positiva definida quase certamente)

ESTUDAR TIPOS DE CONVERGÊNCIA

- **Caso especial:** para $p = 1$, $W_1(\sigma^2, \nu) = \sigma^2 \chi^2(\nu)$, recuperando exatamente a qui-quadrado escalonada

- **Esperança:**

$$\mathbb{E}[\mathbf{W}] = \nu \mathbf{\Sigma}$$

Cada elemento de $\mathbf{W}$ cresce proporcionalmente aos graus de liberdade, assim como $\mathbb{E}[\chi^2(\nu)] = \nu$

- **Fechada sob somas:** se $\mathbf{W}_1 \sim W_p(\mathbf{\Sigma}, \nu_1)$ e $\mathbf{W}_2 \sim W_p(\mathbf{\Sigma}, \nu_2)$ independentes, então

$$\mathbf{W}_1 + \mathbf{W}_2 \sim W_p(\mathbf{\Sigma}, \nu_1 + \nu_2)$$

- **Transformações lineares:** se $\mathbf{W} \sim W_p(\mathbf{\Sigma}, \nu)$ e $\mathbf{A}$ é uma matriz $q \times p$, então

$$\mathbf{A}\mathbf{W}\mathbf{A}^\top \sim W_q(\mathbf{A}\mathbf{\Sigma}\mathbf{A}^\top, \nu)$$

Conexão com a Matriz de Covariâncias Amostral

- Seja $\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e $\mathbf{S}$ a matriz de covariâncias amostral. Então:

$$(n-1) \mathbf{S} \sim W_p(\boldsymbol{\Sigma}, n-1)$$

- Este resultado é o análogo multivariado de

$$(n-1) s^2 / \sigma^2 \sim \chi^2(n-1)$$

- **Consequência:** a distribuição de $\mathbf{S}$ é completamente caracterizada por $\boldsymbol{\Sigma}$ e pelos graus de liberdade $n-1$, o que fundamenta toda a inferência sobre matrizes de covariância

Comparação: Qui-Quadrado vs. Wishart

Conceito	Univariado (χ^2)	Multivariado (Wishart)
Objeto	escalar $w \in \mathbb{R}$	matriz $\mathbf{W} \in \mathbb{R}^{p \times p}$
Parâmetro de escala	σ^2	Σ
Graus de liberdade	ν	$\nu \geq p$
Construção	$\sum_{i=1}^{\nu} x_i^2$	$\sum_{i=1}^{\nu} \mathbf{z}_i \mathbf{z}_i^{\top}$
Esperança	$\nu \sigma^2$	$\nu \Sigma$
Caso especial	—	$p = 1$ recupera $\sigma^2 \chi^2(\nu)$
Ligação com $\mathbf{S}$	$(n-1)s^2 \sim \sigma^2 \chi^2(n-1)$	$(n-1)\mathbf{S} \sim W_p(\Sigma, n-1)$

- A Wishart desempenha na inferência multivariada o mesmo papel que a qui-quadrado desempenha na univariada: é a distribuição de referência para testar e estimar Σ

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência**
- 7 Relação entre Conjuntos de Variáveis
- 8 Técnicas de Redução de Dimensionalidade
- 9 Estruturas Latentes
- 10 Métodos de Classificação e Agrupamento

Inferência sobre Vetores de Médias

- Neste bloco aplicamos as distribuições multivariadas para fazer **inferência sobre vetores de médias**
- O que veremos:
 - ▶ **Teorema do Limite Central:** base assintótica que justifica os procedimentos inferenciais
 - ▶ **Uma população:** teste e intervalo de confiança para o vetor de médias μ
 - ▶ **Duas populações independentes:** comparação entre dois grupos sem relação entre as observações
 - ▶ **Populações pareadas:** comparação quando as observações são medidas repetidas ou naturalmente emparelhadas
 - ▶ **MANOVA:** extensão para comparação simultânea de mais de duas populações



Teorema do Limite Central

Prof. Vinícius Osterne, PhD

O Problema que o TLC Resolve

- Na prática, quase nunca conhecemos a distribuição da população
- Altura, salário, temperatura, pressão arterial: cada variável tem sua própria forma

O Problema que o TLC Resolve

- E ainda assim, precisamos fazer inferências: construir intervalos de confiança, testar hipóteses, etc
- Como fazer isso sem conhecer a distribuição? Sem conhecer as propriedades das nossas medidas de interesse?

Por que Focar na Média?

- Uma saída: focar em **uma** medida, que seria a **média amostral** $\bar{X}$
- A média tem propriedades bem estabelecidas:
 - ▶ **Não-viesada:** em média, $\bar{X}$ acerta o valor real do parâmetro populacional μ
 - ▶ **Eficiente:** dentre os estimadores não-viesados, a média tem a menor variância possível
 - ▶ **Consistente:** conforme o tamanho da amostra cresce, $\bar{X}$ converge para μ

Por que Focar na Média?

- Mas ainda resta o problema: para fazer inferência sobre a média, eu preciso saber qual é a **distribuição** de $\bar{X}$
- É aqui que entra o **Teorema do Limite Central**, a ponte que torna isso possível

Teorema do Limite Central

Sejam $X_1, X_2, \dots, X_n$ variáveis aleatórias i.i.d. com média μ e variância $\sigma^2 < \infty$. Então, quando $n \rightarrow \infty$,


$$\bar{X} \xrightarrow{\mathcal{D}} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{ou, equivalentemente,} \quad \sqrt{n} \frac{\bar{X} - \mu}{\sigma} \xrightarrow{\mathcal{D}} \mathcal{N}(0, 1)$$

- O símbolo $\xrightarrow{\mathcal{D}}$ indica **convergência em distribuição**: a distribuição de $\bar{X}$ se aproxima da normal, não que $\bar{X}$ em si se torna normal
- Não exige normalidade da população, apenas que μ e σ^2 existam e sejam finitos
- A velocidade de convergência depende da forma da população

Intuição: o Experimento das Médias

- Imagine uma população de **salários**, fortemente assimétrica à direita
- Realizamos o seguinte experimento repetidamente:
 - ① Sorteamos uma amostra de $n = 30$ pessoas
 - ② Calculamos a média amostral $\bar{X}$
 - ③ Anotamos esse valor
 - ④ Repetimos o processo milhares de vezes
- A coleção de todas as médias obtidas forma a **distribuição amostral de $\bar{X}$**
- O TLC afirma que essa distribuição se aproxima de uma **normal**, independente da forma da população original

Visualização: da População às Médias



- A média amostral se concentra em torno de μ e a dispersão diminui com n
- A variância de $\bar{X}$ é σ^2/n : quanto maior a amostra, mais estreita a curva

O Efeito do Tamanho Amostral

- A qualidade da aproximação normal depende de dois fatores:
 - ① O **tamanho da amostra** n
 - ② A **forma da distribuição original** da população
- Como assim?

O Efeito do Tamanho Amostral

- Para populações **simétricas**, mesmo $n = 10$ pode ser suficiente
- Para populações **fortemente assimétricas** ou com caudas pesadas, pode ser necessário $n \geq 50$ ou mais
- A regra prática $n \geq 30$ é um ponto de partida, não uma garantia universal

Resumo

Quanto mais longe da normalidade for a população, maior precisa ser a amostra para que a aproximação seja boa

Extensão: Versão Multivariada

TLC Multivariado

Sejam $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ vetores aleatórios i.i.d. com média $\boldsymbol{\mu}$ e matriz de covariâncias $\boldsymbol{\Sigma}$ positiva definida. Então, quando $n \rightarrow \infty$,

$$\bar{\mathbf{X}} \xrightarrow{\mathcal{D}} \mathcal{N}_p\left(\boldsymbol{\mu}, \frac{\boldsymbol{\Sigma}}{n}\right) \quad \text{ou, equivalentemente,} \quad \sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \xrightarrow{\mathcal{D}} \mathcal{N}_p(\mathbf{0}, \boldsymbol{\Sigma})$$

- O resultado vale **para cada componente** individualmente e para a estrutura conjunta dos p vetores
- Ou seja: não só cada variável separada se comporta bem, mas a relação entre elas também é preservada

Consequência: de Normal Multivariada para Qui-Quadrado

- Vimos que $\sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \xrightarrow{\mathcal{D}} \mathcal{N}_p(\mathbf{0}, \boldsymbol{\Sigma})$
- Lembrando do caso univariado:

$$Z \sim \mathcal{N}(0, 1) \implies Z^2 \sim \chi^2(1)$$

- ▶ Ou seja, elevar uma normal padrao ao quadrado gera uma qui-quadrado com 1 grau de liberdade
- E se tivermos uma normal multivariada?

Consequência: de Normal Multivariada para Qui-Quadrado

- O caso multivariado generaliza essa ideia:

$$\mathbf{Z} \sim \mathcal{N}_p(\mathbf{0}, \Sigma) \implies \mathbf{Z}^\top \Sigma^{-1} \mathbf{Z} \sim \chi^2(p)$$

- O papel de Σ^{-1} aqui é o mesmo que dividir por σ^2 no caso univariado: ele padroniza e remove a correlação entre as variáveis
- Essa expressão tem um nome: é a **distância de Mahalanobis** ao quadrado, que mede o afastamento de $\mathbf{Z}$ da origem levando em conta a estrutura de correlação

Consequência: de Normal Multivariada para Qui-Quadrado

- Aplicando ao TLC, substituindo $\mathbf{Z}$ por $\sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu})$:

$$n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \xrightarrow{\mathcal{D}} \chi^2(p)$$

- Na prática $\boldsymbol{\Sigma}$ é desconhecida, então substituímos por $\mathbf{S}$, e o resultado continua valendo assintoticamente
- Essa é a base da estatística T^2 de Hotelling para testes sobre médias multivariadas

Por que o TLC é Fundamental?

O que ele garante

- Médias amostrais têm distribuição aproximadamente normal para n grande
- Vale para qualquer população com variância finita
- Justifica o uso da distribuição normal em inferência mesmo sem normalidade populacional

O que ele viabiliza

- Construção de intervalos de confiança para μ
- Testes de hipótese sobre médias
- Estatística T^2 de Hotelling em amostras grandes
- Toda a teoria assintótica de modelos lineares e multivariados

Em uma frase

O TLC é o que nos permite usar a matemática da distribuição normal no mundo real, onde as populações raramente são normais



Inferência sobre o vetor de médias de uma população

Prof. Vinícius Osterne, PhD

Motivação: um problema concreto

- Um **nutricionista** acompanha **40 pacientes** e mede **três variáveis simultaneamente**:
 - ▶ **pressão sistólica**
 - ▶ **colesterol total**
 - ▶ **glicemia em jejum**

- A literatura indica que, para **adultos saudáveis**, o vetor de médias esperado é

$$\mu_0 = (120, 190, 90)^T$$

- A pergunta é: o vetor de médias observado na amostra é **compatível** com esse valor de referência, ou há evidência de desvio?

Uma Primeira Ideia: Três Testes t Separados

- Uma solução imediata seria testar cada variável individualmente com um teste t de Student:

$$H_0^{(j)} : \mu_j = \mu_{0j} \quad \text{vs} \quad H_1^{(j)} : \mu_j \neq \mu_{0j}, \quad j = 1, 2, 3$$

- Para cada variável, a estatística de teste é

$$t_j = \frac{\bar{x}_j - \mu_{0j}}{s_j / \sqrt{n}} \sim t_{n-1}$$

e rejeitamos $H_0^{(j)}$ se $|t_j| > t_{n-1; \alpha/2}$

- Faríamos isso três vezes (uma para Altura, uma para Peso, uma para Idade) e concluiríamos sobre o vetor de médias com base nos três resultados individuais

Motivação: um problema concreto

- Entretanto, três testes t separados é problemático:
 - ▶ Ignora a correlação entre as variáveis
 - ▶ Infla o erro tipo I

Problema 1: ignorar a correlação

Mas por que **ignorar correlação** é um problema?

- **Variáveis multivariadas raramente são independentes:** peso e altura se **correlacionam**, pressão sistólica e diastólica também
- Ao **testar cada variável separadamente**, tratamos as variáveis como se fossem **independentes**
- Isso distorce a **geometria do problema**: a **distância real entre dois grupos depende da correlação entre as variáveis**, não só das diferenças individuais
- Um **teste univariado** pode **não detectar uma diferença multivariada real**, ou **detectar uma diferença que não existe quando as variáveis são analisadas em conjunto**

Problema 2: inflação do erro tipo I

E porque há uma inflação do erro do tipo I?

- **Erro tipo I** é a probabilidade de **rejeitar H_0** quando ela é **verdadeira** (falso positivo)
- Ao **realizar múltiplos testes**, essa probabilidade se acumula, ou seja, com 3 testes a $\alpha = 0,05$:
 - ▶ A chance de **não** errar em um teste é $1 - 0,05 = 0,95$
 - ▶ A chance de **não** errar em nenhum dos 3 é $0,95^3 \approx 0,86$
 - ▶ A chance de errar em **pelo menos um** é o complemento: $1 - 0,95^3 \approx 0,14$
- Ou seja, mesmo sem nenhuma diferença real, temos **14% de chance de concluir erroneamente que existe alguma**

Motivação: um problema concreto

- Os dois problemas juntos tornam os testes t separados inadequados para dados multivariados
- Precisamos de um teste que avalie o vetor de médias **como um todo**, respeitando a correlação entre as variáveis e controlando o erro tipo I global

Do teste t univariado ao T^2 de Hotelling

- A estatística T^2 de Hotelling é a generalização natural:

$$T^2 = n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)$$

- ▶ Para $p = 1$, temos a generalização exata:

$$T^2 = n \frac{(\bar{X} - \mu_0)^2}{s^2} = t^2$$

- Observação: no caso multivariado, o afastamento entre dois vetores precisa levar em conta a escala de cada variável e a correlação entre elas (isso é exatamente o que a distância de Mahalanobis faz)
- Mas calma, vamos entender como chegamos nessa estatística T^2 de Hotelling a seguir

Configuração formal do problema

- Sejam $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ uma amostra aleatória de $\mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, com $\boldsymbol{\Sigma}$ desconhecida
- O teste de hipóteses de interesse é

$$H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$$

$$H_1 : \boldsymbol{\mu} \neq \boldsymbol{\mu}_0$$

- ▶ $\boldsymbol{\mu}_0$ é um vetor fixado: pode ser um valor normativo, um resultado de estudo anterior ou um valor de referência clínica

O que precisamos estimar?

- Temos uma amostra $\mathbf{X}_1, \dots, \mathbf{X}_n \stackrel{\text{iid}}{\sim} \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$
- Os dois parâmetros desconhecidos são $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$, estimados por:

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i \quad \text{e} \quad \mathbf{S} = \frac{1}{n-1} \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})^\top$$

- A construção da estatística de teste depende de entender a distribuição de $\bar{\mathbf{X}}$ e de $\mathbf{S}$ separadamente

Distribuição de $\bar{\mathbf{X}}$

- O vetor de médias amostrais segue:

$$\bar{\mathbf{X}} \sim \mathcal{N}_p\left(\boldsymbol{\mu}, \frac{\boldsymbol{\Sigma}}{n}\right)$$

- Isso é direto: média de normais independentes é normal, e a variância se divide por n
- Em particular, sob $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$:

$$\sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0) \sim \mathcal{N}_p(\mathbf{0}, \boldsymbol{\Sigma})$$

Distribuição de S: a Distribuição de Wishart

- No caso univariado, sabemos que $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$
- O caso multivariado generaliza esse resultado: se $\mathbf{Y}_1, \dots, \mathbf{Y}_m \stackrel{\text{iid}}{\sim} \mathcal{N}_p(\mathbf{0}, \Sigma)$, então

$$\mathbf{W} = \sum_{i=1}^m \mathbf{Y}_i \mathbf{Y}_i^\top \sim \text{Wishart}_p(m, \Sigma)$$

- A Wishart é a generalização matricial da qui-quadrado: para $p = 1$, ela se reduz a $\sigma^2 \chi^2(m)$
- No contexto amostral:

$$(n-1)\mathbf{S} \sim \text{Wishart}_p(n-1, \Sigma)$$

Independência entre $\bar{X}$ e S

- No caso univariado, $\bar{X}$ e S^2 são independentes quando a população é normal (**PROVE!**)
- O mesmo vale no caso multivariado: $\bar{X}$ e S são independentes, garantido pela normalidade da população (**PROVE!**)
- Essa independência é fundamental: ela permite combinar os dois resultados anteriores para construir a estatística de teste

Independência entre $\bar{\mathbf{X}}$ e $\mathbf{S}$

- Temos então os três ingredientes necessários:

- ▶ $\bar{\mathbf{X}} \sim \mathcal{N}_p(\boldsymbol{\mu}, \frac{\boldsymbol{\Sigma}}{n})$
- ▶ $(n-1)\mathbf{S} \sim \text{Wishart}_p(n-1, \boldsymbol{\Sigma})$
- ▶ $\bar{\mathbf{X}}$ e $\mathbf{S}$ são independentes

Derivação da estatística T^2 : caso ideal

- Sob H_0 , temos $\sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0) \sim \mathcal{N}_p(\mathbf{0}, \boldsymbol{\Sigma})$
- Se $\boldsymbol{\Sigma}$ fosse conhecida, pela propriedade da distância de Mahalanobis:

$$n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)^\top \boldsymbol{\Sigma}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0) \sim \chi^2(p)$$

- Problema: $\boldsymbol{\Sigma}$ é desconhecida na prática
- Solução natural: substituir $\boldsymbol{\Sigma}$ por $\mathbf{S}$

Derivação da estatística T^2 : substituindo Σ por S

- Substituir Σ por S muda a distribuição: agora temos o quociente entre uma forma quadrática normal e uma Wishart
- Isso é a generalização multivariada exata do que acontece no caso univariado: substituir σ^2 por s^2 transforma uma normal em uma t de Student
- A estatística resultante é o T^2 de Hotelling:

$$T^2 = n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)$$

- E sua distribuição exata sob H_0 é:

$$T^2 \sim \frac{(n-1)p}{n-p} F(p, n-p)$$

Duas perguntas naturais

- **Pergunta 1:** a estatística se chama T^2 de Hotelling, mas sua distribuição envolve uma F . Por quê?
- **Pergunta 2:** se o TLC garante que $\bar{X}$ se aproxima de uma normal para qualquer população, por que precisamos assumir normalidade para aplicar o teste?
- **Vamos tentar entender isso!**

Por que T^2 segue uma distribuição F ?

- No caso univariado, substituir σ^2 por s^2 transforma uma normal em uma t de Student
- E a t ao quadrado é uma F :

$$t^2(n-1) = F(1, n-1)$$

- O caso multivariado generaliza esse raciocínio: temos um vetor normal no numerador e uma Wishart no denominador, e Hotelling mostrou que esse quociente, após reescalonamento, segue exatamente uma F
- O nome T^2 vem justamente dessa analogia com o t^2 univariado. E para $p=1$, a fórmula se reduz exatamente ao caso univariado:

$$\frac{(n-1) \cdot 1}{n-1} F(1, n-1) = F(1, n-1) = t^2(n-1)$$

Por que precisamos assumir normalidade?

- O **TLC** garante que $\bar{\mathbf{X}}$ se aproxima de uma normal quando n cresce, independente da distribuição da população
- Então por que a **normalidade da população é necessária?**
 - ▶ A distribuição exata $T^2 \sim \frac{(n-1)p}{n-p} F(p, n-p)$ depende não só de $\bar{\mathbf{X}}$, mas também de $\mathbf{S}$
 - ▶ E o resultado $(n-1)\mathbf{S} \sim \text{Wishart}_p(n-1, \Sigma)$ só vale exatamente quando a população é normal
- Existem portanto **dois regimes**:
 - ▶ **Populacao normal:** a distribuição F é exata para qualquer n , inclusive amostras pequenas
 - ▶ **Populacao nao normal:** o TLC entra em ação e $T^2 \xrightarrow{D} \chi^2(p)$, mas só assintoticamente. Para n pequeno, a distribuição F é apenas uma aproximação e pode ser ruim

- Então, voltando o teste multivariado, rejeitamos H_0 ao nível α se:

$$T_{\text{obs}}^2 > \frac{(n-1)p}{n-p} q_{F(p, n-p), \alpha}$$

- Para amostras grandes, à medida que $n \rightarrow \infty$:

$$\frac{(n-1)p}{n-p} \rightarrow p \quad \text{e} \quad T^2 \xrightarrow{\mathcal{D}} \chi^2(p)$$

ou seja, podemos usar a aproximação qui-quadrado quando n é suficientemente grande

Região de confiança para μ


- No caso univariado, quando queremos não apenas testar mas também estimar μ , construímos um **intervalo de confiança**: um segmento de reta centrado em $\bar{X}$ que contém o verdadeiro μ com probabilidade $(1 - \alpha)$
- No caso multivariado, μ é um vetor, então o intervalo não faz mais sentido geometricamente. A generalização natural é uma **região de confiança**, e essa região tem a forma de um **elipsoide** centrado em $\bar{X}$
- A mudança de intervalo para elipsoide não é arbitrária: ela vem diretamente da geometria da distância de Mahalanobis, que leva em conta a correlação entre as variáveis

Região de confiança para μ

- Uma região com $(1 - \alpha) \times 100\%$ de confiança para μ é o conjunto de vetores μ^* que satisfazem

$$n(\bar{\mathbf{X}} - \mu^*)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \mu^*) \leq \frac{(n-1)p}{n-p} F_\alpha$$

- A **orientação** e o **tamanho** do elipsoide são determinados pelos **autovetores** e **autovalores** de $\mathbf{S}$



Equivalência entre teste e região de confiança

- Há uma dualidade exata entre o teste T^2 e a região de confiança elipsoidal:
 - ▶ μ_0 está **dentro** da região de confiança $(1 - \alpha)$ **se e somente se** H_0 **não é rejeitada** ao nível α
 - ▶ μ_0 está **fora** da região de confiança **se e somente se** H_0 **é rejeitada** ao nível α
- Essa dualidade é a mesma do caso univariado: μ_0 fora do IC de 95% equivale a rejeitar H_0 a 5%
- A região elipsoidal é **mais informativa** do que o teste isolado: ela mostra **quais valores de μ** são compatíveis com os dados, não apenas se μ_0 é compatível
- Em aplicações práticas, reportar a região de confiança junto ao teste é sempre recomendável

Voltando ao exemplo: pressão, colesterol e glicemia

- Suponha que com $n = 40$ pacientes obtivemos

$$\bar{\mathbf{X}} = (126, 198, 94)^{\top}, \quad \boldsymbol{\mu}_0 = (120, 190, 90)^{\top}$$

- Calculada a estatística, obtemos $T_{\text{obs}}^2 = 8,3$
- O valor crítico a 5% é $\frac{39,3}{37} F_{0,05}(3, 37) \approx 3,16 \times 2,86 \approx 9,04$
- Como $T_{\text{obs}}^2 = 8,3 < 9,04$, **não rejeitamos** H_0 ao nível de 5%
- Interpretação: apesar de as médias amostrais se afastarem de $\boldsymbol{\mu}_0$, o desvio conjunto não é suficientemente grande para rejeitar a hipótese de que a população segue o padrão de referência, ao nível de 5%



Inferência sobre o vetor de médias de duas populações independentes

Prof. Vinícius Osterne, PhD

Motivação: comparando dois grupos

- Um pesquisador quer comparar o perfil metabólico de pacientes diabéticos e não diabéticos, medindo três variáveis simultaneamente:
 - ▶ glicemia em jejum
 - ▶ insulina basal
 - ▶ triglicerídeos
- As duas amostras são **independentes**: cada paciente pertence a apenas um grupo
- A pergunta é: os vetores de médias dos dois grupos são compatíveis, ou há evidência de que os perfis metabólicos diferem?

Uma primeira ideia: aplicar o T^2 separadamente

- Poderíamos tentar usar o T^2 de Hotelling de uma população em cada grupo separadamente, comparando cada vetor de médias a um valor de referência μ_0
- Mas isso não responde a pergunta certa: queremos saber se os dois grupos **diferem entre si**, não se cada um difere de um valor externo
- A generalização natural é trabalhar diretamente com a **diferença $\bar{X}_1 - \bar{X}_2$** no lugar de $\bar{X} - \mu_0$
- Mas antes de construir a estatística de teste, há uma suposição importante que precisa ser entendida

Configuração formal

- Sejam duas amostras aleatórias independentes:

- ▶ $\mathbf{X}_{11}, \dots, \mathbf{X}_{1n_1} \stackrel{\text{iid}}{\sim} \mathcal{N}_p(\boldsymbol{\mu}_1, \boldsymbol{\Sigma})$

- ▶ $\mathbf{X}_{21}, \dots, \mathbf{X}_{2n_2} \stackrel{\text{iid}}{\sim} \mathcal{N}_p(\boldsymbol{\mu}_2, \boldsymbol{\Sigma})$

- Suposição central:** as duas populações compartilham a mesma matriz de covariâncias $\boldsymbol{\Sigma}$ (homocedasticidade multivariada)

Configuração formal

- As hipóteses de interesse são:

$$H_0 : \mu_1 = \mu_2$$

$$H_1 : \mu_1 \neq \mu_2$$

- Que podem ser reescritas de uma maneira mais geral como:

$$H_0 : \mu_1 - \mu_2 = \delta_0$$

$$H_1 : \mu_1 - \mu_2 \neq \delta_0,$$

- Onde δ_0 é o valor de referência para a diferença entre os vetores de médias
 - O caso do nosso interesse é $\delta_0 = 0$ (queremos testar ausência de diferença entre os grupos)
- Mas por que as duas populações compartilham a mesma matriz de covariâncias? Onde entra isso?

Por que assumimos $\Sigma_1 = \Sigma_2$?

Mas por que essa **suposição é necessária**?

- Para construir a **estatística de teste**, precisamos estimar Σ a partir dos dados. **Se as duas populações têm a mesma Σ** , podemos combinar a informação das duas amostras em um **único estimador mais preciso**
- Se $\Sigma_1 \neq \Sigma_2$, não há como combinar as amostras dessa forma e o problema fica muito **mais complexo**
- **Na prática, essa suposição é testada antes de prosseguir, usando o teste de Box**
- Quanto mais próximas **forem S_1 e S_2** , mais eficiente é a estimativa combinada que construiremos a seguir

A matriz de covariâncias pooled

- Como Σ é comum aos dois grupos, combinamos as matrizes amostrais ponderando pelos graus de liberdade:

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}$$

- Isso é exatamente a **generalização** matricial da variância pooled univariada:

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

- A lógica é a mesma: **cada grupo contribui com seus graus de liberdade**, e o denominador $n_1 + n_2 - 2$ é a **soma desses graus de liberdade**
- Distribucionalmente:

$$(n_1 + n_2 - 2)\mathbf{S}_p \sim \text{Wishart}_p(n_1 + n_2 - 2, \Sigma)$$

O que precisamos para construir o teste?

- Seguindo a mesma lógica do caso de uma população, precisamos de dois ingredientes:
 - ▶ A distribuição de $\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2$ (análogo de $\bar{\mathbf{X}}$)
 - ▶ Um estimador de Σ com distribuição Wishart conhecida (que é $\mathbf{S}_p$)
- Já temos o segundo. Vamos agora derivar o primeiro

Distribuição da diferença entre médias amostrais

- Usando propriedades da distribuição normal multivariada e a independência das amostras:

$$\mathbb{E}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2$$

$$\text{Var}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \frac{\boldsymbol{\Sigma}}{n_1} + \frac{\boldsymbol{\Sigma}}{n_2} = \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \boldsymbol{\Sigma}$$

- Portanto:

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim \mathcal{N}_p\left(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2, \left(\frac{1}{n_1} + \frac{1}{n_2}\right) \boldsymbol{\Sigma}\right)$$

- Sob $H_0 : \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2 = \boldsymbol{\delta}_0$, a diferença centrada tem média zero e a mesma estrutura de covariância

Temos os ingredientes. E agora?

- Temos então os dois ingredientes necessários:

- ▶ $\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0 \sim \mathcal{N}_p\left(\mathbf{0}, \left(\frac{1}{n_1} + \frac{1}{n_2}\right) \Sigma\right)$ sob H_0
- ▶ $(n_1 + n_2 - 2) \mathbf{S}_p \sim \text{Wishart}_p(n_1 + n_2 - 2, \Sigma)$

- A construção da estatística T^2 segue exatamente a mesma lógica do caso de uma população:

- ▶ Se Σ fosse conhecida, formaríamos a distância de Mahalanobis $\sim \chi^2(p)$
- ▶ Como Σ é desconhecida, substituímos por $\mathbf{S}_p$, obtendo uma distribuição F

- A diferença em relação ao caso de uma população está apenas na **escala** da matriz de covariâncias: $\frac{\Sigma}{n}$ vira $\left(\frac{1}{n_1} + \frac{1}{n_2}\right) \Sigma$

Estatística T^2 para dois grupos independentes

- Substituindo Σ por S_p na distância de Mahalanobis entre as médias, obtemos:

$$T^2 = (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0)^\top \left[\left(\frac{1}{n_1} + \frac{1}{n_2} \right) S_p \right]^{-1} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta_0)$$

- Sob H_0 , sua distribuição exata é:

$$T^2 \sim \frac{(n_1 + n_2 - 2) p}{n_1 + n_2 - p - 1} F(p, n_1 + n_2 - p - 1)$$

- Os graus de liberdade $n_1 + n_2 - p - 1$ refletem que usamos $n_1 + n_2 - 2$ g.l. para estimar Σ via S_p

Uma pergunta natural

- **Pergunta:** no caso de uma população, a fórmula era $\frac{(n-1)p}{n-p} F(p, n-p)$. Agora temos $\frac{(n_1+n_2-2)p}{n_1+n_2-p-1} F(p, n_1+n_2-p-1)$. O que mudou e por quê?
- **Vamos entender isso!**

Por que os graus de liberdade mudam?

- No caso de uma população, o estimador de Σ era S com $n - 1$ graus de liberdade
- Agora, o estimador é S_p com $n_1 + n_2 - 2$ graus de liberdade: cada grupo contribui com seus próprios graus de liberdade, e os dois se somam
- A distribuição F resultante reflete esse acúmulo: mais graus de liberdade no denominador significam uma estimativa mais precisa de Σ e um teste mais poderoso
- Em resumo: $n - 1 \rightarrow n_1 + n_2 - 2$ é a única mudança estrutural. Toda a lógica de derivação é a mesma

Conexão com o caso univariado

Para $p = 1$: $T^2 = t^2$ e $\frac{(n_1+n_2-2)}{n_1+n_2-2} F(1, n_1 + n_2 - 2) = t^2(n_1 + n_2 - 2)$, que é exatamente o t pooled clássico

Regra de decisão

- Rejeitamos H_0 ao nível α se

$$T_{\text{obs}}^2 > \frac{(n_1 + n_2 - 2) p}{n_1 + n_2 - p - 1} q_{F(p, n_1 + n_2 - p - 1), \alpha}$$

- Para amostras grandes, vale a mesma aproximação qui-quadrado do caso de uma população:


$$T^2 \xrightarrow{\mathcal{D}} \chi^2(p) \quad \text{quando } n_1, n_2 \rightarrow \infty$$

Região de confiança para a diferença $\mu_1 - \mu_2$

- A região de confiança $(1 - \alpha) \times 100\%$ para $\mu_1 - \mu_2$ é o elipsoide de todos os δ^* que satisfazem

$$(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta^*)^\top \left[\left(\frac{1}{n_1} + \frac{1}{n_2} \right) \mathbf{S}_p \right]^{-1} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - \delta^*) \leq \frac{(n_1 + n_2 - 2)p}{n_1 + n_2 - p - 1} F_\alpha$$

- Vale a dualidade exata: δ_0 fora do elipsoide $\Leftrightarrow$ rejeitar H_0 ao nível α



O que fazer quando $\Sigma_1 \neq \Sigma_2$?

E se o teste de Box rejeitar a igualdade das matrizes de covariância?

- O uso de S_p não é adequado: estaríamos combinando estimativas de quantidades diferentes
- Alternativas disponíveis na literatura:
 - ▶ **Nel e Van der Merwe (1986)**: generaliza o teste de Welch para o caso multivariado, com graus de liberdade ajustados a partir das matrizes amostrais
 - ▶ **Johansen (1980)**: usa uma estatística F com graus de liberdade estimados a partir dos dados
 - ▶ **Bootstrap**: especialmente útil quando as suposições de normalidade também são questionáveis

Voltando ao exemplo: diabéticos vs não diabéticos

- Com $n_1 = 35$ diabéticos e $n_2 = 38$ não diabéticos, medindo $p = 3$ variáveis metabólicas:

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 = (32,4, 18,7, 45,2)^\top$$

- Calculada a estatística: $T_{\text{obs}}^2 = 24,8$

- Valor crítico a 5%:

$$\frac{71 \times 3}{69} F_{0,05}(3, 69) \approx 3,087 \times 2,74 \approx 8,46$$

- Como $T_{\text{obs}}^2 = 24,8 \gg 8,46$, **rejeitamos** H_0 com folga
- Interpretação: há evidência multivariada forte de que os perfis metabólicos médios dos dois grupos diferem, considerando conjuntamente as três variáveis e a correlação entre elas



Inferência sobre o vetor de médias de populações pareadas

Prof. Vinícius Osterne, PhD

Motivação: quando as amostras têm uma ligação

- Um **médico avalia** 30 pacientes hipertensos antes e após 12 semanas de tratamento, medindo três variáveis simultaneamente:
 - ▶ **pressão sistólica**
 - ▶ **pressão diastólica**
 - ▶ **frequência cardíaca**
- As duas amostras **não são independentes**: cada observação do **grupo “antes”** corresponde exatamente a uma observação do **grupo “depois”** no mesmo paciente
- A pergunta é: **o tratamento produziu uma mudança significativa no vetor de médias dessas três variáveis?**

Por que não podemos usar o teste de dois grupos independentes?

Mas por que o teste de amostras independentes seria inadequado aqui?

- No teste de dois grupos independentes, assumimos que as observações de um grupo não têm relação com as do outro
- Aqui, cada paciente aparece nos dois grupos: o valor “antes” e o valor “depois” pertencem à mesma pessoa
- Ignorar essa ligação seria um erro: parte da variabilidade que observamos entre os grupos não vem do tratamento, mas sim de diferenças individuais entre os pacientes

Por que não podemos usar o teste de dois grupos independentes?

E mais:

- Um paciente naturalmente com pressão alta terá valores altos tanto antes quanto depois, independentemente do tratamento. Isso inflacionaria a variabilidade estimada e reduziria o poder do teste
- A solução é trabalhar com o **vetor de diferenças** $\mathbf{D}_j = \mathbf{X}_{1j} - \mathbf{X}_{2j}$, que elimina exatamente essa variabilidade individual

Independente vs pareado: o que muda na prática?

Amostras independentes

- Duas amostras distintas, sem ligação entre observações
- A variabilidade total inclui diferenças individuais entre os grupos
- Estimativa de Σ usa S_p com $n_1 + n_2 - 2$ g.l.
- Adequado quando grupos são formados por indivíduos diferentes

Amostras pareadas

- Cada observação de um grupo corresponde a uma do outro
- O pareamento remove a variabilidade individual, aumentando poder
- Estimativa usa S_D das diferenças, com $n - 1$ g.l.
- Adequado para medidas repetidas no mesmo indivíduo

Independente vs pareado: o que muda na prática?

Regra prática

Se os dados vieram do mesmo indivíduo em momentos distintos, use o teste pareado. Usar o teste independente nesses casos é conservador e perde poder

Configuração formal e redução ao caso de uma amostra

- Sejam $(\mathbf{X}_{1j}, \mathbf{X}_{2j})$ o par de medidas do j -ésimo indivíduo, $j = 1, \dots, n$
- Definimos o vetor de diferenças $\mathbf{D}_j = \mathbf{X}_{1j} - \mathbf{X}_{2j}$
- Como cada $\mathbf{D}_j$ é combinação linear de normais, então:

$$\mathbf{D}_j \stackrel{\text{iid}}{\sim} \mathcal{N}_p(\boldsymbol{\mu}_D, \boldsymbol{\Sigma}_D), \quad \boldsymbol{\mu}_D = \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2$$

- O problema se reduz a testar $H_0 : \boldsymbol{\mu}_D = \mathbf{0}$ com a amostra $\mathbf{D}_1, \dots, \mathbf{D}_n$: exatamente o caso de uma população com $\boldsymbol{\mu}_0 = \mathbf{0}$
- Essa redução é a ideia central do método pareado: transformamos um problema de duas amostras dependentes em um problema de uma única amostra de diferenças

Os estimadores das diferenças

- As hipóteses de interesse são

$$H_0 : \mu_D = 0$$

$$H_1 : \mu_D \neq 0$$

- No caso mais geral, podemos testar $H_0 : \mu_D = \mu_{D_0}$ para um vetor de referência μ_{D_0} qualquer
- Os estimadores são calculados diretamente sobre as diferenças:

$$\bar{\mathbf{D}} = \frac{1}{n} \sum_{j=1}^n \mathbf{D}_j, \quad \mathbf{S}_D = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{D}_j - \bar{\mathbf{D}})(\mathbf{D}_j - \bar{\mathbf{D}})^\top$$

Por que $\Sigma_D \neq \Sigma$?

Mas qual é a **estrutura de covariância das diferenças**?

- Expandindo a variância de $\mathbf{D}_j = \mathbf{X}_{1j} - \mathbf{X}_{2j}$:

$$\Sigma_D = \Sigma_1 + \Sigma_2 - \Sigma_{12} - \Sigma_{21}$$

onde $\Sigma_{12} = \text{Cov}(\mathbf{X}_{1j}, \mathbf{X}_{2j})$ é a covariância entre as **medidas antes e depois**

- Quando $\Sigma_1 = \Sigma_2 = \Sigma$:

$$\Sigma_D = 2\Sigma - 2\Sigma_{12}$$

- Se as **medidas antes e depois forem fortemente correlacionadas**, Σ_{12} é grande e Σ_D é pequena: **as diferenças variam pouco, tornando o teste mais poderoso**
- Esse é o mecanismo pelo qual o pareamento **ganha eficiência**: ele remove a correlação intra-indivíduo da variabilidade residual

Estatística de teste e distribuição

- Como o problema se reduz ao caso de uma amostra com $\mathbf{D}_1, \dots, \mathbf{D}_n$, a estatística T^2 de Hotelling é diretamente:

$$T^2 = n(\bar{\mathbf{D}} - \mu_{D_0})^\top \mathbf{S}_D^{-1} (\bar{\mathbf{D}} - \mu_{D_0})$$

- Para o caso $\mu_{D_0} = \mathbf{0}$:

$$T^2 = n \bar{\mathbf{D}}^\top \mathbf{S}_D^{-1} \bar{\mathbf{D}}$$

- Sob H_0 , a distribuição exata é

$$T^2 \sim \frac{(n-1)p}{n-p} F(p, n-p)$$

onde n é o número de **pares**, não o total de observações

Regra de decisão

- Rejeitamos H_0 ao nível α se

$$T_{\text{obs}}^2 > \frac{(n-1)p}{n-p} q_{F(p, n-p), \alpha}$$


- A fórmula é **idêntica** à do caso de uma população: o que muda é que os dados de entrada são as diferenças $\mathbf{D}_j$, não as observações originais

Dica de implementação

No R, basta calcular as diferenças $\mathbf{D} \leftarrow \mathbf{X1} - \mathbf{X2}$ e aplicar qualquer função de T^2 para uma amostra sobre $\mathbf{D}$ com $\mu_0 = \mathbf{0}$

Quando o pareamento ajuda e quando não ajuda

- O pareamento **aumenta o poder** quando a correlação intra-indivíduo é alta: Σ_{12} grande reduz Σ_D
- O pareamento **não ajuda** quando a correlação intra-indivíduo é baixa: perde-se graus de liberdade sem ganho de precisão
- Ao parear, usamos $n - 1$ g.l. em vez de $n_1 + n_2 - 2$ g.l. do teste independente
- Se as correlações forem próximas de zero, o teste independente pode ser mais poderoso




Região de confiança para μ_D

- A região de confiança $(1 - \alpha) \times 100\%$ para μ_D é o elipsoide de todos os μ_D^* que satisfazem

$$n(\bar{\mathbf{D}} - \mu_D^*)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{D}} - \mu_D^*) \leq \frac{(n-1)p}{n-p} F_\alpha$$

- Para verificar se há efeito do tratamento: basta checar se $\mathbf{0}$ está **fora** do elipsoide centrado em $\bar{\mathbf{D}}$
- A região de confiança é mais informativa que o teste isolado: ela mostra **em que direção** e com que magnitude o vetor de médias se alterou



Voltando ao exemplo: efeito do tratamento anti-hipertensivo

- Com $n = 30$ pares de medidas (antes e depois) de pressão sistólica, diastólica e frequência cardíaca:

$$\bar{\mathbf{D}} = (-8,4, -5,1, -4,7)^\top$$

os valores negativos indicam redução após o tratamento nas três variáveis

- Calculada a estatística: $T_{\text{obs}}^2 = 18,6$

- Valor crítico a 5%:

$$\frac{29 \times 3}{27} F_{0,05}(3, 27) \approx 3,22 \times 2,96 \approx 9,53$$

- Como $T_{\text{obs}}^2 = 18,6 > 9,53$, **rejeitamos** H_0
- Interpretação: há evidência multivariada de que o tratamento produziu redução significativa no vetor de médias das três medidas cardiovasculares, ao nível de 5%



MANOVA

Prof. Vinícius Osterne, PhD

Motivação: além de dois grupos

- O T^2 de Hotelling compara dois grupos em p variáveis dependentes. Mas e quando temos $g > 2$ grupos?
- Exemplo: um pesquisador compara o desempenho cognitivo de quatro grupos de participantes, medindo três variáveis simultaneamente:
 - ▶ memória
 - ▶ atenção
 - ▶ raciocínio
- Os quatro grupos correspondem a quatro intervenções: controle, dieta mediterrânea, exercício físico e meditação
- A pergunta é: há diferença entre os vetores de médias cognitivas dos quatro grupos?

Uma primeira ideia: vários testes T^2 par a par

- Uma **solução imediata** seria comparar todos os pares de grupos com testes **T^2 separados**
- Com $g = 4$ grupos, teríamos $\binom{4}{2} = 6$ testes. Com $g = 5$, seriam 10 testes. O número cresce rapidamente
- Mas realizar **múltiplos testes T^2 é problemático pela mesma razão que realizar múltiplos testes t era problemático no início do curso:** o erro tipo I se acumula
- Com **6 testes a $\alpha = 0,05$** , a probabilidade de pelo menos um falso positivo pode ultrapassar **26%**
- Precisamos de um teste que **avalie as diferenças entre os g vetores de médias simultaneamente**, controlando o **erro tipo I global**

A MANOVA como generalização natural

- A **MANOVA** (Multivariate Analysis of Variance) é exatamente essa generalização
- Ela está para o T^2 de dois grupos assim como a **ANOVA** está para o teste t : em vez de comparar dois grupos, compara g grupos simultaneamente
- A ideia central é a mesma da **ANOVA** univariada: decompor a variabilidade total em duas fontes
 - ▶ variabilidade **entre** grupos (que queremos detectar)
 - ▶ variabilidade **dentro** dos grupos (que é ruído)
- A diferença é que agora cada fonte de variabilidade é uma **matriz** $p \times p$, não um escalar

Hierarquia dos testes

t de Student $\xrightarrow{p>1}$ T^2 de Hotelling $\xrightarrow{g>2}$ MANOVA

Configuração formal

- Consideramos g grupos independentes, cada um com distribuição normal multivariada e a **mesma** matriz de covariâncias:

- ▶ $\mathbf{X}_{11}, \dots, \mathbf{X}_{1n_1} \stackrel{\text{iid}}{\sim} \mathcal{N}_p(\boldsymbol{\mu}_1, \boldsymbol{\Sigma})$

- ▶ $\mathbf{X}_{21}, \dots, \mathbf{X}_{2n_2} \stackrel{\text{iid}}{\sim} \mathcal{N}_p(\boldsymbol{\mu}_2, \boldsymbol{\Sigma})$

- ▶ $\vdots$

- ▶ $\mathbf{X}_{g1}, \dots, \mathbf{X}_{gn_g} \stackrel{\text{iid}}{\sim} \mathcal{N}_p(\boldsymbol{\mu}_g, \boldsymbol{\Sigma})$

- Denotamos $N = \sum_{k=1}^g n_k$ o total de observações

- As hipóteses são

$$H_0 : \boldsymbol{\mu}_1 = \boldsymbol{\mu}_2 = \dots = \boldsymbol{\mu}_g$$

$$H_1 : \text{pelo menos um } \boldsymbol{\mu}_k \text{ é diferente dos demais}$$

Suposições da MANOVA

- **Normalidade multivariada:** cada grupo deve ter distribuição normal multivariada. Em amostras grandes, o método é relativamente robusto a violações moderadas
 - ▶ Como checar: teste de **Shapiro-Wilk multivariado** (MVN::`mshapiro.test`) ou **gráfico Q-Q** de distâncias de Mahalanobis
- **Homocedasticidade multivariada:** as **matrizes de covariância** devem ser iguais entre os **grupos**
 - ▶ Como checar: **teste de Box** (`biotools::boxM`)
- **Independência das observações:** avaliada pelo **delineamento**, não **por teste estatístico**
- **Ausência de multicolinearidade perfeita:** o determinante de **S** deve ser positivo; **variáveis redundantes** precisam ser removidas

Decomposição da variabilidade total

- Analogamente à ANOVA univariada, decompõe-se a variabilidade total em duas fontes:

$$\underbrace{\mathbf{T}}_{\text{total}} = \underbrace{\mathbf{H}}_{\text{entre grupos}} + \underbrace{\mathbf{E}}_{\text{dentro dos grupos}}$$

- As matrizes são:

- $\mathbf{T} = \sum_{k=1}^g \sum_{j=1}^{n_k} (\mathbf{X}_{kj} - \bar{\mathbf{X}})(\mathbf{X}_{kj} - \bar{\mathbf{X}})^T$ (dispersão total)

- $\mathbf{H} = \sum_{k=1}^g n_k (\bar{\mathbf{X}}_k - \bar{\mathbf{X}})(\bar{\mathbf{X}}_k - \bar{\mathbf{X}})^T$ (dispersão entre grupos)

- $\mathbf{E} = \sum_{k=1}^g \sum_{j=1}^{n_k} (\mathbf{X}_{kj} - \bar{\mathbf{X}}_k)(\mathbf{X}_{kj} - \bar{\mathbf{X}}_k)^T$ (dispersão dentro dos grupos)

- Note que $\mathbf{H}$, $\mathbf{E}$ e $\mathbf{T}$ são matrizes $p \times p$, não escalares como na ANOVA

Como avaliar se $\mathbf{H}$ é grande em relação a $\mathbf{E}$?

Na ANOVA univariada, comparamos SQ_{entre} e SQ_{dentro} pela razão F . Mas agora temos matrizes. Como comparar?

- Não podemos simplesmente dividir matrizes. Precisamos de uma forma de resumir a relação entre $\mathbf{H}$ e $\mathbf{E}$ em um único número
- Uma ideia natural é usar os **determinantes**: $|\mathbf{E}|$ mede o volume da dispersão dentro dos grupos, e $|\mathbf{H} + \mathbf{E}|$ mede o volume total
- Se H_0 for verdadeira, $\mathbf{H}$ deve ser pequena e $|\mathbf{E}| \approx |\mathbf{H} + \mathbf{E}|$
- Se H_0 for falsa, $\mathbf{H}$ captura variabilidade real entre grupos e $|\mathbf{E}| \ll |\mathbf{H} + \mathbf{E}|$
- Essa razão de determinantes é exatamente o **Lambda de Wilks**

Lambda de Wilks e outras estatísticas

- A estatística mais utilizada é o **Lambda de Wilks**:

$$\Lambda^* = \frac{|\mathbf{E}|}{|\mathbf{H} + \mathbf{E}|} \in (0, 1]$$

- $\Lambda^* \approx 1$ indica grupos semelhantes; $\Lambda^* \approx 0$ indica grupos muito diferentes
- Existem quatro estatísticas multivariadas clássicas, todas funções dos autovalores $\lambda_1 \geq \dots \geq \lambda_s$ de $\mathbf{E}^{-1}\mathbf{H}$, com $s = \min(p, g - 1)$:
 - ▶ **Wilks:** $\Lambda^* = \prod_i (1 + \lambda_i)^{-1}$ — a mais comum na literatura
 - ▶ **Pillai:** $V = \sum_i \lambda_i / (1 + \lambda_i)$ — a mais robusta a violações de normalidade
 - ▶ **Lawley-Hotelling:** $U = \sum_i \lambda_i$ — sensível a diferenças em todas as dimensões
 - ▶ **Roy:** $\theta = \lambda_1 / (1 + \lambda_1)$ — maximiza a separação em uma única direção

Duas perguntas naturais

- **Pergunta 1:** existem quatro estatísticas diferentes. Qual devo usar?
- **Pergunta 2:** o Lambda de Wilks usa determinantes para resumir a relação entre $\mathbf{H}$ e $\mathbf{E}$. Por que os autovalores de $\mathbf{E}^{-1}\mathbf{H}$ entram nessa história?
- **Vamos entender isso!**

Qual estatística usar?

- Quando H_0 é verdadeira, as quatro estatísticas tendem a concordar. As diferenças aparecem quando H_0 é falsa
- **Wilks** é a escolha padrão e a mais reportada na literatura. Para $s = 1$ ou $s = 2$, sua distribuição é exata
- **Pillai** é a mais robusta quando as suposições de normalidade ou homocedasticidade são moderadamente violadas. É a recomendação conservadora
- **Roy** é a mais poderosa quando as diferenças entre grupos se concentram em uma única direção, mas é a menos robusta a violações
- Na prática: se as quatro estatísticas concordam na conclusão, o resultado é robusto. Se divergem, investigar as suposições

Por que os autovalores de $\mathbf{E}^{-1}\mathbf{H}$?

De onde vêm os autovalores de $\mathbf{E}^{-1}\mathbf{H}$?

- A ideia é encontrar as direções no espaço das variáveis que maximizam a separação entre grupos em relação à variabilidade dentro dos grupos
- Isso é exatamente o que os autovalores de $\mathbf{E}^{-1}\mathbf{H}$ capturam: cada autovalor λ_i mede o quanto a variabilidade entre grupos supera a variabilidade dentro dos grupos na i -ésima direção discriminante
- Se todos os λ_i forem pequenos, os grupos se sobrepõem em todas as direções e não há evidência contra H_0
- Se algum λ_i for grande, existe pelo menos uma direção em que os grupos se separam claramente

Distribuição e regra de decisão

- Sob H_0 , para amostras grandes, a aproximação qui-quadrado é:

$$-\left(N - 1 - \frac{p + g}{2}\right) \ln(\Lambda^*) \sim \chi^2_{p(g-1)}$$

- Rejeitamos H_0 ao nível α quando essa estatística supera $q_{\chi^2_{p(g-1)}, \alpha}$
- Para amostras menores, existem aproximações F exatas ou quase exatas (Rao, 1951) que são preferíveis à aproximação qui-quadrado
- No R, `manova()` retorna automaticamente as quatro estatísticas:
 - ▶ `summary(fit, test = "Wilks")`
 - ▶ `summary(fit, test = "Pillai")`
 - ▶ `summary(fit, test = "Hotelling-Lawley")`
 - ▶ `summary(fit, test = "Roy")`

Conexão com o T^2 e com a ANOVA

- **Conexão com o T^2 :** para $g = 2$ grupos, $s = \min(p, 1) = 1$ e todas as quatro estatísticas multivariadas são funções monotônicas de T^2 . MANOVA e T^2 são equivalentes nesse caso
- **Conexão com a ANOVA:** para $p = 1$ variável dependente, $\mathbf{H}$ e $\mathbf{E}$ se tornam escalares e o Lambda de Wilks se reduz a

$$\Lambda^* = \frac{SQ_{res}}{SQ_{total}}$$

que é uma transformação monotônica do F da ANOVA univariada

- Em ambos os casos, a MANOVA recupera exatamente o teste mais simples como caso particular

O que fazer após rejeitar H_0 ?

A MANOVA indica que **alguma** diferença existe, mas não **onde**. O passo seguinte são análises post-hoc: comparações par a par com T^2 ajustando o nível de significância, ou análise discriminante para identificar quais variáveis mais contribuem para a separação

Voltando ao exemplo: quatro estratégias cognitivas

- Quatro grupos ($g = 4$) com $n_k = 25$ cada, medindo $p = 3$ variáveis cognitivas: memória, atenção e raciocínio. Total $N = 100$
- Após ajuste do modelo, obtemos $\Lambda^* = 0,42$
- Estatística qui-quadrado aproximada:

$$-\left(100 - 1 - \frac{3 + 4}{2}\right) \ln(0,42) \approx 95,5 \times 0,867 \approx 82,8$$

com $p(g - 1) = 3 \times 3 = 9$ graus de liberdade

- O valor crítico é $q_{\chi^2_9; 0,05} \approx 16,9$. Como $82,8 \gg 16,9$, **rejeitamos** H_0
- Interpretação: há diferença significativa entre os vetores de médias cognitivas dos quatro grupos. Análises post-hoc com T^2 par a par indicariam quais grupos diferem e em quais variáveis

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Relação entre Conjuntos de Variáveis**
- 8 Técnicas de Redução de Dimensionalidade
- 9 Estruturas Latentes
- 10 Métodos de Classificação e Agrupamento

Modelos Multivariados: Visão Geral

- Até aqui estudamos como **descrever** e **fazer inferências** sobre dados multivariados. Agora queremos **modelar relações** entre conjuntos de variáveis
- Neste bloco estudaremos três técnicas que ampliam progressivamente a **análise da relação entre um conjunto de preditores X e um conjunto de respostas Y** :
 - ▶ **i. Regressão Multivariada:** modela como X explica simultaneamente múltiplos desfechos em Y
 - ▶ **ii. Correlação Canônica:** investiga a associação simétrica entre dois conjuntos de variáveis por combinações lineares
 - ▶ **iii. Regressão Canônica:** estende a lógica da **regressão** para o espaço canônico com foco em predição entre **conjuntos**
- As três técnicas compartilham a mesma álgebra, mas diferem no **objetivo**, na **estrutura do problema** e na **interpretação**



Regressão Multivariada

Prof. Vinícius Osterne, PhD

Motivação: um problema concreto

- Um **pesquisador** em uma clínica quer entender como **hábitos de vida** afetam a saúde cardiovascular dos pacientes. Para cada paciente, ele mede:
 - ▶ **Preditores X:** horas de exercício por semana, consumo de sódio (g/dia), índice de massa corporal
 - ▶ **Desfechos Y:** pressão sistólica (mmHg), pressão diastólica (mmHg), frequência cardíaca em repouso (bpm)
- A pergunta é: como os hábitos de vida afetam o perfil cardiovascular dos pacientes, considerando os três desfechos **simultaneamente**?

Uma primeira ideia: três regressões separadas

- Uma solução imediata seria **ajustar três regressões múltiplas separadas**, uma para cada desfecho:
 - ▶ **P. Sistólica** = $\beta_{10} + \beta_{11} \text{ Exercício} + \beta_{12} \text{ Sódio} + \beta_{13} \text{ IMC} + \varepsilon_1$
 - ▶ **P. Diastólica** = $\beta_{20} + \beta_{21} \text{ Exercício} + \beta_{22} \text{ Sódio} + \beta_{23} \text{ IMC} + \varepsilon_2$
 - ▶ **Freq. Cardíaca** = $\beta_{30} + \beta_{31} \text{ Exercício} + \beta_{32} \text{ Sódio} + \beta_{33} \text{ IMC} + \varepsilon_3$
- Mas **pressão sistólica**, **diastólica** e **frequência cardíaca** são **desfechos correlacionados**: um paciente hipertenso tende a ter os três elevados simultaneamente
- Ignorar essa correlação entre os desfechos torna a inferência ineficiente e infla o erro tipo I

Por que a correlação entre desfechos importa?

Mas o que **exatamente se perde ao ignorar a correlação entre os desfechos?**

- Quando os desfechos são correlacionados, os resíduos das três equações também são correlacionados: o que o modelo não explicou em pressão sistólica tende a estar relacionado ao que não foi explicado em diastólica
- Ao ajustar três regressões separadas, jogamos fora essa informação. Os coeficientes estimados são os mesmos, mas os testes de hipótese ficam menos precisos
- Além disso, testar hipóteses sobre os preditores em três equações separadas infla o erro tipo I, pela mesma razão que três testes t separados inflam o erro tipo I
- A regressão multivariada modela os três desfechos **ao mesmo tempo**, usando a correlação entre eles para ganhar eficiência na inferência

Da regressão múltipla ao caso multivariado

Regressão múltipla

- Um vetor de preditores $\mathbf{x}$ explica *uma* resposta y
- Modelo: $y = \mathbf{x}^\top \boldsymbol{\beta} + \varepsilon$
- Resultado: *um* vetor $\hat{\boldsymbol{\beta}}$
- Pergunta: *quais* preditores afetam Y ?

Regressão multivariada

- Um vetor de preditores $\mathbf{x}$ explica *um* *vetor* de respostas $\mathbf{y}$
- Modelo: $\mathbf{y} = \mathbf{B}^\top \mathbf{x} + \boldsymbol{\varepsilon}$
- Resultado: uma matriz $\hat{\mathbf{B}}$
- Pergunta: *quais* preditores afetam *quais* desfechos?

X (preditores)

Y (desfechos)



Formulação do modelo

- O modelo para n observações, p preditores e q desfechos é:

$$\mathbf{Y}_{n \times q} = \mathbf{X}_{n \times p} \mathbf{B}_{p \times q} + \mathbf{E}_{n \times q}$$

- Cada linha de $\mathbf{Y}$ é o vetor de respostas do indivíduo i ; cada coluna é um desfecho
- A matriz $\mathbf{B}$ concentra todos os coeficientes: β_{jk} mede o efeito do preditor X_j sobre o desfecho Y_k
- Os erros seguem distribuição normal multivariada:

$$\text{vec}(\mathbf{E}) \sim \mathcal{N}(\mathbf{0}, \mathbf{\Sigma} \otimes \mathbf{I}_n)$$

onde $\mathbf{\Sigma}$ captura a correlação entre os desfechos e $\mathbf{I}_n$ garante a independência entre os indivíduos

O que significa $\Sigma \otimes \mathbf{I}_n$?

Mas o que essa notação está dizendo exatamente?

- A notação $\Sigma \otimes \mathbf{I}_n$ descreve duas estruturas de dependência ao mesmo tempo:
 - ▶ **Entre desfechos** (capturado por Σ): pressão sistólica e diastólica do mesmo paciente são correlacionadas
 - ▶ **Entre observações** (capturado por $\mathbf{I}_n$): pacientes diferentes são independentes entre si
- Intuitivamente: a correlação existe *dentro* de cada indivíduo, entre seus desfechos, mas não *entre* indivíduos distintos
- Se Σ fosse diagonal, os desfechos seriam independentes entre si e q regressões separadas seriam exatamente equivalentes ao modelo conjunto. É exatamente quando Σ não é diagonal que o modelo conjunto ganha em eficiência

Estimação de $\mathbf{B}$

- O estimador de mínimos quadrados (e de máxima verossimilhança sob normalidade) de $\mathbf{B}$ é:

$$\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

- Cada coluna de $\hat{\mathbf{B}}$ é idêntica ao estimador de uma regressão múltipla separada para aquele desfecho
- **Pergunta natural:** se os coeficientes são os mesmos, para que serve o modelo conjunto?
- A vantagem está na **inferência**: ao **testar hipóteses sobre $\mathbf{B}$** , usamos **$\hat{\Sigma}$ estimado conjuntamente**, o que leva em conta a correlação entre os desfechos e torna os testes mais precisos e controlados
- Os resíduos são $\hat{\mathbf{E}} = \mathbf{Y} - \mathbf{X}\hat{\mathbf{B}}$, e a estimativa de Σ é:

$$\hat{\Sigma} = \frac{1}{n - p} \hat{\mathbf{E}}^\top \hat{\mathbf{E}}$$

Suposições do modelo


- As suposições são extensões diretas das da regressão múltipla clássica:
 - ▶ **Linearidade:** relação linear entre $\mathbf{X}$ e cada Y_j
 - ▶ **Normalidade multivariada dos erros:** $\mathbf{e}_i \sim \mathcal{N}_q(\mathbf{0}, \Sigma)$
 - ▶ **Homogeneidade de covariâncias:** $\text{Cov}(\mathbf{e}_i) = \Sigma$ constante para todo i
 - ▶ **Independência** entre as observações
 - ▶ **Ausência de multicolinearidade** entre os preditores
- A violação mais crítica é a da normalidade multivariada dos erros, pois ela fundamenta os testes de hipótese sobre $\mathbf{B}$
- Para amostras grandes, o TLC garante a aproximação normal e os testes permanecem válidos mesmo sem normalidade exata dos erros

Como interpretar os resultados?

- A análise ocorre em **dois níveis complementares**, e a ordem importa:
 - ▶ **Nível multivariado:** os testes indicam se o conjunto de preditores influencia o vetor de desfechos como um todo. Este é o nível primário: só se avança para o próximo se houver significância aqui
 - ▶ **Nível univariado:** após confirmar a significância multivariada, examina-se cada equação separadamente para identificar quais desfechos são afetados por quais preditores
- O R^2 de cada equação mede a proporção da variância de Y_j explicada por X
- A correlação **residual entre os desfechos**, estimada por $\hat{\Sigma}$, **indica quanto de associação entre eles não foi explicado pelos preditores**

Visualização dos resíduos multivariados

- Em regressão múltipla, **resíduos são escalares**. Na multivariada, são **vetores**
- Cada observação produz um vetor de resíduos $\hat{\mathbf{e}}_i = \mathbf{y}_i - \hat{\mathbf{y}}_i$
- A **nuvem de resíduos no espaço** dos desfechos deve ser **centrada na origem** com forma elíptica compatível com $\hat{\Sigma}$
- Pontos muito afastados do centro são outliers multivariados que podem distorcer $\hat{\mathbf{B}}$. A **distância de Mahalanobis ao centro** é a medida natural para identificá-los



Voltando ao exemplo: hábitos de vida e saúde cardiovascular

- Com $n = 5$ pacientes, $p = 2$ preditores (Exercício e Sódio) e $q = 2$ desfechos (P. Sistólica e Freq. Cardíaca), após calcular $\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$, obtemos aproximadamente:

$$\hat{\mathbf{B}} = \begin{bmatrix} 148,2 & 88,1 \\ -3,8 & -2,2 \\ 1,5 & 0,9 \end{bmatrix}$$

onde as linhas correspondem ao intercepto, Exercício e Sódio; as colunas a P. Sistólica e Freq. Cardíaca

- Interpretando os coeficientes:
 - ▶ Cada hora adicional de exercício reduz a pressão em 3,8 mmHg e a frequência em 2,2 bpm
 - ▶ Cada grama adicional de sódio aumenta a pressão em 1,5 mmHg e a frequência em 0,9 bpm
- A correlação entre os resíduos das duas equações, estimada por $\hat{\Sigma}$, captura o que os preditores não conseguiram explicar e é usada para tornar os testes mais precisos



Correlação Canônica

Prof. Vinícius Osterne, PhD

Motivação: um problema concreto

- Um pesquisador estuda o bem-estar de $n = 300$ indivíduos e mede dois conjuntos de variáveis:
 - ▶ **Conjunto X** (saúde física): capacidade aeróbica, força muscular, flexibilidade, IMC
 - ▶ **Conjunto Y** (saúde mental): nível de ansiedade, qualidade do sono, satisfação com a vida, energia percebida
- Não há uma relação de causa e efeito clara: saúde física e mental se influenciam mutuamente
- A pergunta não é “física prediz mental?”, mas sim: *como os dois domínios de saúde se associam entre si?*

Uma primeira ideia: regressão multivariada

- Uma solução imediata seria tratar um dos conjuntos como preditor e o outro como desfecho e ajustar uma regressão multivariada
- Mas qual conjunto é o preditor? Saúde física prediz saúde mental? Ou é o contrário?
- Não há resposta clara: saúde física e mental se influenciam mutuamente, e escolher uma direção seria arbitrário
- Além disso, os resultados dependeriam de qual conjunto chamamos de $\mathbf{X}$ e qual chamamos de $\mathbf{Y}$: uma abordagem que depende de uma escolha arbitrária não é satisfatória
- Precisamos de uma técnica que trate os dois conjuntos de forma **simétrica**, identificando as dimensões de associação sem impor direcionalidade

A intuição: generalizando a correlação de Pearson

- Pense na correlação de Pearson entre duas variáveis X e Y : ela mede a associação linear de forma simétrica, $r(X, Y) = r(Y, X)$
- A **correlação canônica** é a generalização direta desse conceito para dois **conjuntos** de variáveis:
 - ▶ $U_k = \mathbf{a}_k^\top \mathbf{X}$: combinação dos indicadores de saúde física
 - ▶ $V_k = \mathbf{b}_k^\top \mathbf{Y}$: combinação dos indicadores de saúde mentale buscamos $\mathbf{a}_k$ e $\mathbf{b}_k$ que maximizem $\text{Cor}(U_k, V_k) = \rho_k$
- Cada par (U_k, V_k) revela uma **dimensão latente** de associação entre os dois domínios
- No exemplo, o primeiro par poderia revelar que pessoas com boa capacidade aeróbica e força muscular tendem a ter menos ansiedade e mais energia: uma dimensão de “vitalidade geral” comum aos dois conjuntos

Formulação do problema

- O problema de otimização do k -ésimo par é maximizar a correlação entre as combinações lineares:

$$\max_{\mathbf{a}_k, \mathbf{b}_k} \frac{\mathbf{a}_k^\top \Sigma_{XY} \mathbf{b}_k}{\sqrt{\mathbf{a}_k^\top \Sigma_{XX} \mathbf{a}_k \cdot \mathbf{b}_k^\top \Sigma_{YY} \mathbf{b}_k}}$$

- Sob a normalização $\mathbf{a}_k^\top \Sigma_{XX} \mathbf{a}_k = \mathbf{b}_k^\top \Sigma_{YY} \mathbf{b}_k = 1$, o problema se reduz aos autovetores de:

$$\mathbf{M} = \Sigma_{XX}^{-1} \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}$$

- Os autovalores $\lambda_k = \rho_k^2$ são os quadrados das correlações canônicas, com $\rho_1 \geq \dots \geq \rho_r \geq 0$ e $r = \min(p, q)$
- A restrição de variância unitária é uma normalização: sem ela, poderíamos aumentar $\text{Cor}(U_k, V_k)$ apenas escalando $\mathbf{a}_k$ ou $\mathbf{b}_k$

Uma pergunta natural

- **Pergunta:** a correlação canônica trata os dois conjuntos de forma simétrica. Mas o que isso significa concretamente? Trocar X e Y realmente não muda nada?
- **Vamos entender isso!**


Simetria: o que muda e o que não muda

- Os **valores** de ρ_k não mudam ao trocar $\mathbf{X}$ e $\mathbf{Y}$: a correlação canônica entre U_k e V_k é simétrica por construção, exatamente como a correlação de Pearson
- O que **não muda**: $\rho_1, \rho_2, \dots, \rho_r$ e os testes de significância associados
- O que **muda**: a interpretação dos vetores $\mathbf{a}_k$ e $\mathbf{b}_k$, que descrevem as combinações de cada conjunto, e as cargas canônicas associadas
- Isso contrasta com a regressão multivariada, onde trocar $\mathbf{X}$ e $\mathbf{Y}$ produz um modelo completamente diferente
- Na correlação canônica, não há preditor nem predito: os dois conjuntos têm papel equivalente na análise

Três níveis de interpretação

- Os resultados da correlação canônica são interpretados em três níveis complementares:
 - ▶ **Correlações canônicas** (ρ_k): força da associação entre o k -ésimo par. São o resultado central da análise. ρ_k^2 é a proporção de variância compartilhada entre U_k e V_k
 - ▶ **Cargas canônicas**: correlações entre as variáveis originais e as variáveis canônicas do *mesmo* conjunto. Indicam quais variáveis mais contribuem para cada dimensão canônica e permitem nomear as dimensões latentes
 - ▶ **Cargas cruzadas**: correlações entre as variáveis de $\mathbf{X}$ e as variáveis canônicas de $\mathbf{Y}$, e vice-versa. São a medida mais direta de associação entre os conjuntos: quanto a variável X_j está associada ao espaço de $\mathbf{Y}$?

Visualização das cargas canônicas



- O sinal negativo na Ansiedade é natural: mais condicionamento físico está associado a *menos* ansiedade. A dimensão latente capturada pelo primeiro par pode ser chamada de “vitalidade geral”

Suposições e testes de significância

- As suposições necessárias são:
 - ▶ **Normalidade multivariada conjunta** de $(\mathbf{X}, \mathbf{Y})$: necessária para a validade exata dos testes
 - ▶ **Linearidade** da relação entre os dois conjuntos: relações não lineares não serão capturadas pelos pares canônicos
 - ▶ **Ausência de multicolinearidade** dentro de cada conjunto: garante a invertibilidade de Σ_{XX} e Σ_{YY}
 - ▶ **Tamanho amostral adequado**: recomenda-se $n \geq 10(p + q)$ para estimativas estáveis
- O teste sequencial de Bartlett avalia quantos pares são significativos:

$$\chi_k^2 \approx - \left[n - 1 - \frac{1}{2}(p + q + 1) \right] \ln \prod_{i=k}^r (1 - \rho_i^2)$$

com $(p - k + 1)(q - k + 1)$ graus de liberdade

Voltando ao exemplo: saúde física e saúde mental


- Com $p = q = 4$ variáveis em cada conjunto, obtemos $r = 4$ pares canônicos. Após o teste de Bartlett, apenas o primeiro é significativo:

$$\rho_1 \approx 0,97 \quad \rho_2 \approx 0,09$$

- O **primeiro par canônico**:

- ▶ $U_1 \approx 0,58 \cdot \text{Aeróbico} + 0,42 \cdot \text{Força}$: índice de condicionamento físico
- ▶ $V_1 \approx -0,62 \cdot \text{Ansiedade} + 0,38 \cdot \text{Energia}$: índice de bem-estar mental

- Interpretação: há uma dimensão latente comum aos dois domínios de saúde que poderíamos chamar de “vitalidade geral”. $\rho_1 = 0,97$ indica associação muito forte, e essa relação é simétrica: não há sentido em perguntar qual conjunto causa qual



Regressão Canônica

Prof. Vinícius Osterne, PhD

Motivação: um problema concreto

- Um pesquisador acompanha $n = 200$ estudantes e mede dois conjuntos de variáveis:
 - ▶ **Preditores X** : horas de estudo por dia, frequência às aulas, horas de sono
 - ▶ **Desfechos Y** : nota em Matemática, nota em Português, nota em Ciências, nota em História
- As quatro notas são **altamente correlacionadas**: um aluno dedicado tende a ter boas notas em todas as disciplinas simultaneamente
- A pergunta é: existe uma combinação dos hábitos de estudo que resume bem a performance geral do aluno?

O que muda em relação à correlação canônica?

Já vimos a correlação canônica. O que a regressão canônica acrescenta?

- Na correlação canônica, os dois conjuntos têm papel simétrico: não há preditor nem predito, apenas associação
- Aqui, a situação é diferente: hábitos de estudo são claramente o conjunto de **entrada**, e as notas são claramente o conjunto de **saída**. A direcionalidade faz sentido
- Quando existe essa assimetria natural, a regressão canônica é mais apropriada: ela busca as combinações de **X** que melhor **predizem Y**, não apenas que mais se associam a ele
- A medida de qualidade também muda: em vez de ρ_k , reportamos o **índice de redundância**, que mede quanto da variância de **Y** é efetivamente predita por **X**

A diferença fundamental entre as duas técnicas

Correlação Canônica

- Relação **simétrica**
- **X** e **Y** se associam
- Objetivo: descrever associação
- Medida de qualidade: ρ_k
- Trocar **X** e **Y** não muda ρ_k



Regressão Canônica


- Relação **assimétrica**
- **X** prediz **Y**
- Objetivo: predição
- Medida de qualidade: redundância
- Trocar **X** e **Y** muda o resultado



A ideia central: variáveis canônicas

- Em vez de quatro equações separadas, criamos novas variáveis que **resumem** cada conjunto:
 - ▶ $U = \mathbf{a}^\top \mathbf{X}$: um “score de dedicação” do aluno, combinação linear dos hábitos de estudo
 - ▶ $V = \mathbf{b}^\top \mathbf{Y}$: um “score de desempenho geral”, combinação linear das notas
- Buscamos $\mathbf{a}$ e $\mathbf{b}$ que tornam U o **melhor preditor possível** de V , ou seja, que maximizam $\text{Cor}(U, V)$
- Se um único par (U, V) não for suficiente para capturar toda a relação, extraímos um segundo par ortogonal ao primeiro, e assim por diante
- O número máximo de pares é $r = \min(p, q)$: no nosso exemplo, $r = \min(3, 4) = 3$

Visualização geométrica



- A seta agora é unidirecional: U_1 prediz V_1 , não o contrário. Essa é a diferença geométrica em relação à correlação canônica

Formulação do problema de otimização

- As variáveis canônicas do k -ésimo par são:

$$U_k = \mathbf{a}_k^\top \mathbf{X} \quad \text{e} \quad V_k = \mathbf{b}_k^\top \mathbf{Y}$$

- Os vetores $\mathbf{a}_k$ e $\mathbf{b}_k$ maximizam a correlação entre o par:

$$\max_{\mathbf{a}_k, \mathbf{b}_k} \text{Cor}(U_k, V_k) = \rho_k$$

sujeito a $\text{Var}(U_k) = \text{Var}(V_k) = 1$ e ortogonalidade com os pares anteriores:

$$\text{Cor}(U_k, U_j) = \text{Cor}(V_k, V_j) = 0 \quad \text{para } j < k$$

- A restrição de variância unitária é uma normalização: sem ela, poderíamos aumentar $\text{Cor}(U_k, V_k)$ apenas escalando $\mathbf{a}_k$ ou $\mathbf{b}_k$
- A restrição de ortogonalidade garante que cada par capture informação **nova**, não repetida pelos pares anteriores

Como resolver o problema de otimização?

Como encontrar a_k e b_k na prática?

- A solução é obtida pelos autovetores de uma matriz construída a partir das covariâncias entre e dentro dos conjuntos
- A matriz de covariância conjunta de $(\mathbf{X}, \mathbf{Y})$ se particiona em blocos:

$$\Sigma = \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix}$$

onde Σ_{XY} captura a covariância *entre* os dois conjuntos, Σ_{XX} e Σ_{YY} capturam a variabilidade *dentro* de cada conjunto

- Σ_{XX}^{-1} e Σ_{YY}^{-1} normalizam pela variabilidade interna de cada conjunto, de forma análoga ao que S^{-1} faz na distância de Mahalanobis

A matriz de autovalores

- Após a normalização, a estrutura de predição de $\mathbf{X}$ sobre $\mathbf{Y}$ fica resumida na matriz:

$$\mathbf{M} = \Sigma_{XX}^{-1} \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}$$

- Os autovetores de $\mathbf{M}$ fornecem os vetores $\mathbf{a}_k$, e a partir deles derivam-se os $\mathbf{b}_k$
- Os autovalores $\lambda_k = \rho_k^2$ são os **quadrados das correlações canônicas**, ordenados de forma decrescente: $\rho_1 \geq \rho_2 \geq \dots \geq \rho_r \geq 0$
- Intuitivamente: cada autovalor mede o quanto de predição de $\mathbf{Y}$ a partir de $\mathbf{X}$ existe naquela dimensão. O primeiro par sempre captura a maior parte da relação

Conexão com a correlação canônica

A álgebra é **idêntica** à da correlação canônica. O que muda é o objetivo e a interpretação: aqui há um preditor e um predito, e reportamos o índice de redundância em vez de apenas ρ_k

Duas perguntas naturais

- **Pergunta 1:** quantos pares canônicos devo reter? Todos os $r = \min(p, q)$ pares ou apenas alguns?
- **Pergunta 2:** como saber se a predição do primeiro par é realmente boa, ou se ρ_1 alto pode ser enganoso?
- **Vamos entender isso!**

Quantos pares reter? O teste sequencial de Bartlett

- O teste sequencial de Bartlett avalia quantos pares canônicos são significativos:

$$\chi_k^2 \approx - \left[n - 1 - \frac{1}{2}(p + q + 1) \right] \ln \prod_{i=k}^r (1 - \rho_i^2)$$

com $(p - k + 1)(q - k + 1)$ graus de liberdade

- O procedimento é sequencial:
 - ▶ Testa $H_0 : \rho_1 = \dots = \rho_r = 0$ (nenhum par é relevante)
 - ▶ Se rejeitado, remove ρ_1 e testa $H_0 : \rho_2 = \dots = \rho_r = 0$
 - ▶ Continua até não rejeitar ou esgotar os pares
- Retemos apenas os pares cujos testes rejeitam H_0 : esses são os que capturam predição real, não ruído

ρ_k alto pode ser enganoso?

Por que ρ_k alto sozinho não garante uma boa predição?


- ρ_k mede a correlação entre U_k e V_k , ou seja, entre as **combinações lineares**. Mas essas combinações podem capturar apenas uma pequena fração da variância das variáveis originais
- Um par pode ter ρ_k alto mas cargas canônicas fracas: os scores U_k e V_k se correlacionam bem entre si, mas nenhum deles representa bem as variáveis originais de seus respectivos conjuntos
- A medida correta de qualidade da predição é o **índice de redundância**:

$$\text{Rd}(\mathbf{Y}|\mathbf{X}) = \frac{1}{q} \sum_{k=1}^r \rho_k^2 \cdot \sum_{j=1}^q r^2(Y_j, V_k)$$

que pondera a correlação canônica pela proporção da variância das variáveis originais capturada por cada par

Gráfico dos pares canônicos

- O gráfico de U_k versus V_k mostra a força da k -ésima dimensão de predição
- Para o primeiro par com ρ_1 alto, a nuvem é muito alongada: U_1 prediz V_1 com muita precisão
- Para um segundo par com ρ_2 baixo, a nuvem é praticamente circular: não há predição relevante nessa dimensão e o par deve ser descartado



Voltando ao exemplo: hábitos de estudo e desempenho escolar

- Com $p = 3$ preditores (Estudo, Frequência e Sono) e $q = 4$ desfechos (Matemática, Português, Ciências e História), obtemos $r = 3$ pares canônicos. Após o teste de Bartlett, apenas o primeiro é significativo:

$$\rho_1 \approx 0,98 \quad \rho_2 \approx 0,12$$

- O primeiro par canônico:**

- ▶ $U_1 \approx 0,61 \cdot \text{Estudo} + 0,39 \cdot \text{Sono}$: score de dedicação
 - ▶ $V_1 \approx 0,54 \cdot \text{Mat.} + 0,46 \cdot \text{Port.}$: score de desempenho geral
- Interpretação: a relação entre hábitos de estudo e desempenho escolar se resume em uma única dimensão de predição. Alunos que estudam mais e dormem melhor têm notas gerais mais altas, e essa conclusão captura quase toda a informação disponível nos dados



Comparando as três técnicas

Prof. Vinícius Osterne, PhD

Resumo: as três técnicas

Aspecto	Reg. Multivariada	Reg. Canônica	Corr. Canônica
Relação	Assimétrica	Assimétrica	Simétrica
Objetivo	Predição direta	Predição em dim.	Associação
Opera em	Variáveis originais	Var. canônicas	Var. canônicas
Medida	R^2 por desfecho	Redundância	ρ_k
Exemplo	Clínica	Educação	Bem-estar

- As três técnicas compartilham a mesma álgebra de autovalores e matrizes de covariância em bloco
- A escolha entre elas depende do **objetivo científico**: prever cada desfecho diretamente, encontrar dimensões de predição mais parcimoniosas, ou entender a associação simétrica entre dois conjuntos de variáveis
- Em todos os casos, a interpretação começa pelos testes de significância e só então avança para as cargas e os índices derivados

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Relação entre Conjuntos de Variáveis
- 8 Técnicas de Redução de Dimensionalidade**
- 9 Estruturas Latentes
- 10 Métodos de Classificação e Agrupamento

i. Análise de Componentes Principais (PCA)

ii. Análise de Correspondência

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Relação entre Conjuntos de Variáveis
- 8 Técnicas de Redução de Dimensionalidade
- 9 Estruturas Latentes**
- 10 Métodos de Classificação e Agrupamento

iii. Análise Fatorial Exploratória (AFE)

iv. Análise Fatorial Confirmatória (AFC)

- A redução de dimensionalidade se refere ao processo de reduzir o número de variáveis de um conjunto de dados, mantendo o máximo possível das informações originais
- Existem várias razões pelas quais você pode querer reduzir a dimensionalidade dos dados, dentre elas destacam-se:
 - ▶ Eliminação de ruído e redundância (princípio da parcimônia);
 - ▶ Simplificação e interpretabilidade;
 - ▶ Visualização (projetar os dados em um espaço de menor dimensão).

- Na literatura, existem duas abordagens principais para a redução de dimensionalidade:
 - ▶ **Seleção de variáveis:** envolve selecionar um subconjunto das variáveis originais do conjunto de dados, consideradas as mais importantes para explicar a variabilidade nos dados;
 - ▶ **Extração de variáveis:** as variáveis originais são transformadas em um novo conjunto de variáveis, geralmente de menor dimensão, que são combinações lineares das variáveis originais, escolhidas de forma a capturar a maior parte da variabilidade nos dados.

- As abordagens de **extração de variáveis** serão o foco dos nossos estudos nessa seção e, dentre elas, vamos discutir:
 - ▶ Análise de Componentes Principais (PCA)
 - ▶ Análise de Correspondência
 - ▶ Análise Fatorial Exploratória (AFE)
 - ▶ Análise Fatorial Confirmatória (AFC)

i. Análise de Componentes Principais

- Inicialmente proposta por Karl Pearson em 1901 e estudada e nomeada por Harold Hotelling em 1933
- É uma técnica que transforma linearmente um conjunto de p variáveis correlacionadas em um conjunto de p variáveis (mesma quantidade original) não correlacionadas

- Essa transformação nos permite que, ao invés de trabalhar com p variáveis, seja possível trabalhar com somente k dessas variáveis, tal que $k < p$
- E essas k novas variáveis são capazes de explicar uma parcela substancial das informações (ou variabilidade) do conjunto original de p variáveis

- Os objetivos ao se usar a ACP, então, podem ser listados como:
 - ▶ Redução de dimensionalidade (a partir de novas variáveis que serão não correlacionadas);
 - ▶ Obter um novo conjunto de variáveis (que são combinações das variáveis originais) interpretáveis;
 - ▶ Descrever e/ou compreender a estrutura de correlação das variáveis originais.

- Qual é a ideia básica da ACP, então?

- ▶ A partir do conjunto de dados originais, aplicamos uma transformação especial (que veremos nesta seção em detalhes)
- ▶ Essa transformação fará uma rotação nos eixos originais desses dados
- ▶ Isso fará com que o primeiro eixo (primeira componente principal) nos descreva o acúmulo da maior variabilidade dos dados, o segundo eixo (segunda componente principal) nos descreva o acúmulo da segunda maior variabilidade dos dados (e, assim, sucessivamente)

- Essa transformação faz com que não seja necessário utilizar todas as variáveis originais do problema apresentado, mas somente algumas transformações (representadas pelas componentes principais) que são capazes de acumular um grande percentual da variabilidade dos dados originais

Diferença entre PCA e Análise Fatorial

- Embora ambas sejam técnicas de redução de dimensionalidade, diferem conceitualmente:
 - ▶ **PCA**: as componentes são combinações lineares das variáveis observadas — não há modelo causal. O objetivo é resumir a variabilidade.
 - ▶ **Análise Fatorial**: assume que as variáveis observadas são *causadas* por fatores latentes não observados. O objetivo é descobrir a estrutura subjacente.
- Em PCA, toda a variância é explicada (incluindo a variância específica de cada variável). Na AF, separa-se a variância comum (comunalidade) da variância específica.

- Para fazer essa transformação, considere a matriz de dados $\mathbf{X}_{p \times 1} = (\mathbf{X}_1, \dots, \mathbf{X}_p)$, cujos elementos são variáveis aleatórias de dimensão n , ou seja, a matriz $\mathbf{X}_{p \times 1}$ é dada por:

$$\mathbf{X} = [\mathbf{X}_1 \quad \mathbf{X}_2 \quad \dots \quad \mathbf{X}_p] = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix},$$

onde x_{ij} representa o valor da variável j na observação i , n é o número de observações e p é o número de variáveis

- A transformação a ser realizada nessas variáveis originais é feita de tal forma que

$$\mathbf{e}_1 = e_{11}x_1 + e_{21}x_2 + \dots + e_{n1}x_n$$

$$\mathbf{e}_2 = e_{12}x_1 + e_{22}x_2 + \dots + e_{n2}x_n$$

$$\vdots$$

$$\mathbf{e}_n = e_{1n}x_1 + e_{2n}x_2 + \dots + e_{nn}x_n,$$

tal que

$$e_{11}^2 + e_{21}^2 + \dots + e_{n1}^2 = 1$$

$$e_{12}^2 + e_{22}^2 + \dots + e_{n2}^2 = 1$$

$$\vdots$$

$$e_{1n}^2 + e_{2n}^2 + \dots + e_{nn}^2 = 1.$$

- O objetivo, portanto, é maximizar $\mathbf{e}_1$ (ou qualquer outro) de tal forma que ele tenha a maior variabilidade possível
- Falando matematicamente, estamos interessados em encontrar

$$\arg_{\mathbf{e}_1} [\max[\text{Var}(\mathbf{e}_1)]],$$

ou seja, o objetivo é encontrar o argumento que maximize $\text{Var}(\mathbf{e}_1)$, sujeito a $e_{11}^2 + e_{21}^2 + \dots + e_{n1}^2 = 1$

- Podemos reescrever a expressão interna da maximização de uma outra forma:

$$\begin{aligned}\text{Var}(\mathbf{e}_1) &= \text{Var}(e_{11}x_1 + e_{21}x_2 + \dots + e_{n1}x_n) \\ &= \mathbf{e}_1^\top \text{Var}(\mathbf{X}) \mathbf{e}_1 \\ &= \mathbf{e}_1^\top \Sigma \mathbf{e}_1,\end{aligned}$$

sendo Σ a matriz de covariância dos dados originais

- Consequentemente, o objetivo agora recai sobre o seguinte problema:

$$\arg_{\mathbf{e}_1} [\max[\mathbf{e}_1^\top \Sigma \mathbf{e}_1]],$$

sujeito a $e_{11}^2 + e_{21}^2 + \dots + e_{n1}^2 = 1$

- Agora precisamos saber que método usar para maximizar essa função

- Para maximizar uma função qualquer, temos dois caminhos muito conhecidos:
 - ▶ se o caso for unidimensional, derivamos a função com relação à variável de interesse e igualamos a zero
 - ▶ se o caso for multidimensional, derivamos com relação a cada variável e igualamos a zero (gradiente da função)
- Um outro caminho alternativo aos clássicos é utilizar os **Multiplicadores de Lagrange**

- Essa técnica é uma “sacada” dos pesquisadores para resolver problemas mais complexos, usando problemas mais simples
- A ideia considerada foi a seguinte: se temos que maximizar $f(x)$, então se maximizarmos $h(x, \lambda)$, tal que

$$h(x, \lambda) = f(x) - \sum_{i=1}^n \lambda_j (b_j - g_j(x)),$$

estaremos maximizando $f(x)$

- No contexto da ACP, onde precisamos maximizar a variabilidade para obter os vetores de componentes, a função $h(x, \lambda)$ é dada por

$$h(x, \lambda) = \mathbf{e}_1^\top \mathbf{\Sigma} \mathbf{e}_1 - \lambda(1 - e_{11}^2 - e_{21}^2 - \dots - e_{n1}^2),$$

e, assim, se calcularmos o gradiente com respeito a $\mathbf{e}_1$, estaremos encontrando os valores que maximizam $\text{Var}(\mathbf{e}_1)$

Solução via autovalores e autovetores

- Calculando o gradiente e igualando a zero, obtemos:

$$\frac{\partial h}{\partial \mathbf{e}_1} = 2\mathbf{\Sigma}\mathbf{e}_1 - 2\lambda\mathbf{e}_1 = \mathbf{0} \implies (\mathbf{\Sigma} - \lambda\mathbf{I})\mathbf{e}_1 = \mathbf{0} \quad (1)$$

- Essa é a equação característica de um problema de autovalores: λ é um autovalor de $\mathbf{\Sigma}$ e $\mathbf{e}_1$ é o autovetor associado.
- Como queremos maximizar $\text{Var}(\mathbf{e}_1) = \mathbf{e}_1^\top \mathbf{\Sigma} \mathbf{e}_1 = \lambda$, escolhemos o **maior autovalor** λ_1 e seu autovetor associado $\mathbf{e}_1$.
- As componentes principais seguintes são obtidas pelos autovalores em ordem decrescente: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$.

Variância explicada e critérios de retenção

- A proporção da variância total explicada pela k -ésima componente principal é:

$$\frac{\lambda_k}{\sum_{i=1}^p \lambda_i} \quad (2)$$

- Para decidir quantas componentes reter, os critérios mais utilizados são:
 - ▶ **Critério de Kaiser:** reter componentes com $\lambda_k > 1$ (quando os dados são padronizados)
 - ▶ **Variância acumulada:** reter componentes até atingir 70%–80% da variância total
 - ▶ **Scree plot:** gráfico dos autovalores em ordem decrescente — reter até o ponto de inflexão (cotovelo)
 - ▶ **Análise paralela:** comparar autovalores observados com autovalores de dados aleatórios

Matriz de covariância ou de correlação?

- A PCA pode ser realizada sobre a matriz de covariância Σ ou sobre a matriz de correlação $\mathbf{P}$:
 - ▶ **Matriz de covariância** (Σ): adequada quando as variáveis estão na mesma escala. Variáveis com maior variância dominarão as componentes.
 - ▶ **Matriz de correlação** ($\mathbf{P}$): equivale a padronizar as variáveis antes da PCA. Recomendada quando as variáveis têm escalas ou unidades diferentes.
- Na prática, a maioria das aplicações utiliza a matriz de correlação, pois elimina o efeito de escala.

ii. Análise de Correspondência

- É uma técnica de redução de dimensionalidade para **variáveis categóricas**, análoga à PCA para variáveis contínuas.
- Permite visualizar e explorar associações entre as categorias de duas ou mais variáveis qualitativas, representando-as graficamente em um espaço de baixa dimensão.
- O ponto de partida é sempre uma **tabela de contingência** — a estrutura de dados natural para variáveis categóricas.

- O qui-quadrado diz se há associação entre duas variáveis categóricas.
- A Análise de Correspondência diz *onde* está essa associação e *como* as categorias se relacionam.
- Categorias com perfis de distribuição similares aparecerão próximas no mapa — categorias com perfis diferentes aparecerão distantes.
- Uma categoria de linha próxima a uma categoria de coluna no mapa indica associação positiva entre elas — aquela combinação ocorre mais do que o esperado sob independência.

Tabela de contingência e perfis

- Seja $\mathbf{N}$ uma tabela de contingência $r \times c$, com elemento n_{ij} representando a frequência conjunta das categorias i e j .
- Define-se a **matriz de correspondência**:

$$\mathbf{P} = \frac{1}{n}\mathbf{N}, \quad (3)$$

em que $n = \sum_{i,j} n_{ij}$ é o total de observações.

- Os **perfis de linha** são as distribuições condicionais de cada linha:

$$p_{ij|i} = \frac{p_{ij}}{p_{i\cdot}} = \frac{n_{ij}}{n_{i\cdot}} \quad (4)$$

- Analogamente, os **perfis de coluna**: $p_{ij|j} = p_{ij}/p_{\cdot j}$.

- A **inércia total** da análise de correspondência é equivalente ao qui-quadrado padronizado:

$$\text{Inércia total} = \frac{\chi^2}{n} = \sum_{i=1}^r \sum_{j=1}^c \frac{(p_{ij} - p_{i\cdot} p_{\cdot j})^2}{p_{i\cdot} p_{\cdot j}} \quad (5)$$

- Quanto maior a inércia, maior a associação entre as variáveis.
- Assim como na PCA, a inércia é decomposta em dimensões — a primeira dimensão captura a maior parte da inércia, a segunda captura a segunda maior, e assim por diante.
- O número máximo de dimensões é $\min(r - 1, c - 1)$.

Decomposição em valores singulares

- A solução da análise de correspondência é obtida via **Decomposição em Valores Singulares (SVD)** da matriz de resíduos padronizados:

$$s_{ij} = \frac{p_{ij} - p_{i\cdot} p_{\cdot j}}{\sqrt{p_{i\cdot} p_{\cdot j}}} \quad (6)$$

- A SVD decompõe essa matriz como $\mathbf{S} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$, em que:
 - ▶ $\mathbf{D}$ contém os valores singulares $\mu_1 \geq \mu_2 \geq \dots$ — suas raízes quadradas são as inércias de cada dimensão
 - ▶ $\mathbf{U}$ e $\mathbf{V}$ fornecem as coordenadas de linhas e colunas no mapa
- A proporção da inércia explicada pela k -ésima dimensão é $\mu_k^2 / \sum_k \mu_k^2$.

Interpretação do mapa de correspondência

- O mapa de correspondência (biplot) representa simultaneamente as categorias de linha e coluna no mesmo espaço:
 - ▶ **Categorias próximas** entre si (linha-linha ou coluna-coluna): perfis similares
 - ▶ **Categoria de linha próxima a categoria de coluna**: associação positiva — coocorrem mais do que o esperado
 - ▶ **Categoria de linha distante de categoria de coluna**: coocorrem menos do que o esperado
 - ▶ **Origem do mapa**: representa o perfil médio — categorias próximas à origem têm perfis próximos da média
- A qualidade de representação de cada categoria no mapa é avaliada pelo $\cos^2$ — categorias com $\cos^2$ baixo estão mal representadas nas dimensões escolhidas.

Análise de Correspondência Múltipla (ACM)

- A **Análise de Correspondência Simples** (ACS) opera sobre tabelas de contingência com *duas* variáveis categóricas.
- A **Análise de Correspondência Múltipla** (ACM) é a extensão para três ou mais variáveis categóricas simultaneamente.
- Na ACM, constrói-se a **matriz indicadora** $\mathbf{Z}$ ($n \times \sum_k c_k$), em que cada variável é representada por variáveis dummy para suas categorias.
- A ACM aplica a análise de correspondência sobre $\mathbf{Z}^\top \mathbf{Z}$ (matriz de Burt), generalizando os resultados da ACS para múltiplas variáveis.

iii. Análise Fatorial Exploratória (AFE)

- Assim como a Análise de Componentes Principais, a **Análise Fatorial (AF)**, proposta por Charles Spearman em 1904, também é uma técnica de redução de dimensionalidade
- Objetivo: aplicar uma transformação da matriz de dados $\mathbf{X}_{p \times 1}$ de tal forma que consigamos obter fatores que carreguem a variabilidade original dos dados
- **Diferença fundamental:** os fatores, chamados de *fatores comuns*, são variáveis **latentes** — não observáveis — que se relacionam com $\mathbf{X}$ por meio de um modelo linear

O que é a AFE?

- Na **Análise Fatorial Exploratória**, não temos hipóteses prévias sobre a estrutura dos fatores.
- Deixamos os dados revelarem quantos fatores existem e quais variáveis se agrupam em cada fator.
- É utilizada nas fases iniciais de uma investigação, quando o pesquisador quer *descobrir* a estrutura latente dos dados.
- Contrasta com a AFC, onde a estrutura é *testada* a partir de uma teoria prévia — que veremos no próximo tópico.

- Os objetivos da AFE são:
 - ▶ Agrupar as variáveis originais de $\mathbf{X}_i$, $i = 1, \dots, p$, em fatores mutuamente não correlacionados e interpretáveis
 - ▶ Reduzir a dimensionalidade do problema
 - ▶ Identificar a estrutura latente subjacente aos dados sem impor restrições prévias sobre ela

AFE vs AFC — visão geral

	AFE	AFC
Objetivo	Descobrir estrutura	Testar estrutura
Hipótese prévia	Não	Sim
Cargas	Todas livres	Fixas e livres
Avaliação	Interpretação	Índices de ajuste
Fase da pesquisa	Exploratória	Confirmatória

- Sejam $\mathbf{X}_{p \times 1}$ um vetor aleatório com $\mathbb{E}(\mathbf{X}) = \boldsymbol{\mu}$, $\text{Var}(\mathbf{X}) = \boldsymbol{\Sigma}$, $\text{Cor}(\mathbf{X}) = \mathbf{P}$ e

$$Z_i = \frac{X_i - \mu_i}{\sigma_i},$$

para $i = 1, \dots, p$ tal que $\text{Cov}(\mathbf{Z}) = \mathbf{P} = \text{Cor}(\mathbf{X})$

- Queremos explicar as variáveis padronizadas $\mathbf{Z}_1, \dots, \mathbf{Z}_p$ com m fatores $\mathbf{F}_1, \dots, \mathbf{F}_m$, de tal forma que:

$$\mathbf{Z} = \mathbf{LF} + \boldsymbol{\epsilon}$$

- Essa estrutura matricial é dada, em detalhes, por

$$\begin{aligned}\mathbf{Z}_1 &= l_{11}\mathbf{F}_1 + \dots + l_{1m}\mathbf{F}_m + \epsilon_1 \\ \mathbf{Z}_2 &= l_{21}\mathbf{F}_1 + \dots + l_{2m}\mathbf{F}_m + \epsilon_2 \\ &\vdots \\ \mathbf{Z}_p &= l_{p1}\mathbf{F}_1 + \dots + l_{pm}\mathbf{F}_m + \epsilon_p,\end{aligned}$$

sendo

- ▶ $\mathbf{F}_{m \times 1}$: vetor de fatores latentes não observáveis;
- ▶ ϵ : vetor de erros aleatórios não observáveis;
- ▶ l_{ij} : carga fatorial da i -ésima variável no j -ésimo fator;
- ▶ $\mathbf{L}$: matriz de cargas fatoriais ($p \times m$).

- O modelo $\mathbf{Z} = \mathbf{LF} + \epsilon$ é chamado de modelo fatorial ortogonal, já que os m fatores são ortogonais entre si
- Essa estrutura apresenta as seguintes suposições:
 - ▶ $\mathbb{E}(\mathbf{F}) = \mathbf{0}$;
 - ▶ $\text{Var}(\mathbf{F}) = \mathbf{I}$;
 - ▶ $\mathbb{E}(\epsilon) = \mathbf{0}$;
 - ▶ $\text{Var}(\epsilon) = \mathbf{\Psi} = \text{diag}(\Psi_1, \dots, \Psi_p)$;
 - ▶ $\mathbf{F}$ e ϵ são não correlacionados.

Comunalidade e variância específica

- A variância de cada variável padronizada Z_i se decompõe em:

$$\text{Var}(Z_i) = \underbrace{\sum_{j=1}^m \beta_{ij}^2}_{h_i^2 \text{ (comunalidade)}} + \underbrace{\Psi_i}_{\text{variância específica}} = 1 \quad (7)$$

- A **comunalidade** h_i^2 representa a proporção da variância de Z_i explicada pelos fatores comuns — quanto maior, mais a variável é explicada pelo modelo.
- A **variância específica** Ψ_i é a parte da variância exclusiva de Z_i , não compartilhada com as demais variáveis.

- Para encontrar os fatores dessa transformação, a ideia é decompor a matriz $\mathbf{P}$ na forma

$$\mathbf{P} = \mathbf{L}_{p \times m} \mathbf{L}_{m \times p}^\top + \mathbf{\Psi}_{p \times p},$$

cuja representação aberta das matrizes é dada por

$$\mathbf{P} = \mathbf{L}\mathbf{L}^\top + \mathbf{\Psi} = \begin{pmatrix} \sum_{j=1}^m \ell_{1j}^2 & \cdots & \sum_{j=1}^m \ell_{1j}\ell_{jp} \\ \vdots & \ddots & \vdots \\ \sum_{j=1}^m \ell_{pj}\ell_{j1} & \cdots & \sum_{j=1}^m \ell_{pj}^2 \end{pmatrix} + \begin{pmatrix} \Psi_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \Psi_p \end{pmatrix}$$

- Pode-se estimar $\mathbf{L}$ e Ψ utilizando alguns métodos, dentre eles:
 - ▶ Método das componentes principais ou fatores principais;
 - ▶ Método das componentes principais iterativo ou fatores principais iterativo;
 - ▶ Método da máxima verossimilhança (com a suposição de normalidade).

Estimação pelo Método da Máxima Verossimilhança

- Suponha que $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e, portanto, $\mathbf{Z} \sim \mathcal{N}_p(\mathbf{0}, \mathbf{P})$. Além disso, $\mathbf{F} \sim \mathcal{N}_p(\mathbf{0}, \mathbf{I})$ e $\boldsymbol{\epsilon} \sim \mathcal{N}_p(\mathbf{0}, \boldsymbol{\Sigma})$.

- A função de verossimilhança considerando uma amostra aleatória de tamanho n , $\mathbf{Z}_1, \dots, \mathbf{Z}_n$, é expressa por

$$L(\mathbf{P}) = \frac{1}{(2\pi)^{np/2} |\mathbf{L}\mathbf{L}^\top + \mathbf{\Psi}|^{n/2}} \exp \left(-\frac{1}{2} \sum_{j=1}^n \mathbf{z}_j^\top (\mathbf{L}\mathbf{L}^\top + \mathbf{\Psi})^{-1} \mathbf{z}_j \right),$$

e devemos encontrar o máximo de $L(\mathbf{P})$ em $\mathbf{L}$ e $\mathbf{\Psi}$. Essa maximização é feita em termos numéricos para um valor de m fixo.

- Se a suposição de normalidade é válida, o método da máxima verossimilhança pode produzir estimativas mais precisas
- Se não podemos supor a normalidade multivariada, convém utilizar o método de fatores principais ou fatores principais iterativo
- A principal vantagem do método da máxima verossimilhança é a possibilidade de desenvolver **testes de hipóteses** para avaliar a adequação do modelo — o que não é possível pelo método de componentes principais

Critérios para escolha do número de fatores

- Na AFE, a escolha do número de fatores m é uma decisão central. Os critérios mais utilizados são:
 - ▶ **Análise da proporção da variância:** reter fatores que acumulem variância suficiente (tipicamente 70%–80%)
 - ▶ **Critério de Kaiser:** reter fatores com autovalor de $\mathbf{R}$ maior do que 1
 - ▶ **Scree plot:** gráfico dos autovalores em ordem decrescente — reter até o ponto de inflexão
 - ▶ **Análise paralela:** comparar autovalores observados com autovalores gerados aleatoriamente — critério mais rigoroso
- Recomenda-se usar mais de um critério e triangular a decisão com a interpretabilidade dos fatores.

Rotação Ortogonal de Fatores

- Podemos estar interessados em aplicar transformações ortogonais aos fatores originais de modo que os novos fatores obtidos tenham interpretações mais fáceis e diretas

- Graficamente, estamos interessados em fazer a seguinte rotação:




Figura 1: Representação gráfica da rotação ortogonal de fatores.

- Nesse caso, a ideia consiste em considerar a matriz $\mathbf{T}$ ortogonal tal que $\mathbf{T}\mathbf{T}^\top = \mathbf{T}^\top\mathbf{T} = \mathbf{I}$ e rotacionar a matriz de cargas fatoriais fazendo

$$\hat{\mathbf{L}}^* = \hat{\mathbf{L}}\mathbf{T},$$

note que $\hat{\mathbf{L}}^*\hat{\mathbf{L}}^{*\top} = (\hat{\mathbf{L}}\mathbf{T})(\hat{\mathbf{L}}\mathbf{T})^\top = \hat{\mathbf{L}}\hat{\mathbf{L}}^\top$

- Os critérios para rotação ortogonal de fatores mais comumente utilizados são:
 - ▶ **Varimax** (Kaiser 1958): maximiza a variabilidade das cargas fatoriais dentro de cada fator — produz fatores com algumas cargas altas e outras próximas de zero, facilitando a interpretação;
 - ▶ **Quartimax** (Jobson, 1996): maximiza a variabilidade dos quadrados das cargas sobre todos os fatores — tende a produzir um fator geral com cargas altas;
 - ▶ **Rotação oblíqua** (Oblimin, Promax): permite correlação entre os fatores — mais realista em ciências humanas e da saúde, onde fatores raramente são independentes.

- Os escores dos fatores podem ser estimados para cada observação a partir de duas estratégias:

- ▶ **Mínimos quadrados ponderados**

$$\hat{F}_j = (\hat{\mathbf{L}}^\top \mathbf{\Psi}^{-1} \hat{\mathbf{L}})^{-1} \hat{\mathbf{L}}^\top \mathbf{\Psi}^{-1} \mathbf{z}_j,$$

para $j = 1, \dots, n$.

- ▶ **Método de regressão**

$$\hat{F}_j = \hat{\mathbf{L}}^\top \hat{\mathbf{P}}^{-1} \mathbf{z}_j,$$

para $j = 1, \dots, n$.

iv. Análise Fatorial Confirmatória (AFC)

- Enquanto a AFE *descobre* a estrutura fatorial, a **AFC testa** se uma estrutura fatorial pré-definida com base em teoria é compatível com os dados observados.
- É uma aplicação de **Modelos de Equações Estruturais (SEM)** restrita ao modelo de mensuração.
- Amplamente utilizada para validação de instrumentos e escalas em pesquisas na área de saúde, psicologia e ciências sociais.

Especificação do modelo

- Na AFC, o pesquisador especifica *a priori*:
 - ▶ Quantos fatores latentes existem
 - ▶ Quais variáveis observadas são indicadores de cada fator
 - ▶ Quais cargas fatoriais são **fixadas** em zero (variável não carrega naquele fator) e quais são **livres** para estimação
 - ▶ Se os fatores são ortogonais ou oblíquos (correlacionados)
- O modelo de mensuração da AFC é dado por:

$$\mathbf{X} = \mathbf{\Lambda}\boldsymbol{\xi} + \boldsymbol{\delta}, \quad (8)$$

em que $\mathbf{\Lambda}$ é a matriz de cargas (com zeros fixados), $\boldsymbol{\xi}$ é o vetor de fatores latentes e $\boldsymbol{\delta}$ é o vetor de erros de mensuração.

- A estimação na AFC é feita minimizando a discrepância entre a **matriz de covariância observada** S e a **matriz de covariância implícita pelo modelo** $\Sigma(\theta)$:

$$F(\theta) = \min_{\theta} d[S, \Sigma(\theta)] \quad (9)$$

- O método mais utilizado é a **Máxima Verossimilhança (ML)**, que sob normalidade multivariada leva ao estimador:

$$F_{ML} = \ln |\Sigma(\theta)| - \ln |S| + \text{tr}[S\Sigma^{-1}(\theta)] - p \quad (10)$$

- Quando a normalidade não é válida, utilizam-se estimadores robustos como MLR (máxima verossimilhança robusta).

- A adequação do modelo é avaliada por um conjunto de índices de ajuste:
 - ▶ χ^2 : testa $H_0 : \Sigma = \Sigma(\theta)$. Sensível ao tamanho amostral — raramente usado isoladamente.
 - ▶ **CFI** (Comparative Fit Index): $\geq 0,95$ indica bom ajuste
 - ▶ **TLI** (Tucker-Lewis Index): $\geq 0,95$ indica bom ajuste
 - ▶ **RMSEA** (Root Mean Square Error of Approximation): $\leq 0,06$ bom; $\leq 0,08$ aceitável
 - ▶ **SRMR** (Standardized Root Mean Square Residual): $\leq 0,08$ indica bom ajuste
- Recomenda-se reportar múltiplos índices — nenhum índice isolado é suficiente.

- Após o ajuste do modelo, avalia-se a **validade de construto** em dois níveis:
 - ▶ **Validade convergente**: os indicadores de um mesmo fator devem ter cargas padronizadas altas ($\geq 0,50$). Avaliada pela Variância Média Extraída (AVE):

$$AVE = \frac{\sum_{i=1}^p \lambda_i^2}{p}, \quad AVE \geq 0,50 \quad (11)$$

- ▶ **Validade discriminante**: fatores distintos devem ser suficientemente diferentes. Critério de Fornell-Larcker: AVE de cada fator deve ser maior do que o quadrado da correlação entre fatores.

- A **confiabilidade** dos fatores é avaliada pelo **Ômega de McDonald** (ω):

$$\omega = \frac{(\sum_{i=1}^p \lambda_i)^2}{(\sum_{i=1}^p \lambda_i)^2 + \sum_{i=1}^p \Psi_i} \quad (12)$$

- $\omega \geq 0,70$ indica confiabilidade adequada.
- O ω é preferível ao α de Cronbach, pois não assume cargas iguais entre os indicadores — suposição raramente sustentada na prática.

Modificação do modelo

- Se o ajuste for inadequado, os **índices de modificação** indicam quais parâmetros fixados poderiam ser liberados para melhorar o ajuste:
 - ▶ Cada índice de modificação estima a redução no χ^2 se aquele parâmetro fosse liberado
 - ▶ Modificações devem ser guiadas pela **teoria** — não apenas pelos índices
 - ▶ Modificações puramente empíricas sem justificativa teórica invalidam o caráter confirmatório da análise
- Alternativamente, modelos concorrentes podem ser comparados via:
 - ▶ Teste $\Delta\chi^2$ (para modelos encaixados)
 - ▶ AIC e BIC (para modelos não encaixados)

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Relação entre Conjuntos de Variáveis
- 8 Técnicas de Redução de Dimensionalidade
- 9 Estruturas Latentes
- 10 Métodos de Classificação e Agrupamento**

i. Análise Discriminante L

i. Análise Discriminante Q

ii. Análise de Cluster

- As técnicas de classificação e agrupamento têm em comum o objetivo de **organizar observações em grupos**, mas diferem fundamentalmente em seu ponto de partida:
 - ▶ **Análise Discriminante**: os grupos são *conhecidos* — o objetivo é construir uma regra para classificar novas observações nesses grupos já existentes
 - ▶ **Análise de Cluster**: os grupos são *desconhecidos* — o objetivo é descobrir agrupamentos naturais nos dados sem qualquer informação prévia sobre sua estrutura
- Essa distinção é fundamental: a Análise Discriminante é **supervisionada**, enquanto a Análise de Cluster é **não supervisionada**.

i. Análise Discriminante

- Desenvolvida por Ronald Fisher em 1936, a **Análise Discriminante** é uma técnica multivariada cujo objetivo é encontrar combinações lineares das variáveis originais que melhor **separam grupos pré-definidos**.
- Tem dois propósitos principais:
 - ▶ **Descritivo**: identificar quais variáveis mais contribuem para a separação entre grupos
 - ▶ **Preditivo**: construir uma regra de classificação para alocar novas observações em um dos grupos

- Imagine que temos indivíduos classificados como *saudáveis* e *doentes*, com diversas medidas clínicas coletadas para cada um.
- A Análise Discriminante busca uma combinação linear dessas medidas — a **função discriminante** — que separe ao máximo os dois grupos.
- Essa função projetará cada indivíduo em um eixo, de forma que as distribuições dos dois grupos sejam tão separadas quanto possível.
- Um novo indivíduo será classificado no grupo cuja distribuição seja mais compatível com o seu valor projetado.

Diferença em relação à MANOVA

- **MANOVA:** testa se os grupos diferem nas variáveis dependentes — foco na inferência
- **Análise Discriminante:** dado que os grupos diferem, identifica *como* classificar novas observações e *quais* variáveis mais contribuem para a separação — foco na classificação e interpretação
- Na prática, as duas técnicas são complementares: a MANOVA precede a Análise Discriminante para confirmar que há diferença significativa entre os grupos antes de construir a regra de classificação.

- Sejam g grupos com vetores de médias $\mu_1, \dots, \mu_g$ e matriz de covariância comum Σ .
- A **função discriminante linear** de Fisher é uma combinação linear:

$$D = \mathbf{a}^\top \mathbf{X}, \quad (13)$$

em que $\mathbf{a}$ é o vetor de coeficientes discriminantes, escolhido de forma a **maximizar a razão entre a variância entre grupos e a variância dentro dos grupos**:

$$\max_{\mathbf{a}} \frac{\mathbf{a}^\top \mathbf{B} \mathbf{a}}{\mathbf{a}^\top \mathbf{W} \mathbf{a}}, \quad (14)$$

em que $\mathbf{B}$ é a matriz de variação entre grupos e $\mathbf{W}$ é a matriz de variação dentro dos grupos.

Matrizes entre e dentro dos grupos

- A **matriz de variação entre grupos** ($\mathbf{B}$) captura o quanto os centróides dos grupos diferem entre si:

$$\mathbf{B} = \sum_{k=1}^g n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})(\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top \quad (15)$$

- A **matriz de variação dentro dos grupos** ($\mathbf{W}$) captura a dispersão dentro de cada grupo:

$$\mathbf{W} = \sum_{k=1}^g \sum_{i=1}^{n_k} (\mathbf{x}_{ki} - \bar{\mathbf{x}}_k)(\mathbf{x}_{ki} - \bar{\mathbf{x}}_k)^\top \quad (16)$$

- A solução do problema de maximização é obtida via autovalores e autovetores de $\mathbf{W}^{-1}\mathbf{B}$.

Número de funções discriminantes

- O número de funções discriminantes é $r = \min(p, g - 1)$, em que p é o número de variáveis e g é o número de grupos.
- Cada função discriminante captura uma dimensão independente de separação entre os grupos:
 - ▶ A **primeira função** maximiza a separação entre grupos
 - ▶ A **segunda função** maximiza a separação residual, ortogonal à primeira
 - ▶ E assim sucessivamente
- Os autovalores $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r$ indicam a contribuição relativa de cada função para a separação total entre grupos.

Suposições da LDA

- A Análise Discriminante Linear (LDA) requer as seguintes suposições:
 - ▶ **Normalidade multivariada** dentro de cada grupo: $\mathbf{X}|G = k \sim \mathcal{N}_p(\boldsymbol{\mu}_k, \boldsymbol{\Sigma})$
 - ▶ **Homogeneidade das matrizes de covariância**: $\boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \dots = \boldsymbol{\Sigma}_g = \boldsymbol{\Sigma}$
 - ▶ **Ausência de multicolinearidade** entre as variáveis preditoras
 - ▶ **Tamanho amostral adequado**: recomenda-se ao menos 5 observações por variável em cada grupo
- O **teste M de Box** avalia a homogeneidade das matrizes de covariância. Se rejeitado, utiliza-se a Análise Discriminante Quadrática (QDA).

Análise Discriminante Quadrática (QDA)

- Quando a suposição de homogeneidade das covariâncias é violada, utiliza-se a **QDA**, que permite matrizes de covariância distintas para cada grupo.
- A regra de classificação da QDA é quadrática nas variáveis preditoras:

$$d_k(\mathbf{x}) = -\frac{1}{2} \ln |\Sigma_k| - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^\top \Sigma_k^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) + \ln \pi_k, \quad (17)$$

em que π_k é a probabilidade a priori do grupo k .

- A observação é classificada no grupo k^* que maximiza $d_k(\mathbf{x})$.
- A QDA é mais flexível, mas exige maior tamanho amostral para estimar Σ_k para cada grupo.

Regra de classificação — LDA

- Sob as suposições da LDA, a regra de classificação ótima é a **função discriminante linear de Fisher**. Para dois grupos, uma nova observação $\mathbf{x}_0$ é classificada no grupo 1 se:

$$(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)^\top \hat{\Sigma}^{-1} \mathbf{x}_0 \geq \frac{1}{2}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)^\top \hat{\Sigma}^{-1} (\bar{\mathbf{x}}_1 + \bar{\mathbf{x}}_2) - \ln \frac{\pi_1}{\pi_2}, \quad (18)$$

e no grupo 2 caso contrário.

- As **probabilidades a priori** π_k refletem o conhecimento prévio sobre a prevalência de cada grupo — quando desconhecidas, utilizam-se as proporções amostrais.

Probabilidades posteriores

- Pela regra de Bayes, a **probabilidade posterior** de uma observação pertencer ao grupo k é:

$$P(G = k|\mathbf{x}) = \frac{\pi_k f_k(\mathbf{x})}{\sum_{j=1}^g \pi_j f_j(\mathbf{x})}, \quad (19)$$

em que $f_k(\mathbf{x})$ é a densidade multivariada do grupo k .

- A classificação é feita no grupo com maior probabilidade posterior.
- As probabilidades posteriores quantificam a **incerteza** da classificação — uma observação com probabilidades próximas entre grupos está na região de ambiguidade da fronteira de decisão.

Avaliação do classificador

- A qualidade da regra de classificação é avaliada pela **matriz de confusão**:

		Predito	
		Grupo 1	Grupo 2
2*Real	Grupo 1	VP	FN
	Grupo 2	FP	VN

- As métricas derivadas incluem:
 - ▶ **Acurácia:** $(VP + VN)/n$
 - ▶ **Sensibilidade:** $VP/(VP + FN)$ — capacidade de identificar o grupo 1
 - ▶ **Especificidade:** $VN/(VN + FP)$ — capacidade de identificar o grupo 2
- A avaliação por **resubstituição** é otimista — prefere-se a **validação cruzada leave-one-out (LOO)**, que classifica cada observação com base em um modelo treinado sem ela.

Coeficientes discriminantes padronizados

- Os **coeficientes discriminantes brutos** a dependem da escala das variáveis — não são diretamente comparáveis entre si.
- Os **coeficientes discriminantes padronizados** são obtidos multiplicando cada coeficiente pelo desvio padrão da variável correspondente:

$$a_j^* = a_j \cdot s_j \quad (20)$$

- Variáveis com maior $|a_j^*|$ contribuem mais para a função discriminante — são as mais importantes para separar os grupos.
- Alternativamente, as **cargas discriminantes** (correlação entre cada variável e a função discriminante) também são utilizadas para interpretação.

ii. Análise de Cluster

- A **Análise de Cluster** (ou análise de agrupamento) é uma técnica exploratória que busca **descobrir grupos naturais** em um conjunto de dados, sem qualquer informação prévia sobre a estrutura dos grupos.
- O objetivo é organizar as observações em grupos (clusters) de forma que:
 - ▶ Observações dentro do mesmo grupo sejam o mais **similares** possível entre si
 - ▶ Observações de grupos diferentes sejam o mais **distintas** possível entre si

- Diferentemente da Análise Discriminante, aqui **não sabemos** quantos grupos existem nem a qual grupo cada observação pertence.
- O algoritmo de cluster descobre essa estrutura diretamente dos dados.
- Exemplos de aplicação:
 - ▶ Identificar subtipos de indivíduos com perfis clínicos similares
 - ▶ Segmentar clientes com comportamentos de compra parecidos
 - ▶ Descobrir padrões em dados genômicos
 - ▶ Agrupar países com indicadores econômicos semelhantes
- É uma técnica **exploratória** — os resultados dependem das escolhas metodológicas e devem ser interpretados com cautela.

Medidas de distância e similaridade

- O conceito central da análise de cluster é a **distância** (ou similaridade) entre observações. As mais utilizadas são:

- ▶ **Distância Euclidiana:**

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{(\mathbf{x}_i - \mathbf{x}_j)^\top (\mathbf{x}_i - \mathbf{x}_j)} \quad (21)$$

- ▶ **Distância de Mahalanobis** (leva em conta a correlação entre variáveis):

$$d_M(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{(\mathbf{x}_i - \mathbf{x}_j)^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \mathbf{x}_j)} \quad (22)$$

- ▶ **Distância de Manhattan:** $d(\mathbf{x}_i, \mathbf{x}_j) = \sum_{k=1}^p |x_{ik} - x_{jk}|$

- A escolha da distância afeta diretamente os clusters formados.

Padronização dos dados

- Quando as variáveis têm escalas ou unidades diferentes, a distância euclidiana será dominada pelas variáveis com maior variância.
- Por isso, é **fortemente recomendado padronizar** os dados antes de calcular as distâncias:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j} \quad (23)$$

- Após a padronização, todas as variáveis contribuem igualmente para o cálculo das distâncias.
- Alternativamente, a distância de Mahalanobis já incorpora a padronização e a correlação entre variáveis — não requer padronização prévia.

- Existem duas grandes famílias de métodos de cluster:
 - ▶ **Métodos Hierárquicos**: constroem uma sequência de agrupamentos aninhados, representada por um dendrograma. Não requerem a especificação prévia do número de clusters. Podem ser aglomerativos (de baixo para cima) ou divisivos (de cima para baixo).
 - ▶ **Métodos Não Hierárquicos** (particionais): dividem as observações em k clusters pré-especificados. O mais conhecido é o **k-means**. Requerem a especificação prévia do número de clusters k .

Cluster Hierárquico Aglomerativo

- O algoritmo hierárquico aglomerativo segue os seguintes passos:
 1. Cada observação começa como um cluster individual (n clusters)
 2. Calcula-se a matriz de distâncias entre todos os pares
 3. Une-se o par de clusters mais próximo em um único cluster
 4. Atualiza-se a matriz de distâncias
 5. Repete-se os passos 3 e 4 até restar um único cluster
- O resultado é representado por um **dendrograma** — um diagrama em árvore que mostra a sequência de fusões e as distâncias em que ocorreram.
- O número de clusters é definido pelo pesquisador ao “cortar” o dendrograma na altura desejada.

- A distância entre dois clusters pode ser calculada de diferentes formas — os chamados **métodos de ligação**:
 - ▶ **Ligação simples** (*single linkage*): distância mínima entre elementos dos dois clusters. Tende a produzir clusters alongados (efeito de encadeamento).
 - ▶ **Ligação completa** (*complete linkage*): distância máxima. Tende a produzir clusters compactos.
 - ▶ **Ligação média** (*average linkage*): média das distâncias entre todos os pares.
 - ▶ **Método de Ward**: minimiza a variância total dentro dos clusters após cada fusão — geralmente produz clusters mais homogêneos e é o mais recomendado na prática.

Cluster k-means

- O algoritmo **k-means** é o método particionai mais utilizado. Dado o número k de clusters, o algoritmo:
 1. Inicializa k centróides aleatoriamente
 2. Aloca cada observação ao cluster cujo centróide é mais próximo (distância euclidiana)
 3. Recalcula os centróides como a média das observações em cada cluster
 4. Repete os passos 2 e 3 até a convergência (sem mudança de alocação)
- O k-means minimiza a **soma dos quadrados intra-cluster** (WCSS):

$$\text{WCSS} = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} ||\mathbf{x}_i - \bar{\mathbf{x}}_k||^2 \quad (24)$$

Escolha do número de clusters k

- A escolha de k é uma das decisões mais importantes na análise de cluster. Os critérios mais utilizados são:
 - ▶ **Método do cotovelo** (*elbow method*): plota-se o WCSS em função de k e busca-se o ponto de inflexão — onde a redução do WCSS começa a diminuir expressivamente
 - ▶ **Índice de silhueta**: mede a coesão intra-cluster e a separação inter-cluster para cada observação. Valores próximos de 1 indicam boa alocação; próximos de 0 indicam ambiguidade.
 - ▶ **Gap statistic**: compara o WCSS observado com o esperado sob uma distribuição de referência uniforme
 - ▶ **Índice de Calinski-Harabasz**: razão entre a variância entre clusters e a variância dentro dos clusters

- O **índice de silhueta** de uma observação i é definido como:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \quad (25)$$

em que:

- ▶ $a(i)$: distância média de i a todas as demais observações do *mesmo* cluster (coesão)
- ▶ $b(i)$: distância média mínima de i às observações do cluster *vizinho* mais próximo (separação)
- $s(i) \in [-1, 1]$: quanto mais próximo de 1, melhor a alocação. Valores negativos indicam má alocação.
- A **silhueta média** sobre todas as observações é usada para comparar soluções com diferentes valores de k .

Coeficiente cofenético

- Para métodos hierárquicos, a qualidade do dendrograma é avaliada pelo **coeficiente de correlação cofenética**:

$$r_{\text{cof}} = \text{Cor}(d_{ij}, c_{ij}), \quad (26)$$

em que d_{ij} é a distância original entre as observações i e j , e c_{ij} é a distância cofenética (altura no dendrograma em que i e j foram unidos pela primeira vez).

- Valores próximos de 1 indicam que o dendrograma preserva bem as distâncias originais — o método de ligação escolhido é adequado.
- Recomenda-se calcular o coeficiente cofenético para diferentes métodos de ligação e escolher o que produzir o maior valor.

Validação externa dos clusters

- Quando existe um critério externo conhecido (como um diagnóstico clínico), é possível avaliar o quanto os clusters concordam com esse critério.
- O **Índice de Rand ajustado** mede a concordância entre duas partições:

$$ARI = \frac{\text{Concordâncias observadas} - \text{Concordâncias esperadas}}{\text{Concordâncias máximas} - \text{Concordâncias esperadas}} \quad (27)$$

- $ARI = 1$: concordância perfeita. $ARI = 0$: concordância aleatória.
- A validação externa é importante para verificar se os clusters descobertos têm correspondência com estruturas reais conhecidas — sem que essa informação tenha sido usada na formação dos grupos.

Interpretação dos clusters

- Após definir os clusters, é essencial **caracterizá-los** para que façam sentido substantivo:
 - ▶ **Centróides**: os valores médios de cada variável em cada cluster revelam o perfil típico de cada grupo
 - ▶ **Boxplots por cluster**: mostram a distribuição de cada variável em cada grupo e facilitam a comparação
 - ▶ **Testes de diferença**: ANOVA ou Kruskal-Wallis para variáveis contínuas; qui-quadrado para variáveis categóricas — verificam se os clusters diferem significativamente nas variáveis de interesse
 - ▶ **Biplot no espaço PCA**: projeta as observações e os centróides dos clusters nas duas primeiras componentes principais, facilitando a visualização

Limitações da Análise de Cluster

- A Análise de Cluster é uma ferramenta exploratória poderosa, mas apresenta limitações importantes:
 - ▶ **Subjetividade:** a escolha do método de ligação, da medida de distância e do número de clusters afeta diretamente os resultados
 - ▶ **Sensibilidade a outliers:** observações atípicas podem distorcer os clusters, especialmente no k-means
 - ▶ **Ausência de teste formal:** não há um teste estatístico que confirme se os clusters encontrados são “reais” ou produto do acaso
 - ▶ **Reprodutibilidade:** o k-means depende da inicialização aleatória dos centróides — diferentes inicializações podem levar a soluções diferentes
- Recomenda-se usar múltiplos métodos e verificar a estabilidade dos resultados.

Obrigado

vinicius@osterne.com



www.viniciusosterne.com