

Estatística Multivariada


Vinícius Osterne, PhD

vinicius@osterne.com

| www.viniciusosterne.com

Linha do tempo da disciplina

progressão lógica do curso →



Cronograma das aulas

- **Encontro 1:** Introdução · Conceitos Prévios · Álgebra Linear · Análise Exploratória
- **Encontro 2:** Probabilidade · Inferência (testes de hipóteses, T^2 de Hotelling, MANOVA)
- **Encontro 3:** Modelos Multivariados (regressão, regressão canônica, análise de correlação)
- **Encontro 4:** Estrutura dos Dados (análise de componentes principais, análise fatorial)
- **Encontro 5:** Técnicas de Classificação e Agrupamento (clustering)
- **Encontro 6:** Apresentação dos Trabalhos

Apresentação dos trabalhos

- Cada aluno realizará uma **apresentação individual** ao longo do encontro 6
- **Duração:** 20 minutos por apresentação
- **Tema:** livre, desde que esteja relacionado a algum dos tópicos abordados ao longo do curso
- **Definição do tema:** o tema deverá ser comunicado ao professor com **uma semana de antecedência** em relação ao encontro 6, após a cobertura do conteúdo que o fundamenta
- **Recomendação:** escolha um tema que tenha despertado interesse durante o curso e aplique-o a dados reais da sua área de atuação (ou a que preferir)

Sobre o seu professor :)

Formação

- ▶ Estatístico, Mestre e Doutor
- ▶ Pós-doutorando em modelagem multimodal para detecção de diabetes

Atuação acadêmica

- ▶ *Jefe de Trabajos Prácticos*: Instituto de Cálculo, Universidad de Buenos Aires (UBA)
- ▶ Pesquisador na Universidade Federal do Ceará, Université de Bordeaux e UBA
- ▶ Professor da PUC Minas

Atuação profissional

- ▶ CEO da Vixe (consultoria, treinamentos e cursos online)
- ▶ Data Science Leader: Laboratório de Políticas Públicas do Governo do Estado do Ceará

Minha segunda vida:

- ▶ Bailarino profissional de tango

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Modelos Multivariados
- 8 Estrutura dos Dados
- 9 Técnicas de Classificação e Agrupamento

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Modelos Multivariados
- 8 Estrutura dos Dados
- 9 Técnicas de Classificação e Agrupamento

Definições

- A **estatística multivariada** é um ramo da estatística que lida com a análise simultânea de duas ou mais variáveis
- Ao contrário da estatística **univariada**, que se concentra em **uma única variável**, a estatística multivariada examina **as relações entre múltiplas variáveis**
- Os métodos da estatística multivariada são utilizados em diversas áreas, como **ciências sociais, biologia, economia, engenharia, entre outras**

Objetivos

- A estatística multivariada tem vários objetivos importantes, dentre os quais destacamos:
 - ▶ **Análise de correlação e covariância:** permite estudar as relações entre várias variáveis simultaneamente
 - ▶ **Redução de dimensionalidade:** oferece técnicas, como a análise de componentes principais (PCA), para reduzir a dimensão dos dados, mantendo a maior parte da informação
 - ▶ **Classificação e agrupamento:** ajuda a classificar e agrupar observações com base em múltiplas variáveis
 - ▶ **Modelagem preditiva:** modelos multivariados, como regressão múltipla, permitem prever uma variável com base em outras variáveis independentes

- É aplicada em diversas áreas para entender relações complexas entre várias variáveis:
 - ▶ **Análise descritiva multivariada:** imagine mapear como diferentes estados do Brasil são percebidos com base em várias características; isso envolve análise multivariada para entender as distâncias entre os estados e suas similaridades
 - ▶ **Análise de componentes principais:** esse método reduz a dimensionalidade dos dados, identificando combinações lineares das variáveis originais; por exemplo, um banco pode usá-lo para avaliar candidatos a empréstimos com base em renda, escolaridade, idade, entre outras variáveis
 - ▶ **Análise de correspondência:** verifica associações entre variáveis categóricas por meio de tabelas de contingência; por exemplo, explorar como diferentes categorias de acidentes de trânsito se relacionam

- ▶ **Análise de cluster:** agrupa observações com base em múltiplas variáveis; por exemplo, segmentar clientes com base em seus comportamentos de compra
 - ▶ **Análise de regressão múltipla:** modela a relação entre uma variável dependente e várias variáveis independentes; é útil para previsões financeiras ou de mercado
 - ▶ **Modelagem de equações estruturais:** explora relações complexas entre variáveis latentes em um modelo; amplamente utilizada em pesquisa de marketing e psicologia
- Esses são **apenas alguns exemplos**; como veremos no decorrer do curso, a estatística multivariada é amplamente aplicada em muitos campos para obter insights valiosos e embasar decisões

Conhecimentos de base recomendados

- Para estudar estatística multivariada, é útil ter uma compreensão sólida dos seguintes conceitos:
 - ▶ **Análise exploratória:** medidas como **média**, **mediana**, **desvio padrão** e **gráficos** para resumir e visualizar dados
 - ▶ **Probabilidade e distribuições:** conceitos de probabilidade e distribuições de probabilidade
 - ▶ **Álgebra linear:** **vetores**, **matrizes**, **espaços vetoriais** e **operações matriciais**
 - ▶ **Inferência estatística:** **testes de hipóteses**, **intervalos de confiança** e **regressão**
 - ▶ **Análise de variância (ANOVA):** comparação de médias entre grupos
 - ▶ **Cálculo:** derivadas e integrais, usados em técnicas como a regressão múltipla

- Lembre-se de que a estatística multivariada é uma área ampla e interdisciplinar
- Estar familiarizado com os conceitos básicos apresentados anteriormente ajudará você a explorar análises cada vez mais avançadas ao longo do curso!

Sumário

- 1 Introdução
- 2 Conceitos Prévios**
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Modelos Multivariados
- 8 Estrutura dos Dados
- 9 Técnicas de Classificação e Agrupamento



Tipos de variáveis

Prof. Vinícius Osterne, PhD

Tipos de variáveis

- As variáveis podem ser classificadas em dois grandes grupos:
 - ▶ **Quantitativas:** assumem valores numéricos com sentido aritmético
 - ▶ **Qualitativas (categóricas):** representam categorias ou atributos

Tipos de variáveis: detalhamento

- **As variáveis quantitativas se subdividem em:**
 - ▶ **Contínuas:** podem assumir qualquer valor em um intervalo (ex.: altura, temperatura, salário)
 - ▶ **Discretas:** assumem valores inteiros e contáveis (ex.: número de filhos, contagem de defeitos)
- **As variáveis qualitativas se subdividem em:**
 - ▶ **Nominais:** categorias sem ordem natural (ex.: gênero, cor dos olhos, estado civil)
 - ▶ **Ordinais:** categorias com ordem definida (ex.: grau de instrução, nível de satisfação)
- **Atenção:** variáveis qualitativas frequentemente são codificadas numericamente para a análise (ex.: variáveis *dummy* 0/1), mas isso não as torna quantitativas



Dados transversais vs. Dados longitudinais

Prof. Vinícius Osterne, PhD

Dados transversais vs. longitudinais

- A estrutura temporal da coleta dos dados afeta diretamente a forma da matriz $\mathbf{X}$ e as técnicas adequadas de análise
- **Dados transversais (*cross-sectional*)**: cada **unidade amostral** é observada em um único momento; as linhas da matriz $\mathbf{X}$ representam diferentes indivíduos
- **Dados longitudinais (ou de painel)**: o mesmo conjunto de indivíduos é medido em múltiplos instantes de tempo; cada indivíduo gera várias linhas na matriz de dados

Dados transversais vs. longitudinais: exemplo

- Suponha que medimos renda (X_1) e escolaridade (X_2) de n pessoas:

Transversal: n linhas

dados de n pessoas em 2024

Pessoa	X_1 (renda)	X_2 (escol.)
$i = 1$	3.200	12
$i = 2$	5.100	16
$i = 3$	4.800	14

Longitudinal: $5n$ linhas

as mesmas n pessoas, 2020 - 2024

Pessoa	Ano	X_1	X_2
$i = 1$	2020	2.800	12
$i = 1$	2024	3.200	12
$i = 2$	2020	4.500	16
$i = 2$	2024	5.100	17

Dados transversais vs. longitudinais: uma analogia

Dados transversais



Uma fotografia

Captura o estado de cada indivíduo em um único instante


Dados longitudinais



Um vídeo

Registra o comportamento de cada indivíduo ao longo do tempo

Analogia sugerida pelo Prof. Juvêncio Santos Nobre (UFC).



Vetor aleatório

Prof. Vinícius Osterne, PhD

Vetor aleatório

- Um **vetor aleatório** é uma **coleção ordenada de variáveis aleatórias**, denotado por


$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix},$$

onde cada X_j é uma variável aleatória

- É a **extensão natural do conceito de variável aleatória escalar para o caso multidimensional**

Abrindo a matriz $\mathbf{X}$

- Cada linha da matriz $\mathbf{X}$ é a realização de um vetor aleatório $\mathbf{X}^{(i)\top}$:



Vetor aleatório vs. vetor de observações

- É importante distinguir dois objetos:
 - ▶ **Vetor aleatório $\mathbf{X}$** : representa o mecanismo gerador dos dados; seus elementos são variáveis aleatórias com uma distribuição conjunta
 - ▶ **Vetor de observação $\mathbf{x}_i$** : é uma *realização* do vetor aleatório para o i -ésimo indivíduo, ou seja, um conjunto de valores concretos observados
- Exemplo: $\mathbf{X} = (X_{\text{altura}}, X_{\text{peso}})^T$ é o vetor aleatório; $\mathbf{x}_1 = (1,72 \text{ m}, 68 \text{ kg})^T$ é uma observação



Matriz de dados X

Prof. Vinícius Osterne, PhD

A matriz de dados X

- A organização dos dados multivariados é feita com o auxílio de vetores e matrizes
- Nessas matrizes, as **colunas** representam as variáveis (características medidas) e as **linhas** representam as unidades amostrais (indivíduos observados)

A matriz de dados $\mathbf{X}$: notação formal

- Sejam $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_p$ variáveis aleatórias. Denotamos por $\mathbf{X}$ a matriz que as organiza:

$$\mathbf{X} = [\mathbf{X}_1 \quad \mathbf{X}_2 \quad \dots \quad \mathbf{X}_p] = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix},$$

onde x_{ij} representa o valor da variável j na observação i , n é o número de observações e p é o número de variáveis

A matriz de dados $\mathbf{X}$: exemplo

- Por exemplo, podemos ter uma matriz $\mathbf{X}$ com as variáveis idade (X_1) e gênero (X_2):

$$\mathbf{X} = [\mathbf{X}_1 \quad \mathbf{X}_2] = \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ \vdots & \vdots \\ x_{n1} & x_{n2} \end{bmatrix} = \begin{bmatrix} 23 & F \\ 67 & M \\ \vdots & \vdots \\ 38 & F \end{bmatrix},$$

onde F indica sexo feminino e M indica sexo masculino



Espaço amostral multivariado


Prof. Vinícius Osterne, PhD

Espaço amostral multivariado

- Cada observação $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip})^\top$ pode ser vista como um **ponto no espaço** $\mathbb{R}^p$
- O conjunto de todas as n observações forma uma **nuvem de pontos** nesse espaço
- A posição e a forma dessa nuvem revelam informações sobre a distribuição conjunta das variáveis: espalhamento, correlação, grupos naturais e observações atípicas


Espaço amostral multivariado: $p = 2$

Para $p = 2$, cada observação $\mathbf{x}_i = (x_{i1}, x_{i2})^\top$ é um ponto no plano $\mathbb{R}^2$:
a nuvem de pontos é simplesmente um **gráfico de dispersão**:



Espaço amostral multivariado: $p = 3$

Para $p = 3$, ainda conseguimos visualizar os pontos em $\mathbb{R}^3$:



Espaço amostral multivariado: $p > 3$

- Para $p > 3$, a visualização direta se torna impossível: os dados habitam um espaço que não conseguimos enxergar
- Por isso, técnicas como a **Análise de Componentes Principais (PCA)** buscam **projetar** os dados em dimensões menores sem perder muita informação
- A **geometria da nuvem de pontos** (sua posição, forma e espalhamento em $\mathbb{R}^p$) é o ponto de partida conceitual para quase todos os métodos multivariados que estudaremos nesta disciplina



Maldição da dimensionalidade

Prof. Vinícius Osterne, PhD

Maldição da dimensionalidade

- À medida que o número de variáveis p cresce, surgem problemas que não existem no caso univariado
- Fenômeno chamado de **maldição da dimensionalidade** (*curse of dimensionality*)


Maldição da dimensionalidade: principais consequências

- **Dados cada vez mais esparsos:** o volume do espaço $\mathbb{R}^p$ cresce exponencialmente com p (para cobrir o espaço com a mesma densidade, precisaríamos de amostras exponencialmente maiores)
- **Distâncias perdem significado:** em dimensões altas, qualquer par de pontos tende a ficar aproximadamente à mesma distância (a diferença entre “vizinho próximo” e “vizinho distante” desaparece, o que compromete métodos baseados em distância, como k-NN, clustering, etc.)
- **Estimação se torna inviável:** estimar a distribuição conjunta de p variáveis requer amostras que crescem exponencialmente com p (na prática, nunca temos dados suficientes)

Maldição da dimensionalidade: distâncias perdem significado


À medida que p cresce, todos os pontos tendem a ficar **igualmente distantes** entre si:

$p = 1 (\mathbb{R}^1)$




Distâncias **variam muito**:
há pares próximos e distantes

$p = 2 (\mathbb{R}^2)$



Distâncias ainda **variam**:
pares próximos existem

$p \gg 3 (\mathbb{R}^p)$



Distâncias **convergem**:
todos igualmente distantes

Por que as distâncias convergem?

- A **distância euclidiana** entre dois pontos em $\mathbb{R}^p$ é:

$$d = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}$$

- Com p grande, essa soma tem muitos termos: pela **Lei dos Grandes Números**, ela converge para seu valor esperado
- **Consequência**: todas as distâncias convergem para a **mesma constante** e a **variação** entre elas desaparece proporcionalmente

Lei dos Grandes Números: intuição (I)

- Se $Z_1, Z_2, \dots, Z_p$ são variáveis aleatórias independentes com média μ , então:

$$\frac{1}{p} \sum_{j=1}^p Z_j \xrightarrow{p \rightarrow \infty} \mu$$

- A variabilidade relativa da soma desaparece conforme p cresce: o resultado converge para um valor fixo e previsível
- Analogia:** jogar um dado poucas vezes gera resultados muito variáveis; jogar milhares de vezes faz a média convergir inevitavelmente para 3,5

Lei dos Grandes Números: intuição (II)

- **Aplicação às distâncias:** cada termo $(x_j - y_j)^2$ se comporta como uma variável aleatória com média μ
- Com p grande, a soma converge:

$$\sum_{j=1}^p (x_j - y_j)^2 \approx p \cdot \mu$$

- Essa aproximação vale para **qualquer** par de pontos: daí todas as distâncias convergirem para o mesmo valor
- É exatamente esse nivelamento que faz o conceito de **proximidade perder o sentido** em dimensões altas

Por que as distâncias convergem?

- Formalmente, o que desaparece é a **variação relativa** entre distâncias:


$$\frac{d_{\max} - d_{\min}}{d_{\min}} \rightarrow 0 \quad \text{quando } p \rightarrow \infty$$

- Exemplo numérico:**

- ▶ Em $p = 2$: vizinhos podem estar a distâncias 0,1 e 1,4 (razão de $14\times$)
 - ▶ Em $p = 1000$: todos ficam entre 12,3 e 12,5 (praticamente **indistinguíveis**)
- O conceito de “vizinho mais próximo” perde o sentido e, com ele, todos os métodos baseados em distância (k-NN, clustering, kernels)

Maldição da dimensionalidade: esparsidade (p pequeno)


- Com p pequeno, n observações **cobrem bem** o espaço
- Os pontos são **próximos** entre si: vizinhos existem de verdade
- Estimativas locais (**médias**, **densidades**) são **confiáveis**



$$p = 2, \quad n = 25$$

Maldição da dimensionalidade: esparsidade (p grande)

- Com p grande, os **mesmos n pontos** precisam cobrir um espaço imensamente maior
- Os pontos ficam **isolados**: não há vizinhos reais
- Estimativas locais tornam-se **não confiáveis** ou impossíveis



$p = 100, n = 25$

Maldição da dimensionalidade: implicações práticas

- Isso significa que:
 - ▶ Ter muitas variáveis (p grande) não é sempre vantajoso: pode prejudicar modelos e aumentar o custo computacional
 - ▶ É importante **selecionar** ou **reduzir** as variáveis antes de aplicar técnicas multivariadas
 - ▶ Técnicas como PCA, análise fatorial e seleção de variáveis existem, em parte, para mitigar esse problema
- Uma regra prática comum é ter ao menos $n \geq 10p$ observações para análises multivariadas confiáveis



Dados faltantes

Prof. Vinícius Osterne, PhD

Dados faltantes (*missing values*)

- Na prática, a matriz de dados X pode estar está completa: algumas entradas x_{ij} podem ser desconhecidas
- Os dados faltantes surgem por diversas razões: recusa em responder, falha de equipamento, perda de registros, entre outros
- Ignorar os dados faltantes sem tratamento adequado pode introduzir **viés** nas análises e reduzir o poder estatístico

Dados faltantes: por que ignorar é um problema?

Viés nas estimativas

- Se os dados não faltam aleatoriamente, a amostra restante **não representa** mais a população
- **Exemplo**: em uma pesquisa de saúde, pacientes com quadros mais graves tendem a **abandonar o estudo** (a média de melhora estimada fica **superestimada**)
- O modelo aprende um padrão **distorcido** da realidade

Perda de poder estatístico

- Ao excluir observações com dados faltantes, reduzimos o n efetivo
- Intervalos de confiança ficam **mais largos** e testes menos sensíveis
- Em dados multivariados, a perda é **amplificada**: basta **um** valor faltante numa linha para descartar o indivíduo inteiro

A forma como os dados faltam importa tanto quanto a quantidade que falta.

Estratégias para dados faltantes

- As principais abordagens são:
 - ▶ **Remoção (*listwise deletion*)**: excluir toda a linha que contenha ao menos um valor faltante; simples, mas pode desperdiçar muita informação
 - ▶ **Imputação pela média/mediana**: substituir o valor faltante pela média ou mediana da variável; fácil de implementar, mas subestima a variabilidade
 - ▶ **Imputação múltipla**: gerar várias versões plausíveis do conjunto de dados e combiná-las; método mais robusto e recomendado na prática
- A escolha da estratégia depende do mecanismo de geração dos dados faltantes e do percentual de *missings*



Por que a escala dos dados importa?

Prof. Vinícius Osterne, PhD

Por que a escala importa?

- Variáveis medidas em escalas muito diferentes podem distorcer análises multivariadas
- Exemplo: se X_1 é salário (ordem de grandeza 10^3) e X_2 é idade (ordem de grandeza 10^1), a variável salário **dominará** qualquer medida baseada em distâncias ou variâncias
- Portanto, antes de aplicar muitos métodos multivariados, é necessário **padronizar** ou **normalizar** as variáveis

Métodos de padronização

- **Padronização Z-score:** transforma cada variável para ter média zero e desvio padrão um:


$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j},$$

onde $\bar{x}_j$ é a média amostral e s_j é o desvio padrão amostral da variável j

- **Normalização Min-Max:** reescala os valores para o intervalo $[0, 1]$:

$$z_{ij} = \frac{x_{ij} - \min_j}{\max_j - \min_j}$$

- A padronização **Z-score** é a mais utilizada em estatística multivariada, pois torna a matriz de covariância equivalente à matriz de correlação



Aprendizado estatístico vs. Aprendizado de máquina

Prof. Vinícius Osterne, PhD

Aprendizado estatístico vs. aprendizado de máquina

Aprendizado estatístico

- Foco em **inferência**: entender a relação entre variáveis
- Modelos **interpretáveis**, baseados em suposições sobre a distribuição dos dados
- Interesse em **incerteza**: intervalos de confiança, testes de hipótese
- Pergunta central: *por quê?*

Aprendizado de máquina

- Foco em **predição**: maximizar a acurácia em dados novos
- Modelos **flexíveis**, muitas vezes caixas-pretas, com poucas suposições
- Interesse em **generalização**: desempenho fora da amostra
- Pergunta central: *o quê?*

Na prática, as fronteiras são tênues: os métodos que estudaremos transitam entre as duas abordagens.

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear**
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Modelos Multivariados
- 8 Estrutura dos Dados
- 9 Técnicas de Classificação e Agrupamento



Escalares

Prof. Vinícius Osterne, PhD

- Um **escalar** é um único número real, denotado por letras minúsculas não-negritadas:
 $a, b, c \in \mathbb{R}$
- Exemplos no contexto multivariado:
 - ▶ A altura de um indivíduo: $x_{11} = 1,72$
 - ▶ O número de observações: $n = 150$
 - ▶ O número de variáveis: $p = 5$
- Escalares são o caso mais simples; vetores e matrizes generalizam esse conceito para múltiplas dimensões



Vetores

Prof. Vinícius Osterne, PhD

Vetores

- Um **vetor** é uma lista ordenada de escalares
- Usaremos sempre **vetores coluna**, denotados por letras minúsculas em negrito:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^p$$

- Cada x_j é um **elemento** (ou componente) do vetor
- O **vetor transposto** $\mathbf{x}^\top = [x_1 \ x_2 \ \cdots \ x_p]$ é um vetor linha

Vetores: exemplo

- Suponha que medimos três características de um indivíduo: altura (1,72 m), peso (68 kg) e idade (34 anos)
- Organizamos essas medidas em um vetor coluna:

$$\mathbf{x} = \begin{bmatrix} 1,72 \\ 68 \\ 34 \end{bmatrix} \in \mathbb{R}^3$$

- Sua transposta é o vetor linha:

$$\mathbf{x}^T = [1,72 \quad 68 \quad 34]$$

- Cada linha da matriz de dados $\mathbf{X}$ é exatamente um vetor desse tipo (uma observação multivariada)



Produto interno

Prof. Vinícius Osterne, PhD

- O **produto interno** (ou produto escalar) entre dois vetores $\mathbf{x}, \mathbf{y} \in \mathbb{R}^p$ é definido como

$$\langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^\top \mathbf{y} = \sum_{j=1}^p x_j y_j$$

- O resultado é sempre um **escalar**
- **Conexão estatística:** a covariância amostral entre duas variáveis pode ser escrita como um produto interno dos vetores centrados (veremos isso nas próximas aulas)

Produto interno: exemplo

- Sejam os vetores $\mathbf{x} = (1, 2, 3)^\top$ e $\mathbf{y} = (4, 0, -1)^\top$:

$$\mathbf{x}^\top \mathbf{y} = 1 \cdot 4 + 2 \cdot 0 + 3 \cdot (-1) = 4 + 0 - 3 = 1$$

- Agora, $\mathbf{x} = (1, 2, 3)^\top$ e $\mathbf{z} = (2, 4, 6)^\top$:

$$\mathbf{x}^\top \mathbf{z} = 1 \cdot 2 + 2 \cdot 4 + 3 \cdot 6 = 2 + 8 + 18 = 28$$

- Note que $\mathbf{z} = 2\mathbf{x}$ (vetores paralelos têm produto interno grande)
- Intuição:** o produto interno é grande quando os dois vetores “apontam na mesma direção” e pequeno (ou zero) quando são perpendiculares

Produto interno: para que serve?

- **Medir similaridade entre observações:** o produto interno entre dois vetores de dados indica o quanto duas observações “se parecem” em direção e magnitude
- **Calcular projeções:** a projeção de $\mathbf{x}$ na direção de $\mathbf{y}$ é dada por $\frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{y}\|}$, operação central em métodos como PCA e regressão

- **Expressar covariâncias:** a covariância amostral entre duas variáveis centradas $\tilde{\mathbf{x}}$ e $\tilde{\mathbf{y}}$ é simplesmente:

$$s_{xy} = \frac{1}{n-1} \tilde{\mathbf{x}}^\top \tilde{\mathbf{y}}$$

- **Definir distâncias:** a norma euclidiana (e portanto a distância) vem do produto interno:
 $\|\mathbf{x}\| = \sqrt{\mathbf{x}^\top \mathbf{x}}$

O produto interno é a operação fundamental por trás de quase todos os métodos multivariados que estudaremos.



Norma

Prof. Vinícius Osterne, PhD

Norma de um vetor

- A **norma euclidiana** (comprimento) de um vetor $\mathbf{x} \in \mathbb{R}^p$ é

$$\|\mathbf{x}\| = \sqrt{\mathbf{x}^\top \mathbf{x}} = \sqrt{\sum_{j=1}^p x_j^2}$$

- Um vetor com $\|\mathbf{x}\| = 1$ é chamado **vetor unitário**
- A **distância euclidiana** entre dois pontos $\mathbf{x}$ e $\mathbf{y}$ é

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\| = \sqrt{\sum_{j=1}^p (x_j - y_j)^2}$$

- **Limitação importante:** essa distância trata todas as variáveis como igualmente relevantes e independentes (motivação para a distância de Mahalanobis)

Norma e distância euclidiana: exemplo

- Dois indivíduos com medidas (altura em m, peso em kg):

$$\mathbf{x}_1 = \begin{bmatrix} 1,70 \\ 70 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 1,75 \\ 71 \end{bmatrix}$$

- Distância euclidiana:

$$d(\mathbf{x}_1, \mathbf{x}_2) = \sqrt{(1,75 - 1,70)^2 + (71 - 70)^2} = \sqrt{0,0025 + 1} \approx 1,001$$

- O peso domina completamente o cálculo por estar em escala maior
- Conclusão:** sem padronização, variáveis em escalas diferentes distorcem qualquer medida de distância (retomamos esse problema com a distância de Mahalanobis)



Ângulo entre vetores

Prof. Vinícius Osterne, PhD

Ângulo entre vetores e ortogonalidade

- O produto interno está ligado ao **ângulo** θ entre dois vetores:


$$\cos \theta = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}$$

- Dois vetores são **ortogonais** quando $\mathbf{x}^\top \mathbf{y} = 0$, isto é, $\theta = 90^\circ$
- **Conexão com correlação:** se centrarmos as colunas da matriz $\mathbf{X}$, a correlação entre duas variáveis é exatamente o cosseno do ângulo entre seus vetores coluna:
 - ▶ Correlação = 1: vetores paralelos ($\theta = 0^\circ$)
 - ▶ Correlação = 0: vetores ortogonais ($\theta = 90^\circ$)
 - ▶ Correlação = -1: vetores antiparalelos ($\theta = 180^\circ$)

Ângulo entre vetores e correlação

Correlação = 1


$$\theta = 0^\circ$$



Vetores **paralelos**:
apontam na mesma direção

Correlação = 0


$$\theta = 90^\circ$$



Vetores **ortogonais**:
nenhuma direção em comum

Correlação = -1

$$\theta = 180^\circ$$



Vetores **antiparalelos**:
direções opostas

$$\cos \theta = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}$$

(a correlação é o cosseno do ângulo entre os vetores centrados)

Ângulo entre vetores: exemplo

- Sejam $\mathbf{u} = (1, 0)^\top$ e $\mathbf{v} = (1, 1)^\top$:

$$\cos \theta = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} = \frac{1 \cdot 1 + 0 \cdot 1}{\sqrt{1} \cdot \sqrt{2}} = \frac{1}{\sqrt{2}} \approx 0,707 \implies \theta = 45^\circ$$

- Agora, $\mathbf{u} = (1, 0)^\top$ e $\mathbf{w} = (0, 1)^\top$:

$$\cos \theta = \frac{1 \cdot 0 + 0 \cdot 1}{\sqrt{1} \cdot \sqrt{1}} = 0 \implies \theta = 90^\circ \quad (\text{ortogonais})$$

- Interpretação:** $\mathbf{u}$ e $\mathbf{w}$ são ortogonais (representam variáveis com correlação zero; $\mathbf{u}$ e $\mathbf{v}$ compartilham parte da mesma direção) correlação positiva



Projeção ortogonal

Prof. Vinícius Osterne, PhD

Projeção ortogonal

- A **projeção** de $\mathbf{x}$ sobre a direção de $\mathbf{y}$ é o vetor

$$\text{proj}_{\mathbf{y}} \mathbf{x} = \frac{\mathbf{x}^{\top} \mathbf{y}}{\|\mathbf{y}\|^2} \mathbf{y}$$


- Geometricamente: é a “sombra” de $\mathbf{x}$ sobre a reta definida por $\mathbf{y}$

Projeção ortogonal

- A **projeção** de $\mathbf{x}$ sobre a direção de $\mathbf{y}$ é o vetor:

$$\text{proj}_{\mathbf{y}} \mathbf{x} = \frac{\mathbf{x}^{\top} \mathbf{y}}{\|\mathbf{y}\|^2} \mathbf{y}$$

- Geometricamente: é a “sombra” de $\mathbf{x}$ sobre a reta definida por $\mathbf{y}$



Por que isso importa?


- A **Análise de Componentes Principais (PCA)** é geometricamente uma sequência de projeções: encontramos as direções (componentes) que maximizam a variância projetada dos dados
- Sempre que trabalharmos com combinações lineares de variáveis, estaremos fazendo projeções

Projeção ortogonal: exemplo

- Sejam $\mathbf{x} = (3, 4)^\top$ e $\mathbf{y} = (1, 0)^\top$ (eixo horizontal):

$$\text{proj}_{\mathbf{y}} \mathbf{x} = \frac{3}{1} \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}$$

- A projeção é simplesmente a componente horizontal de $\mathbf{x}$
- Intuição para PCA:** cada componente principal é uma direção $\mathbf{y}$; a projeção é o **escore** do componente





Matrizes

Prof. Vinícius Osterne, PhD

Matrizes

- Uma **matriz** é uma tabela retangular de escalares organizada em linhas e colunas, denotada por letras maiúsculas em negrito:

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1q} \\ a_{21} & a_{22} & \cdots & a_{2q} \\ \vdots & \vdots & \ddots & \vdots \\ a_{p1} & a_{p2} & \cdots & a_{pq} \end{bmatrix} \in \mathbb{R}^{p \times q}$$

- p é o número de **linhas** e q é o número de **colunas**; dizemos que $\mathbf{A}$ é uma matriz $p \times q$
- O elemento a_{ij} está na linha i e coluna j
- Um vetor coluna é um caso especial: matriz $p \times 1$

Matrizes: exemplo

- Suponha $n = 4$ indivíduos e $p = 3$ variáveis (altura, peso, idade). A matriz de dados $\mathbf{X} \in \mathbb{R}^{4 \times 3}$ é:

$$\mathbf{X} = \begin{bmatrix} 1,72 & 68 & 34 \\ 1,65 & 55 & 28 \\ 1,80 & 82 & 45 \\ 1,58 & 61 & 52 \end{bmatrix}$$

- Cada **linha** é um indivíduo; cada **coluna** é uma variável
- O elemento $x_{32} = 82$ indica o peso (variável 2) do terceiro indivíduo
- O elemento x_{14} não existe: a matriz tem apenas 3 colunas

Convenções de notação

- Adotaremos as seguintes convenções ao longo do curso:
 - ▶ **Escalares:** letras minúsculas não-negritadas (a, x_{ij}, n, p)
 - ▶ **Vetores:** letras minúsculas em negrito ($\mathbf{x}, \mathbf{y}, \boldsymbol{\mu}$)
 - ▶ **Matrizes:** letras maiúsculas em negrito ($\mathbf{X}, \mathbf{S}, \boldsymbol{\Sigma}$)
- A **transposta** de $\mathbf{A}$ é denotada por $\mathbf{A}^\top$: troca linhas por colunas

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}_{3 \times 2} \implies \mathbf{A}^\top = \begin{bmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{bmatrix}_{2 \times 3}$$

- **Atenção:** $(\mathbf{A}^\top)^\top = \mathbf{A}$ e $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$

Matrizes: muito além de tabelas

- No nosso nível, não podemos enxergar uma matriz apenas como uma organização tabular de números
- Uma matriz é a representação de uma **transformação linear**
- O termo *matrix* vem do latim *mater* (mãe) e era sinônimo de útero na Idade Média: aquilo que **gera**, que **transforma**

Matrizes: muito além de tabelas

- Dado um vetor de entrada $\mathbf{x} \in \mathbb{R}^n$, a matriz $\mathbf{W}_{m \times n}$ o transforma em um novo vetor de saída $\mathbf{y} \in \mathbb{R}^m$:

$$\mathbf{y}_{m \times 1} = \mathbf{W}_{m \times n} \mathbf{x}_{n \times 1}$$

- É exatamente nesse sentido que o nome faz jus à etimologia: **W gera y** a partir de **x**



Operações com matrizes

Prof. Vinícius Osterne, PhD

Adição de matrizes e multiplicação por escalar

- **Adição:** soma elemento a elemento; exige que **A** e **B** tenham a *mesma dimensão*

$$(\mathbf{A} + \mathbf{B})_{ij} = a_{ij} + b_{ij}$$

- **Multiplicação por escalar:** multiplica todos os elementos pelo escalar c

$$(c\mathbf{A})_{ij} = c a_{ij}$$

- Ambas as operações são realizadas **elemento a elemento** — sem surpresas

Adição e multiplicação por escalar: exemplo

- Sejam as matrizes $\mathbf{A}$ e $\mathbf{B}$ de dimensão 2×2 :

$$\mathbf{A} = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

- Multiplicação por escalar:

$$2\mathbf{A} = \begin{bmatrix} 2 & 6 \\ 4 & 8 \end{bmatrix}$$

- Adição:

$$2\mathbf{A} + \mathbf{B} = \begin{bmatrix} 2 & 6 \\ 4 & 8 \end{bmatrix} + \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 2 & 7 \\ 5 & 8 \end{bmatrix}$$

- Erro comum:** tentar somar matrizes de dimensões diferentes: operação indefinida

Multiplicação de matrizes

- O produto $\mathbf{AB}$ é definido quando o número de **colunas de A** é igual ao número de **linhas de B**
- Se $\mathbf{A} \in \mathbb{R}^{p \times k}$ e $\mathbf{B} \in \mathbb{R}^{k \times q}$, então $\mathbf{C} = \mathbf{AB} \in \mathbb{R}^{p \times q}$ com

$$c_{ij} = \sum_{l=1}^k a_{il} b_{lj}$$

- **Atenção:** a multiplicação de matrizes **não é comutativa** em geral: $\mathbf{AB} \neq \mathbf{BA}$
- No contexto do curso: $\mathbf{X}^T \mathbf{X}$ é uma operação central (gera uma matriz $p \times p$ que resume as relações entre variáveis)

Multiplicação de matrizes: exemplo

- Sejam $\mathbf{A} \in \mathbb{R}^{2 \times 3}$ e $\mathbf{B} \in \mathbb{R}^{3 \times 2}$; o produto $\mathbf{C} = \mathbf{AB} \in \mathbb{R}^{2 \times 2}$:

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 1 & 4 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 2 & 1 \\ 0 & 3 \\ 1 & 2 \end{bmatrix}$$

- Calculando cada elemento de $\mathbf{C}$:

$$c_{11} = 1 \cdot 2 + 2 \cdot 0 + 0 \cdot 1 = 2$$

$$c_{12} = 1 \cdot 1 + 2 \cdot 3 + 0 \cdot 2 = 7$$

$$c_{21} = 3 \cdot 2 + 1 \cdot 0 + 4 \cdot 1 = 10$$

$$c_{22} = 3 \cdot 1 + 1 \cdot 3 + 4 \cdot 2 = 14$$

$$\mathbf{C} = \begin{bmatrix} 2 & 7 \\ 10 & 14 \end{bmatrix}$$



Traço de uma matriz

Prof. Vinícius Osterne, PhD

Traço de uma matriz

- O **traço** de uma matriz quadrada $\mathbf{A} \in \mathbb{R}^{p \times p}$ é a soma dos elementos da diagonal principal:

$$\text{tr}(\mathbf{A}) = \sum_{j=1}^p a_{jj} = a_{11} + a_{22} + \cdots + a_{pp}$$

- Propriedades úteis:

- ▶ $\text{tr}(\mathbf{A} + \mathbf{B}) = \text{tr}(\mathbf{A}) + \text{tr}(\mathbf{B})$
- ▶ $\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$ (mesmo que $\mathbf{AB} \neq \mathbf{BA}$)

- **Aplicação:** na matriz de covariâncias $\mathbf{S}$, o traço representa a **variância total** das variáveis (um resumo escalar da dispersão multivariada)

Traço de uma matriz: exemplo

- Considere uma matriz de covariâncias $\mathbf{S}$ de três variáveis (altura, peso, idade):

$$\mathbf{S} = \begin{bmatrix} 0,04 & 1,20 & 0,30 \\ 1,20 & 64,00 & 8,50 \\ 0,30 & 8,50 & 25,00 \end{bmatrix}$$

- O traço é:

$$\text{tr}(\mathbf{S}) = 0,04 + 64,00 + 25,00 = 89,04$$

- Isso significa que a **variância total** do conjunto de dados é 89,04
- **Observação:** o peso domina o traço por estar em escala maior (motivação para padronizar as variáveis antes da análise)



Determinante de uma matriz


Prof. Vinícius Osterne, PhD

- O **determinante** de uma matriz quadrada $\mathbf{A}$, denotado $\det(\mathbf{A})$ ou $|\mathbf{A}|$, é um escalar que resume propriedades estruturais da matriz
- Para 2×2 :

$$\det \begin{bmatrix} a & b \\ c & d \end{bmatrix} = ad - bc$$

Determinante: área do paralelogramo

Os vetores coluna de A definem um paralelogramo



Por que essa área é igual ao determinante? $\rightarrow$ próximo slide

Por que o determinante mede área?

- O paralelogramo formado por $\mathbf{a}_1 = (a, 0)^\top$ e $\mathbf{a}_2 = (b, d)^\top$ cabe dentro de um retângulo de lados $(a + b)$ e d

- **Área do retângulo:** $(a + b) \cdot d$

- Subtraímos as regiões externas ao paralelogramo:

- ▶ Dois triângulos laterais (base b , altura d): área total = bd
- ▶ Dois triângulos inferior e superior (base a , altura $\frac{d}{2}$ cada): área total = $\frac{1}{2}ad$


- Resultado final:

$$\text{Área} = (a + b)d - bd - \frac{1}{2}ad - \frac{1}{2}ad = \boxed{ad - bc}$$

- Que é exatamente $\det \begin{bmatrix} a & b \\ 0 & d \end{bmatrix} = ad - b \cdot 0$, e o caso geral $(a, c)^\top, (b, d)^\top$ segue o mesmo argumento

Determinante: volume do paralelepípedo

Em 3D, os vetores coluna definem um paralelepípedo



Por que esse volume é igual ao determinante?

Por que o determinante mede volume?

- O argumento é uma extensão direta do caso 2D, aplicado por indução
- O paralelepípedo também cabe dentro de um **bloco retangular** (o menor que o contém); calculamos o volume do bloco e subtraímos os pedaços externos
- Cada “fatia” subtraída corresponde a um menor determinante 2×2 : é exatamente a **expansão de Laplace** que aparece na fórmula recursiva do determinante:

$$\det(\mathbf{A}) = \sum_{j=1}^p (-1)^{1+j} a_{1j} \det(\mathbf{A}_{1j})$$

onde $\mathbf{A}_{1j}$ é a submatriz obtida removendo a linha 1 e coluna j

- **Intuição:** cada termo $(-1)^{1+j} a_{1j} \det(\mathbf{A}_{1j})$ mede o volume de uma “fatia”: somar com sinais alternados é exatamente incluir e excluir as regiões externas ao paralelepípedo

Determinante: exemplo

- Considere duas situações para uma matriz de covariâncias 2×2 :

$$\mathbf{S}_1 = \begin{bmatrix} 4 & 0 \\ 0 & 9 \end{bmatrix}, \quad \mathbf{S}_2 = \begin{bmatrix} 4 & 6 \\ 6 & 9 \end{bmatrix}$$

- Calculando os determinantes:

$$\det(\mathbf{S}_1) = 4 \cdot 9 - 0 \cdot 0 = 36$$

$$\det(\mathbf{S}_2) = 4 \cdot 9 - 6 \cdot 6 = 36 - 36 = 0$$

- **Interpretação:** $\mathbf{S}_2$ tem determinante zero: as duas variáveis são perfeitamente correlacionadas (correlação = 1), ou seja, uma é combinação linear da outra
- Nesse caso, $\mathbf{S}_2$ **não é invertível**: qualquer método que exija $\mathbf{S}^{-1}$ irá falhar



Matriz inversa

Prof. Vinícius Osterne, PhD

- A **inversa** de uma matriz quadrada $\mathbf{A} \in \mathbb{R}^{p \times p}$ é a matriz $\mathbf{A}^{-1}$ tal que

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}_p,$$

onde $\mathbf{I}_p$ é a **matriz identidade** (1's na diagonal, 0's fora)

- A inversa existe somente se $\det(\mathbf{A}) \neq 0$; nesse caso, $\mathbf{A}$ é dita **invertível** (ou não-singular)
- **Analogia escalar:** $\mathbf{A}^{-1}$ é o análogo matricial de $1/a$ para escalares
- **Aplicação central no curso:** a distância de Mahalanobis e o teste de Hotelling T^2 envolvem $\mathbf{S}^{-1}$ (a inversa da matriz de covariâncias)

Matriz inversa: exemplo

- Para uma matriz 2×2 , a fórmula da inversa é direta:

$$\mathbf{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \implies \mathbf{A}^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

- Exemplo com $\mathbf{S} = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$:

$$\det(\mathbf{S}) = 4 \cdot 3 - 2 \cdot 2 = 8 \implies \mathbf{S}^{-1} = \frac{1}{8} \begin{bmatrix} 3 & -2 \\ -2 & 4 \end{bmatrix}$$

- Verificação: $\mathbf{S}\mathbf{S}^{-1} = \frac{1}{8} \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix} \begin{bmatrix} 3 & -2 \\ -2 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2 \checkmark$



Matriz identidade e Matriz diagonal

Prof. Vinícius Osterne, PhD

Matriz identidade e matriz diagonal

- A **matriz identidade** $\mathbf{I}_p$ tem 1's na diagonal e 0's fora; funciona como o número 1 na multiplicação: $\mathbf{A}\mathbf{I} = \mathbf{I}\mathbf{A} = \mathbf{A}$
- Uma **matriz diagonal** tem elementos não-nulos apenas na diagonal principal:

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & 0 \\ 0 & d_2 & 0 \\ 0 & 0 & d_3 \end{bmatrix} = \text{diag}(d_1, d_2, d_3)$$

- **Aplicação:** quando as variáveis são **não correlacionadas**, a matriz de covariâncias $\mathbf{S}$ é diagonal, ou seja, os elementos fora da diagonal (covariâncias) são todos zero

Matriz diagonal: exemplo

- Suponha três variáveis independentes com variâncias $\sigma_1^2 = 4$, $\sigma_2^2 = 9$, $\sigma_3^2 = 1$:

$$\mathbf{S} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 9 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

- Sua inversa é imediata, basta inverter cada elemento diagonal:

$$\mathbf{S}^{-1} = \begin{bmatrix} 1/4 & 0 & 0 \\ 0 & 1/9 & 0 \\ 0 & 0 & 1/1 \end{bmatrix} = \begin{bmatrix} 0,25 & 0 & 0 \\ 0 & 0,11 & 0 \\ 0 & 0 & 1,00 \end{bmatrix}$$

- **Conclusão:** matrizes diagonais são computacionalmente simples; matrizes com covariâncias não-nulas exigem métodos mais elaborados para inversão

Matriz simétrica

Prof. Vinícius Osterne, PhD

Matriz simétrica

- Uma matriz quadrada $\mathbf{A}$ é **simétrica** se $\mathbf{A} = \mathbf{A}^\top$, ou seja, $a_{ij} = a_{ji}$ para todo i, j
- **Importância central:** a matriz de covariâncias $\mathbf{S}$ e a matriz de correlações $\mathbf{R}$ são **sempre simétricas**, pois $\text{Cov}(X_j, X_k) = \text{Cov}(X_k, X_j)$

- Exemplo:

$$\mathbf{S} = \begin{bmatrix} 4,0 & 1,2 & 0,8 \\ 1,2 & 9,0 & 2,1 \\ 0,8 & 2,1 & 1,0 \end{bmatrix} = \mathbf{S}^\top$$

- Matrizes simétricas têm propriedades algébricas convenientes: autovalores sempre reais e autovetores ortogonais entre si

Matriz simétrica: exemplo e verificação

- Uma forma de construir matrizes simétricas: dado qualquer $\mathbf{A}$, o produto $\mathbf{A}^\top \mathbf{A}$ é sempre simétrico

- Verificação com $\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}$:

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix} = \begin{bmatrix} 35 & 44 \\ 44 & 56 \end{bmatrix}$$

- Note que 35 e 56 estão na diagonal, e os dois elementos fora da diagonal são iguais a 44
- **Conexão direta:** a matriz de covariâncias amostral pode ser escrita como $\mathbf{S} \propto \mathbf{X}_c^\top \mathbf{X}_c$, onde $\mathbf{X}_c$ é a matriz de dados centrada



Autovalores e autovetores

Prof. Vinícius Osterne, PhD

- Dado um escalar λ e um vetor não-nulo $\mathbf{v}$, dizemos que λ é **autovalor** e $\mathbf{v}$ é **autovetor** de $\mathbf{A}$ se:

$$\mathbf{A}\mathbf{v} = \lambda \mathbf{v}$$


- **Interpretação geométrica:** multiplicar $\mathbf{v}$ por $\mathbf{A}$ apenas *escala* $\mathbf{v}$ pelo fator λ (a direção não muda, só o comprimento)
- Para uma matriz simétrica $p \times p$ existem sempre p autovalores reais $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$ e p autovetores ortogonais entre si

Autovalores e autovetores: intuição geométrica

- Pense numa matriz como uma **máquina de transformar vetores**: em geral, ela muda a direção e o comprimento de qualquer vetor que passa por ela
- Um **autovetor** é uma direção *especial*: quando passa pela máquina, **não muda de direção** (só o comprimento é afetado)
- O **autovalor** é o fator de escala dessa direção:
 - ▶ $\lambda = 4$: o vetor fica 4 vezes mais longo
 - ▶ $\lambda = 0,5$: o vetor encolhe pela metade
 - ▶ $\lambda < 0$: o vetor inverte o sentido, mas mantém a direção

Autovalores, autovetores e variabilidade

- Os dados formam uma **nuvem de pontos** em $\mathbb{R}^p$: pense nessa nuvem como uma elipse (figura ao lado)
- Os **autovetores** de S são os **eixos dessa elipse**: as direções naturais de alongamento
- Os **autovalores** são os **comprimentos desses eixos**: o quanto a nuvem se estende em cada direção
- Projetar os dados em $\mathbf{v}$ gera escores com **variância exatamente λ**



Autovalores e autovetores: exemplo

- Considere a matriz de covariância:

$$\mathbf{S} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$$

- Os autovalores são obtidos de $\det(\mathbf{S} - \lambda \mathbf{I}) = 0$:

$$(3 - \lambda)^2 - 1 = 0 \implies \lambda_1 = 4, \quad \lambda_2 = 2$$

- Os autovetores correspondentes são:

- ▶ $\lambda_1 = 4$: $\mathbf{v}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ (diagonal positiva)
- ▶ $\lambda_2 = 2$: $\mathbf{v}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ (diagonal negativa)

O que significa “capturar mais variância”?

- Projetando os dados na direção $\mathbf{v}_1 = \frac{1}{\sqrt{2}}(1, 1)^\top$, a variância dos escores é $\lambda_1 = 4$
- Projetando na direção $\mathbf{v}_2 = \frac{1}{\sqrt{2}}(1, -1)^\top$, a variância dos escores é $\lambda_2 = 2$
- $\mathbf{v}_1$ é a direção onde os dados **mais se espalham**: o autovetor do maior autovalor é a direção que **maximiza o espalhamento**
- Pense na elipse: $\mathbf{v}_1$ aponta para o **eixo maior**, $\mathbf{v}_2$ para o **eixo menor**

Autovalores e autovetores: conexão com PCA

- **Variância total** dos dados: $\lambda_1 + \lambda_2 = 4 + 2 = 6$
- **Variância explicada** por cada componente:
 - ▶ 1º componente ($\mathbf{v}_1$): $\frac{4}{6} \approx 67\%$
 - ▶ 2º componente ($\mathbf{v}_2$): $\frac{2}{6} \approx 33\%$
- PCA nada mais faz do que **reorientar o sistema de coordenadas**: o novo eixo 1 aponta para a direção de maior espalhamento, o eixo 2 para a segunda maior, e assim por diante
- Com apenas o 1º componente já capturamos 67% da informação total: esse é o ganho da **redução de dimensionalidade**



Matriz positiva semidefinida e definida

Prof. Vinícius Osterne, PhD

Matriz positiva (semi-)definida

- Uma matriz simétrica $\mathbf{A}$ é **positiva definida** (denotada $\mathbf{A} \succ 0$) se

$$\mathbf{v}^\top \mathbf{A} \mathbf{v} > 0 \quad \text{para todo } \mathbf{v} \neq \mathbf{0}$$

- É **positiva semidefinida** ($\mathbf{A} \succeq 0$) se a desigualdade for ≥ 0
- Equivalentemente: $\mathbf{A} \succ 0 \iff$ todos os autovalores de $\mathbf{A}$ são **estritamente positivos**
- **Por que isso importa?**
 - ▶ A matriz de covariâncias $\mathbf{S}$ é sempre positiva semidefinida
 - ▶ Para ser invertível (necessário em Mahalanobis, Hotelling, etc.), $\mathbf{S}$ precisa ser **positiva definida**, o que requer $n > p$ e variáveis não redundantes

Matriz positiva definida: exemplo

- Verifique se $\mathbf{S} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$ é positiva definida
- **Método 1 (autovalores):** $\lambda_1 = 4 > 0$ e $\lambda_2 = 2 > 0$ ✓
- **Método 2 (forma quadrática):** para $\mathbf{v} = (v_1, v_2)^\top$:

$$\mathbf{v}^\top \mathbf{S} \mathbf{v} = 3v_1^2 + 2v_1v_2 + 3v_2^2 = 2(v_1 + v_2)^2 + v_1^2 + v_2^2 > 0$$

sempre que $(v_1, v_2) \neq (0, 0)$ ✓

- Portanto $\mathbf{S} \succ 0$: é invertível e pode ser usada em todos os métodos do curso



Decomposição espectral

Prof. Vinícius Osterne, PhD

Decomposição espectral

- Toda matriz simétrica $\mathbf{A} \in \mathbb{R}^{p \times p}$ pode ser escrita como

$$\mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^T,$$

onde $\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p)$ contém os autovalores e $\mathbf{P}$ é a matriz cujas colunas são os autovetores correspondentes

- **Interpretação geométrica:** $\mathbf{P}$ define uma *rotação* do espaço e $\mathbf{\Lambda}$ define um *escalonamento* em cada direção rotacionada
- Esta decomposição é o **coração matemático da PCA**, da Análise Fatorial e da maioria dos métodos que estudaremos

Decomposição espectral: exemplo

- Retomando $\mathbf{S} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix}$ com $\lambda_1 = 4$, $\lambda_2 = 2$ e autovetores $\mathbf{v}_1 = \frac{1}{\sqrt{2}}(1, 1)^\top$, $\mathbf{v}_2 = \frac{1}{\sqrt{2}}(1, -1)^\top$:

$$\mathbf{P} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \mathbf{\Lambda} = \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix}$$

- Verificação: $\mathbf{P}\mathbf{\Lambda}\mathbf{P}^\top = \frac{1}{2} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \checkmark$

- Mensagem final:** toda a geometria da nuvem de pontos está codificada nos autovalores (tamanho) e autovetores (orientação) de $\mathbf{S}$

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória**
- 5 Probabilidade
- 6 Inferência
- 7 Modelos Multivariados
- 8 Estrutura dos Dados
- 9 Técnicas de Classificação e Agrupamento

- A partir de uma matriz de dados, podemos começar a realizar algumas análises descritivas
- Nesta seção, apresentaremos as principais e algumas ferramentas gráficas comuns no contexto multivariado

Vetor de médias

- O vetor de médias da matriz de dados $\mathbf{X}$ é dado por

$$\boldsymbol{\mu} = [\mu_1 \quad \mu_2 \quad \dots \quad \mu_p],$$

onde μ_j é a média da variável $\mathbf{X}_j$, que é dada por $\mu_j = \mathbb{E}(\mathbf{X}_j)$ com $j = 1, 2, \dots, p$

Matriz de variâncias e covariâncias

- A matriz de variâncias e covariâncias da matriz de dados $\mathbf{X}$ é dada por

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix},$$

onde σ_{jk} é a covariância entre as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$, que é dada por

$$\sigma_{jk} = \mathbb{E}[(\mathbf{X}_j - \mu_{\mathbf{X}_j})(\mathbf{X}_k - \mu_{\mathbf{X}_k})]$$

- Quando $j = k$, temos $\sigma_{jj} = \sigma_j^2$, que é a variância da variável $\mathbf{X}_j$, ou seja, a diagonal principal da matriz Σ é composta pelas variâncias das variáveis da matriz de dados $\mathbf{X}$
- Assim, podemos reescrever essa matriz da seguinte forma

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_2^2 & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_p^2 \end{bmatrix}.$$

- A matriz de covariância também pode ser diagonal, ou seja

$$\Sigma = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix},$$

nesse caso, as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$, para $j \neq k$, são independentes e, por isso, a covariância é igual a zero

- **Cuidado:** com essa última afirmação, pois o contrário "se duas variáveis tem covariância igual a zero, então elas são independentes" não é sempre válida

Matriz de correlação

- A matriz de correlação da matriz de dados $\mathbf{X}$ é dada por

$$\mathbf{C} = \begin{bmatrix} \rho_{11} & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & \rho_{22} & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & \rho_{pp} \end{bmatrix},$$

onde ρ_{jk} é a correlação entre as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$ que é dada por

$$\rho_{jk} = \frac{\sigma_{jk}}{\sigma_j \sigma_k},$$

sendo $-1 \leq \rho_{jk} \leq 1$

- Quando $j = k$, temos $\rho_{jj} = 1$, pois a correlação entre uma variável e ela mesma é igual a 1
- Assim, podemos reescrever essa matriz da seguinte forma:

$$\mathbf{C} = \begin{bmatrix} \rho_{11} & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & \rho_{22} & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & \rho_{pp} \end{bmatrix} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix}.$$

- A matriz de correlação também pode ser diagonal, ou seja

$$\mathbf{C} = \begin{bmatrix} \rho_1 & 0 & \cdots & 0 \\ 0 & \rho_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \rho_p \end{bmatrix},$$

nesse caso, as variáveis $\mathbf{X}_j$ e $\mathbf{X}_k$, para $j \neq k$, são independentes e, por isso, a correlação é igual a zero

- **Cuidado:** com essa última afirmação, pois o contrário "se duas variáveis tem correlação igual a zero, então elas são independentes" não é sempre válida)

Distâncias multivariadas

- Outras métricas utilizadas a partir da matriz de dados $\mathbf{X}$ são as chamadas distâncias multivariadas
- Essas distâncias podem ser de:
 - ▶ **Similaridade:** quanto maior o valor observado, mais parecidos são os objetos (ex.: coeficiente de correlação, que nós já vimos)
 - ▶ **Dissimilaridade:** quanto maior o valor observado, menos parecidos serão os objetos (ex.: veremos a seguir)

- As principais medidas de Dissimilaridades são:
 - ▶ Distância de Manhattan (distância L_1 : distância puramente geométrica)
 - ▶ Distância Euclidiana (distância L_2 : distâncias puramente geométrica)
 - ▶ Distância de Mahalanobis (distância estatística)
- Vamos detalhar essas medidas a seguir

Distância de Manhattan

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

- **Exemplo:** $x = (1, 2)$, $y = (4, 6)$

$$d = |4 - 1| + |6 - 2| = 3 + 4 = 7$$

- **Ideia:** Soma das diferenças absolutas entre coordenadas (como andar por quarteirões).
- **Vantagens:** Robusta a outliers
- **Desvantagens:** Sensível à escal

Distância de Manhattan entre Dois Pontos




Figura 1: Representação da distância de Manhattan entre os pontos x e y

Distância Euclidiana

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

- **Exemplo:** $x = (1, 2)$, $y = (4, 6)$

$$d = \sqrt{(4 - 1)^2 + (6 - 2)^2} = \sqrt{9 + 16} = \sqrt{25} = 5$$

- **Ideia:** Medida direta ("reta") entre dois pontos no espaço.
- **Vantagens:** Intuitiva e fácil de calcular
- **Desvantagens:** Sensível à escala das variáveis

Distância Euclidiana entre Dois Pontos




Figura 2: Representação geométrica da distância euclidiana entre os pontos x e y

Distância de Mahalanobis

$$d(x, y) = \sqrt{(x - y)^T S^{-1} (x - y)},$$

onde S é a matriz de covariância dos dados

- **Ideia:** Leva em conta correlação e escala entre variáveis. Distância entre ponto e uma distribuição
- **Vantagens:** Invariante à escala; leva em conta correlação entre variáveis; boa para detectar outliers multivariados
- **Desvantagens:** Requer estimar a matriz de covariância; pode ser instável com dados escassos ou colineares

Distância de Mahalanobis: Visualização Simples




Figura 3: Representação simplificada da distância de Mahalanobis

Sobre a distância de Mahalanobis


- Não mede só quão longe o ponto está da média, mas sim quão fora do comum ele está, levando em conta a forma da distribuição dos dados
- Se duas variáveis estão muito correlacionadas (ex: altura e peso), elas não devem "contribuir duas vezes" para a distância (a Mahalanobis "desconta" essa correlação)
- Se uma variável tem variância maior (por exemplo, salário em reais vs idade em anos), ela "domina" na Euclidiana (a Mahalanobis corrige isso automaticamente)

Análises gráficas

- Gráfico de dispersão
- Histogramas
- Diversos outros (que serão mostrados no decorrer das aulas)

Análises gráficas: Gráfico de dispersão


- Utilizado para visualizar a relação entre duas variáveis quantitativas
- É possível detectar padrões e tendências nos dados e identificar possíveis correlações entre as variáveis



figureExemplo de um gráfico de dispersão para as variáveis X e Y.

Análises gráficas: Histograma

- Utilizado para avaliar a forma da distribuição (assimetria e curtose)
- Embora seja univariado, vale usar como comparativo entre duas variáveis



figureExemplo de um histograma com densidade para uma variável contínua.

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade**
- 6 Inferência
- 7 Modelos Multivariados
- 8 Estrutura dos Dados
- 9 Técnicas de Classificação e Agrupamento

Distribuição Normal (univariada)

- A distribuição normal é uma das distribuições de probabilidade mais utilizadas na Estatística
- É caracterizada por ser uma **distribuição de probabilidade absolutamente contínua** e, no contexto univariado, é parametrizada pela esperança matemática (número real μ) e pela variância (número real positivo σ^2)

Distribuições Contínuas vs. Absolutamente Contínuas

- **Distribuição de Probabilidade Contínua:**

- ▶ $\mathbb{P}(X = x) = 0$ (como o número de pontos reais em um intervalo é infinito, a probabilidade de cair em um único ponto específico é nula), mas pode **não ter densidade**.
- ▶ Ex.: Distribuição de Cantor

- **Distribuição de Probabilidade Absolutamente Contínua:**

- ▶ $\mathbb{P}(X = x) = 0$ e existe $f(x)$ tal que $F(x) = \int_{-\infty}^x f(t)dt$
- ▶ Ex.: Normal, Exponencial, Gama, Beta, Uniforme

- Por que importa? Apenas distribuições absolutamente contínuas têm PDF; permitem o uso direto de integrais para cálculo de probabilidades; são necessárias para técnicas clássicas de inferência

- **Nota:** O que é $\mathbb{P}(X = x) = 0$? Como o número de pontos reais em um intervalo é infinito, a probabilidade de cair em um único ponto específico é nula!

Distribuição Normal (univariada)

- Assim, se $X \sim \mathcal{N}(\mu, \sigma^2)$, então sua função densidade de probabilidade é dada por

$$f(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\}$$

Curvas Normais




Figura 4: Três distribuições normais com diferentes médias e desvios-padrão.

- Importante ressaltar que se a distribuição normal tem média nula e variância unitária, então ela é chamada de distribuição normal centrada e reduzida ou de distribuição normal padrão
- No **contexto multivariado**, essa distribuição é parametrizada pela esperança matemática (vetor real μ) e pela matriz de variâncias e covariâncias (matriz positiva definida Σ)

- Assim, se $X \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então sua função densidade de probabilidade é dada por

$$f(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{k/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right).$$

- Duas propriedades importantes dessa distribuição precisam ser destacadas:
 - ▶ Fechada sob marginalização: se Y_i segue uma distribuição normal univariada com média μ_i e variância σ_i^2 , então a marginalização de Y_i em Y resulta em Y_i seguindo uma DNM com média μ_i e variância σ_i^2 ;
 - ▶ Independência e correlação: se Y_i e Y_j são independentes, então a correlação entre eles é zero ($\sigma_{ij} = 0$).

O que significa "fechada sob marginalização"?

Definição

Uma família de distribuições é **fechada sob marginalização** se, ao integrar ("marginalizar") uma ou mais variáveis da distribuição conjunta, a distribuição das variáveis restantes permanece na mesma família.

Distribuição Normal Multivariada

Se

$$\begin{bmatrix} \mathbf{X} \\ \mathbf{Y} \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} \mu_{\mathbf{X}} \\ \mu_{\mathbf{Y}} \end{bmatrix}, \begin{bmatrix} \Sigma_{\mathbf{X}\mathbf{Y}} & \Sigma_{\mathbf{X}\mathbf{Y}} \\ \Sigma_{\mathbf{Y}\mathbf{X}} & \Sigma_{\mathbf{Y}\mathbf{Y}} \end{bmatrix} \right),$$

então

$$\mathbf{X} \sim \mathcal{N}(\mu_{\mathbf{X}}, \Sigma_{\mathbf{X}\mathbf{X}}).$$

Distribuição Student-t

- A distribuição Student-t (ou somente distribuição t) também é uma das distribuições de probabilidade mais utilizadas na Estatística
- É caracterizada por ser uma distribuição de probabilidade absolutamente contínua e, no contexto univariado, é parametrizada pela esperança matemática (número real μ), pela variância (número real positivo σ^2) e pelos graus de liberdade (número inteiro positivo ν)

- Assim, se $X \sim \mathcal{T}(\mu, \sigma^2, \nu)$, então sua função densidade de probabilidade é dada por

$$f(x|\mu, \sigma^2, \nu) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\sqrt{\nu\pi}\Gamma\left(\frac{\nu}{2}\right)(1+x^2/\nu)^{(\nu+1)/2}}$$

Curvas Student-t




Figura 5: Distribuições t de Student com diferentes graus de liberdade ν .

- Essa distribuição é útil quando trabalhamos com amostras pequenas
- É mais robusta em relação a outliers e variações extremas nos dados
- À medida que o tamanho da amostra aumenta, essa distribuição se aproxima da distribuição normal (ou seja, para amostras grandes, podemos usar a distribuição normal como uma aproximação da distribuição Student-t)

Mas o que significam os graus de liberdade?

- Os **graus de liberdade** (ν) estão ligados ao **tamanho da amostra**
- Eles indicam quanto “**conhecimento**” temos sobre a **variabilidade** dos dados
- Quanto **menor** o ν , menos informação temos, e a distribuição t tem **caudas mais pesadas** (mais incerteza)
- Quanto **maior** o ν , mais próxima da **normal padrão** a distribuição t se torna

Distribuições Normal e t de Student




Figura 6: Comparação entre a distribuição Normal padrão e a t de Student com $\nu = 3$. A t possui caudas mais pesadas, o que a torna mais robusta a outliers.

- No **contexto multivariado**, essa distribuição é parametrizada pela esperança matemática (vetor real μ), pela matriz de variâncias e covariâncias (matriz positiva definida Σ) e pelos graus de liberdade (número inteiro positivo ν)
- Assim, se $X \sim \mathcal{T}(\mu, \Sigma)$, então sua função densidade de probabilidade é dada por

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \left(1 + \frac{(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu)}{\nu} \right)^{-\frac{\nu+n}{2}},$$

onde $\mathbf{X}$ é a matriz de dados observada, μ é o vetor de médias, Σ é a matriz de covariância, k é o número de variáveis e ν é o número de graus de liberdade (que determina a forma da distribuição)

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência**
- 7 Modelos Multivariados
- 8 Estrutura dos Dados
- 9 Técnicas de Classificação e Agrupamento

Conceitos prévios

- Teorema do Limite Central
- Sobre o vetor de médias de uma população
- Sobre o vetor de médias de duas populações independentes
- Sobre o vetor de médias de populações pareadas (medidas repetidas)
- Sobre o vetor de médias de mais de uma população (MANOVA)

Teorema do Limite Central

Sejam $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ uma amostra de vetores de variáveis aleatórias i.i.d., de uma distribuição qualquer p -variada, com média $\mathbb{E}(\mathbf{X}_i) = \boldsymbol{\mu}$ e matriz de variâncias e covariâncias $\text{Var}(\mathbf{X}_i) = \boldsymbol{\Sigma}$, para $i = 1, 2, \dots, n$ e $\boldsymbol{\Sigma}$ positiva definida. Então, para n suficientemente grande, temos que

$$\sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \sim N_p(\mathbf{0}, \boldsymbol{\Sigma}),$$

ou seja, a distribuição de $\sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu})$ se aproxima de uma distribuição normal multivariada $N(\mathbf{0}, \boldsymbol{\Sigma})$, onde $\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i$ e, ainda,

$$n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \sim \chi^2(p).$$

Teorema Central do Limite (TLC)

- Se tomarmos muitas amostras aleatórias de tamanho n de uma população com média μ e desvio padrão σ , então a média amostral $\bar{X}$ tende a seguir uma distribuição normal mesmo que a população original não seja normal (desde que o tamanho da amostra n seja suficientemente grande)
- Em suma: com amostras grandes, a média amostral $\bar{X}$ vira "normal"
- Isso é a base da inferência estatística!


Teorema Central do Limite (TLC)

"Mas ainda não entendi a ideia do TLC!"

- Imagine que você tem uma população de **salários**, que é bem desigual (nada normal)
- Aí você:
 - ▶ Pega uma amostra de $n = 30$ pessoas,
 - ▶ Calcula a média dos salários,
 - ▶ Depois pega outra amostra de $n = 30$ e calcula a média de novo,
 - ▶ E faz isso centenas ou milhares de vezes.
- A **distribuição dessas médias** vai formar algo cada vez mais próximo de uma **curva normal**, mesmo que a população original seja **bem distorcida**

Visualização do Teorema Central do Limite

- Na prática, raramente conhecemos a forma da distribuição da população (ela pode ser assimétrica, com caudas pesadas, etc)



Ideia principal: o TCL nos permite usar ferramentas baseadas na normal sem saber a forma exata da população

Por que o TLC é tão importante?

- Permite usar a distribuição normal em:
 - ▶ Intervalos de confiança
 - ▶ Testes de hipótese
- Funciona mesmo com populações não-normais
- Basta ter amostras razoavelmente grandes ($n \geq 30$, por exemplo)

Sobre o vetor de médias de uma população

- Sejam $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_p$ uma amostra aleatória de uma distribuição $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, estamos interessados em testar

$$H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$$

$$H_1 : \boldsymbol{\mu} \neq \boldsymbol{\mu}_0,$$

sendo $\boldsymbol{\mu}_0$ um vetor de médias qualquer a ser considerado

- Para realizar esse teste, utilizamos o fato de que $\bar{\mathbf{X}}$ é o vetor de médias amostrais e $\mathbf{S}$ é a matriz de variâncias e covariâncias amostrais e que
 - ▶ $\bar{\mathbf{X}} \sim N_p(\boldsymbol{\mu}, \sigma^2/n)$
 - ▶ $(n-1)\mathbf{S} \sim \text{Wishart}(n-1)$
 - ▶ $\bar{\mathbf{X}}$ e $\mathbf{S}$ são independentes.

- Considerando H_0 verdadeira, temos que a estatística do teste e sua respectivamente distribuição são dadas por

$$T^2 = \sqrt{n}(\bar{\mathbf{X}} - \mu_0)^\top \left(\frac{(n-1)S}{n-1} \right) \sqrt{n}(\bar{\mathbf{X}} - \mu_0) \sim \left(\frac{(n-1)p}{n-p} \right) F(p, n-p),$$

em que $q_{F(p, n-p), \alpha}$ é o quantil α -superior da distribuição $F(p, n-p)$

- Assim, rejeitamos H_0 , a um nível de significância α , se

$$T_{obs}^2 > \frac{(n-1)p}{n-p} q_{F(p, n-p), \alpha}.$$

- Vale ressaltar que estatística do teste para este caso é chamada estatística T^2 de Hotelling, que é uma generalização do teste T de médias para o caso univariado.
- Além do teste de hipóteses, podemos estar interessados no intervalo de confiança para esse vetor de médias
- Porém, como estamos no contexto multivariado, substituímos o intervalo pela chamada região de confiança

- Assim, sejam $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ uma amostra aleatória de uma distribuição $N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, uma região com $(1 - \alpha) \times 100\%$ de confiança para $\boldsymbol{\mu}$ é dada pelo elipsoide determinado pelos valores de $\boldsymbol{\mu}^*$ que satisfazem

$$n(\bar{\mathbf{X}} - \boldsymbol{\mu}^*)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}^*) \leq \frac{(n-1)p}{n-p} F(p, n-p) = c$$

- Logo, para verificar se $\boldsymbol{\mu}_0$ está dentro da região de confiança, verificamos se

$$n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0^*)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0^*) \leq \frac{(n-1)p}{n-p} F(p, n-p),$$

caso seja, $\boldsymbol{\mu}_0$ está dentro da região de confiança.

Sobre o vetor de médias de duas populações independentes

- Sejam $\mathbf{X}_{11}, \mathbf{X}_{12}, \dots, \mathbf{X}_{1n}$ uma amostra aleatória de uma distribuição normal multivariada, tal que $\mathcal{N}_p(\boldsymbol{\mu}_1, \boldsymbol{\Sigma})$, e $\mathbf{X}_{21}, \mathbf{X}_{22}, \dots, \mathbf{X}_{2n}$ uma outra amostra aleatória de uma distribuição normal multivariada, tal que $\mathcal{N}_p(\boldsymbol{\mu}_2, \boldsymbol{\Sigma})$, retiradas de populações diferentes.

- Neste caso, ambas as populações são normais e têm a mesma matriz de covariância, que é estimada por

$$\begin{aligned} S_{pooled} &= \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2}{n_1 + n_2 - 2} \\ &= \frac{\sum_{j=1}^{n_1} (\mathbf{X}_{1j} - \bar{\mathbf{X}}_1)(\mathbf{X}_{1j} - \bar{\mathbf{X}}_1)^\top + \sum_{j=1}^{n_2} (\mathbf{X}_{2j} - \bar{\mathbf{X}}_2)(\mathbf{X}_{2j} - \bar{\mathbf{X}}_2)^\top}{n_1 + n_2 - 2} \end{aligned}$$

- O interesse consiste em avaliar se não há diferença entre os dois vetores de médias coletados, ou seja, desejamos testar

$$H_0 : \mu_1 = \mu_2$$

$$H_1 : \mu_1 \neq \mu_2,$$

que em um caso mais geral, é dada por

$$H_0 : \mu_1 - \mu_2 = \delta_0$$

$$H_1 : \mu_1 - \mu_2 \neq \delta_0$$

• Note que:

- ▶ $\mathbb{E}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \mathbb{E}(\bar{\mathbf{X}}_1) - \mathbb{E}(\bar{\mathbf{X}}_2) = \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2$
- ▶ $\text{Var}(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) = \text{Var}(\bar{\mathbf{X}}_1) + \text{Var}(\bar{\mathbf{X}}_2)$

. Então,

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 \sim \mathcal{N}_p \left(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2, \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \Sigma \right)$$

- Para verificar se μ_0 estão dentro da região de confiança $100(1 - \alpha)\%$, verificamos se

$$n(\bar{\mathbf{d}} - \boldsymbol{\mu}_D^*)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{d}} - \boldsymbol{\mu}_D^*) \leq \frac{(n-1)p}{n-p} F(p, n-p),$$

caso seja, μ_D está dentro da região de confiança

Sobre o vetor de médias de populações pareadas (medidas repetidas)

- Sejam $\mathbf{X}_{11}, \mathbf{X}_{12}, \dots, \mathbf{X}_{1n}$ uma amostra aleatória de uma distribuição normal multivariada, tal que $\mathcal{N}_p(\boldsymbol{\mu}_1, \boldsymbol{\Sigma})$, e $\mathbf{X}_{21}, \mathbf{X}_{22}, \dots, \mathbf{X}_{2n}$ uma outra amostra aleatória de uma distribuição normal multivariada, tal que $\mathcal{N}_p(\boldsymbol{\mu}_2, \boldsymbol{\Sigma})$, retiradas de uma mesma população, mas em diferentes momentos (momento 1 e momento 2 ou momento antes e momento depois, respectivamente)

- O interesse é consiste em avaliar se não há diferença entre os dois vetores de médias coletados, ou seja, desejamos testar

$$H_0 : \mu_1 = \mu_2$$

$$H_1 : \mu_1 \neq \mu_2.$$

- Para verificar se μ_0 estão dentro da região de confiança $100(1 - \alpha)\%$, verificamos se

$$n(\bar{\mathbf{d}} - \mu_D^*)^\top \mathbf{S}_D^{-1} (\bar{\mathbf{d}} - \mu_D^*) \leq \frac{(n-1)p}{n-p} F(p, n-p),$$

caso seja, μ_D está dentro da região de confiança

Sobre o vetor de médias de mais de uma população (MANOVA)

- A Análise Multivariada da Variância (MANOVA) é um procedimento estatístico usado para comparar médias amostrais multivariadas
- É aplicada quando temos duas ou mais variáveis dependentes e queremos entender como as mudanças nas variáveis independentes afetam essas variáveis dependentes

- Em linhas gerais, a MANOVA compara as médias de várias variáveis dependentes simultaneamente, em vez de analisá-las separadamente
- É uma generalização da Análise de Variância (ANOVA), pois esta testa diferenças de média em uma única variável, aquela considera a covariância entre as variáveis dependentes.
 - ▶ Anova: Comparar notas finais entre 3 métodos de ensino
 - ▶ Manova: Comparar notas em matemática, português e ciências entre os mesmos 3 métodos

- Dessa forma, considere as seguintes amostras, com suas respectivas distribuições de densidade multivariadas, retiradas de populações diferentes e independentes entre si:
 - ▶ $\mathbf{X}_{11}, \mathbf{X}_{12}, \dots, \mathbf{X}_{1n_1}$ uma amostra aleatória de uma distribuição $\mathcal{N}_p(\boldsymbol{\mu}_1, \boldsymbol{\Sigma})$,
 - ▶ $\mathbf{X}_{21}, \mathbf{X}_{22}, \dots, \mathbf{X}_{2n_2}$ uma amostra aleatória de uma distribuição $\mathcal{N}_p(\boldsymbol{\mu}_2, \boldsymbol{\Sigma})$,
 - ▶ ...
 - ▶ $\mathbf{X}_{g1}, \mathbf{X}_{g2}, \dots, \mathbf{X}_{gn_g}$ uma amostra aleatória de uma distribuição $\mathcal{N}_p(\boldsymbol{\mu}_g, \boldsymbol{\Sigma})$,

- Observe que as notações anteriores já nos apresentam as suposições para utilizarmos a MANOVA em qualquer conjunto de dados:
 - ▶ Normalidade multivariada
 - ▶ Homocedasticidade multivariada
 - ▶ Independência das observações
 - ▶ **Extra:** Ausência de multicolinearidade perfeita
- Vamos detalhar isso mais um pouco!

Sobre a normalidade multivariada:

- Cada grupo deve apresentar distribuição **normal multivariada** nas variáveis dependentes
- É mais exigente do que a normalidade univariada (de cada variável separadamente)
- Em amostras grandes, a MANOVA é relativamente robusta a pequenas violações dessa suposição

Como checar: Teste de Shapiro-Wilk multivariado (ex: `MVN::mshapiro.test` no R) ou análise gráfica com plot de distâncias de Mahalanobis

Sobre a homocedasticidade multivariada:

- As **matrizes de covariância** das variáveis dependentes devem ser **iguais entre os grupos**
- Essa suposição é chamada de **homocedasticidade multivariada**
- Pode ser testada com o **teste de Box (Box's M test)** — embora seja sensível a grandes amostras

Como checar: Teste de Box (ex: `biotools::boxM` no R)

Sobre a independência das observações:

- As observações devem ser **independentes** entre e dentro dos grupos
- Violações dessa suposição afetam seriamente a validade dos resultados
- É uma suposição estrutural do desenho do estudo — não se testa estatisticamente

Como checar: Avaliação do desenho amostral; garantir que não haja dependência entre unidades (ex: medidas repetidas)

Sobre a ausência de multicolinearidade perfeita:

- As variáveis dependentes não devem ser **perfeitamente correlacionadas**
- A presença de multicolinearidade perfeita impede a inversão da matriz de covariância
- Uma certa correlação é aceitável — mas não redundância completa entre variáveis

Como checar: Matriz de correlação entre variáveis dependentes ou análise do determinante da matriz de covariância

- O interesse ao se utilizar a MANOVA é testar se as médias multivariadas de cada amostra coletada são iguais ou se pelo menos uma é diferente
- Ou seja, vamos testar as hipóteses:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_g$$

H_1 : pelo menos um μ_i é diferente.

- Com objetivo de facilitar a construção da avaliação desse teste, é preciso fazer uma pequena reparametrização nas expressões, de tal forma que a diferença entre os grupos passa a ser concentrada sobre o parâmetros τ_k , ou seja, o efeito do tratamento sobre o grupo k passa a ser representado por

$$\mu_k = \mu + \tau_k, \quad k = 1, 2, \dots, g,$$

onde τ_k é o efeito do grupo k e, assim, o teste passa a ser representado da seguinte forma:

$$H_0 : \tau_1 = \tau_2 = \dots = \tau_g = 0$$

$$H_1 : \text{pelo menos um } \tau_i \text{ é diferente de zero.}$$

- Para realizar esse teste, decompos a observação $\mathbf{X}_{kj}$ em termos de uma média geral ($\boldsymbol{\mu}$), do efeito do k -ésimo tratamento ($\boldsymbol{\tau}_k$) e de um erro aleatório ($\boldsymbol{\epsilon}_{kj}$), ou seja,

$$\mathbf{X}_{kj} = \boldsymbol{\mu} + \boldsymbol{\tau}_k + \boldsymbol{\epsilon}_{kj},$$

para $j = 1, 2, \dots, n_k$ e $k = 1, 2, \dots, g$, com $\boldsymbol{\epsilon}_{kj} \sim \mathcal{N}_p(\mathbf{0}, \boldsymbol{\Sigma})$.

- Se desenvolvermos a decomposição dada por $\mathbf{X}_{kj} = \boldsymbol{\mu} + \boldsymbol{\tau}_k + \boldsymbol{\epsilon}_{kj}$, conseguimos expressar a variabilidade dos dados em torno da média em variabilidade intra e entre tratamentos, ou seja,

$$SQ_{total} = SQ_{trat} + SQ_{res}$$

sendo SQ_{total} a soma de quadrados e produtos cruzados total, SQ_{trat} a soma de quadrados e produtos cruzados entre tratamentos e SQ_{res} a soma de quadrados e produtos cruzados intra (dentro) tratamentos dados, respectivamente por

- ▶ $SQ_{total} = \sum_{k=1}^g \sum_{j=1}^{n_k} (\mathbf{X}_{jk} - \bar{\mathbf{X}})(\mathbf{X}_{jk} - \bar{\mathbf{X}})^\top$ (mede a dispersão geral de todos os pontos em torno da média geral)
- ▶ $SQ_{trat} = \sum_{k=1}^g n_k (\bar{\mathbf{X}}_k - \bar{\mathbf{X}})(\bar{\mathbf{X}}_k - \bar{\mathbf{X}})^\top$ (mede o quanto as médias de cada grupo se afastam da média geral)
- ▶ $SQ_{res} = \sum_{k=1}^g \sum_{j=1}^{n_k} (\bar{\mathbf{X}}_{kj} - \bar{\mathbf{X}}_k)(\bar{\mathbf{X}}_{kj} - \bar{\mathbf{X}}_k)^\top$ (mede o quanto os indivíduos variam dentro de seus próprios grupos)

- O teste de hipóteses, nesse caso, se reduz a avaliar o quanto SQ_{res} é pequeno em relação a SQ_{total} , pois se todas as médias foram consideradas iguais, pouca informação irá sobrar para o resíduo.
- Para medir essa relação, usamos o chamado lambda de Wilks, que é uma generalização multivariada do teste F univariado, utilizado na ANOVA

- Assim, sob H_0 verdadeira, temos que a estatística do teste e sua respectiva distribuição são dadas por

$$\Lambda^* = \frac{|SQ_{res}|}{|SQ_{res} + SQ_{trat}|},$$

com $-(n - 1 - \frac{p+g}{2}) \log(\Lambda^*) \sim \chi_p^2(g - 1)$.

- Se a variabilidade entre os grupos (SQ_{trat}) for grande, o denominador aumenta e o valor de Λ^* diminui
- Quanto menor o Λ^* , mais evidência contra H_0 (grupos são diferentes)**

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Modelos Multivariados**
- 8 Estrutura dos Dados
- 9 Técnicas de Classificação e Agrupamento

i. Regressão Multivariada

ii. Regressão Canônica

iii. Correlação Canônica

i. Regressão Multivariada

- É uma extensão da regressão múltipla clássica para o caso em que há **múltiplas variáveis dependentes** sendo modeladas simultaneamente.
- Em vez de ajustar um modelo separado para cada variável resposta, a regressão multivariada modela todas elas de forma conjunta, aproveitando a estrutura de correlação entre os desfechos.
- Isso resulta em estimativas mais eficientes e controla o erro tipo I que se acumularia em múltiplos modelos separados.

- Pense na regressão múltipla clássica:
 - ▶ Um conjunto de preditores $\mathbf{X}$ explica *uma* variável resposta Y
- Na regressão multivariada, generalizamos para:
 - ▶ Um conjunto de preditores $\mathbf{X}$ explica *um conjunto* de variáveis resposta $\mathbf{Y}$
- A pergunta central é: *o conjunto de preditores $\mathbf{X}$ influencia significativamente o conjunto de desfechos $\mathbf{Y}$?*
- A diferença fundamental em relação à correlação e regressão canônica é que aqui os preditores $\mathbf{X}$ são fixos — não há simetria entre os conjuntos.

Diferença em relação a outras técnicas

- **Regressão simples:** um preditor X explicando uma variável Y
- **Regressão múltipla:** múltiplos preditores X explicando *uma* variável Y
- **Regressão multivariada:** múltiplos preditores X explicando *múltiplos* desfechos Y simultaneamente
- **MANOVA:** caso especial da regressão multivariada em que os preditores são categóricos (grupos)
- Nos próximos tópicos veremos extensões da regressão multivariada que operam no espaço das combinações lineares dos dois conjuntos.

- O modelo de regressão multivariada é dado por:

$$\mathbf{Y} = \mathbf{XB} + \mathbf{E}, \quad (1)$$

em que:

- ▶ $\mathbf{Y}$ ($n \times q$): matriz de variáveis dependentes
- ▶ $\mathbf{X}$ ($n \times p$): matriz de preditores (com coluna de uns para o intercepto)
- ▶ $\mathbf{B}$ ($p \times q$): matriz de coeficientes de regressão
- ▶ $\mathbf{E}$ ($n \times q$): matriz de erros, com $\text{vec}(\mathbf{E}) \sim \mathcal{N}(\mathbf{0}, \mathbf{\Sigma} \otimes \mathbf{I}_n)$

- O estimador de mínimos quadrados (e de máxima verossimilhança) de $\mathbf{B}$ é:

$$\hat{\mathbf{B}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} \quad (2)$$

- Note que cada coluna de $\hat{\mathbf{B}}$ é equivalente ao estimador de mínimos quadrados de uma regressão múltipla separada para cada Y_j .
- Porém, ao modelar conjuntamente, a inferência sobre $\mathbf{B}$ leva em conta a matriz de covariância dos erros Σ , que é estimada por:

$$\hat{\Sigma} = \frac{1}{n - p} \hat{\mathbf{E}}^\top \hat{\mathbf{E}} \quad (3)$$

- As suposições da regressão multivariada são extensões das suposições da regressão múltipla:
 - ▶ **Linearidade**: relação linear entre $\mathbf{X}$ e cada Y_j
 - ▶ **Normalidade multivariada** dos erros: $\mathbf{e}_i \sim \mathcal{N}_q(\mathbf{0}, \Sigma)$
 - ▶ **Homogeneidade de covariâncias**: $\text{Cov}(\mathbf{e}_i) = \Sigma$ para todo i
 - ▶ **Independência** entre as observações
 - ▶ **Ausência de multicolinearidade** entre os preditores

Testes de hipótese

- Para testar $H_0 : \mathbf{CBM} = \mathbf{0}$ (hipótese linear geral), constroem-se as matrizes:
 - ▶ $\mathbf{H} = (\mathbf{C}\hat{\mathbf{B}}\mathbf{M})^\top [\mathbf{C}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{C}^\top]^{-1} (\mathbf{C}\hat{\mathbf{B}}\mathbf{M})$: matriz de hipótese
 - ▶ $\mathbf{E} = \mathbf{M}^\top \hat{\mathbf{E}}^\top \hat{\mathbf{E}} \mathbf{M}$: matriz de erro
- As estatísticas de teste são as mesmas da MANOVA:
 - ▶ Λ de Wilks: $\Lambda = \frac{|\mathbf{E}|}{|\mathbf{H} + \mathbf{E}|}$
 - ▶ Traço de Pillai: $V = \text{tr}[\mathbf{H}(\mathbf{H} + \mathbf{E})^{-1}]$
 - ▶ Traço de Hotelling-Lawley: $T = \text{tr}[\mathbf{H}\mathbf{E}^{-1}]$
 - ▶ Maior raiz de Roy: $\theta = \lambda_{\max}(\mathbf{H}\mathbf{E}^{-1})$

Interpretação dos resultados

- A interpretação segue dois níveis:
 - ▶ **Nível multivariado:** os testes multivariados indicam se um preditor influencia significativamente o conjunto $\mathbf{Y}$ como um todo
 - ▶ **Nível univariado:** após a significância multivariada, examinam-se os coeficientes de cada regressão separada para identificar *quais* desfechos são influenciados por *quais* preditores
- O R^2 de cada variável dependente mede a proporção da variância de Y_j explicada pelo conjunto $\mathbf{X}$.
- A correlação entre os resíduos das diferentes equações indica se há informação compartilhada entre os desfechos não capturada pelos preditores.

ii. Regressão Canônica

- É uma extensão da regressão multivariada que, em vez de modelar cada variável dependente diretamente, busca **combinações lineares** de $\mathbf{X}$ que melhor predizem **combinações lineares** de $\mathbf{Y}$.
- O objetivo é identificar as dimensões de predição mais relevantes entre os dois conjuntos.
- Mantém a assimetria da regressão — $\mathbf{X}$ prediz $\mathbf{Y}$ — mas opera no espaço das variáveis canônicas.

- Na regressão multivariada, modelamos diretamente cada Y_j em função de $\mathbf{X}$.
- Na regressão canônica, buscamos combinações lineares:
 - ▶ $\mathbf{U} = \mathbf{a}^\top \mathbf{X}$: combinação dos preditores
 - ▶ $\mathbf{V} = \mathbf{b}^\top \mathbf{Y}$: combinação dos desfechostal que $\mathbf{U}$ maximize a predição de $\mathbf{V}$.
- Isso é útil quando as variáveis de $\mathbf{Y}$ são altamente correlacionadas entre si — em vez de modelá-las separadamente, modelamos sua estrutura conjunta.
- A diferença para a correlação canônica está no **objetivo**: aqui queremos prever, não apenas descrever a associação.

- As variáveis canônicas são definidas como:

$$\mathbf{U}_k = \mathbf{a}_k^\top \mathbf{X} \quad \text{e} \quad \mathbf{V}_k = \mathbf{b}_k^\top \mathbf{Y}, \quad (4)$$

em que os vetores $\mathbf{a}_k$ e $\mathbf{b}_k$ são obtidos maximizando:

$$\max_{\mathbf{a}_k, \mathbf{b}_k} \text{Cor}(\mathbf{U}_k, \mathbf{V}_k) = \rho_k, \quad (5)$$

sujeito a $\text{Var}(\mathbf{U}_k) = \text{Var}(\mathbf{V}_k) = 1$ e à não correlação com os pares anteriores.

- A solução é obtida via problema de autovalores da matriz $\Sigma_{XX}^{-1} \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX}$.

Número de pares canônicos

- São obtidos $r = \min(p, q)$ pares canônicos, com correlações $\rho_1 \geq \rho_2 \geq \dots \geq \rho_r \geq 0$.
- Cada par captura uma dimensão independente de predição:
 - ▶ O **primeiro par** captura a maior predição possível
 - ▶ O **segundo par** captura a maior predição residual, ortogonal ao primeiro
 - ▶ E assim sucessivamente
- Na prática, apenas os primeiros pares tendem a ser estatisticamente significativos.

Qualidade do ajuste

- A qualidade da predição é avaliada por:

- ▶ R^2 **canônico** (ρ_k^2): proporção da variância de $\mathbf{V}_k$ predita por $\mathbf{U}_k$
- ▶ **Índice de redundância de Y dado X:**

$$\text{Rd}(\mathbf{Y}|\mathbf{X}) = \frac{1}{q} \sum_{k=1}^r \rho_k^2 \cdot \sum_{j=1}^q r^2(Y_j, \mathbf{V}_k) \quad (6)$$

- ▶ Interpreta-se como a proporção média da variância de $\mathbf{Y}$ predita pelo conjunto $\mathbf{X}$

- O teste sequencial de Bartlett avalia quantos pares canônicos são significativos:

$$\chi_k^2 \approx - \left[n - 1 - \frac{1}{2}(p + q + 1) \right] \ln \prod_{i=k}^r (1 - \rho_i^2) \quad (7)$$

com $(p - k + 1)(q - k + 1)$ graus de liberdade.

- O procedimento é sequencial:
 - ▶ Testa $H_0 : \rho_1 = \rho_2 = \dots = \rho_r = 0$
 - ▶ Se rejeitado, remove ρ_1 e testa $H_0 : \rho_2 = \dots = \rho_r = 0$
 - ▶ Continua até não rejeitar ou esgotar os pares

iii. Correlação Canônica

- É uma técnica estatística multivariada usada para investigar relações entre dois conjuntos de variáveis de forma **simétrica** — sem distinção entre preditor e desfecho.
- Enquanto a regressão canônica pergunta *quanto X prediz Y ?*, a correlação canônica pergunta *como os dois conjuntos se associam?*
- Encontra combinações lineares de cada conjunto que maximizam a correlação entre eles, identificando as dimensões latentes de associação.

Diferença fundamental em relação à regressão canônica

- Embora ambas utilizem as mesmas variáveis canônicas e os mesmos autovalores, diferem conceitualmente:

	Reg. Canônica	Corr. Canônica
Relação	Assimétrica	Simétrica
Objetivo	Predição	Associação
Pergunta	X prediz Y ?	Como X e Y se relacionam?
Medida	Redundância	Correlação canônica

- Na prática, os cálculos são idênticos — a distinção está no **objetivo** e na **interpretação**.

- Dada duas matrizes de dados, $\mathbf{X}_{p \times 1}$ e $\mathbf{Y}_{q \times 1}$, as variáveis canônicas são:

$$\mathbf{U}_k = \mathbf{a}_k^\top \mathbf{X} \quad \text{e} \quad \mathbf{V}_k = \mathbf{b}_k^\top \mathbf{Y}, \quad (8)$$

em que $\mathbf{a}_k$ e $\mathbf{b}_k$ são definidos de tal forma que $\text{Cor}(\mathbf{U}_k, \mathbf{V}_k) = \rho_k$ seja máxima, sujeito a $\text{Var}(\mathbf{U}_k) = \text{Var}(\mathbf{V}_k) = 1$ e à não correlação com os pares anteriores.

Problema de maximização

- Para o primeiro par canônico, o problema de maximização é:

$$\max_{\mathbf{a}, \mathbf{b}} \text{Cor}(\mathbf{U}_1, \mathbf{V}_1) = \mathbf{a}_1^\top \Sigma_{XY} \mathbf{b}_1, \quad (9)$$

sujeito a $\mathbf{a}_1^\top \Sigma_{XX} \mathbf{a}_1 = \mathbf{b}_1^\top \Sigma_{YY} \mathbf{b}_1 = 1$.

- A solução é obtida via autovalores e autovetores da matriz:

$$\Sigma_{XX}^{-1} \Sigma_{XY} \Sigma_{YY}^{-1} \Sigma_{YX} \quad (10)$$

- Os autovalores $\rho_1^2 \geq \rho_2^2 \geq \dots \geq \rho_r^2$ são os quadrados das correlações canônicas.

Cargas canônicas e interpretação

- Os resultados da correlação canônica são interpretados em três níveis:
 - ▶ **Correlações canônicas** (ρ_k): força da associação entre o k -ésimo par de variáveis canônicas
 - ▶ **Cargas canônicas**: correlações entre as variáveis originais e as variáveis canônicas — indicam quais variáveis mais contribuem para cada par
 - ▶ **Cargas cruzadas**: correlações entre as variáveis de $\mathbf{X}$ e as variáveis canônicas de $\mathbf{Y}$ (e vice-versa) — a medida mais direta de associação entre os conjuntos

- O teste sequencial de Bartlett avalia quantos pares canônicos são significativos:

$$\chi_k^2 \approx - \left[n - 1 - \frac{1}{2}(p + q + 1) \right] \ln \prod_{i=k}^r (1 - \rho_i^2) \quad (11)$$

com $(p - k + 1)(q - k + 1)$ graus de liberdade.

- Suposições necessárias:
 - ▶ Normalidade multivariada dos dois conjuntos
 - ▶ Linearidade da relação entre $\mathbf{X}$ e $\mathbf{Y}$
 - ▶ Ausência de multicolinearidade dentro de cada conjunto
 - ▶ Tamanho amostral adequado: $n \geq 10(p + q)$

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Modelos Multivariados
- 8 Estrutura dos Dados**
- 9 Técnicas de Classificação e Agrupamento

- i. Análise de Componentes Principais (PCA)**
- ii. Análise de Correspondência**
- iii. Análise Fatorial Exploratória (AFE)**
- iv. Análise Fatorial Confirmatória (AFC)**

- A redução de dimensionalidade se refere ao processo de reduzir o número de variáveis de um conjunto de dados, mantendo o máximo possível das informações originais
- Existem várias razões pelas quais você pode querer reduzir a dimensionalidade dos dados, dentre elas destacam-se:
 - ▶ Eliminação de ruído e redundância (princípio da parcimônia);
 - ▶ Simplificação e interpretabilidade;
 - ▶ Visualização (projetar os dados em um espaço de menor dimensão).

- Na literatura, existem duas abordagens principais para a redução de dimensionalidade:
 - ▶ **Seleção de variáveis:** envolve selecionar um subconjunto das variáveis originais do conjunto de dados, consideradas as mais importantes para explicar a variabilidade nos dados;
 - ▶ **Extração de variáveis:** as variáveis originais são transformadas em um novo conjunto de variáveis, geralmente de menor dimensão, que são combinações lineares das variáveis originais, escolhidas de forma a capturar a maior parte da variabilidade nos dados.

- As abordagens de **extração de variáveis** serão o foco dos nossos estudos nessa seção e, dentre elas, vamos discutir:
 - ▶ Análise de Componentes Principais (PCA)
 - ▶ Análise de Correspondência
 - ▶ Análise Fatorial Exploratória (AFE)
 - ▶ Análise Fatorial Confirmatória (AFC)

i. Análise de Componentes Principais

- Inicialmente proposta por Karl Pearson em 1901 e estudada e nomeada por Harold Hotelling em 1933
- É uma técnica que transforma linearmente um conjunto de p variáveis correlacionadas em um conjunto de p variáveis (mesma quantidade original) não correlacionadas

- Essa transformação nos permite que, ao invés de trabalhar com p variáveis, seja possível trabalhar com somente k dessas variáveis, tal que $k < p$
- E essas k novas variáveis são capazes de explicar uma parcela substancial das informações (ou variabilidade) do conjunto original de p variáveis

- Os objetivos ao se usar a ACP, então, podem ser listados como:
 - ▶ Redução de dimensionalidade (a partir de novas variáveis que serão não correlacionadas);
 - ▶ Obter um novo conjunto de variáveis (que são combinações das variáveis originais) interpretáveis;
 - ▶ Descrever e/ou compreender a estrutura de correlação das variáveis originais.

- Qual é a ideia básica da ACP, então?

- ▶ A partir do conjunto de dados originais, aplicamos uma transformação especial (que veremos nesta seção em detalhes)
- ▶ Essa transformação fará uma rotação nos eixos originais desses dados
- ▶ Isso fará com que o primeiro eixo (primeira componente principal) nos descreva o acúmulo da maior variabilidade dos dados, o segundo eixo (segunda componente principal) nos descreva o acúmulo da segunda maior variabilidade dos dados (e, assim, sucessivamente)

- Essa transformação faz com que não seja necessário utilizar todas as variáveis originais do problema apresentado, mas somente algumas transformações (representadas pelas componentes principais) que são capazes de acumular um grande percentual da variabilidade dos dados originais

Diferença entre PCA e Análise Fatorial

- Embora ambas sejam técnicas de redução de dimensionalidade, diferem conceitualmente:
 - ▶ **PCA**: as componentes são combinações lineares das variáveis observadas — não há modelo causal. O objetivo é resumir a variabilidade.
 - ▶ **Análise Fatorial**: assume que as variáveis observadas são *causadas* por fatores latentes não observados. O objetivo é descobrir a estrutura subjacente.
- Em PCA, toda a variância é explicada (incluindo a variância específica de cada variável). Na AF, separa-se a variância comum (comunalidade) da variância específica.

- Para fazer essa transformação, considere a matriz de dados $\mathbf{X}_{p \times 1} = (\mathbf{X}_1, \dots, \mathbf{X}_p)$, cujos elementos são variáveis aleatórias de dimensão n , ou seja, a matriz $\mathbf{X}_{p \times 1}$ é dada por:

$$\mathbf{X} = [\mathbf{X}_1 \quad \mathbf{X}_2 \quad \dots \quad \mathbf{X}_p] = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix},$$

onde x_{ij} representa o valor da variável j na observação i , n é o número de observações e p é o número de variáveis

- A transformação a ser realizada nessas variáveis originais é feita de tal forma que

$$\begin{aligned}\mathbf{e}_1 &= e_{11}x_1 + e_{21}x_2 + \dots + e_{n1}x_n \\ \mathbf{e}_2 &= e_{12}x_1 + e_{22}x_2 + \dots + e_{n2}x_n \\ &\vdots \\ \mathbf{e}_n &= e_{1n}x_1 + e_{2n}x_2 + \dots + e_{nn}x_n,\end{aligned}$$

tal que

$$\begin{aligned}e_{11}^2 + e_{21}^2 + \dots + e_{n1}^2 &= 1 \\ e_{12}^2 + e_{22}^2 + \dots + e_{n2}^2 &= 1 \\ &\vdots \\ e_{1n}^2 + e_{2n}^2 + \dots + e_{nn}^2 &= 1.\end{aligned}$$

- O objetivo, portanto, é maximizar $\mathbf{e}_1$ (ou qualquer outro) de tal forma que ele tenha a maior variabilidade possível
- Falando matematicamente, estamos interessados em encontrar

$$\arg_{\mathbf{e}_1} [\max[\text{Var}(\mathbf{e}_1)]],$$

ou seja, o objetivo é encontrar o argumento que maximize $\text{Var}(\mathbf{e}_1)$, sujeito a $e_{11}^2 + e_{21}^2 + \dots + e_{n1}^2 = 1$

- Podemos reescrever a expressão interna da maximização de uma outra forma:

$$\begin{aligned}\text{Var}(\mathbf{e}_1) &= \text{Var}(e_{11}x_1 + e_{21}x_2 + \dots + e_{n1}x_n) \\ &= \mathbf{e}_1^\top \text{Var}(\mathbf{X}) \mathbf{e}_1 \\ &= \mathbf{e}_1^\top \Sigma \mathbf{e}_1,\end{aligned}$$

sendo Σ a matriz de covariância dos dados originais

- Consequentemente, o objetivo agora recai sobre o seguinte problema:

$$\arg_{\mathbf{e}_1} [\max[\mathbf{e}_1^\top \Sigma \mathbf{e}_1]],$$

$$\text{sujeito a } e_{11}^2 + e_{21}^2 + \dots + e_{n1}^2 = 1$$

- Agora precisamos saber que método usar para maximizar essa função

- Para maximizar uma função qualquer, temos dois caminhos muito conhecidos:
 - ▶ se o caso for unidimensional, derivamos a função com relação à variável de interesse e igualamos a zero
 - ▶ se o caso for multidimensional, derivamos com relação a cada variável e igualamos a zero (gradiente da função)
- Um outro caminho alternativo aos clássicos é utilizar os **Multiplicadores de Lagrange**

- Essa técnica é uma “sacada” dos pesquisadores para resolver problemas mais complexos, usando problemas mais simples
- A ideia considerada foi a seguinte: se temos que maximizar $f(x)$, então se maximizarmos $h(x, \lambda)$, tal que

$$h(x, \lambda) = f(x) - \sum_{i=1}^n \lambda_j (b_j - g_j(x)),$$

estaremos maximizando $f(x)$

- No contexto da ACP, onde precisamos maximizar a variabilidade para obter os vetores de componentes, a função $h(x, \lambda)$ é dada por

$$h(x, \lambda) = \mathbf{e}_1^\top \mathbf{\Sigma} \mathbf{e}_1 - \lambda(1 - e_{11}^2 - e_{21}^2 - \dots - e_{n1}^2),$$

e, assim, se calcularmos o gradiente com respeito a $\mathbf{e}_1$, estaremos encontrando os valores que maximizam $\text{Var}(\mathbf{e}_1)$

Solução via autovalores e autovetores

- Calculando o gradiente e igualando a zero, obtemos:

$$\frac{\partial h}{\partial \mathbf{e}_1} = 2\mathbf{\Sigma}\mathbf{e}_1 - 2\lambda\mathbf{e}_1 = \mathbf{0} \implies (\mathbf{\Sigma} - \lambda\mathbf{I})\mathbf{e}_1 = \mathbf{0} \quad (12)$$

- Essa é a equação característica de um problema de autovalores: λ é um autovalor de $\mathbf{\Sigma}$ e $\mathbf{e}_1$ é o autovetor associado.
- Como queremos maximizar $\text{Var}(\mathbf{e}_1) = \mathbf{e}_1^\top \mathbf{\Sigma} \mathbf{e}_1 = \lambda$, escolhemos o **maior autovalor** λ_1 e seu autovetor associado $\mathbf{e}_1$.
- As componentes principais seguintes são obtidas pelos autovalores em ordem decrescente: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$.

Variância explicada e critérios de retenção

- A proporção da variância total explicada pela k -ésima componente principal é:

$$\frac{\lambda_k}{\sum_{i=1}^p \lambda_i} \quad (13)$$

- Para decidir quantas componentes reter, os critérios mais utilizados são:
 - ▶ **Critério de Kaiser:** reter componentes com $\lambda_k > 1$ (quando os dados são padronizados)
 - ▶ **Variância acumulada:** reter componentes até atingir 70%–80% da variância total
 - ▶ **Scree plot:** gráfico dos autovalores em ordem decrescente — reter até o ponto de inflexão (cotovelo)
 - ▶ **Análise paralela:** comparar autovalores observados com autovalores de dados aleatórios

Matriz de covariância ou de correlação?

- A PCA pode ser realizada sobre a matriz de covariância Σ ou sobre a matriz de correlação $\mathbf{P}$:
 - ▶ **Matriz de covariância** (Σ): adequada quando as variáveis estão na mesma escala. Variáveis com maior variância dominarão as componentes.
 - ▶ **Matriz de correlação** ($\mathbf{P}$): equivale a padronizar as variáveis antes da PCA. Recomendada quando as variáveis têm escalas ou unidades diferentes.
- Na prática, a maioria das aplicações utiliza a matriz de correlação, pois elimina o efeito de escala.

ii. Análise de Correspondência

- É uma técnica de redução de dimensionalidade para **variáveis categóricas**, análoga à PCA para variáveis contínuas.
- Permite visualizar e explorar associações entre as categorias de duas ou mais variáveis qualitativas, representando-as graficamente em um espaço de baixa dimensão.
- O ponto de partida é sempre uma **tabela de contingência** — a estrutura de dados natural para variáveis categóricas.

- O qui-quadrado diz se há associação entre duas variáveis categóricas.
- A Análise de Correspondência diz *onde* está essa associação e *como* as categorias se relacionam.
- Categorias com perfis de distribuição similares aparecerão próximas no mapa — categorias com perfis diferentes aparecerão distantes.
- Uma categoria de linha próxima a uma categoria de coluna no mapa indica associação positiva entre elas — aquela combinação ocorre mais do que o esperado sob independência.

Tabela de contingência e perfis

- Seja $\mathbf{N}$ uma tabela de contingência $r \times c$, com elemento n_{ij} representando a frequência conjunta das categorias i e j .
- Define-se a **matriz de correspondência**:

$$\mathbf{P} = \frac{1}{n}\mathbf{N}, \quad (14)$$

em que $n = \sum_{i,j} n_{ij}$ é o total de observações.

- Os **perfis de linha** são as distribuições condicionais de cada linha:

$$p_{ij|i} = \frac{p_{ij}}{p_{i\cdot}} = \frac{n_{ij}}{n_{i\cdot}} \quad (15)$$

- Analogamente, os **perfis de coluna**: $p_{ij|j} = p_{ij}/p_{\cdot j}$.

- A **inércia total** da análise de correspondência é equivalente ao qui-quadrado padronizado:

$$\text{Inércia total} = \frac{\chi^2}{n} = \sum_{i=1}^r \sum_{j=1}^c \frac{(p_{ij} - p_{i\cdot} p_{\cdot j})^2}{p_{i\cdot} p_{\cdot j}} \quad (16)$$

- Quanto maior a inércia, maior a associação entre as variáveis.
- Assim como na PCA, a inércia é decomposta em dimensões — a primeira dimensão captura a maior parte da inércia, a segunda captura a segunda maior, e assim por diante.
- O número máximo de dimensões é $\min(r - 1, c - 1)$.

Decomposição em valores singulares

- A solução da análise de correspondência é obtida via **Decomposição em Valores Singulares (SVD)** da matriz de resíduos padronizados:

$$s_{ij} = \frac{p_{ij} - p_{i\cdot} p_{\cdot j}}{\sqrt{p_{i\cdot} p_{\cdot j}}} \quad (17)$$

- A SVD decompõe essa matriz como $\mathbf{S} = \mathbf{U}\mathbf{D}\mathbf{V}^\top$, em que:
 - ▶ $\mathbf{D}$ contém os valores singulares $\mu_1 \geq \mu_2 \geq \dots$ — suas raízes quadradas são as inércias de cada dimensão
 - ▶ $\mathbf{U}$ e $\mathbf{V}$ fornecem as coordenadas de linhas e colunas no mapa
- A proporção da inércia explicada pela k -ésima dimensão é $\mu_k^2 / \sum_k \mu_k^2$.

Interpretação do mapa de correspondência

- O mapa de correspondência (biplot) representa simultaneamente as categorias de linha e coluna no mesmo espaço:
 - ▶ **Categorias próximas** entre si (linha-linha ou coluna-coluna): perfis similares
 - ▶ **Categoria de linha próxima a categoria de coluna**: associação positiva — coocorrem mais do que o esperado
 - ▶ **Categoria de linha distante de categoria de coluna**: coocorrem menos do que o esperado
 - ▶ **Origem do mapa**: representa o perfil médio — categorias próximas à origem têm perfis próximos da média
- A qualidade de representação de cada categoria no mapa é avaliada pelo $\cos^2$ — categorias com $\cos^2$ baixo estão mal representadas nas dimensões escolhidas.

Análise de Correspondência Múltipla (ACM)

- A **Análise de Correspondência Simples** (ACS) opera sobre tabelas de contingência com *duas* variáveis categóricas.
- A **Análise de Correspondência Múltipla** (ACM) é a extensão para três ou mais variáveis categóricas simultaneamente.
- Na ACM, constrói-se a **matriz indicadora** $\mathbf{Z}$ ($n \times \sum_k c_k$), em que cada variável é representada por variáveis dummy para suas categorias.
- A ACM aplica a análise de correspondência sobre $\mathbf{Z}^\top \mathbf{Z}$ (matriz de Burt), generalizando os resultados da ACS para múltiplas variáveis.

iii. Análise Fatorial Exploratória (AFE)

- Assim como a Análise de Componentes Principais, a **Análise Fatorial (AF)**, proposta por Charles Spearman em 1904, também é uma técnica de redução de dimensionalidade
- Objetivo: aplicar uma transformação da matriz de dados $\mathbf{X}_{p \times 1}$ de tal forma que consigamos obter fatores que carreguem a variabilidade original dos dados
- **Diferença fundamental:** os fatores, chamados de *fatores comuns*, são variáveis **latentes** — não observáveis — que se relacionam com $\mathbf{X}$ por meio de um modelo linear

O que é a AFE?

- Na **Análise Fatorial Exploratória**, não temos hipóteses prévias sobre a estrutura dos fatores.
- Deixamos os dados revelarem quantos fatores existem e quais variáveis se agrupam em cada fator.
- É utilizada nas fases iniciais de uma investigação, quando o pesquisador quer *descobrir* a estrutura latente dos dados.
- Contrasta com a AFC, onde a estrutura é *testada* a partir de uma teoria prévia — que veremos no próximo tópico.

- Os objetivos da AFE são:
 - ▶ Agrupar as variáveis originais de $\mathbf{X}_i$, $i = 1, \dots, p$, em fatores mutuamente não correlacionados e interpretáveis
 - ▶ Reduzir a dimensionalidade do problema
 - ▶ Identificar a estrutura latente subjacente aos dados sem impor restrições prévias sobre ela

AFE vs AFC — visão geral

	AFE	AFC
Objetivo	Descobrir estrutura	Testar estrutura
Hipótese prévia	Não	Sim
Cargas	Todas livres	Fixas e livres
Avaliação	Interpretação	Índices de ajuste
Fase da pesquisa	Exploratória	Confirmatória

- Sejam $\mathbf{X}_{p \times 1}$ um vetor aleatório com $\mathbb{E}(\mathbf{X}) = \boldsymbol{\mu}$, $\text{Var}(\mathbf{X}) = \boldsymbol{\Sigma}$, $\text{Cor}(\mathbf{X}) = \mathbf{P}$ e

$$Z_i = \frac{X_i - \mu_i}{\sigma_i},$$

para $i = 1, \dots, p$ tal que $\text{Cov}(\mathbf{Z}) = \mathbf{P} = \text{Cor}(\mathbf{X})$

- Queremos explicar as variáveis padronizadas $\mathbf{Z}_1, \dots, \mathbf{Z}_p$ com m fatores $\mathbf{F}_1, \dots, \mathbf{F}_m$, de tal forma que:

$$\mathbf{Z} = \mathbf{LF} + \boldsymbol{\epsilon}$$

- Essa estrutura matricial é dada, em detalhes, por

$$\begin{aligned}\mathbf{Z}_1 &= l_{11}\mathbf{F}_1 + \dots + l_{1m}\mathbf{F}_m + \epsilon_1 \\ \mathbf{Z}_2 &= l_{21}\mathbf{F}_1 + \dots + l_{2m}\mathbf{F}_m + \epsilon_2 \\ &\vdots \\ \mathbf{Z}_p &= l_{p1}\mathbf{F}_1 + \dots + l_{pm}\mathbf{F}_m + \epsilon_p,\end{aligned}$$

sendo

- ▶ $\mathbf{F}_{m \times 1}$: vetor de fatores latentes não observáveis;
- ▶ ϵ : vetor de erros aleatórios não observáveis;
- ▶ l_{ij} : carga fatorial da i -ésima variável no j -ésimo fator;
- ▶ $\mathbf{L}$: matriz de cargas fatoriais ($p \times m$).

- O modelo $\mathbf{Z} = \mathbf{LF} + \epsilon$ é chamado de modelo fatorial ortogonal, já que os m fatores são ortogonais entre si
- Essa estrutura apresenta as seguintes suposições:
 - ▶ $\mathbb{E}(\mathbf{F}) = \mathbf{0}$;
 - ▶ $\text{Var}(\mathbf{F}) = \mathbf{I}$;
 - ▶ $\mathbb{E}(\epsilon) = \mathbf{0}$;
 - ▶ $\text{Var}(\epsilon) = \mathbf{\Psi} = \text{diag}(\Psi_1, \dots, \Psi_p)$;
 - ▶ $\mathbf{F}$ e ϵ são não correlacionados.

Comunalidade e variância específica

- A variância de cada variável padronizada Z_i se decompõe em:

$$\text{Var}(Z_i) = \underbrace{\sum_{j=1}^m \beta_{ij}^2}_{h_i^2 \text{ (comunalidade)}} + \underbrace{\Psi_i}_{\text{variância específica}} = 1 \quad (18)$$

- A **comunalidade** h_i^2 representa a proporção da variância de Z_i explicada pelos fatores comuns — quanto maior, mais a variável é explicada pelo modelo.
- A **variância específica** Ψ_i é a parte da variância exclusiva de Z_i , não compartilhada com as demais variáveis.

- Para encontrar os fatores dessa transformação, a ideia é decompor a matriz $\mathbf{P}$ na forma

$$\mathbf{P} = \mathbf{L}_{p \times m} \mathbf{L}_{m \times p}^{\top} + \mathbf{\Psi}_{p \times p},$$

cuja representação aberta das matrizes é dada por

$$\mathbf{P} = \mathbf{L} \mathbf{L}^{\top} + \mathbf{\Psi} = \begin{pmatrix} \sum_{j=1}^m l_{1j}^2 & \cdots & \sum_{j=1}^m l_{1j} l_{jp} \\ \vdots & \ddots & \vdots \\ \sum_{j=1}^m l_{pj} l_{j1} & \cdots & \sum_{j=1}^m l_{pj}^2 \end{pmatrix} + \begin{pmatrix} \Psi_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \Psi_p \end{pmatrix}$$

- Pode-se estimar $\mathbf{L}$ e Ψ utilizando alguns métodos, dentre eles:
 - ▶ Método das componentes principais ou fatores principais;
 - ▶ Método das componentes principais iterativo ou fatores principais iterativo;
 - ▶ Método da máxima verossimilhança (com a suposição de normalidade).

Estimação pelo Método da Máxima Verossimilhança

- Suponha que $\mathbf{X} \sim \mathcal{N}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e, portanto, $\mathbf{Z} \sim \mathcal{N}_p(\mathbf{0}, \mathbf{P})$. Além disso, $\mathbf{F} \sim \mathcal{N}_p(\mathbf{0}, \mathbf{I})$ e $\boldsymbol{\epsilon} \sim \mathcal{N}_p(\mathbf{0}, \boldsymbol{\Sigma})$.

- A função de verossimilhança considerando uma amostra aleatória de tamanho n , $\mathbf{Z}_1, \dots, \mathbf{Z}_n$, é expressa por

$$L(\mathbf{P}) = \frac{1}{(2\pi)^{np/2} |\mathbf{L}\mathbf{L}^\top + \mathbf{\Psi}|^{n/2}} \exp \left(-\frac{1}{2} \sum_{j=1}^n \mathbf{z}_j^\top (\mathbf{L}\mathbf{L}^\top + \mathbf{\Psi})^{-1} \mathbf{z}_j \right),$$

e devemos encontrar o máximo de $L(\mathbf{P})$ em $\mathbf{L}$ e $\mathbf{\Psi}$. Essa maximização é feita em termos numéricos para um valor de m fixo.

- Se a suposição de normalidade é válida, o método da máxima verossimilhança pode produzir estimativas mais precisas
- Se não podemos supor a normalidade multivariada, convém utilizar o método de fatores principais ou fatores principais iterativo
- A principal vantagem do método da máxima verossimilhança é a possibilidade de desenvolver **testes de hipóteses** para avaliar a adequação do modelo — o que não é possível pelo método de componentes principais

Critérios para escolha do número de fatores

- Na AFE, a escolha do número de fatores m é uma decisão central. Os critérios mais utilizados são:
 - ▶ **Análise da proporção da variância:** reter fatores que acumulem variância suficiente (tipicamente 70%–80%)
 - ▶ **Critério de Kaiser:** reter fatores com autovalor de $\mathbf{R}$ maior do que 1
 - ▶ **Scree plot:** gráfico dos autovalores em ordem decrescente — reter até o ponto de inflexão
 - ▶ **Análise paralela:** comparar autovalores observados com autovalores gerados aleatoriamente — critério mais rigoroso
- Recomenda-se usar mais de um critério e triangular a decisão com a interpretabilidade dos fatores.

Rotação Ortogonal de Fatores

- Podemos estar interessados em aplicar transformações ortogonais aos fatores originais de modo que os novos fatores obtidos tenham interpretações mais fáceis e diretas

- Graficamente, estamos interessados em fazer a seguinte rotação:




Figura 7: Representação gráfica da rotação ortogonal de fatores.

- Nesse caso, a ideia consiste em considerar a matriz $\mathbf{T}$ ortogonal tal que $\mathbf{T}\mathbf{T}^\top = \mathbf{T}^\top\mathbf{T} = \mathbf{I}$ e rotacionar a matriz de cargas fatoriais fazendo

$$\hat{\mathbf{L}}^* = \hat{\mathbf{L}}\mathbf{T},$$

note que $\hat{\mathbf{L}}^*\hat{\mathbf{L}}^{*\top} = (\hat{\mathbf{L}}\mathbf{T})(\hat{\mathbf{L}}\mathbf{T})^\top = \hat{\mathbf{L}}\hat{\mathbf{L}}^\top$

- Os critérios para rotação ortogonal de fatores mais comumente utilizados são:
 - ▶ **Varimax** (Kaiser 1958): maximiza a variabilidade das cargas fatoriais dentro de cada fator — produz fatores com algumas cargas altas e outras próximas de zero, facilitando a interpretação;
 - ▶ **Quartimax** (Jobson, 1996): maximiza a variabilidade dos quadrados das cargas sobre todos os fatores — tende a produzir um fator geral com cargas altas;
 - ▶ **Rotação oblíqua** (Oblimin, Promax): permite correlação entre os fatores — mais realista em ciências humanas e da saúde, onde fatores raramente são independentes.

- Os escores dos fatores podem ser estimados para cada observação a partir de duas estratégias:

- ▶ **Mínimos quadrados ponderados**

$$\hat{F}_j = (\hat{\mathbf{L}}^\top \mathbf{\Psi}^{-1} \hat{\mathbf{L}})^{-1} \hat{\mathbf{L}}^\top \mathbf{\Psi}^{-1} \mathbf{z}_j,$$

para $j = 1, \dots, n$.

- ▶ **Método de regressão**

$$\hat{F}_j = \hat{\mathbf{L}}^\top \hat{\mathbf{P}}^{-1} \mathbf{z}_j,$$

para $j = 1, \dots, n$.

iv. Análise Fatorial Confirmatória (AFC)

- Enquanto a AFE *descobre* a estrutura fatorial, a **AFC testa** se uma estrutura fatorial pré-definida com base em teoria é compatível com os dados observados.
- É uma aplicação de **Modelos de Equações Estruturais (SEM)** restrita ao modelo de mensuração.
- Amplamente utilizada para validação de instrumentos e escalas em pesquisas na área de saúde, psicologia e ciências sociais.

Especificação do modelo

- Na AFC, o pesquisador especifica *a priori*:
 - ▶ Quantos fatores latentes existem
 - ▶ Quais variáveis observadas são indicadores de cada fator
 - ▶ Quais cargas fatoriais são **fixadas** em zero (variável não carrega naquele fator) e quais são **livres** para estimação
 - ▶ Se os fatores são ortogonais ou oblíquos (correlacionados)
- O modelo de mensuração da AFC é dado por:

$$\mathbf{X} = \mathbf{\Lambda}\boldsymbol{\xi} + \boldsymbol{\delta}, \quad (19)$$

em que $\mathbf{\Lambda}$ é a matriz de cargas (com zeros fixados), $\boldsymbol{\xi}$ é o vetor de fatores latentes e $\boldsymbol{\delta}$ é o vetor de erros de mensuração.

- A estimação na AFC é feita minimizando a discrepância entre a **matriz de covariância observada** S e a **matriz de covariância implícita pelo modelo** $\Sigma(\theta)$:

$$F(\theta) = \min_{\theta} d[S, \Sigma(\theta)] \quad (20)$$

- O método mais utilizado é a **Máxima Verossimilhança (ML)**, que sob normalidade multivariada leva ao estimador:

$$F_{ML} = \ln |\Sigma(\theta)| - \ln |S| + \text{tr}[S\Sigma^{-1}(\theta)] - p \quad (21)$$

- Quando a normalidade não é válida, utilizam-se estimadores robustos como MLR (máxima verossimilhança robusta).

- A adequação do modelo é avaliada por um conjunto de índices de ajuste:
 - ▶ χ^2 : testa $H_0 : \Sigma = \Sigma(\theta)$. Sensível ao tamanho amostral — raramente usado isoladamente.
 - ▶ **CFI** (Comparative Fit Index): $\geq 0,95$ indica bom ajuste
 - ▶ **TLI** (Tucker-Lewis Index): $\geq 0,95$ indica bom ajuste
 - ▶ **RMSEA** (Root Mean Square Error of Approximation): $\leq 0,06$ bom; $\leq 0,08$ aceitável
 - ▶ **SRMR** (Standardized Root Mean Square Residual): $\leq 0,08$ indica bom ajuste
- Recomenda-se reportar múltiplos índices — nenhum índice isolado é suficiente.

- Após o ajuste do modelo, avalia-se a **validade de construto** em dois níveis:
 - ▶ **Validade convergente**: os indicadores de um mesmo fator devem ter cargas padronizadas altas ($\geq 0,50$). Avaliada pela Variância Média Extraída (AVE):

$$AVE = \frac{\sum_{i=1}^p \lambda_i^2}{p}, \quad AVE \geq 0,50 \quad (22)$$

- ▶ **Validade discriminante**: fatores distintos devem ser suficientemente diferentes. Critério de Fornell-Larcker: AVE de cada fator deve ser maior do que o quadrado da correlação entre fatores.

- A **confiabilidade** dos fatores é avaliada pelo **Ômega de McDonald** (ω):

$$\omega = \frac{(\sum_{i=1}^p \lambda_i)^2}{(\sum_{i=1}^p \lambda_i)^2 + \sum_{i=1}^p \Psi_i} \quad (23)$$

- $\omega \geq 0,70$ indica confiabilidade adequada.
- O ω é preferível ao α de Cronbach, pois não assume cargas iguais entre os indicadores — suposição raramente sustentada na prática.

Modificação do modelo

- Se o ajuste for inadequado, os **índices de modificação** indicam quais parâmetros fixados poderiam ser liberados para melhorar o ajuste:
 - ▶ Cada índice de modificação estima a redução no χ^2 se aquele parâmetro fosse liberado
 - ▶ Modificações devem ser guiadas pela **teoria** — não apenas pelos índices
 - ▶ Modificações puramente empíricas sem justificativa teórica invalidam o caráter confirmatório da análise
- Alternativamente, modelos concorrentes podem ser comparados via:
 - ▶ Teste $\Delta\chi^2$ (para modelos encaixados)
 - ▶ AIC e BIC (para modelos não encaixados)

Sumário

- 1 Introdução
- 2 Conceitos Prévios
- 3 Álgebra Linear
- 4 Análise exploratória
- 5 Probabilidade
- 6 Inferência
- 7 Modelos Multivariados
- 8 Estrutura dos Dados
- 9 Técnicas de Classificação e Agrupamento**

i. Análise Discriminante

ii. Análise de Cluster

- As técnicas de classificação e agrupamento têm em comum o objetivo de **organizar observações em grupos**, mas diferem fundamentalmente em seu ponto de partida:
 - ▶ **Análise Discriminante**: os grupos são *conhecidos* — o objetivo é construir uma regra para classificar novas observações nesses grupos já existentes
 - ▶ **Análise de Cluster**: os grupos são *desconhecidos* — o objetivo é descobrir agrupamentos naturais nos dados sem qualquer informação prévia sobre sua estrutura
- Essa distinção é fundamental: a Análise Discriminante é **supervisionada**, enquanto a Análise de Cluster é **não supervisionada**.

i. Análise Discriminante

- Desenvolvida por Ronald Fisher em 1936, a **Análise Discriminante** é uma técnica multivariada cujo objetivo é encontrar combinações lineares das variáveis originais que melhor **separam grupos pré-definidos**.
- Tem dois propósitos principais:
 - ▶ **Descritivo**: identificar quais variáveis mais contribuem para a separação entre grupos
 - ▶ **Preditivo**: construir uma regra de classificação para alocar novas observações em um dos grupos

- Imagine que temos indivíduos classificados como *saudáveis* e *doentes*, com diversas medidas clínicas coletadas para cada um.
- A Análise Discriminante busca uma combinação linear dessas medidas — a **função discriminante** — que separe ao máximo os dois grupos.
- Essa função projetará cada indivíduo em um eixo, de forma que as distribuições dos dois grupos sejam tão separadas quanto possível.
- Um novo indivíduo será classificado no grupo cuja distribuição seja mais compatível com o seu valor projetado.

Diferença em relação à MANOVA

- **MANOVA:** testa se os grupos diferem nas variáveis dependentes — foco na inferência
- **Análise Discriminante:** dado que os grupos diferem, identifica *como* classificar novas observações e *quais* variáveis mais contribuem para a separação — foco na classificação e interpretação
- Na prática, as duas técnicas são complementares: a MANOVA precede a Análise Discriminante para confirmar que há diferença significativa entre os grupos antes de construir a regra de classificação.

- Sejam g grupos com vetores de médias $\mu_1, \dots, \mu_g$ e matriz de covariância comum Σ .
- A **função discriminante linear** de Fisher é uma combinação linear:

$$D = \mathbf{a}^\top \mathbf{X}, \quad (24)$$

em que $\mathbf{a}$ é o vetor de coeficientes discriminantes, escolhido de forma a **maximizar a razão entre a variância entre grupos e a variância dentro dos grupos**:

$$\max_{\mathbf{a}} \frac{\mathbf{a}^\top \mathbf{B} \mathbf{a}}{\mathbf{a}^\top \mathbf{W} \mathbf{a}}, \quad (25)$$

em que $\mathbf{B}$ é a matriz de variação entre grupos e $\mathbf{W}$ é a matriz de variação dentro dos grupos.

Matrizes entre e dentro dos grupos

- A **matriz de variação entre grupos** ($\mathbf{B}$) captura o quanto os centróides dos grupos diferem entre si:

$$\mathbf{B} = \sum_{k=1}^g n_k (\bar{\mathbf{x}}_k - \bar{\mathbf{x}})(\bar{\mathbf{x}}_k - \bar{\mathbf{x}})^\top \quad (26)$$

- A **matriz de variação dentro dos grupos** ($\mathbf{W}$) captura a dispersão dentro de cada grupo:

$$\mathbf{W} = \sum_{k=1}^g \sum_{i=1}^{n_k} (\mathbf{x}_{ki} - \bar{\mathbf{x}}_k)(\mathbf{x}_{ki} - \bar{\mathbf{x}}_k)^\top \quad (27)$$

- A solução do problema de maximização é obtida via autovalores e autovetores de $\mathbf{W}^{-1}\mathbf{B}$.

Número de funções discriminantes

- O número de funções discriminantes é $r = \min(p, g - 1)$, em que p é o número de variáveis e g é o número de grupos.
- Cada função discriminante captura uma dimensão independente de separação entre os grupos:
 - ▶ A **primeira função** maximiza a separação entre grupos
 - ▶ A **segunda função** maximiza a separação residual, ortogonal à primeira
 - ▶ E assim sucessivamente
- Os autovalores $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r$ indicam a contribuição relativa de cada função para a separação total entre grupos.

Suposições da LDA

- A Análise Discriminante Linear (LDA) requer as seguintes suposições:
 - ▶ **Normalidade multivariada** dentro de cada grupo: $\mathbf{X}|G = k \sim \mathcal{N}_p(\boldsymbol{\mu}_k, \boldsymbol{\Sigma})$
 - ▶ **Homogeneidade das matrizes de covariância**: $\boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \dots = \boldsymbol{\Sigma}_g = \boldsymbol{\Sigma}$
 - ▶ **Ausência de multicolinearidade** entre as variáveis preditoras
 - ▶ **Tamanho amostral adequado**: recomenda-se ao menos 5 observações por variável em cada grupo
- O **teste M de Box** avalia a homogeneidade das matrizes de covariância. Se rejeitado, utiliza-se a Análise Discriminante Quadrática (QDA).

Análise Discriminante Quadrática (QDA)

- Quando a suposição de homogeneidade das covariâncias é violada, utiliza-se a **QDA**, que permite matrizes de covariância distintas para cada grupo.
- A regra de classificação da QDA é quadrática nas variáveis preditoras:

$$d_k(\mathbf{x}) = -\frac{1}{2} \ln |\Sigma_k| - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^\top \Sigma_k^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) + \ln \pi_k, \quad (28)$$

em que π_k é a probabilidade a priori do grupo k .

- A observação é classificada no grupo k^* que maximiza $d_k(\mathbf{x})$.
- A QDA é mais flexível, mas exige maior tamanho amostral para estimar Σ_k para cada grupo.

Regra de classificação — LDA

- Sob as suposições da LDA, a regra de classificação ótima é a **função discriminante linear de Fisher**. Para dois grupos, uma nova observação $\mathbf{x}_0$ é classificada no grupo 1 se:

$$(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)^\top \hat{\Sigma}^{-1} \mathbf{x}_0 \geq \frac{1}{2}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)^\top \hat{\Sigma}^{-1} (\bar{\mathbf{x}}_1 + \bar{\mathbf{x}}_2) - \ln \frac{\pi_1}{\pi_2}, \quad (29)$$

e no grupo 2 caso contrário.

- As **probabilidades a priori** π_k refletem o conhecimento prévio sobre a prevalência de cada grupo — quando desconhecidas, utilizam-se as proporções amostrais.

Probabilidades posteriores

- Pela regra de Bayes, a **probabilidade posterior** de uma observação pertencer ao grupo k é:

$$P(G = k|\mathbf{x}) = \frac{\pi_k f_k(\mathbf{x})}{\sum_{j=1}^g \pi_j f_j(\mathbf{x})}, \quad (30)$$

em que $f_k(\mathbf{x})$ é a densidade multivariada do grupo k .

- A classificação é feita no grupo com maior probabilidade posterior.
- As probabilidades posteriores quantificam a **incerteza** da classificação — uma observação com probabilidades próximas entre grupos está na região de ambiguidade da fronteira de decisão.

Avaliação do classificador

- A qualidade da regra de classificação é avaliada pela **matriz de confusão**:

		Predito	
		Grupo 1	Grupo 2
2*Real	Grupo 1	VP	FN
	Grupo 2	FP	VN

- As métricas derivadas incluem:
 - ▶ **Acurácia:** $(VP + VN)/n$
 - ▶ **Sensibilidade:** $VP/(VP + FN)$ — capacidade de identificar o grupo 1
 - ▶ **Especificidade:** $VN/(VN + FP)$ — capacidade de identificar o grupo 2
- A avaliação por **resubstituição** é otimista — prefere-se a **validação cruzada leave-one-out (LOO)**, que classifica cada observação com base em um modelo treinado sem ela.

Coefficientes discriminantes padronizados

- Os **coeficientes discriminantes brutos** a dependem da escala das variáveis — não são diretamente comparáveis entre si.
- Os **coeficientes discriminantes padronizados** são obtidos multiplicando cada coeficiente pelo desvio padrão da variável correspondente:

$$a_j^* = a_j \cdot s_j \quad (31)$$

- Variáveis com maior $|a_j^*|$ contribuem mais para a função discriminante — são as mais importantes para separar os grupos.
- Alternativamente, as **cargas discriminantes** (correlação entre cada variável e a função discriminante) também são utilizadas para interpretação.

ii. Análise de Cluster

- A **Análise de Cluster** (ou análise de agrupamento) é uma técnica exploratória que busca **descobrir grupos naturais** em um conjunto de dados, sem qualquer informação prévia sobre a estrutura dos grupos.
- O objetivo é organizar as observações em grupos (clusters) de forma que:
 - ▶ Observações dentro do mesmo grupo sejam o mais **similares** possível entre si
 - ▶ Observações de grupos diferentes sejam o mais **distintas** possível entre si

- Diferentemente da Análise Discriminante, aqui **não sabemos** quantos grupos existem nem a qual grupo cada observação pertence.
- O algoritmo de cluster descobre essa estrutura diretamente dos dados.
- Exemplos de aplicação:
 - ▶ Identificar subtipos de indivíduos com perfis clínicos similares
 - ▶ Segmentar clientes com comportamentos de compra parecidos
 - ▶ Descobrir padrões em dados genômicos
 - ▶ Agrupar países com indicadores econômicos semelhantes
- É uma técnica **exploratória** — os resultados dependem das escolhas metodológicas e devem ser interpretados com cautela.

Medidas de distância e similaridade

- O conceito central da análise de cluster é a **distância** (ou similaridade) entre observações. As mais utilizadas são:

- ▶ **Distância Euclidiana:**

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{(\mathbf{x}_i - \mathbf{x}_j)^\top (\mathbf{x}_i - \mathbf{x}_j)} \quad (32)$$

- ▶ **Distância de Mahalanobis** (leva em conta a correlação entre variáveis):

$$d_M(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{(\mathbf{x}_i - \mathbf{x}_j)^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \mathbf{x}_j)} \quad (33)$$

- ▶ **Distância de Manhattan:** $d(\mathbf{x}_i, \mathbf{x}_j) = \sum_{k=1}^p |x_{ik} - x_{jk}|$

- A escolha da distância afeta diretamente os clusters formados.

Padronização dos dados

- Quando as variáveis têm escalas ou unidades diferentes, a distância euclidiana será dominada pelas variáveis com maior variância.
- Por isso, é **fortemente recomendado padronizar** os dados antes de calcular as distâncias:

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j} \quad (34)$$

- Após a padronização, todas as variáveis contribuem igualmente para o cálculo das distâncias.
- Alternativamente, a distância de Mahalanobis já incorpora a padronização e a correlação entre variáveis — não requer padronização prévia.

- Existem duas grandes famílias de métodos de cluster:
 - ▶ **Métodos Hierárquicos**: constroem uma sequência de agrupamentos aninhados, representada por um dendrograma. Não requerem a especificação prévia do número de clusters. Podem ser aglomerativos (de baixo para cima) ou divisivos (de cima para baixo).
 - ▶ **Métodos Não Hierárquicos** (particionais): dividem as observações em k clusters pré-especificados. O mais conhecido é o **k-means**. Requerem a especificação prévia do número de clusters k .

Cluster Hierárquico Aglomerativo

- O algoritmo hierárquico aglomerativo segue os seguintes passos:
 1. Cada observação começa como um cluster individual (n clusters)
 2. Calcula-se a matriz de distâncias entre todos os pares
 3. Une-se o par de clusters mais próximo em um único cluster
 4. Atualiza-se a matriz de distâncias
 5. Repete-se os passos 3 e 4 até restar um único cluster
- O resultado é representado por um **dendrograma** — um diagrama em árvore que mostra a sequência de fusões e as distâncias em que ocorreram.
- O número de clusters é definido pelo pesquisador ao “cortar” o dendrograma na altura desejada.

- A distância entre dois clusters pode ser calculada de diferentes formas — os chamados **métodos de ligação**:
 - ▶ **Ligação simples** (*single linkage*): distância mínima entre elementos dos dois clusters. Tende a produzir clusters alongados (efeito de encadeamento).
 - ▶ **Ligação completa** (*complete linkage*): distância máxima. Tende a produzir clusters compactos.
 - ▶ **Ligação média** (*average linkage*): média das distâncias entre todos os pares.
 - ▶ **Método de Ward**: minimiza a variância total dentro dos clusters após cada fusão — geralmente produz clusters mais homogêneos e é o mais recomendado na prática.

Cluster k-means

- O algoritmo **k-means** é o método particionai mais utilizado. Dado o número k de clusters, o algoritmo:
 1. Inicializa k centróides aleatoriamente
 2. Aloca cada observação ao cluster cujo centróide é mais próximo (distância euclidiana)
 3. Recalcula os centróides como a média das observações em cada cluster
 4. Repete os passos 2 e 3 até a convergência (sem mudança de alocação)
- O k-means minimiza a **soma dos quadrados intra-cluster** (WCSS):

$$\text{WCSS} = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} ||\mathbf{x}_i - \bar{\mathbf{x}}_k||^2 \quad (35)$$

Escolha do número de clusters k

- A escolha de k é uma das decisões mais importantes na análise de cluster. Os critérios mais utilizados são:
 - ▶ **Método do cotovelo** (*elbow method*): plota-se o WCSS em função de k e busca-se o ponto de inflexão — onde a redução do WCSS começa a diminuir expressivamente
 - ▶ **Índice de silhueta**: mede a coesão intra-cluster e a separação inter-cluster para cada observação. Valores próximos de 1 indicam boa alocação; próximos de 0 indicam ambiguidade.
 - ▶ **Gap statistic**: compara o WCSS observado com o esperado sob uma distribuição de referência uniforme
 - ▶ **Índice de Calinski-Harabasz**: razão entre a variância entre clusters e a variância dentro dos clusters

- O **índice de silhueta** de uma observação i é definido como:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \quad (36)$$

em que:

- ▶ $a(i)$: distância média de i a todas as demais observações do *mesmo* cluster (coesão)
- ▶ $b(i)$: distância média mínima de i às observações do cluster *vizinho* mais próximo (separação)
- $s(i) \in [-1, 1]$: quanto mais próximo de 1, melhor a alocação. Valores negativos indicam má alocação.
- A **silhueta média** sobre todas as observações é usada para comparar soluções com diferentes valores de k .

- Para métodos hierárquicos, a qualidade do dendrograma é avaliada pelo **coeficiente de correlação cofenética**:

$$r_{\text{cof}} = \text{Cor}(d_{ij}, c_{ij}), \quad (37)$$

em que d_{ij} é a distância original entre as observações i e j , e c_{ij} é a distância cofenética (altura no dendrograma em que i e j foram unidos pela primeira vez).

- Valores próximos de 1 indicam que o dendrograma preserva bem as distâncias originais — o método de ligação escolhido é adequado.
- Recomenda-se calcular o coeficiente cofenético para diferentes métodos de ligação e escolher o que produzir o maior valor.

Validação externa dos clusters

- Quando existe um critério externo conhecido (como um diagnóstico clínico), é possível avaliar o quanto os clusters concordam com esse critério.
- O **Índice de Rand ajustado** mede a concordância entre duas partições:

$$ARI = \frac{\text{Concordâncias observadas} - \text{Concordâncias esperadas}}{\text{Concordâncias máximas} - \text{Concordâncias esperadas}} \quad (38)$$

- $ARI = 1$: concordância perfeita. $ARI = 0$: concordância aleatória.
- A validação externa é importante para verificar se os clusters descobertos têm correspondência com estruturas reais conhecidas — sem que essa informação tenha sido usada na formação dos grupos.

Interpretação dos clusters

- Após definir os clusters, é essencial **caracterizá-los** para que façam sentido substantivo:
 - ▶ **Centróides**: os valores médios de cada variável em cada cluster revelam o perfil típico de cada grupo
 - ▶ **Boxplots por cluster**: mostram a distribuição de cada variável em cada grupo e facilitam a comparação
 - ▶ **Testes de diferença**: ANOVA ou Kruskal-Wallis para variáveis contínuas; qui-quadrado para variáveis categóricas — verificam se os clusters diferem significativamente nas variáveis de interesse
 - ▶ **Biplot no espaço PCA**: projeta as observações e os centróides dos clusters nas duas primeiras componentes principais, facilitando a visualização

Limitações da Análise de Cluster

- A Análise de Cluster é uma ferramenta exploratória poderosa, mas apresenta limitações importantes:
 - ▶ **Subjetividade:** a escolha do método de ligação, da medida de distância e do número de clusters afeta diretamente os resultados
 - ▶ **Sensibilidade a outliers:** observações atípicas podem distorcer os clusters, especialmente no k-means
 - ▶ **Ausência de teste formal:** não há um teste estatístico que confirme se os clusters encontrados são “reais” ou produto do acaso
 - ▶ **Reprodutibilidade:** o k-means depende da inicialização aleatória dos centróides — diferentes inicializações podem levar a soluções diferentes
- Recomenda-se usar múltiplos métodos e verificar a estabilidade dos resultados.

Obrigado

vinicius@osterne.com

| www.viniciusosterne.com