

Disciplina:

ANÁLISE DE SOBREVIVÊNCIA

Professora: Patrícia de Sousa Ilambwetsi

Bacharel em Estatística pela UFOP

Mestre em Estatística pela UFV

Doutora em Estatística pela UFV

Especialista em Ciências de Dados e Big Data pela PUC Minas



Conteúdo programático

Unidade 1 – Conceitos Básicos para Análise de Sobrevida

Unidade 2 – Métodos Não Paramétricos e Paramétricos

Unidade 3 – Modelos de Regressão para Análise de Sobrevida

Unidade 4 – Testes de Vidas Acelerados

Distribuição dos pontos:

- Exercícios práticos: 4 exercícios totalizando 40 pontos (entrega semanal)
- Relatório Final: 60 pontos (entrega a ser definida pelo professor)

Roteiro

Unidade 2 – Estimação Não Paramétrica e Paramétrica

2.1 Estimação Não Paramétrica

- Estimador Empírico
- Estimador Kaplan-Meier
- Estimador de Nelson Aalen
- Estimador de Kernell

2.2 Estimação Paramétrica

- Método Exponencial
- Método Weibull
- Método Log-Normal

Estimação Não Paramétrica

Estimação Não Paramétrica

Método Não Paramétrico

Refere-se a métodos que **não** assumem **distribuição específica** para o tempo de sobrevivência.

Esses métodos são baseados apenas nos dados observados.

Eles são especialmente úteis quando não há conhecimento prévio ou evidência clara sobre a **distribuição do tempo** até o evento (falha).

Estimação Não Paramétrica

Características

- Não assumem distribuição de probabilidade para o tempo de sobrevivência;
- Lida diretamente com censura à direita, um fenômeno comum em dados de sobrevivência.
- Estimam a função de sobrevivência $S(t)$ e a função de risco acumulado $\Lambda(t)$.

Estimação Não Paramétrica

Vantagem

- Funciona bem com **dados censurados**, onde o tempo exato do evento não é conhecido para todas as observações.
- Fornece estimativas iniciais que podem ser usadas para **validar** suposições de **modelos paramétricos** ou **semiparamétricos**.
- Adequado para situações onde o **comportamento** dos dados é **desconhecido** ou complicado.

Estimação Não Paramétrica

Limitações

- **Não** fornecem uma formulação analítica para **previsão** dos tempos de sobrevivência;
- A **comparação** de múltiplos grupos pode ser **limitada** em poder estatístico quando as amostras **são pequenas**;
- O teste Log-Rank é **sensível** à forma da **função de risco**, mas pode ser menos eficaz se as diferenças entre os grupos variam ao longo do tempo.

OBS: Sensibilidade refere-se à probabilidade de um teste dar um resultado positivo quando realmente é positivo.

Estimação Não Paramétrica

Aplicações

- **Medicina:** Avaliação de tratamentos em estudos clínicos;
- **Engenharia:** Análise da durabilidade de equipamentos;
- **Economia:** Estudo do tempo de sobrevivência de empresas;
- **Ciências Sociais:** Avaliação da duração de eventos sociais, como casamentos ou empregos.

Estimação Não Paramétrica

Estimadores Não Paramétrico

Na ausência de censura

- Estimador empírico

Na presença de censura

- Estimador de Kaplan-Meier (1958)
- Estimador de Nelson-Aalen (1972)
- Estimador de Kernel (Para o Risco Instantâneo)

Estimador Empírico

Estimação Não Paramétrica

Estimação na Ausência de Censura

O método de **estimação empírico** é uma abordagem básica que utiliza as **frequências observadas** nos dados para calcular diretamente as **probabilidades de sobrevivência** e **taxa de falha instantânea** na ausência de censura.

Não atribui suposições sobre a distribuição dos tempos de sobrevivência

Estimação Não Paramétrica

Estimação na Ausência de Censura

Função de Sobrevivência Empírica

$$\hat{S}(t) = \frac{n^{\circ} \text{ de observações que não falharam até o tempo } t}{n^{\circ} \text{ total de observações no estudo}}$$

$\hat{S}(t)$ é uma função escada com degraus nos tempos observados de falha de tamanho $1/n$, em que n é o tamanho da amostra.

Estimação Não Paramétrica

Estimação na Ausência de Censura

Taxa de Falha Instantânea Empírica

$$\hat{h}(t) = \frac{n^{\circ} \text{ de falhas observadas em um intervalo de tempo } t + k}{n^{\circ} \text{ de observações que não falharam no tempo } t}$$

Estimação Não Paramétrica

Estimação na Ausência de Censura

Vantagem

- A estimativa é baseada diretamente nos dados observados, sem necessidade de modelos complexos.
- Não depende de suposições sobre a forma ou características da distribuição dos tempos de sobrevivência.
- Fácil de entender e interpretar, tornando-a útil para análises exploratórias iniciais.
- Eficaz para conjuntos de dados pequenos ou onde não há censura

Estimação Não Paramétrica

Estimação na Ausência de Censura

Limitações

- **Inadequado para Dados Censurados**
- **Perda de Informação** por não aproveitar os dados censurados
- **Estima apenas probabilidades simples de sobrevivência** sem fornecer informações sobre risco acumulado ou taxas de risco instantâneas
- **Menos informativo e eficiente** do que os métodos de Kaplan-Meier ou Nelson-Aalen.
- **Não permitem a extrapolação** para além do intervalo observado

Estimação Não Paramétrica


Estimação na Ausência de Censura

Quando Usar o Método de Estimação Empírico

- Quando é necessário explorar o **risco acumulado**.
- Como base para análises avançadas, como por exemplo modelos de regressão de Cox.

Exemplo: Estimação não Paramétrica na Ausência de Censura

Histograma do tempo de falha observados de 45 pacientes acompanhados por 8 anos




Estimação Não Paramétrica

Exemplo: Qual é a probabilidade de sobrevivência no tempo de 4 anos?

$$\begin{aligned}\hat{S}(4) &= \frac{\# \text{ não falhar até } t = 4}{\# \text{ total no estudo}} \\ &= \frac{45 - (2 + 3 + 10 + 16)}{45} = \frac{14}{45} = 0,31\end{aligned}$$

31% dos pacientes sobrevivem mais do que 4 anos

Distribuição do tempo de falha de 45 pacientes




Estimação Não Paramétrica

Exemplo: Estimativa para a taxa de falha no período compreendido entre 5 e 6 anos é:

$$\begin{aligned}\hat{h}([5,6)) &= \frac{\# \text{ falhar } [5, 6)}{\# \text{ não falha } t = 5} \\ &= \frac{7}{45 - (33)} = \frac{7}{12} = 0,583\end{aligned}$$

58% dos pacientes irá falhar em um período de um ano, compreendido entre [5; 6).

Distribuição do tempo de falha de 45 pacientes



Função de Sobrevivência e Taxa de Falha Empírica para os 45 pacientes acompanhados por 8 anos

t	Intervalo	Sobrevivência	Taxa de falha (1/ano)
0	0 ┤ 1	1,00	0,04
1	1 ┤ 2	0,96	0,07
2	2 ┤ 3	0,89	0,25
3	3 ┤ 4	0,67	0,53
4	4 ┤ 5	0,31	0,14
5	5 ┤ 6	0,27	0,58
6	6 ┤ 7	0,11	0,80
7	7 ┤ 8	0,02	1,00

Estimador de Kaplan-Meier

Estimação Não Paramétrica

Estimador de Kaplan-Meier

É o método não paramétrico usado em análise de sobrevivência para **estimar a função de sobrevivência $S(t)$** ao longo do tempo t na presença de **dados censurados**.

Também é chamado de estimador produto-limite

Na ausência de censura se reduz ao estimador empírico

Estimação Não Paramétrica

Estimador de Kaplan-Meier

Matematicamente, a **função de sobrevivência** $S(t)$ estimada é expressa por:

$$\hat{S}(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i} \right)$$

em que t_i é o tempo em que ocorreram as falhas; d_i é o número de falhas no tempo t_i ; n_i é o número de indivíduos ou produtos em risco (que não falharam e não foram censurados) até o instante imediatamente anterior a t_i .

Estimação Não Paramétrica

Estimador de Kaplan-Meier

Propriedades

- Estimador de Máxima Verossimilhança (EMV) para $S(t)$ (encontrar os parâmetros que melhor se ajustam aos dados observados de sobrevivência)
- Não viciado para grandes amostras (se aproxima da verdadeira curva de sobrevivência da população)
- Normalidade assintótica

Aplicação: comparação de curvas de sobrevivência entre grupos, avaliação de tratamentos médicos, etc.

Estimação Não Paramétrica

Estimador de Kaplan-Meier

Vantagens

- É aplicado na presença de censura
- Intuitivo e fácil de interpretar
- Pode ser usado em conjunto com testes estatísticos (como o teste de Log-Rank) para comparar curvas de sobrevivência

Estimação Não Paramétrica

Estimador de Kaplan-Meier

Limitações

- Não permite modelar o impacto de covariáveis, como idade, sexo ou características clínicas
- O foco está na **função de sobrevivência** $S(t)$, sem estimar diretamente o risco acumulado ou a taxa de risco instantânea
- **Estimativas menos confiável** se muitos dados forem censurados.

Estimação Não Paramétrica

Análise Gráfica do Estimador de Kaplan-Meier

A curva em degraus mostra a probabilidade estimada de sobrevivência ao longo do tempo

- Cada degrau representa a ocorrência de um evento (como falha ou morte).
- Os intervalos de confiança exibidos no gráfico indicam a incerteza em torno da estimativa da sobrevivência.

Estimação Não Paramétrica

Análise Gráfica do Estimador de Kaplan-Meier

- **Comparação entre grupos:** Se uma curva está consistentemente acima da outra, isso indica uma maior probabilidade de sobrevivência no tempo para aquele grupo

Estimação Não Paramétrica

Estimador de Kaplan-Meier

Quando Usar o Método de Estimação

- Quando o objetivo é visualizar a **sobrevivência ao longo do tempo**
- Para comunicação de resultados em termos de probabilidade de sobrevivência.

Estimador de Nelson-Aalen

Estimação Não Paramétrica

Estimador de Nelson-Aalen

O estimador de Nelson-Aalen é interpretado como uma estimativa do **risco acumulado** ou da **função de risco acumulado** ao longo do tempo em um estudo de sobrevivência.

Risco Acumulado

- Representa a soma cumulativa das taxas de risco ao longo do tempo.
- A taxa de risco é a **probabilidade instantânea** de o evento ocorrer em um pequeno intervalo de tempo **dado que** ele ainda não ocorreu.

Estimação Não Paramétrica

Estimador de Nelson-Aalen

Matematicamente, a **Função de Risco Acumulado** estimada é expressa por:

$$\hat{\Lambda}(t) = \sum_{t_i \leq t} \frac{d_i}{n_i}$$

em que t_i é o tempo em que pelo menos ocorre uma falha; d_i é o número de falhas no tempo t_i ; n_i é o número de indivíduos ou produtos em risco até o instante imediatamente anterior a t_i .

Estimação Não Paramétrica

Estimador de Nelson-Aalen

Interpretação:

- Cada termo d_i/n_i representa a taxa de falhas em um tempo t_i .
- A soma acumulada dessas taxas resulta no risco acumulado até o tempo t .
- O risco acumulado, $\hat{\Lambda}(t)$ indica a **propensão total** de um indivíduo em risco **ter experimentado a falha (evento)** até o tempo t .

Estimação Não Paramétrica

Estimador de Nelson-Aalen

Interpretação:

- Se $\hat{\Lambda}(t)$ grande sugere maior **exposição acumulada ao risco** até t .
OBS: não é probabilidade, pois pode ultrapassar o valor 1.
- Um **crescimento rápido** na $\hat{\Lambda}(t)$ sugere períodos de maior risco de ocorrência do evento.
- Quando $\hat{\Lambda}(t)$ apresenta **mudanças mais lentas**, indica períodos de **menor** risco acumulado.

Estimação Não Paramétrica

Estimador de Nelson-Aalen

A função de **risco acumulado** $\hat{\Lambda}(t)$ está relacionada à função de sobrevivência $\hat{S}(t)$ pela expressão:

$$\hat{S}(t) = e^{-\hat{\Lambda}(t)}$$

Interpretação:

- À medida que o **risco acumulado aumenta**, a probabilidade de **sobrevivência diminui exponencialmente**.

Estimação Não Paramétrica

Estimador de Nelson-Aalen

Característica

- Funciona bem mesmo em cenários com censura, desde que a censura seja não-informativa.
- **Conexão com Kaplan-Meier:** O Nelson-Aalen estima o risco acumulado $\hat{\Lambda}(t)$, enquanto o Kaplan-Meier estima a sobrevivência $\hat{S}(t)$.

Vantagem: Estima diretamente o risco acumulado $\hat{\Lambda}(t)$, que é útil para descrever a probabilidade cumulativa de ocorrer uma falha.

Estimação Não Paramétrica

Estimador de Nelson-Aalen

Limitações

- O risco acumulado $\hat{\Lambda}(t)$ é mais difícil de interpretar em comparação com a função de sobrevivência $\hat{S}(t)$
- **Não estima** a função de sobrevivência **diretamente**
- **Menos informativo** se poucos eventos forem observados
- **Mais sensível** a variações em pequenos conjuntos de dados
- **Não inclui covariáveis** importantes no estudo.

Estimação Não Paramétrica

Análise Gráfica do Estimador de Nelson-Aalen

Inclinação no Gráfico

- Uma inclinação íngreme em $\hat{\Lambda}(t)$ reflete um aumento rápido no risco acumulado (mais eventos em menos tempo).
- Uma inclinação suave indica um aumento mais gradual do risco.

Degaus no Gráfico

- Cada degrau corresponde a um tempo em que um ou mais eventos ocorreram.
- A altura do degrau é proporcional à fração d_i/n_i .

Estimação Não Paramétrica

Estimador de Nelson-Aalen

Quando Usar o Método de Estimação

- **Exploração Inicial:** para entender padrões básicos nos dados antes de aplicar métodos mais avançados
- **Amostras Pequenas Sem Censura:** ideal para estudos simples onde não há censura e o tamanho da amostra é pequeno

Estimador de Kernell

Estimação Não Paramétrica

Estimador de Kernell

O estimador de kernel é uma técnica não paramétrica usada para calcular a **taxa de risco instantânea $h(t)$** em análise de sobrevivência exibindo como o risco varia ao longo do tempo.

Esse método usa a técnica de **suavização** para estimar a **função densidade de sobrevivência $f(t)$** a partir dos tempos observados.

Proporciona uma **visão contínua e detalhada** da probabilidade de ocorrência de falha no instante t , dado que o indivíduo sobreviveu até t .

Estimação Não Paramétrica

Estimador de Kernell

Matematicamente, a taxa de risco instantânea ($h(t)$) é expressa por:

$$\hat{h}(t) = \frac{\sum_{i=1}^n K\left(\frac{t - t_i}{k}\right) d_i}{k \sum_{i=1}^n K\left(\frac{t - t_i}{k}\right) n_i}$$

em que K é a função kernel (ex.: Gaussiana ou Epanechnikov); k é a largura de banda para suavização; t_i é o tempo em que pelo menos ocorre uma falha; t o tempo total do estudo; d_i é o número de falhas no tempo t_i ; n_i é o número de indivíduos ou produtos em risco até o instante imediatamente anterior a t_i

Estimação Não Paramétrica

Estimador de Kernell

Característica

- Gera estimativas suaves do risco instantâneo.
- Útil para detectar padrões locais no risco instantâneo por ser **mais sensível** a pequenas variações.
- Pode lidar com dados censurados, mas requer mais **complexidade nos cálculos**, e por isso, menos usado que Kaplan-Meier ou Nelson-Aalen.

Vantagem: Permite detectar padrões locais no risco ou densidade de sobrevivência em dados com censura.

Estimação Não Paramétrica

Estimador de Kernell

Limitações

- Difícil encontrar os valores ideais para k , o que pode levar a resultados subótimos
- Quando há poucos eventos ou **muitos dados censurados**, as estimativas podem ser instáveis

Estimação Não Paramétrica

Análise Gráfica do Estimador de Kernell

Curva no Gráfico

- A curva resultante representa a taxa de risco instantânea estimada, exibindo como o risco varia ao longo do tempo.
- Picos indicam momentos de maior risco de ocorrência do evento.

Variação do Risco

- Pode revelar mudanças no risco ao longo do tempo, como períodos de risco elevado ou estável

Estimação Não Paramétrica

Estimador de Kernell

Quando Usar o Método de Estimação

- **Identificar a variação do risco de falha** ou evento em momentos específicos do tempo. Exemplo: Determinar períodos de maior risco de morte após uma cirurgia
- Em situações onde os tempos de sobrevivência **não seguem distribuição conhecida**.
- Para identificar **flutuações no risco** que podem ser mascaradas por métodos menos sensíveis.

Teste de Log-Rank

Estimação Não Paramétrica

Teste Log-Rank

O teste de Log-Rank é um teste estatístico utilizado para **comparar** as **funções de sobrevivência** de dois ou mais grupos.

Objetivo

Verificar se há uma diferença significativa na probabilidade de sobrevivência entre os grupos ao longo do tempo.

Hipótese

H_0 : Não há diferença entre as funções de sobrevivência

H_1 : Existe diferença entre as funções de sobrevivência

Estimação Não Paramétrica

Teste Log-Rank

Estatística do Teste

A estatística de teste χ^2 do Log-rank é dada por:

$$\chi^2 = \frac{\left(\sum_{i=1}^k (O_i - E_i)\right)^2}{\sum_{i=1}^k V_i}$$

em que

O_i : número de eventos observados no grupo i em cada intervalo de tempo

E_i : Número de eventos esperados no grupo i sob a hipótese nula, calculado considerando o total de indivíduos em risco em todos os grupos.

V_i : Variância associada à diferença entre o número de eventos observados (O_i) e esperados (E_i).

k : Número total de intervalos de tempos ou eventos

Estimação Não Paramétrica

Teste Log-Rank

Interpretação da Estatística do Teste

- A estatística χ^2 é comparada a uma distribuição qui-quadrado (χ^2) com $g - 1$ graus de liberdade, onde g é o número de grupos.

Resultados

- Retorna um *valor* — p , que indica se rejeitamos ou não H_0
- *valor* — $p < \text{nível de significância } (\alpha)$ rejeitamos a hipótese nula H_0 de que as curvas de sobrevivência dos grupos são iguais

Estimação Não Paramétrica

Teste Log-Rank

Vantagem:

É robusto e amplamente utilizado quando se deseja comparar grupos sem especificar modelos paramétricos.

Limitação:

Assume que as proporções de sobrevivência entre os grupos são constantes ao longo do tempo (**proporcionalidade dos riscos**).

Não permite a comparação múltipla dos grupos para dados de sobrevivência

Teste de Wilcoxon-Breslow

Estimação Não Paramétrica

Teste Wilcoxon-Breslow

O teste de Wilcoxon-Breslow é um teste estatístico não paramétrico usado para **comparar as curvas de sobrevivência** de dois ou mais grupos.

Objetivo

Verificar se há uma diferença significativa nas probabilidades de sobrevivência entre os grupos atribuindo mais peso aos primeiros tempos.

Hipótese

H_0 : Não há diferença entre as curvas de sobrevivência

H_1 : Existe diferença entre as curvas de sobrevivência

Estimação Não Paramétrica

Teste Wilcoxon-Breslow

Estatística do Teste

O teste é baseado no rank (ordenação) dos tempos de sobrevivência, ajustado pela censura dado por:

$$w = \sum_{i=1}^k w_i \left(d_{1i} - \frac{n_{1i}}{n_i} d_i \right)$$

em que

k = número de tempos únicos de falha

w_i = peso em cada tempo (Wilcoxon: $w_i = n_i$ número de indivíduos em risco)

d_{1i} = nº de eventos no grupo 1 no tempo t_i

d_i = nº total de eventos no tempo t_i

n_{1i} = nº em risco no grupo 1

n_i = nº total em risco

Estimação Não Paramétrica

Teste Wilcoxon-Breslow

Interpretação da Estatística do Teste

- A estatística W é comparada a uma distribuição Normal

Resultados

- Retorna um *valor* — p , que indica se rejeitamos ou não H_0
- *valor* — $p < \text{nível de significância } (\alpha)$ rejeitamos a hipótese nula H_0 de que as curvas de sobrevivência dos grupos são iguais

Estimação Não Paramétrica

Teste Wilcoxon-Breslow

Vantagem:

Dá mais importância aos eventos precoces

Útil quando o risco não é proporcional

Limitação:

Se um grupo tem mais censura no início, o teste pode ficar enviesado.

Menos amplamente usado que o Log-rank por ser menos potente quando as curvas divergem no final

Aplicação para Estimação Não Paramétrica

Estimação Não Paramétrica

Estimador de Kaplan-Meier

Exemplo: Dados de Hepatite (Gregory *et al.*, 1976)

- Pacientes com Hepatite Viral Aguda;
- **Objetivo:** investigar o efeito da terapia com esteróide;
- **Amostra:** 29 pacientes com esta doença foram aleatorizados para receber um placebo ou o **tratamento** com esteróide.
- Cada paciente foi acompanhado por 16 semanas até a morte (evento de interesse) ou até a perda do acompanhamento (censura).

Exemplo de Hepatite (Gregory et al., 1976) no Python

Os tempos de sobrevivência observados em semana para os dois grupos (+ indica censura)

Grupo	Tempo de sobrevivência em semanas
Controle	1+, 2+, 3, 3, 3+, 5+, 5+, 16+, 16+, 16+, 16+, 16+, 16+, 16+, 16+
Esteróide	1, 1, 1, 1+, 4+, 5, 7, 8, 10, 10+, 12+, 16+, 16+, 16+

Colosimo, Enrico Antonio. Análise de sobrevivência aplicada. São Paulo Blucher 2006.

Exemplo de Hepatite (Gregory et al., 1976) no Python

✓ Passo 1: Configurar o ambiente

Certifique-se de que você tem a biblioteca `lifelines` instalada. Caso contrário, use o seguinte comando:

```
pip install lifelines
```

✓ Passo 2: Código *Python*

Importando as funções

```
[38] import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from lifelines import KaplanMeierFitter
from lifelines import NelsonAalenFitter
from lifelines.statistics import logrank_test
from scipy.stats import gaussian_kde
```

Exemplo de Hepatite (Gregory et al., 1976) no Python

▼ Inserir dados e separar por grupos

```
[39] # Simulação de dados
data = pd.DataFrame({
    "time": [1, 2, 1, 1, 3, 3, 3, 1, 11, 5, 5, 4, 5, 7, 8, 16, 16, 10, 10, 16, 16, 16, 12, 16, 16, 16, 16, 16, 16],
    "event": [0, 0, 1, 1, 1, 1, 0, 1, 0, 0, 0, 0, 1, 1, 1, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0], # 1 = evento ocorreu, 0 = censurado
    "group": ["A", "A", "B", "B", "A", "A", "A", "A", "B", "B", "A", "A", "B", "B", "B", "B", "A", "A", "B", "B", "A", "A", "A", "B", "B", "A", "B", "A", "A"]
})

# Separação dos grupos
group_a = data[data["group"] == "A"]
group_b = data[data["group"] == "B"]
#print(group_a)
#print(group_b)
```

Exemplo de Hepatite (Gregory et al., 1976): Estimação da Função de Sobrevivência por Kaplan-Meier no Python


```
[43] # Estimador de Kaplan-Meier para cada grupo
    kmf_a = KaplanMeierFitter()
    kmf_b = KaplanMeierFitter()

    # Ajustar os modelos
    kmf_a.fit(durations=group_a["time"], event_observed=group_a["event"], label="Controle")
    kmf_b.fit(durations=group_b["time"], event_observed=group_b["event"], label="Esteróide")

    # Visualização
    plt.figure(figsize=(10, 6))
    kmf_a.plot_survival_function(ci_show=True)
    kmf_b.plot_survival_function(ci_show=True)
    plt.title("Função de Sobrevivência Estimada (Kaplan-Meier)")
    plt.xlabel("Tempo (meses)")
    plt.ylabel("Probabilidade de Sobrevivência")
    plt.grid(True)
    plt.show()
```

Exemplo de Hepatite (Gregory et al., 1976): Estimação por Kaplan-meier

Função de sobrevivência estimada por Kaplan-Meier para os dois grupos: controle e esteróide



95% dos pacientes no grupo controle e 85% do grupo esteróide ainda não falharam após 2 meses

Exemplo de Hepatite (Gregory et al., 1976): Estimação por Kaplan-meier

Tabela da Função de Sobrevivência estimada para os dois grupos: placebo e esteróide

```
[ ] # Ajustar os modelos
kmf_a.fit(durations=group_a["time"], event_observed=group_a["event"], label="Controle")
print(kmf_a.survival_function_)
kmf_b.fit(durations=group_b["time"], event_observed=group_b["event"], label="Esteróide")
print(kmf_b.survival_function_)
```

Controle		Esteróide	
timeline		timeline	
0.0	1.000000	0.0	1.000000
1.0	0.937500	1.0	0.846154
2.0	0.937500	5.0	0.769231
3.0	0.793269	7.0	0.683761
4.0	0.793269	8.0	0.598291
5.0	0.793269	10.0	0.598291
10.0	0.694111	11.0	0.598291
12.0	0.694111	16.0	0.598291
16.0	0.694111		

Exemplo de Hepatite (Gregory et al., 1976): Estimação da Taxa Falha Acumulada por Nelson-Aalen no Python


```
[55] # Estimador de Nelson-Aalen para cada grupo
naf_a = NelsonAalenFitter()
naf_b = NelsonAalenFitter()

# Ajustar os modelos
naf_a.fit(durations=group_a["time"], event_observed=group_a["event"], label="Controle")
naf_b.fit(durations=group_b["time"], event_observed=group_b["event"], label="Esteróide")

# Visualização
plt.figure(figsize=(10, 6))
naf_a.plot_cumulative_hazard(ci_show=True)
naf_b.plot_cumulative_hazard(ci_show=True)
plt.title("Estimativa de Risco Acumulado (Nelson-Aalen)")
plt.xlabel("Tempo (meses)")
plt.ylabel("Risco Acumulado")
plt.grid(True)
plt.show()
```

Exemplo de Hepatite (Gregory et al., 1976): Estimação por Nelson-Aalen

Função de Taxa de Falha Acumulada estimada para os dois grupos: controle e esteróide



Pela inclinação no gráfico percebe-se um aumento rápido no risco acumulado de morte para o grupo esteróide

Exemplo de Hepatite (Gregory et al., 1976): Estimação da Taxa de Risco Instantânea por Kernell no Python

```
# Filtrar apenas os tempos e eventos observados em cada grupo

observed_times_a = group_a[data["event"] == 1]["time"].values #grupo controle
observed_times_b = group_b[data["event"] == 1]["time"].values #grupo esteróide

# Kernel Density Estimation (Estimador de Kernel)
kde_a = gaussian_kde(observed_times_a, bw_method='scott') # Suavização automática usando 'scott' grupo controle
kde_b = gaussian_kde(observed_times_b, bw_method='scott') # Suavização automática usando 'scott' grupo esteróide


# Criar valores de tempo para estimar a densidade
time_grid = np.linspace(0, max(group_a["time"]), 1000) # Valores entre 0 e o maior tempo

# Calcular a densidade estimada (taxa de risco instantânea)
risk_density_a = kde_a(time_grid)
risk_density_b = kde_b(time_grid)

# Plotar a taxa de risco instantânea
plt.figure(figsize=(10, 6))
plt.plot(time_grid, risk_density_a, label="Taxa de Risco Instantânea para o grupo Controle", color="blue")
plt.plot(time_grid, risk_density_b, label="Taxa de Risco Instantânea para o grupo Esteróide", color="red")
plt.title("Estimativa de Taxa de Risco Instantânea (Kernel)")
plt.xlabel("Tempo")
plt.ylabel("Taxa de Risco Instantânea")
plt.grid(True)
plt.legend()
plt.show()
```

Exemplo de Hepatite (Gregory et al., 1976): Estimação por Kernel

Função de Taxa de Risco Instantânea estimada para os dois grupos: controle e esteróide



Pacientes do **grupo esteróide** que sobreviveu 8 meses apresenta **3,5 vezes** mais chance de **falha instantânea** do que pacientes do **grupo controle**

Exemplo de Hepatite (Gregory et al., 1976): Comparação da Função de Sobrevivência para os dois grupos pelo teste de Log-Rank no Python

```
# Kaplan-Meier para visualização
kmf_a = KaplanMeierFitter()
kmf_b = KaplanMeierFitter()

plt.figure(figsize=(10, 6))
kmf_a.fit(durations=group_a["time"], event_observed=group_a["event"], label="Controle")
kmf_a.plot_survival_function(ci_show=True)
kmf_b.fit(durations=group_b["time"], event_observed=group_b["event"], label="Esteróide")
kmf_b.plot_survival_function(ci_show=True)

plt.title("Comparação das Funções de Sobrevivência (Kaplan-Meier)")
plt.xlabel("Tempo (meses)")
plt.ylabel("Probabilidade de Sobrevivência")
plt.grid(True)
plt.show()
```

Exemplo de Hepatite (Gregory et al., 1976): Comparação da Função de Sobrevivência para os dois grupos pelo teste de Logrank no Python


```
# Teste de Log-Rank
logrank_result = logrank_test(
    group_a["time"], group_b["time"],
    event_observed_A=group_a["event"], event_observed_B=group_b["event"]
)

# Exibindo o resultado do teste
print("Resultado do Teste de Log-Rank")
print(f"Estatística do teste: {logrank_result.test_statistic:.4f}")
print(f"Valor-p: {logrank_result.p_value:.4f}")

# Interpretação
if logrank_result.p_value < 0.05:
    print("Rejeitamos a hipótese nula: As curvas de sobrevivência são significativamente diferentes.")
else:
    print("Não rejeitamos a hipótese nula: Não há diferença significativa entre as curvas de sobrevivência.")
```

Exemplo de Hepatite (Gregory et al., 1976): Teste de Log-rank

Comparação da Função de Sobrevivência estimada para os dois grupos: controle e esteróide



Resultado do Teste de Log-Rank


Estatística do teste: 0.2220

Valor-p: 0.6375

Não rejeitamos a hipótese nula: Não há diferença significativa entre as curvas de sobrevivência.

Exemplo de Hepatite (Gregory et al., 1976): Teste de Wilcoxon

Comparação da Função de Sobrevivência estimada para os dois grupos: controle e esteróide



Resultado do Teste de Wilcoxon


Estatística do teste: 0.2670

p-valor: 0.6054

Resultado: Não rejeita H_0 (sem diferença significativa, $p \geq 0.05$)

Resumo

Resumo da Análise de Sobrevivência



Quadro Comparativo dos Estimadores Não Paramétricos

Aspecto	Empírico	Kaplan-Meier	Nelson-Aalen	Kernel
Estimativa Principal	$S(t)$: probabilidade de sobrevivência até t	$S(t)$: probabilidade acumulada de sobrevivência até t	$\Lambda(t)$: risco acumulado até t	$h(t)$: taxa de risco instantânea em t
Dados Censurados	Não suporta	Suporta	Suporta	Suporta, mas é sensível a muitos censuramentos
Curva Resultante	Em degraus	Em degraus	Em degraus ou contínua	Suave, contínua
Complexidade Computacional	Muito baixa	Baixa	Moderada	Alta
Aplicação Comum	Análises simples e exploratórias	Estudos clínicos, confiabilidade	Explorar padrões cumulativos de risco	Análises detalhadas de variação de risco

Estimação Paramétrica

Estimação Paramétrica

Método Paramétrico

É um método que pressupõe que o tempo até o evento de interesse segue uma distribuição de probabilidade específica: Exponencial, Weibull, Log-normal, Log-logístico, etc...

Esse tipo de análise permite:

- **modelar e prever** tempos de sobrevivência;
- **realizar inferências** com base em suposições explícitas sobre a forma da distribuição dos dados.

Estimação Paramétrica

Importância

- Fornece uma **descrição completa da distribuição** do tempo de sobrevivência.
- Permite obter a **estimativa de parâmetros** da distribuição, como médias, medianas, percentis e funções de risco.
- **Facilita previsões** baseadas em covariáveis.
- Muitas vezes têm **interpretações diretas e claras** devido à especificação da distribuição.

Estimação Paramétrica

Características

- O tempo de sobrevivência é modelado com base em distribuições.
- Os parâmetros do modelo são **estimados** usando **métodos de máxima verossimilhança**.
- Envolve a modelagem da função de sobrevivência $S(t)$, função de risco acumulado $\lambda(t)$ e a função de densidade $f(t)$.

Estimação Paramétrica

Limitações

- O modelo é sensível à **escolha incorreta** da distribuição facilitando estimativas enviesadas.
- A **estimativa** pode se tornar **menos precisa** quando há alta censura nos dados.
- Requer **análise preliminar** para determinar a distribuição mais apropriada.

Estimação Paramétrica

Aplicações

- **Medicina:** Estimar o tempo de sobrevivência de pacientes com base em tratamentos específicos ou características individuais.
- **Engenharia:** Avaliar a confiabilidade e vida útil de componentes mecânicos ou eletrônicos.
- **Economia:** Modelar tempos de desemprego ou duração de contratos.
- **Ecologia:** Analisar tempos até eventos biológicos como extinções ou migrações.

Estimação Paramétrica

Estimadores Paramétricos

- **Método Exponencial:** Taxa de risco constante no tempo
- **Método Weibull:** Pode modelar risco crescente ou decrescente
- **Método Log-normal:** Útil quando o log do tempo segue distribuição normal
- **Método Log-logístico:** Semelhante ao log-normal, mas com caudas mais pesadas

Estimação Paramétrica

Estimadores Paramétricos

- **Método Gompertz:** Muito usado em demografia e biologia
- **Método Gamma Generalizada:** Modelo flexível que inclui vários outros como casos especiais

Método Exponencial

Estimação Paramétrica

Método Exponencial

É o método paramétrico mais simples para análise de sobrevivência.

Ele assume que o tempo de sobrevivência segue uma distribuição exponencial, com uma **taxa de risco ou função de risco constante** ao longo do tempo.

Estimação Paramétrica

Método Exponencial

Função de Densidade de Probabilidade $f(t)$

Matematicamente, a **função de Densidade de Probabilidade Exponencial $f(t)$** é dada por:

$$f(t) = \lambda e^{-\lambda t}$$

A função densidade descreve a probabilidade de falha em um instante específico t em que $\lambda > 0$ é o parâmetro da taxa de risco (taxa de eventos por unidade de tempo)

Estimação Paramétrica

Método Exponencial

Função de Sobrevivência $S(t)$

Matematicamente, a **função de sobrevivência $S(t)$** estimada é dada por:

$$\hat{S}(t) = P(T > t) = e^{-\lambda t}$$

$S(t)$ é a probabilidade de o evento não ter ocorrido até o tempo t

Estimação Paramétrica

Método Exponencial

Função de Risco $h(t)$

Matematicamente, a **função de Risco $h(t)$** estimada é dada por:

$$\hat{h}(t) = \frac{f(t)}{S(t)} = \lambda$$

OBS: A taxa de risco ou **função de risco é constante**.

Estimação Paramétrica

Método Exponencial

Propriedades

- A taxa de risco é constante e não depende do tempo

$$h(t) = \lambda$$

- Exibe **falta de Memória** que é a probabilidade de falha em um intervalo futuro não depender de quanto tempo o indivíduo já sobreviveu.

$$P(T > t + s | t > s) = P(T > t)$$

Estimação Paramétrica

Método Exponencial

Propriedades

- O tempo médio de sobrevivência é o inverso da taxa de risco

$$E(T) = \frac{1}{\lambda}$$

Estimação Paramétrica

Método Exponencial

Estimação do Parâmetro λ

O estimador de máxima verossimilhança (MLE) para λ é dado por:

$$\hat{\lambda}(t) = \frac{n}{\sum_{i=1}^n t_i}$$

em que

n é o tamanho da amostra

t_i é o tempo de sobrevivência no tempo i

Estimação Paramétrica

Método Exponencial

Interpretação do Parâmetro λ

$\lambda > 0$: fornece a frequência média de falhas.

Estimação Paramétrica

Método Exponencial

Análise Gráfica para Qualidade do Modelo

- **Sobreposição** das Curvas de Sobrevivência de **Kaplan-Meier** e **Exponencial** devem se **alinhar razoavelmente bem** se a distribuição exponencial for adequada,
- **Gráfico da Função de Risco Acumulado:** Uma linha reta na horizontal sugere que a distribuição exponencial é adequada.

Estimação Paramétrica

Método Exponencial

Análise Gráfica para Qualidade do Modelo

- **Gráficos Log-Log:** A linearização de $\ln(-\ln(S(t)))$ versus $\ln(t)$ ajuda a verificar a adequação ao modelo Exponencial.

Interpretação:

Pontos em **linha reta** confirmam que os dados seguem bem a distribuição Exponencial

Pontos **com desvios significativos** indicam que o modelo Exponencial não é adequado

Estimação Paramétrica

Método Exponencial

Vantagens

- As fórmulas são **simples e diretas**, facilitando a interpretação.
- Requer apenas a **estimação de um parâmetro λ** para modelagem.
- Serve como um **modelo de referência** para avaliar a adequação de modelos mais complexos.

Estimação Paramétrica

Método Exponencial

Limitações

- **Taxa de Risco Constante** o que **não é favorável** para muitos cenários em que a taxa de risco varia ao longo do tempo (ex.: maior risco em idades avançadas)
- **Não captura tendências ou padrões** nos dados de sobrevivência

Estimação Paramétrica

Método Exponencial

Quando Usar o Método de Estimação

- Cenários onde o risco não muda com o tempo (ex.: falhas em componentes eletrônicos)
- Primeiro passo para modelos mais complexos.

Estimação Paramétrica

Método Exponencial

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

- Máquinas industriais;
- Objetivo: investigar o tempo de falha (horas) das máquinas;
- Período de observação: 150 horas;
- Amostra: 10 máquinas industriais
- Cada máquina foi acompanhado até a falha (evento de interesse) ou não falha (censura) até o final do período de observação.

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

Instalando a Biblioteca para análise de Sobrevivência

```
[1] pip install lifelines
```

✓ Importando as funções

```
[2] import numpy as np  
import pandas as pd  
import matplotlib.pyplot as plt  
from lifelines import ExponentialFitter
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

```
[3] # Dados simulados: tempos até a falha (em horas)
data = {
    'time': [5, 8, 12, 20, 25, 30, 50, 70, 100, 150], # Tempos observados
    'event': [1, 1, 1, 1, 1, 0, 1, 0, 0, 0] # 1 = Falha observada, 0 = Censurado
}

# Criar um DataFrame
df = pd.DataFrame(data)
print(df)
```



	time	event
0	5	1
1	8	1
2	12	1
3	20	1
4	25	1
5	30	0
6	50	1
7	70	0
8	100	0
9	150	0

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

✓ Ajuste do Modelo Exponencial

```
[ ] # Ajustar o modelo exponencial
exp_fitter = ExponentialFitter()
exp_fitter.fit(df['time'], event_observed=df['event'])

# Exibir os parâmetros do modelo
print("\nParâmetros do modelo exponencial:")
print(exp_fitter.summary)
```



Parâmetros do modelo exponencial:

	coef	se(coef)	coef lower 95%	coef upper 95%	cmp to	\
lambda_	78.333301	31.979423	15.654784	141.011818	0.0	

	z	p	-log2(p)
lambda_	2.449491	0.014306	6.127252

Taxa de risco: em média observa-se 78,33 falhas nos equipamentos por hora.
Parâmetro significativo a 5% (p-valor de 0,01)


Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

✓ Gráfico da Função de Sobrevivência

```
[ ] # Plotar a função de sobrevivência
plt.figure(figsize=(8, 6))
exp_fitter.plot_survival_function()
plt.title('Função de Sobrevivência - Modelo Exponencial')
plt.xlabel('Tempo (horas)')
plt.ylabel('Probabilidade de sobrevivência')
plt.grid()
plt.show()
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

Função de sobrevivência estimada pelo método Exponencial



60% das máquinas ainda não falharam após 40h

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

✓ Probabilidade Estimada de Sobrevivência no tempo t

```
[13] print(exp_fitter.survival_function_)
```

Tabela da Função de Sobrevivência estimada

	Exponential_estimate
5.000000	0.938165
21.111111	0.763758
37.222222	0.621775
53.333333	0.506186
69.444444	0.412085
85.555556	0.335478
101.666667	0.273112
117.777778	0.222340
133.888889	0.181007
150.000000	0.147357

50% das máquinas ainda não falharam após 53h

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

✓ Função de risco

```
[18] # Função de risco constante para o modelo exponencial  
lambda_param = exp_fitter.lambda_ # Taxa de falha  
print(f"\nFunção de risco (constante para modelo exponencial): {lambda_param:.4f}")
```




```
Função de risco (constante para modelo exponencial): 78.3333
```

✓ Gráfico da Função de Risco

```
[19] # Plotar a função de risco (constante para o modelo exponencial)  
plt.figure(figsize=(8, 6))  
tempos = np.linspace(0, 150, 100)  
risco = np.full_like(tempos, lambda_param)  
plt.plot(tempos, risco, label='Função de Risco', color='red')  
plt.title('Função de Risco - Modelo Exponencial')  
plt.xlabel('Tempo (horas)')  
plt.ylabel('Risco (constante)')  
plt.axhline(y=lambda_param, color='red', linestyle='--')  
plt.grid()  
plt.legend()  
plt.show()
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

Função de Risco Constante estimada pelo método Exponencial



Em média ocorrerá
78,33 falhas por hora

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

Análise Gráfica para Adequação do Ajuste

▼ Comparação da Função de Sobrevivência vs Kaplan-Meier

```
[16] # Kaplan-Meier
kmf = KaplanMeierFitter()
kmf.fit(data['time'], event_observed=data['event'])
# Gráfico de sobrevivência empírica e ajustada
plt.figure(figsize=(10, 6))
kmf.plot_survival_function(ci_show=False, label='Kaplan-Meier')
exp_fitter.plot_survival_function(ci_show=False, label='Exponencial Ajustada')
plt.title('Comparação da Função de Sobrevivência vs Kaplan-Meier')
plt.xlabel('Tempo')
plt.ylabel('S(t)')
plt.legend()
plt.show()
```


▼ Gráfico de Risco acumulado

```
# Risco acumulado
plt.figure(figsize=(10, 6))
plt.plot(kmf.event_table.index, -np.log(kmf.survival_function_['KM_estimate']), label='Risco Acumulado (Empírico)')
plt.plot(data['time'], exp_fitter.cumulative_hazard_at_times(data['time']), label='Risco Acumulado (Exponencial)')
plt.title('Gráfico de Risco Acumulado')
plt.xlabel('Tempo')
plt.ylabel('Risco Acumulado')
plt.legend()
plt.show()
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa


Análise Gráfica para Adequação do Ajuste

Comparação da Função de Sobrevivência vs Kaplan-Meier



As curvas de Kaplan-Meier e Exponencial devem se alinhar razoavelmente bem para um modelo adequado

Gráfico de Risco Acumulado



Uma linha reta no gráfico de risco acumulado sugere que a distribuição exponencial é adequada.

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

Análise Gráfica para Adequação do Ajuste

✓ Gráfico log-log para adequação do modelo exponencial


```
[15] # Função de sobrevivência ajustada pelo modelo Weibull
      sobrevivencia = exp_fitter.survival_function_at_times(data['time'])

      # Transformações para o gráfico log-log
      log_tempo = np.log(data['time'])
      log_neg_log_sobrevivencia = np.log(-np.log(sobrevivencia))

      # Plotar gráfico log-log
      plt.figure(figsize=(8, 6))
      plt.plot(log_tempo, log_neg_log_sobrevivencia, 'o-', label='Dados')
      plt.title('Gráfico Log-Log - Modelo Exponencial')
      plt.xlabel('ln(Tempo)')
      plt.ylabel('ln(-ln(Sobrevivência))')
      plt.grid()
      plt.legend()
      plt.show()
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

Gráfico Log-Log para modelo Exponencial



Pontos em linha reta indica que os dados seguem bem a distribuição Exponencial

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

- ✓ Tempo médio de sobrevivência para o modelo exponencial

```
[ ] tempo_medio_sobrevivencia = 1 / lambda_param  
    print(f"Tempo médio de sobrevivência: {tempo_medio_sobrevivencia:.2f} horas")
```

```
⇒ Tempo médio de sobrevivência: 0.01 horas
```

Observação: A expectativa de tempo médio até a falha do equipamento é muito curta, apenas 36 segundos indicando que as falhas ocorrem rapidamente (alto risco).

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

▼ Previsão de Sobrevida para o Método Exponencial

```
[ ] # Exemplo de previsões
    tempo_predicao = np.array([10, 20, 40])
    predicoes = exp_fitter.survival_function_at_times(tempo_predicao)

    print("\nProbabilidade de sobrevivência prevista para tempos específicos:")
    for t, p in zip(tempo_predicao, predicoes):
        print(f"Tempo = {t} horas, Probabilidade de sobrevivência = {p:.2f}")
```



```
Probabilidade de sobrevivência prevista para tempos específicos:
Tempo = 10 horas, Probabilidade de sobrevivência = 0.88
Tempo = 20 horas, Probabilidade de sobrevivência = 0.77
Tempo = 40 horas, Probabilidade de sobrevivência = 0.60
```

O modelo paramétrico permite fazer previsões para tempos diferentes dos observados

Estimação Paramétrica

Método Exponencial

- A suposição de risco constante pode não ser realista em muitos cenários (por exemplo, quando o **risco aumenta ou diminui** com o envelhecimento do equipamento)
- Nesse caso, é recomendável usar um modelo mais flexível, como Weibull, que permite variações no risco ao longo do tempo.

Método Weibull

Estimação Paramétrica

Método Weibull

É o método paramétrico mais usados na análise de sobrevivência devido à sua flexibilidade.

Ele generaliza o modelo exponencial, permitindo que a taxa de risco varie ao longo do tempo: constante, crescente ou decrescente

Estimação Paramétrica

Método Weibull

Matematicamente, a **Função de Densidade de Probabilidade Weibull** $f(t)$ é dada por:

$$f(t) = \frac{\rho}{\lambda} \left(\frac{t}{\lambda} \right)^{\rho-1} e^{-\left(\frac{t}{\lambda} \right)^{\rho}}$$

em que

$\lambda > 0$ é a taxa de risco (parâmetro de escala);

$\rho > 0$ parâmetro de forma

Estimação Paramétrica

Método Weibull

Matematicamente, a **Função de Sobrevivência** $S(t)$ estimada é dada por:

$$\hat{S}(t) = P(T > t) = e^{-\left(\frac{t}{\lambda}\right)^\rho}$$

$S(t)$ é a probabilidade de o evento não ter ocorrido até o tempo t

$\rho > 0$ parâmetro de forma

$\lambda > 0$ é a taxa de risco (parâmetro de escala)

Estimação Paramétrica

Método Weibull

Matematicamente, a **Função de Risco** $h(t)$ estimada é dada por:

$$\hat{h}(t) = \frac{f(t)}{S(t)} = \frac{\rho}{\lambda} \left(\frac{t}{\lambda} \right)^{\rho-1}$$

OBS: ρ determina se o risco aumenta ou diminui ao longo do tempo

Estimação Paramétrica

Método Weibull

Estimação do Parâmetro ρ e λ

Log da função de máxima verossimilhança

$$\ln L(\rho, \lambda) = n \ln(\rho) + \rho n \ln(\lambda) + (\rho - 1) \sum_{i=1}^n \ln(t_i) - \sum_{i=1}^n (\lambda t_i)^\rho$$

Os parâmetros $\hat{\rho}$ e $\hat{\lambda}$ são encontrados maximizando $\ln L(\rho, \lambda)$, geralmente usando métodos numéricos.

Estimação Paramétrica

Método Weibull

Interpretação dos Parâmetros

Parâmetro de Escala (λ)

- $\lambda > 0$:

O **parâmetro de escala** está relacionado ao **tempo médio de vida** de um indivíduo ou produto

Quanto **maior λ** , **maior o tempo típico** até a falha

Estimação Paramétrica

Método Weibull

Interpretação dos Parâmetros

Parâmetro de Forma (ρ)

- $\rho = 1$: A taxa de risco $h(t)$ constante e o modelo Weibull se reduz ao modelo exponencial .
- $\rho > 1$: A **taxa de risco aumenta** com o tempo ($h(t)$ crescente).
Indicativo de desgaste
- $\rho < 1$: A **taxa de risco diminui** com o tempo ($h(t)$ decrescente).
Indicativo de "cura" ou diminuição de vulnerabilidade.

Estimação Paramétrica

Método Weibull

- Tempo de Sobrevivência Esperado

$$E(T) = \frac{\Gamma(1 + 1/\rho)}{\lambda}$$

Em que Γ é a função gama

Estimação Paramétrica

Método Weibull

Análise Gráfica para Qualidade do Modelo

- **Sobreposição** das Curvas de Sobrevivência de **Kaplan-Meier** e **Weibull** devem se **alinhar razoavelmente bem** se a distribuição Weibull for adequada,
- **Gráfico da Função de Risco Acumulado:** Uma linha reta sugere que a distribuição Weibull é adequada.

Estimação Paramétrica

Método Weibull

Análise Gráfica para Qualidade do Ajuste

- **Gráficos Log-Log:** A linearização de $\ln(-\ln(S(t)))$ versus $\ln(t)$ ajuda a verificar a adequação ao modelo Weibull.

Interpretação:

Pontos em **linha reta** confirmam que os dados seguem bem a distribuição Weibull

Pontos **com desvios significativos** indicam que o modelo Weibull não é adequado

Estimação Não Paramétrica

Método Weibull

Vantagens

- Capaz de modelar **taxas de risco** crescentes, decrescentes ou constantes.
- Aplicável em diversas áreas (ex.: confiabilidade, saúde, engenharia).
- Facilmente interpretado no contexto de processos com desgaste acumulativo.

Estimação Paramétrica

Método Weibull

Limitações

- Estimação de dois parâmetros (ρ e λ) pode ser desafiadora para pequenos conjuntos de dados.

Estimação Paramétrica

Método Weibull

Quando Usar o Método de Estimação

- **Cenários com Risco Variável:** Quando a taxa de risco é esperada para mudar ao longo do tempo
- **Confiabilidade e Engenharias:** Avaliação de falhas em sistemas físicos.
- **Estudos Médicos:** Avaliação de tempo de recuperação ou progressão de doenças.

Estimação Paramétrica

Método Weibull

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

- Máquinas industriais;
- Objetivo: investigar o tempo de falha (horas) das máquinas;
- Período de observação: 150 horas;
- Amostra: 10 máquinas industriais
- Cada máquina foi acompanhado até a falha (evento de interesse) ou não falha (censura) até o final do período de observação.

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

✓ Instalando a Biblioteca para análise de Sobrevivência

```
[ ] pip install lifelines
```

✓ Importar as funções

```
[4] import numpy as np  
import pandas as pd  
import matplotlib.pyplot as plt  
from lifelines import WeibullFitter
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

✓ Inserir os dados

```
[19] # Dados simulados: tempos até a falha (em horas)
      data = {
          'time': [5, 8, 12, 20, 25, 30, 50, 70, 100, 150], # Tempos observados
          'event': [1, 1, 1, 1, 1, 0, 1, 0, 0, 0] # 1 = Falha observada, 0 = Censurado
      }

      # Criar um DataFrame
      df = pd.DataFrame(data)
      print(df)
```

	time	event
0	5	1
1	8	1
2	12	1
3	20	1
4	25	1
5	30	0
6	50	1
7	70	0
8	100	0
9	150	0

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

✓ Ajuste do modelo Weibull

```
[20] # Ajustar o modelo Weibull
      weibull_fitter = WeibullFitter()
      weibull_fitter.fit(df['time'], event_observed=df['event'])
```

```
⇒ <lifelines.WeibullFitter:"Weibull_estimate", fitted with 10 total observations, 4 right-censored observations>
```

✓ Parâmetros no Método Weibull

```
[21] # Exibir os parâmetros do modelo
      print("\nParâmetros do modelo Weibull:")
      print(weibull_fitter.summary)
```



Parâmetros do modelo Weibull:

	coef	se(coef)	coef lower 95%	coef upper 95%	cmp to \
lambda_	83.857050	47.575129	-9.388489	177.102589	1.0
rho_	0.736641	0.251940	0.242848	1.230434	1.0

	z	p	-log2(p)
lambda_	1.741604	0.081578	3.615681
rho_	-1.045325	0.295873	1.756951

$\rho(0,73) < 1$: O risco diminui com o tempo, indicando que falhas são mais prováveis em estágios iniciais

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

Lambda é o parâmetro de escala do modelo

$$\hat{\lambda} = 83,857$$

Se $t = \lambda$ temos $S(t) = e^{-1} \approx 0,368$

Aproximadamente 38,8% dos equipamentos não terão apresentado o evento quando o tempo atingir 83,86 horas, considerando o modelo ajustado.

No modelo Weibull λ não deve ser apresentado como a média dos tempos de sobrevivência mas como um tempo de referência de sobrevida.


Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

✓ Estimando a Função de Sobrevivência $S(t)$ pelo Método Weibull

```
[22] # Plotar a função de sobrevivência
plt.figure(figsize=(8, 6))
weibull_fitter.plot_survival_function()
plt.title('Função de Sobrevivência - Modelo Weibull')
plt.xlabel('Tempo (horas)')
plt.ylabel('Probabilidade de sobrevivência')
plt.grid()
plt.show()
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

Função de sobrevivência estimada pelo método Weibull



58% das máquinas ainda não falharam após 40h

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

✓ Probabilidade Estimada de Sobrevivência no tempo t

```
[23] print(weibull_fitter.survival_function_)
```

Tabela da Função de Sobrevivência estimada

	Weibull_estimate
5.000000	0.882237
21.111111	0.696269
37.222222	0.577098
53.333333	0.488456
69.444444	0.418827
85.555556	0.362446
101.666667	0.315870
117.777778	0.276840
133.888889	0.243771
150.000000	0.215508

48% das máquinas ainda não falharam após 53h

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull


✓ Gráfico da Função de Risco



```
# Plotar a função de risco
plt.figure(figsize=(8, 6))
plt.plot(tempos_plot, risco, label='Função de Risco', color='red')
plt.title('Função de Risco - Modelo Weibull')
plt.xlabel('Tempo (horas)')
plt.ylabel('Risco')
plt.grid()
plt.legend()
plt.show()
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

Função de Risco estimada pelo método Weibull



O equipamento que não falhou em 5 horas tem 2 vezes mais chance de falhar instantaneamente do que a que não falhou em 50 horas

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

Análise Gráfica para Adequação do Ajuste

Gráfico Comparação da Função de Sobrevida vs Kaplan-Meier


```
# Kaplan-Meier
kmf = KaplanMeierFitter()
kmf.fit(data['time'], event_observed=data['event'])
# Gráfico de sobrevivência empírica e ajustada
plt.figure(figsize=(10, 6))
kmf.plot_survival_function(ci_show=False, label='Kaplan-Meier')
weibull_fitter.plot_survival_function(ci_show=False, label='Weibull Ajustada')
plt.title('Comparação da Função de Sobrevida vs Kaplan-Meier')
plt.xlabel('Tempo')
plt.ylabel('S(t)')
plt.legend()
plt.show()
```

Risco Acumulado


```
# Risco acumulado
plt.figure(figsize=(10, 6))
plt.plot(kmf.event_table.index, -np.log(kmf.survival_function['KM_estimate']), label='Risco Acumulado (Empírico)')
plt.plot(data['time'], weibull_fitter.cumulative_hazard_at_times(data['time']), label='Risco Acumulado (Weibull)')
plt.title('Gráfico de Risco Acumulado')
plt.xlabel('Tempo')
plt.ylabel('Risco Acumulado')
plt.legend()
plt.show()
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

Análise Gráfica para Adequação do Ajuste



As curvas de Kaplan-Meier e Weibull devem se alinhar razoavelmente bem para um modelo adequado



Uma linha levemente curvilínea no gráfico sugere que a distribuição Weibull não é adequada.

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

Análise Gráfica para Adequação do Ajuste

✓ Gráfico Log-log para verificar a adequação do modelo


```
# Função de sobrevivência ajustada pelo modelo Weibull
sobrevivencia = weibull_fitter.survival_function_at_times(data['time'])

# Transformações para o gráfico log-log
log_tempo = np.log(data['time'])
log_neg_log_sobrevivencia = np.log(-np.log(sobrevivencia))

# Plotar gráfico log-log
plt.figure(figsize=(8, 6))
plt.plot(log_tempo, log_neg_log_sobrevivencia, 'o-', label='Dados')
plt.title('Gráfico Log-Log - Modelo Weibull')
plt.xlabel('ln(Tempo)')
plt.ylabel('ln(-ln(Sobrevivência))')
plt.grid()
plt.legend()
plt.show()
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

Gráfico Log-log Método Weibull



Interpretação:

Todos os pontos em linha reta no gráfico confirma que os dados seguem bem a distribuição Weibull.

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

▼ Tempo Médio Esperado de Sobrevivência

```
[ ] # Tempo médio de sobrevivência (Weibull não possui fórmula analítica direta, mas pode ser estimado numericamente)
def tempo_medio_weibull(a, b):
    from scipy.special import gamma
    return b * gamma(1 + 1/a)

shape = weibull_fitter.rho_ # Forma (shape parameter)
scale = weibull_fitter.lambda_ # Escala (scale parameter)

tempo_medio_sobrevivencia = tempo_medio_weibull(shape, scale)
print(f"\nTempo médio de sobrevivência: {tempo_medio_sobrevivencia:.2f} horas")
```



Tempo médio de sobrevivência: 101.36 horas

Interpretação: em média, um equipamento funcionará por 101.36 horas antes de falhar

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Weibull

▼ Previsão

```
[ ] # Previsões para tempos específicos
    tempos_prev = np.array([10, 20, 40])
    previsoes_sobrevivencia = weibull_fitter.survival_function_at_times(tempos_prev)

    print("\nProbabilidade de sobrevivência para tempos específicos:")
    for t, p in zip(tempos_prev, previsoes_sobrevivencia):
        print(f"Tempo = {t} horas, Probabilidade de sobrevivência = {p:.2f}")
```



```
Probabilidade de sobrevivência para tempos específicos:
Tempo = 10 horas, Probabilidade de sobrevivência = 0.81
Tempo = 20 horas, Probabilidade de sobrevivência = 0.71
Tempo = 40 horas, Probabilidade de sobrevivência = 0.56
```

Interpretação: com o modelo paramétrico é possível fazer previsões de sobrevivência para tempos diferentes dos observados

Estimação Paramétrica

Método Weibull

Conclusão

- **Planejamento de Manutenção:** a empresa pode programar a manutenção preventiva ou substituição dos equipamentos.
- **Comparação de Equipamentos:** pode ser usado para comparar a durabilidade relativa de cada tipo de equipamento.
- **Custos Operacionais:** pode ajudar a estimar o custo médio associado às falhas de equipamentos no tempo e orientar decisões de investimento em equipamentos mais duráveis.

Método Log-Normal

Estimação Paramétrica

Método Log-Normal

É o método paramétrico amplamente utilizado em situações onde o tempo até o evento de interesse segue uma **distribuição assimétrica**, com uma cauda longa à direita.

Ele assume que o logaritmo natural dos tempos de sobrevivência segue uma distribuição normal.

Estimação Paramétrica

Método Log-Normal

Matematicamente, a **Função de Densidade de Probabilidade Log-Normal** $f(t)$ é dada por:

$$f(t) = \frac{1}{t\sigma\sqrt{2\pi}} e^{-\frac{(\ln(t)-\mu)^2}{2\sigma^2}}$$

em que

μ média do logaritmo natural dos tempos de sobrevivência.

σ desvio padrão do logaritmo natural dos tempos.

Estimação Paramétrica

Método Log-Normal

Matematicamente, a **Função de Sobrevivência** $S(t)$ estimada é dada por:

$$\hat{S}(t) = P(T > t) = 1 - \Phi\left(\frac{\ln(t) - \mu}{\sigma}\right)$$

$S(t)$ é a probabilidade de o evento não ter ocorrido até o tempo t
 Φ a função de distribuição acumulada da distribuição normal padrão.

Estimação Paramétrica

Método Log-Normal

Matematicamente, a **Função de Risco** $h(t)$ estimada é dada por:

$$\hat{h}(t) = \frac{f(t)}{S(t)} = \frac{\frac{1}{t\sigma\sqrt{2\pi}} e^{-\frac{(\ln(t)-\mu)^2}{2\sigma^2}}}{1 - \Phi\left(\frac{\ln(t) - \mu}{\sigma}\right)}$$

A taxa de risco instantânea em t pode ter formatos variados dependendo dos parâmetros μ e σ .


Estimação Paramétrica

Método Log-Normal

Propriedades

Assimetria

- A distribuição Log-Normal é assimétrica, com uma cauda longa à direita.
- Isso a torna ideal para modelar tempos de sobrevivência em cenários onde eventos extremos são possíveis



<https://dynamox.net/blog/metricas-de-analise-de-vibracao-curtose-e-skewness>

Estimação Paramétrica

Método Log-Normal

Propriedades

- **Tempo de Sobrevivência Esperado**

$$E(T) = e^{\mu + \frac{\sigma^2}{2}}$$

- **Mediana do Tempo de Sobrevivência**

$$E(T) = e^{\mu}$$

- **Função de Risco:** A forma da função de risco depende de μ e σ e pode ser crescente, decrescente, ou ter um pico (não-monótona).

Estimação Paramétrica

Método Log-Normal

Estimação do Parâmetro μ e σ

Log da função de **máxima verossimilhança** é dado por:

$$\ln L(\mu, \sigma) = -n \ln(\sigma) - n \ln(\sqrt{2\pi}) - \sum_{i=1}^n \ln(t_i) - \frac{1}{2\sigma^2} \sum_{i=1}^n (\ln(t_i) - \mu)^2$$

Os parâmetros $\hat{\mu}$ e $\hat{\sigma}$ são encontrados maximizando $\ln L(\rho, \lambda)$, geralmente usando métodos numéricos.

Estimação Paramétrica

Método Log-Normal

Interpretação dos Parâmetros

Parâmetro de Localização (μ)

- Um aumento em μ desloca a distribuição para a direita, indicando tempos de sobrevivência maiores em média.

Parâmetro de Escala (σ)

- Um aumento em σ indica maior variabilidade nos tempos de sobrevivência
- Valores menores de σ indicam que os tempos de sobrevivência estão mais concentrados ao redor da mediana

Estimação Paramétrica

Método Log-Normal

Análise Gráfica para Adequação do Ajuste

- **Logaritmo do tempo de Sobrevivência:** verificar se segue um comportamento normal.
- **Gráfico do Risco Acumulado:** Verifique a suavidade do comportamento e a consistência com o modelo log-normal.
- **Gráfico QQ-plot:** Uma linha reta no gráfico sugere que a distribuição log-normal é adequada para os dados.

Estimação Não Paramétrica

Método Log-Normal

Vantagens

- Modela tempos de sobrevivência com valores extremos de forma eficaz.
- Conexão com Modelos Lineares

Estimação Paramétrica

Método Log-Normal

Limitações

- Os parâmetros (μ e σ) têm significado no logaritmo dos tempos, o que pode **dificultar a interpretação** no contexto original.
- **Outliers** (dados extremos) podem afetar significativamente a estimativa dos parâmetros.

Estimação Paramétrica

Método Log-Normal

Quando Usar o Método de Estimação

- **Dados Assimétricos:** Quando os tempos de sobrevivência apresentam caudas longas.
- **Estudos com Falhas Extremas:** Exemplos incluem tempos de recuperação de doenças crônicas, falhas em sistemas complexos e tempos de processamento em indústrias.
- **Substituto ao Weibull:** Quando o Weibull não captura bem a distribuição dos dados.

Estimação Paramétrica

Método Log-Normal

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa

- Máquinas industriais;
- Objetivo: investigar o tempo de falha (horas) das máquinas;
- Período de observação: 150 horas;
- Amostra: 10 máquinas industriais
- Cada máquina foi acompanhado até a falha (evento de interesse) ou não falha (censura) até o final do período de observação.

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

✓ Instalando a Biblioteca para análise de Sobrevida

```
[47] pip install lifelines
```

✓ Importar as funções

```
 import numpy as np  
import pandas as pd  
import matplotlib.pyplot as plt  
from scipy.stats import probplot  
from lifelines import LogNormalFitter
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

▼ Inserir os dados

```
[49] # Dados simulados: tempos até a falha (em horas)
      data = {
          'time': [5, 8, 12, 20, 25, 30, 50, 70, 100, 150], # Tempos observados
          'event': [1, 1, 1, 1, 1, 0, 1, 0, 0, 0] # 1 = Falha observada, 0 = Censurado
      }

      # Criar um DataFrame
      df = pd.DataFrame(data)
      print(df)
```

	time	event
0	5	1
1	8	1
2	12	1
3	20	1
4	25	1
5	30	0
6	50	1
7	70	0
8	100	0
9	150	0

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

✓ Ajuste do modelo Log-Normal

```
[50] # Ajustar o modelo Log-Normal
lognormal_fitter = LogNormalFitter()
lognormal_fitter.fit(df['time'], event_observed=df['event'])
```

```
➡ <lifelines.LogNormalFitter:"LogNormal_estimate", fitted with 10 total observations, 4 right-censored observations>
```

✓ Parâmetros no Método Log-Normal

```
▶ # Exibir os parâmetros do modelo
print("\nParâmetros do modelo Log-Normal:")
print(lognormal_fitter.summary)
```

```
➡
Parâmetros do modelo Log-Normal:
      coef  se(coef)  coef lower 95%  coef upper 95%  cmp to      z  \
mu_      3.79749   0.558246      2.703348      4.891632      0.0  6.802538
sigma_    1.56930   0.498833      0.591605      2.546996      1.0  1.141263
```

	p	-log2(p)
mu_	1.027916e-11	36.501486
sigma_	2.537604e-01	1.978461

Sigma nunca será “zero”, então esse p-valor não tem interpretação prática importante.

Método Log-Normal

$\mu = 3,79$ representa a média do $\log(T)$

Ao retornar a escala original temos:

$$e^{3,79} = 44,6$$

A **mediana estimada** do tempo de sobrevivência dos equipamentos é de aproximadamente 44,6 horas.

A média do tempo de sobrevivência, propriamente dita, é:

$$E(T) = e^{\mu + \sigma^2/2}$$

que, com seus parâmetros, é aproximadamente:

$$E(T) \approx 152,5$$

A diferença entre média (152,5) e mediana (44,6) indica forte **assimetria à direita**, característica da distribuição Log-Normal.


Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

✓ Estimando a Função de Sobrevida $S(t)$ pelo Log-Normal

```
[ ] # Plotar a função de sobrevivência
plt.figure(figsize=(8, 6))
lognormal_fitter.plot_survival_function()
plt.title('Função de Sobrevida - Modelo Log-Normal')
plt.xlabel('Tempo (horas)')
plt.ylabel('Probabilidade de sobrevivência')
plt.grid()
plt.show()
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

Função de sobrevivência estimada pelo método Log-Normal



58% das máquinas ainda não falharam após 40h

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

✓ Probabilidade Estimada de Sobrevivência no tempo t

```
[23] print(weibull_fitter.survival_function_)
```

Tabela da Função de Sobrevivência estimada

```
[52] print(lognormal_fitter.survival_function_)
```

	LogNormal_estimate
5.000000	0.918384
21.111111	0.683123
37.222222	0.545806
53.333333	0.454576
69.444444	0.388851
85.555556	0.338974
101.666667	0.299719
117.777778	0.267977
133.888889	0.241763
150.000000	0.219747

45% das máquinas ainda não falharam após 53h

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

✓ Função de risco


```
[54] # Calcular a função de risco
      tempos_plot = np.linspace(0.1, max(tempos), 100) # Evitar divisão por zero
      risco = lognormal_fitter.hazard_at_times(tempos_plot)
```

✓ Gráfico da Função de Risco

```
▶ # Plotar a função de risco
  plt.figure(figsize=(8, 6))
  plt.plot(tempos_plot, risco, label='Função de Risco', color='red')
  plt.title('Função de Risco - Modelo Log-Normal')
  plt.xlabel('Tempo (horas)')
  plt.ylabel('Risco')
  plt.grid()
  plt.legend()
  plt.show()
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

Função de Risco estimada pelo método Log-Normal



O **risco cresce** até o pico porque mais equipamentos atingem o "**tempo típico**" de falha que foi em 5h.

Depois do pico, o risco diminui, pois a **maioria** dos equipamentos **já falharam**.

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

Análise Gráfica para Adequação do Ajuste




```
# Calcular risco acumulado
times = np.linspace(1, 50, 100) # Intervalo de tempos para avaliar o risco acumulado
cumulative_hazard = lognormal_fitter.cumulative_hazard_at_times(df['time'])

# Plotar o risco acumulado
plt.figure(figsize=(10, 6))
plt.plot(df['time'], cumulative_hazard, label='Função de Risco Acumulado (Log-Normal)', color='blue')
plt.title('Função de Risco Acumulado - Modelo Log-Normal')
plt.xlabel('Tempo')
plt.ylabel('Risco Acumulado (H(t))')
plt.legend()
plt.grid()
plt.show()
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

Função de Risco acumulado pelo método Log-Normal



O gráfico mostra a suavidade do comportamento e a consistência com o modelo log-normal.

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal


Análise Gráfica para Adequação do Ajuste

- ✓ Gráfico Q-Qplot para verificar a adequação do modelo

```
[ ] # Gráfico QQ-Plot para verificar ajuste ao modelo Log-Normal
    log_tempos = np.log(tempos) # Log-transformação dos tempos
    plt.figure(figsize=(8, 6))
    probplot(log_tempos, dist="norm", plot=plt)
    plt.title("Gráfico QQ-Plot - Modelo Log-Normal")
    plt.grid()
    plt.show()
```

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

Gráfico Q-Qplot



O gráfico QQ-Plot avalia o quanto bem os dados se ajustam à suposição de distribuição Log-Normal.

Uma boa aderência é indicada por pontos próximos à linha de referência

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

✓ Tempo Médio Esperado de Sobrevivência

```
[56] # Tempo médio de sobrevivência (estimado numericamente)
def tempo_medio_lognormal(mu, sigma):
    from scipy.stats import lognorm
    mean = lognorm.mean(s=sigma, scale=np.exp(mu))
    return mean

mu = lognormal_fitter.mu_ # Parâmetro de localização (mu)
sigma = lognormal_fitter.sigma_ # Parâmetro de escala (sigma)

tempo_medio_sobrevivencia = tempo_medio_lognormal(mu, sigma)
print(f"\nTempo médio de sobrevivência: {tempo_medio_sobrevivencia:.2f} horas")
```



```
Tempo médio de sobrevivência: 152.76 horas
```

Interpretação: em média, um equipamento funcionará por 152,76 horas antes de falhar

Exemplo: Situação hipotética dos tempos de falha de equipamentos industriais observados em uma empresa – Método Log-Normal

▼ Previsão



```
# Previsões para tempos específicos
tempos_prev = np.array([10, 20, 40])
previsoes_sobrevivencia = lognormal_fitter.survival_function_at_times(tempos_prev)

print("\nProbabilidade de sobrevivência para tempos específicos:")
for t, p in zip(tempos_prev, previsoes_sobrevivencia):
    print(f"Tempo = {t} horas, Probabilidade de sobrevivência = {p:.2f}")
```



```
Probabilidade de sobrevivência para tempos específicos:
Tempo = 10 horas, Probabilidade de sobrevivência = 0.83
Tempo = 20 horas, Probabilidade de sobrevivência = 0.70
Tempo = 40 horas, Probabilidade de sobrevivência = 0.53
```

Interpretação: com o modelo paramétrico é possível fazer previsões de sobrevivência para tempos diferentes dos observados

Estimação Paramétrica

Método Log-Normal

Conclusão

- A função de risco não monotônica da Log-Normal é útil para modelar situações onde o risco aumenta inicialmente devido ao desgaste de componentes, mas diminui após um certo ponto porque os itens sobreviventes são mais robustos.

Estimação Paramétrica

Comparação dos Métodos

O AIC (Akaike Information Criterion) combina:

- qualidade do ajuste aos dados;
- complexidade do modelo.

A regra é:

quanto menor o AIC, melhor.

Estimação Paramétrica

Comparação dos Modelos pelo Método AIC

```
▶ # AIC do modelo Exponencial
aic_exponencial = exp_fitter.AIC_

# AIC do modelo Weibull
aic_weibull = weibull_fitter.AIC_

# AIC do modelo Log-Normal
aic_lognormal = lognormal_fitter.AIC_

print("AIC - Modelo Exponencial:", aic_exponencial)
print("AIC - Modelo Weibull:", aic_weibull)
print("AIC - Modelo lognormal:", aic_lognormal)
```

```
... AIC - Modelo Exponencial: 66.33167870571361
AIC - Modelo Weibull: 67.40558112563153
AIC - Modelo lognormal: 65.61800758145154
```

Método Log-logístico

Estimação Paramétrica

Método Log-logístico

É um dos modelos paramétricos mais utilizados na análise de sobrevivência quando os dados apresentam uma **taxa de risco** que primeiro **aumenta** e depois **diminui** (forma em sino).

Exemplos:

- Modelar o tempo até uma infecção pós-cirúrgica após uma cirurgia abdominal.
- O tempo da recidiva de câncer após o tratamento

Estimação Paramétrica

Método Log-logístico


O modelo log-logístico assume que o **logaritmo do tempo até o evento T** segue uma **distribuição logística**

$$\log(T) \sim \text{Distribuição Logística}$$

A **distribuição logística** é uma distribuição contínua de probabilidade que se parece com a distribuição normal, mas com **caudas mais pesadas** e é **simétrica** em torno da média.

Estimação Paramétrica

Método Log-logístico



Estimação Paramétrica

Método Log-logístico

Matematicamente, a **Função de Densidade de Probabilidade log-logístico** $f(t)$ é dada por:

$$f(t) = \frac{(\gamma/\lambda)(t/\lambda)^{\gamma-1}}{[1 + (t/\lambda)^\gamma]^2}$$

em que

$\lambda > 0$ parâmetro de escala, define "quando" o risco atinge seu pico (se houver) e quanto tempo leva para o evento (como morte, falha, etc.) se tornar provável. E a mediana de sobrevivência.

$\gamma > 0$ parâmetro de forma, define como o risco muda ao longo do tempo

Estimação Paramétrica

Método Log-logístico

Matematicamente, a **Função de Sobrevivência** $S(t)$ estimada é dada por:

$$\hat{S}(t) = P(T > t) = \frac{1}{1 + (t/\lambda)^\gamma}$$

$S(t)$ é a probabilidade de o evento não ter ocorrido até o tempo t

$\lambda > 0$ parâmetro de escala, define "quando" o risco atinge seu pico (se houver) e quanto tempo leva para o evento (como morte, falha, etc.) se tornar provável. É a mediana de sobrevivência.

$\gamma > 0$ parâmetro de forma, define como o risco muda ao longo do tempo

Estimação Paramétrica

Método Log-logístico

Matematicamente, a **Função de Risco** $h(t)$ estimada é dada por:

$$\hat{h}(t) = \frac{f(t)}{S(t)} = \frac{(\gamma/\lambda)(t/\lambda)^{\gamma-1}}{1 + (t/\lambda)^\gamma}$$

OBS: γ define como o risco muda ao longo do tempo e a função de risco tem forma de sino: risco aumenta e depois diminui com o tempo (muito útil em medicina, falhas de produtos etc.).

Estimação Paramétrica

Método Log-logístico

Matematicamente, a **Razão de Risco** $HR(t)$ estimada é dada por:

$$\hat{h}(t) = \frac{h_1(t)}{h_2(t)} = \left(\frac{\lambda_2}{\lambda_1} \right)^\gamma \frac{1 + (t/\lambda_2)^\gamma}{1 + (t/\lambda_1)^\gamma}$$

- Observe que $HR(t)$ depende de t , isto é, não é constante no tempo.
- Se $\lambda_1 = \lambda_2$ a $HR(t) = 1 \Rightarrow$ constante

Estimação Paramétrica

Método Log-logístico

A vantagem conceitual importante da log-logística é que ela gera um modelo de chances proporcionais dada por:

$$F(t) = 1 - S(t) = \frac{(t/\lambda)^\gamma}{1 + (t/\lambda)^\gamma} \Rightarrow \frac{F(t)}{1 - F(t)} = (t/\lambda)^\gamma$$

Se compararmos dois grupos com escalas $\lambda_1 = \lambda_2$, a razão das chances de falha é

$$\frac{F_1(t)/(1 - F_1(t))}{F_2(t)/(1 - F_2(t))} = \frac{(t/\lambda_1)^\gamma}{(t/\lambda_2)^\gamma} = (\lambda_1/\lambda_2)^\gamma$$

que é **constante no tempo**. A razão de chances é constante ao longo do tempo, mesmo que a razão de risco não seja.

Estimação Paramétrica

Método Log-logístico

Estimação do Parâmetro γ e λ

Log da função de máxima verossimilhança

$$\ln L(\gamma, \lambda) = n \ln(\gamma) + \rho n \ln(\lambda) + (\gamma - 1) \sum_{i=1}^n \ln(t_i) - \sum_{i=1}^n (\lambda t_i)^\gamma$$

Os parâmetros $\hat{\gamma}$ e $\hat{\lambda}$ são encontrados maximizando $\ln L(\gamma, \lambda)$, geralmente usando métodos numéricos.

Estimação Paramétrica

Método Log-logístico

Interpretação dos Parâmetros

Parâmetro de Escala (λ)

- $\lambda > 0$:

O parâmetro de escala controla onde a curva de sobrevivência se posiciona no tempo

Quanto **maior** λ , indica que o evento tende a ocorrer mais tarde.

É o ponto em que a função de sobrevivência é a mediana.

Estimação Paramétrica

Método Log-logístico

Interpretação dos Parâmetros

Parâmetro de Forma (γ)

- $\gamma = 1$: A taxa de risco $h(t)$ constante se reduz ao modelo exponencial .
- $\gamma > 1$: A **taxa de risco** é em **forma de sino** (aumenta e depois diminui)
- $\gamma < 1$: A **taxa de risco diminui** com o tempo ($h(t)$ decrescente).

Estimação Paramétrica

Método Log-logístico

- Tempo de Sobrevivência Esperado

$$E(T) = \lambda * (\pi/\gamma) * \frac{1}{\text{sen}(\pi/\gamma)}$$

Só existe de $\gamma > 1$

Estimação Paramétrica

Método Log-logístico

Análise Gráfica para Qualidade do Modelo

- **Sobreposição** das Curvas de Sobrevivência de **Kaplan-Meier** e **log-logístico** devem se **alinhar razoavelmente bem** se a distribuição for adequada,
- **Gráfico da Função de Risco Acumulado:** Uma linha reta sugere que a distribuição é adequada.
- **Gráfico QQ-plot:** Uma linha reta no gráfico sugere que a distribuição é adequada para os dados.

Estimação Não Paramétrica

Método Log-logístico

Vantagens

- Capta formas de risco **não-monótonas** (como curva em sino: risco inicialmente alto (período crítico), depois reduzido (recuperação))
- Flexível e fácil de interpretar
- Útil para dados com caudas longas (ex: sobrevivência longa de pacientes)

Estimação Paramétrica

Método Log-logístico

Limitações

- Sujeito a **erro de especificação**: se os dados não seguem distribuição log-logística, o ajuste pode ser ruim
- Estimativa $E(T)$ não existe se $\gamma < 1$

Estimação Paramétrica

Método Log-logístico

Quando Usar o Método de Estimação

- Há **evidência visual** de que o **risco** primeiro **aumenta** e depois **diminui**
- Você deseja extrapolar a função de sobrevivência
- O modelo log-normal não se ajusta bem (log-logístico tem caudas mais pesadas)

Estimação Paramétrica

Método Log-logístico

Exemplo: Situação hipotética do tempo de óbito de dois grupo após uma cirurgia:

- 1 - Grupo sem infecção:** indivíduos que não apresentam infecção.
- 2 - Grupo com infecção:** indivíduos que apresentam infecção, o que provavelmente altera seu risco e tempo até o evento.
 - Objetivo: investigar o tempo do óbito (dias) ;
 - Período de observação: 80 dias;
 - Amostra: 200 indivíduos em cada grupo, totalizando 400 observações.

Estimação Paramétrica

Método Log-logístico

Exemplo: Situação hipotética do tempo de óbito de dois grupo após uma cirurgia:

- Grupo sem infecção: 51 dados censurados
- Grupo com infecção: 34 dados censurados

Resumo Métodos Paramétricos

Resumo da Análise de Sobrevida

