

Disciplina:

ANÁLISE DE SOBREVIVÊNCIA

Professora: Patrícia de Sousa Ilambwetsi

Bacharel em Estatística pela UFOP

Mestre em Estatística pela UFV

Doutora em Estatística pela UFV

Especialista em Ciências de Dados e Big Data pela PUC Minas



Conteúdo programático

Unidade 1 – Conceitos Básicos para Análise de Sobrevida

Unidade 2 – Métodos Não Paramétricos e Paramétricos

Unidade 3 – Modelos de Regressão para Análise de Sobrevida

Unidade 4 – Testes de Vidas Acelerados

Distribuição dos pontos:

- Exercícios práticos: 4 exercícios de múltiplas escolhas totalizando 40 pontos (entrega semanal)
- Relatório Final: 60 pontos (entrega a ser definida pelo professor)

Roteiro

Unidade 3 – Modelos de Regressão para Análise de Sobrevida

3.1 Modelo de Regressão Semiparamétrico

- Modelo de Cox
- Ajuste e Adequação do Modelo
- Análise de Resíduos

3.2 Modelo de Regressão Paramétricos

- Modelo Clássico
- Modelo de Taxa Acelerada
- Ajuste e Adequação do Modelo
- Análise de Resíduos

Modelos de Regressão para Análise de Sobrevivência

Modelos de Regressão

Em análise de sobrevivência **modelos regressão** busca compreender a **relação** entre o **tempo** até falha e as **variáveis explicativas** (covariáveis). É usado para prever o tempo de sobrevivência e avaliar o impacto de fatores de risco. A regressão nesses modelos é feita assumindo que o **parâmetro de escala da distribuição é função de covariáveis**.

Esse tipo de análise permite:

- **modelar e prever** tempos de sobrevivência;
- avaliar os **efeitos de covariáveis**;
- explorar como as interações entre variáveis afetam o risco de ocorrência do evento.

Modelos de Regressão

A regressão nos modelos em análise de sobrevivência é feita assumindo uma transformação logarítmica na resposta resultando em um modelo linear que permite distribuições assimétricas para os erros.

$$Y = \log(T) = X\beta + \sigma\varepsilon$$

em que

X são as covariáveis

β são os coeficientes estimados

σ parâmetro de dispersão

ε segue uma distribuição específica (ex: normal para log-normal, logística para log-logístico, etc).

Modelos de Regressão

Um modelo linear com a transformação logarítmica da resposta é equivalente a utilizar um **componente determinístico** não linear nos parâmetros e uma distribuição assimétrica para os erros.

O componente determinístico é dado por:

$$\exp(\beta_1 X_1 + \cdots + \beta_n X_n) = \exp(\beta X)$$

Assim será possível avaliar a **relação entre as variáveis** em que se tem uma **resposta** envolvendo o **tempo** até a ocorrência de um evento de interesse e a **presença de censura** que apresenta a **distribuição assimétrica** nos dados como é o caso dos dados de sobrevivência.

Importância

- **Avaliação de Risco e Fatores de Influência**
- **Suporte para Decisões Estratégicas**
- **Análise Longitudinal de Risco Dinâmico** para entender a evolução no tempo
- **Flexibilidade de Modelagem** ao incluir distribuição de probabilidade e covariáveis.

Características

- **Incorporação de censura e covariáveis:** consegue modelar dados censurados e a influência de covariáveis
- **Risco dinâmico:** permite que o risco de um evento mude ao longo do tempo.
- **Modelagem flexível:** adapta-se a diferentes distribuições de tempo de sobrevivência.

Limitações

- O Modelo de Cox assume **proporcionalidade dos riscos** (nem sempre válida).
- Modelos paramétricos exigem **validação cuidadosa** das suposições de distribuição.
- Sensível a **dados censurados** inadequadamente tratados.
- Coeficientes em **termos de riscos ou taxas** podem ser difíceis de interpretar diretamente.
- O ajuste e a validação do modelo podem se tornar desafiadores na **presença de muitas covariáveis**.

Aplicações

- **Medicina:** Identificar tratamentos que aumentam a sobrevida.
- **Engenharia:** Prever a vida útil de componentes mecânicos.
- **Marketing:** Modelar tempo até cancelamento de assinatura.
- **Recursos Humanos:** Analisar tempo até promoção ou saída de funcionários.
- **Negócios:** Analisar rotatividade de clientes em um serviço
- **Ciências sociais:** Estudar eventos como divórcios ou mudanças de emprego.

Tipos de Modelos de Regressão

- **Semiparamétrico: Modelos de Cox**

Não assume uma forma específica para a **distribuição** do tempo de sobrevivência, mas assume que **as covariáveis alteram a taxa de risco relativa** (riscos proporcionais)

- **Paramétrico: Modelos de Taxa Acelerada**

Assumem uma forma específica para a distribuição dos tempos e que as covariáveis **afetam diretamente o tempo de sobrevivência**, acelerando ou retardando o tempo até o evento de interesse.

Modelo de Regressão Semiparamétrico de Cox

Modelo de Cox

O modelo de regressão de Cox, também chamado de **modelo de riscos proporcionais**, é utilizado na análise de sobrevivência para **modelar diretamente a Função de Risco**.

É um método **semiparamétrico** que combina a flexibilidade de **não assumir** uma **distribuição** para o tempo de sobrevivência com a capacidade de **incluir covariáveis que alteram a taxa de risco**.

Risco Proporcional: a **razão de risco** (hazard ratio) **permanece constante ao longo do tempo** entre dois indivíduos ou grupos

Modelo de Cox

A função de sobrevivência ($S(t)$) estimada no modelo de Cox é expressa como:

$$S(t|X) = [S_o(t)]^{\exp(\beta X)}$$

em que

$S(t|X)$: probabilidade de sobrevivência do indivíduo no tempo t .

$S_o(t)$: curva de sobrevivência base (com covariáveis zero)

β : vetor de coeficientes estimados

X : vetor de covariáveis

$e^{\beta X}$: razão de riscos (hazard ratio - HR) entre grupos

Modelo de Cox

A **função de risco** ($h(t)$) no modelo de Cox é expressa como:

$$h(t|X) = h_o(t)e^{\beta X}$$

em que

$h(t|X)$: risco do evento no tempo t dado as covariáveis $X = (X_1, \dots, X_n)$

$h_o(t)$: função de risco base que representa o risco para $X = 0$ e não apresenta uma distribuição específica.

β : vetor de coeficientes que medem o impacto das covariáveis no risco.

$e^{\beta X}$: termo exponencial que ajusta o risco em função das covariáveis

Modelo de Cox

Proporcionalidade do Risco

Para dois indivíduos i e j , a razão de risco (HR) é dados por:

$$HR = \frac{h(t|X_i)}{h(t|X_j)} = \frac{h_0 t \cdot e^{\beta_1 X_{i1} + \dots + \beta_n X_{in}}}{h_0 t \cdot e^{\beta_1 X_{j1} + \dots + \beta_n X_{jn}}} = e^{\beta_1 (X_{i1} - X_{j1}) + \dots + \beta_n (X_{in} - X_{jn})} = e^{\beta X}$$

OBS: A **razão de risco não depende** do tempo t , mas permanece constante ao longo do tempo.

Isso significa que, sob a suposição de **riscos proporcionais**, se um grupo tem o dobro do risco de outro grupo em um instante t , essa **relação se mantém** para qualquer outro instante t .

Modelo de Cox

Proporcionalidade do Risco

O risco proporcional implica que:

- O **efeito das covariáveis** no risco é **constante** ao longo do tempo
- A **razão de risco** entre indivíduos é **fixa** e não depende do tempo

Modelo de Cox

Em alguns cenários, a suposição de riscos proporcionais pode não ser válida:

- **Mudança no efeito da covariável ao longo do tempo**

Exemplo: O efeito de um medicamento pode ser mais forte logo após a administração, mas diminuir ao longo do tempo.

- **Curvas de sobrevivência que se cruzam**

Se a função de risco de um grupo é inicialmente maior, mas depois se torna menor do que a de outro grupo, então a razão de riscos não é constante

- **Quando há um efeito retardado das covariáveis**

Exemplo: Exposição a um fator de risco (como fumar) pode ter um efeito de longo prazo, tornando o risco não proporcional no início

Modelo de Cox

Pressuposições do Modelo

- A **razão de risco** entre dois indivíduos permanece **constante** ao longo do tempo (Riscos Proporcionais).
- Independência dos Tempos de Sobrevivência
- O efeito das covariáveis é linear no logaritmo da função de risco
- Ausência de Multicolinearidade (correlação nula)

Modelo de Cox

Estimação dos Parâmetros

Método de **máxima verossimilhança parcial**: maximiza a probabilidade de que os dados observados tenham sido gerados pelo modelo

$$L(\beta) = \prod_{i=1}^n \left[\frac{\exp(\beta^T X_i)}{\sum_{j \in R(t_i)} \exp(\beta^T X_j)} \right]^{d_i}$$

A estimação dos parâmetros é feita por métodos numéricos, como o algoritmo de Newton-Raphson.

Modelo de Cox

Avaliação do Modelo

- **Validação Estatística:** Teste a significância dos coeficientes das covariáveis (p-valores ou intervalos de confiança).
- **Diagnóstico de Resíduos:** Avalie a adequação do modelo analisando resíduos.
- **Critérios de Ajuste:** Compare o AIC/BIC entre diferentes modelos.
 - Menor AIC/BIC melhor o modelo ajustado

Modelo de Cox

Interpretação do Parâmetro β

Os coeficientes (β): quantifica o impacto da covariável x sobre o risco.

p-valores: testam a hipótese nula de que $\beta = 0$ (ou seja, de que a covariável não tem efeito significativo sobre o risco)

Se $p - valor < 0.05$, rejeitamos a hipótese nula, concluindo que a covariável é significativa

Razão de Risco (HR) e^{β} : representa o efeito no risco associado a um aumento unitário na covariável

Modelo de Cox

Interpretação do Parâmetro β

- Se $\beta > 0$: O aumento em x **aumenta** o risco $h(t|X)$, ou seja, a probabilidade do evento ocorrer mais cedo.
- Se $\beta < 0$: O aumento em x **reduz** o risco $h(t|X)$, ou seja, prolonga o tempo até o evento

Modelo de Cox

Interpretação do Parâmetro β

Os coeficientes β são interpretados como o logaritmo da Razão de Risco (HR):

$$HR_j = e^{\beta_j}$$

- $HR_j > 1$: aumento em X_j associado a um risco maior do evento
- $HR_j < 1$: aumento em X_j associado a um risco menor do evento
- $HR_j = 1$: X_j não tem efeito no risco

Modelo de Cox

Análise de Resíduos

- **Resíduos de Schoenfeld:** validar a suposição de riscos proporcionais.

No gráfico um padrão temporal indica violação da suposição

- **Resíduos Cox-Snell:** Verifica se a distribuição escolhida para o modelo é adequada.

Um gráfico de resíduos Cox-Snell deve se aproximar de uma linha de 45 graus ($y = x$).

Desvio acima da linha indica que o modelo subestima a taxa de risco para certos tempos e **desvio abaixo da linha** que o modelo superestima

Modelo de Cox

Análise de Resíduos

- **Resíduos Generalizados:** Avaliam a adequação da escolha da distribuição dos erros.

O gráfico de resíduos generalizados deve mostrar um padrão aleatório.

- **Resíduos deviance:** Avaliam a diferença entre a função de sobrevivência estimada e a observada

Resíduos em torno do zero e sem padrões claros no gráfico indicam que o modelo é adequado.

Modelo de Cox

Análise de Resíduos

- **Análise de Resíduos (QQ Plots):** Compara os resíduos ajustados pelo modelo com a distribuição teórica.

Uma linha reta no gráfico indica que a distribuição escolhida é adequada para modelar os dados

- **Gráficos Log-Log:** Examinam a proporcionalidade dos riscos

Curvas paralelas sugerem que a suposição é válida

Modelo de Cox

Critérios dos Ajuste

Os critérios **Akaike Information Criterion (AIC)** e **Bayesian Information Criterion (BIC)** são amplamente usados para comparar modelos de regressão para dados de sobrevivência, especialmente para modelos paramétricos de taxa acelerada.

Eles ajudam a avaliar a **qualidade do ajuste** do modelo considerando a complexidade da modelagem.

Modelo de Cox

Critérios dos Ajuste

Akaike Information Criterion (AIC)

O AIC mede o ajuste do modelo enquanto **penaliza a complexidade excessiva** (quantidade de parâmetros). Ele é definido como:

$$AIC = -2 \log(L) + 2k$$

L é a verossimilhança máxima do modelo.

k é o número de parâmetros estimados.

Interpretação: Quanto **menor** o AIC, **melhor** o modelo.

Modelo de Cox

Critérios dos Ajuste

Bayesian Information Criterion (BIC)

O BIC também penaliza modelos mais complexos, mas com um peso maior que o AIC, pois leva em conta o tamanho da amostra (n):

$$BIC = -2 \log(L) + k \log(n)$$

n é o tamanho da amostra.

L é a verossimilhança máxima do modelo

k é o número de parâmetros estimados.

Interpretação: Quanto menor o BIC, melhor o modelo.

Modelo de Cox

Vantagens

- **Semiparamétrico:** Não requer a especificação da forma da distribuição de $h_o(t)$, tornando-o mais robusto.
- Adequado para explorar **efeitos de covariáveis** sem restrições severas.
- As razões de risco **fornece medidas claras** de associação.

Modelo de Cox

Limitações

- Suposição de **Riscos Proporcionais** se **violada**, os resultados podem ser enganosos.
- O modelo **assume** que o **efeito** das covariáveis é **linear no log-risco**.
- Muitos **dados incompletos** podem **afetar a precisão**.

Modelo de Cox

Quando Usar o Modelo

- Quando você tem dados censurados
- Quando quer avaliar o impacto de múltiplas covariáveis
- Quando a suposição de riscos proporcionais é validada

Modelo de Cox

Exemplo Hipotético1:

Os dados simulados representam um estudo clínico hipotético realizado para avaliar a eficácia de um novo tratamento em pacientes diagnosticados com câncer.

Objetivo: identificar fatores que influenciam a sobrevivência dos pacientes, como idade, sexo e se eles receberam ou não o tratamento experimental.

Modelo de Cox

Exemplo Hipotético 1:

Amostra: 100 pacientes diagnosticados com uma condição de câncer.

Local: Um grande hospital de referência especializado em oncologia.

Duração do Estudo: Os pacientes foram acompanhados por até 10 anos (120 meses)

Número de mortes observados: 70

Número de dados censurados: 30

Modelo de Cox

Exemplo Hipotético 1:

Tratamento Experimental: Um novo medicamento desenvolvido para reduzir a progressão da doença, aplicado em metade dos pacientes de forma randomizada

Covariáveis:

Idade: Pacientes de 30 a 80 anos.

Sexo: 0 = feminino, 1 = masculino.

Tratamento: 0 = grupo controle, 1 = grupo tratado.

Modelo de Cox

Exemplo Hipotético 1

Perguntas a serem respondidas:

- O tratamento experimental aumenta a sobrevivência dos pacientes?
- A idade afeta a sobrevivência dos pacientes?
- Há diferenças entre homens e mulheres na probabilidade de sobrevivência?

Instalando a Biblioteca para análise de Sobrevida

```
[ ] pip install lifelines
```

✓ Importando as funções

```
[ ] import pandas as pd  
import numpy as np  
from lifelines import CoxPHFitter  
from lifelines.plotting import add_at_risk_counts  
import matplotlib.pyplot as plt
```

▼ Inserir dados



1. Criação dos Dados Simulados

```
np.random.seed(42)
n = 100 # Número de pacientes

data = pd.DataFrame({
    'time': np.random.exponential(10, size=n).astype(int), # Tempo de sobrevivência
    'event': np.random.choice([1, 0], size=n, p=[0.7, 0.3]), # Evento (1=falha, 0=censurado)
    'age': np.random.randint(30, 80, size=n), # Idade
    'sex': np.random.choice([0, 1], size=n), # Sexo (0=feminino, 1=masculino)
    'treatment': np.random.choice([0, 1], size=n) # Tratamento (0=controle, 1=tratado)
})
print(data)
```



	time	event	age	sex	treatment
0	4	1	53	1	1
1	30	1	40	0	0
2	13	1	78	0	0
3	9	1	37	0	1
4	1	0	65	1	1
...	...	...	...	...	...
95	6	1	56	0	0
96	7	0	71	1	0
97	5	0	31	0	0
98	0	0	55	0	1
99	1	0	46	0	0

[100 rows x 5 columns]

time fit was run 2024-12-30 15:03:38 UTC

Concordance	0.53
--------------------	------

Partial AIC 509.21log-likelihood ratio test 0.68 on 3 df

-log2(p) of ll-ratio test 0.19

Interpretação dos Resultados

- Idade

	coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
age	0.00	1.00	0.01	-0.02	0.02	0.98	1.02	0.00	0.08	0.94	0.10
sex	0.19	1.21	0.25	-0.29	0.68	0.75	1.98	0.00	0.78	0.44	1.19
treatment	0.06	1.06	0.25	-0.43	0.54	0.65	1.72	0.00	0.23	0.82	0.29

Coeficiente (0,00): O risco não se altera com a idade

Razão de Risco (1,00): a idade não causa efeito no risco

p-valor (0,94): a idade é uma covariável não significativa

Interpretação dos Resultados

	coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
age	0.00	1.00	0.01	-0.02	0.02	0.98	1.02	0.00	0.08	0.94	0.10
sex	0.19	1.21	0.25	-0.29	0.68	0.75	1.98	0.00	0.78	0.44	1.19
treatment	0.06	1.06	0.25	-0.43	0.54	0.65	1.72	0.00	0.23	0.82	0.29

- **Sexo**

Coeficiente (0,19): homens tem o risco ligeiramente maior

Razão de Risco (1,21): homens têm um risco 21% maior de morte em comparação às mulheres

p-valor (0,44): o sexo é covariável não significativa para o estudo

Interpretação dos Resultados

	coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
age	0.00	1.00	0.01	-0.02	0.02	0.98	1.02	0.00	0.08	0.94	0.10
sex	0.19	1.21	0.25	-0.29	0.68	0.75	1.98	0.00	0.78	0.44	1.19
treatment	0.06	1.06	0.25	-0.43	0.54	0.65	1.72	0.00	0.23	0.82	0.29

- **Tratamento**


Coeficiente (0,06): O risco apresentou uma leve alteração com o tratamento.

Razão de Risco (1,06): pacientes tratados têm um risco 6% maior de morte em comparação aos pacientes no grupo controle

p-valor (0,82): o tratamento não é significativo para o estudo

Análise de Resíduos Schoenfeld

Scaled Schoenfeld residuals of 'age'




Os resíduos de Schoenfeld para variável idade não apresentaram padrão sistemático ao longo do tempo. A linha suavizada oscilou em torno de zero sem tendência clara de crescimento ou declínio.

Teste Rank-Transformed Time e KM-Transformed Time

H_0 : O risco é proporcional

$p\text{valor} > 0,05$ indica que a suposição de proporcionalidade dos risco não foi violada.

Análise de Resíduos Schoenfeld



Os resíduos de Schoenfeld para variável sexo mostraram alguma variação em torno de zero, mas sem padrão sistemático persistente. A linha suavizada manteve-se próxima da linha de referência.


Teste Rank-Transformed Time e KM-Transformed Time

H_0 : O risco é proporcional

$p\text{valor} > 0,05$ indica que a suposição de **proporcionalidade dos risco não foi violada.**

Análise de Resíduos Schoenfeld

Scaled Schoenfeld residuals of 'treatment'



Os resíduos de Schoenfeld para variável tratamento oscilaram em torno de zero. Embora haja dispersão em alguns pontos, não se observou tendência persistente ao longo do tempo.

Teste Rank-Transformed Time e KM-Transformed Time

H_0 : O risco é proporcional

$p\text{valor} > 0,05$ indica que a suposição de **proporcionalidade dos risco não foi violada.**

Estimando a Função de Sobrevivência $S(t)$ pelo Modelo de Cox


- ✓ Gráfico da função de sobrevivência para comparar 2 pacientes com 40 anos do sexo masculino: paciente 1 - controle e paciente 2 - tratado

```
# Predição de curvas de sobrevivência para diferentes perfis
new_patients = pd.DataFrame({
    'age': [40, 40], # Idade
    'sex': [1, 1],   # Sexo
    'treatment': [0, 1] # Tratamento
})

# Obter curvas de sobrevivência
survival_curves = cph.predict_survival_function(new_patients)

# Plotar curvas de sobrevivência
plt.figure(figsize=(10, 6))
for i, curve in enumerate(survival_curves.T.iterrows()):
    plt.plot(curve[1], label=f'Paciente {i+1}')
plt.title('Curvas de Sobrevivência Estimadas')
plt.xlabel('Tempo')
plt.ylabel('Probabilidade de Sobrevivência')
plt.legend()
plt.grid()
plt.show()
```

Função de sobrevivência estimada pelo Modelo de Cox



Caso: Pacientes com 40 anos do sexo masculino:
paciente 1 - controle
paciente 2 – tratado

A probabilidade de sobrevivência do paciente que não foi tratado é maior do que do paciente tratado com o remédio.


- ✓ Gráfico da função de sobrevivência para comparar 2 pacientes com 40 anos do sexo feminino: paciente 1 - controle e paciente 2 - tratado

```
[35] # Predição de curvas de sobrevivência para diferentes perfis
      new_patients = pd.DataFrame({
          'age': [40, 40], # Idade
          'sex': [0, 0],   # Sexo
          'treatment': [0, 1] # Tratamento
      })

      # Obter curvas de sobrevivência
      survival_curves = cph.predict_survival_function(new_patients)

      # Plotar curvas de sobrevivência
      plt.figure(figsize=(10, 6))
      for i, curve in enumerate(survival_curves.T.iterrows()):
          plt.plot(curve[1], label=f'Paciente {i+1}')
      plt.title('Curvas de Sobrevivência Estimadas')
      plt.xlabel('Tempo')
      plt.ylabel('Probabilidade de Sobrevivência')
      plt.legend()
      plt.grid()
      plt.show()
```

Função de sobrevivência estimada pelo Modelo de Cox



Caso: Pacientes com 40 anos do sexo feminino:
paciente 1 - controle
paciente 2 – tratado

A probabilidade de sobrevivência do paciente que não foi tratado é maior do que do paciente tratado com o remédio.

▼ Razão de risco para o tratamento no sexo masculino

```
[41] # 5. Razão de Risco
# Comparar dois pacientes:
# Paciente A: idade 40, sexo masculino, sem tratamento
# Paciente B: idade 40, sexo masculino, com tratamento

patient_A = pd.DataFrame({'age': [40], 'sex': [1], 'treatment': [0]})
patient_B = pd.DataFrame({'age': [40], 'sex': [1], 'treatment': [1]})

hazard_A = cph.predict_partial_hazard(patient_A).values[0]
hazard_B = cph.predict_partial_hazard(patient_B).values[0]
hazard_ratio = hazard_B / hazard_A

print(f"Razão de Risco (Paciente B / Paciente A): {hazard_ratio:.2f}")
```

⇒ Razão de Risco (Paciente B / Paciente A): 1.06

▼ Razão de Risco para o tratamento no sexo feminino

```
# 5. Razão de Risco
# Comparar dois pacientes:
# Paciente A: idade 40, sexo feminino, sem tratamento
# Paciente B: idade 40, sexo feminino, com tratamento

patient_A = pd.DataFrame({'age': [40], 'sex': [0], 'treatment': [0]})
patient_B = pd.DataFrame({'age': [40], 'sex': [0], 'treatment': [1]})

hazard_A = cph.predict_partial_hazard(patient_A).values[0]
hazard_B = cph.predict_partial_hazard(patient_B).values[0]
hazard_ratio = hazard_B / hazard_A

print(f"Razão de Risco (Paciente B / Paciente A): {hazard_ratio:.2f}")
```

⇒ Razão de Risco (Paciente B / Paciente A): 1.06

Caso: Pacientes com 40 anos do sexo masculino e feminino:

paciente 1 - controle

paciente 2 – tratado

Resultado: Paciente com 40 anos independente do sexo que foi tratado com a medicação nova apresentou um risco 6% maior de morte em comparação a não tratado

Modelo de Cox

Resultados

- **O tratamento experimental aumenta a sobrevivência dos pacientes?**

Resposta: Os pacientes que receberam o tratamento apresentaram um risco de morte 6 vezes maior, indicando um tratamento ineficaz.

- **A idade afeta a sobrevivência dos pacientes?**

Resposta: A idade não impactou nos resultados sendo estatisticamente não significativa no modelo indicando que pacientes mais velhos apresentaram o mesmo risco de morte do que pacientes mais novos

Modelo de Cox

Resultados

Há diferenças entre homens e mulheres na probabilidade de sobrevivência?

Resposta: O sexo não impactou nos resultados sendo estatisticamente não significativo no modelo indicando que o sexo não afeta a probabilidade de sobrevivência

Modelo de Cox

Conclusões

O que significa não ter significância nos parâmetros das covariáveis?

- O hazard ratio ($\exp(\text{coef})$) estimado para cada covariável não difere estatisticamente de 1
- Isso indica que, com os dados disponíveis, não há evidência de que idade, sexo ou tratamento influenciem o risco de evento

Importante: **não significa que as variáveis não tenham efeito na vida real**, mas sim que os dados não trouxeram evidência estatística suficiente

Modelo de Cox

Conclusões

O que fazer nesses casos?

- **Verificar qualidade e tamanho da amostra:** amostra tem 100 indivíduos e 70 eventos → razoável, mas ainda pode ser pouco para detectar efeitos pequenos.
- **Revisar modelo:** verificar se todas as covariáveis são necessárias → talvez um modelo mais parcimonioso (menos variáveis) seja melhor.
- **Testar pressupostos:** Se alguma variável violar riscos proporcionais, o teste de significância fica distorcido. Nesse caso, você poderia precisar de interação com o tempo ou modelos acelerados AFT.

Modelo de Cox

Conclusões

O que fazer nesses casos?

- **Explorar modelos alternativos:** se a hipótese de riscos proporcionais não faz sentido ou se os efeitos não são claros, pode ser útil tentar modelos paramétricos (Weibull, Log-normal) ou modelos acelerados (AFT).
- **Interpretação prática:** mesmo sem significância, os hazard ratios ainda dão tendência de direção. Exemplo: sexo $HR=1.21 \rightarrow$ sugere risco 21% maior, mas não é confiável estatisticamente. Dependendo do contexto, a informação exploratória pode ser útil para estudos futuros.

Modelo de Cox

Estratégias para lidar com a violação de proporcionalidade

Estratificação do modelo

- Usar strata (variável) no modelo de Cox. A variável não entra como covariável, mas o modelo permite que sua influência seja diferente entre estratos. Exemplo: `coxph(Surv(time, status) ~ age + treatment + strata(sex), data = dados)`

Modelos com efeitos dependentes do tempo

- Incluir a interação da covariável com a função do tempo (time-dependent covariates). Isso permite que o efeito da variável mude ao longo do tempo. Exemplo: `coxph(Surv(time, status) ~ age + treatment + sex + sex:tt(time), data = dados)`

Modelo de Cox

Estratégias para lidar com a violação de proporcionalidade

Modelos alternativos à regressão de Cox

- Modelos de regressão paramétricos de sobrevivência (exponencial, Weibull).
- Modelos de riscos proporcionais generalizados.
- Modelos AFT (Accelerated Failure Time), que não dependem do pressuposto de riscos proporcionais.

Modelo de Cox

Conclusões

Resumindo:

- Checar pressupostos de proporcionalidade
- Tentar reduzir o modelo
- Comparar com modelos alternativos (AFT, Weibull)

Importante: Se mesmo assim **não houver significância** → concluir que, para esse conjunto de dados, **não há efeito estatístico.**

Modelo de Regressão Paramétricos

Modelo de Regressão Paramétrico Clássico

Modelos paramétricos de regressão para análise de sobrevivência assumem que o **tempo** até o evento segue uma **distribuição de probabilidade específica**.

Isso contrasta com o modelo semi-paramétrico de Cox, que não faz essa suposição explícita.

Os modelos paramétricos são úteis quando há um **conhecimento prévio sobre a distribuição** dos tempos de falha e quando **se deseja extrapolar além do período observado**.

O efeito das covariáveis **não afeta diretamente o tempo de sobrevivência**, mas a **taxa de risco quando se tem risco proporcional**.

Modelo de Regressão Paramétrico Clássico

Os modelos de regressão paramétricos clássicos assumem que as **covariáveis** influenciam **diretamente** a função de risco $h(t)$ e atribui uma distribuição de probabilidade. A **função de risco** ($h(t)$) é expressa como:

$$h(t|X) = h_o(t)e^{\beta X} = h_o(t)\exp(\beta_1 X_1 + \cdots + \beta_n X_n)$$

em que

$h(t|X)$: risco do evento no tempo t dado as covariáveis $X = (X_1, \cdots, X_n)$

$h_o(t)$: função de risco base que representa o risco para $X = 0$ e assume uma distribuição de probabilidade específica.

β : vetor de coeficientes que medem o impacto das covariáveis no risco.

$e^{\beta X}$: termo exponencial que ajusta o risco em função das covariáveis

Modelos de Regressão Paramétricos Clássicos

Modelo Exponencial de Risco Proporcional

No modelo de regressão exponencial para análise de sobrevivência, é possível incluir covariáveis tais como idade, gênero, ou qualquer outra característica que influenciam a taxa de falha (ou risco) dos indivíduos.

O modelo exponencial assume que o **risco de falha é constante** ao longo do tempo, e com a inclusão de covariáveis, você pode modelar esse risco de forma ajustada às características estudadas.

Modelos de Regressão Paramétricos Clássicos

Modelo Exponencial de Risco Proporcional

Matematicamente, a Função de Risco de um modelo de regressão exponencial é dado por:

$$h(t|X) = \lambda e^{\beta X} = \lambda \cdot \exp(\beta_1 X_1 + \cdots + \beta_n X_n)$$

$h(t|X)$: taxa de falha no tempo t , dada as covariáveis X

λ : parâmetro de taxa de falha (parâmetro de escala) que descreve a falha em **função das covariáveis (coeficientes)**

$e^{\beta X}$: O risco relativo (hazard ratio) para a covariável (coeficiente).

Modelos de Regressão Paramétricos Clássicos

Modelo Exponencial de Risco Proporcional

Interpretação dos coeficientes β' s

Os coeficientes indicam a direção e a intensidade da associação entre as covariáveis e a taxa de falha (risco):

- **Coeficiente positivo:** Significa que, à medida que a covariável aumenta, o risco de falha aumenta.
- **Coeficiente negativo:** Significa que, à medida que a covariável aumenta, o risco de falha diminui.
- **O risco relativo** para variável for, por exemplo, de 1.025 significa que para cada aumento de 1 unidade na variável o risco de falha aumenta em 2.5%.

Modelos de Regressão Paramétricos Clássicos

Modelo Weibull de Risco Proporcional

O modelo de regressão Weibull para análise de sobrevivência, assim como o modelo exponencial, pode ser expandido para incluir covariáveis que modelam a relação entre as características do indivíduo e o tempo até o evento de interesse.

É capaz de modelar taxas de risco constante, crescentes ou decrescentes ao longo do tempo e a inclusão de covariáveis modela esse risco de forma ajustada às características estudadas.

Modelos Paramétricos Clássicos

Modelo Weibull de Risco Proporcional

Matematicamente, a Função de Risco de um modelo de regressão weibull é dado por:

$$h(t|X) = \lambda \rho t^{\rho-1} \exp(\beta_1 X_1 + \cdots + \beta_n X_n)$$

$h(t|X)$: taxa de falha no tempo t , dada as covariáveis X

λ : parâmetro de taxa de falha (parâmetro de escala)

ρ : parâmetro de forma que determina se o risco aumenta ou diminui com o tempo

$e^{\beta X}$: O risco relativo (hazard ratio) para a covariável (coeficiente).

Modelos de Regressão Paramétricos Clássicos

Modelo Exponencial de Risco Proporcional

Interpretação do parâmetro ρ :

Os coeficientes indicam a direção e a intensidade da associação entre as covariáveis e a taxa de falha (risco):

- $\rho > 1$: indica que o risco de falha aumenta.
- $\rho < 1$: indica que o risco de falha diminui.
- $\rho = 1$: o modelo se torna um modelo exponencial

Modelos de Regressão Paramétricos Clássicos

Modelo Weibull de Risco Proporcional

Interpretação dos coeficientes β' s

Os coeficientes indicam a direção e a intensidade da associação entre as covariáveis e a taxa de falha (risco):

- **Coeficiente positivo e $\rho > 1$** : Significa que, à medida que a covariável aumenta, o risco de falha aumenta.
- **Coeficiente negativo e $\rho < 1$** : Significa que, à medida que a covariável aumenta, o risco de falha diminui.
- **$\rho = 1$** : o modelo se torna um modelo exponencial
- **O risco relativo** para cada aumento de 1 unidade na variável o risco de falha aumenta ou diminui em $e^{\beta X}$.

Modelos de Regressão Paramétricos Clássicos

Os critérios AIC e BIC são especialmente úteis para escolher entre diferentes **modelos paramétricos e modelos de regressão** em análise de sobrevivência.

Modelo de Cox é semi-paramétrico e o AIC/BIC não é diretamente aplicável, pois não há uma função de verossimilhança completa especificada.

Modelos **Log-Normal** e **Log-Logístico** são baseados em situações que as **covariáveis afetam diretamente o tempo de sobrevivência** de forma acelerada ou desacelerada conhecidos como **Modelos de Taxa Acelerada.**

Modelo de Regressão Paramétrico de Taxa Acelerada

Modelo de Taxa Acelerada (AFT)

O modelo de taxa de falha acelerada (AFT) é uma **abordagem alternativa** à modelagem baseada na função de risco proporcional (como o modelo de Cox).

É particularmente útil para situações em que as **covariáveis afetam diretamente o tempo de sobrevivência**, acelerando ou retardando o tempo até o evento de interesse.

Modelo de Taxa Acelerada (AFT)

Características

- As **covariáveis** ajustam o **tempo de sobrevivência diretamente** multiplicando o tempo esperado de sobrevivência por um fator $e^{\beta x}$
- A **função de risco** $h(t)$ está relacionada ao **tempo transformado**
 $t^* = t \cdot e^{\beta x}$

OBS: O efeito das **covariáveis** é **multiplicativo** sobre o **tempo de sobrevivência** ao contrário do modelo de Cox, onde a **função de risco** é **proporcional**

$e^{\beta x}$: representa o fator de aceleração/desaceleração do tempo até o evento

Modelo de Taxa Acelerada

A suposição fundamental do modelo de taxa acelerada é que $\ln(T)$ segue uma distribuição linear em relação às covariáveis

$$\ln(T) = \beta_1 X_1 + \cdots + \beta_n X_n + \sigma\epsilon = \beta X + \sigma\epsilon$$

em que

T : Tempo de sobrevivência (variável dependente)

β : Vetor de coeficientes estimados associados a covariáveis

X : Vetor de covariáveis explicativas que podem influenciar o tempo de sobrevivência

$\sigma\epsilon$: termo de erro aleatório que captura a variação não explicada pelo modelo

Modelo de Taxa Acelerada

Pressuposições

- As covariáveis têm um efeito **linear no logaritmo do tempo** de sobrevivência
- O modelo assume que os **tempos de sobrevivência** e o **termo de erro** seguem uma **distribuição específica**, como Exponencial, Weibull, Log-normal, Log-logística, etc...
- Os **tempos de sobrevivência** das observações devem ser **independentes** uns dos outros.
- O componente determinístico $\exp(\beta X)$ é inserido no parâmetro de escala do modelo

Modelo de Taxa Acelerada

Principais Distribuições de Probabilidade

AFT Weibull

- Muito flexível, capaz de modelar taxas de risco crescentes ou decrescentes ao longo do tempo
- Amplamente usada em engenharia de confiabilidade
- A função de sobrevivência:

$$S(t; x) = e^{-\left(\frac{t}{\exp(\beta X)}\right)^{\frac{1}{\rho}}}$$

- Função de Risco

$$h(t|X) = \lambda \rho t^{\rho-1} e^{\beta X}$$

Modelo de Taxa Acelerada

Principais Distribuições de Probabilidade

AFT Log-Normal

- Adequado para dados de sobrevivência altamente assimétricos
- A função de sobrevivência:

$$S(t; x) = 1 - \Phi \left(\frac{\ln(t) - (\beta X)}{\sigma} \right)$$

- Função de Risco

$$h(t|X) = \frac{\frac{1}{t\sigma\sqrt{2\pi}} \exp \left(-\frac{(\ln(t) - \beta X)^2}{2\sigma^2} \right)}{1 - \Phi \left(\frac{\ln(t) - (\beta X)}{\sigma} \right)}$$

Modelo de Taxa Acelerada

Principais Distribuições de Probabilidade

AFT Log-Logística

- Permite modelar situações em que o risco é não monotônico (aumenta e depois diminui com o tempo)
- A função de sobrevivência:

$$S(t|x) = \frac{1}{1 + \left(\frac{t}{\exp(\beta X)} \right)^\gamma}$$

- Função de Risco

$$h(t|X) = \frac{\gamma t^{\gamma-1} e^{\gamma \beta X}}{1 + t^\gamma e^{\gamma \beta X}}$$

Modelo de Taxa Acelerada

Estimação dos Parâmetros

Os parâmetros do modelo AFT são estimados utilizando:

- **Estimador Máxima Verossimilhança (MLE)**

Maximiza a probabilidade dos dados observados serem produzidos pelo modelo

Produz estimativas robustas quando lidam com dados censurados

Modelo de Taxa Acelerada

Avaliação do Modelo

- **Validação Estatística:** Teste a significância dos coeficientes das covariáveis (valores p ou intervalos de confiança).
- **Diagnóstico de Resíduos:** Avalie a adequação do modelo analisando resíduos.
- **CrITÉrios de Ajuste:** Compare o AIC/BIC entre diferentes modelos.

→ Menor AIC/BIC melhor o modelo ajustado

Modelo de Taxa Acelerada

Significância do Parâmetro β

Os coeficientes (β): quantifica o impacto da covariável x sobre o tempo de sobrevivência.

p-valores: testam a hipótese nula de que $\beta = 0$ (ou seja, de que a covariável não tem efeito significativo sobre o risco)

Se $pvalor < 0.05$, rejeitamos a hipótese nula, concluindo que a covariável é significativa

Modelo de Taxa Acelerada

Interpretação do Parâmetro β

- Se $\beta > 0$: A covariável x **aumenta** o tempo de sobrevivência (a covariável tem um efeito protetor).
- Se $\beta < 0$: A covariável x **reduz** o tempo de sobrevivência (a covariável tem efeito prejudicial).

Modelo de Taxa Acelerada

Relação com o Tempo de Sobrevivência Original

No tempo de sobrevivência original (T), o modelo pode ser expresso como:

$$\exp(\beta_1 X_1 + \cdots + \beta_n X_n) = e^{\beta X}$$

O que implica que:

- $e^{\beta X}$ atua como um fator de aceleração que ajusta o tempo de sobrevivência

Modelo de Taxa Acelerada

Interpretação do Fator de Aceleração

- $e^{\beta X} > 1$: o tempo de sobrevivência aumenta (o evento ocorre mais lentamente).
- $e^{\beta X} < 1$: o tempo de sobrevivência diminui (o evento ocorre mais rapidamente).

Modelo de Taxa Acelerada

Análise de Resíduos

- **Resíduos de Schoenfeld:** validar a suposição de riscos proporcionais.
No gráfico um padrão temporal indica violação da suposição
- **Resíduos Cox-Snell:** Verifica se a distribuição escolhida para o modelo é adequada.
Um gráfico de resíduos Cox-Snell deve se aproximar de uma linha de 45 graus ($y = x$).
Desvio abaixo da linha indica que o modelo subestima a taxa de risco para certos tempos e **desvio acima da linha** que o modelo superestima

Modelo de Taxa Acelerada

Análise de Resíduos

- **Resíduos Generalizados:** Avaliam a adequação da escolha da distribuição dos erros.

O gráfico de resíduos generalizados deve mostrar um padrão aleatório.

- **Resíduos Deviance:** Avaliam a diferença entre a função de sobrevivência estimada e a observada

Resíduos em torno do zero e sem padrões claros no gráfico indicam que o modelo é adequado.

Modelo de Taxa Acelerada

Análise de Resíduos

- **Análise de Resíduos (QQ Plots):** Compara os resíduos ajustados pelo modelo com a distribuição teórica.

Uma linha reta nos gráficos indica que a distribuição escolhida é adequada para modelar os dados

Lognormal = Normal

Loglogístico = Logística

Weibull = Gumbel

Modelo de Taxa Acelerada

Crítérios dos Ajuste

Os critérios **Akaike Information Criterion (AIC)** e **Bayesian Information Criterion (BIC)** são amplamente usados para comparar modelos de regressão para dados de sobrevivência, especialmente para modelos paramétricos e modelos de taxa alecerada.

Eles ajudam a avaliar a **qualidade do ajuste** do modelo considerando a complexidade da modelagem.

Modelo de Taxa Acelerada

Critérios dos Ajuste

Akaike Information Criterion (AIC)

O AIC mede o ajuste do modelo enquanto **penaliza a complexidade excessiva** (quantidade de parâmetros). Ele é definido como:

$$AIC = -2 \log(L) + 2k$$

L é a verossimilhança máxima do modelo.

k é o número de parâmetros estimados (coeficientes, variância etc.).

Interpretação: Quanto **menor** o AIC, **melhor** o modelo.

Modelo de Taxa Acelerada

Critérios dos Ajuste

Bayesian Information Criterion (BIC)

O BIC também penaliza modelos mais complexos, mas com um peso maior que o AIC, pois leva em conta o tamanho da amostra (n):

$$BIC = -2 \log(L) + k \log(n)$$

n é o tamanho da amostra.

L é a verossimilhança máxima do modelo

k é o número de parâmetros estimados (coeficientes, variância etc.).

Interpretação: Quanto menor o BIC, melhor o modelo.

Modelo de Taxa Acelerada

Limitações

- **Distribuição paramétrica não adequada** geram estimativas enviesadas e pouco confiáveis
- **Sensibilidade a Outliers** que podem influenciar significativamente os resultados devido à sua estrutura paramétrica.

Modelo de Taxa Acelerada

Limitações

- **Muitos valores censurados** pode se tornar o ajuste do modelo menos preciso
- **Não fornece** diretamente **informações** sobre o **risco relativo**.
- **Muitas covariáveis** pode ser **computacionalmente** mais caro e menos eficiente.

Modelo de Taxa Acelerada

Quando Usar o Modelo

- Quando a interpretação dos **efeitos das covariáveis** no tempo é essencial
- Quando os dados seguem uma distribuição específica como Weibull ou log-normal.
- Quando a hipótese de **proporcionalidade de riscos** no **modelo de Cox** é violada.

Modelo de Taxa Acelerada

Exemplo Hipotético1:

Os dados simulados representam um estudo clínico hipotético realizado para avaliar a eficácia de um novo tratamento em pacientes diagnosticados com câncer.

Objetivo: identificar fatores que influenciam a sobrevivência dos pacientes, como idade, sexo e se eles receberam ou não o tratamento experimental.

Modelo de Taxa Acelerada

Exemplo Hipotético 1:

Amostra: 100 pacientes diagnosticados com uma condição de câncer.

Local: Um grande hospital de referência especializado em oncologia.

Duração do Estudo: Os pacientes foram acompanhados por até 10 anos (120 meses)

Número de mortes observados: 70

Número de dados censurados: 30

Modelo de Taxa Acelerada

Exemplo Hipotético 1:

Tratamento Experimental: Um novo medicamento desenvolvido para reduzir a progressão da doença, aplicado em metade dos pacientes de forma randomizada

Covariáveis:

Idade: Pacientes de 30 a 80 anos.

Sexo: 0 = feminino, 1 = masculino.

Tratamento: 0 = grupo controle, 1 = grupo tratado.

Modelo de Taxa Acelerada

Exemplo Hipotético 1

Perguntas a serem respondidas:

- O tratamento experimental aumenta a sobrevivência dos pacientes?
- A idade afeta a sobrevivência dos pacientes?
- Há diferenças entre homens e mulheres na probabilidade de sobrevivência?

✓ Instalando a Biblioteca

```
[1] pip install lifelines
```

✓ Importar as funções

```
[53] import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from lifelines import KaplanMeierFitter, CoxPHFitter, LogLogisticAFTFitter, WeibullAFTFitter, LogNormalAFTFitter
from lifelines.statistics import proportional_hazard_test
```

✓ Inserindo os dados

```
[81] # 1. Criação dos Dados Simulados
      np.random.seed(42)
      n = 100 # Número de pacientes

      data = pd.DataFrame({
          'time': np.random.exponential(10, size=n).astype(int)+ 1, # Tempo de sobrevivência
          'event': np.random.choice([1, 0], size=n, p=[0.7, 0.3]), # Evento (1=falha, 0=censurado)
          'age': np.random.randint(30, 80, size=n), # Idade
          'sex': np.random.choice([0, 1], size=n), # Sexo (0=feminino, 1=masculino)
          'treatment': np.random.choice([0, 1], size=n) # Tratamento (0=controle, 1=tratado)
      })
      print(data)
```

```
↵
   time  event  age  sex  treatment
0      5      1   53   1          1
1     31      1   40   0          0
2     14      1   78   0          0
3     10      1   37   0          1
4      2      0   65   1          1
..     ...    ...   ...   ...      ...
95      7      1   56   0          0
96      8      0   71   1          0
97      6      0   31   0          0
98      1      0   55   0          1
99      2      0   46   0          0
```

```
[100 rows x 5 columns]
```

Modelo de Taxa Acelerado Weibull

```
from lifelines import WeibullAFTFitter
# Ajustar um modelo AFT Weibull
aft_weibull = WeibullAFTFitter()
aft_weibull.fit(data, duration_col='time', event_col='event')

# Resumo do modelo
print("\nResumo do modelo AFT (Weibull):")
aft_weibull.print_summary()
```

Resumo do modelo AFT (Weibull):

model	lifelines.WeibullAFTFitter
duration col	'time'
event col	'event'
number of observations	100
number of events observed	70
log-likelihood	-252.67
time fit was run	2025-08-25 15:44:47 UTC

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
lambda_	age	-0.00	1.00	0.01	-0.02	0.02	0.98	1.02	0.00	-0.02	0.99	0.02
	sex	-0.17	0.84	0.21	-0.59	0.25	0.55	1.28	0.00	-0.80	0.42	1.24
	treatment	-0.07	0.93	0.22	-0.49	0.35	0.61	1.42	0.00	-0.34	0.73	0.44
	Intercept	2.78	16.07	0.48	1.83	3.73	6.23	41.48	0.00	5.74	<0.005	26.66
rho_	Intercept	0.12	1.13	0.09	-0.06	0.30	0.94	1.35	0.00	1.32	0.19	2.42

Concordance	0.53
AIC	515.34
log-likelihood ratio test	0.75 on 3 df
-log2(p) of ll-ratio test	0.21

Interpretação dos Resultados

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
lambda_	age	-0.00	1.00	0.01	-0.02	0.02	0.98	1.02	0.00	-0.02	0.99	0.02
	sex	-0.17	0.84	0.21	-0.59	0.25	0.55	1.28	0.00	-0.80	0.42	1.24
	treatment	-0.07	0.93	0.22	-0.49	0.35	0.61	1.42	0.00	-0.34	0.73	0.44
	Intercept	2.78	16.07	0.48	1.83	3.73	6.23	41.48	0.00	5.74	<0.005	26.66
rho_	Intercept	0.12	1.13	0.09	-0.06	0.30	0.94	1.35	0.00	1.32	0.19	2.42

- **Covariável Idade**

Coeficiente (-0,00): cada aumento de 1 ano na idade não interfere no tempo de sobrevivência esperado.

Fator de aceleração (1,00) o tempo de sobrevivência não é alterado com o aumento da idade.

p-valor (0,99): a idade é uma covariável não significativa para explicar a morte por câncer.

Interpretação dos Resultados

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
lambda_	age	-0.00	1.00	0.01	-0.02	0.02	0.98	1.02	0.00	-0.02	0.99	0.02
	sex	-0.17	0.84	0.21	-0.59	0.25	0.55	1.28	0.00	-0.80	0.42	1.24
	treatment	-0.07	0.93	0.22	-0.49	0.35	0.61	1.42	0.00	-0.34	0.73	0.44
	Intercept	2.78	16.07	0.48	1.83	3.73	6.23	41.48	0.00	5.74	<0.005	26.66
rho_	Intercept	0.12	1.13	0.09	-0.06	0.30	0.94	1.35	0.00	1.32	0.19	2.42

- **Sexo**

Coeficiente (-0,17): homens têm uma redução de 17% no tempo de sobrevivência esperado em comparação com as mulheres.

Fator de Aceleração (0,84) < 1 o tempo de sobrevivência diminui para o sexo masculino

p-valor (0,42): o sexo é covariável não significativa para o estudo

Interpretação dos Resultados

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
lambda_	age	-0.00	1.00	0.01	-0.02	0.02	0.98	1.02	0.00	-0.02	0.99	0.02
	sex	-0.17	0.84	0.21	-0.59	0.25	0.55	1.28	0.00	-0.80	0.42	1.24
	treatment	-0.07	0.93	0.22	-0.49	0.35	0.61	1.42	0.00	-0.34	0.73	0.44
	Intercept	2.78	16.07	0.48	1.83	3.73	6.23	41.48	0.00	5.74	<0.005	26.66
rho_	Intercept	0.12	1.13	0.09	-0.06	0.30	0.94	1.35	0.00	1.32	0.19	2.42

- Tratamento

Coeficiente (-0,07): O tratamento experimental diminuiu a sobrevivência em 7% em comparação com o tratamento padrão

Fator de Aceleração (0,93) < 1 pacientes em tratamento experimental diminuiu a sobrevivência em 93% em comparação com o tratamento padrão.

p-valor (0,73): o tratamento é não significativo para o estudo

Análise de Resíduos


✓ Resíduos de Cox-Snell

```
# Calcular a função de risco cumulativo predita para cada indivíduo no tempo observado
data['cox_snell_residuals'] = [
    aft_Weibull.predict_cumulative_hazard(data.iloc[[i]]).loc[data['time'].iloc[i]].values[0]
    for i in range(len(data))
]

# Ajustar um estimador Kaplan-Meier aos resíduos
from lifelines import KaplanMeierFitter
kmf = KaplanMeierFitter()
kmf.fit(data['cox_snell_residuals'], event_observed=data['event'])

# Plotar os resíduos de Cox-Snell
plt.figure(figsize=(10, 6))
plt.step(kmf.survival_function_.index, -np.log(kmf.survival_function_['KM_estimate']), where="post", label="Kaplan-Meier")
plt.plot([0, max(data['cox_snell_residuals'])], [0, max(data['cox_snell_residuals'])], linestyle='--', color='red', label="Linha de referência")
plt.title("Resíduos de Cox-Snell para o Modelo Weibull AFT")
plt.xlabel("Resíduo de Cox-Snell")
plt.ylabel("-log(S(t)) (estimado)")
plt.legend()
plt.grid()
plt.show()
```

Resíduo de Cox-Snell



Desvio acima ou abaixo da linha indica que o modelo superestima ou subestima a taxa de risco para certos tempos.

Indica um bom ajuste do modelo aos dados


Resíduos Deviance

▼ Resíduos Deviance

```
[58] # Resíduos vs. Previsões
      previsoes = aft_Weibull.predict_expectation(data)

      plt.figure(figsize=(10, 6))
      plt.scatter(previsoes, data['residuo'], alpha=0.7, color='blue')
      plt.axhline(0, color='red', linestyle='--', linewidth=1)
      plt.title("Resíduos vs. Previsões (Modelo Weibull AFT)", fontsize=14)
      plt.xlabel("Tempo Esperado de Sobrevida (Previsões)", fontsize=12)
      plt.ylabel("Resíduos", fontsize=12)
      plt.grid(True)
      plt.show()
```

Resíduos vs. Previsões



Concentração dos tempos previstos em poucos valores (12, 13, 14, 15) indicando os coeficientes são poucos significativos o que limita o poder explicativo do modelo.


Análise de Resíduos

```
# Pegar o parâmetro rho_ do modelo
rho = 0.12
sigma = 1 / rho

# Padronizar resíduos
residuos_padronizados = data['residuo'] / sigma

# QQ-plot
stats.probplot(residuos_padronizados, dist="gumbel_r", plot=plt)
plt.title("QQ-Plot dos Resíduos Padronizados (Weibull AFT vs Gumbel)")
plt.xlabel("Quantis Teóricos (Gumbel)")
plt.ylabel("Quantis Observados (Resíduos)")
plt.grid(True)
plt.show()
```

QQ-Plot dos Resíduos



O desvio nas caudas sugere que os resíduos podem não seguir perfeitamente a distribuição Gumbel nas regiões extremas, apresentando alguma assimetria ou outliers.

O modelo está razoavelmente adequado para capturar o comportamento geral dos resíduos, mas pode haver alguma limitação para capturar os extremos.

Análise de Resíduos

✓ Curva de Sobrevida Kaplan-Meier vs Modelo Ajustado Weibul_AFT

```
[102] # Curva de Sobrevida (Kaplan-Meier vs Modelo Weibull)
      kmf = KaplanMeierFitter()
      plt.figure(figsize=(10, 6))


      # Estimativa Kaplan-Meier
      kmf.fit(data['time'], event_observed=data['event'], label='Kaplan-Meier')
      kmf.plot_survival_function(ci_show=True, ax=plt.gca(), color='blue')

      # Previsão do Modelo Weibull
      times = np.linspace(1, data['time'].max(), 100)
      survival_curve = aft_Weibull.predict_survival_function(data.iloc[0:1], times=times)
      plt.plot(times, survival_curve.values.flatten(), label='Weibull AFT', color='red', linestyle='--')

      # Configurações do Gráfico
      plt.title("Curva de Sobrevida: Kaplan-Meier vs Weibull AFT", fontsize=14)
      plt.xlabel("Tempo", fontsize=12)
      plt.ylabel("Probabilidade de Sobrevida", fontsize=12)
      plt.legend(fontsize=12)
      plt.grid(True)
      plt.tight_layout()
      plt.show()
```

Curva de sobrevivência estimada

Modelo Weibull AFT vs. Kaplan Meier



o modelo apresenta um bom ajuste à curva de sobrevivência empírica, principalmente nos tempos iniciais e intermediários. Apesar de uma leve subestimação da probabilidade de sobrevivência em tempos mais longos,

Métricas do Ajuste do Modelo Weibull

▼ AIC e BIC do modelo AFT_Weibull

```
[20] print(aft_Weibull.AIC_)  
      print (aft_Weibull.BIC_)
```

```
⇒ 515.3402400083787  
   514.550580380355
```

Modelo de Taxa Acelerado Log-Normal

Resumo do modelo AFT (Weibull):

model		lifelines.LogNormalAFTFitter															
duration col		'time'															
event col		'event'															
number of observations		100															
number of events observed		70															
log-likelihood		-253.74															
time fit was run		2025-08-25 17:43:00 UTC															
		coef	exp(coef)	se(coef)	coef	lower 95%	coef	upper 95%	exp(coef)	lower 95%	exp(coef)	upper 95%	cmp to	z	p	-log2(p)	
mu_	age	-0.00	1.00	0.01		-0.02		0.01			0.98		1.02	0.00	-0.30	0.77	0.38
	sex	-0.13	0.88	0.25		-0.62		0.36			0.54		1.44	0.00	-0.52	0.61	0.72
	treatment	-0.02	0.98	0.25		-0.52		0.47			0.60		1.60	0.00	-0.10	0.92	0.12
	Intercept	2.39	10.97	0.54		1.35		3.44			3.84		31.31	0.00	4.47	<0.005	16.99
sigma_	Intercept	0.13	1.14	0.08		-0.04		0.29			0.96		1.34	0.00	1.50	0.13	2.92
Concordance		0.53															
AIC		517.47															
log-likelihood ratio test		0.42 on 3 df															
-log2(p) of ll-ratio test		0.09															

Interpretação dos Resultados

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
mu_	age	-0.00	1.00	0.01	-0.02	0.01	0.98	1.02	0.00	-0.30	0.77	0.38
	sex	-0.13	0.88	0.25	-0.62	0.36	0.54	1.44	0.00	-0.52	0.61	0.72
	treatment	-0.02	0.98	0.25	-0.52	0.47	0.60	1.60	0.00	-0.10	0.92	0.12
	Intercept	2.39	10.97	0.54	1.35	3.44	3.84	31.31	0.00	4.47	<0.005	16.99
sigma_	Intercept	0.13	1.14	0.08	-0.04	0.29	0.96	1.34	0.00	1.50	0.13	2.92

- **Covariável Idade**

Coeficiente (-0,00): cada aumento de 1 ano na idade não interfere no tempo de sobrevivência esperado.

Fator de aceleração (1,00) o tempo de sobrevivência não é alterado com o aumento da idade.

p-valor (0,77): a idade é uma covariável não significativa para explicar a morte por câncer.

Interpretação dos Resultados

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
mu_	age	-0.00	1.00	0.01	-0.02	0.01	0.98	1.02	0.00	-0.30	0.77	0.38
	sex	-0.13	0.88	0.25	-0.62	0.36	0.54	1.44	0.00	-0.52	0.61	0.72
	treatment	-0.02	0.98	0.25	-0.52	0.47	0.60	1.60	0.00	-0.10	0.92	0.12
	Intercept	2.39	10.97	0.54	1.35	3.44	3.84	31.31	0.00	4.47	<0.005	16.99
sigma_	Intercept	0.13	1.14	0.08	-0.04	0.29	0.96	1.34	0.00	1.50	0.13	2.92

- Sexo

Coeficiente (-0,13): homens têm uma redução de 13% no tempo de sobrevivência esperado em comparação com as mulheres.

Fator de Aceleração (0,88) < 1 o tempo de sobrevivência diminui para o sexo masculino

p-valor (0,61): o sexo é covariável não significativa para o estudo

Interpretação dos Resultados

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
mu_	age	-0.00	1.00	0.01	-0.02	0.01	0.98	1.02	0.00	-0.30	0.77	0.38
	sex	-0.13	0.88	0.25	-0.62	0.36	0.54	1.44	0.00	-0.52	0.61	0.72
	treatment	-0.02	0.98	0.25	-0.52	0.47	0.60	1.60	0.00	-0.10	0.92	0.12
	Intercept	2.39	10.97	0.54	1.35	3.44	3.84	31.31	0.00	4.47	<0.005	16.99
sigma_	Intercept	0.13	1.14	0.08	-0.04	0.29	0.96	1.34	0.00	1.50	0.13	2.92

- **Tratamento**

Coeficiente (-0,02): O tratamento experimental diminuiu a sobrevivência em 2% em comparação com o tratamento padrão

Fator de Aceleração (0,98) < 1 pacientes em tratamento experimental diminuiu a sobrevivência em 98% em comparação com o tratamento padrão.

p-valor (0,92): o tratamento é não significativo para o estudo

Análise de Resíduos


▼ Resíduos Cox-Snell

```
[85] # Calcular a função de risco cumulativo predita para cada indivíduo no tempo observado
data['cox_snell_residuals'] = [
    aft_LogNormal.predict_cumulative_hazard(data.iloc[[i]].loc[data['time'].iloc[i]].values[0])
    for i in range(len(data))
]

# Ajustar um estimador Kaplan-Meier aos resíduos
from lifelines import KaplanMeierFitter
kmf = KaplanMeierFitter()
kmf.fit(data['cox_snell_residuals'], event_observed=data['event'])

# Plotar os resíduos de Cox-Snell
plt.figure(figsize=(10, 6))
plt.step(kmf.survival_function_.index, -np.log(kmf.survival_function_['KM_estimate']), where="post", label="Kaplan-Meier")
plt.plot([0, max(data['cox_snell_residuals'])], [0, max(data['cox_snell_residuals'])], linestyle='--', color='red', label="Linha de referência")
plt.title("Resíduos de Cox-Snell para o Modelo LogNormal AFT")
plt.xlabel("Resíduo de Cox-Snell")
plt.ylabel("-log(S(t)) (estimado)")
plt.legend()
plt.grid()
plt.show()
```

Resíduo de Cox-Snell



A curva se afasta da linha de identidade $\rightarrow$ pode haver superestimação ou subestimação do risco cumulativo para indivíduos com tempos de sobrevivência mais altos (ou eventos tardios).

Pode sugerir que o modelo não está representando bem a cauda da distribuição.


Resíduos Deviance

Resíduos Deviance

```
] # Resíduos vs. Previsões
previsoes = aft_LogNormal.predict_expectation(data)

plt.figure(figsize=(10, 6))
plt.scatter(previsoes, data['residuo_log'], alpha=0.7, color='blue')
plt.axhline(0, color='red', linestyle='--', linewidth=1)
plt.title("Resíduos vs. Previsões (Modelo Log-Normal AFT)", fontsize=14)
plt.xlabel("Tempo Esperado de Sobrevida (Previsões)", fontsize=12)
plt.ylabel("Resíduos", fontsize=12)
plt.grid(True)
plt.show()
```

Resíduos vs. Previsões



A análise do resíduo deviance foi menos sensível a não significância dos parâmetros do que o modelo weibull.

Resíduos aleatório em torno do zero indica um bom ajuste.


Análise de Resíduos

✓ QQ-Plot dos resíduos

```
[87] # QQ-Plot dos Resíduos
import scipy.stats as stats

plt.figure(figsize=(10, 6))
stats.probplot(data['residuo_log'], dist="norm", plot=plt)
plt.title("QQ-Plot dos Resíduos (Modelo Log-Normal AFT)", fontsize=14)
plt.xlabel("Quantis Teóricos", fontsize=12)
plt.ylabel("Quantis Observados", fontsize=12)
plt.grid(True)
plt.show()
```

QQ-Plot dos Resíduos



O modelo está razoavelmente adequado para capturar o comportamento geral dos resíduos, mas pode haver alguma limitação para capturar os extremos.

Nas extremidades, há um desvio um pouco maior, mas não muito expressivo, indicando que os resíduos seguem bem a distribuição log-normal.

Análise de Resíduos

Curva de sobrevivência Kaplan-Meier vs AFT-Log-normal

```
95] # Curva de Sobrevivência (Kaplan-Meier vs Modelo Weibull)
    kmf = KaplanMeierFitter()
    plt.figure(figsize=(10, 6))


    # Estimativa Kaplan-Meier
    kmf.fit(data['time'], event_observed=data['event'], label='Kaplan-Meier')
    kmf.plot_survival_function(ci_show=True, ax=plt.gca(), color='blue')

    # Previsão do Modelo Weibull
    times = np.linspace(1, data['time'].max(), 100)
    survival_curve = aft_LogNormal.predict_survival_function(data.iloc[0:1], times=times)
    plt.plot(times, survival_curve.values.flatten(), label='Log-Normal AFT', color='red', linestyle='--')

    # Configurações do Gráfico
    plt.title("Curva de Sobrevivência: Kaplan-Meier vs Log-Normal AFT", fontsize=14)
    plt.xlabel("Tempo", fontsize=12)
    plt.ylabel("Probabilidade de Sobrevivência", fontsize=12)
    plt.legend(fontsize=12)
    plt.grid(True)
    plt.tight_layout()
    plt.show()
```

Curva de sobrevivência estimada

Modelo Log-Normal AFT vs. Kaplan Meier



o modelo apresenta um bom ajuste à curva de sobrevivência empírica nos tempos iniciais.

Apesar de uma leve sub e super estimação da probabilidade de sobrevivência em tempos médio e mais longos respectivamente.

Métricas do Ajuste do Modelo Log-Normal

▼ AIC e BIC log_normal

```
[88] print(aft_LogNormal.AIC_)  
      print (aft_LogNormal.BIC_)
```

```
⇒ 517.4733597682896  
   516.6837001402658
```

Modelo de Taxa Acelerado Log-Logístico

Resumo do modelo AFT (Log-logístico):

model		lifelines.LogLogisticAFTFitter														
duration col		'time'														
event col		'event'														
number of observations		100														
number of events observed		70														
log-likelihood		-255.00														
time fit was run		2025-08-25 17:46:46 UTC														
		coef	exp(coef)	se(coef)	coef	lower 95%	coef	upper 95%	exp(coef)	lower 95%	exp(coef)	upper 95%	cmp to	z	p	-log2(p)
alpha_	age	-0.00	1.00	0.01	-0.02		0.01		0.98		1.01	0.00	-0.39	0.69	0.53	
	sex	-0.15	0.86	0.25	-0.65		0.35		0.52		1.42	0.00	-0.59	0.55	0.85	
	treatment	0.04	1.04	0.26	-0.47		0.54		0.63		1.72	0.00	0.14	0.89	0.17	
	Intercept	2.47	11.88	0.55	1.40		3.55		4.05		34.86	0.00	4.51	<0.005	17.21	
beta_	Intercept	0.41	1.51	0.10	0.22		0.60		1.25		1.82	0.00	4.27	<0.005	15.63	
Concordance		0.54														
AIC		520.00														
log-likelihood ratio test		0.51 on 3 df														
-log2(p) of ll-ratio test		0.12														

Interpretação dos Resultados

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
alpha_	age	-0.00	1.00	0.01	-0.02	0.01	0.98	1.01	0.00	-0.39	0.69	0.53
	sex	-0.15	0.86	0.25	-0.65	0.35	0.52	1.42	0.00	-0.59	0.55	0.85
	treatment	0.04	1.04	0.26	-0.47	0.54	0.63	1.72	0.00	0.14	0.89	0.17
	Intercept	2.47	11.88	0.55	1.40	3.55	4.05	34.86	0.00	4.51	<0.005	17.21
beta_	Intercept	0.41	1.51	0.10	0.22	0.60	1.25	1.82	0.00	4.27	<0.005	15.63

- Covariável Idade

Coeficiente (-0,00): cada aumento de 1 ano na idade não interfere no tempo de sobrevivência esperado.

Fator de aceleração (1,00) o tempo de sobrevivência não é alterado com o aumento da idade.

p-valor (0,69): a idade é uma covariável não significativa para explicar a morte por câncer.

Interpretação dos Resultados

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
alpha_	age	-0.00	1.00	0.01	-0.02	0.01	0.98	1.01	0.00	-0.39	0.69	0.53
	sex	-0.15	0.86	0.25	-0.65	0.35	0.52	1.42	0.00	-0.59	0.55	0.85
	treatment	0.04	1.04	0.26	-0.47	0.54	0.63	1.72	0.00	0.14	0.89	0.17
	Intercept	2.47	11.88	0.55	1.40	3.55	4.05	34.86	0.00	4.51	<0.005	17.21
beta_	Intercept	0.41	1.51	0.10	0.22	0.60	1.25	1.82	0.00	4.27	<0.005	15.63

- Sexo

Coeficiente (-0,15): homens têm uma redução de 15% no tempo de sobrevivência esperado em comparação com as mulheres.

Fator de Aceleração (0,86) < 1 o tempo de sobrevivência diminui para o sexo masculino

p-valor (0,55): o sexo é covariável não significativa para o estudo

Interpretação dos Resultados

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
alpha_	age	-0.00	1.00	0.01	-0.02	0.01	0.98	1.01	0.00	-0.39	0.69	0.53
	sex	-0.15	0.86	0.25	-0.65	0.35	0.52	1.42	0.00	-0.59	0.55	0.85
	treatment	0.04	1.04	0.26	-0.47	0.54	0.63	1.72	0.00	0.14	0.89	0.17
	Intercept	2.47	11.88	0.55	1.40	3.55	4.05	34.86	0.00	4.51	<0.005	17.21
beta_	Intercept	0.41	1.51	0.10	0.22	0.60	1.25	1.82	0.00	4.27	<0.005	15.63

- Tratamento

Coeficiente (0,04): O tratamento experimental aumentou a sobrevivência em 4% em comparação com o tratamento padrão

Fator de Aceleração (1,04) > 1 pacientes em tratamento experimental aumentou a sobrevivência em 4% em comparação com o tratamento padrão.

p-valor (0,89): o tratamento é não significativo para o estudo

Análise de Resíduos


▼ Resíduos de cox-snell

```
[95] # Calcular a função de risco cumulativo predita para cada indivíduo no tempo observado
data['cox_snell_residuals'] = [
    aft_LogListico.predict_cumulative_hazard(data.iloc[[i]]).loc[data['time'].iloc[i]].values[0]
    for i in range(len(data))
]

# Ajustar um estimador Kaplan-Meier aos resíduos
from lifelines import KaplanMeierFitter
kmf = KaplanMeierFitter()
kmf.fit(data['cox_snell_residuals'], event_observed=data['event'])

# Plotar os resíduos de Cox-Snell
plt.figure(figsize=(10, 6))
plt.step(kmf.survival_function_.index, -np.log(kmf.survival_function_['KM_estimate']), where="post", label="Kaplan-Meier")
plt.plot([0, max(data['cox_snell_residuals'])], [0, max(data['cox_snell_residuals'])], linestyle='--', color='red', label="Linha de referência")
plt.title("Resíduos de Cox-Snell para o Modelo Log-Logístico AFT")
plt.xlabel("Resíduo de Cox-Snell")
plt.ylabel("-log(S(t)) (estimado)")
plt.legend()
plt.grid()
plt.show()
```

Resíduo de Cox-Snell



A curva se afasta da linha de identidade → pode haver superestimação ou subestimação do risco cumulativo para indivíduos com tempos de sobrevivência mais altos.

O modelo LogLogístico AFT tem um ajuste razoável nos dados, mas pode ser melhorado, especialmente para valores maiores do tempo residual.

Resíduos Deviance


✓ Resíduos Deviance

```
[94] # Resíduos vs. Previsões
      previsoos = aft_logListico.predict_expectation(data)

      plt.figure(figsize=(10, 6))
      plt.scatter(previsoos, data['residuo_log1'], alpha=0.7, color='blue')
      plt.axhline(0, color='red', linestyle='--', linewidth=1)
      plt.title("Resíduos vs. Previsões (Modelo Log-Logístico AFT)", fontsize=14)
      plt.xlabel("Tempo Esperado de Sobrevida (Previsões)", fontsize=12)
      plt.ylabel("Resíduos", fontsize=12)
      plt.grid(True)
      plt.show()
```

Resíduos vs. Previsões

Resíduos vs. Previsões (Modelo Log-Logístico AFT)



A análise do resíduo deviance também foi menos sensível a não significância dos parâmetros do que o modelo weibull.

Resíduos aleatório em torno do zero indica um bom ajuste e sugere ausência de viés sistemático.

Análise de Resíduos


✓ QQplot do modelo Log-logístico

```
[97] import scipy.stats as stats
import matplotlib.pyplot as plt

# Parâmetro de forma da distribuição log-logística (c = 1 / beta)
c = 1 / 0.41 # aproximadamente 2.44

plt.figure(figsize=(10, 6))
# Usando 'fisk' que é a distribuição log-logística no scipy
stats.probplot( data['residuo_logl'], dist="fisk",sparams=(c,), plot=plt)
plt.title("QQ-Plot dos Resíduos (Modelo Log-Logístico AFT)", fontsize=14)
plt.xlabel("Quantis Teóricos (Log-Logístico)", fontsize=12)
plt.ylabel("Quantis Observados (Resíduos)", fontsize=12)
plt.grid(True)
plt.show()
```

QQ-Plot dos Resíduos



O gráfico sugere que o modelo log-logístico não se ajusta perfeitamente aos dados.

O modelo parece razoável no centro da distribuição, mas falha nas caudas — especialmente para grandes valores de tempo de sobrevivência.

Análise de Resíduos

Curva de sobrevivência por Kaplan-Meier vesus AFT Log-Logístico

```
[ ] # Curva de Sobrevivência (Kaplan-Meier vs Modelo Weibull)
    kmf = KaplanMeierFitter()
    plt.figure(figsize=(10, 6))


    # Estimativa Kaplan-Meier
    kmf.fit(data['time'], event_observed=data['event'], label='Kaplan-Meier')
    kmf.plot_survival_function(ci_show=True, ax=plt.gca(), color='blue')

    # Previsão do Modelo Weibull
    times = np.linspace(1, data['time'].max(), 100)
    survival_curve = aft_Loglistico.predict_survival_function(data.iloc[0:1], times=times)
    plt.plot(times, survival_curve.values.flatten(), label='Log-Logístico AFT', color='red', linestyle='--')

    # Configurações do Gráfico
    plt.title("Curva de Sobrevivência: Kaplan-Meier vs Log-Logístico AFT", fontsize=14)
    plt.xlabel("Tempo", fontsize=12)
    plt.ylabel("Probabilidade de Sobrevivência", fontsize=12)
    plt.legend(fontsize=12)
    plt.grid(True)
    plt.tight_layout()
    plt.show()
```

Curva de sobrevivência estimada

Modelo Log-Logístico AFT vs. Kaplan Meier



O modelo Log-Logístico AFT apresenta um ajuste razoável em todos os períodos de tempo, resultado não melhorou em relação o Log-Normal em médio e longo prazo.

Ele permanece dentro da faixa de confiança da curva empírica, oferecendo uma modelagem confiável da sobrevivência.

Métricas do Ajuste do Modelo Log-Logístico

▼ AIC e BIC modelo Log-Logístico

```
[19] print(aft_LogListico.AIC_)  
      print (aft_LogListico.BIC_)
```

```
→ 520.0008555658573  
   519.2111959378334
```

Modelo de Taxa Acelerada

Conclusões:

Após usar os modelos de taxa acelerada os resultados mostraram que as covariáveis estudadas não foram são significativas para estudar o tempo do óbito dos pacientes.

Não significa que as covariáveis não tenham efeito na vida real, mas sim que os dados não trouxeram evidência estatística suficiente

Se por conhecimento prévio do analista for julgado que as covariáveis são importantes, deve-se verificar a qualidade do tamanho da amostra.

Modelo de Taxa Acelerada

Exemplo Hipotético 2:

Pesquisa conduzida para investigar o tempo de sobrevivência de pacientes após o diagnóstico de insuficiência cardíaca, considerando variáveis como idade, sexo e tratamento.

Objetivos:

Investigar os fatores que influenciam o tempo de sobrevivência de pacientes diagnosticados com a doença de insuficiência cardíaca.

Modelo de Taxa Acelerada

Exemplo Hipotético 2:

Este estudo acompanha 300 pacientes diagnosticados com a mesma condição médica grave. Os pacientes foram alocados aleatoriamente em dois grupos:

- Tratamento padrão.
- Tratamento experimental.

Modelo de Taxa Acelerada

Exemplo Hipotético 2

Amostra: 300 pacientes diagnosticado com insuficiência cardíaca

Duração do Estudo: 120 meses (10 anos)

Tratamento Experimental: novo medicamento

Número de mortes observados: 214

Número de dados censurados: 86

Modelo de Taxa Acelerada

Exemplo Hipotético 2

Covariáveis:

Idade (age): Faixa: 30 a 80 anos.

Sexo (sex): 1 = Male (homem) ; 0 = Female (mulher).

Tratamento (treatment): 1 = Experimental, 0 = Standard).

Tempo de sobrevivência (temp): Tempo medido em meses até o evento (óbito) ou censura.

Evento (event): 1 = falha, 0 = censurado.

Modelo de Taxa Acelerada

Exemplo Hipotético 2

A pergunta central do estudo era:

- Como a **idade** do paciente afeta o tempo de sobrevivência?
- Existe uma diferença de sobrevivência entre homens e mulheres?
- O **tratamento experimental** melhora a sobrevivência em comparação com o tratamento padrão?

Modelo de Taxa Acelerado Weibull

✓ Instalando a Biblioteca para análise de Sobrevivência

```
▶ pip install lifelines
```

✓ Importar as funções

```
[ ] import pandas as pd
import numpy as np
from lifelines import WeibullAFTFitter, LogNormalAFTFitter, KaplanMeierFitter
from lifelines.datasets import load_rossi
import matplotlib.pyplot as plt
import scipy.stats as stats
```

✓ Carregar os dados



```
# Fixar semente para reprodutibilidade
np.random.seed(42)

# Criar dados sintéticos
n = 300 # Número de pacientes
age = np.random.uniform(30, 80, n) # Idade dos pacientes (30-80 anos)
sex = np.random.choice(['Male', 'Female'], size=n) # Sexo
treatment = np.random.choice(['Standard', 'Experimental'], size=n) # Tipo de tratamento

# Mapear variáveis categóricas para numéricas
sex_numeric = (sex == 'Male').astype(int) # 1 para Male, 0 para Female
treatment_numeric = (treatment == 'Experimental').astype(int) # 1 para Experimental, 0 para Standard

# Gerar tempos de sobrevivência simulados (em meses)
baseline_hazard = 0.02
survival_time = (-np.log(np.random.uniform(0, 1, n)) /
                 (baseline_hazard * np.exp(0.03 * age - 0.5 * treatment_numeric + 0.2 * sex_numeric)))
survival_time = np.round(survival_time, 2)

# Gerar censura (evento observado ou não)
censoring = np.random.uniform(0.8, 1.5, n) * survival_time
event_observed = (survival_time <= censoring).astype(int) # 1 para falha, 0 para censurado
observed_time = np.minimum(survival_time, censoring)
```

```
# Construir DataFrame
data = pd.DataFrame({
    'age': age,
    'sex': sex_numeric,          # Usando valores numéricos
    'treatment': treatment_numeric, # Usando valores numéricos
    'time': observed_time,
    'event': event_observed
})

# Visualizar os primeiros dados
print(data.head())
```

	age	sex	treatment	time	event
0	48.727006	1	0	15.960384	0
1	77.535715	0	1	8.423111	0
2	66.599697	0	1	17.946813	0
3	59.932924	0	0	20.060000	1
4	37.800932	1	0	27.860000	1

✓ Ajuste do modelo Taxa Acelerada Weibull

```
[ ] # Ajustar um modelo AFT Weibull
aft_model = WeibullAFTFitter()
aft_model.fit(data, duration_col='time', event_col='event')

# Resumo do modelo
aft_model.print_summary()
```



model	lifelines.WeibullAFTFitter
duration col	'time'
event col	'event'
number of observations	300
number of events observed	214
log-likelihood	-802.80
time fit was run	2024-12-31 23:57:20 UTC

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
lambda_	age	-0.03	0.97	0.00	-0.04	-0.02	0.96	0.98	0.00	-7.05	<0.005	39.03
	sex	-0.12	0.89	0.12	-0.36	0.12	0.70	1.13	0.00	-0.97	0.33	1.58
	treatment	0.55	1.74	0.12	0.31	0.79	1.37	2.21	0.00	4.48	<0.005	17.05
	Intercept	4.17	64.87	0.25	3.68	4.67	39.56	106.39	0.00	16.53	<0.005	201.51
rho_	Intercept	0.11	1.11	0.05	-0.00	0.21	1.00	1.23	0.00	1.96	0.05	4.31

Concordance	0.63
AIC	1615.59
log-likelihood ratio test	61.48 on 3 df
-log2(p) of ll-ratio test	41.68

Interpretação dos Resultados

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
lambda_	age	-0.03	0.97	0.00	-0.04	-0.02	0.96	0.98	0.00	-7.05	<0.005	39.03
	sex	-0.12	0.89	0.12	-0.36	0.12	0.70	1.13	0.00	-0.97	0.33	1.58
	treatment	0.55	1.74	0.12	0.31	0.79	1.37	2.21	0.00	4.48	<0.005	17.05
	Intercept	4.17	64.87	0.25	3.68	4.67	39.56	106.39	0.00	16.53	<0.005	201.51
rho_	Intercept	0.11	1.11	0.05	-0.00	0.21	1.00	1.23	0.00	1.96	0.05	4.31

- **Covariável Idade**

Coeficiente (-0,03): cada aumento de 1 ano na idade reduz o tempo de sobrevivência esperado em 3%, mantendo todas as outras variáveis constantes

Fator de aceleração (0,97) < 1 o tempo de sobrevivência diminui com o aumento da idade

p-valor (<0,005): a idade é uma covariável significativa para explicar a morte por insuficiência cardíaca

Interpretação dos Resultados

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
lambda_	age	-0.03	0.97	0.00	-0.04	-0.02	0.96	0.98	0.00	-7.05	<0.005	39.03
	sex	-0.12	0.89	0.12	-0.36	0.12	0.70	1.13	0.00	-0.97	0.33	1.58
	treatment	0.55	1.74	0.12	0.31	0.79	1.37	2.21	0.00	4.48	<0.005	17.05
	Intercept	4.17	64.87	0.25	3.68	4.67	39.56	106.39	0.00	16.53	<0.005	201.51
rho_	Intercept	0.11	1.11	0.05	-0.00	0.21	1.00	1.23	0.00	1.96	0.05	4.31

- **Sexo**

Coeficiente (-0,12): homens têm uma redução de 12% no tempo de sobrevivência esperado em comparação com as mulheres.

Fator de Aceleração (0,89) < 1 o tempo de sobrevivência diminui para o sexo masculino

p-valor (0,33): o sexo é covariável não significativa para o estudo

Interpretação dos Resultados

		coef	exp(coef)	se(coef)	coef lower 95%	coef upper 95%	exp(coef) lower 95%	exp(coef) upper 95%	cmp to	z	p	-log2(p)
lambda_	age	-0.03	0.97	0.00	-0.04	-0.02	0.96	0.98	0.00	-7.05	<0.005	39.03
	sex	-0.12	0.89	0.12	-0.36	0.12	0.70	1.13	0.00	-0.97	0.33	1.58
	treatment	0.55	1.74	0.12	0.31	0.79	1.37	2.21	0.00	4.48	<0.005	17.05
	Intercept	4.17	64.87	0.25	3.68	4.67	39.56	106.39	0.00	16.53	<0.005	201.51
rho_	Intercept	0.11	1.11	0.05	-0.00	0.21	1.00	1.23	0.00	1.96	0.05	4.31

- Tratamento

Coeficiente (0,55): O tratamento experimental aumentou a sobrevivência em 55% em comparação com o tratamento padrão

Fator de Aceleração (1,74) > 1 pacientes em tratamento experimental aumentou a sobrevivência em 74% em comparação com o tratamento padrão.

p-valor (<0,005): o tratamento é significativo para o estudo

Análise de Resíduos

▼ Resíduos de Cox-Snell


```
[ ] # (b) Calculando os resíduos de Cox-Snell
# A função de sobrevivência acumulada para Weibull é calculada como  $S(t) = \exp(-\lambda * t^{\rho})$ 
# Onde lambda e rho são parâmetros estimados do modelo

# Calcular a função de risco cumulativo predita para cada indivíduo no tempo observado
data['cox_snell_residuals'] = [
    aft_model.predict_cumulative_hazard(data.iloc[[i]]).loc[data['time'].iloc[i]].values[0]
    for i in range(len(data))
]

# Ajustar um estimador Kaplan-Meier aos resíduos
from lifelines import KaplanMeierFitter
kmf = KaplanMeierFitter()
kmf.fit(data['cox_snell_residuals'], event_observed=data['event'])

# Plotar os resíduos de Cox-Snell
plt.figure(figsize=(10, 6))
plt.step(kmf.survival_function_.index, -np.log(kmf.survival_function_['KM_estimate']), where="post", label="Kaplan-Meier")
plt.plot([0, max(data['cox_snell_residuals'])], [0, max(data['cox_snell_residuals'])], linestyle='--', color='red', label="Linha de referência")
plt.title("Resíduos de Cox-Snell para o Modelo Weibull AFT")
plt.xlabel("Resíduo de Cox-Snell")
plt.ylabel("-log(S(t)) (estimado)")
plt.legend()
plt.grid()
plt.show()
```

Resíduo de Cox-Snell



Desvio acima da linha indica que o modelo subestima a taxa de risco para certos tempos.

Sendo necessário testar outros modelos ou incluir outras variáveis importantes


Análise de Resíduos

✓ Resíduos versus Previsões

```
[ ] # (c) Resíduos vs. Previsões
previsoes = aft_model.predict_expectation(data)

plt.figure(figsize=(10, 6))
plt.scatter(previsoes, data['residuos'], alpha=0.7, color='blue')
plt.axhline(0, color='red', linestyle='--', linewidth=1)
plt.title("Resíduos vs. Previsões (Modelo Weibull AFT)", fontsize=14)
plt.xlabel("Tempo Esperado de Sobrevida (Previsões)", fontsize=12)
plt.ylabel("Resíduos", fontsize=12)
plt.grid(True)
plt.show()
```

Resíduos vs. Previsões



Observa-se um **padrão** nos resíduos indicando que o modelo não conseguiu se adequar ao dados de forma satisfatória

Análise de Resíduos

✓ QQ-plot dos resíduos


```
# (d) QQ-Plot dos Resíduos
import scipy.stats as stats
import matplotlib.pyplot as plt

# Pegar o parâmetro rho_ do modelo
rho = 0.11
sigma = 1 / rho

# Padronizar resíduos
residuos_padronizados = data['residuos'] / sigma

# QQ-plot
stats.probplot(residuos_padronizados, dist="gumbel_r", plot=plt)
plt.title("QQ-Plot dos Resíduos Padronizados (Weibull AFT vs Gumbel)")
plt.xlabel("Quantis Teóricos (Gumbel)")
plt.ylabel("Quantis Observados (Resíduos)")
plt.grid(True)
plt.show()
```

QQ-Plot dos Resíduos



Observa-se uma **linha curvilínea** em torno da reta indicando que o **modelo não é adequado** ao ajuste dos dados

Análise de Resíduos

✓ Curva de Sobrevivência (Kaplan-Meier vs Modelo Weibull)

```
[ ] # 4. Curva de Sobrevivência (Kaplan-Meier vs Modelo Weibull)
    kmf = KaplanMeierFitter()
    plt.figure(figsize=(10, 6))


    # Estimativa Kaplan-Meier
    kmf.fit(data['time'], event_observed=data['event'], label='Kaplan-Meier')
    kmf.plot_survival_function(ci_show=True, ax=plt.gca(), color='blue')

    # Previsão do Modelo Weibull
    times = np.linspace(1, data['time'].max(), 100)
    survival_curve = aft_model.predict_survival_function(data.iloc[0:1], times=times)
    plt.plot(times, survival_curve.values.flatten(), label='Weibull AFT', color='red', linestyle='--')

    # Configurações do Gráfico
    plt.title("Curva de Sobrevivência: Kaplan-Meier vs Weibull AFT", fontsize=14)
    plt.xlabel("Tempo", fontsize=12)
    plt.ylabel("Probabilidade de Sobrevivência", fontsize=12)
    plt.legend(fontsize=12)
    plt.grid(True)
    plt.tight_layout()
    plt.show()
```

Curva de sobrevivência estimada

Modelo Weibull AFT vs. Kaplan Meier



- Distribuição Weibull não é adequada para modelar os dados como foi verificado na análise de resíduos.
- Existem vieses nos dados devido a muitos dados censurados

✓ Gráfico da Curva de Sobrevivência Estimada para Indivíduos selecionados

```
[ ] # 3. Curva de Sobrevivência Estimada para Indivíduos Selecionados

# Selecionando os dois indivíduos com base nas condições fornecidas:
indivíduo_1 = data[(data['sex'] == 1) & (data['treatment'] == 0)].iloc[0:1] # Masculino e Controle
indivíduo_2 = data[(data['sex'] == 1) & (data['treatment'] == 1)].iloc[0:1] # Masculino e Tratado

# Gerando os tempos para a curva de sobrevivência
times = np.linspace(1, data['time'].max(), 100)


# Prever as curvas de sobrevivência para os indivíduos
survival_curve_1 = aft_model.predict_survival_function(indivíduo_1, times=times)
survival_curve_2 = aft_model.predict_survival_function(indivíduo_2, times=times)

# Plotando as curvas de sobrevivência
plt.figure(figsize=(10, 6))
plt.plot(times, survival_curve_1.values.flatten(), label='Indivíduo 1 (Masculino, Controle)', color='blue')
plt.plot(times, survival_curve_2.values.flatten(), label='Indivíduo 2 (Masculino, Tratado)', color='green', linestyle='--')

# Configurações do gráfico
plt.title("Curvas de Sobrevivência Estimadas para Indivíduos Selecionados", fontsize=14)
plt.xlabel("Tempo", fontsize=12)
plt.ylabel("Probabilidade de Sobrevivência", fontsize=12)
plt.legend(fontsize=12)
plt.grid(True)
plt.tight_layout()

# Exibir o gráfico
plt.show()
```

Função de sobrevivência estimada pelo Modelo de Taxa Acelerada



Caso: Pacientes do sexo masculino:

paciente 1 - controle

paciente 2 – tratado

58% dos pacientes que receberam o tratamento experimental continuavam vivos após 20 meses, em contrapartida a 25% dos pacientes que não receberam.

Modelo de Taxa Acelerada

Resultados

Como a idade do paciente afeta o tempo de sobrevivência?

Resposta: A idade foi impactante nos resultados, acelerando o tempo de morte pela insuficiência cardíaca

Existe uma diferença de sobrevivência entre homens e mulheres?

Resposta: O sexo é uma variável não significativa para o risco de morte por insuficiência cardíaca, apesar de os homens com a doença apresentar uma redução de 12% no tempo de sobrevivência esperado em comparação com as mulheres.

Modelo de Taxa Acelerada

Resultados

O tratamento experimental melhora a sobrevivência em comparação com o tratamento padrão?

Resposta: Observa-se pela análise uma redução de 50% no tempo de morte em pacientes que receberam o tratamento experimental

Modelo de Taxa Acelerada

Conclusão Geral:

O modelo Weibull AFT não foi adequado ao dados e por isso não foi realizado a previsão de sobrevivência.

Nesses casos de inadequação do modelo se faz necessário testar outros modelos de taxa acelerada ao dados e compará-los com a análise de resíduo, métrica AIC e a estatística de verossimilhança.


Regressão Paramétrica

Resumo

- Se o foco está em comparar **taxas de risco** ao longo do tempo, use **modelos paramétricos clássicos**
- Se o foco está em entender quanto **o tempo até o evento é encurtado ou prolongado**, use **modelos paramétricos de taxa acelerada**

Resumo Modelos de Regressão

Resumo da Análise de Sobrevida



Quadro Comparativo dos Modelos de Regressão para Análise de Sobrevivência

Característica	Modelo de Cox (Risco Proporcional)	Modelos AFT (Taxa Acelerada de Falha)
Distribuição do Tempo	Não assume distribuição específica	Assume distribuição fixa (Weibull, Log-Normal, Log-Logística etc.)
Influência das Covariáveis	Afetam a taxa de risco relativa	Afetam diretamente o tempo de falha
Fórmula Geral	$h(t) = h_0(t)e^{X\beta}$	$\log(T) = X\beta + \sigma\epsilon$
Interpretação	Covariáveis alteram a taxa de risco relativa comparada ao grupo de referência	Covariáveis aceleram ou desaceleram o tempo até o evento
Interpretação do Parâmetro β	e^β é a razão de riscos (hazard ratio - HR) entre grupos	e^β representa o fator de aceleração/desaceleração do tempo até o evento

Quadro Comparativo dos Modelos de Regressão para Análise de Sobrevivência

Característica	Modelo de Cox (Risco Proporcional)	Modelos AFT (Taxa Acelerada de Falha)
Teste de Diagnóstico	Teste de proporcionalidade dos riscos (ex: Gráficos de Schoenfeld, Teste de Grambsch-Therneau)	Teste de aderência à distribuição e gráficos de resíduos (ex: Quantile-Quantile plot)
Limitações	- Supõe que a razão de riscos seja constante ao longo do tempo (hipótese de proporcionalidade). - Não permite prever tempos futuros, apenas comparar riscos entre grupos.	- Requer uma distribuição específica do tempo de falha. - Difícil interpretar quando há variáveis altamente correlacionadas.
Quando Usar?	Quando não se quer assumir uma distribuição específica e deseja comparar riscos entre grupos.	Quando se deseja modelar diretamente o tempo de falha e entender o impacto das variáveis sobre ele.