

Disciplina:

ANÁLISE DE SOBREVIVÊNCIA

Professora: Patrícia de Sousa Ilambwetsi

Bacharel em Estatística pela UFOP

Mestre em Estatística pela UFV

Doutora em Estatística pela UFV

Especialista em Ciências de Dados e Big Data pela PUC Minas



Conteúdo programático

Unidade 1 – Conceitos Básicos para Análise de Sobrevida

Unidade 2 – Métodos Não Paramétricos e Paramétricos

Unidade 3 – Modelos de Regressão para Análise de Sobrevida

Unidade 4 – Testes de Vida Acelerados

Distribuição dos pontos:

- Exercícios práticos: 4 exercícios de múltiplas escolhas totalizando 40 pontos (entrega semanal)
- Relatório Final: 60 pontos (entrega a ser definida pelo professor)

Roteiro

Unidade 4 – Modelos de Vida Acelerados

4.1 Conceitos Básicos

4.2 Relação Estresse-Resposta

- Componentes Determinístico
- Componente Probabilístico
- Ajuste e Verificação do Modelo

4.3 Aplicações

Testes de Vida Acelerados

Testes de Vida Acelerados

Os **testes de vida acelerados** (ou ALT, do inglês Accelerated Life Testing) são usados para avaliar a confiabilidade, durabilidade e vida útil de produtos ou componentes em um período de tempo reduzido.

Esses testes simulam **condições extremas** ou aceleradas para identificar possíveis **falhas** e **prever** o desempenho do produto em **uso normal** ao longo do tempo, utilizando dados coletados sob condições de estresse.

Testes de Vida Acelerados

- **Objetivos**

1. Determinar a **vida útil** de um produto ou componente
2. Identificar **mecanismos de falha** que podem ocorrer em condições normais de uso.
3. Avaliar a **qualidade** e a **confiabilidade** do produto antes de sua introdução no mercado
4. Reduzir o tempo necessário para validar o desempenho de um produto

Testes de Vida Acelerados

- **Princípio de Aceleração**

Os testes utilizam condições que aumentam a taxa de falha, como:

1. Temperaturas elevada ou Ciclos térmicos
2. Umidade extrema
3. Carga mecânica ou elétrica excessiva
4. Radiação UV, vibração intensa ou corrosão

Essas condições devem ser projetadas para simular o envelhecimento ou desgaste do produto.

Testes de Vida Acelerados

- **Formas de simular o envelhecimento ou desgaste do produto**
 1. Testes sob **condições fixas** de estresse
 2. Testes com **estresse progressivos** para avaliar o ponto de falha.
 3. Testes com **variações cíclicas** de estresse para simular condições reais de operação.

Testes de Vida Acelerados

Para analisar dados de **testes de vida acelerados** e **prever** o comportamento do produto em condições normais, utilizam-se **modelos matemáticos** em uma **relação de estresse resposta**.

A relação de estresse resposta é composta por:

- **Componente determinístico:** responsável por estudar a influência da variável de estresse no experimento.
- **Componente probabilístico:** responsável por explicar a variabilidade dos tempos de falha para vários níveis de estresse.

Testes de Vida Acelerados

Vantagens

- **Redução do tempo** para identificar problemas e validar o produto.
- **Previsão mais rápida** da confiabilidade e durabilidade.
- **Menores custos** de desenvolvimento devido à identificação precoce de falhas.
- **Melhoria contínua** do design e da qualidade.
- Cálculo do **prazo de garantia** com menos prejuízo

Testes de Vida Acelerados

Limitações

- **Exposição excessiva** a condições extremas pode causar falhas artificiais não representativas.
- Se os **pressupostos dos modelos** não forem válidos, as previsões podem ser imprecisas.
- **Custos Iniciais por** exigir especialistas para projetar, executar e interpretar os testes.
- **Complexidade** na análise de resíduos que pode revelar inadequações nos modelos exigindo ajustes.

Testes de Vida Acelerados

Aplicações

- **Indústria Eletrônica:** prever falhas em semicondutores, resistores, capacitores, circuitos integrados, entre outros.
- **Indústria Automotiva:** avaliar a durabilidade de peças críticas, como airbags, freios e sistemas de controle eletrônico.
- **Indústria de Baterias e Energia:** sistemas de energia solar e eólica para avaliar a resistência de painéis fotovoltaicos e turbinas.

Testes de Vida Acelerados

Aplicações

- **Industria farmacêutica:** estimar o prazo de validade e a eficiência dos medicamentos em diferentes temperaturas.

Ensaio para avaliar a degradação de vacinas, proteínas ou compostos biológicos em condições adversas.

- **Setor Médico:** avaliar stents, marca-passos, próteses e equipamentos de diagnóstico para prever o desempenho a longo prazo.
- Entre outras...

Relação Estresse-Resposta

Relação Estresse-Resposta

A **relação estresse-resposta** nos modelos de testes de vida acelerados é usada para descrever como a vida útil de um produto ou sistema muda sob diferentes níveis de estresse, sendo esses

- temperatura
- umidade
- carga
- vibração

Os modelos se baseiam na **relação** entre a **taxa de falha** e o **fatores de estresse** assumindo que esses aceleram os mecanismos de falha.

Relação Estresse-Resposta

Cada modelo conecta a **relação estresse-resposta** com **distribuições de probabilidade**, que descrevem o comportamento do tempo de falha sob estresse.

A principal **diferença** entre os modelos está nas **variáveis de aceleração** (ou estresse) e, como eles, modelam a relação entre essas variáveis e a taxa de falha.

Relação Estresse-Resposta

O modelo Estresse-Resposta matematicamente é dado por:

$$Y = \ln(T) = x'\beta + \sigma\varepsilon$$

sendo

$Y = \ln(T)$ o logaritmo do tempo de falha

$x'\beta$ vetor de parâmetros determinado pelo **componente determinístico** e dependente da variável de estresse x

$\sigma > 0$ variabilidade determinada pelo **componente probabilístico**

ε é o erro aleatório

Relação Estresse-Resposta

- **Componente Determinístico**
 1. Modelo Arrhenius
 2. Modelo de Eyring
 3. Modelo Peck
 4. Modelo de Vibração
 5. Modelo Coffin-Manson

Modelo de Arrhenius

Relação Estresse-Resposta

Modelo de Arrhenius

O modelo de Arrhenius é amplamente utilizado para descrever como a taxa de uma reação química (ou o comportamento de materiais) varia com a temperatura.

Na confiabilidade, o modelo Arrhenius ajuda a prever a vida útil e o desgaste de sistemas com base nas condições de temperatura.

Esse modelo assume que o aumento da temperatura acelera a taxa de falha de componentes e materiais.

Relação Estresse-Resposta

Modelo de Arrhenius

Objetivos:

O principal objetivo do modelo de Arrhenius é **prever** como a **taxa de falha** ou a degradação de materiais varia com a temperatura.

É frequentemente usado para:

- Estimar a vida útil de um componente ou sistema sob diferentes condições térmicas.

Relação Estresse-Resposta

Modelo de Arrhenius

Objetivos:

- Avaliar o impacto da temperatura na confiabilidade dos produtos.
- Acelerar os testes de confiabilidade através de temperaturas elevadas e extrapolar esses dados para condições de temperatura normais.

Relação Estresse-Resposta

Modelo de Arrhenius

Pressupostos:

- O modelo assume que a **taxa de falha** depende exponencialmente da temperatura
- Temperaturas elevadas **aceleram** a probabilidade de falhas
- A **relação** entre a taxa de falha e a temperatura é dominada por um **único fator de ativação**
- **Homogeneidade** das condições de operação

Relação Estresse-Resposta

Modelo de Arrhenius

Pressupostos:

- O modelo assume que a **taxa de falha** depende exponencialmente da temperatura
- Temperaturas elevadas **aceleram** a probabilidade de falhas
- A **relação** entre a taxa de falha e a temperatura é dominada por um **único fator de ativação**
- Homogeneidade das condições de operação

Relação Estresse-Resposta

Modelo de Arrhenius

A forma básica da equação da taxa de falha de Arrhenius é dada por:

$$\lambda(\tau) = \lambda_0 \cdot e^{-\frac{E}{k\tau}}$$

sendo: $\lambda(\tau)$ taxa de falha estimada na temperatura τ

λ_0 é a taxa de falha preditiva à temperatura de referência (geralmente a 0°C ou a temperatura ambiente);

E é a energia de ativação medida em elétron-volts;

k é a constante de Boltzmann: $8,6171 \times 10^{-5} K$;

$\tau^{-1} = (^\circ\text{C} + 273,16)$ é a variável de estresse (temperatura).

Relação Estresse-Resposta

Modelo de Arrhenius

Modelo de Arrhenius **linearizado** para modelar a relação da taxa de falha com a temperatura em teste de vida acelerado é dado por:

$$\ln(\lambda(\tau)) = \ln(\lambda_0) - \frac{E}{k\tau} = \beta_0 + \beta_1 X$$

$$\beta_0 = \ln(\lambda_0)$$

$$\beta_1 = -\frac{E}{k}$$

$$X = \frac{1}{\tau}$$

Relação Estresse-Resposta

Modelo de Arrhenius

Característica

- $\ln(\lambda(\tau))$ define o **parâmetro de escala ou de localização** de uma distribuição probabilidade
- A **relação** entre **temperatura** e **taxa de falha** segue uma curva exponencial
- O modelo considera condições **homogêneas de estresse**
- É o modelo mais utilizado em testes de Confiabilidade
- **Fator de Aceleração:** temperatura

Relação Estresse-Resposta

Modelo de Arrhenius

Hipóteses para o parâmetro estimados:

$H_0: \beta_1$ não é significativo para o efeito da temperatura

$H_1: \beta_1$ é significativo para o efeito da temperatura

p-valor < nível de significância de 5% rejeita-se H_0

Relação Estresse-Resposta

Interpretação do Parâmetro

Coeficiente do Termo Arrhenius (β_1)

$\beta_1 < 0$: Indica que o tempo de falha aumenta à medida que a temperatura diminui (sobrevivência melhora).

$\beta_1 > 0$: Indica que o tempo de falha aumenta à medida que a temperatura aumenta (sobrevivência piora).

Relação Estresse-Resposta

Tempo médio estimado

Condições normais de Uso

$$Vida\ útil = \left(\frac{\tau_{teste}}{\tau_{normal}} \right)^{\frac{E}{k}} . Tempo\ de\ Teste$$

τ_{teste} é a temperatura utilizada nos testes de estresse.

τ_{normal} é a temperatura de operação normal (geralmente a temperatura ambiente).

Tempo de Teste é o tempo observado durante o teste acelerado

Modelo de Eyring

Relação Estresse-Resposta

Modelo de Eyring

O modelo de Eyring é uma generalização do modelo de Arrhenius, utilizado principalmente para descrever processos de reação térmica e falhas de componentes, especialmente em sistemas complexos que envolvem mudanças de estado e barreiras de energia.

Ele é frequentemente aplicado em materiais, dispositivos eletrônicos e processos químicos, oferecendo uma visão mais detalhada sobre como a **temperatura e múltiplos fatores de estresse** afetam a taxa de falha.

Relação Estresse-Resposta

Modelo de Eyring

Objetivos:

O principal objetivo do modelo de Eyring é modelar a taxa de falha ou a taxa de degradação de um material ou sistema em função da temperatura e de outros fatores estressantes, como a umidade, o campo **elétrico**, a pressão, entre outros

É frequentemente usado para:

- **Fenômenos complexos:** como mudanças de fase e processos irreversíveis.

Relação Estresse-Resposta

Modelo de Eyring

Objetivos:

- Taxas de falha sob múltiplos estresses: Como combinações de temperatura, umidade, e outros fatores ambientais.

Relação Estresse-Resposta

Modelo de Eyring

Pressupostos:

- Ativação térmica: assume que a taxa de falha depende exponencialmente da temperatura
- Considera a interação entre múltiplos fatores como temperatura, pressão e umidade.
- Assume que o processo de falha (ou reação) envolve a um estado de transição que passa de estado inicial não-falhado para um estado de falha.

Relação Estresse-Resposta

Modelo de Eyring

A forma básica da equação da taxa de falha de Eyring é dada por:

$$\lambda(\tau, V) = \lambda_0 \cdot e^{-\frac{E}{k\tau}} \cdot V^m$$

sendo: $\lambda(\tau)$ taxa de falha estimada na temperatura τ

λ_0 é a taxa de falha preditiva à temperatura de referência (geralmente a 0°C ou a temperatura ambiente);

E é a energia de ativação medida em elétron-volts;

k é a constante de Boltzmann: $8,6171 \times 10^{-5} K$;

$\tau^{-1} = (^\circ C + 273,16)$ é a variável de estresse (temperatura).

V variável de aceleração adicional; m o parâmetro de sensibilidade ao fator

Relação Estresse-Resposta

Modelo de Eyring

O modelo de Eyring linearizado para modelar a relação da **taxa de falha** com **múltiplos fatores de estresse** em testes de vida acelerado é dado por:

$$\ln(\lambda(\tau, V)) = \ln(\lambda_0) - \frac{E}{k\tau} + m\ln(V) = \beta_0 + \beta_1 X_1 + \beta_2 X_2$$

$$Y = \ln(\lambda(\tau, V)) \quad \beta_0 = \ln(\lambda_0)$$

$$\beta_1 = -\frac{E}{k} \quad \beta_2 = m$$

$$X_1 = \frac{1}{\tau} \quad X_2 = \ln(V)$$

Relação Estresse-Resposta

Modelo de Eyring

Característica

- $\ln(\lambda(\tau, V))$ define o **parâmetro de escala ou de localização** de uma distribuição probabilidade
- **Generaliza** o modelo de **Arrhenius** ao incluir termos adicionais para outras variáveis de aceleração
- É usado quando múltiplos fatores influenciam **simultaneamente** a taxa de falha
- **Fator de Aceleração:** Temperatura, tensão, pressão, umidade (dependendo do caso).

Relação Estresse-Resposta

Modelo de Eyring

Hipóteses para os parâmetros estimados:

$H_0: \beta_1$ não é significativo para o efeito da temperatura

$H_0: \beta_2$ é significativo para o efeito de outra variável de estresse

p-valor < nível de significância de 5% rejeita-se H_0

Relação Estresse-Resposta

Interpretação do Parâmetro

Coeficiente do Termo Eyring (β_1)

$\beta_1 < 0$: Indica que o tempo de falha aumenta à medida que a temperatura diminui.

Coeficiente do Termo Eyring (β_2)

$\beta_2 < 0$: Indica que o tempo de falha diminui à medida que o estresse V aumenta

Relação Estresse-Resposta

Tempo médio estimado

Condições normais de Uso

$$Vida\ útil = \left(\frac{\tau_{teste}}{\tau_{normal}} \right)^{\frac{E}{k}} \cdot \exp \left(-V \left(\frac{1}{\tau_{normal}} - \frac{1}{\tau_{teste}} \right) \right)^m \cdot Tempo\ de\ Teste$$

τ_{teste} é a temperatura utilizada nos testes de estresse.

τ_{normal} é a temperatura de operação normal (geralmente a temperatura ambiente).

Tempo de Teste é o tempo observado durante o teste acelerado

Modelo de Peck

Relação Estresse-Resposta

Modelo de Peck

O modelo de Peck é uma extensão do modelo de Arrhenius, utilizado principalmente para modelar **falhas induzidas por umidade e temperatura**, como em **corrosão, delaminação e migração eletroquímica** em componentes eletrônicos e materiais.

Ele é amplamente usado em engenharia de confiabilidade e testes de estresse acelerado.

Relação Estresse-Resposta

Modelo de Peck

Objetivos:

Estimar a **vida útil** de dispositivos e materiais sujeitos à **temperatura e umidade relativa (RH)**.

Realizar extrapolação de dados de **testes acelerados** (combinando temperatura alta e umidade elevada) para prever o comportamento em **condições normais de operação**.

Avaliar falhas típicas de ambientes úmidos e quentes, como corrosão, oxidação de contatos, e vazamentos dielétricos.

Relação Estresse-Resposta

Modelo de Peck

Pressupostos:

- A taxa de falha ou degradação aumenta exponencialmente com a temperatura (como no modelo de Arrhenius)
- A umidade relativa influencia a taxa de falha como uma potência (RH^n)..
- A temperatura e umidade atuam **independentemente**, mas de forma **combinada** para afetar a taxa de falha.

Relação Estresse-Resposta

Modelo de Peck

Pressupostos:

- A taxa de falha ou degradação aumenta exponencialmente com a temperatura (como no modelo de Arrhenius)
- A umidade relativa influencia a taxa de falha como uma potência (RH^n)..
- A temperatura e umidade atuam **independentemente**, mas de forma **combinada** para afetar a taxa de falha.

Relação Estresse-Resposta

Modelo de Peck

A forma básica da equação da taxa de falha de Peck é dada por:

$$\lambda(\tau, RH) = \lambda_0 \cdot e^{-\frac{E}{k\tau}} \cdot RH^n$$

sendo: $\lambda(\tau, RH)$ taxa de falha estimada na temperatura τ e umidade RH ;

λ_0 é taxa de falha em uma temperatura de referência;

E é a energia de ativação medida em elétron-volts;

k é a constante de Boltzmann: $8,6171 \times 10^{-5} K$;

$\tau^{-1} = (^\circ C + 273,16)$ é a variável de estresse (temperatura);

RH variável de aceleração adicional; n o parâmetro de sensibilidade ao fator

Relação Estresse-Resposta

Modelo de Peck

O modelo de Peck linearizado para modelar a relação da **taxa de falha** com **temperatura e umidade relativa (RH)** em testes de vida acelerado é dado por:

$$\ln(\lambda(\tau, RH)) = \ln(\lambda_0) - \frac{E}{k\tau} - n\ln(RH) = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

$$Y = \ln(\lambda(\tau, RH)) \quad \beta_0 = \ln(\lambda_0)$$

$$\beta_1 = -\frac{E}{k} \quad \beta_2 = n$$

$$X_1 = \frac{1}{\tau} \quad X_2 = \ln(RH)$$

Relação Estresse-Resposta

Modelo de Peck

Característica

- $\ln(\lambda(\tau, RH))$ define o **parâmetro de escala ou de localização** de uma distribuição probabilidade
- Considera explicitamente os efeitos da **umidade** sobre o tempo de vida
- Usado para **prever falhas** por degradação ambiental, como corrosão ou oxidação.
- **Fator de Aceleração:** Temperatura e umidade relativa

Relação Estresse-Resposta

Modelo de Peck

Hipóteses para os parâmetros estimados:

$H_0: \beta_1$ não é significativo para o efeito da temperatura

$H_0: \beta_2$ é significativo para o efeito da umidade

p-valor < nível de significância de 5% rejeita-se H_0

Relação Estresse-Resposta

Interpretação do Parâmetro

Coeficiente do Termo Peck (β_1)

$\beta_1 < 0$: Indica que o tempo de falha aumenta à medida que a temperatura diminui.

Coeficiente do Termo Peck (β_2)

$\beta_2 < 0$: indica que o tempo de falha diminui conforme a umidade aumenta.

Relação Estresse-Resposta

Tempo médio estimado

Condições normais de Uso

$$TTF_{normal} = TTF_{acel} \left(\frac{RH_{acel}}{RH_{normal}} \right)^n \cdot \exp \left(\frac{E}{k} \left(\frac{1}{\tau_{normal}} - \frac{1}{\tau_{acel}} \right) \right)^m$$

TTF_{normal} tempo até a falha

τ_{acel} é a temperatura utilizada nos testes acelerado.

τ_{normal} é a temperatura de operação normal (geralmente a temperatura ambiente).

RH_{acel} umidade relativa em condições extremas

RH_{normal} umidade relativa em condições normais

Modelo de Vibração

Relação Estresse-Resposta

Modelo de Vibração

O modelo de estresse-resposta por vibração é utilizado para prever a **vida útil de produtos** ou **componentes** sujeitos a vibrações mecânicas, especialmente em ambientes automotivos, aeroespaciais, ferroviários e industriais.

Diferente dos modelos clássicos como Arrhenius (temperatura) ou Peck (umidade e temperatura), o modelo por vibração foca em como aceleração, frequência, carga cíclica ou amplitude de deslocamento afetam a taxa de falha.

Relação Estresse-Resposta

Modelo de Vibração

Objetivos:

Prever a **vida útil** (Time To Failure - TTF) de componentes expostos a **vibrações mecânicas cíclicas**.

Ajudar a extrapolar dados de testes acelerados (em laboratório) para condições reais de uso.

Estimar a **taxa de falha associada ao estresse vibracional**.

Relação Estresse-Resposta

Modelo de Vibração

Pressupostos:

- Aplicado em vibrações que causam **danos acumulativos** que levam à **fadiga mecânica** (rachaduras, falhas estruturais).
- A taxa de falha **aumenta** com a amplitude da vibração, frequência ou aceleração.

Relação Estresse-Resposta

Modelo de Vibração

Pressupostos:

- A relação entre o estresse vibracional e a vida útil pode ser representada por **leis de potência empíricas**.
- O mecanismo de falha é **mecânico e repetitivo**, e não muda com o **nível de estresse**.

Relação Estresse-Resposta

Modelo de Vibração

A forma básica da equação da taxa de falha de Vibração é dada por:

$$\lambda(f) = \lambda_0 \cdot f^n$$

sendo: $\lambda(f)$ taxa de falha estimada para uma frequência de vibração f ;

λ_0 é taxa de falha em condição de referência

f é frequência de vibração;

n o parâmetro de sensibilidade ao fator de vibração

Relação Estresse-Resposta

Modelo de Vibração

O modelo de Vibração linearizado para modelar a relação da **taxa de falha** com a **aceleração** em testes de vida acelerado é dado por:

$$\ln(\lambda(f)) = \ln(\lambda_0) - n \ln(f) = \beta_0 + \beta_1 x$$

$$Y = \ln(\lambda(f))$$

$$\beta_0 = \ln(\lambda_0)$$

$$\beta_1 = -n$$

$$X_1 = \ln(f)$$

Relação Estresse-Resposta

Modelo de Vibração

Característica

- $\ln(\lambda(f))$ define o **parâmetro de escala ou de localização** de uma distribuição probabilidade
- Relaciona a **vida útil inversamente** à frequência ou intensidade da vibração
- Usado em dispositivos sujeitos a vibrações repetitivas, como automóveis, aviões e máquinas industriais.
- **Fator de Aceleração:** aceleração ou frequência ou amplitude

Relação Estresse-Resposta

Modelo de Vibração

Hipóteses para o parâmetro estimado:

$H_0: \beta_1$ não é significativo para o efeito da vibração

p-valor < nível de significância de 5% rejeita-se H_0

Relação Estresse-Resposta

Interpretação do Parâmetro

Coeficiente do Termo Vibração (β_1)

$\beta_1 < 0$: Vibrações mais intensas (maior aceleração) causam falhas mais rápidas.

Relação Estresse-Resposta

Tempo médio estimado

Condições normais de Uso

$$TTF_{normal} = TTF_{accel} \left(\frac{f_{accel}}{f_{normal}} \right)^n$$

TTF_{normal} tempo até a falha

TTF_{accel} é o tempo até a falha em condições acelerado.

f_{normal} é a vibração de operação normal.

f_{accel} é a vibração em condições extremas

Modelo de Potência Inversa

Relação Estresse-Resposta

Modelo de Potência Inversa

O modelo de potência inversa é muito utilizado em engenharia de confiabilidade para estimar a vida útil de componentes sujeitos a estresses mecânicos, elétricos ou ambientais.

É especialmente eficaz para situações em que o estresse é constante e cumulativo ao longo do tempo, como tensão elétrica, pressão mecânica, corrente, carga, entre outros.

Relação Estresse-Resposta

Modelo de Potência Inversa

Objetivos:

Estimar a vida útil (TTF) ou a taxa de falha de sistemas sujeitos a **estresses físicos constantes** (como tensão, corrente, carga, pressão etc.).

Extrapolar resultados de testes acelerados para condições normais de uso

Avaliar o impacto de **estresses não térmicos** (diferente de modelos como Arrhenius ou Peck).

Relação Estresse-Resposta

Modelo de Potência Inversa

Pressupostos:

- A **vida útil** está relacionada ao estresse aplicado por meio de uma **relação de potência inversa**.
- O **mecanismo de falha permanece constante** ao longo dos diferentes níveis de estresse.
- O estresse atua de forma **cumulativa**: quanto maior o estresse, menor a vida útil.
- Não há efeitos térmicos explícitos

Relação Estresse-Resposta

Modelo de Potência Inversa

A forma básica da equação da taxa de falha de Potência Inversa é dada por:

$$\lambda(x) = \lambda_0 \cdot x^n$$

sendo: $\lambda(x)$ taxa de falha estimada para uma carga ou tensão x ;

λ_0 é taxa de falha em condição de referência x carga, tensão ou outro estresse mecânico/elétrico;

n o parâmetro de sensibilidade ao fator x

Relação Estresse-Resposta

Modelo de Potência Inversa

O modelo de Potência Inversa linearizado para modelar a relação da taxa de falha com a tensão elétrica ou carga ou pressão em testes de vida acelerado é dado por:

$$\ln(\lambda(x)) = \ln(\lambda_0) - n \ln(x) = \beta_0 + \beta_1 x$$

$$Y = \ln(\lambda(x))$$

$$\beta_0 = \ln(\lambda_0)$$

$$\beta_1 = n$$

$$X_1 = \ln(x)$$

Relação Estresse-Resposta

Modelo de Potência Inversa

Característica

- $\ln(\lambda(x))$ define o **parâmetro de escala ou de localização** de uma distribuição probabilidade.
- Representa falhas relacionadas a cargas aplicadas, como fadiga ou degradação elétrica.
- Usados frequentemente em dispositivos elétricos e mecânicos.
- **Fator de Aceleração:** Carga ou Tensão

Relação Estresse-Resposta

Modelo de Potência Inversa

Hipóteses para o parâmetro estimado:

$H_0: \beta_1$ não é significativo para o efeito da vibração

p-valor < nível de significância de 5% rejeita-se H_0

Relação Estresse-Resposta

Interpretação do Parâmetro

Coeficiente do Termo Potência Inversa (β_1)

β_1 é geralmente negativo

- Se $|\beta_1|$ é grande, o tempo de falha é altamente sensível ao estresse: pequenas perturbações causam grandes variações no tempo de falha.
- Se $|\beta_1|$ é pequeno o tempo de falha é menos sensível ao estresse: o impacto no tempo de falha é mais gradual.

Relação Estresse-Resposta

Tempo médio estimado

Condições normais de Uso

$$TTF_{normal} = TTF_{accel} \left(\frac{x_{accel}}{x_{normal}} \right)^n$$

TTF_{normal} tempo até a falha.

TTF_{accel} é o tempo até a falha em condições acelerado.

x_{normal} é a tensão de operação normal.

x_{accel} é a tensão em condições extremas.

Modelo de Coffin Manson

Relação Estresse-Resposta

Modelo de Coffin-Manson

O modelo Coffin-Manson é amplamente utilizado para estimar vida útil sob fadiga térmica e mecânica de baixo ciclo (Low-Cycle Fatigue — LCF).

É fundamental em confiabilidade de componentes eletrônicos, soldas, ligas metálicas e materiais sujeitos a ciclos térmicos ou deformações plásticas cíclicas.

Relação Estresse-Resposta

Modelo de Coffin-Manson

Objetivos:

Prever o **número de ciclos até falha (N_f)** devido a **fadiga térmica ou mecânica de baixo ciclo**.

Estimar a **vida útil de materiais** e componentes expostos a ciclos de **expansão/contração** por variações térmicas ou deformações.

Extrapolar resultados de **testes acelerados de fadiga** para condições normais de operação.

Relação Estresse-Resposta

Modelo de Coffin-Manson

Pressupostos:

- A falha ocorre devido à **acumulação de dano plástico cíclico**.
- A falha ocorre após um **número finito de ciclos** de deformação.
- O dano é **cumulativo**, e a **amplitude de deformação plástica** determina a vida útil.

Relação Estresse-Resposta

Modelo de Coffin-Manson

Pressupostos:

- O comportamento segue uma **lei de potência inversa** entre deformação plástica e número de ciclos até a falha.

Relação Estresse-Resposta

Modelo de Coffin-Manson

A forma básica da equação da taxa de falha de Coffin-Manson é dada por:

$$\varepsilon_p = \varepsilon'_f \cdot (2N_f)^{-c}$$

sendo: ε_p amplitude de deformação plástica por ciclo

N_f número de ciclos até a falha

ε'_f constante empírica relacionada à vida útil em deformação baixa

c expoente de Coffin-Manson (típico entre 0.5 e 0.7).

Relação Estresse-Resposta

Modelo de Coffin-Manson

O **modelo de Coffin-Manson** linearizado para modelar a relação da **taxa de falha com deformação de ciclos térmicos ou ciclos de carga mecânica** em testes de vida acelerado é dado por:

$$\ln(\varepsilon_p) = \ln(\varepsilon'_f) - c \ln(2N_f) = \beta_0 + \beta_1 x$$

$$Y = \ln(\varepsilon_p)$$

$$\beta_0 = \ln(\varepsilon'_f)$$

$$\beta_1 = c$$

$$X_1 = \ln(2N_f)$$

Relação Estresse-Resposta

Modelo de Coffin-Manson

Característica

- $\ln(\varepsilon_p)$ define o **parâmetro de escala ou de localização** de uma distribuição probabilidade.
- Usado para prever a vida útil de materiais submetidos a **cargas cíclicas** ou ciclos térmicos.
- **Fator de Aceleração:** Deformação cíclica.

Relação Estresse-Resposta

Modelo de Potência Inversa

Hipóteses para o parâmetro estimado:

$H_0: \beta_1$ não é significativo para o efeito da deformação
p-valor < nível de significância de 5% rejeita-se H_0

Relação Estresse-Resposta

Interpretação do Parâmetro

Coeficiente do Termo Coffin-Manson (β_1)

β_1 é geralmente negativo e indica que um aumento na amplitude de deformação (ε'_f) reduz o número de ciclos até a falha (N_f).

- Se $|\beta_1|$ é grande, indica que o número de ciclos até a falha é muito sensível a mudanças na amplitude de deformação
- Se $|\beta_1|$ é pequeno indica que o número de ciclos até a falha é menos sensível a mudanças na amplitude de deformação

Relação Estresse-Resposta

Números de ciclos em vida para condições normais

Condições normais de Uso

$$N_f^{normal} = \left(\frac{\varepsilon_p^{accel}}{\varepsilon_p^{normal}} \right)^{1/c} \cdot N_f^{accel}$$

ε_p^{accel} deformação plástica por ciclo em condições acelerado.

ε_p^{normal} deformação plástica por ciclo em condições normais

N_f^{accel} número de ciclos até a falha em condições acelerado

N_f^{normal} vida em ciclos para condições normais

Relação Estresse-Resposta

Tempo médio estimado

Condições normais de Uso

$$Vida\ Média_{tempo} = \frac{N_f^{normal}}{f}$$

N_f^{normal} é número de ciclos em vida para condições normais

f é frequência de ciclos.

Relação Estresse-Resposta

A escolha do modelo do componente determinístico dependerá do mecanismo de falha dominante e do tipo de estresse aplicado no estudo: térmico, elétrico, mecânico, ambiental etc.

Ainda temos:

- **Modelo de Black:** para eletromigração em interconexões metálicas de circuitos integrados;
- **Modelo de Norris-Landzberg:** para fadiga térmica de ciclos de temperatura em soldas e componentes eletrônicos;

Relação Estresse-Resposta

- **Modelo de Basquin:** para fadiga por deformação elástica de alto ciclo (High-Cycle Fatigue - HCF),
- **Modelo de Miner (Dano Acumulado):** quando diferentes estresses são aplicados ao longo do tempo — útil para carga variável;
- **Modelo Combinado Eyring-Potência Inversa:** combina efeitos térmicos (via Eyring) com efeitos mecânicos ou elétricos (via potência inversa).

Relação Estresse-Resposta

- **Componente Probabilístico**
 1. Modelo Exponencial
 2. Modelo Weibull
 3. Modelo Log-Normal
 4. Modelo Log-Logístico
 5. entre outros...

Relação Estresse-Resposta

Componente Probabilístico

A **parte probabilística** do modelo estresse-resposta é composta pelos modelos **exponencial, Weibull, Log-Normal, Log-Logístico, entre outros**.

Esses modelos tem a função de **explicar a variabilidade no tempo** para os vários níveis de estresse e **relacionar a função de confiabilidade ou sobrevivência** com a parte **determinística** do modelo estresse-resposta por meio dos **parâmetros de escala e de localização**.

Lembrete: Função de Sobrevivência $S(t)$ é a probabilidade de que um produto funcione além de um tempo t

Modelo Exponencial Estresse-Resposta

Relação Estresse-Resposta

Modelo Exponencial

- **Função de Sobrevivência**

$$S(t; x) = e^{-\left(\frac{t}{\exp(\beta_0 + \beta_1 x)}\right)}$$

- **Função de sobrevivência do Modelo Arrhenius-Exponencial**

$$S(t; x) = e^{-\left(\frac{t}{\exp(\ln(\lambda_0) - \frac{E}{k\tau})}\right)}$$

Relação Estresse-Resposta

Modelo Exponencial

- Função de Risco $h(t)$

$$\hat{h}(t) = \frac{f(t)}{S(t)} = \lambda$$

- Para o modelo Arrhenius-Exponencial

$$\hat{h}(t) = \exp \left(\ln(\lambda_0) - \frac{E}{k\tau} \right)$$

Relação Estresse-Resposta

Modelo Exponencial

- Tempo médio de sobrevivência esperado

$$E(T) = \frac{1}{\lambda}$$

- Para o modelo Arrhenius-Exponencial

$$E(T) = \frac{1}{\exp \left(\ln(\lambda_0) - \frac{E}{k\tau} \right)}$$

Modelo Weibull Estresse-Resposta

Relação Estresse-Resposta

Modelo Weibull

- **Função de Sobrevivência**

$$S(t; x) = e^{-\left(\frac{t}{\exp(\beta_0 + \beta_1 x)}\right)^{\frac{1}{\rho}}}$$

- **Função de sobrevivência do Modelo Arrhenius-Weibull**

$$S(t; x) = e^{-\left(\frac{t}{\exp(\ln(\lambda_0) - \frac{E}{k\tau})}\right)^{\frac{1}{\rho}}}$$

Relação Estresse-Resposta

Modelo Weibull

- Função de Risco $h(t)$

$$\hat{h}(t) = \frac{f(t)}{S(t)} = \frac{\rho}{\lambda} \left(\frac{t}{\lambda} \right)^{\rho-1}$$

- Para o modelo Arrhenius-Weibull

$$\hat{h}(t) = \frac{\rho}{\exp\left(\ln(\lambda_0) - \frac{E}{k\tau}\right)} \left(\frac{t}{\exp\left(\ln(\lambda_0) - \frac{E}{k\tau}\right)} \right)^{\rho-1}$$

Relação Estresse-Resposta

Modelo Weibull

- **Tempo de Sobrevivência Esperado**

$$E(T) = \frac{\Gamma(1 + 1/\rho)}{\lambda}$$

em que Γ é a função gama

- **Para o modelo Arrhenius-Weibull**

$$E(T) = \frac{\Gamma(1 + 1/\rho)}{\exp\left(\ln(\lambda_0) - \frac{E}{k\tau}\right)}$$

Modelo Log-Normal Estresse-Resposta

Relação Estresse-Resposta

Modelo Log-Normal

- **Função de Sobrevivência**

$$S(t; x) = 1 - \Phi \left(\frac{\ln(t) - (\beta_0 + \beta_1 x)}{\sigma} \right)$$

A média do logaritmo do tempo de vida depender do fator de aceleração

- **Função de sobrevivência do Modelo Arrhenius-Log-Normal**

$$S(t; x) = 1 - \Phi \left(\frac{\ln(t) - (\ln(\lambda_0) - \frac{E}{k\tau})}{\sigma} \right)$$

Relação Estresse-Resposta

Modelo Log-Normal

- Função de Risco $h(t)$

$$\hat{h}(t) = \frac{f(t)}{S(t)} = \frac{\frac{1}{t\sigma\sqrt{2\pi}} e^{-\frac{(\ln(t)-\mu)^2}{2\sigma^2}}}{1 - \Phi\left(\frac{\ln(t) - \mu}{\sigma}\right)}$$

- Para o modelo Arrhenius-Log-Normal

$$\hat{h}(t) = \frac{\frac{1}{t\sigma\sqrt{2\pi}} e^{-\frac{(\ln(t) - (\ln(\lambda_0) - \frac{E}{k\tau}))^2}{2\sigma^2}}}{1 - \Phi\left(\frac{\ln(t) - (\ln(\lambda_0) - \frac{E}{k\tau})}{\sigma}\right)}$$

Relação Estresse-Resposta

Modelo Log-Normal

- Tempo Médio e Mediano de Sobrevivência

$$E(T) = e^{\mu + \frac{\sigma^2}{2}}$$

$$E(T_{med}) = e^{\mu}$$

- Para o modelo Arrhenius-Log-Normal

$$E(T) = e^{\left(\ln(\lambda_0) - \frac{E}{k\tau}\right) + \frac{\sigma^2}{2}}$$

$$E(T_{med}) = e^{\ln(\lambda_0) - \frac{E}{k\tau}}$$

Modelo Log-Logístico Estresse-Resposta

Relação Estresse-Resposta

Modelo Log-Logístico

- **Função de Sobrevivência**

$$S(t; x) = \frac{1}{1 + \left(\frac{t}{\beta_0 + \beta_1 x} \right)^\gamma}$$

- **Função de sobrevivência do Modelo Arrhenius-Log-Logístico**

$$S(t; x) = \frac{1}{1 + \left(\frac{t}{\exp(\ln(\lambda_0) - \frac{E}{k\tau})} \right)^\gamma}$$

Relação Estresse-Resposta

Modelo Log-Logístico

- Função de Risco $h(t)$

$$\hat{h}(t) = \frac{f(t)}{S(t)} = \frac{(\gamma/\lambda)(t/\lambda)^{\gamma-1}}{1 + (t/\lambda)^\gamma}$$

- Para o modelo Arrhenius-Log-Logístico

$$\hat{h}(t) = \frac{\left(\frac{\gamma}{\exp(\ln(\lambda_0) - \frac{E}{k\tau})}\right) \left(\frac{t}{\exp(\ln(\lambda_0) - \frac{E}{k\tau})}\right)^{\gamma-1}}{1 + \left(\frac{t}{\exp(\ln(\lambda_0) - \frac{E}{k\tau})}\right)^\gamma}$$

Relação Estresse-Resposta

Modelo Log-Logístico

- **Tempo de Sobrevivência Esperado**

$$E(T) = \lambda * (\pi/\gamma) * \frac{1}{\text{sen}(\pi/\gamma)}$$

Só existe de $\gamma > 1$

- **Para o modelo Arrhenius-Log-Logístico**

$$E(T) = \left(\exp(\ln(\lambda_0) - \frac{E}{k\tau}) * (\pi/\gamma) * \frac{1}{\text{sen}(\pi/\gamma)} \right)$$

Ajuste e Validação do Modelo

Relação Estresse-Resposta

Estimação dos Parâmetros

- **Método de Máxima Verossimilhança:** maximiza a probabilidade dos dados observados serem produzidos pelo modelo e produz estimativas robustas quando lidam com dados censurados

$$L(\theta) = \prod_{i=1}^n [f(y_i|x_i)]^{\delta_i} [S(y_i|x_i)]^{1-\delta_i}$$

sendo

$$y_i = \ln(t_i) ;$$

$$\theta = (\beta' s, \sigma);$$

δ_i é o indicador de falha e censura

Relação Estresse-Resposta

Significância do Parâmetro β

Os coeficientes (β): quantifica o impacto da variável de estresse sobre o tempo de sobrevivência.

p-valores: testam a hipótese nula de que $\beta = 0$ (ou seja, de que a covariável não tem efeito significativo sobre o risco)

Se $pvalor < 0.05$, rejeitamos a hipótese nula, concluindo que a covariável é significativa

Relação Estresse-Resposta

Validação do Modelo

- **Análise gráfica da curva de sobrevivência de Kaplan-Meier sobreposta ao modelo teórico**
- **Diagnóstico de Resíduos:** Avaliar a adequação do modelo
- **Métricas de Estimação:** Mede a qualidade do ajuste
- **Critérios de Ajuste:** Compare o AIC/BIC entre diferentes modelos
→ menor AIC/BIC é indicativo de melhor modelo

Relação Estresse-Resposta

Análise Gráfica para Qualidade do Modelo

- Se as curvas de Kaplan-Meier sobreposta a distribuição **escolhida** estiverem alinhadas razoavelmente bem indica que a distribuição escolhida é adequada

Relação Estresse-Resposta

Análise de Resíduos

- **Resíduos Cox-Snell:** Verifica se a distribuição escolhida para o modelo é adequada.

Se o modelo de sobrevivência está corretamente especificado, os resíduos de Cox-Snell devem seguir uma distribuição Exponencial com parâmetro 1.

Desvio acima indica que o modelo superestima a taxa de risco para certos tempos e **desvio abaixo da linha** que o modelo subestima

Relação Estresse-Resposta

Análise de Resíduos

- **Resíduos v.s Temperatura:** avaliam o quanto o modelo conseguiu capturar o efeito da temperatura.

O gráfico deve mostrar um padrão aleatório

- **Resíduos deviance:** Permitem identificar observações influentes ou discrepantes que podem impactar o modelo

Gráficos de resíduos deviance contra valores ajustados devem ser simétricos em torno de zero e sem padrões claros

Relação Estresse-Resposta

Análise de Resíduos

- **Resíduos Generalizados:** Avaliam a adequação da escolha da função de sobrevivência

O gráfico de resíduos generalizados deve mostrar um padrão aleatório

- **Análise de Resíduos (QQ Plots):** Compara os resíduos ajustados pelo modelo com a distribuição teórica.

Uma linha reta nos gráficos indica que a distribuição escolhida é adequada para modelar os dados

Relação Estresse-Resposta

Validação do Modelo

Métricas de Estimação: usadas para avaliar o desempenho do modelo

- **Erro quadrático médio (RMSE):** avalia a média dos quadrados das diferenças entre os valores previstos e os valores reais.

$$RMSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

em que y_i são os valores observados da série original; $\hat{y}_i$ valores previsto (estimado) pelo modelo; n número de observações

Relação Estresse-Resposta

Validação do Modelo

Característica do Erro quadrático médio (RMSE)

- **Sensibilidade a grandes erros:** o RMSE penaliza mais fortemente grandes erros e, por isso, o torna mais sensível a outliers.
- **Diferenciação de modelos:** o RMSE amplifica os maiores erros apontando os modelos com pequenas e grandes falhas.

Relação Estresse-Resposta

Validação do Modelo

- **Erro médio absoluto (MAE):** avalia a média das diferenças absolutas entre os valores previstos e os valores reais.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

em que y_i são os valores observados da série original; $\hat{y}_i$ valores previsto (estimado) pelo modelo; n número de observações

Relação Estresse-Resposta

Validação do Modelo

Característica do Erro médio absoluto (MAE)

- **Interpretação Intuitiva:** interpretação direta por medir a média dos erros em termos das unidades originais das observações.
- **Robustez a Outliers:** é menos sensível a grandes erros ou outliers em comparação com o MSE.

Relação Estresse-Resposta

Validação do Modelo

Critérios de Informação

- **AIC (Akaike Information Criterion):** é uma medida usada para comparar a qualidade do ajuste quanto a complexidade de diferentes modelo (número de parâmetros).

$$AIC = 2k - 2\ln(L)$$

sendo k é o número de parâmetros e L a função de verossimilhança

Interpretação: o modelo com o menor valor de AIC é considerado o melhor.

Relação Estresse-Resposta

Validação do Modelo

- **BIC (Bayesian Information Criterion):** considera a qualidade do ajuste e a complexidade do modelo, mas aplica uma penalização mais forte para modelos com mais parâmetros. É utilizado para grandes tamanhos de amostras.

$$BIC = \ln(n)k - 2\ln(L)$$

sendo K é o número de parâmetros, L a função de verossimilhança e n tamanho da amostra.

Interpretação: o modelo com o menor valor de BIC é considerado o melhor.

Relação Estresse-Resposta

Comparação das Curvas de Sobrevivência

- **Teste de Log-Rank:** para comparar as funções de sobrevivência para as diferentes temperaturas.

Hipótese - H_0 : Não há diferença entre as funções de sobrevivência

Se $p - valor < 0.05$ conclui que a diferença é significativa

Relação Estresse-Resposta

Previsões para as Condições Normais de Uso

O tempo de vida esperado em condições normais de uso é dado por:

$$T_{normal} = T_{estresse}FA$$

T_{normal} : é o tempo de vida normal de operação

$T_{estresse}$: é o tempo de vida do teste acelerado

FA : fator de aceleração

Relação Estresse-Resposta

Vantagens

- É fácil de aplicar e amplamente aceito em indústrias.
- Pode prever o comportamento em condições normais a partir de dados de testes acelerados.

Relação Estresse-Resposta

Limitações

- Pode levar a erros significativos se as condições de teste estiverem muito distantes das condições normais.
- Não captura tendências ou padrões nos dados de sobrevivência.

Aplicações dos Testes de vida Acelerados

Aplicação do Modelo Arrhenius-Log-Normal

Exemplo: Experimento simulado que busca aplicar o modelo de Teste de Vida Acelerado Estresse-Resposta de Arrhenius com a distribuição log-normal.

Objetivo: Investigar o tempo de falha (dias) de um dispositivo submetido a diferentes temperaturas;

Duração do estudo: Aproximadamente 6 meses;

Amostra: 200 dispositivos;

Fator de Aceleração: Temperaturas simuladas na faixa de 70°C a 120°C correspondendo a 343,15K e 393,15K, respectivamente.

Modelo Arrhenius-Log-Normal

- **O termo de Arrhenius (τ^{-1}):** é calculado para modelar o parâmetro de localização da log-normal e capturar a dependência exponencial inversa entre temperatura e taxa de falhas
- Cada dispositivo foi acompanhado até a **falha** (evento de interesse) ou **não falha** até o final do período de observação.
- 70% (falhas observadas) e 30% (censuras).

Modelo Arrhenius-Log-Normal

Etapas Realizadas em Python:

1. Simulação dos Dados
2. Ajuste do Teste de Vida Acelerado Arrhenius-Log-Normal
3. Estimativa da Curva Sobrevivência ou Confiabilidade
4. Estimativa da Função de Risco
5. Análise de Adequação do Modelo e Análise de Resíduos
6. Previsões para Novas Condições: 10°C; 25°C; 40°C

- ✓ Modelo de Arrhenius-Log-Normal
- ✓ Instalando bibliotecas para análise de sobrevivência

```
[2] pip install lifelines
```

- ✓ Importando as funções

```
[4] import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from lifelines import LogNormalAFTFitter, KaplanMeierFitter
import scipy.stats as stats
```

Inserir dados

```

# Configuração do seed para reprodutibilidade
np.random.seed(42)
n = 200

# Temperatura em Celsius e Kelvin
temperatura_celsius = np.random.uniform(70, 120, n) # Temperatura em °C
temperatura_kelvin = temperatura_celsius + 273.15

# Transformação Arrhenius com normalização
arrhenius_term = 1 / temperatura_kelvin
arrhenius_term_normalized = (arrhenius_term - arrhenius_term.mean()) / arrhenius_term.std()

# Simulação de tempos de falha com dependência Arrhenius
tempo_falha_base = np.random.lognormal(mean=np.log(10), sigma=0.5, size=n)
# Garantindo que os tempos de falha sejam estritamente positivos
tempo_falha = tempo_falha_base * (arrhenius_term_normalized + abs(arrhenius_term_normalized.min()) + 1e-6)

# Indicador de censura (70% de falhas observadas)
censura = np.random.binomial(1, 0.7, n) # 1 = falha observada, 0 = censura

# Criando o DataFrame
df = pd.DataFrame({
    "temperature_celsius": temperatura_celsius,
    "temperature_kelvin": temperatura_kelvin,
    "arrhenius_term": arrhenius_term,
    "arrhenius_term_normalized": arrhenius_term_normalized,
    "time_to_failure": tempo_falha,
    "event": censura # 1 para falha observada, 0 para censura
})

# Visualizando os 5 primeiros registros
print(df.head())

```

	temperature_celsius	temperature_kelvin	arrhenius_term	arrhenius_term_normalized	time_to_failure	event
0	88.727006	361.877006	0.002763	0.337803	14.079302	1
1	117.535715	390.685715	0.002560	-1.532055	1.215625	0
2	106.599697	379.749697	0.002633	-0.855649	9.084704	1
3	99.932924	373.082924	0.002680	-0.423846	8.510848	1
4	77.800932	350.950932	0.002849	1.127262	70.346686	1

▼ Ajuste do modelo Lognormal com o modelo de Arrhenius

```

from lifelines import LogNormalAFTFitter

aft = LogNormalAFTFitter()
aft.fit(df, duration_col="time_to_failure", event_col="event", formula="arrhenius_term_normalized")
print(aft.summary)

```

		coef	exp(coef)	se(coef)	\
param	covariate				
mu_	Intercept	2.771273	15.978966	0.103923	
	arrhenius_term_normalized	1.145006	3.142461	0.102309	
sigma_	Intercept	0.302364	1.353054	0.059182	
		coef lower 95%	coef upper 95%		\
param	covariate				
mu_	Intercept	2.567588	2.974958		
	arrhenius_term_normalized	0.944485	1.345527		
sigma_	Intercept	0.186370	0.418359		
		exp(coef) lower 95%	exp(coef) upper 95%		\
param	covariate				
mu_	Intercept	13.034352	19.588804		
	arrhenius_term_normalized	2.571489	3.840211		
sigma_	Intercept	1.204867	1.519466		
		cmp to	z	p	-log2(p)
param	covariate				
mu_	Intercept	0.0	26.666658	1.147231e-156	518.022627
	arrhenius_term_normalized	0.0	11.191694	4.477942e-29	94.173079
sigma_	Intercept	0.0	5.109052	3.237791e-07	21.558487

O tempo médio de falha é de 16 dias quando é **nulo** o efeito da temperatura

O tempo médio de falha **aumenta 3,14 vezes** para cada **aumento de uma unidade** na temperatura

A variável temperatura é **significativa** ao nível de 5% de significância

✓ Curva de Sobrevida Estimada para Modelo Arrhenius-Lognormal

```
[42] import numpy as np
import matplotlib.pyplot as plt


# Definição do intervalo de tempo para previsão
time_range = np.linspace(df["time_to_failure"].min(), df["time_to_failure"].max(), 100)

# Previsão da função de sobrevivência para diferentes temperaturas
survival_estimates_70 = aft.predict_survival_function(
    pd.DataFrame({"arrhenius_term_normalized": [(1 / (70 + 273.15) - arrhenius_term.mean()) / arrhenius_term.std()]}),
    times=time_range
)

survival_estimates_120 = aft.predict_survival_function(
    pd.DataFrame({"arrhenius_term_normalized": [(1 / (120 + 273.15) - arrhenius_term.mean()) / arrhenius_term.std()]}),
    times=time_range
)

# Plot da função de sobrevivência
plt.figure(figsize=(10, 6))
plt.title("Função de Sobrevida Estimada (Modelo Arrhenius-Log-Normal)")
plt.plot(time_range, survival_estimates_70.iloc[:, 0], label="Estimada (AFT) para 70°C")
plt.plot(time_range, survival_estimates_120.iloc[:, 0], label="Estimada (AFT) para 120°C")
plt.xlabel("Tempo")
plt.ylabel("Probabilidade de Sobrevida")
plt.legend()
plt.grid()
plt.show()
```

Função de sobrevivência estimada pelo método Arrhenius-Log-Normal



Observa-se que o **tempo funcional** do dispositivo para a temperatura 120°C é menor ao comparar com a de 70°C.

88% dos dispositivos na temperatura de 70 °C sobrevivem mais do que 25 dias e na de 120 °C temos menos de 1%

Comparação usando o teste de Log-Rank



```
# Simulando dados a partir das curvas de sobrevivência estimadas
temps = [70, 120]
survival_functions = [survival_estimates_70, survival_estimates_120]

simulated_data = []
for i, temp in enumerate(temps):
    survival_func = survival_functions[i].iloc[:, 0] # Curva de sobrevivência estimada
    times = time_range
    # Simulando eventos (1 para falha, 0 para censura)
    random_probs = np.random.uniform(size=len(times))
    events = (random_probs < (1 - survival_func)).astype(int) # Falha se random_probs < P(falha)

    # DataFrame para o grupo específico
    temp_df = pd.DataFrame({
        "time": times,
        "event": events,
        "group": temp
    })
    simulated_data.append(temp_df)

# Unindo os datasets simulados
simulated_data = pd.concat(simulated_data, ignore_index=True)

# Comparação usando o teste de Log-Rank
results_70_120 = logrank_test(
    simulated_data[simulated_data["group"] == 70]["time"],
    simulated_data[simulated_data["group"] == 120]["time"],
    event_observed_A=simulated_data[simulated_data["group"] == 70]["event"],
    event_observed_B=simulated_data[simulated_data["group"] == 120]["event"],
)
```

Teste de Log-Rank para comparar as curvas de sobrevivência para as temperaturas 70°C e 120°C

```
# Exibindo o resultado do teste
print("Resultado do Teste de Log-Rank entre 70°C e 120°C:")
print(f"Estatística do teste: {results_70_120.test_statistic:.4f}")
print(f"Valor-p: {results_70_120.p_value:.4f}")

# Interpretação
if results_70_120.p_value < 0.05:
    print("Rejeitamos a hipótese nula: As curvas de sobrevivência são significativamente diferentes.")
else:
    print("Não rejeitamos a hipótese nula: Não há diferença significativa entre as curvas de sobrevivência.")
```

```
⇒ Resultado do Teste de Log-Rank entre 70°C e 120°C:
Estatística do teste: 22.2271
Valor-p: 0.0000
Rejeitamos a hipótese nula: As curvas de sobrevivência são significativamente diferentes.
```

Observa-se que o teste de Log-Rank corrobora para o resultado de significância do parâmetro que mostrou a temperatura como uma variável significativa para acelerar o tempo de falha

Tabela da Função de Sobrevivência estimada

```
[23] print(pd.DataFrame({'temp:70':(survival_estimates_70.iloc[:, 0]), 'temp:120':(survival_estimates_120.iloc[:, 0])}))
```

	temp:70	temp:120
0.000004	1.000000	1.000000
1.816341	0.998895	0.575171
3.632679	0.994584	0.373450
5.449017	0.987725	0.266841
7.265354	0.979115	0.201856
...	...	...
172.552073	0.380085	0.000746
174.368410	0.377142	0.000727
176.184748	0.374236	0.000708
178.001085	0.371367	0.000689
179.817423	0.368534	0.000672

[100 rows x 2 columns]

98% dos dispositivos na temperatura de 70°C continuaram funcionando em aproximadamente 5 dias ao comparar com 26% dos dispositivos na temperatura 120°C

▼ Função de Risco

```
[25] import numpy as np
import matplotlib.pyplot as plt
import pandas as pd

# Temperaturas para comparação
temperatures = [70, 120]
hazards = []

# Estimando a taxa de risco para diferentes temperaturas
for temp in temperatures:
    arrhenius_term_normalized = (1 / (temp + 273.15) - arrhenius_term.mean()) / arrhenius_term.std() # Normalização

    # Previsão da taxa de risco para cada temperatura
    hazard = aft.predict_hazard(
        pd.DataFrame({"arrhenius_term_normalized": [arrhenius_term_normalized]}),
        times=time_range
    )


    hazards.append(hazard)

# Plotando as taxas de risco para cada temperatura
plt.figure(figsize=(10, 6))
plt.title("Taxa de Risco Estimada para Diferentes Temperaturas")

for i, temp in enumerate(temperatures):
    hazard = hazards[i].iloc[:, 0] # Selecionando a primeira coluna da previsão
    plt.plot(time_range, hazard, label=f"Taxa de Risco (T={temp}°C)")

plt.xlabel("Tempo")
plt.ylabel("Taxa de Risco")
plt.legend()
plt.grid()
plt.show()
```

Função de Risco estimada pelo método Arrhenius-Log-Normal



O risco cresce até o pico porque mais dispositivos atingem o "**tempo típico**" de **falha** que foi de aproximadamente 5 dias para a temperatura de 120 °C .

Dispositivos a 120 °C mostrou um risco de falha 25 vezes maior do que dispositivos a 70 °C no início do estudo

Análise Gráfica para Adequação do Ajuste

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from lifelines import KaplanMeierFitter

# Recalcular média e desvio da normalização (se ainda não tiver feito)
arrh_mean = df['arrhenius_term'].mean()
arrh_std = df['arrhenius_term'].std()

# Grupos por temperatura (ajuste os limites se necessário)
grupo_70 = df[(df['temperature_celsius'] >= 69) & (df['temperature_celsius'] <= 71)]
grupo_120 = df[(df['temperature_celsius'] >= 119) & (df['temperature_celsius'] <= 121)]

# Temperaturas para predição
temps = [70, 120]
colors = ['blue', 'orange'] # Azul para 70, laranja para 120

# Inicializar o gráfico
plt.figure(figsize=(10, 6))

# Loop sobre as temperaturas e os grupos
for T, grupo, color in zip(temps, [grupo_70, grupo_120], colors):
    # Kaplan-Meier empírica
    kmf = KaplanMeierFitter()
    kmf.fit(grupo['time_to_failure'], event_observed=grupo['event'], label=f'KM {T}°C')
    kmf.plot_survival_function(ci_show=False, color=color, linestyle='-')


    # Termo de Arrhenius normalizado para o modelo
    T_K = T + 273.15
    inv_temp = 1 / T_K
    inv_temp_norm = (inv_temp - arrh_mean) / arrh_std

    # Curva predita pelo modelo
    times = np.linspace(0, 100, 200)
    surv_pred = aft.predict_survival_function(
        pd.DataFrame({'arrhenius_term_normalized': [inv_temp_norm]}),
        times=times
```

```
)
plt.plot(
    surv_pred.index,
    surv_pred.values.flatten(),
    linestyle='--',
    color=color,
    label=f'Modelo Log-Normal AFT {T}°C'
)

# Finalização do gráfico
plt.title("Curvas de Sobrevivência: Kaplan-Meier (sólido) vs Log-Normal AFT (tracejado)")
plt.xlabel("Tempo")
plt.ylabel("Probabilidade de Sobrevivência")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()
```

Curva de Kaplan-Meier sobreposta a curva pelo método Arrhenius-Log-Normal



O modelo ajustado se aproxima razoavelmente bem da curva empírica, especialmente na tendência geral.

Para 120°C, há falhas muito rápidas, indicando vida útil curta sob essa temperatura.

Para 70°C, a vida útil é maior, com quedas graduais e mais espaçadas.

Análise Gráfica para Adequação do Ajuste

✓ Gráfico QQ-plot


```
[43] from scipy.stats import probplot
import matplotlib.pyplot as plt

# Ajuste do modelo AFT (Log-Normal) e obtenção das previsões (expectativa)
mu_pred = aft.predict_expectation(df[["arrhenius_term_normalized"]])

# Cálculo dos resíduos logarítmicos
residuals_log = np.log(df["time_to_failure"]) - np.log(mu_pred)

# Gerar o QQ-Plot
fig, ax = plt.subplots(figsize=(10, 6))
probplot(residuals_log, dist="norm", plot=ax)
plt.title("QQ-Plot dos Resíduos (Arrhenius-Log-Normal)")
plt.grid()
plt.show()
```

Gráfico Q-Qplot



O gráfico QQ-Plot avalia o quanto bem os dados se ajustam à suposição de distribuição Log-Normal.

Uma boa aderência é indicada por pontos próximos à linha de referência

Análise dos Resíduos

```
# Resíduos de Cox-Snell

# Calculando a função de sobrevivência estimada para o modelo ajustado
survival_function = aft.predict_survival_function(df[["arrhenius_term_normalized"]])

# Calculando os resíduos de Cox-Snell (baseados na fórmula:  $-\log(S(t))$ )
residuals_cox_snell = -np.log(survival_function.iloc[:, 0])

# Obter  $S(t_i | x_i)$  para cada indivíduo → valor da linha i e coluna i
surv_vals = surv_funcs.to_numpy()[np.arange(len(df_model)), np.arange(len(df_model))]


# Ajustar Kaplan-Meier sobre os resíduos
kmf = KaplanMeierFitter()
kmf.fit(residuals_cox_snell, event_observed=df_model["event"])

# Plotar curva KM dos resíduos vs curva teórica exponencial(1)
plt.figure(figsize=(8, 6))
kmf.plot_survival_function(ci_show=False, label="Kaplan-Meier dos resíduos")

# Curva teórica Exponencial(1):  $S(t) = \exp(-t)$ 
t_vals = np.linspace(0, residuals_cox_snell.max(), 200)
plt.plot(t_vals, np.exp(-t_vals), label="Exponencial(1)", linestyle="--", color="red")

# Gráfico final
plt.title("Verificação do Ajuste: Resíduos de Cox-Snell")
plt.xlabel("Resíduo de Cox-Snell")
plt.ylabel("Probabilidade de Sobrevivência")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

Resíduo de Cox-Snell




No gráfico, a linha azul (Kaplan-Meier dos resíduos) está próxima, mas abaixo da linha vermelha, indicando que a sobrevivência estimada pelos resíduos é menor do que a esperada pela distribuição exponencial.

Análise dos Resíduos

```
# Resíduos versus Temperatura
plt.figure(figsize=(10, 6))
plt.scatter(df["temperature_celsius"], residuals_log, alpha=0.6)
plt.title("Resíduos Logarítmicos versus Temperatura")
plt.xlabel("Temperatura (°C)")
plt.ylabel("Resíduos Logarítmicos")
plt.grid()
plt.show()
```

Resíduo Resíduos versus temperatura



O modelo apresenta um padrão de resíduos que indica possível viés (superestimação) em algumas temperaturas. O ajuste pode ser bom para a maioria dos dados, mas pode ser melhorado para reduzir os grandes erros em temperaturas mais altas.

Previsão para as condições Normais de Uso

✓ Função de Sobrevivência estimada para condições normais de uso

```
[ ] # Normalizando o termo Arrhenius de acordo com os dados usados no modelo ajustado
temperaturas = [10, 25, 40]
previsoes = {}

for temp in temperaturas:
    # Calculando o termo Arrhenius normalizado para a temperatura
    arrhenius_term = 1 / (temp + 273.15)
    arrhenius_term_normalized = (arrhenius_term - df["arrhenius_term"].mean()) / df["arrhenius_term"].std()

    # Previsão da função de sobrevivência para a temperatura
    previsoes[temp] = aft.predict_survival_function(
        pd.DataFrame({"arrhenius_term_normalized": [arrhenius_term_normalized]}),
        times=time_range
    )


# Gráfico das funções de sobrevivência estimadas
plt.figure(figsize=(10, 6))

# Plotando a função de sobrevivência para cada temperatura
for temp in temperaturas:
    survival_estimate = previsoes[temp].iloc[:, 0]
    plt.plot(time_range, survival_estimate, label=f"T={temp}°C")

# Configurações do gráfico
plt.title("Função de Sobrevivência Estimada para Temperaturas de 10°C, 25°C e 40°C")
plt.xlabel("Tempo")
plt.ylabel("Probabilidade de Sobrevivência")
plt.legend()
plt.grid()
plt.show()
```

Previsão para as condições Normais de Uso

Temperaturas: 10°C; 25°C; 40°C



Modelo Arrhenius-Log-Normal

Conclusões

- Foi atingido o objetivo da análise de utilizar os dados em testes acelerados para prever tempo funcional de vida em condições normais de uso.
- Temperaturas altas diminuiu o tempo funcional de vida dos dispositivos de forma bem significativa.
- A análise de resíduo não foi muito precisa para todos os gráficos analisados o que se faz necessário o tratamento mais refinado dos dados ou o ajuste de outros modelos de taxa de vida acelerada.

Resumo Geral

