

Sobrevida de Pacientes com Câncer Colorretal no Estado de São Paulo

Análise de Sobrevivência com Modelagem Paramétrica e de Regressão — RHC/SP (FOSP)

Matheus

04/10/2026

Sumário

1	Apresentação dos Dados	1
1.1	Fonte e população	1
1.2	Eventos e censuras	2
2	Curva de Sobrevivência (Kaplan-Meier) e Teste de Log-Rank	4
2.1	Curva global	4
2.2	Comparação por estágio clínico	5
2.3	Outros grupos	7
3	Curvas de Risco por Técnicas Não Paramétricas	8
3.1	Risco acumulado (Nelson-Aalen)	8
3.2	Taxa de risco instantânea (<i>hazard</i>)	9
4	Ajuste de Modelos Paramétricos e de Regressão	10
4.1	Modelos paramétricos sem covariáveis	10
4.2	Modelos de regressão	13
4.3	Comparação dos modelos	20
5	Conclusão	20
5.1	Limitações	21
6	Apêndice: código R	22

1 Apresentação dos Dados

1.1 Fonte e população

Os dados vêm do Registro Hospitalar de Câncer do Estado de São Paulo (RHC/SP), mantido pela Fundação Oncocentro de São Paulo (FOSP). O registro reúne os casos de câncer atendidos nos hospitais habilitados em oncologia do estado. Foram usados os arquivos por ano de diagnóstico de 2020 a 2023, restritos aos **casos analíticos** de câncer colorretal, isto é, topografias CID-O C18 (cólon), C19 (junção retossigmoide) e C20 (reto). Foram incluídos os pacientes que chegaram ao hospital sem diagnóstico e sem tratamento prévios ($\text{DIAGPREV} = 1$), um subconjunto dos casos analíticos.

- **Evento de interesse:** óbito por qualquer causa ($\text{ULTINFO} = 3$, óbito por câncer, ou 4, óbito por outras causas). A escolha pela sobrevida global evita depender da causa do óbito registrada no prontuário

hospitalar. Também evita tratar o óbito por outras causas como censura não informativa, quando ele é, na verdade, um risco competitivo.

- **Tempo de sobrevida:** dias entre a data do diagnóstico (DTDIAG) e a data da última informação (DTULTINFO), expressos em anos.
- **Censura:** à direita, para os pacientes vivos na última informação ($ULTINFO = 1$ ou 2), incluindo os classificados como perda de seguimento pelo registro.

Tabela 1: Fluxograma de seleção dos casos.

Critério	n restante	Excluídos
Base empilhada	343.765	
Topografia colorretal (C18-C20)	31.227	312.538
Admissão sem erro	31.227	0
Caso analítico (sem diag./trat. prévio)	9.785	21.442
Idade ≥ 18	9.770	15
Estádio I-IV conhecido	8.209	1.561
Tempo e status não ausentes	8.209	0
Tempo não negativo	8.207	2
Diagnóstico entre 2020 e 2023	6.013	2.194

1.2 Eventos e censuras

A coorte final tem **6.013 pacientes**, com **2.803 óbitos (46,6%)** e **3.210 censuras (53,4%)**. O seguimento máximo foi de 6,3 anos. O seguimento mediano, estimado pelo Kaplan-Meier reverso, foi de 3,18 anos. Entre os censurados, 0,1% foram classificados pelo registro como perda de seguimento.

Tabela 2: Número de pacientes, óbitos e censuras por estágio clínico.

Estádio	Pacientes	Óbitos	Censuras	% óbitos
I	842	182	660	21,6%
II	1.551	454	1.097	29,3%
III	1.739	701	1.038	40,3%
IV	1.881	1.466	415	77,9%
Total	6.013	2.803	3.210	46,6%

Tabela 3: Características da coorte e proporção de óbitos por categoria.

Variável	Nível	n (%)	Óbitos no grupo
Sexo	Masculino	3.071 (51,1%)	48,6%
	Feminino	2.942 (48,9%)	44,5%
Faixa etária	18-49	717 (11,9%)	39,1%
	50-64	2.174 (36,2%)	40,5%
	65-74	1.847 (30,7%)	49,2%
	75+	1.275 (21,2%)	57,5%
Categoria de atendimento	SUS	4.954 (82,4%)	47,1%
	Convênio	1.015 (16,9%)	45,2%
	Particular	44 (0,7%)	20,5%
Localização	Cólon	3.998 (66,5%)	45,9%

Variável	Nível	n (%)	Óbitos no grupo
Estádio clínico	Reto/junção	2.015 (33,5%)	48,0%
	I	842 (14,0%)	21,6%
	II	1.551 (25,8%)	29,3%
	III	1.739 (28,9%)	40,3%
	IV	1.881 (31,3%)	77,9%

A idade mediana ao diagnóstico foi de 65 anos (intervalo interquartil 56 a 73).

A coorte tem 6.013 pacientes, com 2.803 óbitos (46,6%) e 3.210 censuras (53,4%), uma proporção de censura moderada a alta. Parte importante dela decorre do tempo curto de acompanhamento: com diagnósticos entre 2020 e 2023, o seguimento máximo é de 6,3 anos e o mediano, de 3,2 anos, de modo que muitos pacientes ainda estavam vivos na data da última informação. Entre os censurados, 0,1% foram classificados pelo registro como perda de seguimento. A censura também varia muito por estágio, de 78,4% no estágio I a 22,1% no IV. Isso é esperado, porque pacientes em estágios iniciais vivem mais e chegam com mais frequência ao fim do acompanhamento, mas significa que as estimativas do estágio I se apoiam em menos eventos (182 óbitos).

Há predomínio de doença avançada ao diagnóstico: os estágios III e IV somam 60,2% dos casos, e o estágio IV sozinho, 31,3%. Esse perfil pesa na sobrevida global da coorte, já que o estágio IV concentra 52,3% de todos os óbitos (1.466 de 2.803).

Nas demais variáveis, a proporção bruta de óbitos cresce com a idade, de 39,1% entre 18 e 49 anos para 57,5% a partir dos 75, e é um pouco maior nos homens (48,6%) que nas mulheres (44,5%). Essas proporções não consideram o tempo de seguimento de cada grupo, por isso as comparações formais ficam para as Seções 2 e 4. Por fim, o atendimento particular reúne apenas 44 pacientes (0,7%), o que torna as estimativas desse grupo imprecisas nos modelos.

2 Curva de Sobrevivência (Kaplan-Meier) e Teste de Log-Rank

2.1 Curva global




Figura 1: Curva de Kaplan-Meier global com intervalo de confiança de 95% e número em risco.

Tabela 4: Sobrevida estimada por Kaplan-Meier em tempos selecionados.

Tempo (anos)	Em risco	S(t)	IC 95%
1	4.017	0,719	[0,708; 0,731]
2	2.852	0,604	[0,591; 0,617]
3	1.739	0,524	[0,511; 0,538]
4	855	0,457	[0,442; 0,472]
5	230	0,412	[0,394; 0,431]
6	17	0,366	[0,330; 0,406]

A sobrevida global estimada em 1 ano foi de 71,9% e, em 6 anos, de 36,6%. A mediana de sobrevida foi de 3,31 anos.

A queda é mais acentuada no primeiro ano: 28,1% dos pacientes morreram nos primeiros 12 meses após o diagnóstico. Depois disso, a perda desacelera. Entre os pacientes vivos no início de cada ano, a proporção de óbitos foi de 16,0% no segundo ano, 13,2% no terceiro, 12,8% no quarto e 9,8% no quinto. A curva não chega a se estabilizar num platô, mas o ritmo de queda no segundo ano já é pouco mais da metade do observado no primeiro e continua diminuindo depois.

Esse formato é compatível com uma coorte em que parte relevante dos pacientes chega ao diagnóstico com doença avançada: esses casos concentram os óbitos precoces, enquanto os diagnosticados em estádios iniciais sustentam a parte mais lenta da curva. Dos óbitos ocorridos no primeiro ano, 56,4% foram de pacientes no estágio IV. A estimativa em 6 anos deve ser lida com cautela, porque se apoia em apenas 17 pacientes em risco, o que explica o intervalo de confiança mais largo.

2.2 Comparação por estágio clínico




Figura 2: Curvas de Kaplan-Meier por estágio clínico.

Tabela 5: Teste de log-rank por estágio: óbitos observados (O) e esperados (E) sob a hipótese de igualdade das curvas.

Estádio	N	Óbitos obs.	Óbitos esp.	O/E	Mediana (anos)
I	842	182	451,2	0,40	não atingida
II	1.551	454	842,8	0,54	não atingida
III	1.739	701	868,8	0,81	4,28
IV	1.881	1.466	640,2	2,29	1,00

Tabela 6: Sobrevida em 1 e 3 anos por estágio.

Estádio	S(t) em 1 ano(s)	IC 95% em 1 ano(s)	S(t) em 3 ano(s)	IC 95% em 3 ano(s)
I	0,878	[0,855; 0,901]	0,780	[0,750; 0,812]
II	0,836	[0,818; 0,855]	0,713	[0,689; 0,738]
III	0,781	[0,762; 0,801]	0,600	[0,576; 0,626]
IV	0,499	[0,476; 0,522]	0,194	[0,175; 0,215]

O teste de log-rank indica diferença estatisticamente significativa entre as curvas dos estádios ($\chi^2 = 1.474,2$, $gl = 3$, $p < 0,001$). Como o teste global só informa que pelo menos uma curva difere, as comparações par a par abaixo usam a correção de Holm para comparações múltiplas.

Tabela 7: Valores-p do log-rank par a par entre estádios (ajuste de Holm).

	Estádio I	Estádio II	Estádio III
Estádio II	0,001		
Estádio III	< 0,001	< 0,001	
Estádio IV	< 0,001	< 0,001	< 0,001

O gradiente é monótono e clinicamente expressivo. A sobrevida em 3 anos cai de 78,0% no estágio I para 71,3% no II, 60,0% no III e 19,4% no IV. As curvas já estão separadas no primeiro ano, e a distância entre elas aumenta com o tempo: a diferença entre os estádios I e IV passa de 37,9 pontos percentuais em 1 ano para 58,6 pontos em 3 anos.

Todos os pares de estádios diferem após o ajuste de Holm. A diferença entre I e II é a menos marcada ($p = 0,001$), e é nela que o valor-p precisa ser lido junto com a magnitude: com quase 2.400 pacientes nesses dois grupos, o teste detecta uma diferença de 4,2 pontos percentuais em 1 ano e de 6,7 em 3 anos, que é real, mas modesta. O salto clinicamente decisivo está entre os estádios III e IV, com 28,2 pontos percentuais de diferença já no primeiro ano. Metade dos pacientes no estágio IV morre no primeiro ano (mediana de 1,00 ano), e, entre os que sobrevivem a ele, 61,1% morrem até o terceiro. No estágio III, a mediana é de 4,28 anos; nos estádios I e II, ela não foi atingida no período de seguimento.

A razão entre óbitos observados e esperados resume o gradiente: no estágio IV ocorreram 2,29 vezes os óbitos esperados sob igualdade das curvas, contra 0,40 no estágio I. O estágio IV reúne 31,3% dos pacientes, mas 52,3% dos óbitos, e é o principal determinante da sobrevida global da coorte. Mesmo no estágio I, porém, 12,2% dos pacientes morreram no primeiro ano. Como o desfecho é óbito por qualquer causa, parte dessas mortes pode não estar ligada ao câncer, e sim à idade e a comorbidades.

2.3 Outros grupos




Figura 3: Curvas de Kaplan-Meier por sexo, categoria de atendimento, localização e faixa etária.

Tabela 8: Testes de log-rank por grupo.

Grupo	Qui-quadrado	gl	p
Estádio clínico	1.474,2	3	< 0,001
Sexo	5,2	1	0,022
Categoria	14,8	2	< 0,001
Localização	0,3	1	0,601
Faixa etária	151,7	3	< 0,001

Além do estágio, as curvas diferem por faixa etária ($\chi^2 = 151,7$; $p < 0,001$), categoria de atendimento ($\chi^2 = 14,8$; $p < 0,001$) e sexo ($\chi^2 = 5,2$; $p = 0,022$). Não há evidência de diferença entre tumores de cólon e de reto/junção retossigmoide ($p = 0,601$). A magnitude das estatísticas mostra a hierarquia entre os fatores: o estágio ($\chi^2 = 1.474,2$) separa as curvas com força cerca de dez vezes maior que a idade e muito maior que sexo e categoria.

Em 3 anos, a sobrevida é de 59,7% entre 18 e 49 anos e de 41,6% a partir dos 75 anos. Por categoria, é de 51,5% no SUS, 56,0% em convênio e 75,1% em particular. Por sexo, é de 50,5% nos homens e 54,5% nas mulheres.

Essas comparações são brutas e não separam o efeito de cada fator do efeito da composição dos grupos. No caso da categoria de atendimento, a distribuição de estádios é parte da explicação a ser verificada: a proporção de pacientes no estágio IV é de 31,1% no SUS, 32,7% em convênio e 20,5% em particular. A diferença por sexo, embora significativa, tem a menor estatística entre os fatores significativos. Com mais de 6 mil pacientes, uma diferença pequena já atinge $p < 0,05$, e ela pode não se manter após o ajuste. A faixa etária, por sua vez, também carrega a mortalidade por outras causas, já que o desfecho é óbito por qualquer causa. A Seção 4 reavalia esses fatores com ajuste simultâneo.

3 Curvas de Risco por Técnicas Não Paramétricas

3.1 Risco acumulado (Nelson-Aalen)

O estimador de Nelson-Aalen é $\hat{H}(t) = \sum_{t_j \leq t} d_j/n_j$, em que d_j é o número de óbitos e n_j o número em risco no tempo t_j . A inclinação de $\hat{H}(t)$ é a taxa de risco: trechos mais íngremes indicam risco maior.




Figura 4: Risco acumulado de Nelson-Aalen: global (esquerda) e por estágio (direita).

Tabela 9: Probabilidade condicional de óbito em cada intervalo anual, dado que o paciente estava vivo no início do intervalo: $1 - \exp\{-[\hat{H}(b) - \hat{H}(a)]\}$.

Intervalo	Global	Estádio I	Estádio II	Estádio III	Estádio IV
[0; 1) anos	28,0%	12,2%	16,4%	21,8%	50,1%
[1; 2) anos	16,0%	6,5%	7,9%	12,8%	38,4%
[2; 3) anos	13,2%	4,9%	7,4%	11,8%	36,6%
[3; 4) anos	12,9%	6,9%	7,6%	13,7%	33,4%

A curva global de $\hat{H}(t)$ é côncava no início e aproximadamente linear a partir do segundo ano. A probabilidade condicional de óbito é máxima no primeiro ano (28,0%), cai para 16,0% no segundo e se estabiliza em torno de 13% no terceiro e no quarto (13,2% e 12,9%). Ou seja, o risco é decrescente no início e aproximadamente

constante depois: quem sobrevive ao primeiro ano passa a enfrentar um risco anual de óbito bem menor, mas que deixa de cair a partir do segundo ano. Esse formato já indica que um modelo de risco constante, como o exponencial, não descreve bem o início do seguimento. O mesmo desenho aparece em todos os estádios, com o maior risco sempre no primeiro ano, mas em níveis muito diferentes. Nos estádios I a III, a probabilidade cai entre 41% e 52% do primeiro para o segundo ano (de 12,2% para 6,5% no I, de 16,4% para 7,9% no II e de 21,8% para 12,8% no III) e fica relativamente estável depois. No estágio IV, a queda é menor e mais lenta: de 50,1% no primeiro ano para 38,4% no segundo e 33,4% no quarto. Mesmo depois de sobreviver ao primeiro ano, um paciente no estágio IV tem cerca de um terço de chance de morrer a cada ano, risco maior que o do primeiro ano em qualquer outro estágio. As pequenas altas no último intervalo dos estádios I e III (de 4,9% para 6,9% e de 11,8% para 13,7%) devem ser lidas com cautela, porque o número de pacientes em risco nesse intervalo é bem menor. Também chama atenção que a razão entre as probabilidades dos estádios IV e I muda de um intervalo para outro (de cerca de 4 vezes no primeiro ano para mais de 7 no terceiro), o que antecipa a avaliação de riscos proporcionais da Seção 4.

3.2 Taxa de risco instantânea (*hazard*)

A função de risco foi estimada por suavização de kernel (estimador de Müller e Wang, pacote `muhaz`). A estimação de cada grupo foi limitada ao último tempo com pelo menos 200 pacientes em risco (ou 10% do grupo, o que for maior), porque na cauda da distribuição o estimador produz oscilações artificiais.




Figura 5: Taxa de risco suavizada: global (esquerda) e por estágio (direita, escala logarítmica).

Tabela 10: Taxa de risco suavizada (óbitos por pessoa-ano) em tempos selecionados.

Grupo	$h(0,25)$	$h(0,50)$	$h(1,00)$	$h(2,00)$	$h(3,00)$	Fim da janela (anos)
Global	0,470	0,271	0,208	0,145	0,146	4,3
Estádio I	0,183	0,138	0,082	0,058	0,079	3,6
Estádio II	0,276	0,175	0,099	0,081	0,078	4,5
Estádio III	0,373	0,255	0,155	0,132	0,134	4,4
Estádio IV	0,906	0,598	0,548	0,431	0,334	3,1

O período de maior risco é o início do seguimento. A taxa de risco global é de 0,470 óbitos por pessoa-ano aos 3 meses do diagnóstico e cai para 0,208 em 1 ano, 0,145 em 2 anos e 0,146 em 3 anos. Só nos primeiros 30 dias ocorreram 389 óbitos, 13,9% de todos os óbitos da coorte. O formato confirma a tabela de Nelson-Aalen: risco decrescente no início e aproximadamente estável a partir do segundo ano. O período de menor risco é o final do seguimento observado; a leve alta no fim da janela está na região de borda da estimativa, onde há menos pacientes em risco, e não deve ser interpretada como aumento real.

Na prática, isso concentra a necessidade de acompanhamento intensivo nos primeiros meses após o diagnóstico, quando a taxa de risco é várias vezes maior que a dos anos seguintes. Para quem sobrevive a esse período, o risco cai, ou seja, a sobrevida condicional melhora com o tempo. É uma informação útil no aconselhamento: a chance de sobreviver aos anos seguintes é maior para quem já passou do primeiro ano do que a estimada no momento do diagnóstico.

Todos os estádios seguem o mesmo desenho, com risco máximo no início, mas em níveis muito diferentes. Em 1 ano, a taxa de risco no estágio IV (0,548) é cerca de 7 vezes a do estágio I (0,082). Em 2 anos, o estágio IV ainda tem 0,431 óbitos por pessoa-ano, contra 0,132 no estágio III.

Esse formato orienta a escolha da distribuição na Seção 4. A exponencial, de risco constante, é incompatível com ele. A Weibull com forma menor que 1 e a log-logística com forma até 1 produzem risco decrescente. A log-normal produz um risco que sobe muito rápido logo após o início e depois decresce, o que, com pico tão precoce, também se aproxima do observado. Os critérios de ajuste decidem entre elas.

4 Ajuste de Modelos Paramétricos e de Regressão

4.1 Modelos paramétricos sem covariáveis

Cada distribuição impõe uma forma à função de risco. Por isso, o formato observado na Seção 3 já sugere quais modelos são plausíveis:

Tabela 11: Forma da função de risco implicada por cada distribuição.

Modelo	Forma de $h(t)$
Exponencial	Constante
Weibull	Monótona: crescente (forma > 1) ou decrescente (forma < 1)
Log-normal	Unimodal: cresce e depois decresce
Log-logística	Decrescente (forma ≤ 1) ou unimodal (forma > 1)

Tabela 12: Critérios de ajuste dos modelos paramétricos sem covariáveis (BIC com penalização $\log(n)$). A gama generalizada entra como referência, pois engloba Weibull, log-normal e exponencial como casos particulares.

Modelo	k	logLik	AIC	BIC	Dif. AIC
Gama generalizada	3	-6.497,3	13.000,7	13.020,8	0,0
Weibull	2	-6.504,5	13.013,1	13.026,5	12,4
Log-logística	2	-6.505,8	13.015,7	13.029,1	15,0
Log-normal	2	-6.533,1	13.070,2	13.083,6	69,5
Exponencial	1	-6.947,7	13.897,3	13.904,0	896,7

Tabela 13: Estimativas dos parâmetros (parametrização do pacote flexsurv).

Modelo	Parâmetro	Estimativa	IC 95%
Exponencial	rate	0,228	[0,220; 0,237]
Weibull	shape	0,632	[0,611; 0,653]
	scale	5,910	[5,533; 6,312]
Log-normal	meanlog	1,277	[1,197; 1,358]
	sdlog	2,483	[2,413; 2,556]
Log-logística	shape	0,736	[0,712; 0,760]
	scale	3,387	[3,158; 3,633]

Tabela 14: Testes da razão de verossimilhanças entre modelos encaixados.

Teste	TRV	gl	p
Exponencial vs Weibull (H_0 : forma = 1)	886,2	1	< 0,001
Weibull vs Gama generalizada (H_0 : $Q = 1$)	14,4	1	< 0,001
Log-normal vs Gama generalizada (H_0 : $Q = 0$)	71,5	1	< 0,001




Figura 6: Kaplan-Meier (degraus) e curvas de sobrevida ajustadas pelos modelos paramétricos.




Figura 7: Gráficos de linearização com base no Kaplan-Meier. Se a distribuição for adequada, os pontos ficam próximos de uma reta (tracejada: ajuste de mínimos quadrados).

Entre as quatro distribuições pedidas, a de menor AIC sem covariáveis foi a **Weibull**. O parâmetro de forma estimado da Weibull foi 0,632 (IC 95%: [0,611; 0,653]), o que indica risco decrescente no tempo.

AIC e BIC concordam e apontam a Weibull, com 2,6 pontos de AIC a menos que a segunda colocada (log-logística). O teste da razão de verossimilhanças entre exponencial e Weibull rejeita a forma igual a 1 ($p < 0,001$), ou seja, o risco não é constante no tempo. Os testes contra a gama generalizada, com uma amostra deste tamanho, tendem a rejeitar os casos particulares mesmo quando a diferença é pequena; por isso a diferença de AIC e os gráficos são mais informativos que eles.

Nos gráficos de linearização, a exponencial é a única claramente inadequada: a curva de $-\log S(t)$ é côncava, cresce rápido no início e desacelera, o que indica risco decrescente, e não constante. A Weibull e a log-logística são as mais próximas da reta em praticamente toda a faixa de tempo. No gráfico da Weibull, a inclinação da reta corresponde ao parâmetro de forma e é visivelmente menor que 1, coerente com a estimativa acima. A log-normal acompanha bem a reta a partir de $\log t \approx -2,5$ (cerca de um mês), mas se afasta dela nos tempos mais curtos. Os desvios das três no extremo esquerdo ($\log t < -5$, os primeiros dois a três dias) correspondem aos 81 óbitos ocorridos até o terceiro dia, incluindo os registrados no próprio dia do diagnóstico, cujo tempo foi fixado em meio dia.

Essa leitura é coerente com a forma do risco vista na Seção 3. O risco é máximo logo após o diagnóstico e decresce, formato que a Weibull e a log-logística com forma menor que 1 reproduzem. A log-normal, ao contrário, impõe um risco que parte de zero e sobe antes de cair, e é exatamente nos primeiros dias que ela se afasta da reta.

A escolha da Weibull pelo AIC é, portanto, coerente com os gráficos e com a forma do risco.

4.2 Modelos de regressão

As covariáveis são estágio clínico, idade (centrada em 60 anos, por década), sexo, categoria de atendimento e localização do tumor. Os indicadores de tratamento **não** entram no modelo, por dois motivos. Primeiro, o tratamento é definido depois do diagnóstico, o que gera viés de tempo imortal: o paciente precisa sobreviver até a cirurgia para ser classificado como operado. Segundo, há confusão por indicação: a escolha do tratamento depende do estado clínico do paciente.

Foram usados 6.013 pacientes com informação completa nas covariáveis (0 excluídos por dados ausentes, 0,0%).

4.2.1 Modelos de tempo de falha acelerado (AFT)

No modelo AFT, $\log T = \mathbf{x}^\top \beta + \sigma \varepsilon$, em que a distribuição de ε define o modelo. O termo e^{β_j} é a **razão de tempos** (*time ratio*): valores menores que 1 indicam que a covariável **encurta** o tempo até o óbito.

Tabela 15: Critérios de ajuste dos modelos AFT com covariáveis (C = índice de concordância de Harrell).

Modelo	k	logLik	AIC	BIC	C	Dif. AIC
Weibull	10	-5.736,8	11.493,6	11.560,6	0,705	0,0
Log-logística	10	-5.807,6	11.635,1	11.702,2	0,706	141,6
Log-normal	10	-5.917,7	11.855,4	11.922,4	0,706	361,8
Exponencial	9	-6.009,6	12.037,2	12.097,5	0,706	543,6

Tabela 16: Modelo AFT Weibull: razões de tempos estimadas (escala estimada = 1,428).

Termo	Razão de tempos	IC 95%	p
Estádio II (vs I)	0,721	[0,563; 0,922]	0,009
Estádio III (vs I)	0,386	[0,305; 0,488]	< 0,001
Estádio IV (vs I)	0,078	[0,062; 0,098]	< 0,001
Idade (+10 anos)	0,705	[0,673; 0,738]	< 0,001
Sexo feminino (vs masculino)	1,104	[0,993; 1,228]	0,068
Convênio (vs SUS)	1,304	[1,129; 1,506]	< 0,001
Particular (vs SUS)	4,802	[1,884; 12,242]	0,001
Reto/junção retossigmoide (vs cólon)	0,892	[0,798; 0,998]	0,046




Figura 8: Resíduos de Cox-Snell dos modelos AFT. Se o modelo for adequado, o risco acumulado dos resíduos (estimado por Kaplan-Meier) acompanha a reta identidade.

Nos resíduos de Cox-Snell, a Weibull é o único modelo cujo risco acumulado acompanha a reta identidade em praticamente toda a faixa dos resíduos, com afastamentos apenas na cauda, onde restam poucas observações. A exponencial fica abaixo da reta a partir de resíduos em torno de 1, e a log-normal e a log-logística se afastam para cima a partir de 0,8 a 1,0. O gráfico confirma, portanto, a ordem do AIC, que também aponta a Weibull como o melhor modelo AFT. O resultado é coerente com as seções anteriores: a escala estimada de 1,428 corresponde a um parâmetro de forma de $1/1,428 \approx 0,70$, menor que 1, ou seja, risco decrescente no tempo, como indicaram a taxa de risco suavizada e os gráficos de linearização.

No modelo AFT Weibull, mantidas as demais covariáveis, o tempo até o óbito é 27,9% menor no estágio II, 61,4% menor no estágio III e 92,2% menor no estágio IV, em relação ao estágio I. No estágio IV, ele equivale a cerca de 1/13 do observado no estágio I. Cada década a mais de idade reduz o tempo até o óbito em 29,5%. Pacientes atendidos por convênio têm tempo 30,4% maior que os do SUS, mesmo após o ajuste por estágio e idade. A diferença vista no log-rank, portanto, não se explica só pela composição de estágios, embora ainda possa refletir fatores não medidos, como condição socioeconômica e acesso ao tratamento. Como a Weibull também é um modelo de riscos proporcionais, cada razão de tempos (RT) corresponde a uma razão de riscos $HR = RT^{-1/\sigma}$: para o estágio IV, cerca de 6,0; para cada década de idade, cerca de 1,28.

A razão de tempos de 4,80 para o atendimento particular deve ser lida com cautela. O intervalo de confiança é muito largo (1,88 a 12,24), porque o grupo é pequeno (44 pacientes), e o efeito é grande demais para ser atribuído só ao tipo de atendimento. Uma hipótese é a qualidade do seguimento: se o óbito desses pacientes é registrado com menos frequência pelo hospital, eles parecem viver mais. Entre os censurados, a proporção classificada como perda de seguimento é de 0,0% no atendimento particular e de 0,0% no SUS, o

que não sustenta essa hipótese; o efeito pode refletir características não medidas do grupo, como condição socioeconômica e comorbidades. O efeito do sexo não é significativo ao nível de 5% (razão de tempos de 1,10; $p = 0,068$), e o da localização do tumor também é significativo (razão de tempos de 0,892; $p = 0,046$).

4.2.2 Modelo de regressão de Cox

O modelo de Cox, $h(t | \mathbf{x}) = h_0(t) \exp(\mathbf{x}^\top \beta)$, não especifica o risco basal $h_0(t)$. Em troca, ele supõe **riscos proporcionais**: a razão de riscos entre dois pacientes é constante no tempo. Os empates foram tratados pelo método de Efron.

Tabela 17: Modelo de Cox: razões de riscos (C de Harrell = 0,705).

Termo	Razão de riscos	IC 95%	p
Estádio II (vs I)	1,256	[1,057; 1,492]	0,010
Estádio III (vs I)	1,947	[1,653; 2,292]	< 0,001
Estádio IV (vs I)	5,997	[5,136; 7,003]	< 0,001
Idade (+10 anos)	1,277	[1,237; 1,319]	< 0,001
Sexo feminino (vs masculino)	0,932	[0,865; 1,004]	0,062
Convênio (vs SUS)	0,830	[0,751; 0,918]	< 0,001
Particular (vs SUS)	0,332	[0,172; 0,638]	< 0,001
Reto/junção retossigmoide (vs cólon)	1,086	[1,004; 1,174]	0,039

4.2.3 Validação do modelo de Cox

Tabela 18: Teste de proporcionalidade dos riscos baseado nos resíduos de Schoenfeld (Grambsch & Therneau, 1994).

Termo	Qui-quadrado	gl	p
Estádio	27,47	3	< 0,001
Idade	31,27	1	< 0,001
Sexo	8,60	1	0,003
Categoria	6,34	2	0,042
Localização	38,11	1	< 0,001
Global	109,49	8	< 0,001

Tabela 19: Razão de riscos no início (percentil 10 dos tempos de óbito, 0,05 anos) e no fim do seguimento (percentil 90, 2,81 anos), pela tendência linear dos coeficientes no tempo. Relevante: razão entre a HR no fim e no início abaixo de 0,8 ou acima de 1,25.

Termo	HR (Cox)	HR no início	HR no fim	Variação	Relevante
Estádio II (vs I)	1,26	1,28	1,23	-4,3%	não
Estádio III (vs I)	1,95	1,84	2,07	12,2%	não
Estádio IV (vs I)	6,00	4,57	8,03	75,7%	sim
Idade (+10 anos)	1,28	1,43	1,13	-21,1%	sim
Sexo feminino (vs masculino)	0,93	1,07	0,81	-24,4%	sim
Convênio (vs SUS)	0,83	0,69	1,02	47,8%	sim
Particular (vs SUS)	0,33	0,45	0,24	-46,4%	sim
Reto/junção retossigmoide (vs cólon)	1,09	0,79	1,52	92,7%	sim

O teste rejeita a proporcionalidade para todas as covariáveis ao nível de 5%, assim como o teste global ($\chi^2 = 109,49$; 8 gl; $p < 0,001$). Para medir o tamanho do desvio, ajustou-se uma reta a cada curva $\hat{\beta}(t)$, na mesma escala de tempo usada pelo teste, e comparou-se a razão de riscos no início e no fim do seguimento. Adotou-se como relevante uma razão entre a HR no fim e no início abaixo de 0,8 ou acima de 1,25, isto é, uma mudança de 25% na escala multiplicativa, em qualquer sentido. Por esse critério, o desvio é relevante para estágio IV (vs I), cuja razão de riscos passa de 4,57 para 8,03; idade (+10 anos), cuja razão de riscos passa de 1,43 para 1,13; sexo feminino (vs masculino), cuja razão de riscos passa de 1,07 para 0,81; convênio (vs SUS), cuja razão de riscos passa de 0,69 para 1,02; particular (vs SUS), cuja razão de riscos passa de 0,45 para 0,24 e reto/junção retossigmoide (vs cólon), cuja razão de riscos passa de 0,79 para 1,52. Para esses termos, uma razão de riscos única resume mal a relação, porque o efeito muda ao longo do seguimento. Para os demais, o desvio é estatisticamente detectável, mas pequeno, e a suposição de riscos proporcionais é aceitável na prática.

A localização do tumor merece destaque. Ela tem a maior estatística do teste por grau de liberdade ($\chi^2 = 38,11$ com 1 gl), embora não tenha mostrado diferença no log-rank ($p = 0,601$). Essa combinação aparece quando o efeito muda de direção ao longo do tempo: se um grupo tem risco maior no início e menor depois, os dois períodos se compensam tanto no log-rank quanto na razão de riscos média do Cox. É o que a tabela mostra: a razão de riscos de reto/junção em relação ao cólon passa de 0,79 no início para 1,52 no fim, ou seja, o efeito inverte de sentido ao longo do seguimento.

Esse resultado tem uma consequência para a escolha do modelo. A Weibull, que teve o melhor ajuste entre os modelos AFT, é também um modelo de riscos proporcionais: as razões de riscos implícitas nela são constantes no tempo, como as do Cox. Os desvios identificados aqui afetam, portanto, os dois modelos da mesma forma e não são um argumento para preferir um ao outro. A log-normal e a log-logística não impõem riscos proporcionais, mas tiveram ajuste global pior nos resíduos de Cox-Snell.

Com 6.013 pacientes, o teste tem poder para detectar desvios de proporcionalidade pequenos e sem relevância prática. Por isso, a decisão deve combinar o valor-p com a **magnitude** do desvio, vista nas curvas $\hat{\beta}(t)$ abaixo. Se a curva oscila pouco em torno de uma reta horizontal, a hipótese de riscos proporcionais é aceitável na prática, mesmo com $p < 0,05$.




Figura 9: Coeficientes ao longo do tempo estimados pelos resíduos de Schoenfeld escalonados, com banda de 95%. Uma linha horizontal indica riscos proporcionais. A linha tracejada vermelha marca a estimativa do modelo de Cox.




Figura 10: $\log(-\log S(t))$ por estágio versus $\log(t)$. Curvas aproximadamente paralelas são compatíveis com riscos proporcionais para o estágio.




Figura 11: Esquerda: resíduos martingale do modelo sem idade versus idade (forma funcional). Direita: resíduos de Cox-Snell do modelo de Cox.

4.2.4 Cox estratificado por estágio (análise de sensibilidade)

Quando a proporcionalidade falha para o estágio, uma alternativa é estratificar por ele. Cada estágio passa a ter o seu risco basal $h_{0k}(t)$, livre de forma, e o efeito do estágio deixa de ser estimado. A comparação abaixo mostra se as razões de riscos das demais covariáveis mudam com isso.

Tabela 20: Razões de riscos [IC 95%] no Cox, no Cox estratificado por estágio e implícitas no modelo Weibull.

Termo	Cox	Cox estratificado	Weibull (HR implícita)
Estádio II (vs I)	1,256 [1,057; 1,492]	estrato	1,258
Estádio III (vs I)	1,947 [1,653; 2,292]	estrato	1,947
Estádio IV (vs I)	5,997 [5,136; 7,003]	estrato	5,958
Idade (+10 anos)	1,277 [1,237; 1,319]	1,280 [1,239; 1,321]	1,278
Sexo feminino (vs masculino)	0,932 [0,865; 1,004]	0,934 [0,867; 1,006]	0,933
Convênio (vs SUS)	0,830 [0,751; 0,918]	0,830 [0,751; 0,918]	0,830
Particular (vs SUS)	0,332 [0,172; 0,638]	0,329 [0,171; 0,633]	0,333
Reto/junção retossigmoide (vs cólon)	1,086 [1,004; 1,174]	1,090 [1,008; 1,179]	1,083

No Cox estratificado, o teste global de proporcionalidade teve $p < 0,001$. O modelo Weibull é ao mesmo tempo AFT e de riscos proporcionais. Por isso, quando as razões de riscos implícitas nele ficam próximas das do Cox, há indicação de que uma forma paramétrica é compatível com os dados.

Os gráficos de $\hat{\beta}(t)$ confirmam e detalham a tabela anterior. Os coeficientes dos estádios II e III oscilam em torno da estimativa do Cox, com a reta horizontal dentro da banda de confiança em todo o seguimento, e a variação estimada é pequena ($-4,3\%$ e $12,2\%$). Para eles, a proporcionalidade se sustenta na prática.

O estágio IV é o desvio mais importante. Seu coeficiente sobe de cerca de 1,2 nas primeiras semanas para cerca de 2,0 entre 1 e 2,5 anos, e nos dois primeiros meses a banda de confiança fica inteiramente abaixo da estimativa do Cox. Em razão de riscos, o excesso de risco do estágio IV em relação ao I passa de 4,57 no início para 8,03 por volta de 2,8 anos. Isso retoma o que a tabela de Nelson-Aalen sugeria na Seção 3: logo após o diagnóstico, os estádios iniciais também concentram parte dos óbitos, e a vantagem do estágio I se amplia com o tempo. A razão de riscos única de 6,00 é, portanto, a média de um efeito que cresce ao longo do primeiro ano.

A idade tem o comportamento oposto: seu efeito é mais forte no início (razão de riscos de 1,43 por década) e se atenua para 1,13 depois de dois a três anos, com a banda de confiança excluindo a estimativa do Cox nos dois extremos. Uma interpretação plausível é que a idade pesa sobretudo na mortalidade precoce, ligada à fragilidade e a complicações do tratamento. A vantagem do convênio sobre o SUS também se concentra no início: a razão de riscos de 0,69 nas primeiras semanas chega a cerca de 1,0 por volta de 2,5 a 3 anos, ou seja, a diferença praticamente desaparece entre os pacientes que sobrevivem aos primeiros anos.

A localização confirma a inversão de sentido antecipada pela comparação entre o teste de Schoenfeld e o log-rank. O coeficiente começa negativo, cruza o zero por volta de 4 meses e fica positivo depois, com a banda de confiança excluindo o zero nos dois trechos. Os tumores de reto e junção retossigmoide têm risco menor que os de cólon nos primeiros meses (razão de riscos de 0,79 no início) e maior a partir daí (1,52 por volta de 2,8 anos). Os dois efeitos se compensam na curva bruta, o que explica o log-rank não significativo ($p = 0,601$). Uma explicação possível é a maior frequência de apresentação em urgência nos tumores de cólon, com mortalidade precoce, enquanto no reto o tratamento costuma começar por terapia neoadjuvante e os óbitos se distribuem mais tarde; a base, porém, não permite verificar essa hipótese.

Para sexo e atendimento particular, o critério linear acusa variação, mas os gráficos não sustentam uma tendência: as curvas oscilam, e a banda de confiança contém a estimativa do Cox em quase todo o seguimento. No atendimento particular, a banda é tão larga, por causa do tamanho do grupo, que a curva não permite conclusão. Esses dois desvios não foram considerados relevantes.

Quanto à forma funcional, os resíduos martingale do modelo sem idade ficam praticamente constantes até cerca de 55 anos e crescem a partir daí, cada vez mais rápido. O efeito da idade não é linear: é pequeno entre os adultos jovens e se concentra nas idades mais altas. Substituir o termo linear por um spline natural com 4 graus de liberdade reduz o AIC em 28,0 pontos ($p < 0,001$), o que confirma a não linearidade. O

termo linear foi mantido para preservar a leitura de um efeito por década, mas ele subestima a diferença de risco entre os mais idosos e superestima a diferença entre os adultos jovens. Os resíduos de Cox-Snell do Cox seguem a reta identidade até cerca de 2, com afastamento apenas na cauda, onde restam poucas observações, em padrão muito parecido com o da Weibull.

Por fim, os efeitos das demais covariáveis são robustos à forma de modelar o estágio: estratificar por ele muda as razões de riscos em menos de 1% (a da idade, por exemplo, passa de 1,277 para 1,280). As razões de riscos implícitas na Weibull praticamente coincidem com as do Cox (estádio IV: 5,958 contra 5,997; idade: 1,278 contra 1,277). Como os dois modelos diferem apenas no tratamento do risco basal, essa coincidência indica que a forma Weibull descreve bem o risco basal destes dados.

4.3 Comparação dos modelos

Tabela 21: Comparação dos modelos de regressão. AIC e BIC só são comparáveis entre os modelos AFT, pois o Cox maximiza uma verossimilhança parcial; o índice C é comparável entre todos.

Modelo	Suposição	logLik	AIC	BIC	C
AFT Weibull	Tempo de falha acelerado	-5.736,8	11.493,6	11.560,6	0,705
AFT	Tempo de falha acelerado	-5.807,6	11.635,1	11.702,2	0,706
Log-logística	Tempo de falha acelerado	-5.917,7	11.855,4	11.922,4	0,706
AFT Log-normal	Tempo de falha acelerado	-6.009,6	12.037,2	12.097,5	0,706
AFT Exponencial	Tempo de falha acelerado	-22.246,8 (parcial)	não comparável	não comparável	0,705
Cox	Riscos proporcionais				

5 Conclusão

Entre os modelos paramétricos de regressão, o **AFT Weibull** teve o menor AIC, 141,6 pontos abaixo do segundo colocado (Log-logística). Pelo BIC, o melhor foi o **Weibull**. No modelo de Cox, o teste global de proporcionalidade teve $p < 0,001$. O índice de concordância foi 0,705 no Cox e 0,705 no AFT Weibull.

O modelo final escolhido é o **AFT Weibull**, com estágio clínico, idade, sexo, categoria de atendimento e localização como covariáveis, tendo o Cox como referência semiparamétrica. A escolha se apoia nos três critérios do enunciado:

1. **Qualidade do ajuste.** Entre os modelos com verossimilhança completa, o AFT Weibull tem a maior log-verossimilhança e o menor AIC, 141,6 pontos abaixo do segundo colocado (log-logística), e também o menor BIC. Uma diferença acima de 10 pontos indica, pela regra usual de Burnham e Anderson (2002), suporte praticamente nulo para o modelo concorrente. O Cox não entra nessa comparação, porque sua verossimilhança é parcial, mas o índice de concordância dele (0,705) é praticamente igual ao da Weibull (0,705): os dois ordenam os pacientes por risco da mesma forma.
2. **Validação dos resíduos.** Os resíduos de Cox-Snell da Weibull seguem a reta identidade em praticamente toda a faixa, ao contrário dos da exponencial, da log-normal e da log-logística, e de forma muito parecida com os do Cox. A proporcionalidade dos riscos não se sustenta para o estágio IV, a idade, o convênio e a localização, cujos efeitos mudam ao longo do seguimento. Essa violação afeta igualmente a Weibull e o Cox, já que ambos são modelos de riscos proporcionais. Ela também não se resolve com as alternativas disponíveis. O Cox estratificado acomoda o desvio do estágio, mas não o das demais covariáveis, e mantém as razões de riscos delas praticamente inalteradas (variação inferior a 1%). Os modelos AFT que não impõem proporcionalidade, log-normal e log-logística, tiveram ajuste

global claramente pior. A violação, portanto, não justifica trocar de modelo, mas exige ler as razões de tempos e de riscos como efeitos médios ao longo do seguimento, complementados pela mudança no tempo descrita na Seção 4.2.

3. **Interpretação.** A Weibull permite as duas leituras, o que é uma vantagem prática. A razão de tempos comunica o efeito na escala em que o paciente o vive: no estágio IV, o tempo até o óbito equivale a cerca de 1/13 do observado no estágio I, e cada década de idade o reduz em 29,5%. A razão de riscos, idêntica à do Cox, é a medida padrão na literatura oncológica e facilita a comparação com outros estudos: o risco de óbito no estágio IV é cerca de 6 vezes o do estágio I, e cada década de idade o multiplica por 1,28. Por ser paramétrica, a Weibull também permite estimar a curva de sobrevida e a mediana para qualquer perfil de paciente, o que o Cox só faz de forma não paramétrica. Os efeitos são coerentes com o esperado clinicamente: o risco cresce do estágio I ao IV e com a idade, e o atendimento por convênio se associa a maior sobrevida, sobretudo nos primeiros anos. A estimativa para o atendimento particular, baseada em apenas 44 pacientes, não deve ser interpretada além do sentido do efeito.

5.1 Limitações

- **Registro hospitalar.** A coorte representa pacientes atendidos em hospitais habilitados em oncologia de São Paulo, não a população geral.
- **Censura possivelmente informativa.** Pacientes perdidos de seguimento são censurados na última informação. Se a perda estiver associada a pior prognóstico, a sobrevida é superestimada.
- **Unidade de análise.** A base não tem identificador de paciente, então quem teve mais de um tumor colorretal pode aparecer mais de uma vez.
- **Seguimento.** Os anos de diagnóstico mais recentes têm seguimento curto e, segundo a FOSP, podem estar com o registro em andamento.
- **Covariáveis.** O tratamento foi excluído pelos motivos da Seção 4.2. As variáveis biológicas e de comorbidade não estão disponíveis.

6 Apêndice: código R

```
knitr::opts_chunk$set(echo = FALSE, message = FALSE, warning = FALSE,
  fig.align = "center", fig.width = 7, fig.height = 4.2,
  fig.pos = "H", out.width = "92%")
options(OutDec = ",")

library(survival)      # Surv, survfit, survdiff, coxph, cox.zph, survreg
library(flexsurv)      # flexsurvreg: modelos paramétricos sem covariáveis
library(survminer)    # ggsurvplot, pairwise_survdiff
library(muhaz)         # taxa de risco suavizada por kernel
library(dplyr)
library(tidyr)
library(purrr)
library(ggplot2)
library(knitr)

theme_set(theme_minimal(base_size = 11))

# Formatação pt-BR
fmt <- function(x, d = 2) formatC(x, format = "f", digits = d, decimal.mark = ",",
  ↪ big.mark = ".")
fmt_n <- function(x) formatC(round(x), format = "d", big.mark = ".")
fmt_p <- function(p) ifelse(p < 0.001, "< 0,001", fmt(p, 3))
pct <- function(x, d = 1) paste0(fmt(100 * x, d), "%")
ic <- function(lo, hi, d = 3) paste0("[", fmt(lo, d), "; ", fmt(hi, d), "]")
tabela <- function(df, legenda, ...) kable(df, caption = legenda, booktabs = TRUE,
  ↪ position = "H", ...)

# Teste de log-rank em texto: qui-quadrado, gl e p
frase_lr <- function(t) {
  gl <- length(t$n) - 1
  p <- pchisq(t$chisq, gl, lower.tail = FALSE)
  sprintf("$\\chi^2$ = %s, gl = %d, p %s", fmt(t$chisq, 1), gl,
    if (p < 0.001) "< 0,001" else paste("=", fmt(p, 3)))
}

# Rótulos legíveis dos coeficientes
rotulos <- c(
  "estadioII" = "Estádio II (vs I)",
  "estadioIII" = "Estádio III (vs I)",
  "estadioIV" = "Estádio IV (vs I)",
  "idade10" = "Idade (+10 anos)",
  "sexoFeminino" = "Sexo feminino (vs masculino)",
  "categoriaConvênio" = "Convênio (vs SUS)",
  "categoriaParticular" = "Particular (vs SUS)",
  "localizacaoReto/junção" = "Reto/junção reto sigmoides (vs cólon)"
)
rotular <- function(x) unname(ifelse(x %in% names(rotulos), rotulos[x], x))
dados <- readRDS(params$arquivo_rds) |>
  filter(between(ANODIAG, params$ano_min, params$ano_max)) |>
  mutate(
    localizacao = factor(if_else(TOPOGRUP == "C18", "Cólon", "Reto/junção"),
      levels = c("Cólon", "Reto/junção")),

```

```

    faixa_idade = cut(IDADE, breaks = c(18, 50, 65, 75, Inf), right = FALSE,
                      labels = c("18-49", "50-64", "65-74", "75+")),
    idade10      = (IDADE - 60) / 10      # idade centrada em 60 anos, por década
  )

n_total <- nrow(dados)
n_obitos <- sum(dados$status)
n_cens <- n_total - n_obitos
t_max <- max(dados$tempo_anos)

# Seguimento mediano pelo KM reverso (Schemper & Smith, 1996)
km_rev <- survfit(Surv(tempo_anos, 1 - status) ~ 1, data = dados)
seg_med <- unname(summary(km_rev)$table["median"])

perda_cens <- mean(dados$PERDASEG[dados$status == 0] == "1", na.rm = TRUE)
funil <- if (file.exists(params$arquivo_funil)) readRDS(params$arquivo_funil) else NULL

if (!is.null(funil)) {
  funil |>
    bind_rows(tibble(etapa = sprintf("Diagnóstico entre %d e %d", params$ano_min,
    ↪ params$ano_max),
                      n = n_total)) |>
    mutate(`Excluídos` = c(NA, -diff(n)),
           n = fmt_n(n),
           `Excluídos` = ifelse(is.na(`Excluídos`), "", fmt_n(`Excluídos`))) |>
    rename(`Critério` = etapa, `n restante` = n) |>
    tabela("Fluxograma de seleção dos casos.")
}

tab_ev <- dados |>
  group_by(`Estádio` = as.character(estadio)) |>
  summarise(Pacientes = n(), `Óbitos` = sum(status), Censuras = sum(1 - status), .groups
    ↪ = "drop")

bind_rows(tab_ev, summarise(tab_ev, `Estádio` = "Total", across(where(is.numeric), sum)))
  ↪ |>
  mutate(`% óbitos` = pct(`Óbitos` / Pacientes),
         across(c(Pacientes, `Óbitos`, Censuras), fmt_n)) |>
  tabela("Número de pacientes, óbitos e censuras por estágio clínico.", align = "lrrrr")

desc_var <- function(v, rotulo) {
  dados |>
    group_by(`Nível` = .data[[v]]) |>
    summarise(n = n(), obitos = sum(status), .groups = "drop") |>
    mutate(`Variável` = rotulo,
           `Nível` = ifelse(is.na(`Nível`), "Sem informação", as.character(`Nível`)),
           `n (%)` = paste0(fmt_n(n), " (", pct(n / sum(n)), ")"),
           `Óbitos no grupo` = pct(obitos / n)) |>
    select(`Variável`, `Nível`, `n (%)`, `Óbitos no grupo`)
}

map2_dfr(c("sexo", "faixa_idade", "categoria", "localizacao", "estadio"),
         c("Sexo", "Faixa etária", "Categoria de atendimento", "Localização", "Estádio
    ↪ clínico"),
         desc_var) |>
  mutate(`Variável` = ifelse(duplicated(`Variável`), "", `Variável`)) |>

```

```

  tabela("Características da coorte e proporção de óbitos por categoria.", align =
    ↪ "llrr")
km_geral <- survfit(Surv(tempo_anos, status) ~ 1, data = dados)

ggsurvplot(km_geral, data = dados, conf.int = TRUE, censor = FALSE,
  risk.table = TRUE, break.time.by = 1, surv.median.line = "hv",
  xlab = "Anos desde o diagnóstico", ylab = "Probabilidade de sobrevida",
  legend = "none", ggtheme = theme_minimal(), risk.table.height = 0.22,
  risk.table.y.text = FALSE, tables.theme = theme_cleantable())
s_geral <- summary(km_geral, times = 1:floor(t_max))
med_geral <- unname(summary(km_geral)$table["median"])

tibble(`Tempo (anos)` = s_geral$time,
  `Em risco` = fmt_n(s_geral$n.risk),
  `S(t)` = fmt(s_geral$surv, 3),
  `IC 95%` = ic(s_geral$lower, s_geral$upper)) |>
  tabela("Sobrevida estimada por Kaplan-Meier em tempos selecionados.", align = "rrrrr")
km_est <- survfit(Surv(tempo_anos, status) ~ estadio, data = dados)

ggsurvplot(km_est, data = dados, conf.int = TRUE, censor = FALSE,
  risk.table = TRUE, break.time.by = 1, palette = "Dark2",
  legend.title = "Estádio", legend.labs = levels(dados$estadio),
  xlab = "Anos desde o diagnóstico", ylab = "Probabilidade de sobrevida",
  ggtheme = theme_minimal(), risk.table.height = 0.28,
  tables.theme = theme_cleantable())
lr_est <- survdiff(Surv(tempo_anos, status) ~ estadio, data = dados)
s_est <- summary(km_est, times = c(1, 3))
med_est <- summary(km_est)$table[, "median"]

tibble(`Estádio` = levels(dados$estadio),
  N = fmt_n(lr_est$n),
  `Óbitos obs.` = fmt_n(lr_est$obs),
  `Óbitos esp.` = fmt(lr_est$exp, 1),
  `O/E` = fmt(lr_est$obs / lr_est$exp, 2),
  `Mediana (anos)` = ifelse(is.na(med_est), "não atingida", fmt(med_est, 2))) |>
  tabela("Teste de log-rank por estágio: óbitos observados (O) e esperados (E) sob a
    ↪ hipótese de igualdade das curvas.",
    align = "lrrrrr")

tibble(`Estádio` = sub("estadio=", "", as.character(s_est$strata)),
  `Tempo (anos)` = s_est$time,
  `S(t)` = fmt(s_est$surv, 3),
  `IC 95%` = ic(s_est$lower, s_est$upper)) |>
  pivot_wider(names_from = `Tempo (anos)`, values_from = c(`S(t)`, `IC 95%`),
    names_glue = "{.value} em {`Tempo (anos)`} ano(s)", names_vary = "slowest")
    ↪ |>
  tabela("Sobrevida em 1 e 3 anos por estágio.")
pares <- pairwise_survdiff(Surv(tempo_anos, status) ~ estadio, data = dados,
  p.adjust.method = "holm")

pmat <- pares$p.value
pmat[] <- ifelse(is.na(pmat), "", fmt_p(pmat))
rownames(pmat) <- paste("Estádio", rownames(pmat))
colnames(pmat) <- paste("Estádio", colnames(pmat))
tabela(pmat, "Valores-p do log-rank par a par entre estádios (ajuste de Holm).")

```

```

vars_grupo <- c(sexo = "Sexo", categoria = "Categoria", localizacao = "Localização",
               faixa_idade = "Faixa etária")

km_sub <- imap(vars_grupo, \(rot, v)
  surv_fit(as.formula(paste("Surv(tempo_anos, status) ~", v)), data = dados))

graf_sub <- imap(km_sub, \(f, v)
  ggsurvplot(f, data = dados, censor = FALSE, conf.int = FALSE, palette = "Dark2",
             legend.title = vars_grupo[[v]], legend.labs = sub(".*=", "",
  ↪   names(f$strata)),
             xlab = "Anos", ylab = "S(t)", ggtheme = theme_minimal(base_size = 9)))

arrange_ggsurvplots(unname(graf_sub), ncol = 2, nrow = 2, print = TRUE)
c(estadio = "Estádio clínico", vars_grupo) |>
  imap_dfr(\(rot, v) {
    t <- survdiff(as.formula(paste("Surv(tempo_anos, status) ~", v)), data = dados)
    gl <- length(t$n) - 1
    tibble(Grupo = rot, `Qui-quadrado` = fmt(t$chisq, 1), gl = gl,
           p = fmt_p(pchisq(t$chisq, gl, lower.tail = FALSE)))
  }) |>
  tabela("Testes de log-rank por grupo.", align = "lrrr")
s3_grupo <- function(v) {
  s <- summary(km_sub[[v]], times = 3, extend = TRUE) # extend: grupo pequeno sem
  ↪   seguimento até 3 anos não some da saída
  setNames(s$surv, sub(".*=", "", as.character(s$strata)))
}
s3_sexo <- s3_grupo("sexo")
s3_cat <- s3_grupo("categoria")
s3_idade <- s3_grupo("faixa_idade")

iv_cat <- dados |>
  filter(!is.na(categoria)) |>
  group_by(categoria) |>
  summarise(p_iv = mean(estadio == "IV"), .groups = "drop")
iv_cat <- setNames(iv_cat$p_iv, as.character(iv_cat$categoria))
na_geral <- survfit(Surv(tempo_anos, status) ~ 1, data = dados, ctype = 1)
na_est <- survfit(Surv(tempo_anos, status) ~ estadio, data = dados, ctype = 1)

df_na <- tibble(tempo = na_geral$time, H = na_geral$cumhaz, se = na_geral$std.chaz) |>
  mutate(lo = pmax(H - 1.96 * se, 0), hi = H + 1.96 * se)

df_na_est <- tibble(tempo = na_est$time, H = na_est$cumhaz,
                   estadio = sub("estadio=", "", rep(names(na_est$strata),
  ↪   na_est$strata)))

g1 <- ggplot(df_na, aes(tempo, H)) +
  geom_ribbon(aes(ymin = lo, ymax = hi), fill = "grey80", stat = "identity") +
  geom_step() +
  labs(x = "Anos desde o diagnóstico", y = expression(hat(H)(t)), title = "Global")

g2 <- ggplot(df_na_est, aes(tempo, H, colour = estadio)) +
  geom_step() +
  scale_colour_brewer(palette = "Dark2") +
  labs(x = "Anos desde o diagnóstico", y = expression(hat(H)(t)), colour = "Estádio",

```

```

    title = "Por estádio")

gridExtra::grid.arrange(g1, g2, ncol = 2)
corte_max <- floor(quantile(dados$tempo_anos, 0.95))
cortes <- 0:corte_max

delta_H <- function(fit_time, fit_H) {
  H <- stepfun(fit_time, c(0, fit_H))
  dH <- diff(H(cortes))
  1 - exp(-dH)      # P(óbito no intervalo | vivo no início do intervalo)
}

tab_int <- tibble(Intervalo = paste0("[", head(cortes, -1), "; ", cortes[-1], ") anos"),
                  Global = delta_H(na_geral$time, na_geral$cumhaz))

for (e in levels(dados$estadio)) {
  sel <- df_na_est$estadio == e
  tab_int[[paste("Estádio", e)]] <- delta_H(df_na_est$time[sel], df_na_est$H[sel])
}

tab_int |>
  mutate(across(-Intervalo, \(x) pct(x))) |>
  tabela("Probabilidade condicional de óbito em cada intervalo anual, dado que o paciente
  ⇨ estava vivo no início do intervalo:  $1 - \exp\{-[\hat{H}(b) - \hat{H}(a)]\}$ .",
        escape = FALSE)

janela <- function(d) {
  n_min <- max(200, 0.10 * nrow(d))
  km <- survfit(Surv(tempo_anos, status) ~ 1, data = d)
  max(km$time[km$n.risk >= n_min])
}

estimar_h <- function(d) {
  m <- muhaz(d$tempo_anos, d$status, max.time = janela(d))
  tibble(tempo = m$est.grid, h = m$haz.est)
}

h_geral <- estimar_h(dados)
h_est <- map_dfr(levels(dados$estadio),
                 \(e) estimar_h(filter(dados, estadio == e)) |> mutate(estadio = e))

g1 <- ggplot(h_geral, aes(tempo, h)) + geom_line(linewidth = 0.9) +
  labs(x = "Anos desde o diagnóstico", y = "h(t) (óbitos por pessoa-ano)", title =
  ⇨ "Global")

g2 <- ggplot(h_est, aes(tempo, h, colour = estadio)) + geom_line(linewidth = 0.9) +
  scale_y_log10() + scale_colour_brewer(palette = "Dark2") +
  labs(x = "Anos desde o diagnóstico", y = "h(t) (escala log)", colour = "Estádio",
        title = "Por estádio")

gridExtra::grid.arrange(g1, g2, ncol = 2)
tempos_h <- c(0.25, 0.5, 1, 2, 3)
grupos_h <- c(list(Global = h_geral,
                  setNames(map(levels(dados$estadio), \(e) filter(h_est, estadio == e)),
                             paste("Estádio", levels(dados$estadio))))))

```

```

hz <- t(sapply(grupos_h, \ (df) approx(df$tempo, df$h, xout = tempos_h)$y)) # NA fora da
  ↪ janela
colnames(hz) <- sprintf("%g", tempos_h) # sprintf ignora OutDec = ","; colnames(hz) <-
  ↪ tempos_h geraria "0,25"
fim_janela <- sapply(grupos_h, \ (df) max(df$tempo))

tibble(Grupo = rownames(hz)) |>
  bind_cols(as_tibble(ifelse(is.na(hz), "-", fmt(hz, 3)), .name_repair = "minimal") |>
    setNames(paste0("h(", fmt(tempos_h, 2), ")"))) |>
  mutate(`Fim da janela (anos)` = fmt(fim_janela, 1)) |>
  tabela("Taxa de risco suavizada (óbitos por pessoa-ano) em tempos selecionados.")
obitos_30d <- sum(dados$status == 1 & dados$tempo_dias <= 30)
sobe_fim <- tail(h_geral$h, 1) > 1.25 * min(h_geral$h)
razao_lano <- hz["Estádio IV", "1"] / hz["Estádio I", "1"]
dists0 <- c("Exponencial" = "exp", "Weibull" = "weibull", "Log-normal" = "lnorm",
  "Log-logística" = "llogis", "Gama generalizada" = "gengamma")

fits0 <- map(dists0, \ (d) tryCatch(
  flexsurvreg(Surv(tempo_anos, status) ~ 1, data = dados, dist = d),
  error = \ (e) NULL)) |>
  compact()

crit0 <- imap_dfr(fits0, \ (f, nome) tibble(
  Modelo = nome, k = f$npars, logLik = f$loglik,
  AIC = -2 * f$loglik + 2 * f$npars,
  BIC = -2 * f$loglik + log(n_total) * f$npars)) |>
  arrange(AIC) |>
  mutate(`Dif. AIC` = AIC - min(AIC))

crit0 |>
  mutate(across(c(logLik, AIC, BIC, `Dif. AIC`), \ (x) fmt(x, 1))) |>
  tabela("Critérios de ajuste dos modelos paramétricos sem covariáveis (BIC com
  ↪ penalização log(n)). A gama generalizada entra como referência, pois engloba
  ↪ Weibull, log-normal e exponencial como casos particulares.",
  align = "lrrrrr")

melhor0 <- crit0 |> filter(Modelo != "Gama generalizada") |> slice_min(AIC, n = 1)
imap_dfr(fits0[names(fits0) != "Gama generalizada"], \ (f, nome)
  as_tibble(f$res, rownames = "Parâmetro") |>
    transmute(Modelo = nome, `Parâmetro`, Estimativa = fmt(est, 3), `IC 95%` = ic(`L95%`,
  ↪ `U95%`))) |>
  mutate(Modelo = ifelse(duplicated(Modelo), "", Modelo)) |>
  tabela("Estimativas dos parâmetros (parametrização do pacote flexsurv).", align =
  ↪ "llrr")

trv <- function(restrito, completo) {
  est <- 2 * (completo$loglik - restrito$loglik)
  gl <- completo$npars - restrito$npars
  tibble(TRV = fmt(est, 1), gl = gl, p = fmt_p(pchisq(est, gl, lower.tail = FALSE)))
}

testes <- list(
  "Exponencial vs Weibull (H0: forma = 1)" = c("Exponencial", "Weibull"),
  "Weibull vs Gama generalizada (H0: Q = 1)" = c("Weibull", "Gama generalizada"),

```

```

"Log-normal vs Gama generalizada (H0: Q = 0)" = c("Log-normal", "Gama generalizada")
)
testes <- keep(testes, \ (par) all(par %in% names(fits0)))

imap_dfr(testes, \ (par, nome) trv(fits0[[par[1]]], fits0[[par[2]]]) |> mutate(Tests =
  nome)) |>
  relocate(Tests) |>
  tabela("Testes da razão de verossimilhanças entre modelos encaixados.", align = "lrrr")
grade_t <- seq(0.01, t_max, length.out = 200)

curvas <- imap_dfr(fits0[c("Exponencial", "Weibull", "Log-normal", "Log-logística")],
  \ (f, nome) summary(f, t = grade_t, type = "survival", ci = FALSE, tidy
    = TRUE) |>
    mutate(Modelo = nome))

ggplot() +
  geom_step(data = tibble(time = c(0, km_geral$time), surv = c(1, km_geral$surv)),
    aes(time, surv), colour = "black", linewidth = 0.7) +
  geom_line(data = curvas, aes(time, est, colour = Modelo), linewidth = 0.8, linetype =
    "dashed") +
  scale_colour_brewer(palette = "Set1") +
  labs(x = "Anos desde o diagnóstico", y = "S(t)", colour = NULL) +
  theme(legend.position = "bottom")
km_df <- tibble(t = km_geral$time, S = km_geral$surv) |> filter(S > 0, S < 1, t > 0)

lin <- with(km_df, bind_rows(
  tibble(Modelo = "Exponencial: -log S(t) vs t", x = t, y = -log(S)),
  tibble(Modelo = "Weibull: log(-log S(t)) vs log t", x = log(t), y = log(-log(S))),
  tibble(Modelo = "Log-normal: qnorm(1 - S(t)) vs log t", x = log(t), y = qnorm(1 - S)),
  tibble(Modelo = "Log-logística: log[(1-S)/S] vs log t", x = log(t), y = log((1 - S) /
    S))
))

ggplot(lin, aes(x, y)) +
  geom_line(colour = "grey30") +
  geom_smooth(method = "lm", se = FALSE, colour = "firebrick", linetype = "dashed",
    linewidth = 0.6) +
  facet_wrap(~ Modelo, scales = "free") +
  labs(x = NULL, y = NULL)

nome_d <- function(x) ifelse(x == "Weibull", x, tolower(x)) # nome em texto corrido
quatro <- filter(crit0, Modelo != "Gama generalizada")
ordem_aic <- quatro$Modelo[order(quatro$AIC)]
melhor_aic0 <- ordem_aic[1]
melhor_bic0 <- quatro$Modelo[which.min(quatro$BIC)]
dif2_0 <- sort(quatro$AIC)[2] - min(quatro$AIC)
p_exp_weib <- pchisq(2 * (fits0[["Weibull"]]$loglik - fits0[["Exponencial"]]$loglik), 1,
  lower.tail = FALSE)
obitos_3d <- sum(dados$status == 1 & dados$tempo_dias <= 3)
graf_ok <- melhor_aic0 %in% c("Weibull", "Log-logística")

txt_crit0 <- if (melhor_aic0 == melhor_bic0) {
  paste0("AIC e BIC concordam e apontam a ", nome_d(melhor_aic0), ", com ", fmt(dif2_0,
    1),
    " pontos de AIC a menos que a segunda colocada (", nome_d(ordem_aic[2]), ").")
}

```

```

} else {
  paste0("O AIC aponta a ", nome_d(melhor_aic0), " e o BIC aponta a ",
    nome_d(melhor_bic0),
    "; a divergência vem da penalização maior do BIC por parâmetro.")
}

txt_graf <- if (graf_ok) {
  paste0("A escolha da ", nome_d(melhor_aic0), " pelo AIC é, portanto, coerente com os
    gráficos e com a forma do risco.")
} else {
  paste0("Há, portanto, uma divergência: o AIC aponta a ", nome_d(melhor_aic0),
    ", enquanto os gráficos e a forma do risco favorecem a Weibull e a
    log-logística. ",
    "Como o AIC pondera o ajuste em toda a distribuição e os gráficos destacam
    desvios nos extremos, ",
    "a decisão considera também os resíduos dos modelos com covariáveis (Seção
    4.2).")
}

vars_mod <- c("tempo_anos", "status", "estadio", "idade10", "sexo", "categoria",
  "localizacao")
dados_mod <- dados |> select(all_of(vars_mod)) |> drop_na()
n_mod <- nrow(dados_mod)
form <- Surv(tempo_anos, status) ~ estadio + idade10 + sexo + categoria +
  localizacao
dists_aft <- c("Exponencial" = "exponential", "Weibull" = "weibull",
  "Log-normal" = "lognormal", "Log-logística" = "loglogistic")

fits_aft <- map(dists_aft, \(d) survreg(form, data = dados_mod, dist = d))

crit_aft <- imap_dfr(fits_aft, \(f, nome) tibble(
  Modelo = nome, k = attr(logLik(f), "df"), logLik = as.numeric(logLik(f)),
  AIC = AIC(f), BIC = BIC(f), C = concordance(f)$concordance) |>
  arrange(AIC) |>
  mutate(`Dif. AIC` = AIC - min(AIC))

crit_aft |>
  mutate(across(c(logLik, AIC, BIC, `Dif. AIC`), \(x) fmt(x, 1)), C = fmt(C, 3)) |>
  tabela("Critérios de ajuste dos modelos AFT com covariáveis (C = índice de concordância
    de Harrell).",
    align = "lrrrrrr")

melhor_aft_nome <- crit_aft$Modelo[1]
melhor_aft <- fits_aft[[melhor_aft_nome]]
tab_razao <- function(f, rotulo_efeito) {
  b <- coef(f)
  ci <- confint(f)
  p <- summary(f)$table[names(b), "p"]
  tibble(Termo = rotular(names(b)), Efeito = fmt(exp(b), 3),
    `IC 95%` = ic(exp(ci[names(b), 1]), exp(ci[names(b), 2])), p = fmt_p(p)) |>
    filter(Termo != "(Intercept)") |>
    rename(!rotulo_efeito := Efeito)
}

tab_razao(melhor_aft, "Razão de tempos") |>

```

```

    tabela(sprintf("Modelo AFT %s: razões de tempos estimadas (escala estimada = %s).",
                  melhor_aft_nome, fmt(melhor_aft$scale, 3)), align = "lrrr")
cox_snell_df <- function(r, status) {
  km_r <- survfit(Surv(r, status) ~ 1)
  tibble(r = km_r$time, H = -log(km_r$surv)) |> filter(is.finite(H))
}

cs_aft <- imap_dfr(fits_aft, \(f, nome) {
  lp <- predict(f, type = "lp")
  S <- 1 - psurvreg(dados_mod$tempo_anos, mean = lp, scale = f$scale, distribution =
    ↪ f$dists)
  cox_snell_df(-log(S), dados_mod$status) |> mutate(Modelo = nome)
})

ggplot(cs_aft, aes(r, H)) +
  geom_step(colour = "steelblue") +
  geom_abline(slope = 1, intercept = 0, linetype = "dashed", colour = "firebrick") +
  facet_wrap(~ factor(Modelo, levels = names(dists_aft)), scales = "free") +
  labs(x = "Resíduo de Cox-Snell", y = "Risco acumulado estimado dos resíduos")
b_w <- coef(melhor_aft)
p_w <- summary(melhor_aft)$table[names(b_w), "p"]
tr_reto <- exp(b_w[["localizacaoReto/junção"]])
p_reto <- p_w[["localizacaoReto/junção"]]
n_part <- sum(dados_mod$categoria == "Particular")

perda_grupo <- function(g) mean(dados$PERDASEG[dados$categoria %in% g & dados$status ==
  ↪ 0] == "1", na.rm = TRUE)
perda_part <- perda_grupo("Particular")
perda_sus <- perda_grupo("SUS")
fit_cox <- coxph(form, data = dados_mod, ties = "efron")
s_cox <- summary(fit_cox)

tibble(Termo = rotular(rownames(s_cox$conf.int)),
       `Razão de riscos` = fmt(s_cox$conf.int[, "exp(coef)"], 3),
       `IC 95%` = ic(s_cox$conf.int[, "lower .95"], s_cox$conf.int[, "upper .95"]),
       p = fmt_p(s_cox$coefficients[, "Pr(>|z|)"]) |>
  tabela(sprintf("Modelo de Cox: razões de riscos (C de Harrell = %s).",
                fmt(s_cox$concordance[1, 3]), align = "lrrr")
zph <- cox.zph(fit_cox)

as_tibble(zph$table, rownames = "Termo") |>
  mutate(Termo = recode(Termo, estadio = "Estádio", idade10 = "Idade", sexo = "Sexo",
                        categoria = "Categoria", localizacao = "Localização", GLOBAL =
  ↪ "Global"),
         chisq = fmt(chisq, 2), p = fmt_p(p)) |>
  rename(`Qui-quadrado` = chisq, gl = df) |>
  tabela("Teste de proporcionalidade dos riscos baseado nos resíduos de Schoenfeld
  ↪ (Grambsch & Therneau, 1994).",
        align = "lrrr")

p_global <- zph$table["GLOBAL", "p"]
lista <- function(x, sep = "", n) if (length(x) <= n) x else paste(paste(head(x, -1),
  ↪ collapse = sep), "e", tail(x, 1))
txt_minus <- function(x) paste0(tolower(substr(x, 1, 1)), substring(x, 2))

```

```

# Magnitude do desvio: reta ajustada a cada curva beta(t), na escala de tempo do próprio
  teste,
# comparando a HR nos percentis 10 e 90 dos tempos de óbito
zph_coef <- cox.zph(fit_cox, terms = FALSE)
tq <- quantile(zph_coef$time, c(0.1, 0.9))
x_q <- approx(zph_coef$time, zph_coef$x, xout = tq, ties = mean)$y

var_tempo <- map_dfr(seq_along(coef(fit_cox)), \(j) {
  ab <- coef(lm(zph_coef$y[, j] ~ zph_coef$x))
  tibble(coef = names(coef(fit_cox))[j],
    hr_cox = exp(coef(fit_cox)[[j]]),
    hr_ini = exp(ab[[1]] + ab[[2]] * x_q[1]),
    hr_fim = exp(ab[[1]] + ab[[2]] * x_q[2]))
}) |>
  mutate(variacao = hr_fim / hr_ini - 1,
    relevante = abs(log(hr_fim / hr_ini)) > log(1.25)) # variação > 25% para mais
  # ou para menos

var_tempo |>
  transmute(Termo = rotular(coef), `HR (Cox)` = fmt(hr_cox, 2), `HR no início` =
    # fmt(hr_ini, 2),
    `HR no fim` = fmt(hr_fim, 2), `Variação` = pct(variacao),
    Relevante = ifelse(relevante, "sim", "não")) |>
  tabela(sprintf("Razão de riscos no início (percentil 10 dos tempos de óbito, %s anos) e
    # no fim do seguimento (percentil 90, %s anos), pela tendência linear dos
    # coeficientes no tempo. Relevante: razão entre a HR no fim e no início abaixo de 0,8
    # ou acima de 1,25.",
    fmt(tq[[1]], 2), fmt(tq[[2]], 2)), align = "lrrrrc")

rel <- filter(var_tempo, relevante)
reto <- filter(var_tempo, coef == "localizacaoReto/junção")

txt_ph <- if (nrow(rel) > 0) {
  paste0("Por esse critério, o desvio é relevante para ",
    lista(paste0(txt_minus(rotular(rel$coef)), ", cuja razão de riscos passa de ",
      fmt(rel$hr_ini, 2), " para ", fmt(rel$hr_fim, 2)), sep = "; "),
    ". Para ", if (nrow(rel) > 1) "esses termos" else "esse termo",
    ", uma razão de riscos única resume mal a relação, porque o efeito muda ao longo
    # do seguimento.",
    if (nrow(rel) < nrow(var_tempo)) " Para os demais, o desvio é estatisticamente
    # detectável, mas pequeno, e a suposição de riscos proporcionais é aceitável
    # na prática." else "")
} else {
  "Por esse critério, nenhuma razão de riscos varia de forma relevante, e a suposição de
  # riscos proporcionais é aceitável na prática, apesar dos valores-p."
}

txt_reto <- if ((reto$hr_ini - 1) * (reto$hr_fim - 1) < 0) {
  paste0("É o que a tabela mostra: a razão de riscos de reto/junção em relação ao cólon
    # passa de ",
    fmt(reto$hr_ini, 2), " no início para ", fmt(reto$hr_fim, 2),
    " no fim, ou seja, o efeito inverte de sentido ao longo do seguimento.")
} else {

```

```

paste0("Na tendência linear, a razão de riscos de reto/junção em relação ao cólon passa
  ↪ de ",
        fmt(reto$hr_ini, 2), " para ", fmt(reto$hr_fim, 2),
        ", sem inversão de sentido; a mudança pode não ser linear no tempo.")
}
zph_coef <- cox.zph(fit_cox, terms = FALSE) # uma curva por coeficiente (fatores
  ↪ desdobrados)
n_coef <- length(coef(fit_cox))
par(mfrow = c(ceiling(n_coef / 3), 3), mar = c(4, 4, 2, 1))
for (j in seq_len(n_coef)) {
  plot(zph_coef[j], resid = FALSE, se = TRUE, xlab = "Anos", main =
    ↪ rotular(names(coef(fit_cox))[j]),
        ylab = expression(hat(beta)(t)))
  abline(h = coef(fit_cox)[j], col = "firebrick", lty = 2)
}
tibble(t = km_est$time, S = km_est$surv,
        estadio = sub("estadio=", "", rep(names(km_est$strata), km_est$strata))) |>
  filter(S > 0, S < 1, t > 0) |>
  ggplot(aes(log(t), log(-log(S)), colour = estadio)) +
  geom_step() +
  scale_colour_brewer(palette = "Dark2") +
  labs(x = "log(tempo em anos)", y = "log(-log S(t))", colour = "Estádio")
fit_sem_idade <- update(fit_cox, . ~ . - idade10)
df_mart <- tibble(idade = dados_mod$idade10 * 10 + 60,
                  r = residuals(fit_sem_idade, type = "martingale"))

set.seed(42)
g1 <- ggplot(df_mart, aes(idade, r)) +
  geom_point(data = slice_sample(df_mart, n = min(4000, nrow(df_mart))), alpha = 0.08,
    ↪ size = 0.6) +
  geom_smooth(colour = "firebrick", se = TRUE) +
  labs(x = "Idade (anos)", y = "Residuo martingale", title = "Forma funcional da idade")

r_cs_cox <- dados_mod$status - residuals(fit_cox, type = "martingale")
g2 <- ggplot(cox_snell_df(r_cs_cox, dados_mod$status), aes(r, H)) +
  geom_step(colour = "steelblue") +
  geom_abline(slope = 1, intercept = 0, linetype = "dashed", colour = "firebrick") +
  labs(x = "Resíduo de Cox-Snell", y = "Risco acumulado", title = "Ajuste global (Cox)")

gridExtra::grid.arrange(g1, g2, ncol = 2)
fit_cox_estr <- coxph(Surv(tempo_anos, status) ~ strata(estadio) + idade10 + sexo +
  ↪ categoria + localizacao,
                    data = dados_mod, ties = "efron")

hr <- function(f) { s <- summary(f)$conf.int
  tibble(Termo = rownames(s), hr = paste0(fmt(s[, 1], 3), " ", ic(s[, 3], s[, 4]))) }

# HR implícita pela Weibull AFT: HR = exp(-beta / escala)
fw <- fits_aft[["Weibull"]]
hr_weib <- tibble(Termo = names(coef(fw))[-1], hr_w = fmt(exp(-coef(fw)[-1] / fw$scale),
  ↪ 3))

hr(fit_cox) |> rename(`Cox` = hr) |>
  left_join(hr(fit_cox_estr) |> rename(`Cox estratificado` = hr), by = "Termo") |>

```

```

left_join(hr_weib |> rename(`Weibull (HR implícita)` = hr_w), by = "Termo") |>
mutate(Termo = rotular(Termo),
       across(everything(), \(x) replace_na(x, "estrato"))) |>
tabela("Razões de riscos [IC 95%] no Cox, no Cox estratificado por estágio e implícitas
  ↳ no modelo Weibull.",
       align = "lrrr")

zph_estr <- cox.zph(fit_cox_estr)
fit_cox_ns <- coxph(Surv(tempo_anos, status) ~ estadio + splines::ns(idade10, df = 4) +
  ↳ sexo + categoria + localizacao,
              data = dados_mod, ties = "efron")
p_nl <- anova(fit_cox, fit_cox_ns)[["Pr(>|Chi|)"]][2]
daic_nl <- AIC(fit_cox) - AIC(fit_cox_ns)
p_nl_txt <- ifelse(p_nl < 0.001, "< 0,001", paste("=", fmt(p_nl, 3)))

txt_nl <- if (daic_nl > 10) {
  paste0("Substituir o termo linear por um spline natural com 4 graus de liberdade reduz
  ↳ o AIC em ", fmt(daic_nl, 1),
        " pontos (p ", p_nl_txt, "), o que confirma a não linearidade. O termo linear
  ↳ foi mantido para preservar a leitura de um efeito por década, mas ele
  ↳ subestima a diferença de risco entre os mais idosos e superestima a
  ↳ diferença entre os adultos jovens.")
} else if (daic_nl > 0) {
  paste0("Substituir o termo linear por um spline natural com 4 graus de liberdade reduz
  ↳ o AIC em apenas ", fmt(daic_nl, 1),
        " pontos (p ", p_nl_txt, "), então o termo linear é uma aproximação aceitável na
  ↳ faixa em que está a maior parte dos pacientes.")
} else {
  paste0("Ainda assim, substituir o termo linear por um spline natural com 4 graus de
  ↳ liberdade não melhora o AIC (p ", p_nl_txt,
        "), então o termo linear é uma aproximação aceitável.")
}
c_cox <- s_cox$concordance[1]

bind_rows(
  crit_aft |> transmute(Modelo = paste("AFT", Modelo), `Suposição` = "Tempo de falha
  ↳ acelerado",
                      logLik = fmt(logLik, 1), AIC = fmt(AIC, 1), BIC = fmt(BIC, 1), C
                      ↳ = fmt(C, 3)),
  tibble(Modelo = "Cox", `Suposição` = "Riscos proporcionais",
         logLik = paste(fmt(fit_cox$loglik[2], 1), "(parcial)"),
         AIC = "não comparável", BIC = "não comparável", C = fmt(c_cox, 3))
) |>
tabela("Comparação dos modelos de regressão. AIC e BIC só são comparáveis entre os
  ↳ modelos AFT, pois o Cox maximiza uma verossimilhança parcial; o índice C é
  ↳ comparável entre todos.",
       align = "llrrrr")
segundo_aft <- crit_aft$Modelo[2]
dif_aic <- crit_aft$`Dif. AIC`[2]
melhor_bic <- crit_aft$Modelo[which.min(crit_aft$BIC)]

```