

Redes Neurais e Deep Learning

REDES NEURAIS CONVOLUCIONAIS


LENET / ALEXNET / VGG

Zenilton K. G. Patrocínio Jr

zenilton@pucminas.br


ConvNets – LeNet

[LeCun et al., 1998]



ConvNets – LeNet


[LeCun et al., 1998]



- Filtros convolucionais 5×5 com passo 1

ConvNets – LeNet


[LeCun et al., 1998]



- Filtros convolucionais 5×5 com passo 1
- Camadas de agrupamento (“subsampling”) com filtros 2×2 e passo 2

ConvNets – LeNet

[LeCun et al., 1998]




- Filtros convolucionais 5×5 com passo 1
- Camadas de agrupamento (“subsampling”) com filtros 2×2 e passo 2
- Arquitetura → [CONV-POOL-CONV-POOL-FC-FC]

ConvNets – LeNet

Classificação de Dígitos Manuscritos

Características
extraídas pelo
filtros




Saída

Entrada

ConvNets – AlexNet


[Krizhevsky et al. 2012]



ConvNets – AlexNet


[Krizhevsky et al. 2012]

Entrada: imagem $227 \times 227 \times 3$



ConvNets – AlexNet

[Krizhevsky et al. 2012]




Entrada: imagem 227×227×3

Primeira camada (CONV1): 96 filtros 11×11 com passo 4

ConvNets – AlexNet

[Krizhevsky et al. 2012]




Entrada: imagem $227 \times 227 \times 3$

Primeira camada (CONV1): 96 filtros 11×11 com passo 4

P: Qual é o tamanho do volume de saída? Dica: $(227-11)/4+1 = 55$

ConvNets – AlexNet

[Krizhevsky et al. 2012]




Entrada: imagem 227×227×3

Primeira camada (CONV1): 96 filtros 11×11 com passo 4

Tamanho do volume de saída = **[55×55×96]**

ConvNets – AlexNet

[Krizhevsky et al. 2012]



Entrada: imagem 227×227×3


Primeira camada (CONV1): 96 filtros 11×11 com passo 4

Tamanho do volume de saída = **[55×55×96]**

P: Qual é o número total de parâmetros nessa camada?

ConvNets – AlexNet

[Krizhevsky et al. 2012]



Entrada: imagem 227×227×3

Primeira camada (CONV1): 96 filtros 11×11 com passo 4


Tamanho do volume de saída = **[55×55×96]**

Número de parâmetros = $(11 \times 11 \times 3 + 1) \times 96 \approx$ **35K**

ConvNets – AlexNet


[Krizhevsky et al. 2012]

Entrada: imagem $227 \times 227 \times 3$
Depois de CONV1: $55 \times 55 \times 96$



ConvNets – AlexNet

[Krizhevsky et al. 2012]




Entrada: imagem $227 \times 227 \times 3$

Depois de CONV1: $55 \times 55 \times 96$

Segunda camada (POOL1): 96 filtros 3×3 com passo 2

ConvNets – AlexNet

[Krizhevsky et al. 2012]



Entrada: imagem 227×227×3


Depois de CONV1: 55×55×96

Segunda camada (POOL1): 96 filtros 3×3 com passo 2

P: Qual é o tamanho do volume de saída? Dica: $(55-3)/2+1 = 27$

ConvNets – AlexNet

[Krizhevsky et al. 2012]



Entrada: imagem $227 \times 227 \times 3$


Depois de CONV1: $55 \times 55 \times 96$

Segunda camada (POOL1): 96 filtros 3×3 com passo 2

Tamanho do volume de saída = **$27 \times 27 \times 96$**

ConvNets – AlexNet

[Krizhevsky et al. 2012]



Entrada: imagem $227 \times 227 \times 3$

Depois de CONV1: $55 \times 55 \times 96$


Segunda camada (POOL1): 96 filtros 3×3 com passo 2

Tamanho do volume de saída = **$27 \times 27 \times 96$**

P: Qual é o número total de parâmetros nessa camada?

ConvNets – AlexNet

[Krizhevsky et al. 2012]



Entrada: imagem 227×227×3
Depois de CONV1: 55×55×96

Segunda camada (POOL1): 96 filtros 3×3 com passo 2

Tamanho do volume de saída = **[27×27×96]**


Número de parâmetros = **0 !**

ConvNets – AlexNet

[Krizhevsky et al. 2012]

Entrada: imagem $227 \times 227 \times 3$
Depois de CONV1: $55 \times 55 \times 96$
Depois de POOL1: $27 \times 27 \times 96$


⋮



ConvNets – AlexNet

[Krizhevsky et al. 2012]

Arquitetura da AlexNet:




- [227×227×3] Entrada
- [55×55×96] **CONV1**: 96 filtros 11×11 passo 4, pad 0
- [27×27×96] **MAX POOL1**: 96 filtros 3×3 passo 2
- [27×27×96] **NORM1**: camada de normalização
- [27×27×256] **CONV2**: 256 filtros 5×5 passo 1, pad 2
- [13×13×256] **MAX POOL2**: 256 filtros 3×3 passo 2
- [13×13×256] **NORM2**: camada de normalização
- [13×13×384] **CONV3**: 384 filtros 3×3 passo 1, pad 1
- [13×13×384] **CONV4**: 384 filtros 3×3 passo 1, pad 1
- [13×13×256] **CONV5**: 256 filtros 3×3 passo 1, pad 1
- [6×6×256] **MAX POOL3**: filtros 3×3 passo 2
- [4096] **FC6**: 4096 neurônios
- [4096] **FC7**: 4096 neurônios
- [1000] **FC8**: 1000 neurônios (“scores” de classe)

ConvNets – AlexNet

[Krizhevsky et al. 2012]

Arquitetura da AlexNet:



[227×227×3] Entrada
[55×55×96] **CONV1**: 96 filtros 11×11 passo 4, pad 0
[27×27×96] **MAX POOL1**: 96 filtros 3×3 passo 2
[27×27×96] **NORM1**: camada de normalização
[27×27×256] **CONV2**: 256 filtros 5×5 passo 1, pad 2
[13×13×256] **MAX POOL2**: 256 filtros 3×3 passo 2
[13×13×256] **NORM2**: camada de normalização
[13×13×384] **CONV3**: 384 filtros 3×3 passo 1, pad 1
[13×13×384] **CONV4**: 384 filtros 3×3 passo 1, pad 1
[13×13×256] **CONV5**: 256 filtros 3×3 passo 1, pad 1
[6×6×256] **MAX POOL3**: filtros 3×3 passo 2
[4096] **FC6**: 4096 neurônios
[4096] **FC7**: 4096 neurônios
[1000] **FC8**: 1000 neurônios (“scores” de classe)


Detalhes:

- Primeiro uso de ReLU

ConvNets – AlexNet

[Krizhevsky et al. 2012]

Arquitetura da AlexNet:



[227×227×3] Entrada
[55×55×96] **CONV1**: 96 filtros 11×11 passo 4, pad 0
[27×27×96] **MAX POOL1**: 96 filtros 3×3 passo 2
[27×27×96] **NORM1**: camada de normalização
[27×27×256] **CONV2**: 256 filtros 5×5 passo 1, pad 2
[13×13×256] **MAX POOL2**: 256 filtros 3×3 passo 2
[13×13×256] **NORM2**: camada de normalização
[13×13×384] **CONV3**: 384 filtros 3×3 passo 1, pad 1
[13×13×384] **CONV4**: 384 filtros 3×3 passo 1, pad 1
[13×13×256] **CONV5**: 256 filtros 3×3 passo 1, pad 1
[6×6×256] **MAX POOL3**: filtros 3×3 passo 2
[4096] **FC6**: 4096 neurônios
[4096] **FC7**: 4096 neurônios
[1000] **FC8**: 1000 neurônios (“scores” de classe)


Detalhes:

- Primeiro uso de ReLU
- Uso de camada de normalização (desuso)

ConvNets – AlexNet

[Krizhevsky et al. 2012]

Arquitetura da AlexNet:



[227×227×3] Entrada
[55×55×96] **CONV1**: 96 filtros 11×11 passo 4, pad 0
[27×27×96] **MAX POOL1**: 96 filtros 3×3 passo 2
[27×27×96] **NORM1**: camada de normalização
[27×27×256] **CONV2**: 256 filtros 5×5 passo 1, pad 2
[13×13×256] **MAX POOL2**: 256 filtros 3×3 passo 2
[13×13×256] **NORM2**: camada de normalização
[13×13×384] **CONV3**: 384 filtros 3×3 passo 1, pad 1
[13×13×384] **CONV4**: 384 filtros 3×3 passo 1, pad 1
[13×13×256] **CONV5**: 256 filtros 3×3 passo 1, pad 1
[6×6×256] **MAX POOL3**: filtros 3×3 passo 2
[4096] **FC6**: 4096 neurônios
[4096] **FC7**: 4096 neurônios
[1000] **FC8**: 1000 neurônios (“scores” de classe)


Detalhes:

- Primeiro uso de ReLU
- Uso de camada de normalização (desuso)
- Grande uso de “data augmentation”

ConvNets – AlexNet

[Krizhevsky et al. 2012]

Arquitetura da AlexNet:



[227×227×3] Entrada
[55×55×96] **CONV1**: 96 filtros 11×11 passo 4, pad 0
[27×27×96] **MAX POOL1**: 96 filtros 3×3 passo 2
[27×27×96] **NORM1**: camada de normalização
[27×27×256] **CONV2**: 256 filtros 5×5 passo 1, pad 2
[13×13×256] **MAX POOL2**: 256 filtros 3×3 passo 2
[13×13×256] **NORM2**: camada de normalização
[13×13×384] **CONV3**: 384 filtros 3×3 passo 1, pad 1
[13×13×384] **CONV4**: 384 filtros 3×3 passo 1, pad 1
[13×13×256] **CONV5**: 256 filtros 3×3 passo 1, pad 1
[6×6×256] **MAX POOL3**: filtros 3×3 passo 2
[4096] **FC6**: 4096 neurônios
[4096] **FC7**: 4096 neurônios
[1000] **FC8**: 1000 neurônios (“scores” de classe)


Detalhes:

- Primeiro uso de ReLU
- Uso de camada de normalização (desuso)
- Grande uso de “data augmentation”
- Tamanho de *minibatch* = 128

ConvNets – AlexNet

[Krizhevsky et al. 2012]

Arquitetura da AlexNet:



[227×227×3] Entrada
[55×55×96] **CONV1**: 96 filtros 11×11 passo 4, pad 0
[27×27×96] **MAX POOL1**: 96 filtros 3×3 passo 2
[27×27×96] **NORM1**: camada de normalização
[27×27×256] **CONV2**: 256 filtros 5×5 passo 1, pad 2
[13×13×256] **MAX POOL2**: 256 filtros 3×3 passo 2
[13×13×256] **NORM2**: camada de normalização
[13×13×384] **CONV3**: 384 filtros 3×3 passo 1, pad 1
[13×13×384] **CONV4**: 384 filtros 3×3 passo 1, pad 1
[13×13×256] **CONV5**: 256 filtros 3×3 passo 1, pad 1
[6×6×256] **MAX POOL3**: filtros 3×3 passo 2
[4096] **FC6**: 4096 neurônios
[4096] **FC7**: 4096 neurônios
[1000] **FC8**: 1000 neurônios (“scores” de classe)


Detalhes:

- Primeiro uso de ReLU
- Uso de camada de normalização (desuso)
- Grande uso de “data augmentation”
- Tamanho de *minibatch* = 128
- *SGD+Momentum* com constante de 0,9

ConvNets – AlexNet

[Krizhevsky et al. 2012]

Arquitetura da AlexNet:



[227×227×3] Entrada
[55×55×96] **CONV1**: 96 filtros 11×11 passo 4, pad 0
[27×27×96] **MAX POOL1**: 96 filtros 3×3 passo 2
[27×27×96] **NORM1**: camada de normalização
[27×27×256] **CONV2**: 256 filtros 5×5 passo 1, pad 2
[13×13×256] **MAX POOL2**: 256 filtros 3×3 passo 2
[13×13×256] **NORM2**: camada de normalização
[13×13×384] **CONV3**: 384 filtros 3×3 passo 1, pad 1
[13×13×384] **CONV4**: 384 filtros 3×3 passo 1, pad 1
[13×13×256] **CONV5**: 256 filtros 3×3 passo 1, pad 1
[6×6×256] **MAX POOL3**: filtros 3×3 passo 2
[4096] **FC6**: 4096 neurônios
[4096] **FC7**: 4096 neurônios
[1000] **FC8**: 1000 neurônios (“scores” de classe)


Detalhes:

- Primeiro uso de ReLU
- Uso de camada de normalização (desuso)
- Grande uso de “data augmentation”
- Tamanho de *minibatch* = 128
- SGD+*Momentum* com constante de 0,9
- Tx. Aprendizado = 10^{-2} e reduzida manualmente em “plateaus”

ConvNets – AlexNet

[Krizhevsky et al. 2012]

Arquitetura da AlexNet:



[227×227×3] Entrada
[55×55×96] **CONV1**: 96 filtros 11×11 passo 4, pad 0
[27×27×96] **MAX POOL1**: 96 filtros 3×3 passo 2
[27×27×96] **NORM1**: camada de normalização
[27×27×256] **CONV2**: 256 filtros 5×5 passo 1, pad 2
[13×13×256] **MAX POOL2**: 256 filtros 3×3 passo 2
[13×13×256] **NORM2**: camada de normalização
[13×13×384] **CONV3**: 384 filtros 3×3 passo 1, pad 1
[13×13×384] **CONV4**: 384 filtros 3×3 passo 1, pad 1
[13×13×256] **CONV5**: 256 filtros 3×3 passo 1, pad 1
[6×6×256] **MAX POOL3**: filtros 3×3 passo 2
[4096] **FC6**: 4096 neurônios
[4096] **FC7**: 4096 neurônios
[1000] **FC8**: 1000 neurônios (“scores” de classe)


Detalhes:

- Primeiro uso de ReLU
- Uso de camada de normalização (desuso)
- Grande uso de “data augmentation”
- Tamanho de *minibatch* = 128
- SGD+*Momentum* com constante de 0,9
- Tx. Aprendizado = 10^{-2} e reduzida manualmente em “plateaus”
- “Ensemble” de 7 CNNs: 18,2% → 15,4%


ConvNets – VGG

[Simonyan and Zisserman, 2014]

Uso de filtros menores em redes mais profundas



AlexNet



VGG16

VGG19

ConvNets – VGG

[Simonyan and Zisserman, 2014]

Uso de filtros menores em redes mais profundas




ConvNets – VGG

[Simonyan and Zisserman, 2014]

Uso de filtros menores em redes mais profundas

Apenas CONV 3×3 passo 1, pad 1
e
MAX POOL 2×2 passo 2





ConvNets – VGG

[Simonyan and Zisserman, 2014]

Uso de filtros menores em redes mais profundas

Apenas CONV 3×3 passo 1, pad 1
e
MAX POOL 2×2 passo 2

CONV3 × CONV7




ConvNets – VGG

[Simonyan and Zisserman, 2014]


Uso de filtros menores em redes mais profundas

Apenas CONV 3×3 passo 1, pad 1
e
MAX POOL 2×2 passo 2

CONV3 × CONV7



- Mesmo efeito / cobertura
- Maior profundidade $\Rightarrow$ mais não linearidade
- Menor número de parâmetros



ConvNets – VGG

[Simonyan and Zisserman, 2014]

Uso de filtros menores em redes mais profundas

Apenas CONV 3×3 passo 1, pad 1
e
MAX POOL 2×2 passo 2

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

Table 2: **Number of parameters** (in millions).

Network	A,A-LRN	B	C	D	E
Number of parameters	133	133	134	138	144

ConvNets – VGG

[Simonyan and Zisserman, 2014]

Uso de filtros menores em redes mais profundas

Apenas CONV 3×3 passo 1, pad 1
e
MAX POOL 2×2 passo 2

Melhor modelo

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

Table 2: Number of parameters (in millions).

Network	A,A-LRN	B	C	D	E
Number of parameters	133	133	134	138	144

ConvNets – VGG

[Simonyan and Zisserman, 2014]

Uso de filtros menores em redes mais profundas

Apenas CONV 3×3 passo 1, pad 1
e
MAX POOL 2×2 passo 2

Melhor modelo

Erro (top 5) = 11,2% - ILSVRC 2013



Erro (top 5) = 7,3%

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

Table 2: Number of parameters (in millions).

Network	A,A-LRN	B	C	D	E
Number of parameters	133	133	134	138	144

ConvNets – VGG

[Simonyan and Zisserman, 2014]

Uso de filtros menores em redes mais profundas

Apenas CONV 3×3 passo 1, pad 1
e
MAX POOL 2×2 passo 2

Melhor modelo

Erro (top 5) = 11,2% - ILSVRC 2013



Erro (top 5) = 7,3%

ConvNet Configuration					
A	A-LRN	B	C	D	E
11 weight layers	11 weight layers	13 weight layers	16 weight layers	16 weight layers	19 weight layers
input (224 × 224 RGB image)					
conv3-64	conv3-64 LRN	conv3-64	conv3-64 conv3-64	conv3-64 conv3-64	conv3-64 conv3-64
maxpool					
conv3-128	conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128	conv3-128 conv3-128
maxpool					
conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256	conv3-256 conv3-256 conv1-256	conv3-256 conv3-256 conv3-256	conv3-256 conv3-256 conv3-256 conv3-256
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512	conv3-512 conv3-512 conv1-512	conv3-512 conv3-512 conv3-512	conv3-512 conv3-512 conv3-512 conv3-512
maxpool					
FC-4096					
FC-4096					
FC-1000					
soft-max					

Table 2: Number of parameters (in millions)

Network	A,A-LRN	B	C	D	E
Number of parameters	133	133	134	138	144

138M

ConvNets – VGG

ENTRADA: [224x224x3] **memória:** $224*224*3=150K$ **params:** 0 (sem contar vieses)

CONV3-64: [224x224x64] **memória:** $224*224*64=3.2M$ **params:** $(3*3*3)*64 = 1.728$

CONV3-64: [224x224x64] **memória:** $224*224*64=3.2M$ **params:** $(3*3*64)*64 = 36.864$

POOL2: [112x112x64] **memória:** $112*112*64=800K$ **params:** 0

CONV3-128: [112x112x128] **memória:** $112*112*128=1.6M$ **params:** $(3*3*64)*128 = 73.728$

CONV3-128: [112x112x128] **memória:** $112*112*128=1.6M$ **params:** $(3*3*128)*128 = 147.456$

POOL2: [56x56x128] **memória:** $56*56*128=400K$ **params:** 0

CONV3-256: [56x56x256] **memória:** $56*56*256=800K$ **params:** $(3*3*128)*256 = 294.912$

CONV3-256: [56x56x256] **memória:** $56*56*256=800K$ **params:** $(3*3*256)*256 = 589.824$

CONV3-256: [56x56x256] **memória:** $56*56*256=800K$ **params:** $(3*3*256)*256 = 589.824$

POOL2: [28x28x256] **memória:** $28*28*256=200K$ **params:** 0

CONV3-512: [28x28x512] **memória:** $28*28*512=400K$ **params:** $(3*3*256)*512 = 1.179.648$

CONV3-512: [28x28x512] **memória:** $28*28*512=400K$ **params:** $(3*3*512)*512 = 2.359.296$

CONV3-512: [28x28x512] **memória:** $28*28*512=400K$ **params:** $(3*3*512)*512 = 2.359.296$

POOL2: [14x14x512] **memória:** $14*14*512=100K$ **params:** 0

CONV3-512: [14x14x512] **memória:** $14*14*512=100K$ **params:** $(3*3*512)*512 = 2.359.296$

CONV3-512: [14x14x512] **memória:** $14*14*512=100K$ **params:** $(3*3*512)*512 = 2.359.296$

CONV3-512: [14x14x512] **memória:** $14*14*512=100K$ **params:** $(3*3*512)*512 = 2.359.296$

POOL2: [7x7x512] **memória:** $7*7*512=25K$ **params:** 0

FC: [1x1x4096] **memória:** 4096 **params:** $7*7*512*4096 = 102.760.448$

FC: [1x1x4096] **memória:** 4096 **params:** $4096*4096 = 16.777.216$

FC: [1x1x1000] **memória:** 1000 **params:** $4096*1000 = 4.096.000$

[Simonyan and Zisserman, 2014]

ConvNet Configuration			
B	C	D	E
13 weight layers	16 weight layers	16 weight layers	19 weight layers
Input (224 × 224 RGB image)			
conv3-64	conv3-64	conv3-64	conv3-64
conv3-64	conv3-64	conv3-64	conv3-64
maxpool			
conv3-128	conv3-128	conv3-128	conv3-128
conv3-128	conv3-128	conv3-128	conv3-128
maxpool			
conv3-256	conv3-256	conv3-256	conv3-256
conv3-256	conv3-256	conv3-256	conv3-256
	conv1-256	conv3-256	conv3-256
maxpool			
conv3-512	conv3-512	conv3-512	conv3-512
conv3-512	conv3-512	conv3-512	conv3-512
	conv1-512	conv3-512	conv3-512
maxpool			
conv3-512	conv3-512	conv3-512	conv3-512
conv3-512	conv3-512	conv3-512	conv3-512
	conv1-512	conv3-512	conv3-512
maxpool			
FC-4096			
FC-4096			
FC-1000			
soft-max			

ConvNets – VGG

ENTRADA: [224x224x3] memória: $224*224*3=150K$ params: 0 (sem contar vieses)
CONV3-64: [224x224x64] memória: $224*224*64=3.2M$ params: $(3*3*3)*64 = 1.728$
CONV3-64: [224x224x64] memória: $224*224*64=3.2M$ params: $(3*3*64)*64 = 36.864$
POOL2: [112x112x64] memória: $112*112*64=800K$ params: 0
CONV3-128: [112x112x128] memória: $112*112*128=1.6M$ params: $(3*3*64)*128 = 73.728$
CONV3-128: [112x112x128] memória: $112*112*128=1.6M$ params: $(3*3*128)*128 = 147.456$
POOL2: [56x56x128] memória: $56*56*128=400K$ params: 0
CONV3-256: [56x56x256] memória: $56*56*256=800K$ params: $(3*3*128)*256 = 294.912$
CONV3-256: [56x56x256] memória: $56*56*256=800K$ params: $(3*3*256)*256 = 589.824$
CONV3-256: [56x56x256] memória: $56*56*256=800K$ params: $(3*3*256)*256 = 589.824$
POOL2: [28x28x256] memória: $28*28*256=200K$ params: 0
CONV3-512: [28x28x512] memória: $28*28*512=400K$ params: $(3*3*256)*512 = 1.179.648$
CONV3-512: [28x28x512] memória: $28*28*512=400K$ params: $(3*3*512)*512 = 2.359.296$
CONV3-512: [28x28x512] memória: $28*28*512=400K$ params: $(3*3*512)*512 = 2.359.296$
POOL2: [14x14x512] memória: $14*14*512=100K$ params: 0
CONV3-512: [14x14x512] memória: $14*14*512=100K$ params: $(3*3*512)*512 = 2.359.296$
CONV3-512: [14x14x512] memória: $14*14*512=100K$ params: $(3*3*512)*512 = 2.359.296$
CONV3-512: [14x14x512] memória: $14*14*512=100K$ params: $(3*3*512)*512 = 2.359.296$
POOL2: [7x7x512] memória: $7*7*512=25K$ params: 0
FC: [1x1x4096] memória: 4096 params: $7*7*512*4096 = 102.760.448$
FC: [1x1x4096] memória: 4096 params: $4096*4096 = 16.777.216$
FC: [1x1x1000] memória: 1000 params: $4096*1000 = 4.096.000$

TOTAL memória: $24M * 4 \text{ bytes} \approx 93MB$ / imagem (apenas *forward* ! ~ $\times 2$ para *backward*)
TOTAL params: 138M parâmetros

[Simonyan and Zisserman, 2014]

ConvNet Configuration			
B	C	D	E
13 weight layers	16 weight layers	16 weight layers	19 weight layers
Input (224 × 224 RGB image)			
conv3-64	conv3-64	conv3-64	conv3-64
conv3-64	conv3-64	conv3-64	conv3-64
maxpool			
conv3-128	conv3-128	conv3-128	conv3-128
conv3-128	conv3-128	conv3-128	conv3-128
maxpool			
conv3-256	conv3-256	conv3-256	conv3-256
conv3-256	conv3-256	conv3-256	conv3-256
maxpool			
conv3-512	conv3-512	conv3-512	conv3-512
conv3-512	conv3-512	conv3-512	conv3-512
maxpool			
conv3-512	conv3-512	conv3-512	conv3-512
conv3-512	conv3-512	conv3-512	conv3-512
maxpool			
FC-4096			
FC-4096			
FC-1000			
soft-max			

ConvNets – VGG

[Simonyan and Zisserman, 2014]

ENTRADA: [224x224x3] memória: $224*224*3=150K$ params: 0 (sem contar vieses)
CONV3-64: [224x224x64] memória: $224*224*64=3.2M$ params: $(3*3*3)*64 = 1.728$
CONV3-64: [224x224x64] memória: $224*224*64=3.2M$ params: $(3*3*64)*64 = 36.864$
POOL2: [112x112x64] memória: $112*112*64=800K$ params: 0
CONV3-128: [112x112x128] memória: $112*112*128=1.6M$ params: $(3*3*64)*128 = 73.728$
CONV3-128: [112x112x128] memória: $112*112*128=1.6M$ params: $(3*3*128)*128 = 147.456$
POOL2: [56x56x128] memória: $56*56*128=400K$ params: 0
CONV3-256: [56x56x256] memória: $56*56*256=800K$ params: $(3*3*128)*256 = 294.912$
CONV3-256: [56x56x256] memória: $56*56*256=800K$ params: $(3*3*256)*256 = 589.824$
CONV3-256: [56x56x256] memória: $56*56*256=800K$ params: $(3*3*256)*256 = 589.824$
POOL2: [28x28x256] memória: $28*28*256=200K$ params: 0
CONV3-512: [28x28x512] memória: $28*28*512=400K$ params: $(3*3*256)*512 = 1.179.648$
CONV3-512: [28x28x512] memória: $28*28*512=400K$ params: $(3*3*512)*512 = 2.359.296$
CONV3-512: [28x28x512] memória: $28*28*512=400K$ params: $(3*3*512)*512 = 2.359.296$
POOL2: [14x14x512] memória: $14*14*512=100K$ params: 0
CONV3-512: [14x14x512] memória: $14*14*512=100K$ params: $(3*3*512)*512 = 2.359.296$
CONV3-512: [14x14x512] memória: $14*14*512=100K$ params: $(3*3*512)*512 = 2.359.296$
CONV3-512: [14x14x512] memória: $14*14*512=100K$ params: $(3*3*512)*512 = 2.359.296$
POOL2: [7x7x512] memória: $7*7*512=25K$ params: 0
FC: [1x1x4096] memória: 4096 params: $7*7*512*4096 = 102.760.448$
FC: [1x1x4096] memória: 4096 params: $4096*4096 = 16.777.216$
FC: [1x1x1000] memória: 1000 params: $4096*1000 = 4.096.000$

OBS:

Maior parte da memória está nas camadas CONV iniciais

Maioria dos params estão nas camadas FC finais

TOTAL memória: $24M * 4 \text{ bytes} \approx 93MB$ / imagem (apenas *forward* ! ~ $\times 2$ para *backward*)
TOTAL params: 138M parâmetros