



PUC Minas

Frameworks de Deep Learning

Renan Santos Mendes




PUC Minas

Introdução

Large Language Model

Introducing Llama 3.1: Our most capable to date

July 23, 2024 · 15 min



Mamba: A shallow dive into a new architecture for LLMs

July 18, 2024

GPT-4o mini: advancing cost-efficient intelligence

Introducing our most cost-efficient small model

Google DeepMind's new AI systems can now solve complex math problems

AlphaProof and AlphaGeometry 2 are steps toward building systems that can reason, which could unlock exciting new capabilities.

By Rhiannon Williams

July 25, 2024



Corretores de imóveis nos EUA: Não imaginamos como trabalhar sem o ChatGPT agora

Bard é nova plataforma de IA do Google para rivalizar com ChatGPT

© 28/01/2023



PUC Minas

Introdução ao uso de Frameworks

Introdução ao uso de Frameworks

- Frameworks de deep learning **são bibliotecas de software para criação, treinamento e implantação de modelos** de redes neurais profundas em tarefas de aprendizado de máquina.
- Eles fornecem uma interface para definir, configurar e treinar modelos de deep learning, bem como realizar outras tarefas comuns.


Introdução ao uso de Frameworks

- Os frameworks **oferecem implementações eficientes** de algoritmos de backpropagation e outras técnicas de otimização, o que ajuda a acelerar o processo de treinamento.
- Alguns exemplos de frameworks de deep learning populares incluem TensorFlow, PyTorch, Keras, Caffe, Theano, MXNet, entre outros.

Introdução ao uso de Frameworks

- Cada framework tem suas próprias características, pontos fortes e fracos, mas todos eles compartilham o objetivo comum de **tornar mais fácil e acessível a criação de modelos de deep learning** poderosos e eficientes.
- Diversas aplicações, como **visão computacional, NLP, speech**, entre outras áreas de **inteligência artificial**.
- Permitem que pesquisadores e engenheiros criem modelos de deep learning mais **rapidamente** e com **menos esforço**.

Introdução ao uso de Frameworks



Introdução ao uso de Frameworks





PUC Minas

Redes Neurais Artificiais


Renan Santos Mendes



PUC Minas

Neurônio Artificial

Neurônio Artificial



Entradas Pesos

*Silva, N., et al. (2009). Detecção de intrusões baseada em user profiling e redes neurais.
Adaptado por Renan Santos Mendes, 2024.*

Neurônio Artificial

Elementos básicos do neurônio artificial:


- **Conjunto de sinapses** em que cada uma é caracterizada por um peso (ou força) entre os neurônios com valores podendo ser positivos ou negativos;
- **Somador** para agregar os sinais que chegam ao neurônio, ponderados pelos respectivos pesos (combinação linear);
- **Função de ativação** que limita a amplitude da saída de um neurônio.



PUC Minas

Rede Neural Artificial

Rede Neural Artificial



IVANOV, V. A. et al. A neural-network-based competition between short-lived particle candidates in the CBM experiment at FAIR. *Journal of Physics: Conference Series*, v. 1690, n. 1, p. 012090, 2020. Adaptado por Renan Santos Mendes, 2024.




PUC Minas

Nomenclatura

Nomenclatura


- **Camada de entrada:** camada pela qual os dados entram na rede;
- **Camada oculta:** uma ou mais camadas intermediárias;
- **Camada de saída:** camada por onde o processamento feito pela rede é obtido;
- **Conexões:** ligações entre os neurônios (pesos da rede).

Nomenclatura




IVANOV, V. A. et al. A neural-network-based competition between short-lived particle candidates in the CBM experiment at FAIR. Journal of Physics: Conference Series, v. 1690, n. 1, p. 012090, 2020. Adaptado por Renan Santos Mendes, 2024.

Nomenclatura




IVANOV, V. A. et al. A neural-network-based competition between short-lived particle candidates in the CBM experiment at FAIR. Journal of Physics: Conference Series, v. 1690, n. 1, p. 012090, 2020. Adaptado por Renan Santos Mendes, 2024.

Nomenclatura




IVANOV, V. A. et al. A neural-network-based competition between short-lived particle candidates in the CBM experiment at FAIR. *Journal of Physics: Conference Series*, v. 1690, n. 1, p. 012090, 2020. Adaptado por Renan Santos Mendes, 2024.

Nomenclatura




IVANOV, V. A. et al. A neural-network-based competition between short-lived particle candidates in the CBM experiment at FAIR. *Journal of Physics: Conference Series*, v. 1690, n. 1, p. 012090, 2020. Adaptado por Renan Santos Mendes, 2024.

Nomenclatura



IVANOV, V. A. et al. A neural-network-based competition between short-lived particle candidates in the CBM experiment at FAIR. *Journal of Physics: Conference Series*, v. 1690, n. 1, p. 012090, 2020. Adaptado por Renan Santos Mendes, 2024.

Nomenclatura



IVANOV, V. A. et al. A neural-network-based competition between short-lived particle candidates in the CBM experiment at FAIR. *Journal of Physics: Conference Series*, v. 1690, n. 1, p. 012090, 2020. Adaptado por Renan Santos Mendes, 2024.



PUC Minas



PUC Minas

Construção de Modelos

Renan Santos Mendes



PUC Minas

Fluxo Geral da Construção de Modelos

Fluxo Geral da Construção de Modelos

A construção de modelos em frameworks segue etapas comuns. Essas etapas incluem:

- Definição do modelo (arquitetura da rede).
- Configuração do otimizador e da função de perda.
- Treinamento e avaliação do modelo.



PUC Minas

Definição do Modelo

Definição do Modelo

- O modelo é construído adicionando **camadas**, que são os blocos fundamentais das redes neurais.
- Cada camada realiza transformações nos dados.
- Operações como multiplicações matriciais.
- Aplicação de funções de ativação (ReLU, Sigmoid, etc.)



PUC Minas

Otimizador e Função de Perda

Otimizador e Função de Perda

Otimizador:

- Atualiza os pesos da rede durante o treinamento.
- Exemplo: **Adam, SGD.**

Função de Perda:

- Mede o erro entre a previsão e o valor esperado.
- Exemplo:
 - **Cross-Entropy Loss** para classificação.
 - **Mean Squared Error (MSE)** para regressão.



PUC Minas

Treinamento do Modelo

Treinamento do Modelo

Forward Pass:

- Os dados de entrada são passados pela rede para gerar previsões.

Cálculo da Perda:

- O erro é calculado usando a função de perda.

Backpropagation:

- Os gradientes são calculados para atualizar os pesos.

Atualização dos Pesos:

- O otimizador ajusta os pesos para minimizar o erro.



PUC Minas

Avaliação e Ajustes

Avaliação e Ajustes

Avaliação:

- O modelo é avaliado em dados de validação ou teste.
- Métricas comuns incluem **acurácia**, **precisão** e **erro médio**.

Ajustes Finais:

- Modificar a arquitetura da rede.
- Ajustar hiperparâmetros como taxa de aprendizado ou número de camadas.



PUC Minas