




Principais Arquiteturas



Modelos Generativos Pré-Treinados

Modelos Generativos Pré Treinados

- **Treinamento Inicial:**

- Modelos são treinados em grandes quantidades de texto da internet.
- Aprendem padrões na linguagem, gramática, fatos sobre o mundo, e um pouco de raciocínio comum.

- **Arquitetura do Modelo:**

- Utilizam a arquitetura chamada Transformer.
- Transformers são eficientes em lidar com contextos longos.
- Usam mecanismos de atenção para **focar em partes específicas** do texto de entrada enquanto geram saídas.


Introdução ao Transformer

Modelos Generativos Pré Treinados

- Revolução em NLP e Deep Learning (2017 – artigo [*Attention is All You Need*](#))
- Base de modelos modernos como BERT, GPT, T5 e LLaMA
- **Elimina a dependência** de estruturas sequenciais (RNNs e LSTMs)
- RNNs e LSTMs: processam tokens em sequência → lentidão e dificuldade em capturar dependências longas
- CNNs: paralelismo melhor, mas dificuldade em lidar com contexto global
- **Transformer:** capta dependências de longo alcance via *mecanismo de atenção* + alta paralelização

Arquitetura do Transformer

Modelos Generativos Pré Treinados



VASWANI, Ashish et al (2017). *Attention is all you need*. In: *Advances in Neural Information Processing Systems*. [s. l.], 2017. p. 5998-6008

Modelos Generativos Pré Treinados

Embeddings

- Representação vetorial dos tokens (palavras/subpalavras).
- Inclui **positional encoding** para indicar ordem na sequência.

Mecanismo de Atenção

- **Self-Attention**: cada token interage com todos os outros.
- **Scaled Dot-Product Attention**: cálculo central usando *queries*, *keys* e *values*.
- **Multi-Head Attention**: múltiplas cabeças para capturar diferentes relações.

Camada Feed-Forward

- Rede totalmente conectada aplicada a cada posição.
- Enriquece e transforma as representações.

Modelos Generativos Pré Treinados

Normalização e Regularização

- **Residual connections:** facilitam o treinamento de redes profundas.
- **Layer Normalization:** estabiliza o aprendizado.
- **Dropout:** evita overfitting.

Arquitetura Encoder–Decoder

- **Encoder:** gera representações da entrada.
- **Decoder:** usa masked self-attention + atenção ao encoder para gerar saídas.

Saída

- Camada linear + softmax para gerar probabilidades sobre o vocabulário.




PUC Minas

© **PUC Minas** • Todos os direitos reservados, de acordo com o art. 184 do Código Penal e com a lei 9.610 de 19 de fevereiro de 1998.

Proibidas a reprodução, a distribuição, a difusão, a execução pública, a locação e quaisquer outras modalidades de utilização sem a devida autorização da Pontifícia Universidade Católica de Minas Gerais.




Detalhes do Transformer




Alguns pontos para detalhar

Modelos Generativos Pré Treinados

Scaled Dot-Product



Multi-Head Attention



VASWANI, Ashish et al (2017). *Attention is all you need*. In: *Advances in Neural Information Processing Systems*. [s. l.], 2017. p. 5998-6008

Mecanismo de Atenção

Modelos Generativos Pré Treinados

- **Mecanismo de Auto-Atenção:**

- Algebricamente, os mecanismos de auto-atenção são calculados da seguinte forma

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

$$\text{where head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

Funcionamento e Uso

Modelos Generativos Pré Treinados

- **Predição de Próximas Palavras:**

- Prever a próxima palavra com base nas palavras anteriores.
- Utiliza informações aprendidas durante o treinamento para fazer as previsões.

- **Ajuste Fino (*Fine-Tuning*):**

- Após o treinamento inicial, os modelos podem ser ajustados com dados específicos de domínio.
- Melhora o desempenho em tarefas específicas, como atendimento ao cliente, redação de artigos, etc.

Modelos Generativos Pré Treinados

- **Geração de Conteúdo:**

- Quando uma pergunta ou instrução é dada, o modelo gera uma resposta ao prever a sequência de palavras mais provável.
- Respostas são baseadas em tudo que o modelo aprendeu durante o treinamento.

- Modelos não entendem o texto da mesma forma que os humanos.
- Conseguem gerar respostas coerentes e contextualmente relevantes.




PUC Minas

© **PUC Minas** • Todos os direitos reservados, de acordo com o art. 184 do Código Penal e com a lei 9.610 de 19 de fevereiro de 1998.

Proibidas a reprodução, a distribuição, a difusão, a execução pública, a locação e quaisquer outras modalidades de utilização sem a devida autorização da Pontifícia Universidade Católica de Minas Gerais.



Principais Arquiteturas do Transformer



Divisões da Arquitetura

Principais Arquiteturas do Transformer


Algumas aplicações do Transformer

- **Encoder-Decoder:** T5, mT5, ByT5
- **Encoder Only:** BERT, RoBERTa, DistilBERT, ModernBERT
- **Decoder Only:** Família GPT
 - GPT-5.2
 - GPT-5 Mini
 - o3-mini
 - o4-mini
 - GPT-4o Mini
 - GPT-4.1
 - GPT-4.5

Encoder-Decoder

Principais Arquiteturas: Encoder-Decoder

Usa-se ambos os
lados do Transformer



VASWANI, Ashish et al (2017). *Attention is all you need*. In: *Advances in Neural Information Processing Systems*. [s. l.], 2017. p. 5998-6008

Arquitetura: Encoder-Decoder

Ideia central

- Modelo **Sequence** → **Sequence**
- Um bloco **entende** a entrada e outro **gera** a saída

Estrutura

- **Encoder**: processa todo o input de uma vez
- **Decoder**: gera a saída **token a token**
- Conectados via **Cross-Attention**

Arquitetura: Encoder-Decoder

Quando usar

- Tradução automática
- Resumo de texto
- Pergunta → resposta baseada em contexto
- Qualquer tarefa de **transformação de sequência**

Ponto forte: excelente quando **entrada e saída são diferentes**, mas relacionadas

Encoder Only

Arquitetura: Encoder Only

Ideia central

- Aprender **representações contextuais bidirecionais** do texto
- Usar **self-attention** para capturar dependências de curto e longo alcance
- Foco em **entendimento de linguagem**, não em geração
- Produzir **embeddings ricos** para tokens ou para a sequência inteira

Estrutura

- Pilha de **N camadas de encoder** idênticas.


Arquitetura: Encoder Only

Quando usar

- Tarefas de **NLP discriminativas / de entendimento**:
 - Classificação de texto
 - Análise de sentimentos
 - NER, POS tagging
 - Similaridade semântica / embeddings
 - Busca semântica e RAG (encoder para indexação)
- Quando **não é necessário gerar texto**, apenas interpretar
- Cenários que exigem **embeddings de alta qualidade** e processamento eficiente em paralelo

Principais Arquiteturas: Encoder Only

Usa-se apenas os
Encoders do
Transformer



Decoder Only

Arquitetura: Decoder Only

Ideia central

- Modelar linguagem de forma auto-regressiva: prever o próximo token dado o contexto anterior.
- Usar self-attention causal (mascarada) para garantir que cada token só “veja” o passado.
- Foco em **geração de texto** e **modelagem de sequência**.
- Aprender um modelo geral de linguagem capaz de gerar, completar ou continuar conteúdo.

Estrutura


- Pilha de **N camadas de decoder** sem o bloco de cross-attention.

Arquitetura: Decoder Only

Quando usar

- Tarefas de geração de linguagem:
 - Chatbots e assistentes.
 - Geração de texto (artigos, resumos, e-mails).
 - Completação de código ou texto.
 - Tradução, reescrita, QA generativo.
- Cenários que exigem modelagem **generativa geral** (LLMs).
- Quando a tarefa pode ser formulada como **predição do próximo token** (prompt → continuação).

Principais Arquiteturas: Decoder Only



VASWANI, Ashish et al (2017). *Attention is all you need*. In: *Advances in Neural Information Processing Systems*. [s. l.], 2017. p. 5998-6008




PUC Minas

© **PUC Minas** • Todos os direitos reservados, de acordo com o art. 184 do Código Penal e com a lei 9.610 de 19 de fevereiro de 1998.

Proibidas a reprodução, a distribuição, a difusão, a execução pública, a locação e quaisquer outras modalidades de utilização sem a devida autorização da Pontifícia Universidade Católica de Minas Gerais.



Modelos Generativos Pré-Treinados




Funcionamento dos Modelos Generativos Pré-Treinados

Modelos Generativos Pré Treinados



Stollnitz, B. (2023). *How GPT models work: Accessible to everyone*. [Link](#)

Modelos Generativos Pré Treinados



Stollnitz, B. (2023). *How GPT models work: Accessible to everyone.* [Link](#)

Modelos Generativos Pré Treinados

in out

We need to stop

We need to stop anthrop

We need to stop anthropomorph

We need to stop anthropomorphizing

We need to stop anthropomorphizing Chat

We need to stop anthropomorphizing ChatG

We need to stop anthropomorphizing ChatGPT

We need to stop anthropomorphizing ChatGPT.

Stollnitz, B. (2023). *How GPT models work: Accessible to everyone.* [Link](#)

Large Language Models (LLMs)

Large Language Models

- Modelos de linguagem baseados em Transformer (Decoder-only) com bilhões de parâmetros
- Treinados em corpora massivos e diversificados de texto
- Aprendem uma distribuição sobre sequências de tokens: $P(\text{token}_t \mid \text{token}_1, \dots, \text{token}_{t-1})$
- "Large" não é apenas tamanho — é escala que provoca comportamentos emergentes
- Exemplos: GPT-4, Llama 3, Gemini, Claude, Mistral


Importante:

- A diferença de um LM tradicional para um LLM não é só quantitativa
- A escala muda qualitativamente o que o modelo consegue fazer

Large Language Models


DeepSeek V3 (671B)

More, smaller experts



Llama 4 Maverick (400B)

Fewer, bigger experts



Raschka, S. (2025, July 19). *The big LLM architecture comparison: From DeepSeek-V3 to Kimi K2: A look at modern LLM architecture design*. Ahead of AI. [Link](#)



PUC Minas

© **PUC Minas** • Todos os direitos reservados, de acordo com o art. 184 do Código Penal e com a lei 9.610 de 19 de fevereiro de 1998.

Proibidas a reprodução, a distribuição, a difusão, a execução pública, a locação e quaisquer outras modalidades de utilização sem a devida autorização da Pontifícia Universidade Católica de Minas Gerais.