

03_fine_tuning_indie

September 29, 2026

1 Fine-tuning do Qwen3-4B para a Indie com Unsloth (QLoRA)

Projeto final: Generative AI & Advanced Analytics

Este notebook treina o assistente virtual da **Indie**, fintech fictícia para quem trabalha por conta própria, a partir da base de perguntas e respostas gerada no notebook `02_geracao_base_qna.ipynb`. A técnica é **PEFT com QLoRA**: o Qwen3-4B é carregado em 4 bits e congelado, e apenas adaptadores LoRA de baixo rank são treinados. Isso cabe numa GPU T4 do Colab.

O pipeline segue o notebook de aula `fine_tuning_qwen3_aula.ipynb`, com as mesmas funções auxiliares e a mesma sequência de etapas. As principais adaptações foram:

Item	Aula (SynapseAI)	Este projeto (Indie)	Motivo
Dataset	<code>synapseai_knowledge_base</code>	<code>indie_knowledge_base</code>	Base própria da empresa
Prompt de sistema	Definido no código	Lido do próprio dataset	Garante que treino e inferência usem exatamente o mesmo prompt
MAX_SEQ_LENGTH	2048	1024	Os exemplos têm menos de 700 tokens (verificado na seção 1.6); menos memória
Épocas	1	3	Base pequena (~500 exemplos de treino): uma época dá só ~60 passos, pouco para fixar preços e prazos
Melhor checkpoint	—	<code>load_best_model_at_end</code>	Protege contra overfitting nas épocas finais
Avaliação qualitativa	2 perguntas após o treino	10 perguntas antes e depois do treino	Mostra o que o modelo aprendeu sobre o domínio

Item	Aula (SynapseAI)	Este projeto (Indie)	Motivo
Publicação	<code>push_to_hub</code> do modelo e do dataset formatado	Adaptadores e model card; dataset <code>.jsonl</code> e dataset card em um repositório separado	Atende ao item 2.4 do enunciado

Organização: a Parte 1 cobre o treinamento e a publicação. A Parte 2 cobre a inferência a partir do modelo publicado no Hub.

Antes de executar: - Use um ambiente com GPU (*Ambiente de execução* → *Alterar o tipo* → *T4 GPU*). - Cadastre nos *secrets* do Colab um `HF_TOKEN` com permissão de **escrita**. - Preencha `HF_USERNAME` na classe `Config`.

1.1 Parte 1 - Treinamento do modelo

1.1.1 1.1 Preparação do ambiente

A célula abaixo instala o Unsloth, que já traz `transformers`, `trl`, `peft` e `bitsandbytes`, usando o `uv`, como no notebook de aula.

```
[1]: !uv pip install unsloth psutil -qqq
```

O Unsloth precisa ser importado **antes** de `transformers` e `trl` para aplicar as otimizações dele. Por isso, fica em uma célula própria.

```
[2]: import warnings

warnings.filterwarnings("ignore", category=FutureWarning)

from unsloth import FastLanguageModel

print("Unsloth carregado com sucesso.")
```

Unsloth: Will patch your computer to enable 2x faster free finetuning.

Unsloth Zoo will now patch everything to make training faster!

Unsloth carregado com sucesso.

1.1.2 1.2 Configuração do treinamento

A classe `Config` centraliza todos os hiperparâmetros e caminhos. A tabela abaixo justifica as escolhas.

Modelo e dados

Parâmetro	Valor	Justificativa
<code>MODEL_NAME</code>	<code>unsloth/Qwen3-4B</code>	Mesmo modelo da aula: bom em português, suporta <i>chat template</i> com papéis e cabe numa T4 em 4 bits

Parâmetro	Valor	Justificativa
LOAD_IN_4BIT	True	QLoRA: o modelo base fica quantizado em 4 bits e congelado, usando cerca de 3,5 GB de VRAM
MAX_SEQ_LENGTH	1024	O maior exemplo tem menos de 700 tokens
EVAL_SIZE	0.10	~55 exemplos para a curva de validação, conforme o enunciado
ENABLE_THINKING	False	O assistente responde direto, sem o modo de raciocínio do Qwen3

LoRA

Parâmetro	Valor	Justificativa
LORA_RANK (r)	16	Capacidade suficiente para um domínio restrito (~33 M parâmetros treináveis, menos de 1% do modelo). Ranks maiores aumentam o risco de overfitting numa base pequena
LORA_ALPHA	16	Com rsLoRA, a escala efetiva é $\alpha/\sqrt{r} = 4$, e as atualizações continuam estáveis mesmo com rank maior
USE_RSLORA	True	<i>Rank-stabilized LoRA</i> , como na aula
LORA_DROPOUT	0	Caminho otimizado do Unsloth. O overfitting é controlado pela validação e pelo melhor checkpoint
TARGET_MODULES	atenção (q, k, v, o) + MLP (gate, up, down)	Todas as camadas lineares. As MLPs são onde fica boa parte do conhecimento factual (preços, prazos, regras)

Treinamento

Parâmetro	Valor	Justificativa
BATCH_SIZE $\times$ GRAD_ACCUM	$2 \times 4 = 8$	Batch efetivo 8 com pouca memória por passo

Parâmetro	Valor	Justificativa
EPOCHS	3	~500 exemplos / 8 = ~63 passos por época, ou ~190 no total
LEARNING_RATE	1e-4	Valor da aula. Com rsLoRA, a escala do adaptador já é 4×, então não é preciso subir para 2e-4
LR_SCHEDULER / WARMUP_RATIO	cosine / 0.05	Aquecimento curto e decaimento suave até o fim da 3ª época
WEIGHT_DECAY / MAX_GRAD_NORM	0.01 / 1.0	Regularização leve e <i>gradient clipping</i>
EVAL_STEPS	20	~9 pontos na curva de validação
LOAD_BEST_MODEL_AT_END	True	Restaura o checkpoint com a menor perda de validação

```
[3]: import json
import math
import os
from pathlib import Path
from string import Template
from typing import Any, Optional

import matplotlib.pyplot as plt
import pandas as pd
import torch
from datasets import Dataset, load_dataset
from huggingface_hub import HfApi
from transformers import TextStreamer
from trl import SFTConfig, SFTTrainer
from unsloth.chat_templates import train_on_responses_only

class Config:
    """Central configuration for the fine-tuning run.

    This class groups model, dataset, LoRA and training
    hyperparameters in a single place, making the experiment
    easier to reproduce and adjust.
    """

    MODEL_NAME = "unsloth/Qwen3-4B"
    MAX_SEQ_LENGTH = 1024
    LOAD_IN_4BIT = True
```

```

USE_GOOGLE_DRIVE = True
DRIVE_DIR = "/content/drive/MyDrive/PUC_GenAI_Indie"
LOCAL_DIR = "indie_ft"
DATA_FILE = "indie_knowledge_base.jsonl"
METADATA_FILE = "indie_qna_com_metadados.jsonl"
PIPELINE_SUMMARY_FILE = "resumo_pipeline.json"
USE_EVAL_SPLIT = True
EVAL_SIZE = 0.10
ENABLE_THINKING = False

LORA_RANK = 16
LORA_ALPHA = 16
LORA_DROPOUT = 0
USE_RSLORA = True
TARGET_MODULES = [
    "q_proj",
    "k_proj",
    "v_proj",
    "o_proj",
    "gate_proj",
    "up_proj",
    "down_proj",
]

BATCH_SIZE = 2
GRAD_ACCUM = 4
EPOCHS = 3
LEARNING_RATE = 1e-4
WARMUP_RATIO = 0.05
WEIGHT_DECAY = 0.01
MAX_GRAD_NORM = 1.0
LR_SCHEDULER = "cosine"
LOGGING_STEPS = 5
EVAL_STEPS = 20
LOAD_BEST_MODEL_AT_END = True
SEED = 3407
OUTPUT_DIR = "outputs"

MAX_NEW_TOKENS = 512
TEMPERATURE = 0.1

PUSH_TO_HUB = True
HF_USERNAME = "SEU_USUARIO_HF" # <- preencha com o seu usuario do Hugging_
Face
HF_PRIVATE = False
MODEL_REPO = "Indie-Qwen3-4B-LoRA"

```

```

DATASET_REPO = "Indie-Knowledge-Base"

def __init__(self) -> None:
    self.base_dir = Path(
        self.DRIVE_DIR if self.USE_GOOGLE_DRIVE else self.LOCAL_DIR
    )

def path(self, filename: str) -> Path:
    """Return the full path of a project file inside the base dir."""
    return self.base_dir / filename

@property
def model_repo_id(self) -> str:
    """Hugging Face Hub id of the model repository."""
    return f"{self.HF_USERNAME}/{self.MODEL_REPO}"

@property
def dataset_repo_id(self) -> str:
    """Hugging Face Hub id of the dataset repository."""
    return f"{self.HF_USERNAME}/{self.DATASET_REPO}"

```

A célula abaixo monta o Google Drive, onde estão a base gerada no notebook 02 e onde serão salvos os artefatos (curva de perda, exemplos, adaptadores). Também mostra qual GPU está em uso.

```

[4]: config = Config()

if config.USE_GOOGLE_DRIVE:
    from google.colab import drive

    drive.mount("/content/drive")
    config.base_dir.mkdir(parents=True, exist_ok=True)

assert torch.cuda.is_available(), "Ative uma GPU no Colab antes de continuar."
print(f"GPU: {torch.cuda.get_device_name(0)}")
print(f"Artefatos em: {config.base_dir}")

```

Mounted at /content/drive

GPU: Tesla T4

Artefatos em: /content/drive/MyDrive/PUC_GenAI_Indie

1.1.3 1.3 Carregamento do dataset

A base é lida do Drive. Se não estiver lá, o Colab abre o upload. Cada linha tem uma lista `messages` com os papéis `system`, `user` e `assistant`. O prompt de sistema padrão, usado nas inferências, é lido do próprio dataset.

```

[5]: data_path = config.path(config.DATA_FILE)
if not data_path.exists():

```

```

from google.colab import files

print(f"Envie o arquivo {config.DATA_FILE}:")
uploaded = files.upload()
data_path.write_bytes(next(iter(uploaded.values()))))

raw_dataset = load_dataset("json", data_files=str(data_path), split="train")
DEFAULT_SYSTEM_PROMPT = raw_dataset[0]["messages"][0]["content"]

print(f"{len(raw_dataset)} exemplos carregados.")
print("\nPrompt de sistema:\n")
print(DEFAULT_SYSTEM_PROMPT)
print("\nExemplo:")
for message in raw_dataset[1]["messages"][1:]:
    print(f"[{message['role']}] {message['content']}")

```

Generating train split: 0 examples [00:00, ? examples/s]

634 exemplos carregados.

Prompt de sistema:

Você é a assistente virtual da Indie, o banco de quem trabalha por conta própria. A Indie é uma fintech brasileira que oferece serviços financeiros para MEIs, microempresas de serviços, freelancers e profissionais liberais.

Produtos da Indie:

- Indie Conta PJ: conta digital para pessoa jurídica, com Pix, cartões e Indie Abre MEI
- Indie Notas: emissão de nota fiscal de serviço (NFS-e)
- Indie Global: recebimento de pagamentos do exterior em USD, EUR e GBP
- Cofre Fiscal: reserva automática para impostos e DAS-MEI automático
- Indie Contábil: contabilidade online com contador dedicado
- Indie Futuro: Caixinhas, Salário Indie, Seguro Renda Protegida e Previdência
- Indie Cobranças: links de pagamento, cobrança recorrente e Tap to Pay

Planos: Essencial (grátis), Pro (R\$ 39,90/mês) e Premium (R\$ 99,90/mês).

Responda em português, de forma clara, cordial e precisa. Não dê recomendações individuais de investimento nem planejamento tributário personalizado, nunca peça senhas ou códigos e, se não souber uma informação, oriente o cliente a falar com o atendimento.

Exemplo:

[user] O que acontece se um boleto emitido não for pago?

[assistant] Se um boleto emitido não for pago, você não será cobrado por isso. A Indie Cobranças não cobra taxas por boletos que não são pagos, permitindo que você tenha flexibilidade nas suas cobranças.

1.1.4 1.4 Funções auxiliares

As funções abaixo são as mesmas do notebook de aula, com pequenas adaptações:

- `format_dataset`: aplica o *chat template* do Qwen3 a cada exemplo;
- `plot_loss`: plota as curvas de perda de treino e de validação e salva a figura no Drive;
- `generate_response`: versão de `predict_response` que também **retorna** o texto gerado, para montar a comparação antes/depois;
- `get_hf_token`: lê o token do Hugging Face dos *secrets* do Colab.

```
[6]: def format_dataset(
    example: dict,
    tokenizer: Any,
    config: Config,
) -> dict:
    """Apply the Qwen3 chat template to a single dataset example.

    Args:
        example: A single dataset row containing a 'messages' key
            with the chat-formatted conversation (list of dicts
            with 'role' and 'content' keys).
        tokenizer: The tokenizer associated with the base model,
            used to render the chat template.
        config: The training configuration, used to read whether
            the Qwen3 'thinking' mode should be enabled.

    Returns:
        A dictionary with a single 'text' key containing the
        rendered chat string.
    """
    text = tokenizer.apply_chat_template(
        example["messages"],
        tokenize=False,
        add_generation_prompt=False,
        enable_thinking=config.ENABLE_THINKING,
    )
    return {"text": text}

def plot_loss(trainer: Any, output_path: Path) -> None:
    """Plot the training and evaluation loss curves.

    Reads the trainer's log history, extracts the training and
    (when available) evaluation loss values per step, plots both
    curves and saves the resulting figure.

    Args:
        trainer: A trained Hugging Face / TRL trainer instance
```

*exposing a 'state.log_history' attribute.
output_path: Where to save the figure (PNG).*

Returns:

None. The plot is displayed and saved to disk as a side effect.

```
"""
log_history = trainer.state.log_history

train_steps, train_losses = [], []
eval_steps, eval_losses = [], []

for log in log_history:
    if "loss" in log and "step" in log:
        train_steps.append(log["step"])
        train_losses.append(log["loss"])
    if "eval_loss" in log and "step" in log:
        eval_steps.append(log["step"])
        eval_losses.append(log["eval_loss"])

plt.figure(figsize=(10, 6))
plt.plot(
    train_steps,
    train_losses,
    label="Training Loss",
    color="blue",
    marker="o",
    markersize=4,
)
if eval_losses:
    plt.plot(
        eval_steps,
        eval_losses,
        label="Eval Loss",
        color="red",
        marker="s",
        markersize=4,
    )
plt.xlabel("Steps (Passos de Treinamento)")
plt.ylabel("Loss (Perda)")
plt.title("Curva de Convergencia - Indie Qwen3-4B QLoRA")
plt.legend()
plt.grid(True, linestyle="--", alpha=0.7)
plt.tight_layout()
plt.savefig(output_path, dpi=120)
plt.show()
print(f"Grafico salvo em '{output_path}')
```

```

def generate_response(
    model: Any,
    tokenizer: Any,
    config: Config,
    question: str,
    system_prompt: Optional[str] = None,
    stream: bool = False,
) -> str:
    """Generate a model response for a given question.

    Builds the chat prompt using the system and user messages and
    generates an answer, optionally streaming the tokens to standard
    output. The model must already be in inference mode.

    Args:
        model: The language model (base or fine-tuned).
        tokenizer: The tokenizer associated with the model.
        config: The training configuration (thinking mode,
            generation length and temperature).
        question: The user question to send to the model.
        system_prompt: An optional system prompt overriding the
            default persona. Defaults to 'DEFAULT_SYSTEM_PROMPT'.
        stream: Whether to stream the answer to standard output.

    Returns:
        The generated answer as a string.
    """

    if system_prompt is None:
        system_prompt = DEFAULT_SYSTEM_PROMPT

    messages = [
        {"role": "system", "content": system_prompt},
        {"role": "user", "content": question},
    ]
    text = tokenizer.apply_chat_template(
        messages,
        tokenize=False,
        add_generation_prompt=True,
        enable_thinking=config.ENABLE_THINKING,
    )
    inputs = tokenizer(text, return_tensors="pt").to("cuda")
    streamer = TextStreamer(tokenizer, skip_prompt=True,
↪ skip_special_tokens=True) if stream else None

    output = model.generate(

```

```

        **inputs,
        streamer=streamer,
        max_new_tokens=config.MAX_NEW_TOKENS,
        temperature=config.TEMPERATURE,
        use_cache=True,
    )
    new_tokens = output[0][inputs["input_ids"].shape[1]:]
    return tokenizer.decode(new_tokens, skip_special_tokens=True).strip()

def answer_questions(
    model: Any,
    tokenizer: Any,
    config: Config,
    questions: list[str],
) -> list[str]:
    """Answer a list of questions in inference mode and restore training mode.

    Args:
        model: The language model with LoRA adapters.
        tokenizer: The tokenizer associated with the model.
        config: The training configuration.
        questions: The questions to answer.

    Returns:
        The generated answers, in the same order as the questions.
    """
    FastLanguageModel.for_inference(model)
    answers = []
    for question in questions:
        answer = generate_response(model, tokenizer, config, question)
        print(f"Usuario: {question}\nAssistente: {answer}\n" + "-" * 80)
        answers.append(answer)
    FastLanguageModel.for_training(model)
    return answers

def get_hf_token() -> str:
    """Fetch the Hugging Face authentication token.

    Attempts to read the token from Google Colab secrets first,
    falling back to the 'HF_TOKEN' environment variable when the
    Colab API is not available.

    Returns:
        The Hugging Face authentication token as a string.
    """

```

```

Raises:
    ValueError: If the token cannot be found in either the
    Colab secrets or the environment variables.
    """
    try:
        from google.colab import userdata
        return userdata.get("HF_TOKEN")
    except Exception:
        token = os.environ.get("HF_TOKEN")
        if not token:
            raise ValueError(
                "Token nao encontrado. Configure o HF_TOKEN nos "
                "segredos do Colab ou exporte a variavel de "
                "ambiente HF_TOKEN."
            )
        return token

```

1.1.5 1.5 Carregamento do modelo base e aplicação do LoRA

O Qwen3-4B é carregado em 4 bits (QLoRA) e, em seguida, recebe os adaptadores LoRA. Só os adaptadores são treináveis. A saída mostra quantos parâmetros são treinados em relação ao total.

```

[7]: model, tokenizer = FastLanguageModel.from_pretrained(
    model_name=config.MODEL_NAME,
    max_seq_length=config.MAX_SEQ_LENGTH,
    load_in_4bit=config.LOAD_IN_4BIT,
    use_gradient_checkpointing="unsloth",
)
if tokenizer.pad_token is None:
    tokenizer.pad_token = tokenizer.eos_token

model = FastLanguageModel.get_peft_model(
    model,
    r=config.LORA_RANK,
    target_modules=config.TARGET_MODULES,
    lora_alpha=config.LORA_ALPHA,
    lora_dropout=config.LORA_DROPOUT,
    bias="none",
    use_rslora=config.USE_RSLORA,
    use_gradient_checkpointing="unsloth",
    random_state=config.SEED,
)

trainable_params = sum(p.numel() for p in model.parameters() if p.requires_grad)
total_params = sum(p.numel() for p in model.parameters())
print(
    f"Parametros treinaveis: {trainable_params:,} de {total_params:,} "

```

```

f"({100 * trainable_params / total_params:.2f}%)"
)

==(====)== Unsloth 2026.9.11: Fast Qwen3 patching. Transformers: 5.5.0.
  \ \ / | Tesla T4. Num GPUs = 1. Max memory: 14.563 GB. Platform: Linux.
0^0/ \_/ \ Torch: 2.11.0+cu128. CUDA: 7.5. CUDA Toolkit: 12.8. Triton: 3.6.0
\ / Bfloat16 = FALSE. FA [Xformers = 0.0.35. FA2 = False]
"-____-" Free license: http://github.com/unslothai/unsloth
Unsloth: Fast downloading is enabled - ignore downloading bars which are red
colored!

Loading weights: 0%| | 0/398 [00:00<?, ?it/s]

Unsloth 2026.9.11 patched 36 layers with 36 QKV layers, 36 O layers and 36 MLP
layers.

Parametros treinaveis: 33,030,144 de 2,541,616,640 (1.30%)

```

1.1.6 1.6 Formatação do dataset e divisão treino/validação

Cada conversa é convertida em texto com o *chat template* do Qwen3. A célula também mede o tamanho dos exemplos em tokens, para confirmar que nenhum passa de MAX_SEQ_LENGTH, e separa 10% da base para validação.

```

[8]: dataset = raw_dataset.map(lambda example: format_dataset(example, tokenizer,
    ↪config))

token_lengths = pd.Series([len(tokenizer(text)["input_ids"]) for text in
    ↪dataset["text"]])
print("Tamanho dos exemplos (tokens):")
print(token_lengths.describe(percentiles=[0.5, 0.95]).round(0).to_string())
assert token_lengths.max() <= config.MAX_SEQ_LENGTH, "Aumente MAX_SEQ_LENGTH."

eval_dataset = None
if config.USE_EVAL_SPLIT:
    split = dataset.train_test_split(test_size=config.EVAL_SIZE, seed=config.
    ↪SEED)
    train_dataset, eval_dataset = split["train"], split["test"]
    print(f"\nTreino: {len(train_dataset)} | Validacao: {len(eval_dataset)}")
else:
    train_dataset = dataset

steps_per_epoch = math.ceil(len(train_dataset) / (config.BATCH_SIZE * config.
    ↪GRAD_ACCUM))
print(f"Passos por epoca: {steps_per_epoch} | Total: {steps_per_epoch * config.
    ↪EPOCHS}")

print("\n----- Exemplo formatado -----")
print(train_dataset[0]["text"])

```

Map: 0% | 0/634 [00:00<?, ? examples/s]

Tamanho dos exemplos (tokens):

count	634.0
mean	411.0
std	26.0
min	351.0
50%	410.0
95%	459.0
max	499.0

Treino: 570 | Validacao: 64

Passos por epoca: 72 | Total: 216

----- Exemplo formatado -----

<|im_start|>system

Você é a assistente virtual da Indie, o banco de quem trabalha por conta própria. A Indie é uma fintech brasileira que oferece serviços financeiros para MEIs, microempresas de serviços, freelancers e profissionais liberais.

Produtos da Indie:

- Indie Conta PJ: conta digital para pessoa jurídica, com Pix, cartões e Indie Abre MEI
- Indie Notas: emissão de nota fiscal de serviço (NFS-e)
- Indie Global: recebimento de pagamentos do exterior em USD, EUR e GBP
- Cofre Fiscal: reserva automática para impostos e DAS-MEI automático
- Indie Contábil: contabilidade online com contador dedicado
- Indie Futuro: Caixinhas, Salário Indie, Seguro Renda Protegida e Previdência
- Indie Cobranças: links de pagamento, cobrança recorrente e Tap to Pay

Planos: Essencial (grátis), Pro (R\$ 39,90/mês) e Premium (R\$ 99,90/mês).

Responda em português, de forma clara, cordial e precisa. Não dê recomendações individuais de investimento nem planejamento tributário personalizado, nunca peça senhas ou códigos e, se não souber uma informação, oriente o cliente a falar com o atendimento.<|im_end|>

<|im_start|>user

A Indie Conta PJ parece ter muitas funcionalidades, mas e se eu não entender alguma? Vou ter que pagar por isso?<|im_end|>

<|im_start|>assistant

<think>

</think>

Não se preocupe! A Indie oferece um atendimento humano 24 horas pelo chat do app em todos os planos, onde você pode tirar suas dúvidas sem custo adicional. A ideia é tornar o uso da conta simples e transparente, sem taxas escondidas. Você pode contar com suporte sempre que precisar.<|im_end|>

1.1.7 1.7 Respostas do modelo base (antes do treino)

Logo após `get_peft_model`, a matriz B dos adaptadores LoRA é inicializada com zeros. Por isso, o modelo ainda se comporta **exatamente como o Qwen3-4B original**. As perguntas abaixo são respondidas agora e de novo depois do treino. Elas cobrem produtos, planos, taxas, regulação, golpes, limites da assistente e perguntas fora do escopo, e várias foram escritas de um jeito diferente das perguntas da base.

```
[9]: TEST_QUESTIONS = [
    "Quais produtos a Indie oferece?",
    "Qual a diferença entre o plano Pro e o Premium?",
    "Sou tradutora e recebo em euro de clientes na Alemanha. Quanto a Indie
    cobra para converter?",
    "O dinheiro que fica parado na conta da Indie tem garantia do FGC?",
    "Me ligaram dizendo ser da Indie e pediram o código da Indie Chave para
    cancelar uma compra. O que eu faço?",
    "vcs tem maquininha de cartao?",
    "Em qual ação eu deveria investir o dinheiro da minha empresa?",
    "Como faço para abrir um MEI pelo app?",
    "Consigo pagar um fornecedor nos Estados Unidos pela Indie?",
    "Qual é a capital da Austrália?",
]

answers_before = answer_questions(model, tokenizer, config, TEST_QUESTIONS)
```

```
Both `max_new_tokens` (=512) and `max_length` (=40960) seem to have been set.
`max_new_tokens` will take precedence. Please refer to the documentation for
more information.
(https://huggingface.co/docs/transformers/main/en/main\_classes/text\_generation)
Both `max_new_tokens` (=512) and `max_length` (=40960) seem to have been set.
`max_new_tokens` will take precedence. Please refer to the documentation for
more information.
(https://huggingface.co/docs/transformers/main/en/main\_classes/text\_generation)
```

Usuario: Quais produtos a Indie oferece?

Assistente: A Indie oferece diversos produtos e serviços financeiros para MEIs, microempresas de serviços, freelancers e profissionais liberais. Abaixo estão os principais produtos:

- ****Indie Conta PJ****: Conta digital para pessoa jurídica, com Pix, cartões e Indie Abre MEI.
- ****Indie Notas****: Emissão de nota fiscal de serviço (NFS-e).
- ****Indie Global****: Recebimento de pagamentos do exterior em USD, EUR e GBP.
- ****Cofre Fiscal****: Reserva automática para impostos e DAS-MEI automático.
- ****Indie Contábil****: Contabilidade online com contador dedicado.
- ****Indie Futuro****: Caixinhas, Salário Indie, Seguro Renda Protegida e Previdência.

- **Indie Cobranças**: Links de pagamento, cobrança recorrente e Tap to Pay.

Temos planos Essencial (grátis), Pro (R\$ 39,90/mês) e Premium (R\$ 99,90/mês). Se você precisar de mais detalhes sobre algum produto ou plano, fique a vontade para perguntar!

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.
(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Qual a diferença entre o plano Pro e o Premium?

Assistente: Claro! A diferença entre o **Plano Pro** e o **Plano Premium** da Indie está principalmente no **nível de funcionalidade** e no **suporte** oferecido. Veja as principais diferenças:

Plano Pro (R\$ 39,90/mês)

- **Disponível para MEIs, microempresas e freelancers.**
- **Funcionalidades principais:**
 - Conta digital para pessoa jurídica (Indie Conta PJ)
 - Emissão de NFS-e (Nota Fiscal de Serviço)
 - Pix, cartões e Indie Abre MEI
 - Cofre Fiscal (reserva automática para impostos)
 - Indicador de DAS-MEI (automatizado)
 - Acesso a recursos básicos de gestão financeira
- **Suporte:**
 - Acesso a atendimento via chat ou e-mail (não inclui suporte prioritário)

Plano Premium (R\$ 99,90/mês)

- **Disponível para MEIs, microempresas e freelancers.**
- **Funcionalidades principais:**
 - Tudo o que o Plano Pro oferece, mais:
 - Contabilidade online com contador dedicado (Indie Contábil)
 - Acesso a serviços como Caixinhas, Salário Indie, Seguro Renda Protegida e Previdência (Indie Futuro)
 - Acesso a Indicador de DAS-MEI (automatizado)
 - Suporte prioritário (atendimento direto com um especialista)
- **Suporte:**
 - Acesso a atendimento prioritário com um especialista da Indie

Resumo:

Funcionalidade	Plano Pro	Plano Premium
Contabilidade	Não	Sim (Indie Contábil)
Suporte	Normal	Prioritário
Serviços Extras	Não	Sim (Indie Futuro)
DAS-MEI	Sim	Sim
Cofre Fiscal	Sim	Sim

Se você quiser, posso ajudar a escolher qual plano é mais adequado para o seu negócio!

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.
(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Sou tradutora e recebo em euro de clientes na Alemanha. Quanto a Indie cobra para converter?

Assistente: Olá! A Indie oferece a opção de converter euros para reais com uma taxa competitiva, mas a taxa exata pode variar conforme o momento do dia e a cotação do euro.

Se você deseja converter euros para reais, pode fazer isso por meio do **Indie Global**, que permite o recebimento de pagamentos em diferentes moedas, incluindo euros. Ao receber o pagamento, você pode converter a moeda no momento do recebimento, e a taxa será calculada com base na cotação atual.

Se você quiser saber a taxa exata ou precisar de orientação sobre como fazer a conversão, posso te ajudar a entender o processo. Você também pode entrar em contato com o atendimento da Indie para obter a taxa atual e mais detalhes.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.
(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: O dinheiro que fica parado na conta da Indie tem garantia do FGC?

Assistente: O dinheiro que fica parado na conta da Indie **não** tem garantia do FGC (Fundo Garantia de Clientes).

A Indie é uma fintech que oferece serviços financeiros, mas não é uma instituição financeira autorizada pelo Banco Central do Brasil (BCB) para oferecer garantia do FGC. Portanto, os fundos depositados em contas da Indie não são protegidos por esse fundo.

Se você desejar maior segurança, recomenda-se que os recursos sejam depositados em contas bancárias tradicionais, que são garantidas pelo FGC.

Se você tiver dúvidas sobre como proteger seus recursos ou quiser mais informações sobre as garantias oferecidas por instituições financeiras, sinta-se livre para falar com o atendimento da Indie.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for

more information.

(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Me ligaram dizendo ser da Indie e pediram o código da Indie Chave para cancelar uma compra. O que eu faço?

Assistente: Se você recebeu uma ligada dizendo ser da Indie e pedindo o código da "Indie Chave" para cancelar uma compra, é importante que você ****nunca forneça informações pessoais ou de acesso**** a terceiros. A Indie não pede códigos de acesso por telefone ou por qualquer meio externo.

Aqui está o que você deve fazer:

1. ****Não forneça nenhum código ou senha**** para a Indie ou para qualquer outro serviço.
2. ****Desligue o telefone**** ou ****interrompa a conversa****.
3. ****Entre em contato com o atendimento da Indie**** diretamente pelo site ou app da Indie, ou pelo telefone de atendimento oficial.
4. ****Relate o incidente**** ao atendimento, informando que você recebeu uma ligada suspeita e que não forneceu nenhuma informação sensível.

A Indie tem medidas de segurança para proteger seus clientes, e qualquer solicitação de informações sensíveis por telefone é um sinal de possível fraude.

Se precisar, posso te ajudar a localizar o telefone de atendimento da Indie.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.

(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: vcs tem maquininha de cartao?

Assistente: Não, a Indie não oferece maquininha de cartão. No entanto, temos várias opções para receber pagamentos, como:

- ****Pix****: pagamento instantâneo via código ou link.
- ****Indie Cobranças****: links de pagamento personalizados.
- ****Indie Global****: recebimento de pagamentos do exterior em USD, EUR e GBP.
- ****Cartões****: você pode emitir cartões de crédito ou débito com o Indie Conta PJ.

Se você precisar de orientação sobre como receber pagamentos, estou aqui para ajudar!

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.

(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Em qual ação eu deveria investir o dinheiro da minha empresa?

Assistente: Prezado cliente,

Como assistente virtual da Indie, não posso oferecer recomendações específicas de investimento ou planejamento financeiro personalizado. A Indie se dedica a facilitar o gerenciamento e o crescimento de sua empresa por meio de soluções financeiras e administrativas, como contas digitais, emissão de notas fiscais, cobranças, gestão fiscal e contábil.

Se você estiver buscando orientações sobre investimentos, recomenda-se que consulte um profissional da área de finanças ou um economista para análise personalizada com base em seu perfil de risco, objetivos e situação financeira.

Estamos aqui para ajudar com as soluções da Indie que podem apoiar o crescimento e a gestão de sua empresa. Se precisar de orientações sobre os nossos serviços, fique a vontade para nos contactar.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.

(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Como faço para abrir um MEI pelo app?

Assistente: Para abrir um MEI (Microempresa de Serviços) pelo app da Indie, siga os passos abaixo:

1. **Baixe e instale o app da Indie** no seu celular (Android ou iOS).
2. **Faça o login** no app, se já tiver conta. Se não tiver, crie uma conta.
3. **Acesse a seção "Indie Abre MEI"** no app.
4. **Preencha os dados** solicitados para a abertura do MEI, como:
 - Nome da empresa
 - CPF do representante
 - Endereço
 - Atividade econômica
 - Outras informações necessárias
5. **Confirme os dados** e aguarde a aprovação da Indie.
6. **Receba o cadastro do MEI** e confirme a abertura.

Se você tiver dúvidas durante o processo, pode falar com o atendimento da Indie pelo app ou pelo site.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.

(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Consigo pagar um fornecedor nos Estados Unidos pela Indie?

Assistente: Sim, você pode pagar um fornecedor nos Estados Unidos utilizando a

****Indie Global****, que permite o recebimento de pagamentos do exterior em ****USD, EUR e GBP****.

Para realizar o pagamento, você precisa:

1. ****Possuir uma conta Indie**** (Essencial, Pro ou Premium).
2. ****Incluir o fornecedor nos seus cadastros**** (como cliente ou parceiro).
3. ****Gerar um link de pagamento**** ou usar o ****Pix**** para o pagamento do fornecedor.
4. ****Realizar o pagamento**** por meio do ****Pix**** ou outros métodos compatíveis.

Se você precisar de orientações específicas sobre como fazer isso, posso te ajudar a seguir os passos. Se tiver dúvidas sobre cadastro ou configuração, entre em contato com o atendimento da Indie.

Usuario: Qual é a capital da Austrália?

Assistente: A capital da Austrália é Canberra.

1.1.8 1.8 Treinamento supervisionado (SFT)

O `SFTTrainer` é configurado como na aula, com duas diferenças: salva checkpoints no mesmo ritmo da avaliação e restaura o melhor pela perda de validação (`load_best_model_at_end`).

`train_on_responses_only` mascara o prompt de sistema e a pergunta do usuário no cálculo da perda. Assim, o modelo aprende só a **gerar as respostas** da assistente, e não a reproduzir o prompt de sistema, que se repete em todos os exemplos.

```
[10]: sft_args = dict(
    dataset_text_field="text",
    per_device_train_batch_size=config.BATCH_SIZE,
    gradient_accumulation_steps=config.GRAD_ACCUM,
    warmup_ratio=config.WARMUP_RATIO,
    num_train_epochs=config.EPOCHS,
    learning_rate=config.LEARNING_RATE,
    logging_steps=config.LOGGING_STEPS,
    optim="adamw_8bit",
    weight_decay=config.WEIGHT_DECAY,
    max_grad_norm=config.MAX_GRAD_NORM,
    lr_scheduler_type=config.LR_SCHEDULER,
    seed=config.SEED,
    output_dir=config.OUTPUT_DIR,
    report_to="none",
)
if eval_dataset is not None:
    sft_args.update(
        eval_strategy="steps",
        eval_steps=config.EVAL_STEPS,
```

```

        per_device_eval_batch_size=config.BATCH_SIZE,
    )
    if config.LOAD_BEST_MODEL_AT_END:
        sft_args.update(
            save_strategy="steps",
            save_steps=config.EVAL_STEPS,
            save_total_limit=2,
            load_best_model_at_end=True,
            metric_for_best_model="eval_loss",
            greater_is_better=False,
        )

trainer = SFTTrainer(
    model=model,
    tokenizer=tokenizer,
    train_dataset=train_dataset,
    eval_dataset=eval_dataset,
    args=SFTConfig(**sft_args),
)
trainer = train_on_responses_only(
    trainer,
    instruction_part="<|im_start|>user\n",
    response_part="<|im_start|>assistant\n",
)

```

warmup_ratio is deprecated and will be removed in v5.2. Use `warmup\_steps` instead.

```

Unsloth: Tokenizing ["text"] (num_proc=2):   0%|          | 0/570 [00:00<?, ?_
↪examples/s]

```

```

Unsloth: Tokenizing ["text"] (num_proc=2):   0%|          | 0/64 [00:00<?, ?_
↪examples/s]

```

Unsloth: Padding-free auto-enabled, enabling faster training.

```

Map:   0%|          | 0/570 [00:00<?, ? examples/s]

```

```

Map:   0%|          | 0/64 [00:00<?, ? examples/s]

```

Antes de treinar, a célula abaixo decodifica um exemplo **com a máscara aplicada**. Os tokens ignorados na perda aparecem como espaços, e só a resposta da assistente deve continuar visível. Essa é a verificação recomendada pelo Unsloth para `train_on_responses_only`.

```

[11]: sample_labels = trainer.train_dataset[0]["labels"]
      visible = tokenizer.decode(
          [token if token != -100 else tokenizer.pad_token_id for token in_
↪sample_labels],
          skip_special_tokens=True,
      )

```

```
print(visible.strip())
```

<think>

</think>

Não se preocupe! A Indie oferece um atendimento humano 24 horas pelo chat do app em todos os planos, onde você pode tirar suas dúvidas sem custo adicional. A ideia é tornar o uso da conta simples e transparente, sem taxas escondidas. Você pode contar com suporte sempre que precisar.

```
[12]: train_result = trainer.train()
print(f"\nTreinamento concluído em {train_result.metrics['train_runtime'] / 60:.
      ↪1f} min.")
```

The tokenizer has new PAD/BOS/EOS tokens that differ from the model config and generation config. The model config and generation config were aligned accordingly, being updated with the tokenizer's values. Updated tokens:

```
{'bos_token_id': None}.
```

```
==(====)== Unsloth - 2x faster free finetuning | Num GPUs used = 1
  \ \   / |   Num examples = 570 | Num Epochs = 3 | Total steps = 216
0^0/ \_/ \   Batch size per device = 2 | Gradient accumulation steps = 4
\         /   Data Parallel GPUs = 1 | Total batch size (2 x 4 x 1) = 8
"-____-"     Trainable parameters = 33,030,144 of 4,055,498,240 (0.81% trained)
`use_return_dict` is deprecated! Use `return_dict` instead!
```

Unsloth: Will smartly offload gradients to save VRAM!

```
/usr/local/lib/python3.13/dist-packages/unsloth/import_fixes.py:4091:
```

UserWarning: 'has_cuda' is deprecated, please use

```
'torch.backends.cuda.is_built()'
```

```
    return original(name)
```

```
/usr/local/lib/python3.13/dist-packages/unsloth/import_fixes.py:4091:
```

UserWarning: 'has_cudnn' is deprecated, please use

```
'torch.backends.cudnn.is_available()'
```

```
    return original(name)
```

```
/usr/local/lib/python3.13/dist-packages/unsloth/import_fixes.py:4091:
```

UserWarning: 'has_mps' is deprecated, please use 'torch.backends.mps.is_built()'

```
    return original(name)
```

```
/usr/local/lib/python3.13/dist-packages/unsloth/import_fixes.py:4091:
```

UserWarning: 'has_mkldnn' is deprecated, please use

```
'torch.backends.mkldnn.is_available()'
```

```
    return original(name)
```

Unsloth: Double buffering enabled (parallel H2D + compute) for backward pass.

<IPython.core.display.HTML object>

```
Filter:   0%|          | 0/64 [00:00<?, ? examples/s]
```

Unsloth: Restored added_tokens_decoder metadata in

```

outputs/checkpoint-20/tokenizer_config.json.
Unsloth: Restored added_tokens_decoder metadata in
outputs/checkpoint-40/tokenizer_config.json.
Unsloth: Restored added_tokens_decoder metadata in
outputs/checkpoint-60/tokenizer_config.json.
Unsloth: Restored added_tokens_decoder metadata in
outputs/checkpoint-80/tokenizer_config.json.
Unsloth: Restored added_tokens_decoder metadata in
outputs/checkpoint-100/tokenizer_config.json.
Unsloth: Restored added_tokens_decoder metadata in
outputs/checkpoint-120/tokenizer_config.json.
Unsloth: Restored added_tokens_decoder metadata in
outputs/checkpoint-140/tokenizer_config.json.
Unsloth: Restored added_tokens_decoder metadata in
outputs/checkpoint-160/tokenizer_config.json.
Unsloth: Restored added_tokens_decoder metadata in
outputs/checkpoint-180/tokenizer_config.json.
Unsloth: Restored added_tokens_decoder metadata in
outputs/checkpoint-200/tokenizer_config.json.
Unsloth: Restored added_tokens_decoder metadata in
outputs/checkpoint-216/tokenizer_config.json.

```

Treinamento concluído em 25.2 min.

1.1.9 1.9 Curva de perda e avaliação

Uma curva saudável mostra as duas perdas caindo. Se a perda de validação voltar a subir enquanto a de treino continua caindo, há overfitting. Nesse caso, `load_best_model_at_end` já restaurou o checkpoint com a menor perda de validação.

```

[14]: plot_loss(trainer, config.path("training_loss.png"))

# Não chamamos trainer.evaluate(): nas versões recentes do transformers ele
↳ falha
# numa célula separada do train(). Como metric_for_best_model="eval_loss",
# o best_metric já é a perda de validação do checkpoint restaurado.
train_losses = [log["loss"] for log in trainer.state.log_history if "loss" in
↳ log]
eval_losses = [log["eval_loss"] for log in trainer.state.log_history if
↳ "eval_loss" in log]
best_eval_loss = trainer.state.best_metric or (min(eval_losses) if eval_losses
↳ else float("nan"))

training_summary = {
    "modelo_base": config.MODEL_NAME,
    "gpu": torch.cuda.get_device_name(0),
    "exemplos_treino": len(train_dataset),

```

```

"exemplos_validacao": len(eval_dataset) if eval_dataset is not None else 0,
"parametros_treinaveis": trainable_params,
"percentual_treinavel": round(100 * trainable_params / total_params, 3),
"lora_rank": config.LORA_RANK,
"lora_alpha": config.LORA_ALPHA,
"lora_dropout": config.LORA_DROPOUT,
"use_rslora": config.USE_RSLORA,
"target_modules": config.TARGET_MODULES,
"batch_size_efetivo": config.BATCH_SIZE * config.GRAD_ACCUM,
"epocas": config.EPOCHS,
"learning_rate": config.LEARNING_RATE,
"scheduler": config.LR_SCHEDULER,
"passos_totais": trainer.state.global_step,
"tempo_treino_min": round(train_result.metrics["train_runtime"] / 60, 1),
"loss_treino_inicial": round(train_losses[0], 4),
"loss_treino_final": round(train_losses[-1], 4),
"eval_loss_inicial": round(eval_losses[0], 4) if eval_losses else None,
"melhor_eval_loss": round(best_eval_loss, 4),
"melhor_checkpoint": trainer.state.best_model_checkpoint,
}
config.path("treino_resumo.json").write_text(
    json.dumps(training_summary, ensure_ascii=False, indent=2), encoding="utf-8"
)
print(json.dumps(training_summary, ensure_ascii=False, indent=2))

```




Grafico salvo em '/content/drive/MyDrive/PUC_GenAI_Indie/training_loss.png'

```
{
  "modelo_base": "unsloth/Qwen3-4B",
  "gpu": "Tesla T4",
  "exemplos_treino": 570,
  "exemplos_validacao": 64,
  "parametros_treinaveis": 33030144,
  "percentual_treinavel": 1.3,
  "lora_rank": 16,
  "lora_alpha": 16,
  "lora_dropout": 0,
  "use_rslora": true,
  "target_modules": [
    "q_proj",
    "k_proj",
    "v_proj",
    "o_proj",
    "gate_proj",
    "up_proj",
    "down_proj"
  ],
  "batch_size_efetivo": 8,
  "epocas": 3,
  "learning_rate": 0.0001,
  "scheduler": "cosine",
  "passos_totais": 216,
  "tempo_treino_min": 25.2,
  "loss_treino_inicial": 2.5743,
  "loss_treino_final": 0.4687,
  "eval_loss_inicial": 1.2053,
  "melhor_eval_loss": 0.8324,
  "melhor_checkpoint": "outputs/checkpoint-140"
}
```

1.1.10 1.10 Respostas do modelo treinado (depois do treino)

As mesmas perguntas da seção 1.7 são respondidas pelo modelo treinado, e a tabela compara as duas versões. O arquivo `exemplos_inferencia.csv` é salvo no Drive para o relatório.

```
[15]: answers_after = answer_questions(model, tokenizer, config, TEST_QUESTIONS)

comparison = pd.DataFrame(
    {
        "pergunta": TEST_QUESTIONS,
        "antes_do_treino": answers_before,
        "depois_do_treino": answers_after,
    }
)
```

```
comparison.to_csv(config.path("exemplos_inferencia.csv"), index=False,
    ↪encoding="utf-8-sig")

with pd.option_context("display.max_colwidth", None):
    display(comparison.style.set_properties(**{"text-align": "left",
    ↪"white-space": "pre-wrap"}))
```

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.

(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.

(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Quais produtos a Indie oferece?

Assistente: A Indie oferece diversos produtos financeiros para profissionais independentes, como a Indie Conta PJ, Indie Notas, Indie Global, Cofre Fiscal, Indie Contábil, Indie Cobranças, Indie Futuro e serviços de câmbio.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.

(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Qual a diferença entre o plano Pro e o Premium?

Assistente: O plano Pro custa R\$ 39,90/mês e oferece funcionalidades como Pix ilimitado e gratuito, além de cobrança recorrente. Já o Premium, que custa R\$ 99,90/mês, inclui tudo do Pro, mas também permite a abertura de conta corrente no Banco Horizonte e conta de pagamento no Banco Horizonte, além de acesso ao Cofre Fiscal ilimitado.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.

(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Sou tradutora e recebo em euro de clientes na Alemanha. Quanto a Indie cobra para converter?

Assistente: A Indie cobra uma taxa de conversão de 0,6% para recebimentos em euro, que é bem baixa. Além disso, não há tarifa fixa mensal, então você pode escolher o que melhor atende suas necessidades.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.

(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: O dinheiro que fica parado na conta da Indie tem garantia do FGC?
Assistente: Sim, o saldo da conta da Indie é coberto pelo FGC, que garante até R\$ 250 mil por CPF ou CNPJ por instituição emissora. Isso significa que, em caso de problemas financeiros, você pode contar com essa proteção para seus recursos.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.
(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Me ligaram dizendo ser da Indie e pediram o código da Indie Chave para cancelar uma compra. O que eu faço?
Assistente: Não compartilhe sua senha ou código da Indie Chave com ninguém. A Indie nunca pedirá essas informações por telefone. Se você suspeitar de uma tentativa de golpe, bloqueie seu acesso à conta pelo app e entre em contato com o nosso suporte imediatamente.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.
(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: vcs tem maquininha de cartao?
Assistente: Não, a Indie não oferece maquininha de cartão. No entanto, você pode emitir notas fiscais e gerenciar cobranças diretamente pelo app.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.
(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Em qual ação eu deveria investir o dinheiro da minha empresa?
Assistente: Não posso oferecer recomendações individuais de investimento. Para escolher ações ou outros investimentos, é importante consultar um contador ou um consultor financeiro qualificado. A Indie não fornece conselhos sobre investimentos.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.
(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Como faço para abrir um MEI pelo app?
Assistente: Para abrir um MEI pelo app, você deve acessar a seção de 'Indie Abre MEI' no app. Lá, você pode seguir o passo a passo para abrir o MEI gratuitamente. O processo é rápido e leva cerca de 15 minutos.

Both `max\_new\_tokens` (=512) and `max\_length` (=40960) seem to have been set. `max\_new\_tokens` will take precedence. Please refer to the documentation for more information.
(https://huggingface.co/docs/transformers/main/en/main_classes/text_generation)

Usuario: Consigo pagar um fornecedor nos Estados Unidos pela Indie?

Assistente: Sim, você pode pagar fornecedores nos Estados Unidos pelo app da Indie. A funcionalidade permite que você envie Pix internacional, que é uma forma de pagamento rápida e segura para empresas que têm recebimentos do exterior.

Usuario: Qual é a capital da Austrália?

Assistente: A capital da Austrália é Canberra.

<pandas.io.formats.style.Styler at 0x7a57af5a78c0>

1.1.11 1.11 Salvando os adaptadores no Drive

Uma cópia dos adaptadores LoRA e do tokenizer fica no Drive, para que o modelo não se perca se o upload para o Hub falhar ou o Colab desconectar.

```
[16]: adapters_dir = config.path("indie_lora_adapters")
model.save_pretrained(adapters_dir)
tokenizer.save_pretrained(adapters_dir)
print(f"Adaptadores salvos em: {adapters_dir}")
print(sorted(p.name for p in adapters_dir.iterdir()))
```

Unsloth: Restored added_tokens_decoder metadata in /content/drive/MyDrive/PUC_GenAI_Indie/indie_lora_adapters/tokenizer_config.json.

Adaptadores salvos em:

/content/drive/MyDrive/PUC_GenAI_Indie/indie_lora_adapters
['README.md', 'adapter_config.json', 'adapter_model.safetensors',
'chat_template.jinja', 'tokenizer.json', 'tokenizer_config.json']

1.1.12 1.12 Publicação no Hugging Face Hub

As funções abaixo publicam dois repositórios **públicos** e separados:

1. **Modelo** (Indie-Qwen3-4B-LoRA): adaptadores LoRA e tokenizer, com um model card (README.md) que descreve a empresa, o modelo base, os hiperparâmetros, os resultados e como carregar o modelo para inferência.
2. **Dataset** (Indie-Knowledge-Base): o arquivo .jsonl usado no treinamento, no formato messages, com um dataset card que explica como a base foi construída. A versão com metadados (tema e estilo de cada par) também é enviada, se existir.

```
[17]: MODEL_CARD_TEMPLATE = Template("""---
base_model: $base_model
library_name: peft
language:
```

```

- pt
license: apache-2.0
pipeline_tag: text-generation
datasets:
- $dataset_repo_id
tags:
- lora
- qlora
- unsloth
- trl
- sft
- fintech
---

# Indie-Qwen3-4B-LoRA

Adaptadores **LoRA** treinados sobre o **$model_name** para atuar como
↳ assistente virtual da
**Indie**, uma fintech **fictícia** criada para o trabalho final da disciplina
*Generative AI & Advanced Analytics*.

## Caso de uso: a Indie

A Indie é "o banco de quem trabalha por conta própria": uma fintech que oferece
↳ serviços financeiros
para MEIs, microempresas de serviços, freelancers e profissionais liberais. O
↳ modelo responde sobre:

- **Indie Conta PJ**: conta digital PJ com Pix, cartões e abertura de MEI
↳ (Indie Abre MEI);
- **Indie Notas**: emissão de nota fiscal de serviço (NFS-e);
- **Indie Global**: recebimento do exterior em USD, EUR e GBP;
- **Cofre Fiscal**: reserva automática para impostos e DAS-MEI automático;
- **Indie Contábil**: contabilidade online com contador dedicado;
- **Indie Futuro**: Caixinhas, Salário Indie, Seguro Renda Protegida e
↳ Previdência;
- **Indie Cobranças**: links de pagamento, cobrança recorrente e Tap to Pay;
- planos (Essencial, Pro e Premium), atendimento, segurança e os limites da
↳ própria assistente.

## Treinamento

- **Modelo base**: `$model_name` (carregado em 4 bits: `$base_model`)
- **Técnica**: SFT com QLoRA (PEFT) via [Unsloth](https://github.com/unslothai/
↳ unsloth) e TRL, com perda calculada só nas respostas da assistente
↳ (`train_on_responses_only`)

```

```

- **Dataset:** [$dataset_repo_id](https://huggingface.co/datasets/
  ↳$dataset_repo_id), com $n_train exemplos de treino e $n_eval de validação

| Hiperparâmetro | Valor |
|---|---|
| LoRA rank (r) / alpha / dropout | $lora_rank / $lora_alpha / $lora_dropout |
| rsLoRA | $use_rslora |
| Módulos-alvo | $target_modules |
| Parâmetros treináveis | $trainable_params ($trainable_pct% do total) |
| Batch efetivo | $batch_size (batch $per_device × acumulação $grad_accum) |
| Épocas / passos | $epochs / $steps |
| Learning rate / scheduler | $learning_rate / $scheduler (warmup $warmup) |
| Comprimento máximo | $max_seq_length tokens |
| GPU / tempo de treino | $gpu / $runtime min |

**Perdas:** treino $loss_start → $loss_end; melhor perda de validação:␣
  ↳**$eval_loss**.

## Como usar

### Com Unsloth (recomendado)

```python
from unsloth import FastLanguageModel

model, tokenizer = FastLanguageModel.from_pretrained(
 model_name="$model_repo_id",
 max_seq_length=$max_seq_length,
 load_in_4bit=True,
)
FastLanguageModel.for_inference(model)

messages = [
 {"role": "system", "content": SYSTEM_PROMPT}, # prompt de sistema abaixo
 {"role": "user", "content": "Quais produtos a Indie oferece?"},
]
text = tokenizer.apply_chat_template(
 messages, tokenize=False, add_generation_prompt=True, enable_thinking=False
)
inputs = tokenizer(text, return_tensors="pt").to("cuda")
output = model.generate(**inputs, max_new_tokens=512, temperature=0.1)
print(tokenizer.decode(output[0][inputs["input_ids"].shape[1]:],␣
 ↳skip_special_tokens=True))
```

### Com Transformers + PEFT

```

```

```python
from peft import AutoPeftModelForCausalLM
from transformers import AutoTokenizer

model = AutoPeftModelForCausalLM.from_pretrained("$model_repo_id",
 ↪device_map="auto")
tokenizer = AutoTokenizer.from_pretrained("$model_repo_id")
```

Requer GPU com `bitsandbytes`, porque o modelo base de referência está
    ↪quantizado em 4 bits.

### Prompt de sistema usado no treinamento

Use o mesmo prompt de sistema do treinamento para obter o comportamento
    ↪esperado:

```text
$system_prompt
```

## Exemplos (modelo treinado)

$examples

## Limitações

- A Indie é uma **empresa fictícia**. Produtos, preços e parceiros não existem,
    ↪e o modelo **não** deve ser usado
    para orientação financeira ou tributária real.
- O modelo pode errar valores ou combinar informações de forma incorreta,
    ↪sobretudo em perguntas muito distantes da base de treino.
"""

DATASET_CARD_TEMPLATE = Template("""---
language:
- pt
license: apache-2.0
task_categories:
- text-generation
- question-answering
size_categories:
- n<1K
pretty_name: Indie Knowledge Base
tags:
- fintech
- synthetic

```

```

- instruction-tuning
- chat
configs:
- config_name: default
  data_files: $data_file
---

# Indie Knowledge Base

Base de **$n_examples conversas** (pergunta e resposta) sobre a **Indie**,
↳fintech **fictícia** para
quem trabalha por conta própria. Foi usada para treinar o modelo
[$model_repo_id](https://huggingface.co/$model_repo_id) no trabalho final da
↳disciplina
*Generative AI & Advanced Analytics*.

## Formato

Arquivo `$data_file`: uma conversa por linha, no formato `messages` com os
↳papéis `system`, `user` e `assistant`.

```json
$example
```

$metadata_note

## Como a base foi construída

A base foi **gerada com apoio de LLM e revisada**, a partir de um documento de
↳referência da empresa
(produtos, planos, taxas, suporte, segurança e diretrizes da assistente):

1. **Geração** com `gpt-4o-mini` (LangChain, `ChatPromptTemplate` +
↳`with_structured_output`), guiada por
  uma matriz de **24 temas × 6 estilos de pergunta** (direta, comparação,
↳suporte, caso de uso, objeção e
  informal), com personas sorteadas e a lista de perguntas já geradas no
↳prompt para evitar repetições.
2. **Limpeza**: normalização, filtros de tamanho, remoção de duplicatas exatas
↳e de quase-duplicatas
  (similaridade TF-IDF 0,85).
3. **Checagem automática de números** (valores em R$$ e percentuais que não
↳estão no documento).
4. **LLM como juiz**: cada par comparado com o documento; os inconsistentes são
↳descartados.

```

5. **Revisão humana** de uma amostra estratificada de 10% e correções pontuais.

`$pipeline_table`

`## Uso`

```
```python
from datasets import load_dataset

dataset = load_dataset("$dataset_repo_id", split="train")
```
```

`## Limitações`

Os dados são **sintéticos** e descrevem uma empresa fictícia. Não servem como
↳ fonte de informação financeira,
tributária ou regulatória real.

`"""`

```
PIPELINE_LABELS = {
    "pares_brutos": "Pares gerados (brutos)",
    "apos_limpeza_e_deduplicacao": "Após limpeza e deduplicação",
    "reprovados_pelo_juiz": "Reprovados pelo LLM juiz",
    "apos_juiz": "Após o LLM juiz",
    "amostra_revisao_manual": "Revisados manualmente",
    "correcoes_pontuais": "Correções pontuais",
    "dataset_final": Dataset final,
}
```

```
def format_examples(questions: list[str], answers: list[str], limit: int = 4)↳
```

↳ `str:`

`"""Format question/answer pairs as Markdown for the model card."""`

`blocks = [`

`f"Pergunta: {q}\n\nResposta: {a}"`

`for q, a in list(zip(questions, answers))[:limit]`

`]`

`return "\n\n---\n\n".join(blocks)`

```
def format_pipeline_table(summary: dict) -> str:
```

`"""Format the dataset-construction funnel as a Markdown table."""`

`rows = [`

`f"| {label} | {summary[key]} |"`

`for key, label in PIPELINE_LABELS.items()`

`if key in summary`

`]`

```

if not rows:
    return ""
return "| Etapa | Pares |\n|---|---|\n" + "\n".join(rows)

def build_model_card(
    config: Config,
    summary: dict,
    base_model: str,
    system_prompt: str,
    examples: str,
) -> str:
    """Render the model card (README.md) for the Hub model repository."""
    return MODEL_CARD_TEMPLATE.substitute(
        base_model=base_model,
        model_name=config.MODEL_NAME,
        model_repo_id=config.model_repo_id,
        dataset_repo_id=config.dataset_repo_id,
        n_train=summary["exemplos_treino"],
        n_eval=summary["exemplos_validacao"],
        lora_rank=config.LORA_RANK,
        lora_alpha=config.LORA_ALPHA,
        lora_dropout=config.LORA_DROPOUT,
        use_rslora=config.USE_RSLORA,
        target_modules=", ".join(f"`{m}`" for m in config.TARGET_MODULES),
        trainable_params=f"{summary['parametros_treinaveis']:,}",
        trainable_pct=summary["percentual_treinavel"],
        batch_size=summary["batch_size_efetivo"],
        per_device=config.BATCH_SIZE,
        grad_accum=config.GRAD_ACCUM,
        epochs=config.EPOCHS,
        steps=summary["passos_totais"],
        learning_rate=config.LEARNING_RATE,
        scheduler=config.LR_SCHEDULER,
        warmup=config.WARMUP_RATIO,
        max_seq_length=config.MAX_SEQ_LENGTH,
        gpu=summary["gpu"],
        runtime=summary["tempo_treino_min"],
        loss_start=summary["loss_treino_inicial"],
        loss_end=summary["loss_treino_final"],
        eval_loss=summary["melhor_eval_loss"],
        system_prompt=system_prompt,
        examples=examples,
    )

def build_dataset_card(

```

```

config: Config,
n_examples: int,
example: dict,
pipeline_summary: dict,
has_metadata: bool,
) -> str:
    """Render the dataset card (README.md) for the Hub dataset repository."""
    metadata_note = (
        f"O arquivo `{config.METADATA_FILE}` traz as mesmas conversas com `id`,  

        ↪      "`topic` (tema) e `style` (estilo da pergunta), para rastreabilidade."  

        if has_metadata  

        else ""
    )
    return DATASET_CARD_TEMPLATE.substitute(
        n_examples=n_examples,
        data_file=config.DATA_FILE,
        model_repo_id=config.model_repo_id,
        dataset_repo_id=config.dataset_repo_id,
        example=json.dumps(example, ensure_ascii=False, indent=2),
        metadata_note=metadata_note,
        pipeline_table=format_pipeline_table(pipeline_summary),
    )

def push_to_hub(
    model: Any,
    tokenizer: Any,
    config: Config,
    model_card: str,
    dataset_card: str,
) -> None:
    """Push the LoRA adapters, tokenizer and dataset to the Hub.

    Args:
        model: The fine-tuned model whose LoRA adapters will be pushed.
        tokenizer: The tokenizer associated with the model.
        config: The training configuration (usernames, repos, paths).
        model_card: The README.md content for the model repository.
        dataset_card: The README.md content for the dataset repository.

    Returns:
        None. The artifacts are uploaded as a side effect.
    """
    token = get_hf_token()
    api = HfApi(token=token)

```

```

    print(f"Enviando modelo para: {config.model_repo_id} ...")
    model.push_to_hub(config.model_repo_id, token=token, private=config.
↪HF_PRIVATE)
    tokenizer.push_to_hub(config.model_repo_id, token=token, private=config.
↪HF_PRIVATE)
    api.upload_file(
        path_or_fileobj=model_card.encode("utf-8"),
        path_in_repo="README.md",
        repo_id=config.model_repo_id,
        repo_type="model",
    )
    print(f"Modelo disponivel em: https://huggingface.co/{config.
↪model_repo_id}")

    print(f"Enviando dataset para: {config.dataset_repo_id} ...")
    api.create_repo(
        config.dataset_repo_id,
        repo_type="dataset",
        private=config.HF_PRIVATE,
        exist_ok=True,
    )
    for filename in (config.DATA_FILE, config.METADATA_FILE):
        if config.path(filename).exists():
            api.upload_file(
                path_or_fileobj=str(config.path(filename)),
                path_in_repo=filename,
                repo_id=config.dataset_repo_id,
                repo_type="dataset",
            )
    api.upload_file(
        path_or_fileobj=dataset_card.encode("utf-8"),
        path_in_repo="README.md",
        repo_id=config.dataset_repo_id,
        repo_type="dataset",
    )
    print(f"Dataset disponivel em: https://huggingface.co/datasets/{config.
↪dataset_repo_id}")

```

A célula abaixo monta os dois cards e mostra uma prévia do model card antes de publicar. Com `PUSH_TO_HUB = True`, ela envia os artefatos para o Hub.

```

[19]: config.HF_USERNAME = "EstudoAI"
      print(config.model_repo_id, "|", config.dataset_repo_id)

```

EstudoAI/Indie-Qwen3-4B-LoRA | EstudoAI/Indie-Knowledge-Base

```

[21]: pipeline_summary_path = config.path(config.PIPELINE_SUMMARY_FILE)
      pipeline_summary = (

```

```

        json.loads(pipeline_summary_path.read_text(encoding="utf-8"))
    if pipeline_summary_path.exists()
    else {}
)

model_card = build_model_card(
    config,
    training_summary,
    base_model=model.peft_config["default"].base_model_name_or_path,
    system_prompt=DEFAULT_SYSTEM_PROMPT,
    examples=format_examples(TEST_QUESTIONS, answers_after),
)
dataset_card = build_dataset_card(
    config,
    n_examples=len(raw_dataset),
    example=raw_dataset[0],
    pipeline_summary=pipeline_summary,
    has_metadata=config.path(config.METADATA_FILE).exists(),
)
print(model_card[:3000])

if config.PUSH_TO_HUB:
    assert config.HF_USERNAME != "SEU_USUARIO_HF", "Preencha HF_USERNAME na
↳ classe Config."
    push_to_hub(model, tokenizer, config, model_card, dataset_card)

```

```

---
base_model: unsloth/qwen3-4b-unsloth-bnb-4bit
library_name: peft
language:
- pt
license: apache-2.0
pipeline_tag: text-generation
datasets:
- EstudoAI/Indie-Knowledge-Base
tags:
- lora
- qlora
- unsloth
- trl
- sft
- fintech
---

```

Indie-Qwen3-4B-LoRA

Adaptadores ****LoRA**** treinados sobre o ****unsloth/Qwen3-4B**** para atuar como assistente virtual da

****Indie****, uma fintech ****fictícia**** criada para o trabalho final da disciplina ***Generative AI & Advanced Analytics***.

Caso de uso: a Indie

A Indie é "o banco de quem trabalha por conta própria": uma fintech que oferece serviços financeiros para MEIs, microempresas de serviços, freelancers e profissionais liberais. O modelo responde sobre:

- ****Indie Conta PJ****: conta digital PJ com Pix, cartões e abertura de MEI (Indie Abre MEI);
- ****Indie Notas****: emissão de nota fiscal de serviço (NFS-e);
- ****Indie Global****: recebimento do exterior em USD, EUR e GBP;
- ****Cofre Fiscal****: reserva automática para impostos e DAS-MEI automático;
- ****Indie Contábil****: contabilidade online com contador dedicado;
- ****Indie Futuro****: Caixinhas, Salário Indie, Seguro Renda Protegida e Previdência;
- ****Indie Cobranças****: links de pagamento, cobrança recorrente e Tap to Pay;
- planos (Essencial, Pro e Premium), atendimento, segurança e os limites da própria assistente.

Treinamento

- ****Modelo base**** `unsloth/Qwen3-4B` (carregado em 4 bits: `unsloth/qwen3-4b-unsloth-bnb-4bit`)
- ****Técnica**** SFT com QLoRA (PEFT) via [Unsloth](https://github.com/unslothai/unsloth) e TRL, com perda calculada só nas respostas da assistente (`train\_on\_responses\_only`)
- ****Dataset**** [EstudoAI/Indie-Knowledge-Base](https://huggingface.co/datasets/EstudoAI/Indie-Knowledge-Base), com 570 exemplos de treino e 64 de validação

| Hiperparâmetro | Valor |
|---------------------------------|---|
| LoRA rank (r) / alpha / dropout | 16 / 16 / 0 |
| rsLoRA | True |
| Módulos-alvo | `q_proj`, `k_proj`, `v_proj`, `o_proj`, `gate_proj`, `up_proj`, `down_proj` |
| Parâmetros treináveis | 33,030,144 (1.3% do total) |
| Batch efetivo | 8 (batch 2 × acumulação 4) |
| Épocas / passos | 3 / 216 |
| Learning rate / scheduler | 0.0001 / cosine (warmup 0.05) |
| Comprimento máximo | 1024 tokens |
| GPU / tempo de treino | Tesla T4 / 25.2 min |

****Perdas**** treino 2.5743 → 0.4687; melhor perda de validação: ****0.8324****.

```

## Como usar

### Com Unsloth (recomendado)

```python
from unsloth import FastLanguageModel

model, tokenizer = FastLanguageModel.from_pretrained(
 model_name="EstudoAI/Indie-Qwen3-4B-LoRA",
 max_seq_length=1024,
 load_in_4bit=True,
)
FastLanguageModel.for_inference(model)

messages = [
 {"role": "system", "content": SYSTEM_PROMPT}, # prompt de sistema abaixo
 {"role": "user", "content": "Quais produtos a Indie oferece?"},
]
text = tokenizer.apply_chat_template(
 messages, tokenize=False, add_generation_prompt=True, enable_thinking=False
)
inputs = tokenizer(text, return_tensors="pt").to("cuda")
output = model.generate(**inputs, max_new_tokens=512, temper
Enviando modelo para: EstudoAI/Indie-Qwen3-4B-LoRA ...

README.md: 0%| | 0.00/565 [00:00<?, ?B/s]
Processing Files (0 / 0) : | | 0.00B / 0.00B
New Data Upload : | | 0.00B / 0.00B
...adapter_model.safetensors: 0%| | 51.8kB / 66.1MB
Saved model to https://huggingface.co/EstudoAI/Indie-Qwen3-4B-LoRA
Unsloth: Restored added_tokens_decoder metadata in
/tmp/tmpthxbrdsc/tokenizer_config.json.
Processing Files (0 / 0) : | | 0.00B / 0.00B
New Data Upload : | | 0.00B / 0.00B
...mpthxbrdsc/tokenizer.json: 100%|#####| 11.4MB / 11.4MB
Modelo disponivel em: https://huggingface.co/EstudoAI/Indie-Qwen3-4B-LoRA
Enviando dataset para: EstudoAI/Indie-Knowledge-Base ...
Dataset disponivel em: https://huggingface.co/datasets/EstudoAI/Indie-Knowledge-
Base

```

## 1.2 Parte 2 - Inferência e chat interativo

Esta parte carrega o modelo **publicado no Hub** e pode ser executada de forma independente da Parte 1, por exemplo em uma nova sessão do Colab: basta instalar o Unsloth (seção 1.1) e executar

as células abaixo. É também um teste de que o repositório publicado funciona. Se estiver na mesma sessão da Parte 1 e faltar memória na GPU, reinicie a sessão antes.

```
[28]: import os
 from typing import Any, Optional

 from unsloth import FastLanguageModel
 from transformers import TextStreamer

 MODEL_ID = "EstudoAI/Indie-Qwen3-4B-LoRA" # <- mesmo repositório da Parte 1
 MAX_SEQ_LENGTH = 1024
 LOAD_IN_4BIT = True
 ENABLE_THINKING = False

 DEFAULT_SYSTEM_PROMPT = (
 "Você é a assistente virtual da Indie, o banco de quem trabalha por conta_
 ↳própria. A Indie é uma fintech brasileira que oferece serviços financeiros_
 ↳para MEIs, microempresas de serviços, freelancers e profissionais liberais.
 ↳\n"
 "\n"
 "Produtos da Indie:\n"
 "- Indie Conta PJ: conta digital para pessoa jurídica, com Pix, cartões e_
 ↳Indie Abre MEI\n"
 "- Indie Notas: emissão de nota fiscal de serviço (NFS-e)\n"
 "- Indie Global: recebimento de pagamentos do exterior em USD, EUR e GBP\n"
 "- Cofre Fiscal: reserva automática para impostos e DAS-MEI automático\n"
 "- Indie Contábil: contabilidade online com contador dedicado\n"
 "- Indie Futuro: Caixinhas, Salário Indie, Seguro Renda Protegida e_
 ↳Previdência\n"
 "- Indie Cobranças: links de pagamento, cobrança recorrente e Tap to Pay\n"
 "\n"
 "Planos: Essencial (grátis), Pro (R$ 39,90/mês) e Premium (R$ 99,90/mês).\n"
 "\n"
 "Responda em português, de forma clara, cordial e precisa. Não dê_
 ↳recomendações individuais de investimento nem planejamento tributário_
 ↳personalizado, nunca peça senhas ou códigos e, se não souber uma informação,_
 ↳oriente o cliente a falar com o atendimento."
)
```

A função `load_model` carrega o modelo base com os adaptadores LoRA publicados e já o prepara para inferência.

```
[29]: def load_model(model_id: str = MODEL_ID) -> tuple:
 """Load the base model with the fine-tuned LoRA adapters.

 Args:
 model_id: The Hugging Face Hub repository identifier of
```

*the fine-tuned model. Defaults to 'MODEL\_ID'.*

*Returns:*

*A tuple '(model, tokenizer)' with the loaded model, ready for inference, and its associated tokenizer.*

```
"""
model, tokenizer = FastLanguageModel.from_pretrained(
 model_name=model_id,
 max_seq_length=MAX_SEQ_LENGTH,
 load_in_4bit=LOAD_IN_4BIT,
 token=os.environ.get("HF_TOKEN"),
)
FastLanguageModel.for_inference(model)
model.generation_config.max_length = None
return model, tokenizer
```

A função `chat` gera e transmite (streaming) a resposta do modelo para uma pergunta.

```
[30]: def chat(
 model: Any,
 tokenizer: Any,
 question: str,
 system_prompt: Optional[str] = None,
 max_new_tokens: int = 512,
) -> None:
 """Generate and stream a single chat answer.

 Args:
 model: The fine-tuned language model, already prepared
 for inference.
 tokenizer: The tokenizer associated with the model.
 question: The user question to send to the model.
 system_prompt: An optional system prompt overriding the
 default persona. Defaults to None, in which case
 'DEFAULT_SYSTEM_PROMPT' is used.
 max_new_tokens: The maximum number of new tokens to
 generate. Defaults to 512.

 Returns:
 None. The generated answer is streamed to standard output
 as a side effect.
 """
 if system_prompt is None:
 system_prompt = DEFAULT_SYSTEM_PROMPT

 messages = [
 {"role": "system", "content": system_prompt},
```

```

 {"role": "user", "content": question},
]
 text = tokenizer.apply_chat_template(
 messages,
 tokenize=False,
 add_generation_prompt=True,
 enable_thinking=ENABLE_THINKING,
)
 inputs = tokenizer(text, return_tensors="pt").to("cuda")
 streamer = TextStreamer(tokenizer, skip_prompt=True,
↪skip_special_tokens=True)

 print(f"Voce: {question}")
 print("Assistente: ", end="")
 _ = model.generate(
 **inputs,
 streamer=streamer,
 max_new_tokens=max_new_tokens,
 temperature=0.1,
 use_cache=True,
)
 print("-" * 50)

```

A célula abaixo carrega o modelo do Hub e responde a algumas perguntas novas, que não estão na base nem na comparação da Parte 1.

```

[31]: hub_model, hub_tokenizer = load_model()

for question in [
 "Sou personal trainer e cobro mensalidade dos meus alunos. Como a Indie
↪pode me ajudar?",
 "Quanto custa a declaração anual do MEI no plano Essencial?",
 "Se eu cancelar o plano anual no meio do ano, recebo algum dinheiro de
↪volta?",
]:
 chat(hub_model, hub_tokenizer, question)

```

```

==(====)== Unsloth 2026.9.11: Fast Qwen3 patching. Transformers: 5.5.0.
 \ \ /| Tesla T4. Num GPUs = 1. Max memory: 14.563 GB. Platform: Linux.
0^0/ _/ \ Torch: 2.11.0+cu128. CUDA: 7.5. CUDA Toolkit: 12.8. Triton: 3.6.0
\ / Bfloat16 = FALSE. FA [Xformers = 0.0.35. FA2 = False]
"-____-" Free license: http://github.com/unslothai/unsloth
Unsloth: Fast downloading is enabled - ignore downloading bars which are red
colored!

```

```

Loading weights: 0%| | 0/398 [00:00<?, ?it/s]

```

```

Voce: Sou personal trainer e cobro mensalidade dos meus alunos. Como a Indie
pode me ajudar?

```

Assistente: A Indie pode ajudar você, pois oferece a Indie Cobranças, que permite criar links de pagamento e cobrança recorrente. Assim, você pode cobrar seus alunos de forma prática e automatizada, sem precisar gerenciar a cobrança manualmente.

-----  
Voce: Quanto custa a declaração anual do MEI no plano Essencial?

Assistente: No plano Essencial, a declaração anual do MEI é gratuita. Você pode fazer a declaração sem custo, mas é importante lembrar que a Indie não oferece serviços de planejamento tributário personalizado.

-----  
Voce: Se eu cancelar o plano anual no meio do ano, recebo algum dinheiro de volta?

Assistente: Sim, se você cancelar o plano anual no meio do ano, a Indie reembolsa a diferença proporcional do valor pago, proporcionalmente ao tempo que você utilizou o plano.

-----  
A função main executa um chat interativo no terminal, que termina com sair, exit, quit ou q, como no notebook de aula.

```
[32]: def main() -> None:
 """Run an interactive chat loop in the terminal.

 Repeatedly prompts the user for a question, streaming the
 model's answer until an exit command is entered.

 Returns:
 None.
 """
 print("Digite 'sair' para encerrar.\n")
 while True:
 question = input("Voce: ").strip()
 if question.lower() in {"sair", "exit", "quit", "q"}:
 print("Ate logo!")
 break
 if not question:
 continue
 chat(hub_model, hub_tokenizer, question)

 if __name__ == "__main__":
 main()
```

Digite 'sair' para encerrar.

Voce: sair

Ate logo!