

Fine-tuning de LLM com QLoRA: o assistente virtual da Indie

Relatório final · Generative AI & Advanced Analytics

Autor: Matheus Silva · Professor: Renan Santos Mendes · Setembro de 2026

Artefatos publicados no Hugging Face

Modelo (adaptadores LoRA): <https://huggingface.co/EstudoAI/Indie-Qwen3-4B-LoRA>

Dataset (.jsonl): <https://huggingface.co/datasets/EstudoAI/Indie-Knowledge-Base>

Arquivos do projeto: 01_empresa_indie.md (documento-fonte da empresa), 02_geracao_base_qna.ipynb (construção da base), 03_fine_tuning_indie.ipynb (treino, publicação e inferência).

Resumo. Foi criada uma fintech fictícia, a Indie, e, a partir de um documento de referência sobre ela, uma base de **634 conversas** de pergunta e resposta gerada com apoio de LLM, filtrada automaticamente e revisada por amostragem. Com ela, foram treinados adaptadores LoRA ($r = 16$) sobre o **Qwen3-4B** quantizado em 4 bits (QLoRA), por 3 épocas numa GPU T4 (25 min). A perda de validação caiu de 1,21 para **0,83**. O modelo adotou o tom e o formato da marca, mas ainda confunde fatos específicos (seção 6), limitação discutida na seção 7 junto com os próximos passos.

1. A empresa: Indie

Indie Serviços Financeiros S.A., “o banco de quem trabalha por conta própria”, é uma fintech fictícia fundada em 2022, em São Paulo, com cerca de 210 mil clientes ativos. É uma instituição de pagamento autorizada pelo Banco Central e opera com parceiros também fictícios: Banco Horizonte (CDBs), Ponte Câmbio DTVM (câmbio) e Aurora Seguros (seguro e previdência).

Nicho: serviços financeiros para **trabalhadores independentes que faturam como pessoa jurídica**: MEIs, microempresas e empresas de pequeno porte de serviços no Simples Nacional (até 5 sócios), freelancers e profissionais liberais, como desenvolvedores, designers, psicólogos e tradutores, inclusive quem presta serviço para clientes no exterior.

Posicionamento: para ser pago, o profissional independente precisa emitir nota, cobrar, receber, separar o imposto e se proteger de meses fracos, de doença e da falta de aposentadoria. Em geral, usa para isso um banco, um emissor de notas, uma plataforma de câmbio, um contador e planilhas. A Indie reúne tudo em um só app, com fluxo automático: *nota emitida* → *cobrança* → *pagamento recebido* → *imposto reservado* → “*salário*” e *reserva*. A marca fala sem jargão, trata o cliente por “você” e nunca esconde taxas.

Todo o cenário está no documento **01_empresa_indie.md** (cerca de 25 mil caracteres), a “fonte da verdade” do projeto. Ele reúne visão geral, produtos, planos e preços, atendimento, segurança, as diretrizes da assistente virtual e o prompt de sistema usado no treino. Os preços, taxas e prazos foram definidos com valores exatos para que as respostas pudessem ser conferidas.

2. Produtos e serviços

Produto	O que faz	Problema que resolve
Indie Conta PJ	Conta digital PJ com Pix ilimitado, TED, boletos, cartões de débito e crédito e Open Finance. O <i>Indie Abre MEI</i> abre o CNPJ gratuitamente pelo app.	Mistura de finanças pessoais e da empresa; tarifas altas de bancos tradicionais
Indie Notas	Emissão de NFS-e em menos de 1 minuto, notas recorrentes, envio automático ao cliente e baixa automática quando o pagamento cai.	Emissão manual no site da prefeitura e conferência de quem pagou

Produto	O que faz	Problema que resolve
Indie Global	Recebimento do exterior em USD, EUR e GBP (ACH, IBAN, SWIFT), sem tarifa fixa. Spread de 1,5%, 0,9% ou 0,6% conforme o plano; reais na conta em até 1 hora.	Spreads altos, tarifas por operação e pouca transparência no câmbio bancário
Cofre Fiscal	Separa automaticamente uma porcentagem de cada recebimento para impostos (rende 100% do CDI), paga o DAS-MEI no vencimento e simula o Fator R.	Gastar o dinheiro do imposto antes do vencimento
Indie Contábil	Contabilidade online com contador dedicado: DASN-SIMEI para MEI; apuração, pró-labore e obrigações para ME/EPP (R\$ 129 a R\$ 169/mês).	Contabilidade cara, lenta e desconectada da conta
Indie Futuro	Caixinhas (100% a 105% do CDI, com FGC), Salário Indie (valor fixo mensal da PJ para a conta pessoal), Seguro Renda Protegida e Previdência PGBL/VGBL.	Renda irregular e ausência de 13º, FGTS e licença remunerada
Indie Cobranças	Links de pagamento (Pix, boleto e cartão em até 12x), cobrança recorrente, lembretes automáticos e Tap to Pay (o celular como maquininha).	Cobrança manual e inadimplência

Planos: Essencial (grátis), Pro (R\$ 39,90/mês) e Premium (R\$ 99,90/mês). Eles diferem em franquias (TED, boletos, notas), spread do câmbio, rendimento das Caixinhas, recursos exclusivos (Salário Indie, Tap to Pay, usuários adicionais) e canais de atendimento. O documento também define o que a Indie **não** faz (enviar dinheiro ao exterior, maquininha física, conta pessoa física, Lucro Presumido) e o que a assistente não deve fazer (recomendar investimentos, pedir senhas, falar mal de concorrentes).

3. Construção da base de perguntas e respostas

Fonte dos dados: mista. Os pares foram **gerados com apoio de LLM** (gpt-4o-mini, pelo proxy da disciplina) a partir do documento-fonte, passaram por **filtros automáticos** e um **LLM como juiz**, e uma amostra foi **revisada manualmente**. A geração usou LangChain com ChatPromptTemplate e with_structured_output (modelos Pydantic). O prompt de sistema traz o documento inteiro e as regras de qualidade: usar só fatos do documento, seguir as diretrizes da assistente, responder em 2 a 6 frases e nunca citar “o documento”.

Diversidade: a geração seguiu uma matriz de **24 temas × 6 estilos** de pergunta (direta, comparação, suporte, caso de uso, objeção e mensagem informal de WhatsApp), com 5 pares por combinação. Os temas incluem o que a Indie não oferece, os limites da assistente e perguntas fora do escopo, para que o modelo também aprenda a recusar e a redirecionar. Para evitar repetição, cada chamada recebia as perguntas já geradas no mesmo tema e 3 personas sorteadas de uma lista de 18 (psicóloga MEI, dev que recebe em dólar etc.).

Etapa	Pares	Observação
Geração	680	136 das 140 combinações; 4 falharam por limite de taxa do proxy
Limpeza e deduplicação	665	–15: duplicatas exatas e quase-duplicatas (TF-IDF de caracteres, cosseno $\geq 0,85$)
Checação de números	665	Nenhuma resposta com valor em R\$ ou percentual ausente do documento
LLM como juiz	634	597 avaliados e 31 reprovados (5,2%); 68 pares não avaliados (falhas do proxy) foram mantidos
Revisão manual	634	57 pares (amostra estratificada por tema, cerca de 9%), sem alterações
Base final	634	570 para treino e 64 para validação (10%)

Tabela 1. Etapas de construção da base (arquivo resumo_pipeline.json e checkpoints do notebook 02).

A base final cobre os 24 temas (10 a 30 pares cada) e os 6 estilos (95 a 113 pares cada). As perguntas têm, em média, 87 caracteres; as respostas, 252 (de 61 a 530). O formato é o mesmo do dataset de aula: um arquivo **.jsonl** com uma conversa por linha, na estrutura messages, com os papéis system, user e assistant:

```
{
  "messages": [
    {
      "role": "system",
      "content": "Você é a assistente virtual da Indie, o banco de quem trabalha por conta própria. [...] (1.074 caracteres)"
    },
    {
      "role": "user",
      "content": "A Indie faz transferência de grana pro exterior?"
    },
    {
      "role": "assistant",
      "content": "Atualmente, a Indie não oferece a opção de enviar dinheiro para o exterior. Isso está no nosso roadmap e deve ser disponibilizado em 2027. No momento, você pode receber pagamentos do exterior, mas não enviar."
    }
  ]
}
```

4. Fine-tuning: modelo base e hiperparâmetros

O pipeline adapta o notebook de aula *[fine_tuning_qwen3_aula.ipynb](#)*: Unsloth + TRL (SFTTrainer) com **PEFT/QLoRA**. O modelo base fica congelado em 4 bits e só os adaptadores de baixo rank são treinados. Com `train_on_responses_only`, a perda considera apenas as respostas da assistente, e não o prompt de sistema, que se repete em todos os exemplos. O treino rodou no Google Colab com uma **Tesla T4**: a máquina local não tem GPU NVIDIA, e a TPU oferecida pelo Colab não é compatível com Unsloth e bitsandbytes.

Parâmetro	Valor	Justificativa
Modelo base	unsloth/Qwen3-4B (4 bits)	Modelo da aula; bom em português; cabe numa T4 com folga
LoRA r / alpha / dropout	16 / 16 / 0	Capacidade suficiente para um domínio restrito; com rsLoRA, a escala é $\alpha/vr = 4$. Dropout 0 é o caminho otimizado do Unsloth
Módulos-alvo	q, k, v, o, gate, up, down	Todas as camadas lineares; as MLPs concentram boa parte do conhecimento factual
Parâmetros treináveis	33,0 M ($\approx 0,8\%$)	Relativo aos 4,0 B do modelo. O notebook mostra 1,3% porque conta os pesos de 4 bits empacotados (2 por byte)
Batch efetivo	$2 \times 4 = 8$	Batch por dispositivo $\times$ acumulação de gradiente
Épocas / passos	3 / 216	Base pequena: uma época são só 72 passos; a aula usava 1 época
Learning rate / scheduler	1e-4, cosine, warmup 5%	Valor da aula; com rsLoRA, a escala já é 4x
Weight decay / clipping	0,01 / 1,0	Regularização leve
Otimizador / comprimento	AdamW 8 bits / 1.024 tokens	Os exemplos têm menos de 700 tokens
Validação	10% (64 exemplos)	Avaliada a cada 20 passos; o melhor checkpoint pela perda de validação é restaurado ao final

Tabela 2. Configuração do treinamento (classe *Config* do notebook 03 e *treino_resumo.json*).

5. Resultado do treinamento

O treino levou **25,2 min** (216 passos). A perda de treino caiu de **2,57 para 0,47**, e a de validação, de **1,21 para 0,83**. O mínimo da validação aconteceu no **passo 140** (cerca de 1,9 época); depois disso, ela subiu levemente (0,86 a 0,88) enquanto a de treino continuava caindo. A queda da perda de treino em degraus no início de cada época (passos 72 e 144) é um sinal típico de memorização dos exemplos. É um overfitting leve, e o `load_best_model_at_end` restaurou o checkpoint do passo 140, que é o modelo publicado.




Figura 1. Perda de treino (azul) e de validação (vermelho) por passo. O ponto isolado no passo 216 é a avaliação do melhor checkpoint já restaurado.

6. Exemplos de respostas do modelo treinado

As 10 primeiras perguntas foram respondidas pelo modelo base (antes do treino) e pelo modelo ajustado (depois), com o mesmo prompt de sistema. As 3 últimas foram feitas ao modelo **carregado do Hugging Face Hub**, o que também confirma que a publicação funciona. Várias perguntas foram escritas de um jeito diferente das perguntas da base. A avaliação foi feita manualmente, comparando cada resposta com o documento-fonte.

#	Pergunta	Resposta do modelo ajustado	Avaliação
1	Quais produtos a Indie oferece?	A Indie oferece diversos produtos financeiros para profissionais independentes, como a Indie Conta PJ, Indie Notas, Indie Global, Cofre Fiscal, Indie Contábil, Indie Cobranças, Indie Futuro e serviços de câmbio.	Correta Lista os produtos (o “serviço de câmbio” é o Indie Global).
2	Qual a diferença entre o plano Pro e o Premium?	O plano Pro custa R\$ 39,90/mês e oferece funcionalidades como Pix ilimitado e gratuito, além de cobrança recorrente. Já o Premium, que custa R\$ 99,90/mês, inclui tudo do Pro, mas também permite a abertura de conta corrente no Banco Horizonte e conta de pagamento no Banco Horizonte, além de acesso ao Cofre Fiscal ilimitado.	Incorreta Inventa uma “conta corrente no Banco Horizonte” e um “Cofre Fiscal ilimitado”. O Premium difere em spread de 0,6%, 105% do CDI, cashback, usuários adicionais e gerente.
3	Sou tradutora e recebo em euro de clientes na Alemanha. Quanto a Indie cobra para converter?	A Indie cobra uma taxa de conversão de 0,6% para recebimentos em euro, que é bem baixa. Além disso, não há tarifa fixa mensal, então você pode escolher o que melhor atende suas necessidades.	Parcial 0,6% é o spread do Premium (Essencial: 1,5%; Pro: 0,9%). “Tarifa fixa mensal” mistura conceitos.
4	O dinheiro que fica parado na conta da Indie tem garantia do FGC?	Sim, o saldo da conta da Indie é coberto pelo FGC, que garante até R\$ 250 mil por CPF ou CNPJ por instituição emissora. Isso significa que, em caso de problemas financeiros, você pode contar com essa proteção para seus recursos.	Incorreta O saldo da conta não tem FGC; só Caixinhas e Cofre Fiscal têm. O modelo base acertava.

#	Pergunta	Resposta do modelo ajustado	Avaliação
5	Me ligaram dizendo ser da Indie e pediram o código da Indie Chave para cancelar uma compra. O que eu faço?	Não compartilhe sua senha ou código da Indie Chave com ninguém. A Indie nunca pedirá essas informações por telefone. Se você suspeitar de uma tentativa de golpe, bloqueie seu acesso à conta pelo app e entre em contato com o nosso suporte imediatamente.	Correta Segue as diretrizes de segurança.
6	vcs tem maquininha de cartao?	Não, a Indie não oferece maquininha de cartão. No entanto, você pode emitir notas fiscais e gerenciar cobranças diretamente pelo app.	Correta Não menciona o Tap to Pay.
7	Em qual ação eu deveria investir o dinheiro da minha empresa?	Não posso oferecer recomendações individuais de investimento. Para escolher ações ou outros investimentos, é importante consultar um contador ou um consultor financeiro qualificado. A Indie não fornece conselhos sobre investimentos.	Correta Recusa conforme as diretrizes.
8	Como faço para abrir um MEI pelo app?	Para abrir um MEI pelo app, você deve acessar a seção de 'Indie Abre MEI' no app. Lá, você pode seguir o passo a passo para abrir o MEI gratuitamente. O processo é rápido e leva cerca de 15 minutos.	Correta Gratuito e em cerca de 15 minutos, como no documento.
9	Consigo pagar um fornecedor nos Estados Unidos pela Indie?	Sim, você pode pagar fornecedores nos Estados Unidos pelo app da Indie. A funcionalidade permite que você envie Pix internacional, que é uma forma de pagamento rápida e segura para empresas que têm recebimentos do exterior.	Incorreta Inventa um "Pix internacional". A Indie não envia dinheiro ao exterior (roadmap para 2027).
10	Qual é a capital da Austrália?	A capital da Austrália é Canberra.	Incorreta Deveria recusar e redirecionar para os temas da Indie.
11*	Sou personal trainer e cobro mensalidade dos meus alunos. Como a Indie pode me ajudar?	A Indie pode ajudar você, pois oferece a Indie Cobranças, que permite criar links de pagamento e cobrança recorrente. Assim, você pode cobrar seus alunos de forma prática e automatizada, sem precisar gerenciar a cobrança manualmente.	Correta Poderia citar lembretes automáticos e Pix Automático.
12*	Quanto custa a declaração anual do MEI no plano Essencial?	No plano Essencial, a declaração anual do MEI é gratuita. Você pode fazer a declaração sem custo, mas é importante lembrar que a Indie não oferece serviços de planejamento tributário personalizado.	Incorreta No Essencial, a DASN-SIMEI custa R\$ 49; é gratuita no Pro e no Premium.
13*	Se eu cancelar o plano anual no meio do ano, recebo algum dinheiro de volta?	Sim, se você cancelar o plano anual no meio do ano, a Indie reembolsa a diferença proporcional do valor pago, proporcionalmente ao tempo que você utilizou o plano.	Correta Reembolso proporcional dos meses não usados.

Tabela 3. Respostas do modelo ajustado (temperatura 0,1). * Perguntas feitas ao modelo carregado do Hub. Placar: 7 corretas, 1 parcial e 5 incorretas.

Antes e depois: “Como faço para abrir um MEI pelo app?”

Modelo base (antes do treino)	Modelo ajustado (depois do treino)
Para abrir um MEI (Microempresa de Serviços) pelo app da Indie, siga os passos abaixo: 1. Baixe e instale o app da Indie no seu celular (Android ou iOS). 2. Faça o login no app, se já tiver conta. Se não tiver, crie uma conta. 3. Acesse a seção "Indie Abre MEI" no app. 4. Preencha os dados solicitados para a abertura do MEI, como: - Nome da empresa - CPF do representante - Endereço - Atividade econômica - Outras informações necessárias 5. Confirme os dados e aguarde a aprovação da Indie. 6. Receba o cadastro do MEI e confirme a abertura. Se você tiver dúvidas durante o processo, pode falar com o atendimento da Indie pelo app ou pelo site.	Para abrir um MEI pelo app, você deve acessar a seção de 'Indie Abre MEI' no app. Lá, você pode seguir o passo a passo para abrir o MEI gratuitamente. O processo é rápido e leva cerca de 15 minutos.

Tabela 4. O modelo base inventa um fluxo com “aguarde a aprovação da Indie” e traduz MEI como “Microempresa de Serviços”. O ajustado responde no tom da marca e com os fatos do documento.

O que o fine-tuning mudou. O efeito mais claro foi no **comportamento**: as respostas passaram de 757 para 202 caracteres em média, sem tabelas, títulos em markdown ou fórmulas como “Prezado cliente”, que o modelo base usava. Ficaram diretas e no tom definido para a Indie. Alguns fatos foram aprendidos (Abre MEI, reembolso proporcional, Indie Cobranças para mensalidades). Vale notar que o modelo base já partia de um bom patamar, porque o prompt de sistema lista os produtos e os preços dos planos (pergunta 1). Por outro lado, o modelo ajustado **trocou fatos que aparecem juntos** (FGC, planos) e **inventou funcionalidades** quando a pergunta fugia do que viu no treino (perguntas 2, 9 e 12).

7. Dificuldades encontradas

- **Limite de taxa do proxy.** Na primeira execução, 22 das 140 combinações falharam (6 chamadas em paralelo, 3 tentativas), justamente nos temas de segurança, limites da assistente e “o que a Indie não oferece”. Reduzir para 3 chamadas em paralelo com 5 tentativas resolveu quase tudo, mas 4 combinações ainda ficaram de fora e 68 pares da segunda rodada não passaram pelo juiz.
- **Lacuna no documento-fonte.** O documento não listava os requisitos do Indie Abre MEI. O gerador copiou os da abertura de conta e produziu **3 respostas afirmando que é preciso “CNPJ ativo” para abrir o MEI**. Nem o juiz nem a revisão amostral detectaram o erro, encontrado só numa análise posterior da base. O documento e o notebook 02 já foram corrigidos, mas optou-se por não regerar a base e retrainar. **A base publicada ainda contém essas 3 respostas**, registradas aqui como problema conhecido.
- **O LLM juiz erra nos dois sentidos.** Deixou passar o erro acima e reprovou pares corretos (por exemplo, afirmou que “o Premium não inclui o certificado A1”, quando inclui). Como sobravam pares, reprovar a mais foi aceitável, mas o juiz não substitui a revisão humana.
- **Fatos versus estilo.** O fine-tuning ensinou tom e formato rapidamente, mas não fixou fatos que aparecem poucas vezes e misturou fatos que aparecem juntos. O FGC está em 22 respostas, quase sempre ligado às Caixinhas, e o modelo passou a dizer que o saldo da conta também tem FGC. A recusa de perguntas fora do escopo não foi aprendida: havia só 10 exemplos desse tipo.
- **Ambiente.** O treino não roda localmente (sem GPU NVIDIA). No Colab, `trainer.evaluate()` chamado depois do treino falha nas versões recentes do transformers (“on_train_begin must be called before

on_evaluate”) e foi trocado por `trainer.state.best_metric`. Também houve ajustes de configuração no Hugging Face: o nome do secret HF_TOKEN e o nome de usuário do repositório, que não é o nome do token.

Próximos passos

- **Regerar e retreinar** com a versão atual do notebook 02, que corrige as 3 respostas, completa as 4 combinações e avalia os 68 pares pendentes.
- **Reforçar fatos críticos:** várias paráfrases por fato e pares contrastivos (“o saldo não tem FGC; as Caixinhas têm”), além de ampliar as perguntas fora do escopo de 10 para cerca de 50.
- **Ajustar o treino:** 2 épocas ou *early stopping* (o melhor ponto foi em 1,9 época) e testar $r = 32$.
- **Avaliação quantitativa:** um conjunto de teste fixo com respostas de referência, pontuado por juiz e por humano, antes e depois do treino.
- **RAG + fine-tuning:** usar o modelo ajustado para o comportamento (tom, formato, recusas) e buscar os fatos no documento-fonte na hora de responder. Preços e taxas mudam, e o fine-tuning mostrou não ser a forma confiável de guardá-los.

Conclusão

O ciclo completo foi executado de ponta a ponta: cenário de negócio, documento-fonte, base de 634 conversas no formato `messages`, fine-tuning com QLoRA sobre o Qwen3-4B, com validação e escolha do melhor checkpoint, e publicação do modelo e do dataset no Hugging Face com model card e dataset card. O resultado mostra, na prática, o que se espera de um fine-tuning com poucos dados: ele muda com eficiência o *comportamento* do modelo, mas não garante a fidelidade a fatos específicos.