

Documentação Técnica

Modelo de Classificação de Severidade de Sinistros de Trânsito — Óbito

Pipeline de Machine Learning de Ponta a Ponta sobre a base Infosiga.SP

Disciplina: Machine Learning — Pós-Graduação em Ciência de Dados e Big Data / Estatística — PUC Minas

Professor: Murilo Afonso Robiati Bigoto

Aluno: [Preencher]

Data: [Preencher]

Sumário

1. Visão Geral do Projeto
 2. Proposta de Implementação de Negócio
 3. Arquitetura de Dados e Engenharia
 4. Modelagem e Validação
 5. Interpretabilidade e Governança
 6. Formato de Deploy e MLOps
 7. Referências
-

1. Visão Geral do Projeto

1.1 Contextualização do problema

Os sinistros de trânsito constituem uma das principais causas de morte evitável no Brasil. O Instituto de Pesquisa Econômica Aplicada (IPEA) estimou o custo social anual em torno de R\$ 50 bilhões, sendo que sinistros com vítima fatal — embora representem menos de 5% das ocorrências — concentram aproximadamente 35% do custo total ([IPEA](#)

TD 2565). Em São Paulo, o sistema **Infosiga.SP** (Detran-SP, parceria com a Iniciativa Bloomberg para Segurança Viária Global) consolida o registro oficial dessas ocorrências sob a Lei Estadual de Dados Abertos (CC-BY 4.0), constituindo uma das bases públicas mais granulares do país.

1.2 Justificativa de negócio

A priorização de recursos finitos — fiscalização preventiva, equipes de resposta de emergência (SAMU, PMRv), intervenções de engenharia de tráfego — depende criticamente da capacidade de **identificar, em escala, perfis de sinistro com alta probabilidade de letalidade**. Análises cruzadas tradicionais (tabulação por município, tipo de via, faixa horária) capturam parte do sinal, mas não a interação simultânea de múltiplos fatores. Um modelo supervisionado bem calibrado fornece um **score contínuo de risco** que ordena os eventos por probabilidade de óbito, viabilizando regras operacionais de priorização auditáveis e replicáveis.

1.3 Objetivo técnico

Problema: classificação binária — prever se um sinistro registrado resultou em óbito ($qtd_gravidade_fatal \geq 1$), a partir de atributos observáveis no momento do registro (espaço-temporais, tipo de sinistro e veículos envolvidos).

População: sinistros confirmados (excluem-se as NOTIFICACAO, que não contêm dados de cena — 35,9% da base original). Após o recorte: **539.674 registros**, prevalência de óbito de **4,36%**.

Protocolo de validação: Out-of-Time 3-way — treino 2022–2024, validação temporal 2025 (tuning), teste OOT 2026 (intocado até a avaliação final). Esse desenho mitiga overfit temporal, identificado como o maior risco metodológico do projeto.

Métrica primária: *Precision-Recall AUC* (PR-AUC), apropriada para a alta razão de desbalanceamento (~24:1). Como métricas complementares: ROC-AUC, Brier (calibração) e recall em threshold operacional.

1.4 Limitações de escopo

Esta documentação assume três limitações como premissas declaradas:

1. **Ausência de variáveis comportamentais.** A base do Infosiga não contém os preditores que a literatura de segurança viária (OMS, ONSV) aponta como dominantes para letalidade: velocidade, uso de álcool, uso de cinto/capacete,

idade e papel da vítima. O modelo captura **risco estrutural/de exposição** (perfil pedestre × rodovia × madrugada), não risco comportamental.

- 2. **Modelo retrospectivo, não preditor de ocorrência.** A base contém apenas eventos registrados; não há espaço amostral de “não-sinistro”. Portanto, o modelo é apropriado para **priorização agregada** (alocar recursos onde a letalidade é mais provável), e não para predição individual de ocorrência futura.
- 3. **Subnotificação estrutural.** O Infosiga concentra registros com algum nível de gravidade; o dicionário oficial sinaliza que dados de vítimas ilenas têm cobertura parcial. A definição de alvo restrita ao óbito (e não a “qualquer vítima”) torna esse viés inócuo para o objetivo.

2. Proposta de Implementação de Negócio

2.1 KPIs gerados pelo modelo

Métricas oficiais avaliadas no **teste OOT 2026** (30.899 sinistros, 1.701 fatais):

KPI	Valor	Leitura
PR-AUC OOT	0,343	Discriminação ~6× acima da base aleatória (0,055)
ROC-AUC OOT	0,853	Capacidade discriminativa robusta
Recall @ threshold operacional	68,9%	1.172 dos 1.701 óbitos reais identificados
Precision @ threshold operacional	19,6%	1 em cada 5 alertas é um óbito real
Lift sobre base	3,5×	Densidade de óbito no top X% vs. aleatório
Taxa de alerta	19,4%	Volume operacional (~6.000 sinistros sinalizados em 4 meses)

2.2 Ação operacional mapeada

O score do modelo alimenta **três ações operacionais distintas**, ordenadas por nível de intervenção:

1. **Priorização de resposta de emergência (curto prazo).** Sinistros com score acima do threshold (top ~19% por probabilidade) recebem priorização de despacho do SAMU/PMRv. Mesma frota, melhor alocação.
2. **Fiscalização preventiva por perfil (médio prazo).** O ranking SHAP identifica os perfis estruturais mais letais (atropelamento em rodovia na madrugada, presença de motociclistas, municípios específicos do interior). Operações de fiscalização da PMRv e da CET concentram-se nesses perfis.
3. **Política de infraestrutura (longo prazo).** Municípios e trechos com alto risco estrutural — identificados pelo Target Encoding de `municipio` combinado com `tipo_via` — tornam-se candidatos prioritários a intervenções de engenharia de tráfego (semaforização, redutores, faixas elevadas, iluminação pública).

2.3 Regras de decisão e *guardrails*

Regra	Especificação
Threshold operacional	0,594 (calibrado por F2 sobre a validação 2025 — recall ponderado em peso 2× sobre precision, coerente com o uso de triagem).
Reavaliação do threshold	Trimestral, ou quando o volume diário de alertas extrapolar a capacidade operacional declarada.
Override humano	Análise da equipe técnica pode reclassificar qualquer alerta. O modelo é sistema de apoio à decisão , não decisão autônoma.
Flag de incerteza	Registros com <code>coord_valida = 0</code> ou imputação extensiva (≥ 3 campos imputados pela moda) recebem marcador no painel, sinalizando confiança reduzida na predição.
Bloqueio de inputs vazantes	Pipeline de produção rejeita qualquer registro que contenha colunas-rótulo (<code>qtd_gravidade_*</code> , <code>tipo_registro</code>) — <i>fail-fast</i> para evitar contaminação por leakage em re-treino.

2.4 Estimativa de impacto financeiro (ROI)

Premissas declaradas (todas conservadoras):

- Custo social médio por sinistro fatal: **R\$ 664.821**, base 2014 (IPEA TD 2565). Atualização IPCA 2014 2024 ($\approx 80\%$): **R\$ 1,2 milhão** por óbito.
- Captura do modelo no OOT 2026 (4 meses): 1.172 óbitos no top 19,4% da base.

- Premissa de eficácia operacional: priorização preventiva sobre perfis de alto risco reduz letalidade no grupo identificado em **5%** (estimativa conservadora; literatura Vision Zero internacional reporta reduções de 5–20% em programas comparáveis).

Cálculo:

- Óbitos evitáveis em 4 meses (premissa 5%): $1.172 \times 5\% \approx 59$
- Anualizado: **~177 óbitos** evitáveis
- Ganho social anual estimado: **$177 \times \text{R\$ } 1,2\text{M} \approx \text{R\$ } 212 \text{ milhões}$**
- Custo marginal de operacionalização: irrelevante em comparação, dado o reaproveitamento de equipes e infraestrutura já existentes (SAMU, PMRv, CET)

*Disclaimer técnico: o número de R\$ 212M/ano é referência de **ordem de magnitude**, condicionada à eficácia da execução operacional. A premissa de redução de 5% é a alavanca dominante do cálculo e deve ser auditada após o primeiro ciclo de implementação.*

3. Arquitetura de Dados e Engenharia

3.1 Fontes de dados

Origem primária: Infosiga.SP, sistema oficial de informações gerenciais de sinistros de trânsito do Estado de São Paulo, operado pelo Detran-SP em parceria com a Iniciativa Bloomberg para Segurança Viária Global. Dados disponibilizados sob licença [Creative Commons CC-BY 4.0](#) via Portal de Dados Abertos do Estado, com atualização nominal mensal.

Escopo deste projeto: tabela `sinistros` (cabecalho do evento). O ecossistema completo do Infosiga é relacional (`sinistros` `veículos` `pessoas` por `id_sinistro`), e o enriquecimento dessas tabelas irmãs é o vetor natural de evolução do modelo para uma próxima iteração.

3.2 Granularidade e janelas temporais

Atributo	Definição
Unidade da linha	1 sinistro confirmado (<code>tipo_registro</code> { <code>SINISTRO FATAL</code> , <code>SINISTRO NAO FATAL</code> }). Excluem-se as notificações sem dados de cena (artefato de cadastro — vide §3.3).
Janela de treino	2022-01 a 2024-12 — 406.710 linhas, prevalência de óbito 3,95%

Janela de validação (tuning)	2025-01 a 2025-12 — 102.065 linhas, prevalência 5,63%
Janela de teste OOT	2026-01 a 2026-04 — 30.899 linhas, prevalência 5,51%

Concept drift documentado nos próprios dados: a prevalência de óbito subiu de 3,95% (2022) para ~5,5% (2025–2026). Esse drift natural é parte do que torna a validação Out-of-Time *exigente* — e o OOT 2026 é, por construção, mais difícil que o treino, tornando as métricas reportadas conservadoras.

3.3 Tratamento de leakage estrutural

Dois focos de vazamento foram identificados e neutralizados antes da modelagem:

(a) Leakage de população — NOTIFICACAO . Registros do tipo NOTIFICACAO (35,9% da base original) representam *notificações sem dados de cena*: 98,4% têm todas as contagens de veículos/vítimas nulas. A taxa de óbito condicionada à ausência de detalhe de cena é 0,015% — contra 4,67% quando há detalhe. Mantê-los introduziria o atalho “registro vazio não-fatal”, que reflete o **processo de cadastro**, não o risco real.

Decisão: exclusão integral de NOTIFICACAO da base modelada.

(b) Leakage residual — categoria NAO DISPONIVEL . Em quatro campos (turno , tipo_via , circunscricao , administracao), o valor NAO DISPONIVEL aparece em fração marginal das linhas (0,2%–2,3%), mas com taxas de óbito anômalas (100%, 98%, 40%, 11% — todas acima da base de 4,36%). A origem é administrativa: registros fatais entram por fluxo distinto, que deixa esses campos em branco. **Decisão:** mapear NAO DISPONIVEL NaN somente nesses campos, e imputar pela moda do treino — sem indicador de missing, pois é a própria ausência que vaza.

Ambas as decisões foram corroboradas pelo relatório ydata-profiling, que sinalizou independentemente as correlações elevadas entre tipo_registro / qtd_gravidade_* e o alvo obito .

3.4 Estratégia de Feature Engineering

Camada	Operação	Tipo de cálculo
Drop	Identificadores (id_sinistro), rótulo (qtd_gravidade_* , tipo_registro), flags constantes (tp_sinistro_* esparsas — 11 colunas), alta	Determinístico

	cardinalidade ruidosa (<code>logradouro</code> , <code>conservacao</code>), redundantes (<code>cod_ibge</code>).	
Cleansing	Coordenadas: parse decimal vírgula ponto + validação por <i>bounding box</i> do Estado de SP + flag <code>coord_valida</code> . Hora: extração <code>HH:MM</code> inteiro 0– 23.	<i>Row-wise</i>
Features de negócio (7)	<code>total_veiculos</code> , <code>usuarios_vulneraveis</code> (pedestre + bicicleta + motocicleta), <code>envolve_moto</code> , <code>envolve_pedestre</code> , <code>envolve_pesado</code> (ônibus/caminhão), <code>multiplos_veiculos</code> , <code>madrugada</code> .	<i>Row-wise</i>
Encoding cíclico	<code>hora_sin</code> , <code>hora_cos</code> , <code>mes_sin</code> , <code>mes_cos</code> — captura a periodicidade 24h/12m.	<i>Row-wise</i>
Imputação	Numéricas: mediana do treino. Categóricas: moda do treino. Aplicada nos três splits a partir das estatísticas calculadas exclusivamente no treino.	<i>Train-only</i>
Cap de outliers	Winsorização ao percentil 99,9% das contagens de veículos (skewness $y_1 \approx 27$ no diagnóstico ydata- profiling).	<i>Train-only</i>
Encoding categórico	Baixa cardinalidade (5 colunas após Boruta): One- Hot. Alta cardinalidade (<code>municipio</code> , 645 valores): Target Encoding com smoothing=20. Ambos <i>fitted</i> dentro do pipeline do modelo, sobre o treino.	<i>Train-only,</i> leakage-safe

A disciplina de “estatística calculada *somente* no treino” é o mecanismo operacional concreto que sustenta a prevenção de data leakage neste projeto. Não é princípio retórico — é implementação verificável em três células do notebook (medianas, modas, caps).

4. Modelagem e Validação

4.1 Seleção rigorosa de features — Boruta

Por que Boruta: ao contrário de Feature Importance solta (que ordena, mas não testa significância), o Boruta opera por teste de hipótese: cria *shadow features* (cópias

embaralhadas das colunas reais) e mantém apenas as features que vencem consistentemente a melhor sombra ao longo de múltiplas iterações de Random Forest. É seleção fundamentada estatisticamente.

Configuração: BorutaPy com Random Forest base (200 árvores, `max_depth=7`, `class_weight='balanced'`), `max_iter=40`, amostra estratificada de **60.000 linhas do treino** (preserva prevalência de óbito; selecionar em amostra é prática padrão em alta volumetria — o que importa é o ranking, não estimativa pontual).

Resultado: 27 features confirmadas, 0 tentativas (zona cinzenta), 33 rejeitadas. A separação limpa indica que as confirmadas têm boa margem estatística sobre o ruído. A redução foi de **31 candidatas para 23 colunas originais finais** (após mapeamento dummy coluna).

Leitura técnica das rejeições:

- `regiao_administrativa` redundante a `municipio` (Target-Encoded) + coordenadas.
- `turno` redundante a `hora_num` + `hora_cos` + `madrugada` (a engenharia cíclica + flag noturna substituiu a discretização categórica).
- `mes_sin/cos` rejeitadas: não há sazonalidade mensal relevante de óbito após controlar pelas demais variáveis.
- `qtd_onibus` e `dia_da_semana`: sem sinal incremental.

4.2 Estratégia de validação Out-of-Time

A divisão temporal 3-way (treino 2022–24 / validação 2025 / teste OOT 2026) é a defesa principal contra duas armadilhas:

1. **Concept drift no alvo:** prevalência sobe ao longo do tempo (3,95% → 5,5%). Validação cruzada *in-time* superestimaria a generalização.
2. **Vazamento via estatísticas globais:** todas as estatísticas (medianas, modas, caps, target encodings) são *fitted* apenas sobre o treino, e aplicadas via transformação a val/teste.

A janela 2025 é usada para tuning e calibração do threshold; o teste OOT 2026 é **intocado até a avaliação final** — *single-shot*, sem vazamento de informação.

4.3 Desempenho comparado dos modelos

Treino realizado sobre 406.710 linhas, avaliação em val 2025 (102.065) e teste OOT 2026 (30.899):

Modelo	CV in-time (PR-AUC)	Val 2025 (PR-AUC)	OOT 2026 (PR-AUC)	ROC OOT	Brier OOT
Dummy (prior)	0,055	0,056	0,055	0,500	0,052
Regressão Logística (baseline)	0,272 ± 0,002	0,198	0,198	0,818	0,190
LightGBM	0,481 ± 0,012	0,198	0,240	0,848	0,167
XGBoost	0,485 ± 0,010	0,205	0,250	0,849	0,171
CatBoost (não tunado)	0,487 ± 0,012	0,274	0,307	0,855	0,171
Random Forest	0,421 ± 0,015	0,296	0,335	0,846	0,167
CatBoost (tunado — campeão)	—	0,342	0,343	0,853	—

4.4 Achado central — divergência CV vs Out-of-Time

A comparação revela um padrão metodologicamente relevante: **CV in-time superestima sistematicamente a performance dos GBMs**. LightGBM cai de 0,481 (CV) para 0,240 (OOT) — queda de 50%. XGBoost cai 48%. CatBoost cai 37%. Já a Random Forest cai apenas 20% (CV 0,421 OOT 0,335).

Causa-raiz identificada: GBMs configurados com `scale_pos_weight` agressivo e sem regularização adequada decoraram padrões temporais de 2022–24 que não generalizam para 2026 (drift natural). A Random Forest, com `max_depth=10`, `class_weight='balanced'` e `min_samples_leaf=20`, ficou estruturalmente mais conservadora.

Implicação operacional: o Optuna não poderia otimizar contra CV in-time (otimizaria uma métrica enganosa). A escolha de validar tuning contra **a janela 2025** ataca o overfit temporal na raiz: hiperparâmetros que sobrevivem ao salto temporal são preferidos sobre os que apenas decoram o treino.

4.5 Tunagem fina — Optuna com validação temporal

Modelo escolhido para tuning: CatBoost — melhor GBM no OOT não-tunado, melhor calibração (Brier 0,171), tratamento nativo de variáveis categóricas, e queda CV OOT menor dentre os gradient boosters (37% vs ~50% dos demais).

Configuração: TPESampler (otimização bayesiana), 30 trials, storage SQLite (estudo persistido — resiliente a interrupção). Early stopping com `eval_set = (val 2025, y_val)` dentro de cada trial: o próprio CatBoost decide quantas iterações usar por configuração, economizando custo computacional e prevenindo overfit por trial.

Espaço de busca:

Hiperparâmetro	Range	Justificativa
iterations	300–1.200	Limitado por early stopping
depth	4–8	CatBoost > 8 tende a overfitar
learning_rate	0,01–0,1 (log)	Espaço usual de GBM
l2_leaf_reg	1–30 (log)	Controle de overfit explícito
min_data_in_leaf	5–100 (log)	Anti-fragmentação
random_strength	0–10	Ruído nas decisões de split
bagging_temperature	0–1	Sub-amostragem de Poisson

Resultado: o CatBoost tunado superou o Random Forest no OOT 2026 (**PR-AUC 0,343 vs 0,335**), validando a tese de que regularização adequada + validação temporal fecham o gap GBM RF. O ganho não é apenas marginal em pontos: também há melhoria de calibração (probabilidades mais confiáveis) e capacidade nativa de lidar com `município`.

4.6 Definição do threshold de decisão ótimo

Critério: F2-score ($\beta=2$, recall ponderado 2× sobre precision), calculado sobre a validação 2025 em grade fina de 199 pontos entre 0,01 e 0,99.

Justificativa do F2: o uso operacional é triagem para priorização. O custo de um *falso negativo* (não sinalizar um sinistro que terá óbito — não priorizar resposta — potencial vida perdida) é radicalmente assimétrico ao custo de um *falso positivo* (alarme falso — equipe atendeu um caso menos grave). F2 incorpora essa assimetria sem precisar declarar uma matriz de custos explícita.

Threshold escolhido: $t^* = 0,594$.

Performance no OOT 2026 (single-shot, intocado até aqui):

Métrica	Valor
Recall (óbitos capturados)	68,9% (1.172 dos 1.701 óbitos reais)
Precision (alertas certos)	19,6%
F2-score	0,458
Taxa de alerta	19,4% (5.991 dos 30.899 sinistros)
Lift sobre base	3,5×

Matriz de confusão OOT 2026:

	Previsto: não-fatal	Previsto: fatal
Real: não-fatal	TN = 24.379	FP = 4.819
Real: fatal	FN = 529	TP = 1.172

Síntese executiva: filtrando os 19,4% sinistros mais prováveis pelo modelo, captura-se 68,9% das fatalidades ocorridas — densidade 3,5× superior à aleatória. O modelo entrega, na prática, uma redução de ~80% no volume operacional necessário para varrer ~70% das fatalidades.

5. Interpretabilidade e Governança

A interpretabilidade não é entregue como camada opcional sobre o modelo: é parte do produto. As predições do CatBoost são decompostas via SHAP (*SHapley Additive exPlanations*), técnica fundamentada na teoria dos jogos cooperativos que atribui a cada feature uma contribuição aditiva ao desvio da predição em relação à média do modelo.

5.1 Importância global das features

Tabela das 15 features com maior impacto médio absoluto no score (`|SHAP|` médio), calculada sobre amostra de 2.000 sinistros do teste OOT 2026:

#	Feature	<code> SHAP </code> médio	Direção dominante
---	---------	------------------------------	-------------------

1	qtd_pedestre	0,345	(artefato de média — vide §5.2)
2	coord_valida	0,283	flag de qualidade do registro
3	qtd_automovel	0,243	carro reduz risco vs. moto/pedestre
4	tipo_local_NAO_DISPONIVEL	0,231	+0,059 — perfil mais letal
5	usuarios_vulneraveis	0,205	proxy de exposição vulnerável
6	hora_cos	0,204	sinal cíclico horário
7	tp_sinistro_primario_COLISAO	0,202	colisão <i>reduz</i> risco vs. base
8	administracao_PREFEITURA	0,187	vias municipais menos letais
9	municipio	0,160	Target Encoding — geografia
10	qtd_motocicleta	0,150	exposição de motociclistas
11	tipo_local_PUBLICO	0,136	+0,038 — perfil mais letal
12	tp_sinistro_primario_ATROPELAMENTO	0,119	+0,051 — empurra para fatal
13	qtd_caminhao	0,112	veículo pesado eleva risco
14	tipo_via ESTRADAS E RODOVIAS	0,108	rodovia eleva risco (vide §5.2)
15	tp_sinistro_primario_NAO_DISPONIVEL	0,106	sinal residual

Agrupamento por bloco semântico do impacto observado:

- **Tipo de envolvimento humano:** `qtd_pedestre` , `usuarios_vulneraveis` , `envolve_pedestre` — atropelamento e usuários vulneráveis são o eixo dominante.
- **Tipologia do sinistro:** `tp_sinistro_primario_ATROPELAMENTO` (positivo), `tp_sinistro_primario_COLISAO` (negativo) — alinhado com a EDA.
- **Cenário físico:** `tipo_via_ESTRADAS E RODOVIAS` (rodovia eleva), `administracao_PREFEITURA` (municipal reduz), `tipo_local_PUBLICO` .
- **Geografia agregada:** `municipio` (Target-Encoded) captura risco residual por município que coordenadas não capturam — particularmente importante para municípios atravessados por rodovias federais.
- **Período:** `hora_cos` , `madrugada` — período noturno/madrugada eleva.
- **Qualidade do registro:** `coord_valida` aparece como #2 — alerta de governança (vide §5.4).

5.2 Nuance metodológica — lendo o sinal do `mean_shap`

Para features *one-hot-encoded* com prevalência baixa (e.g., `tipo_via_ESTRADAS E RODOVIAS` , ativa em ~9% dos registros), o `mean_shap` calculado sobre toda a amostra **não reflete diretamente a direção do efeito**. Para a vasta maioria das observações onde o *dummy* = 0, o SHAP retorna um valor pequeno e negativo (a ausência de rodovia “puxa para baixo” relativamente à média), o que arrasta o `mean_shap` agregado para o negativo. Quando o *dummy* = 1, o SHAP é grande e positivo — visível no plot *beeswarm* como pontos vermelhos à direita.

Recomendação prática para análise: use `mean |SHAP|` para *ranking de importância* e o gráfico *beeswarm* (ou *waterfall* em casos individuais) para *direção do efeito*. Não confundir agregação com causalidade local.

5.3 Análise local — caso ilustrativo (sinistro de teste #7036)

Selecionou-se o sinistro do conjunto OOT 2026 com maior probabilidade prevista entre os casos efetivamente fatais (TP de alta confiança), para demonstrar a decomposição local da predição:

Contexto observado:

Atributo	Valor
Hora	3h00 (madrugada)
Tipo de sinistro	ATROPELAMENTO
Tipo de via	VIAS URBANAS

Tipo de local	PÚBLICO
Administração	PREFEITURA
Município	REGISTRO (Vale do Ribeira/SP)
Pedestres envolvidos	1
Outros veículos envolvidos	1
coord_valida	0 (coordenadas originais inválidas)
Probabilidade prevista de óbito	0,9993
Resultado real	Fatal (rótulo = 1)

Tradução para stakeholders não-técnicos: “Para um atropelamento ocorrido às 3h da madrugada em via urbana do município de Registro/SP, o modelo somou contribuições positivas robustas das features `tp_sinistro_primario_ATROPELAMENTO`, `madrugada`, `envolve_pedestre`, e do efeito geográfico capturado pelo Target Encoding de `municipio` (Registro é atravessado pela BR-116 / Régis Bittencourt, com perfil estrutural de alta letalidade). A probabilidade final atingiu 99,9% — o modelo identificou corretamente o caso como fatal.”

A decomposição via *waterfall plot* mostra a soma das contribuições, partindo do log-odds basal ($E[f(x)] \approx -1,4$ — espelhando a prevalência de ~5% da janela 2026) e somando até o log-odds final correspondente à probabilidade 0,999. Cada feature aparece com sua contribuição individual, permitindo conversa direta com a área de operações sobre quais fatores moveram a predição.

5.4 Governança via interpretabilidade

A camada SHAP cumpre função operacional dupla:

(a) Auditoria de novos deploys. A cada re-treino, o ranking SHAP top-20 é comparado ao ranking da versão atual em produção. Mudanças bruscas na importância relativa, ou inversões de direção de uma feature dominante, disparam revisão técnica antes da promoção. É uma camada de **detecção de drift conceitual silencioso** — mudanças no que o modelo aprendeu, não necessariamente nos dados de entrada.

(b) Transparência regulatória. O ranking + direções por feature + uma análise local por categoria de alerta compõem o artefato mínimo de explicabilidade arquivado por versão do modelo, garantindo conformidade com práticas emergentes de governança de IA aplicadas ao setor público.

Alerta específico deste modelo: `coord_valida` (qualidade do dado de coordenadas) aparece como segunda feature mais importante. Isso indica que **a qualidade do cadastro tem peso preditivo significativo** — o modelo, em última análise, também aprendeu a ler a integridade do registro. Esse achado deve ser comunicado à área de cadastro do Detran como insumo para melhoria de processo.

6. Formato de Deploy e MLOps

6.1 Padrão de inferência: batch diário

A operação real do modelo — priorização de fiscalização, alocação de equipes de resposta de emergência, estudos territoriais para política pública — **não exige SLA de milissegundos**. Inferência em batch (diária sobre os registros ingeridos no dia anterior) é mais barata, mais auditável e mais alinhada à cadência de decisão das equipes consumidoras do que uma API real-time.

A saída diária é uma tabela `sinistros_scored` com schema (`id_sinistro`, `data_processamento`, `prob_obito`, `alerta_flag`, `top3_shap_features`) , consumida por painel BI do Detran e/ou exposta via API simples (CRUD-style) para sistemas operacionais (CAD do SAMU, painel da PMRv).

6.2 Arquitetura de implantação — Medallion + containerização

Camada	Função	Tecnologias
Bronze	Ingestão diária do extrato Infosiga (Parquet bruto, sem transformação)	S3 / ADLS / GCS
Silver	Pipeline de feature engineering replicando <i>exatamente</i> o notebook, consumindo artefatos congelados do treino (<code>medianas.json</code> , <code>modas.json</code> , <code>caps.json</code>)	Spark / Pandas job containerizado
Gold	Tabela de score: predição + flag operacional + top-3 SHAP por linha	Delta Lake / Iceberg / Athena

O modelo é distribuído como container Docker contendo:

- `preprocessor.pkl` (`ColumnTransformer` ajustado no treino)
- `champion.cbm` (CatBoost serializado nativo)

- medianas.json , modas.json , caps.json (estatísticas do treino — *nunca* recalculadas em produção; isso é parte do contrato anti-leakage)
- requirements.txt com versões pinadas
- score.py (ponto de entrada CLI)

6.3 Infraestrutura — opção sugerida

Recomendação: Databricks (medallion nativo, governança simplificada). Alternativa equivalente em AWS:

Componente	AWS	Databricks
Storage	S3 + Glue Catalog	DBFS / Unity Catalog
Container Registry	ECR	Databricks Repos
Orquestração	Step Functions / MWAA (Airflow)	Databricks Workflows
Compute	ECS Fargate (sob demanda)	Job cluster
Acesso analítico	Athena + QuickSight	Databricks SQL
Custo estimado	< R\$ 500/mês para volume diário	< R\$ 800/mês (cluster mínimo)

A escolha final depende do ecossistema já adotado pelo Detran-SP. Ambas as opções são tecnicamente equivalentes para este caso de uso.

6.4 Pipeline de monitoramento

Data Drift (covariate shift) — PSI (Population Stability Index):

Métrica	Threshold	Ação
PSI < 0,10	OK	Apenas logar
$0,10 \leq \text{PSI} < 0,25$	Atenção	Notificar time de modelagem
PSI $\geq 0,25$	Crítico	Acionar revisão imediata; bloquear score

Calculado mensalmente sobre as top-10 features por |SHAP|: qtd_pedestre , coord_valida , qtd_automovel , tipo_local , usuarios_vulneraveis , hora_cos , tp_sinistro_primario , administracao , municipio (Target-Encoded como numérica), qtd_motocicleta .

Concept Drift (prior shift): janela móvel de 30/90 dias da prevalência observada de óbito e do PR-AUC sobre o rótulo confirmado (com defasagem temporal de ingestão de ~60 dias para confirmação dos óbitos). **Este projeto já documentou drift natural na prevalência:** 3,95% (2022) 5,63% (2025) 5,51% (2026). O monitor é capaz de detectar continuação ou intensificação dessa tendência.

Calibração: Brier score por trimestre. Degradação relativa > 10% dispara revisão de calibração (via *Platt scaling* ou regressão isotônica) sem necessariamente exigir re-treino completo.

6.5 Estratégia de re-treino e governança

Item	Política
Cadência mínima de re-treino	Mensal
Cadência por evento	Disparado por qualquer alerta crítico de drift ou degradação > 10% em métrica primária
Gate de promoção	Nova versão só vai para produção se OOT PR-AUC ≥ versão atual em janela equivalente (4 meses)
Artefatos arquivados por versão	Hash do dataset (SHA-256), <code>study.best_params</code> do Optuna, ranking SHAP top-20, <code>champion.cbm</code> , métricas OOT
Versionamento	MLflow Registry (ou DVC) com rótulos <code>staging</code> / <code>production</code> / <code>archived</code>
Aprovação	Promoção a produção requer revisão técnica (ranking SHAP) e operacional (impacto no volume de alertas)

Esse desenho replica em produção o protocolo metodológico do projeto: **toda nova versão passa pelo mesmo crivo Out-of-Time que a versão original**, garantindo que o ciclo de re-treino não introduza regressão silenciosa.

7. Referências

1. **Infosiga.SP — Detran-SP.** Sistema de informações gerenciais de sinistros de trânsito do Estado de São Paulo. Disponível em: <https://www.infosiga.sp.gov.br>. Licença CC-BY 4.0.

2. **CARVALHO, C. H. R. de.** *Custos dos acidentes de trânsito no Brasil: estimativa simplificada com base na atualização das pesquisas do Ipea sobre custos de acidentes nos aglomerados urbanos e rodovias*. Texto para Discussão Ipea nº 2565. Brasília: IPEA, 2020. Disponível em:
<https://www.ipea.gov.br/atlasviolencia/arquivos/artigos/7018-td2565.pdf>.
3. **KURSA, M. B.; RUDNICKI, W. R.** Feature Selection with the Boruta Package. *Journal of Statistical Software*, v. 36, n. 11, 2010.
4. **LUNDBERG, S. M.; LEE, S.-I.** A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
5. **AKIBA, T. et al.** Optuna: A Next-generation Hyperparameter Optimization Framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 2019.
6. **DOROGUSH, A. V.; ERSHOV, V.; GULIN, A.** CatBoost: gradient boosting with categorical features support. *arXiv:1810.11363*, 2018.
7. **World Health Organization (WHO).** *Global status report on road safety 2023*. Genebra: WHO, 2023.

Documento gerado a partir do pipeline de Machine Learning end-to-end implementado em Jupyter Notebook (Componente A). Todas as métricas reportadas decorrem de execução real sobre a base Infosiga.SP — janelas temporais 2022-01 a 2026-04.