



Pontifícia Universidade Católica de Minas Gerais

PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
PRÓ-REITORIA DE PESQUISA E PÓS-GRADUAÇÃO
DIRETORIA DE EDUCAÇÃO CONTINUADA

PLANO DE ENSINO

DISCIPLINA: MACHINE LEARNING

“nome da disciplina conforme previsto no projeto pedagógico do curso”

CURSO: CIÊNCIA DE DADOS E BIG DATA / ESTATÍSTICA PARA CIÊNCIA DE DADOS

“nome do curso conforme previsto no projeto pedagógico do curso.”

PROF (A): MURILO AFONSO ROBIATI BIGOTO

“nome completo do professor titular.”

CARGA HORÁRIA TOTAL (sala de aula + trabalho orientado): **24hrs/a**

CH conforme previsto no projeto pedagógico do curso. Incluir carga horária de “sala de aula” e do trabalho orientado; Exemplo **24hrs/a + 04 TO**.

TRABALHO ORIENTADO (descrição das atividades extracurriculares): **Não Há**

“É a carga horária complementar da disciplina. A carga horária externa registrada na disciplina compreende o trabalho acadêmico efetivo realizado pelo discente, sob a supervisão do professor, mas fora do horário da aula.”

EMENTA (conforme Projeto Pedagógico):

Processo de aprendizagem de máquina. Feature engineering. Técnicas e algoritmos de aprendizado supervisionado e não-supervisionado. Modelos ensemble. Métricas e avaliação de modelos. Explicabilidade, interpretação de métricas e validação cruzada com IA Generativa. Prompts para identificação e criação de features relevantes. Projeto prático.

“A ementa traz os pontos essenciais do conteúdo programático da disciplina. Deve ser idêntica à do Projeto Pedagógico do Curso.”

UNIDADES DE ENSINO (Conteúdo Programático):

“Os professores devem detalhar os conteúdos apresentados na ementa com a organização e hierarquização dos assuntos que serão trabalhados em módulos. Assim, os temas, conceitos e conhecimentos serão especificados e divididos entre os diversos pontos abordados ao longo da disciplina. São os conteúdos contemplados durante as aulas que compõem as diretrizes curriculares e são determinados para o estudo durante o ano. Deve ser detalhado juntamente com os pontos principais a serem abordados (objetivos, metodologia, avaliação, entre outros).”

Unidade 1 – Processo de Aprendizado de Máquina



Pontifícia Universidade Católica de Minas Gerais

1.1 – Introdução ao ML: Definições, tipos de aprendizado e paradigmas.

1.2 – Ciclo de vida de um projeto de dados.

1.3 – Formulação de problemas: Traduzindo dores de negócio em tarefas de ML.

Unidade 2 – Feature Engineering (Engenharia de Atributos)

2.1 – Tratamento de variáveis numéricas e categóricas (Encoding e Scaling).

2.2 – Imputação de dados faltantes e tratamento de outliers.

2.3 – Criação de novos atributos a partir de conhecimento de domínio.

2.4 – Técnicas de seleção de atributos (Filter, Wrapper e Embedded methods).

Unidade 3 – Técnicas e Algoritmos de Aprendizado Supervisionado e Não-Supervisionado

3.1 – Modelos Lineares (ex.: Regressão Linear, Logística e Regularização (Lasso/Ridge)).

3.2 – Modelos Lineares (ex.: Regressão Linear, Logística e Regularização (Lasso/Ridge)).

3.3 – Modelos Clássicos (ex.: Árvores de Decisão, KNN e Support Vector Machines (SVM))

3.4 – Agrupamento (Clustering): K-Means, DBSCAN e Hierárquico.

3.5 – Redução de dimensionalidade com PCA.

Unidade 4 – Modelos Ensemble (Aprendizado por Comitê)

4.1 – Fundamentos de Ensemble: Por que combinar modelos?

4.2 – Bagging: Random Forest e o conceito de amostragem bootstrap.

4.3 – Boosting: Funcionamento do Gradient Boosting, XGBoost e LightGBM.

4.4 – Combinando modelos de diferentes naturezas.

Unidade 5 – Métricas e Avaliação de Modelos

5.1 – Métricas de Classificação: Acurácia, Precisão, Recall, F1-Score e AUC-ROC.

5.2 – Métricas de Regressão: MAE, MSE, RMSE e R2.

5.3 – Análise de resíduos e diagnóstico de erros.

5.4 – Matriz de Confusão e curvas de ganho/elevação.

Unidade 6 – Explicabilidade, Interpretação e Validação com IA Generativa

6.1 – Introdução à IA Explicável.



Pontifícia Universidade Católica de Minas Gerais

6.2 – Métodos de interpretação (SHAP).

6.3 – Validação Cruzada (K-Fold e Stratified)

6.4 – IA Generativa na Validação: Uso de LLMs para gerar relatórios de diagnóstico e interpretar criticamente as métricas de performance.

Unidade 7 – Prompts para Identificação e Criação de Features Relevantes

7.1 – Engenharia de Prompts (Prompt Engineering) para Cientistas de Dados.

7.2 – Brainstorming de variáveis latentes: Usando a IA para sugerir atributos baseados no contexto do setor.

7.3 – Automação de pré-processamento via prompts e geração de código para transformações de dados.

Unidade 8 – Projeto Prático (Case Real)

8.1 – Definição do Case Real: Escolha do dataset e objetivo.

8.2 – Execução do Pipeline completo: Da extração à explicabilidade.

8.3 – Redação Técnica: Discussão sobre o estado da arte em ML.

8.4 – Documentação e Apresentação de Resultados.

OBJETIVOS/MÉTODOS DIDÁTICOS:

“Os objetivos (geral e específico) podem ser considerados os resultados esperados ou metas definidas, indicando aquilo que o(a) estudante deverá ser capaz de realizar como consequência das atividades propostas no componente curricular. Os objetivos envolvem os assuntos descritos na ementa e apresenta a função de tornar possível a sua execução. Considerando a diversidade de métodos didáticos, o(a) professor(a) deve especificar os recursos que serão eventualmente utilizados como quadro branco, lousa interativa, aparelho multimídia, softwares, celulares, tablets, vídeos, veículos de transporte, obras de arte, equipamentos, materiais de consumo, entre outros.”

O objetivo da disciplina é capacitar o estudante a compreender e executar o ciclo completo de um projeto de Machine Learning, desde a concepção do problema e engenharia de atributos até a avaliação crítica de modelos. A disciplina foca na aplicação prática de algoritmos supervisionados e não-supervisionados, integrando o uso de IA Generativa como ferramenta de suporte para o aumento de produtividade no desenvolvimento de features e na interpretação de métricas complexas. As aulas serão expositivas e dialogadas, acompanhadas de demonstrações técnicas em ambiente de programação (Notebooks) e laboratórios práticos para a resolução de problemas reais.

DISTRIBUIÇÃO DE PONTOS / CRITÉRIOS DE AVALIAÇÃO:

“Os processos de avaliação contemplados no plano de ensino são as formas de medir a aprendizagem dos estudantes. Então, os professores devem especificar e detalhar quais os critérios e informações sobre as avaliações, como trabalhos e provas a serem realizados, as datas programadas e a atribuição de notas aos alunos”

DISTRIBUIÇÃO DE PONTOS / CRITÉRIOS DE AVALIAÇÃO: A avaliação da disciplina será composta por três pilares principais, totalizando 100 pontos, com foco na aplicação prática e capacidade analítica do estudante:



Pontifícia Universidade Católica de Minas Gerais

Trabalho Final - Montagem de Case Real (50 pontos): Desenvolvimento prático de um pipeline completo de Machine Learning aplicado a um problema real de mercado. Serão avaliados: a fundamentação na escolha dos algoritmos, o rigor técnico na feature engineering assistida por IA e a performance final do modelo.

Documentação do Trabalho Final (20 pontos): Elaboração de um relatório técnico detalhando todas as etapas do projeto e as decisões de modelagem. Inclui a organização do código (Notebooks) e a qualidade dos prompts utilizados para a criação de atributos e interpretação de métricas.

Redação Técnica (10 pontos): Produção de um texto dissertativo sobre um tópico contemporâneo de Machine Learning (ex: Ética em IA, Explicabilidade ou o impacto da GenAI no fluxo de dados). Avalia-se a clareza conceitual e a capacidade de síntese.

Participação - Pontos Extras (20 pontos): Pontuação atribuída por engajamento ativo em discussões em sala, desempenho em quizzes de perguntas rápidas de machine learning e contribuições nos fóruns da disciplina.

REFERÊNCIAS BIBLIOGRÁFICAS

“Constituem-se naquelas referências bibliográficas e fontes de consultas que serão efetivamente utilizadas em situações, nas quais o(a) professor(a) se baseia para o desenvolvimento dos conteúdos”

- FACELI, K. et al. *Inteligência artificial: Uma abordagem de aprendizado de máquina*. 2011.
- GÉRON, A. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*.
- 2.2 Aprendizado de Máquina: Uma visão geral - Apenas a Seção 2.2 - <https://bdta.abcd.usp.br/item/003152937>
- 2.2 Inteligência artificial: uma abordagem de machine learning - Apenas a Seção 2.2 - <https://www.teses.usp.br/teses/disponiveis/95/95131/tde-22112025-113709/pt-br.php>
- *Introdução ao machine learning com Python: Um guia para cientistas de dados*, por Andreas C. Müller e Sarah Guido
- *Machine learning para hackers*, de Drew Conway e John Myles White
- *Inteligência Artificial: Uma abordagem moderna* por Stuart Russell e Peter Norvig